


P: 



Rationality: from AI to Zombies — Eliezer Yudkowsky

Вперше опубліковано як записи у блогах Overcoming Bias та Less Wrong, з 2006-го по 2009-й рік.

Цей переклад — фанатський проєкт, що створюється з 2023-го року, з люб'язного дозволу авторів. Не для продажу. Не для комерційного використання. Всі права на оригінальний твір належать Елієзеру Юдковські



Від перекладача — Данила Жирка

Красно дякую друзям зі спільноти pre post, які терпляче і вичерпно роз'яснювали складні моменти у книзі щоразу, коли я цього потребував.

Завдяки вам у перекладі куди менше помилок.



Від дизайнера — Дениса Лук'яненка

Долучитися до перекладу, вказати на помилку або просто подивитись, як все влаштовано можна на GitHub:

github.com/DanTheStrongworded/rationality-ua-public



Зверстано у Сторінкаторі 1.0.0

Гарнітури: EB Garamond, Geologica.

github.com/denlukia/storinkator



Версія перекладу 2.0 · 3 травня 2026

Зміст

6	Передмова
10	Біаси: Вступ від Роба Бенсінгера
16	Передбачувані помилки
17	Ігнорування масштабу
20	Бойове мистецтво раціональності
23	Доступність
26	Що таке біас?
29	Обтяжливі подробиці
34	Що ми маємо на увазі під «раціональністю»
40	Омана планування
44	Чому істина?
47	Відчувати — раціонально
51	Лінзи, крізь які видно власні помилки
54	Хибні уявлення
55	Вимагайте оренду від своїх переконань (у розмірі очікуваного досвіду)
59	Притча про науку та політику
64	Віра у віру
68	Релігійні твердження та їхня неспростовність
73	Сповідувати та вболівати
76	Віра напоказ
78	Удавання мудрості
82	Знак «ОПЛЕСКИ»
86	Навчитися помічати спантеличення
87	Зосередити свою невизначеність
90	Що таке свідчення?
94	Свідчення наукові та раціональні. Процесуальні докази

98	Скільки потрібно свідчень?
102	Зухвалість Айнштейна
105	Лезо Оккама
110	Сила раціоналіста
113	Відсутність свідчень є свідченням відсутності
116	Закон збереження очікуваних свідчень
119	Ретроспектива знецінює науку
122	Ілюзія прозорості: чому вас не розуміють
125	В очікуванні коротких умовивідних дистанцій
128	Загадкові відповіді
129	Вигадані пояснення
132	Вгадати вчительський пароль
136	Наука напоказ
138	Вигадана причиновість
143	Семантичні стоп-сигнали
147	Загадкові відповіді на загадкові питання
151	Емерджентність: чи потрібна вона?
154	Скажіть складності «Ніт»
158	Упередження позитивного: зазирнути в темряву
162	Закономірна невизначеність
166	Моя наївна й несвідома юність
170	Прогавлені уроки історії
172	Зробити історію доступною
175	Пояснити? Поклонятися? Чи проігнорувати?
177	«Наука» як гальмівник допитливості
180	Справжня частина вас
185	ІНТЕРЛЮДІЯ

Передмова

Перед вами добірка щоденних дописів, на написання яких у мене пішло два роки. Оглядаючись у минуле, я бачу, що скоїв багато дурниць. До цього я ставлюся цілком спокійно. Якби я озирався і не бачив тих численних помилок, це означало б, що ні моя писанина, ні моє розуміння не покращилися з 2009 року. *Йой* — вигук, який сповіщає про те, що ми покращили свої переконання і методи. А тому озирнутися у минуле і не побачити своїх помилок — означає, що з того часу ви нічого не навчилися і не змінили свою думку.

Я припустився помилки, коли протягом цих двох років писав свої дописи, щоб допомогти людям розв'язати масштабні, складні і важливі проблеми, а не краще поратися коло їхніх повсякденних справ. Я віддавав перевагу прикладам вражаючих та абстрактних проблем.

Оглядаючись у минуле, я розумію: це була друга за величиною помилка у моєму підході. Вона ж перегукується із *першою* найбільшою помилкою: я не усвідомлював, що головна проблема у вивченні цього цінного способу мислення полягає у тому, щоб зрозуміти, як застосовувати його на практиці, а не як вивчити теорію. Я не розумів, що саме практичній частині слід приділяти більше уваги. Що ж, із цього приводу можу лише сказати «Йой» та «От трясця».

Безумовно, іноді ці масштабні проблеми дійсно не з пальця висмоктані і дуже важливі. Та це аж ніяк не змінює засадничої істини: без вправлянь вам ніяк не опанувати навички, і що віддаленіша річ, на якій практикують, то важче її опанувати. (У Центрі прикладної раціональності вже працюють над виправленням цієї моєї грубої помилки у більш систематичний спосіб.)

Моя третя помилка: я забагато уваги приділяв раціональним переконанням і замало — раціональним діям.

Четверта помилка: мені слід було краще структурувати матеріал, котрий я висвітлював у ланцюжках. Зокрема, варто було раніше

створити вікі-сайт і полегшити прочитання своїх дописів у ланцюжках.

Але *цю* помилку можна принаймні виправити. У цьому виданні Роб Бенсінгер упорядкував дописи якомога ретельніше, не переписуючи фактичний матеріал (хоча дещо він таки переписав).

П'ятою помилкою було відверто (як мені здавалося) говорити про безглуздість тих ідей, які мені видавалися дурними. Я намагався уникати хиби, відомої як бульваризм, коли дискусія *починається* з того, наскільки дурна людина, яка вірить у щось. Я завжди спочатку обговорював проблему, а вже потім казав: «Ось тому це — дурня». Але у 2009 році питання, чи варто бути в оточенні людей, які висловлюють своє презирство до гомеопатії, було для мене відкритим. Я вважав — і досі вважаю — що є одна прикра проблема: чемне ставлення до ідей багато хто на якомусь рівні сприймає як «мені нічого не буде, якщо я скажу, що в це вірю; я ж не втрачу свого статусу, якщо скажу, що вірю в гомеопатію». І саме тому глузливий сміх коміків іноді допомагає людям прокинутися від цього сну.

Сьогодні, гадаю, я б написав таке у більш м'якій формі. Грубість виконала свою функцію, і, думаю, знайшлися люди, яким вона була помічною. Але тепер я серйозніше ставлюся до ризику формування спільнот, в яких відкрито висміювати та зневажати низькостатусні погляди тих, хто поза цією спільнотою, — нормальна та очікувана реакція.

Попри цю помилку, з радістю скажу, що мої читачі *не* використовували мою риторику як привід для цькування чи приниження. (Особлива подяка Скотту Александру — людині, яка є більш приємною за мене, чудовому письменнику у галузі раціональності. У нетоксичності культури *Less Wrong* є і його заслуга.)

Якщо ви озираєтеся у минуле і кажете, що припустилися помилки, це означає, що у вас були цілі. Тож якою була моя мета?

Існує один цінний спосіб мислення, якого не навчають у школі, навіть у наш час. Його взагалі не навчають систематично. Засвоюють

його ті, хто вирости на книжках на кшталт «Та ви жартуєте, містере Фейнман!»¹ або мали виняткового вчителя у старших класах.

Цей спосіб мислення відомий тим, що перегукується з наукою та експериментальним методом. З тією наукою, коли ви виходите поглянути на всесвіт, а не вигадуєте щось, коли кажете «Йой» і відмовляєтеся від поганої теорії, якщо вона не відповідає результатам експериментів.

Але цей спосіб мислення не обмежується навіть вищесказаним. Він глибший й універсальніший за захисні окуляри, які одягають, коли заходять до лабораторії, і знімають при виході. Він стосується і повсякденного життя, хоча ця частина складніша і не настільки явна. Якщо ви не можете сказати «Йой» і відступитись, коли щось, очевидно, йде шкереберть, то продовжуватимете стріляти собі в ногу. Ви постійно перезаряджаєте рушницю і натискаєте на спусковий гачок. Ви знаєте таких людей. У певних життєвих ситуаціях — ви б воліли взагалі не думати про це — ви *і є* тією людиною. У такому разі хіба не було б чудово, якби існував певний спосіб мислення, який допоміг би нам відмовитися від добровільних пострілів у ногу?

Попри серйозність моїх помилок протягом тих двох років, як я вів цей блог, мої дописи, як виявилось, допомогли, на диво, багатьом людям. Не завжди мої поради спрацьовували як слід, та іноді все ж були помічними.

У сучасному суспільстві майже не навчають навичок формування раціональних переконань і прийняття раціональних рішень, математики і наук, що лежать у їх основі... І, виявляється, ознайомлення із тим величезним нагромадженням філософських і наукових проблем може бути напрочуд корисним досвідом. Розглядаючи всі ці ідеї з кільканадцятьох різних кутів, ви можете іноді вловити проблиск наскрізного внутрішнього ритму.

Бо, зрештою, все це стосується того самого. Я говорив про масштабні, складні і важливі проблеми, нехтуючи власне життям, але закони, яким підпорядковуються обидва, насправді ті самі. Те, на чому

1. Книжка перекладена українською Миколою Климчуком та опублікована видавництвом «Наш Формат». — Прим. пер.

я зосереджувався, мало свої недоліки, я обирав погані приклади; та врешті-решт усе це описує єдине знання. Пишаюся тим, що озираюся у минуле і пишу про це. Навіть після усіх тих помилок, яких я припустився, та інших випадків, коли казав «Йой»...

Навіть п'ять років потому мені здається, що це краще ніж нічого.

Елієзер Юдковскі, лютий 2015 р.

Біаси: Вступ від Роба Бенсінґера

Уявіть: ви опускаєте руку у скриньку. У ній сімдесят білих кульок і тридцять червоних. Ви дістаєте десять кульок невідомих кольорів.

Можливо, три з десяти кульок будуть червоними, і ви відгадаєте кількість червоних у скриньці. Або, можливо, до рук вам потраплять чотири червоні чи якась інша кількість. Тоді ви, імовірно, помилитеся, вгадуючи загальну кількість.

За неповноту своїх знань вам доведеться розплачуватися випадковими помилками. Та ціна не така вже й велика. У *середньому* ваші оцінки не будуть помилковими. І чим більше вчитиметеся, тим менших помилок припускатиметеся.

А тепер припустімо, що білі кульки важчі і скочуються на дно скриньки. Тоді ваша вибірка може виявитися нерепрезентативною у певному напрямку.

Така помилка називається «статистичною похибкою». Якщо ваш метод пізнання світу викривлений, вивчення більшої кількості даних може не принести жодної користі. Збільшення обсягу інформації може призвести до подальшого *погіршення* і без того упередженого передбачення.

Якщо ви схильні високо оцінювати знання і дослідження, такий погляд не може не лякати. Якщо ми хочемо впевнитися у тому, що вивчення більшої кількості даних не зашкодить, а посприє кращому розумінню, ніж до цього, ми маємо знайти і скоригувати упередження у наших даних.

Аналогічно функціонує ідея *когнітивного упередження* у психології. Когнітивне упередження — систематична помилка, яка виникає у *нашому мисленні*, на відміну від випадкової або спричиненої незнанням помилки. Якщо статистичне упередження спотворює вибірку так, що вона меншою мірою відображає генеральну сукупність, то когнітивні упередження спотворюють мислення у такий спосіб,

що воно не так точно відображає істину (або менш надійно служить іншим нашим цілям).

Можливо, у вас сформувалася оптимістична упередженість: ви дізнаєтеся, що червоними кульками можна вилікувати рідкісну хворобу вашого брата, і зрештою переоціните кількість червоних кульок у скриньці через ваше *бажання*, щоб усі кульки виявилися переважно червоними.

Подібно до статистичних упереджень, когнітивні можуть спотворювати наше уявлення про реальність. Їх не завжди можна позбутися збором більшої кількості даних, а їхній вплив може з часом посилюватися. Та коли *ви* і є тим самим кепсько каліброваним вимірювальним пристроєм, процес усунення біасів перетворюється на виклик, не схожий на всі інші.

Тому на початку очікуваним буде питання: якщо я не можу довірити своєму розумові, як я можу довірити чому-небудь іншому?

Навчитися помічати біаси

Уявіть, що ви зустрічаєте якусь людину вперше й анічогісінько про неї не знаєте, крім того, що вона сором'язлива.

Питання: Вища ймовірність того, що ця людина бібліотекар чи продавець?

Більшість людей відповідає «бібліотекар». І це помилка: сором'язливі продавці зустрічаються набагато частіше за бібліотекарів, тому що їх узагалі більше — у сімдесят п'ять разів частіше у Сполучених Штатах.¹

Така відповідь пояснюється *нехтуванням базовим відсотком*: ви ґрунтуєте свої судження на тому, наскільки гармонійно в людині поєднуються набори якостей, і нехтуєте тим, як часто ця характеристика зустрічається серед людей у цілому.² Ще один приклад когнітивного упередження — *помилка незворотних затрат*: люди схильні

1. Wayne Weiten, *Psychology: Themes and Variations*, Briefer Version, Eighth Edition (Cengage Learning, 2010).

2. Richards J. Heuer, *Psychology of Intelligence Analysis* (Center for the Study of Intelligence, Central Intelligence Agency, 1999).

відчувати прихильність до речей, на які вони витратили ресурси у минулому, тоді як їм варто відмовитися від подальших вкладів і рухатися далі.

Навіть будучи свідомими цих біасів, ви, на жаль, не застраховані від них. Можете і не помітити їхніх проявів.

У дослідженні *сліпої плями* учасники експерименту прогнозували, що їм буде важче безпристрасно оцінювати якість картин, якщо вони знатимуть, що вони намальовані відомим художником. І справді — коли експериментатори потім протестували ці прогнози, учасники продемонстрували той самий біас, про який заявляли. Однак після другого опитування ті самі учасники сказали, що їхні оцінки картин були об'єктивними і не зазнали впливу упередженості.³

Навіть якщо ми точно визначаємо біас інших, ми самі потрапляємо у *сліпу зону упередження*, коли доходить до власних помилок.⁴ Не помічаючи присмаку упередженості під час інтроспекції, ми висноуємо, що просто менш упереджені порівняно з іншими.⁵

Проте розпізнати і подолати біаси все ж *можливо*, хоч і складно. Відомо, що учасники експерименту можуть зменшити ефект нехтування базовим відсотком, якщо, наприклад, розглядатимуть імовірність як частоту спостереження об'єктів або подій.

Підхід до зменшення впливу біасів, описаний у цій книзі, полягає у тому, щоб донести систематичне розуміння того, *чому належне мислення ефективно* і як мозок хибує на шляху до нього.

Те, як ця книга справляється зі своїм завданням, можна описати підходом, який у своєму дослідженні описав Себастьян Серфас (2010). Він зазначає, що «роки досвіду у роботі з фінансами» жодним чином не впливають на вразливість до ефекту незворотних

3. Katherine Hansen et al., "People Claim Objectivity After Knowingly Using Biased Strategies," *Personality and Social Psychology Bulletin* 40, no. 6 (2014): 691–699.

4. Emily Pronin, Daniel Y. Lin, and Lee Ross, "The Bias Blind Spot: Perceptions of Bias in Self versus Others," *Personality and Social Psychology Bulletin* 28, no. 3 (2002): 369–381.

5. Joyce Ehrlinger, Thomas Gilovich, and Lee Ross, "Peering Into the Bias Blind Spot: People's Assessments of Bias in Themselves and Others," *Personality and Social Psychology Bulletin* 31, no. 5 (2005): 680–692.

затрат, на відміну від «кількості відвіданих уроків із бухгалтерського обліку».

Через те може виникнути необхідність розрізняти досвід та експертизу, де під другим мається на увазі «розробка схематичного принципу, яка передбачає концептуальне розуміння проблеми», яке, своєю чергою, допомагає тому, хто приймає рішення, розпізнати конкретні біаси. Однак щоб використувати експертизу як інструмент для протидії біасам, бути свідомим контексту ситуації або фахівцем у певній галузі недостатньо. Для цього необхідно повністю розуміти глибинну причину відповідного упередження, вміти розпізнати його у конкретній ситуації, а також мати під рукою відповідні засоби для протидії біасові.⁶

Отже, мета цієї книги — закласти основу для створення «експертизи» раціональності. Під експертизою я маю на увазі глибоке розуміння структури вельми загальної проблеми, а саме: людської упередженості, самообману та тисячі способів, якими витончена думка може перемогти саму себе.

Кілька слів про цю книгу

Книга «Мапа і територія» починалася як збірка есеїв теоретика прийняття рішень Еліезера Юдковскі, опублікованих між 2006 і 2009 роками в окремому блозі з економіки *Overcoming Bias* («Подолання упереджень»), що переріс у спільноту *LessWrong*. Тематично пов'язані есеї були зібрані у «ланцюжки», а згодом — у книжки.

6. Sebastian Serfas, *Cognitive Biases in the Capital Investment Context: Theoretical Considerations and Empirical Experiments on Violations of Normative Rationality* (Springer, 2010).

«Мапа і територія» — перша з шістьох таких книг, об'єднаних у серію під назвою «Рациональність: від Алгоритмів до Якорування».⁷

Стиль різниться від «ненудний підручник» до «збірник замальовок» та «бунтівний маніфест», а от зміст уже не опишеш у кількох словах. Кінцевий довідник раціоналіста вирізняється-таки індивідуальним підходом і явною непоштивістю. Матеріал автор черпав із досвіду спілкування зі своєю матір'ю — ортодоксальною єврейкою і психіатриною, — батьком-фізиком, а також із розмов у чатах та листування в електронній пошті. Читачі, які знайомі з Юдковскі за його циклом книг «Гаррі Поттер і Методи Рациональності»⁸ — переосмисленням серії Джоан Роулінг у дусі відданості науковому методу, — впізнають у цих текстах його завзяту боротьбу з традиційними віруваннями і забобонами.

Якось філософ Альфред Коржібський писав таке: «Мапа *не* територія, яку вона відображає, та якщо вона складена правильно, її *структура* буде *подібною* до території. Саме цим вона й корисна». Що Коржібський стверджував про мапу, те можна сказати і про переконання, твердження та слова.

«Мапа не територія». Ось таке підступно просте твердження і є провідною ідеєю цієї книги, а також чотирьох ланцюжків есеїв, зібраних по частинах, серед яких «Передбачувані помилки» (ідеться про те, як наші переконання систематично дисонують з реальністю), «Хибні уявлення» (що саме робить переконання «мапою»), «Навчитися помічати спантеличення» (як насправді наш розум «мапує» дійсність) і «Загадкові відповіді» (тут усі аспекти зводяться до купи). А завершує книгу есей «Проста істина» — окремий діалог про саму ідею істини.

Люди не раціональні. Однак, як зауважує Ден Аріелі, наша ірраціональність — *передбачувана*. З того, як ми помиляємося, можна вивести закономірності. Так само існують і моделі поведінки, за яких

7. Перше англomовне видання *Rationality: From AI to Zombies* було опубліковано у вигляді однієї розлогої електронної книги, перш ніж цю серію відредагували і розділили на окремі книги. Повне англomовне видання можна знайти за посиланням <https://lesswrong.com/rationality>.

8. <https://xn--c1asif2i.xn--j1amh/>

ми *не* помиляємося. Обидва підходи передбачають більш глибоке розуміння, а разом з ним і надію на те, що, покладаючись на це розуміння, ми зможемо створити краще майбутнє для себе.



Предбачувані помилки

Ігнорування масштабу

Якось три групи респондентів опитали, скільки б вони заплатили, щоб врятувати 2 000 / 20 000 / 200 000 перелітних птахів від загибелі у відкритих ставках, забруднених нафтою. Групи назвали відповідні суми: \$80, \$78 і \$88.¹ Щойно ви прочитали опис біасу під назвою *ігнорування масштабу*: кількість врятованих птахів — *масштаб* альтруїзму — мала незначний вплив на готовність жертвувати кошти.

Згідно з результатами подібних експериментів, мешканці Торонто пожертвували б трохи більше коштів, щоб очистити всі забруднені озера в Онтаріо, ніж забруднені озера у конкретному муніципалітеті провінції. А мешканці чотирьох західних штатів Америки заплатили б на 28% більше за охорону усіх 57 диких територій у цих штатах, аніж за захист однієї території.² У людській уяві постає образ «знесиленого птаха, пір'я якого просякнуте мазутом і не дає йому злетіти».³ Цей образ — або *прототип* — породжує емоційну реакцію, яка, власне, і є причиною бажання пожертвувати кошти. І цей образ лишається незмінним, хай скільки птахів зможуть врятувати. Людині кепсько вдається оцінити масштаб, адже уявити 2 тис. птахів водночас — завдання нереалістичне (що вже казати про число у 200 тис.).

1. William H. Desvousges et al., *Measuring Nonuse Damages Using Contingent Valuation: An Experimental Evaluation of Accuracy*, technical report (Research Triangle Park, NC: RTI International, 2010).

2. Daniel Kahneman, "Comments by Professor Daniel Kahneman," in *Valuing Environmental Goods: An Assessment of the Contingent Valuation Method*, ed. Ronald G. Cummings, David S. Brookshire, and William D. Schulze, vol. 1.B, Experimental Methods for Assessing Environmental Benefits (Totowa, NJ: Rowman & Allanheld, 1986), 226–235; Daniel L. McFadden and Gregory K. Leonard, "Issues in the Contingent Valuation of Environmental Goods: Methodologies for Data Collection and Analysis," in *Contingent Valuation: A Critical Assessment*, ed. Jerry A. Hausman, Contributions to Economic Analysis 220 (New York: North-Holland, 1993), 165–215.

3. Daniel Kahneman, Ilana Ritov, and David Schkade, "Economic Preferences or Attitude Expressions?: An Analysis of Dollar Responses to Public Issues," *Journal of Risk and Uncertainty* 19, nos. 1–3 (1999): 203–235.

Отже, експоненційне розширення масштабу сприяє лінійному приросту у готовності платити, що, можливо, узгоджується з лінійним часом, за який наші очі пробігають нулі. Тобто емоційний вплив не множить, а додається до впливу від початкового образу. Ця гіпотеза за відома як «оцінювання за прототипом».

Альтернативна гіпотеза — жертводавці хочуть «купити відчуття морального задоволення». Люди витрачають чималі кошти, щоб наповнити себе *душевним теплом*, відчувати, що вони виконали свій обов'язок. Обсяг витрат на душевне тепло залежить від особистості та фінансового становища, але з кількістю птахів, безумовно, не має нічого спільного.

Нечутливість до масштабу проявляється і тоді, коли на кону людське життя: внаслідок підвищення заявленого ризику від хлорованої питної води з 0,004 до 2,43 щорічних смертей на 1 тис. осіб — тобто у 600 разів більше — готовність платити зросла з \$3,78 до \$15,23.⁴ Джонатан Бёрон і Джошуа Грін не встановили ніяких змін, навіть якщо кількість врятованих життів зросла б у 10,5 раза.⁵

У статті «Нечутливість до цінності людського життя: дослідження психофізичного оніміння⁶» зібрано свідчення того, що наше сприйняття людських смертей відповідає закону Вебера — себто підпорядковується логарифмічній шкалі, на якій «ледь помітна різниця» становить постійну частку від цілого. Наприклад, програма охорони здоров'я із порятунку біженців із Руанди отримала набагато більшу підтримку, коли представники заявили, що врятовують 4,5 тис. жителів у таборі з 11 тис. біженців, а не 4,5 тис. у таборі з 250 тис. А щоб отримати фінансування на потенційні ліки від хвороби, вони

4. Richard T. Carson and Robert Cameron Mitchell, "Sequencing and Nesting in Contingent Valuation Surveys," *Journal of Environmental Economics and Management* 28, no. 2 (1995): 155–173.

5. Jonathan Baron and Joshua D. Greene, "Determinants of Insensitivity to Quantity in Valuation of Public Goods: Contribution, Warm Glow, Budget Constraints, Availability, and Prominence," *Journal of Experimental Psychology: Applied* 2, no. 2 (1996): 107–125.

6. <https://web.archive.org/web/20130328012735/http://commonsenseatheism.com/wp-content/uploads/2011/09/Fetherstonhaugh-et-al-Insensitivity-to-the-value-of-human-life-A-study-of-psychophysical-numbing.pdf>

мають врятувати набагато більше життів, наприклад: початково було заявлено про смерть 290 000, а не 160 000 чи 15 000 людей на рік.⁷

Висновок: якщо ви прагнете бути ефективними у своєму альтруїзмі, маєте думати тією частиною вашого мозку, яка обробляє нудні нулі, прописані чорнилом на папері, а не лише тією, яка переймається бідолашною пташкою, що тоне у мазуті.

7. David Fetherstonhaugh et al., “Insensitivity to the Value of Human Life: A Study of Psychophysical Numbing,” *Journal of Risk and Uncertainty* 14, no. 3 (1997): 283–300.

Бойове мистецтво раціональності

Я часто вдаюся до метафори, що раціональність — це бойове мистецтво для розуму¹. Щоб опанувати бойові мистецтва, вам не потрібні здоровенні рельєфні м'язи, хоч і прослідковується тенденція, що спортсмени охочіше беруться вивчати бойові мистецтва (проте причиною може бути як *задоволення*, так і щось інше). Якщо у вас є рука із сухожиллями і м'язами у потрібних місцях — можна навчитися стискати кулак.

Так само із мозком: якщо частки кори та підкіркові структури на місці — можна навчитися правильно ними користуватися. Проте навіть якщо ви здібні і швидко навчаєтеся, мистецтво раціональності передбачає дещо інше. Суть полягає у тренуванні мозкового механізму, спільного для нас усіх. Там, де наш мозок припускається систематичних помилок — скажімо, ігнорування масштабу, — раціональність покликана виправляти їх або шукати обхідні шляхи.

На жаль, наш мозок не так охоче реагує на силу волі, як на рухи тіла. Наша здатність розпоряджатися своїми м'язами розвинулася ще із сивої давнини еволюційної необхідності, а от здатність осмислювати процеси власного мислення з'явилася не так давно. Тож не випадає дивуватися, що орудувати м'язами простіше, ніж мозком. Та це не означає, що тренувати розум узагалі не варто, бо складно. Хіба завдяки здоровенним м'язам люди зайняли панівні позиції на Землі?

Якщо ви мешкаєте у місті, вам, напевно, не доведеться заходити до чорта на болото у пошуках залу бойових мистецтв. Чому ж тоді немає таких закладів, в яких навчали б раціональності?

Певно, одна з причин — складність перевірки навичок. Щоб отримати новий пасок у тхеквондо, вас, можливо, попросять розбити дошку певної ширини. Розбили — зал винагороджує вас оплесками. Не розбили — вчитель дивиться, як ви тримаєте кулак, і вказує на ваші помилки. Або він простягає руку і навчає, як правильно стискати кулак.

1. https://old-wiki.lesswrong.com/wiki/Rationality_as_martial_art

У школах бойових мистецтв техніки тренування м'язів розроблялися і вдосконалювалися протягом багатьох поколінь. А от передати техніки раціональності навіть найстараннішому учневі важче, ніж навчити фізичних прийомів.

За останні кілька десятиліть люди накопичили чимало нових знань про раціональність з похибкою на наш мозок. Найяскравіший приклад — програма² вивчення евристик³ і біасів в експериментальній психології. Також можна назвати баєсову⁴ систематизацію теорії ймовірностей і статистики, еволюційну і соціальну психологію. Експериментальними розвідками практичної психології і теоретичною частиною теорії ймовірностей можна пояснити результати наших експериментів, а еволюційною теорією — висновки. Крізь ці галузі знання ми можемо чіткіше бачити ландшафт нашого розуму, а саме — кожен порух його м'язів і кожную судину думки. У нас з'явився спільний набір понять, якими ми можемо описати проблему і її розв'язання. Можливо, людству нарешті вдасться синтезувати бойове мистецтво розуму — вдосконалювати, ділитися, систематизувати і передавати випрацювані техніки власної раціональності.

Моє нинішнє розуміння раціональності я здобув, коли намагався розв'язати проблему загального штучного інтелекту (ЗШІ). І задля успіху у цій справі раціональність потрібно опанувати настільки, щоб із самих лише зубочисток і канцелярських гумок зібрати повноцінного раціоналіста. Здебільшого проблема ШІ геть складніша за особисте мистецтво раціональності, проте де в чому він простіший. Що стосується бойового мистецтва розуму, наше завдання — набутти в реальному часі методичної навички смикати потрібні важелі у потрібний момент всередині великої мислівої машини з уже заданими внутрішніми параметрами, вносити зміни до яких кінцевий споживач не має змоги. Деякі з цих машин налаштовані під тиском еволюційного добору таким чином, що прямо суперечить нашим

2. https://uk.wikipedia.org/wiki/Евристика_в_судженнях_та_прийнятті_рішень

3. Недосконалий метод досягнення цілі. Корисне наближення. Когнітивні евристики — вроджені, універсальні евристики людського мозку. — Прим. пер.

4. <https://old-wiki.lesswrong.com/wiki/Bayesian>

заявленим цілям використання. Наш свідомий вибір — пошук істини, хоч мозок людини і має вбудовану програму для обґрунтування брехні. Ми можемо спробувати скоригувати недоліки цієї машини, але переробити нейронну схему — нездійсненне завдання. Подібно до того, як майстри бойових мистецтв не можуть накласти титанові пластини на свої кістки — принаймні не сьогодні.

Спроба зібрати особисте мистецтво раціональності з науки раціональності може виявитися недолугою: уявіть-но, як хтось витворює бойове мистецтво на основі абстрактної теорії фізики, теорії ігор та анатомії людини.

Але люди здатні до рефлексій. Нам таки притаманний інстинкт самоаналізу. Внутрішнє око видюще, хоч і бачить воно невиразно, із систематичними спотвореннями. Саме тому, щоб *коригувати* наші ментальні рухи і *посиливати* метакогнітивні навички, інтуїції *не обійтися* без науки і теоретичних знань.

Ми не пишемо комп'ютерну програму для того, щоб примусити маріонетку до бойового мистецтва. Ми маємо навчитися керувати власними ментальними кінцівками, тому слід пов'язати теорію з практикою. Ми повинні зрозуміти, яке значення має наука раціональності особисто для нас, для особного повсякдення.

Доступність

Евристика доступності — це оцінювання частоти або ймовірності події за тим, наскільки легко ви її пригадуєте.

У відомому дослідженні 1978 року «Оцінювальна частота летальних випадків» за керівництва Сари Ліхтенштайн, Пола Словіка, Баруха Фішгофа, Марка Леймана та Барбари Комбс вивчали помилки, яких припускаються люди, коли оцінюють ризики або частотність однієї з двох подій. На думку учасників експерименту, внаслідок аварій гине стільки ж людей, скільки й через хвороби, а вбивства стаються частіше за самогубства. Насправді ж хвороби спричиняють у 16 разів більше смертельних випадків, аніж аварії, а самогубства стаються вдвічі частіше за вбивства.

Із цього можна виснувати очевидну гіпотезу, що пояснюватиме ці викривлені уявлення: про вбивства говорять частіше, ніж про самогубства, тому людина з більшою ймовірністю пригадає, що чула про випадки першого, ніж другого. Новини про аварії викликають більше емоцій, ніж хвороби, тому, можливо, це і є причиною того, що люди найімовірніше пригадують саме випадки аварій. У подальшому дослідженні 1979 року за керівництва Комбс та Словіка було виявлено, що викривлені ймовірнісні судження суттєво корелювали (0,85 та 0,89) із частотою викривлених репортажів у газетах. Та це не допомагає відповісти на питання, чи вбивства частіше спадають на думку, тому що про них більше пишуть, або у газетах частіше повідомляють про вбивства, тому що вони викликають більш емоційну реакцію (і тому краще запам'ятовуються). У будь-якому разі тут не обійшлося без евристики доступності.

Вибіркове висвітлення — одне з основних джерел цього упередження. Більшість із того, що знали наші пращури, вони переживали на власному досвіді або чули безпосередньо від одноплемінника, який бачив якусь подію на власні очі. Як правило, між людиною та самою подією проходив щонайбільше один пласт вибіркового висвітлення. В епоху інтернету вам може трапитися новина, яка на шляху

до вас пройшла через руки шістьох блогерів, кожен з яких навряд чи обмежився неупередженим переказом. Та у порівнянні з нашими пращурами ми живемо у більш глобалізованому світі, де відбувається значно більше всього, а до нас з усього того доходить значно менше, що породжує набагато сильніший вибірковий ефект, а разом із ним — упередження доступності.

У вас доволі мало шансів наживо зустрітися з Біллом Гейтсом. Однак завдяки вибіркового висвітленню у ЗМІ ви можете піддатися спокусі порівняти його звернення за життя зі своїми, а потім вас задавить жаба. Об'єктивна частота появи Білла Гейтса складає 0,00000000015, проте чуєте ви про нього набагато частіше. Навпаки, 19% планети живуть менше ніж на долар на день, і я сумніваюся, що п'ята частина тих дописів, які ви читаете у соцмережах, написана ними.

І схоже, на підґрунті доступності проросла ще одна хиба — упередження абсурдності¹, — яка позначає події, що ніколи не ставалися і не спадають на думку, тому їхня ймовірність вважається нульовою. Якщо останнім часом не ставалося ніякої повені (а ймовірність цієї події цілком обчислювальна), люди відмовляються купувати страхування від повені, навіть коли воно значною мірою компенсується, а ціна за нього набагато нижча за обґрунтовану страхувальну вартість. Говард Кунройтер та інші припускають, що недооцінка загрози повені, ймовірно, виникає через «людську неспроможність уявити собі повені, які ніколи не траплялися... Люди, які живуть у долині затоплення, наче перебувають у полоні власного досвіду... Верхню межу розміру збитків, вочевидь, встановили з урахуванням повеней, які ставалися за останній час».²

Єн Бертон та інші зазначають, що за наявності гребель знижується частота повеней, що, вочевидь, призводить до хибного відчуття безпеки та зменшення запобіжних заходів.³ І хоча через будівництво

1. https://www.greaterwrong.com/lw/j4/absurdity_heuristic_absurdity_bias/

2. Howard Kunreuther, Robin Hogarth, and Jacqueline Meszaros, "Insurer Ambiguity and Market Failure," *Journal of Risk and Uncertainty* 7 (1 1993): 71–87.

3. Ian Burton, Robert W. Kates, and Gilbert F. White, *The Environment as Hazard*, 1st ed. (New York: Oxford University Press, 1978).

дамб знижується *частота* поводей, збитки від *кожного розливу* настільки великі, що середньорічні збитки *зростають*.

Мудрі масштабують висновки, які винесли з малих небезпек, на ймовірність появи серйозніших. Натомість минулий досвід малих небезпек, схоже, встановив верхню межу ризику, яка сприймається як максимальна. Суспільство, добре захищене від малих небезпек, не вживає жодних заходів проти суттєвих ризиків, поселяючись на долинах затоплення, щойно загрозу регулярних незначних паводків усунуто. Суспільство, що піддається регулярним незначним загрозам, сприймає їх як верхню межу можливих ризиків і захищається від регулярних підтоплень, а не від рідкісних масштабних повеней.

Саме тому пам'ять далеко не завжди надійний помічник в оцінюванні ймовірностей минулого, не кажучи вже про майбутнє.

Що таке біас?

Евристика доступності — це когнітивний простець, за допомогою якого люди приходять до висновків. А якщо цей простець систематично заводить до неточних висновків, можна стверджувати, що ми маємо справу з упередженням доступності. До цієї когорти *когнітивних упереджень* можна віднести й ігнорування масштабу.

«Біаси»¹ — це такі перешкоди на шляху до істини, спричинені ані зусиллями, які докладають для отримання інформації, ані обмеженою обчислювальною потужністю, а саме *формою наших розумових механізмів*. Можливо, ці механізми еволюційно налаштовують нас вірити у неправдивий стан речей, коли потрібно виграти політичну суперечку у племінному середовищі. Або ж тиск добору призвів до перекоосу у протилежний до епістемічної точності бік: наприклад, хтось вірить у те, у що вірять інші, щоб вписатися в соціум. Також біас може бути побічним продуктом помічної евристики мислення. Евристика доступності сама по собі не є біасом, але слугує плідним підґрунтям для них. Цей механізм працює за алгоритмом — наділяти певні явища більшою доказовою вагою, якщо вони швидше спадають на думку, — який виконує якусь корисну роботу, але при цьому припускається системних помилок.

Наш мозок постійно припускається помилок, і після численних експериментів та/або довгих роздумів хтось ословлює проблему у конкретний спосіб, а вже потім ми називаємо її «(когнітивним) біасом». Але не сплутайте термін із розмовним висловлюванням «ця людина упереджена», яке означає «у цієї людини викривлене або стереотипне ставлення до чогось».

У когнітивістиці «біаси» відрізняють від хиб, які виникають на *підґрунті вмісту розуму*, наприклад, сформовані хибні переконання. Цей вид погрішностей ми називаємо скоріше «помилками», а не «біасами», оскільки після усвідомлення їх набагато легше

1. Також когнітивні упередження або когнітивні спотворення. Термін «біас» обрано з міркувань лаконічності. — Прим. пер.

виправити. (Хоча джерело помилки або джерело джерела помилки може зводитися до якогось когнітивного упередження.)

«Біаси» також відрізняють від хиб, які виникають на підґрунті травми людського мозку або засвоєних культурних порядків; когнітивні упередження виникають же на підґрунті механізму, універсального для всіх людей.

Платон не був «упередженим», оскільки він поняття зеленого не мав про загальну теорію відносності і дізнатися про неї ніяк не міг, тому його нетямущість проростала не із форми розумових механізмів. Та якби Платон вірив, що з філософів виходять путні правителі, бо він сам був філософом — а це переконання, своєю чергою, виникло у нього через адаптивний політичний інстинкт саморекламування, а не тому що тато Платона розказав йому в дитинстві, що усі мають моральний обов'язок просувати свою професію на керівні посади, чи тому що Платон у підлітковому віці зловживав опіумом, — тоді це був би біас незалежно від того, чи Платона хтось попереджав про це.

І хоча я не від того (як ви вже пересвідчилися), щоб обговорити визначення, я не хочу стверджувати, що проєкт, який передбачає ефективніше орудування власним розумом, не залежить від оперування якимось особливим термінологічним апаратом. Якщо термін «біас» або «когнітивне упередження» втратить свою доцільність — ми просто відмовимося від нього.

Ми не починаємо з морального обов'язку «зменшити вплив біасів» просто тому, що упередження — щось неприйнятне і взагалі жахливе зло. Схожі міркування світять тим, хто взяв на себе деонтологічний обов'язок слідувати шляхом пасивно засвоєної «раціональності», що призводить до вправлянь у зменшенні біасів, не до кінця розуміючи причини і сенс технік. (Такий шлях сам по собі жахливий і просто неприйнятний, про що я ще дитиною вчитав у книзі «Та ви жартуєте, містере Фейнман!».) Біас — це перешкода *на шляху* до нашої мети — істини.

Ми тут для того, щоб долучитися до загальнолюдських шукань істини — адже нам конче потрібні знання, і до всього ж ми вкрай

допитливі. Отож, заради цього стараймося долати будь-які перешкоди на нашому шляху, хай би як ми їх називали — «біаси» чи якось іще.

Обтяжливі подробиці

Просто уточнювальна дрібниця, покликана надати художньої правдоподібності і так невиразній та непереконливій історії...

Пу-Ба, опера Гілберта і Саллівана «Мікадо»

Омана поєднання — це коли люди оцінюють імовірність події $P(A, B)$ як вищу за подію $P(B)$, навіть попри теорему $P(A, B) \leq P(B)$. Наприклад, в одному експерименті 1981 року 68% учасників оцінили твердження «Рейган надасть державну підтримку самотнім матерям і скоротить її для органів місцевої влади» як більш імовірне, ніж «Рейган надасть державну підтримку самотнім матерям».¹

Завдяки низці продуманих експериментів, які відсіяли альтернативні гіпотези та підкріпили стандартну інтерпретацію², було підтверджено, що причина омани поєднання полягає у «заміні судження про репрезентативність судженням про ймовірність».³ Додавши кілька подробиць, ви можете отримати результат, який здається *більш* притаманним процесові, що його зумовлює. Ви можете надати правдоподібності твердженню про те, що Рейган надасть підтримку самотнім матерям, *додавши*, що *також* Рейган уріже підтримку органам місцевого самоврядування. Таким чином, неправдоподібність

1. Amos Tversky and Daniel Kahneman, "Judgments of and by Representativeness: Heuristics and Biases," in *Judgment Under Uncertainty*, ed. Daniel Kahneman, Paul Slovic, and Amos Tversky (New York: Cambridge University Press, 1982), 84–98.

2. https://www.greaterwrong.com/lw/jj/conjunction_controversy_or_how_they_nail_it_down/

3. Див. Amos Tversky and Daniel Kahneman, "Extensional Versus Intuitive Reasoning: The Conjunction Fallacy in Probability Judgment," *Psychological Review* 90, no. 4 (1983): 293–315 and Daniel Kahneman and Shane Frederick, "Representativeness Revisited: Attribute Substitution in Intuitive Judgment," in *Heuristics and Biases: The Psychology of Intuitive Judgment*, ed. Thomas Gilovich, Dale Griffin, and Daniel Kahneman (Cambridge University Press, 2002) для детальної інформації.

одного твердження компенсується вірогідністю іншого, внаслідок чого вони «урівнюють» імовірності.

Іншими словами: додаючи подробиць, ви можете надати ситуації правдоподібного звучання, навіть якщо ця подія неминуче стає менш імовірною.

У такому разі *можна припустити*, що існують футурологи, які безсовісно правлять реалістичні деталізовані байки про майбутнє, або люди, які наївно вірять у безліч непідтверджених тверджень, підкріплених кількома переконливими тезами. Якщо ви стикаєтеся з оманомою поєднання у вигляді наочного порівняння, то зможете розпізнати проблему, свідомо виправивши себе. Проте таке рішення тимчасове і не розв'язує проблему в цілому.

В експерименті 1982 року⁴, в якому професійні аналітики систематично приписували вищу ймовірність події «після того, як припиняться дипломатичні відносини між США та СРСР, Росія вдереться в Польщу» замість «дипломатичні відносини між США та СРСР припиняться», кожній експериментальній групі представили лиш одну пропозицію.⁵ Якій стратегії мали би колективно слідувати ці аналітики, щоб усунути оману поєднання, якщо жоден із них не знав про порівняння безпосередньо? За умови, що жоден учасник не знав, що *предметом дослідження була* омана поєднання. Яким чином вони могли б реалістичніше оцінити імовірнісне судження?

Виправивши одну помилку в окремому випадку, ви не вирішите загальну проблему. Така неочевидна хиба є симптомом, а не хворобою.

Що мали б зробити аналітики, щоб уникнути омани поєднання, не бачачи прямого порівняння чи навіть не усвідомлюючи, що хтось тестуватиме їх на цю помилку? Як на мене, вони мали б помітити єднаний сполучник «і». І не просто остерігатися — ба навіть триматися якомога далі від нього. А ще — вони не мали б знати, що хтось опісля тестуватиме їх, зокрема на оману поєднання. Аналітики мали

4. https://www.greaterwrong.com/lw/ji/conjunction_fallacy/

5. Tversky and Kahneman, “Extensional Versus Intuitive Reasoning.” (<https://www.lesswrong.com/s/5g5TkQTe9rmPS5vvM/p/Yq6aA4M3JKWaQepPJ#cite.0.Tversky.1983>)

б помітити сполучення *цілих двох подробиць* та *здивуватися* зухвало-сті того, хто просить затвердити настільки складне передбачення. Тоді довелося б *суттєво* знизити ймовірність — принаймні учетверо, — як того вимагає експеримент.

Також помічною могла бути думка про можливі причини зупинення дипломатичних відносин між США та Радянським Союзом. Адже йдеться не про те, що «США та Радянський Союз раптово призупиняють дипломатичні відносини без причин», а про те, що «США та Радянський Союз призупиняють дипломатичні відносини з будь-якої причини».

А як щодо тих учасників, які оцінювали ймовірність події «Рейган надасть державну підтримку самотнім матерям і скоротить її для органів місцевої влади»? Знову ж таки, їх мав насторожити єдина сполучка «і». Ба більше, їм довелося б *додати* одиниць абсурдності, де абсурдність — це логарифм ймовірності, тому урівнювати ці два твердження точно не варто. Крім додавання, доведеться поміркувати: «Рейган може скоротити або не скоротити державну підтримку органів місцевої влади (1 біт), однак вельми мало ймовірним здається, що він підтримає самотніх матерів (4 біти). Сума абсурдності: 5 бітів». Або можливо: «Рейган не підтримуватиме самотніх матерів. Один хибний крок — і все зійде нанівець. Міркування не в той бік лиш погіршить ситуацію».

А тепер у тому ж дусі розглянемо експеримент Тверські та Канемана (1983) про шестигранну гральну кість із чотирма зеленими (з) гранями і двома червоними (ч).⁶ Учасники експерименту мали зробити ставку на одну з послідовностей: 1) ч-з-ч-ч-ч, 2) з-ч-з-ч-ч-ч або 3) з-ч-ч-ч-ч-ч, яка з'явиться після будь-якого з двадцяти кидків кубиків. 65% опитуваних обрали варіант «з-ч-з-ч-ч-ч», хоча виграною є послідовність «ч-з-ч-ч-ч», оскільки будь-яка послідовність, котра містить варіант «з-ч-з-ч-ч-ч», спрацює і для «ч-з-ч-ч-ч». Як вони могли б реалістичніше оцінити ймовірність? Помітивши поєднання? Можливо. Та це лише тимчасове рішення, яке не вплине на розв'язання

6. Там же (<https://www.lesswrong.com/s/5g5TkQTe9rmPS5vvM/p/Yq6aA4M3JKWaQepPJ#cite.0.Tversky.1983>).

засадничої проблеми. Шляхом безпосереднього підрахунку ймовірностей? Цей спосіб напевне розв'язав би цю проблему, однак ви ж не можете щоразу вираховувати точну ймовірність.

Учасники експерименту спокусилися на програшну евристику, розмірковуючи так: «Ага! У другій послідовності найбільше зеленого до червоного! Ставлю на друге!». Але виграшний хід міркувань для піддослідних має дещо інший вигляд: «Ага! Перша послідовність *коротка!* Ставлю на перше!»

Їх мало би *насторожити* те, що вони знехтували лезом Оккама: *кожна* додана дрібниця — це тягар, навіть один зайвий кидок гральних кісток.

Якось я розмовляв з одним паном, який захоплювався необачливим футурологом (котрий накидував купу деталей, щоб звучати якомога точніше). Намагався пояснити, чому мене не зачаровують ці пишномовні розповіді так, як його. Отже, я розповів про оману поєднання, зокрема експеримент стосовно «призупинення відносин $\pm$ вторгнення у Польщу».

— Гаразд, але як це пов'язано з..., — відповів він.

— Більш імовірно, що всесвіти відтворюються з будь-якої причини, ніж *завдяки чорним дірам через те, що високорозвинені цивілізації створюють чорні діри, бо всесвіти рухаються до того, що ті цивілізації вимушені це робити*, — зауважив я.

— Трясця! — відповів він.

Доти він не сприймав ці додаткові подробиці як зайву нашу. Натомість вони виконували роль уточнювальних дрібниць, які надавали правдоподібності цій історії. Ось вас ознайомлюють із цілим букетом дивних ідей, суть *однієї* з яких у відтворюваності всесвітів. А згодом вам уже надають *підкріплення твердження про те, що всесвіти відтворюються*. Проте це ніяке не підкріплення цього набору⁷ ідей, хоча і подається як суцільна історія.

Варто розібратися у цих деталях. А саме — взяти кожную з них окремо і запитати: «Звідки взялася *ця* деталь?». Хтось малює перспективу занурення людства у війну нанотехнологій, в якій уряд

7. [https://uk.wikipedia.org/wiki/Оптова_угода_\(логічна_хиба\)](https://uk.wikipedia.org/wiki/Оптова_угода_(логічна_хиба))

Китаю відмовляється дотримуватися міжнародної угоди про контроль, що призводить до перегонів озброєнь... Заждіть-но: звідки ви взяли, що це буде саме Китай? Карти показали чи інтуїція футуролога? Яке джерело усіх цих подробиць? Звідки взялася *та конкретна* деталь?

Написано-бо:

Можеш полегшити ношу свою — зроби це.

Адже немає такої соломинки, яка б не зігнула спини твоєї.

Що ми маємо на увазі під «раціональністю»

Ось що маю на увазі я:

1. **Епістемічна раціональність** — систематичне підвищення точності власних поглядів.
2. **Інструментальна раціональність** — систематичне досягнення цінностей.

Перше поняття доволі просте. Ви розплющуєте очі, оглядаєте кімнату і бачите, що ваш ноутбук стоїть відносно столу, а книжкова шафа — відносно стіни. Та раптом щось стається із вашими очима (або мозком) — у вашій ментальній моделі книжкова шафа може й досі існувати (хоч насправді її там і немає). Тому при всьому бажанні взяти книгу на вас чекає розчарування.

Ось так воно — мати хибні погляди, мапу, яка не відповідає території. Однак завдання епістемічної раціональності — побудова точних мап. І цю відповідність між переконанням та дійсністю я радо називаю «істиною».¹

А ось інструментальна раціональність стосується *кермування* дійсністю. Її завдання — задати курс майбутньому у бажаному напрямку. По суті, це — мистецтво обирати дії, які приведуть до наслідків, які ви ранжуєте вище у своєму переліку уподобань. Деколи слово «виграш» також підходить для цього поняття.

Тому раціональність — це про формування істинних переконань та прийняття виграшних рішень.

(У цьому випадку під «істиною» не мається на увазі «певність», оскільки ми можемо багато чого зробити, щоб підвищити *ймовірність* правильності наших переконань, навіть якщо не певні. А «виграш» не означає «перемогу над кимось», оскільки до наших цінностей входить *усе*, до чого ми не байдужі, зокрема й інші люди.)

1. Якщо ви хочете продовження обговорення про істину, читайте есей «Проста істина», яким закінчується ця книга. — Прим. авт.

Коли кажуть «Х раціонально!», зазвичай хочуть у більш різкий спосіб сказати «На мою думку, Х є істинним» або «На мою думку, Х є добре». Тож навіщо вживати такі додаткові поняття, як «раціональність», «істина», «добре»?

Подібний аргумент можна навести й проти використання поняття «істина». Навіщо казати «правда в тому, що сніг білий», коли можна обійтися виразом «сніг білий»? Ідея істини корисна тим, що вказує на відповідність між мапою та територією у загальних рисах. «Істинні моделі зазвичай дають кращі експериментальні прогнози, ніж хибні» — одне з таких корисних узагальнень, і його вже не виведеш без таких понять, як «істинний» чи «точний».

Так само думка «Раціональні агенти приймають рішення, які максимізують математичне сподівання узгодженої функції корисності» залежить від поняття (інструментальної) раціональності, тоді як риторику «Їсти овочі раціонально» можна замінити на «Їсти овочі корисно» чи «Їсти овочі у твоїх інтересах». Нам потрібне поняття «раціональність», аби краще розуміти ті способи міркування, котрі систематично приводять до істини або цінності. Те саме стосується і помилок у мисленні, яких ми постійно припускаємося.

Як ми вже дізналися з попередніх есеїв, експериментальні психологи виявляють доволі дивні процеси людського мислення. Скажімо, дехто оцінює подію «Білл грає джаз» як *менш* імовірну від події «Білл — бухгалтер, який грає джаз». Таке судження видається дивним, оскільки будь-який бухгалтер, який грає джаз, зараховується до його виконавців. Однак що це за така вища позиція, з якої ми говоримо, що дане судження *хибне*?

В експериментальній психології використовують два золоті стандарти, а саме: *теорію ймовірностей* та *теорію рішень*.

Теорія ймовірностей — це сукупність законів, що лежить в основі раціонального переконання. Математика ймовірностей із неабиякою точністю описує «розташування вашої книжкової шафи» та оцінює «кількість волосинок на голові Цезаря», навіть якщо наші свідчення на користь твердження «Юліус Цезар був лисим», швидше за все, будуть набагато складнішими і більш опосередкованими за

ті, що свідчать на користь твердження «у моїй кімнаті є книжкова шафа». Що те, що інше стосується обробки свідчень та спостережень задля оновлення переконань. Так само теорія рішень — це сукупність законів, які лежать в основі раціональних дій і однаково застосовні, хай би якими були цілі та наявні можливості.

Нехай « $P(\text{таке-то й таке-то})$ » позначає «ймовірність такої-то події», а « $P(A, B)$ » — «ймовірність події A та B ». Оскільки універсальний закон імовірностей свідчить, що $P(A) \geq P(A, B)$, то судження, що $P(\text{Білл грає джаз})$ менше за $P(\text{Білл грає джаз, Білл — бухгалтер})$, вважається хибним.

Мовою термінів, дане ймовірнісне судження є *небаєсовим*. І, навпаки, переконання, які відповідають узгодженому розподілу ймовірностей, і рішення, які максимізують математичне сподівання узгодженої функції корисності, зветься «баєсовими».

Зауважте: це *ніяк не стосується* того уявлення про раціональність, поширеного у популярній культурі. Люди можуть вживати ту саму послідовність складів «ра-ці-о-наль-ність», але мати на увазі «діяти як містер Спок із “Зоряного шляху”» та «діяти як баєсіанець», проте це не означає, що мавпування Спока хоч якось стане вам у нагоді при опануванні епістемічної чи інструментальної раціональності.²

Однак це не вичерпує проблему, що означає «раціональність» на практиці. З двох головних причин:

По-перше, коли доходить до розв’язування проблем реального світу, баєсові формальні системи неможливо обчислити за розумний час. *Насправді* нікому не під силу обчислити математику чи

2. Яскравим прикладом є уявлення про те, що раціональність — це суцільні словесні міркування, котрі душать почуття. Баєсова раціональність застосовна не тільки до тверджень, а й до імпульсів, здогадок, відчуттів та невиражених передчуттів. Я навіть приклад з розплющенням очей, роззиранням та побудовою ментальної моделі кімнати з книжковою шафою навпроти стіни. Сучасній раціональності загалом досить залучити у процес обмірковування переконань і цілей ваші очі, візуальні ділянки мозку, які відповідатимуть за мапування, а також невербальну інтуїцію. — Прим. авт.

задовольнити її умови, не більше ніж рівнянням руху кварків³ передбачити розвиток подій на фондовій біржі.

З цієї ж причини й існує цілий сайт під назвою *Less Wrong*, а не одна-єдина сторінка з формальними аксіомами, на чому усе б закінчилося. Існує ціле мистецтво пошуку істини та видобування цінностей *зсередини людського розуму*, спрямоване на вивчення власних помилок, подолання біасів, убезпечення від самоомани, щоби стачало сміливості дивитися правді у вічі, а також робити інші необхідні для цього речі.

По-друге, іноді зміст самої математики ставиться під сумнів. З цієї ж причини точні закони теорії ймовірностей беруться під сумнів, скажімо, через проблему антропності⁴, за якої число спостерігачів невідоме, а точні закони теорії рішень — через проблеми на кшталт парадокса Ньюкома, за якого інші агенти можуть передбачати ваше рішення перед його реалізацією.⁵

Тоді, коли з наших найкращих формалізацій небагато користі, ми можемо повернутися до простіших ідей, як-от «істина» та «виграш». Якщо ви науковець, який тільки починає досліджувати вогонь, можливо, набагато розумніше буде вказати на багаття і сказати щось штибу «Вогонь — це ота жовтогаряча пекуча штукovina», а не «Я визначаю вогонь як алхімічну трансмутацію речовин, внаслідок якої утворюється флогістон». Звичайно, не слід нехтувати чимось лишень тому, що ви не можете дати цьому визначення. Навряд чи мені вдасться з пам'яті процитувати рівняння загальної теорії відносності, проте якщо я зйду зі скелі, то впаду. Те саме можна сказати про біаси та інші перешкоди, що можуть збити на манівці спраглого шукача істини: їх наслідки не стануть менш відчутними, якщо виявиться, що ми не можемо підібрати влучне визначення для поняття «ірраціональність».

3. Елементарна частинка матерії. - Прим. пер.

4. https://anthropic-principle.com/?q=anthropic_principle/primer

5. Щоб ознайомитися з неформальним формулюванням проблеми Ньюкомба, див. Jim Holt, "Thinking Inside the Boxes," Slate, 2002, https://www.slate.com/articles/arts/egghead/2002/02/thinkinginside_the_boxes.single.html. — Прим. авт.

У таких випадках марно намагатися розв'язати проблему, вигадуючи якийсь нове визначення раціональності, при цьому кажучи: «І саме тому обрана мною дефініція раціональності *за визначенням* краща». До такого формулювання виникають питання доцільності. Теорія ймовірностей цікавить мене не тому, що вона — Святе Письмо, дане Господом нашим Лапласом. Я віддаю перевагу баєсовому оновленню власних уявлень (орудуючи пріорами Оккама) та очікую, що такий спосіб мислення крок за кроком наближає нас до *точності* — коли мапа відповідає території.

Тоді ж виникають питання доцільного міркування, на які достоту нема відповіді ні у теорії ймовірностей, ні у теорії рішень. Це схоже на те питання, як ставитися до істини, коли вона вам відома. Повторюся: визначення раціональності не дасть нам нічого, крім припущень.

Я не беруся сперечатися про значення слова, навіть якщо це слово — раціональність. Взагалі, сенс надання поняттю якоїсь послідовності літер у тому, щоб уможливити *комунікацію* двох людей — допомогти їм передавати ідеї з однієї голови в іншу. Вам не вдасться змінити дійсність чи вдало обґрунтувати свою ідею, викривлюючи значення слів.

Тому якщо ви *в загальних рисах зрозуміли*, що я маю на увазі під «раціональністю» та її видами — епістемічною та інструментальною, — *комунікація відбулася успішно*, і тему визначення цього терміна можна вважати закритою. А подальший простір для дискусії не в *наданні точного значення* череді складів «раціональність», а у *визначенні кращих способів міркування*.

Та якщо ви кажете, що «Для мене (епістемічно) раціонально вірити в X, проте істина — Y», то, певно, у вашій голові поняття раціональності набуває іншого вигляду. (Скажімо, «раціональність» має бути *узгодженою* при рефлексивному застосуванні до себе: при розгляді свідчень та врахуванні того, як мозок їх опрацьовує, ми не можемо прийти до різних висновків.)

Схожим чином, коли ви ловите себе на словах «Для мене (поінструментальному) раціонально робити X, та правильно було б діяти

У», то ви майже напевне користуєтеся іншим визначенням або слова «раціонально», або слова «правильно». Я натомість виходжу з *нормативного значення* терміну «раціональність», щоб виокремити бажані моделі мислення.

У такому разі — або в будь-якому іншому, коли люди розходяться у семантиці слова — замість «раціональність» вам слід використовувати специфічніші висловлювання: «Вигідною стратегією була б втеча, але сподіваюся, що мені бодай вдасться відтягнути дитину від залізничної колії» або «У звичайному формулюванні каузальної теорії рішень йдеться, що ви повинні обрати обидві коробки у задачі Ньюкома, але краще б у мене було мільйон доларів».

А знаєте що: поверніться до початку цього розділу і спробуйте щоразу, коли вам траплятиметься лексема «раціональність», замінити її лексемою «фузальність», а потім подивіться, чи ця заміна хоч трохи змінює конотації моїх слів. І коли вже так подумати: раціональність вам ні до чого — беріть вже курс прямисінько на фузальність.

Безумовно, слово «раціональність» має потенційні недоліки, та є безліч *немежових* ситуацій, коли це слово чудово спрацьовує при передачі ідей. Те саме і зі словом «ірраціональність»: не бачу причин не вживати його.

Утім, закликаю: *будьте обачними при використанні* цього слова. Ніхто не зарахує вам додаткових очок, якщо ви ним вимахуватиметеся. Адже той, хто торочить про Шлях, так і не пізнає його.

Омана планування

Міжнародний аеропорт Денвер відкрився із запізненням на шістнадцять місяців, а перевитрати на його будівництво склали два мільярди доларів.¹

Спільний оборонний проєкт кількох європейських країн «Єврофайтер Тайфун» було представлено на 54 місяці пізніше, а його кошторис склав 19 мільярдів доларів замість семи.

Сіднейський оперний театр, певно, заслуговує на звання легенди усіх часів у плані відтермінування реченців та перевищення коштів на будівництво. Спочатку його планували завершити у 1963 році за 7 мільйонів доларів, проте врешті-решт роботу закінчили у 1973 році за 102 мільйони доларів.²

Чи спали ці окремі прогріхи на думку під впливом вибіркової доступності? Усі ці випадки свідчать про бюрократію чи невдалу державну підтримку? Так, цілком імовірно. Та, крім того, сюди можна припасувати відповідний біас, який повторюється в експериментах з окремими проєктувальниками.

Роджер Бюлер та інші якось опитали своїх студентів, коли ті розраховували завершити особисті академічні проєкти.³ Зокрема, дослідники питали про очікуваний час, до якого студенти планували завершити роботу з імовірністю 50%, 75% та 99%. Як гадаєте: скільки студентів виконали завдання вчасно або раніше терміну з імовірністю 50%, 75% та 99%?

- 13% учасників експерименту завершили свої проєкти до зазначеного ними часу, і були певні цього на 50%;
- 19% здали роботу до зазначеного часу з упевненістю 75%;

1. Також бачив інформацію і про 3,1 мільярда доларів. — Прим. авт.

2. Roger Buehler, Dale Griffin, and Michael Ross, "Exploring the 'Planning Fallacy': Why People Underestimate Their Task Completion Times," *Journal of Personality and Social Psychology* 67, no. 3 (1994): 366–381.

3. Roger Buehler, Dale Griffin, and Michael Ross, "It's About Time: Optimistic Predictions in Work and Love," *European Review of Social Psychology* 6, no. 1 (1995): 1–32.

- і тільки 45% (менше половини!) довели проєкт до кінця вчасно, хоча були впевнені на 99%.

Як писали Бюлер та інші: «Особливо вражають результати з упевненістю 99%. Навіть коли студентів просили давати скромний прогноз, у втіленні якого вони були переконані, впевненість в оцінці часу виконання роботи значно перевищувала їхні досягнення».⁴

Більш відоме це явище під назвою «омана планування». І полягає воно у тому, що люди думають, що вміють планувати. Сміх та й годі.

Ключ до розгадки глибинної проблеми з алгоритмом планування знайшли Ньюбі-Кларк та ін., які виявили, що

- прогнози учасників експерименту на підґрунті реалістичних сценаріїв «якщо усе піде якнайкраще» та
- бажані сценарії «якнайкращого»...

... *ні на йоту* не відрізняються.⁵

Коли людей питають про «реалістичний» сценарій, вони уявляють собі, що все йтиме за планом, без *несподіваних* затримок чи *передбачуваних* нещасть, себто як у їхньому «якнайкращому» сценарії.

Однак, як виявляється, дійсність зазвичай дає дещо гірші результати, ніж у «найгіршому випадку».

Та на відміну від більшості когнітивних упереджень, нам таки відома дієва евристика, покликана вилучити оману планування. Що правда, безладу на рівні Міжнародного аеропорту Денвер нею навряд чи можна зарадити. Проте вона діятиме для особистого планування та навіть маломасштабних організаційних моментів. Ідеться про «погляд ззовні» замість «погляду зсередини».

4. Roger Buehler, Dale Griffin, and Michael Ross, "Inside the Planning Fallacy: The Causes and Consequences of Optimistic Time Predictions," in *Heuristics and Biases: The Psychology of Intuitive Judgment*, ed. Thomas Gilovich, Dale Griffin, and Daniel Kahneman (New York: Cambridge University Press, 2002), 250–270.

5. Ian R. Newby-Clark et al., "People Focus on Optimistic Scenarios and Disregard Pessimistic Scenarios While Predicting Task Completion Times," *Journal of Experimental Psychology: Applied* 6, no. 3 (2000): 171–182.

Люди схильні формувати свої передбачення, тримаючи в голові специфіку поставленого завдання, з якої складають сценарій подальших кроків. Саме це зазвичай і мають на увазі під *плануванням*.

Коли ви ставите перед собою мету, слід продумати місце, час та спосіб дії, визначити, скільки знадобиться часу та засобів, сформувавши план дій від початку і до вдалого завершення. Усе викладене стосується «погляду зсередини», який не враховує неочікувані затримки та непередбачені переломи. І як ми вже пересвідчилися, прохання уявити собі «найгірший сценарій» таки замало, щоб побороти цей наївний оптимізм, — адже люди просто нехтують законом Мерфі.⁶

Погляд ззовні — це зумисне *нехтування* специфікою проекту і переведення погляду на те, скільки часу зайняло виконання попередніх схожих проєктів *у цілому*. Так, це суперечить інтуїції, оскільки погляд зсередини містить на порядок більше подробиць, через що виникає спокуса вважати ретельно продуманий прогноз з усіма наявними даними найдієвішим.

Однак, наскільки ми бачимо з експериментів, що більше подробиць уявляє собі респондент, то більш оптимістичний (і, відповідно, менш точний) його прогноз. Бюлер та ін. попросили експериментальну групу докладно описати свої плани щодо різдвяних покупок, які б містили в собі місце, час і спосіб дії.⁷ У середньому учасники групи планували повністю скупитися за тиждень до Різдва. Іншу групу просто запитали, коли вони планували повністю скупитися на Різдво, і середньостатистичною відповіддю було чотири дні. Обидві групи впоралися в середньому за три дні до Різдва.

У схожому міжкультурному дослідженні Бюлер та ін. виявили, що японські студенти розраховували дописати свої твори за десять днів до реченця. Але здали роботу за день до закінчення терміну. А коли їх запитали, на який день вони справлялися з подібним завданням у минулому, відповіддю було «за день до терміну здачі». У цьому й полягає перевага погляду ззовні над внутрішнім.

6. Суть закону можна висловити афоризмом «Ніщо не зупинить лихо, час котрого настав». — Прим. пер.

7. Buehler, Griffin, and Ross, “Inside the Planning Fallacy (<https://www.lesswrong.com/s/5g5TkQTe9rmPSSvvM/p/CPm5LTwHrvBJCa9h5#cite.0.Buehler.2002>).”

У схожому висновку йдеться про те, що досвідчена людина зі сторони, котра менш свідома деталей, але не раз стикалася з подібними завданнями, часто менш оптимістична та більш точна у своїх прогнозах, аніж розробники.

Отже, є доволі надійний спосіб розвіяти оману планування, якщо ви займаєтеся чимось *загалом* подібним до попередніх проєктів. Досить пригадати, скільки часу зайняло виконання схожих завдань у минулому, не враховуючи *жодних* особливостей задачі. Ще краще — запитати поради у людини ззовні, скільки часу у нього пішло на схожий проєкт.

Ви отримаєте довжелезну відповідь, у якій навряд чи знайдеться місце цілковитому розумінню того, чому саме це завдання займе менше часу. Та головне: ця відповідь слушна. Її сміливо можна брати на озброєння.

Чому істина?

Мета інструментальної раціональності здебільшого очевидна з її назви. Хоча деякі коментатори і питаються, чому раціоналісти не байдужі до істини. На це можна відповісти по-різному — залежить від того, хто питає. І ці відповіді — а вона не одна — впливатимуть на те, як ви її шукатимете.

Можливо, ви поділяєте думку, що пошук істини — справа сама по собі шляхетна, важлива і варта затрачених зусиль. У такому разі ваші пріоритети визначатимуть ваші уявлення про те, які істини найважливіші або коли пошук істини стає найбільшою чеснотою.

Така мотивація, як правило, набуває морального характеру. Якщо ви вважаєте своїм обов'язком зазирнути у безодню невідомості, ви, швидше за все, вважатимете, що й *іншим* варто дивитися у неї, або суворо засуджуватимете тих, хто навмисне відводить погляд.

Я скептично ставлюся до моральності як мотивації до раціональності *не* тому, що відкидаю моральний ідеал, а через певні види неприємностей, які він спричиняє. Не складає проблеми висікти на скрижалях моралі помилкові способи мислення.

Згадайте-но містера Спока — наївний архетип раціональності. Емоційний стан Спока за замовчуванням налаштований на «спокій», навіть коли це зовсім не доречно. При визначенні ймовірностей він часто наводить значущі цифри, які потребують суттєвого калібрування.¹ Втім, цей відомий образ віддзеркалює уявлення багатьох людей про те, як воно — бути «раціональним». Не дивно, що нікому він не відгукується.

Зробити з раціональності моральний обов'язок означає наділити її усіма можливими примхами племінного звичаю. Спочатку люди

1. Наприклад: «Капітане, якщо ви скеруєте наш зореліт прямісінько у ту чорну діру, ймовірність того, що ми виживемо, складає всього-на-всього 2,234%». Однак у дев'яти випадках з десяти *зореліт* уцілів. Яким трагічним бовдуром потрібно бути, щоб настільки занизити ймовірність? — Прим. авт.

приходять до хибних відповідей, а потім обурено заявляють, що чинили як слід замість того, щоб вчитися на своїх помилках.

Які ж іще існують мотиви для пошуку істини?

Можливо, ви хочете досягти якоїсь конкретної реальної мети — побудувати аероплан, і тому вам не обійтися без якогось предметного знання з аеродинаміки. Або щось більш буденне: вам захотілося какао — маєте дізнатися, чи продається у місцевому продуктовому магазині какао-порошок, і вирішити, чи йти у цей магазин або якийсь інший.

Якщо для цього вам потрібна істина, то визначена пріоритетність запитань відображатиме очікувану корисність від отриманої інформації: на скільки можливі відповіді повпливають на ваші рішення, наскільки велике значення вони мають та наскільки великими є ваші очікування знайти відповідь, яка змінить ваш вибір порівняно з початковим?

Може здатися, що шукати правду лиш задля її інструментальної цінності — справа неблагородна (Чи не маємо ми прагнути істини лиш заради неї самої?), проте такі дослідження надзвичайно корисні, оскільки завдяки їм формується зовнішній критерій вивіряння: якщо ваш аероплан впаде на землю або ви зайдете в магазин і ніякого какао там не знайдете, то це свідчитиме про помилку. Ви отримаєте зворотний зв'язок про те, які способи мислення дієві, а які ні.

Або ж ви можете бути небайдужими до істини, бо вам у біса *цікаво*.

Допитливість як один із мотивів для пошуку істини вирізняється особливою чистотою. Якщо ви мотивовані допитливістю, то самі визначите порядок запитань, на які найбільше кортить відшукати відповіді. Що складніше завдання, то вищий ризик зазнати поразки, тим більших зусиль воно вартує, але, зрештою, і набагато цікавіше.

Що допитливість, що моральний обов'язок наділяють істину внутрішньою цінністю. Та все ж проявляти цікавість до незвіданого не те саме, що відчувати моральний обов'язок зазирнути у безодню невідомості. Якщо вам цікаво, ви самі визначите пріоритетність

істин, які вважаєте найзахопливішими, і вони не обов'язково мають бути найважливішими чи найкориснішими.

І хоча чиста допитливість — чудова річ, щойно таємницю розкрито, вона, певно, не дуже баритиметься над вивірянням відповідей. Допитливість як людська емоція існувала ще задовго до давніх греків. Проте саме спостереження того, що певні способи мислення розкрили розуміння, як *керувати світом*, направило людство на шлях Науки. Адже навіть надзвичайно допитливі люди задовольнялися байками про богів та героїв біля тріскотливого вогнища, і нікому й на думку не спадало, що з тими історіями було щось не так.

І все ж якщо ми збираємося вдосконалювати наші навички раціональності, тобто вийти за межі критеріїв ефективності, встановлених мисливцями та збирачами, нам знадобляться усвідомлені переконання про те, як мислити обґрунтовано. Такі переконання можна вважати нормами «пристойності» для раціоналістів. Коли ми розвиваємо нові ментальні програми, їх шлях починається з чіткого розпорядження, і згодом вони поволі — якщо цей момент узагалі коли-небудь настає — навчаються нейронних схем, які лежать в основі наших базових мотивацій і звичок.

Допитливість, прагматизм і позірно моральні приписи — основні складники раціоналістського проекту. Та якби ви запитали мене, що з цього є найбільш засадничим, я б відповів: «Допитливість». У мене є свої принципи і плани, які можуть спонукати мене зазирнути у ту безодню. Мені ж так само цікаво. Що я там побачу? Світ підкинув мені загадку, і розгадка ще ніколи не була настільки близькою.

Відчувати — раціонально

Оскільки допитливість — це емоція, припускаю, що дехто відмовлятиметься вважати її частиною раціональності. У масовій свідомості побутує уявлення про раціональність як про антагоніста усіх емоцій. Мовляв, прояви суму та радості алогічні лиш тому, що вони є *почуттями*. Проте — хай би як дивно це виглядало — я не можу підібрати якоїсь доладної теореми з теорії ймовірностей, згідно з якою я мав би ходити всюди з кам'яним лицем.

Коли кажуть про «емоційність» та «раціональність» як щось протилежне, гадаю, мають на увазі Систему 1 та Систему 2 — швидкі судження, засновані на сприйнятті, на протигагу повільним та усвідомленим роздумам. Однак усвідомлені роздуми не завжди істинні, так само як чуттєві судження не завжди хибні, тому ми маємо розрізняти цю дихотомію від власне раціональності. Обидві системи можуть або служити меті істини, або підривати її — залежить від того, як їх використовувати.

Я, зі свого боку, позначаю таку емоцію «нераціональною», яка ґрунтується на помилкових уявленнях або на такій епістемічній поведінці, що призводить до помилок: «Якщо праска ось-ось торкнеться вашого обличчя, і ви вважаєте, що вона гаряча (хоча насправді холодна), то ваш страх не раціональний. Якщо ж праска ось-ось торкнеться вашого обличчя, і ви думаєте, що вона холодна (хоча насправді гаряча), то ваша незворушність суперечить раціональності». І тоді, навпаки, емоція, породжена вірними уявленнями або епістемічно раціональними роздумами, може вважатися «раціональною емоцією». А тому спокій відносимо до емоційного стану, а не до привілейованої безвиразності.

Отже, чи є раціональність протилежністю почуттів? Насправді ні. Емоції постають із наших моделей реальності. Повірю, що мого мертвого брата знайшли живим, — зрадію. А коли прокинуся й усвідомлю, що це був сон, — засмучуся. Як пише Патриція Крістін Ходжелл: «Що може бути зруйноване істиною — повинне». Щастя,

яке примарилося мені уві сні, суперечило істині. Моє розчарування після пробудження раціональне, і ніякою істиною воно не буде зруйноване.

Раціональність починається з питання «Як улаштовано світ?» і ланцюговою реакцією поширюється на подальші думки, на яких стоять уявлення про світоустрій. Ці ваші уявлення можуть стосуватися всього, що в цій реальності, на вашу думку, існує (чи не існує), а також будь-якого члена класу «речі, завдяки яким можуть відбуватися інші речі». Якщо ви вірите, що у вашій шафі живе підступний курдупель, який зав'яже шнурівки на черевиках, це переконання стосується світоустрою. Черевики справжні — їх ви можете взути. І якщо вже є щось таке, що може дотягнутися до ваших черевиків і зав'язати вам шнурівки, воно ж теж має бути справжнім — частиною розлогої мережі причин і наслідків, яку ми називаємо «всесвітом».

Відчуття гніву на підступного курдупля, який перев'язав вам шнурівки, позначає стан розуму, який *просто* не віддзеркалює дійсного світоустрою. Припустімо, що вас як буддиста, людину з лоботомією чи флегматичної вдачі не турбують зав'язані шнурівки на черевиках. Така знахідка вас аніскілечки не здивувала б, а очікування, що при відкриванні шафи шнурівки так і будуть зав'язаними, ні на йоту не змінилося б. Почуття гніву або спокою у жодному разі не мають впливати на ваше найліпше припущення, оскільки емоції не зарадять тому, що відбувається у вашій шафі. Та для чіткого усвідомлення цього може знадобитися певне зусилля.

Тобто відчуття гніву переплітається зі станом розуму, який *відповідає* за уявлення про світ, і вас охоплює гнів, *тому що* ви переконані, що курдупель зав'язав ваші шнурівки. Раціональність поширюється з блискавичною швидкістю — від початкового питання, чи зашнуровує курдупель мої черевики, аж до спалаху гніву.

Стаючи більш раціональними, себто приходячи до кращих оцінок реальності, ми можемо зменшити вплив почуттів або, навпаки, *посилити їх*. Іноді ми уникаємо сильних переживань, відкидаючи спостереження, відвертаючись від того погляду на світ, що призвів до потужних емоцій. У такому разі, що глибше ви вивчатимете

раціональність, чим краще привчите себе не нехтувати спостереженнями, то сильнішими будуть ваші емоції.

Коли я ще починав, мені не до кінця було зрозуміло, чи *правильними* були мої сильні переживання, чи були вони дозволеними та доладними. Сумніваюся, що лишень моє юнацьке нерозуміння раціональності породило це сум'яття. Я спостерігав подібні проблеми і в людей, які навіть не прагнули стати раціоналістами: коли вони щасливі, вони питають себе, чи дозволено їм проявляти своє щастя, а коли сумні, то ніколи як слід не втямлять, чи варто якомога швидше позбутися цієї емоції чи, навпаки, прийняти її. Щонайменше з часів Сократа (а то й, певно, задовго до нього) існує спосіб здаватися культурним і досвідченим, себто ніколи й нікому не показувати своє сильне занепокоєння чимось. Відчувати *ніяково* — у культурному суспільстві цього просто не роблять. Бачили б ви ті здивовані погляди, якими мене обдаровували люди, котрі усвідомлювали, наскільки я не байдужий до раціональності. Хоча це й наче не якесь химеродство, та все ж вони не звикли бачити людей при тямі, які не приховують своєї пристрасті до *чогось*.

Та тепер я знаю, що немає нічого осоружного у сильних емоціях. А після того, як я прийняв правило «Що може бути зруйноване істиною — повинне», прийшло й усвідомлення «Те, що живиться істиною, має процвітати». Стається щось гарне — почуваюся щасливим, і в моєму розумі не виникає сум'яття з приводу того, чи раціонально відчувати щастя. Коли стається щось зле¹, я не уникаю суму, шукаючи оманливих утіх та отого примарного добра, без якого немає лиха. У своїй уяві я маюю минувшину і майбуття людства, десятки мільярдів смертей за всю нашу історію, оте горе і той страх, пошук відповідей, тремтячі руки, простягнуті ввись з рік крові; я уявляю собі, ким ми можемо стати одного дня, коли поселимося на далеких зорях, увесь той морок і все те світло, котрі не те що описати — ба навіть збагнути достоту — у мене не стало б снаги. Навіть попри всі філософствування мені й досі ніяково визнавати свої сильні емоції, а вам,

1. <https://www.yudkowsky.net/other/yehuda>

певно, неприємно переживати їх разом зі мною. Та тепер я знаю, що відчувати — цілком раціонально.

Лінзи, крізь які видно власні помилки

Сонце випромінює світло, яке потрапляє на ваші шнурівки і відбивається від них. Фотони, що досягають зіниць, потрапляють на сітківку ока. Енергія фотонів породжує нейронні імпульси, які дають сигнал зоровій корі головного мозку. Там оптична інформація піддається обробці, внаслідок чого утворюється тривимірна модель, яка розпізнається як розв'язані шнурівки. Так з'являється розуміння, що ваші шнурівки розв'язані.

У цьому й полягає таємниця *усвідомленої раціональності*: увесь цей процес не оповитий серпанком магії, тому ви можете його зрозуміти. Зрозуміти, яким чином можна побачити свої шнурівки. Ви можете думати про те, які типи мисленневих процесів формують істинні переконання, а які — ефемерні візії.

Миші теж мають зір, але не розуміють, як він функціонує. Завдяки тому, що ви маєте уявлення про те, як функціонує зір, для вас відкриваються можливості, недоступні для мишей. Усвідомлюєте, наскільки це дивовижна річ?

Миші можуть бачити, проте навіть не здогадуються про існування зорової кори у своєму мозку, тому й не можуть врахувати оптичні ілюзії. Миша живе у своєму світі, в якому є місце для котів, шпарин, сиру та мишоловок, та не мійшачих мізків. Їхній зоровий апарат не бачить власних лінз. Однак ми, люди, дивлячись на позірно химерне зображення¹, усвідомлюємо, що маємо справу зі спотворенням. Зовсім не обов'язково завжди вірити своїм очам, однак варто розуміти, як вони *функціонують*, а саме — розрізняти мапу і територію, чуття та дійсність. Та перш ніж ви подумаєте, що здатність до розрізнення — то щось тривіальне, згадайте, наскільки вона рідкісна у тварин.

Суть науки — це, простіше кажучи, рефлексія про те, як надійніше узгоджувати вміст розуму з реальністю. Це саме те, до чого миші ніколи б не додумалися. Осмислюючи питання «проведення

1. <http://www.richrock.com/gifs/optical-illusion-wheels-circles-rotating.png>

відтворюваних експериментів для спростування теорій», ми отримуємо змогу побачити, *чому* воно так працює. Помиляється той, хто вважає, що наука — це окрема магістерія², далека від реалій та розуміння простих смертних. Наука — це не якась така річ, застосовна тільки в лабораторіях. Зрозумілий світовий устрій, що узгоджує переконання людей з дійсністю, є, власне, наукою.

Якщо задуматися, то наука *має сенс*. Проте миші не можуть розмірковувати про мислення, що й унеможливило появу мійшачої науки. Нехтувати такою дивовижною та потенційною силою, яку вона надає нам — окремим особистостям та науковим спільнотам, — було б повною дурістю.

Хоча слід визнати, що розуміння того, як працює мислення, може видатися *дещо складнішим* за розуміння функціонування парового двигуна. Проте *на фундаментальному рівні* ці завдання не сильно й відрізняються.

Якось я зайшов у тематичний чат #філософія у мережі EFNet і запитав одного з тамтешніх користувачів: «Ви вірите, що протягом наступних 20 років розпочнеться ядерна війна? Якщо ні, то чому?» Мій співрозмовник відповів, що не очікує ядерної війни у найближчі 100 років, тому що «Усі гравці, які можуть її розпочати, нині не зацікавлені у ній». «Але навіщо розтягувати аж на 100 років?» — запитав тоді я. «Гадки не маю. Сподіваюся, що її таки не буде» — такою була його відповідь.

З цього діалогу можна виснувати, що думка про ядерну війну робить людину настільки нещасною, що її мозок зовсім відкидає це припущення. Однак якщо ви уявите мільярд світів — гілки Єверетта

2. Термін авторства Стівена Гулда на позначення сфери, в якій певна спільнота володіє владними повноваженнями. Гулд стверджував, що наука та релігія — окремі та неперетинні магістерії. На його думку, релігія має повноваження відповідати на питання вищого сенсу та моральних цінностей (але не емпіричних даних), наука ж, навпаки, займається емпіричними даними (але не сенсами чи цінностями). — Прим.пер.

або світи Тегмарка³, — такий хід думок не наближатиме оптимістів до тих гілок, в яких не сталося жодної ядерної війни.⁴

Якщо ви питаєтеся, при яких переконаннях почуватиметеся щасливим, то це звернення всередину, а не назовні — так дізнаєтеся дещо про себе, але не про навколишній світ. Нічого не маю проти щастя, та воно має бути наслідком вашої картини світу, а не полотном, що його розфарбували ментальними пензлями.

Якщо ви помічаєте, що надія скеровує траєкторію думок *першої ланки* у зовсім інше русло, та усвідомлюєте потенційну помилковість свого розуму як картографічного пристрою, то саме час скоригувати відображення. Мозок — це така неповноцінна лінза, крізь яку ми дивимося на світ. Це стосується і мійшачого, і людського мозку. Однак розум людини здатен розуміти власні похибки: системні помилки та біаси — і надалі коригувати їх. *На практиці* завдяки цій здатності до коригування лінза значно ефективніша. Недосконала, проте набагато потужніша.



3. Max Tegmark, “Parallel Universes,” in *Science and Ultimate Reality: Quantum Theory, Cosmology, and Complexity*, ed. John D. Barrow, Paul C. W. Davies, and Charles L. Harper Jr. (New York: Cambridge University Press, 2004), 459–491, <https://arxiv.org/abs/astro-ph/0302131>.

4. І якийсь мудрагель неодмінно скаже: «Та коли у мене є надія, то я виконуватиму свої робочі обов’язки старанніше, підніматиму світову економіку, а отже, не дозволю країнам скотитися у злість та відчай, за яких можлива ядерна війна. Врешті-решт це ж усе пов’язано між собою». На цьому етапі нам варто підключити теорему Баєса та оцінити співвідношення з кількісної сторони. Ваш оптимізм не може аж так повпливати на світ, щоб зменшити ймовірність ядерної війни на 20% (що б ви там собі не вигадували). Зміна переконань на значний відсоток імовірності через подію, яка лиш трохи підвищить шанси виявитися правим, все одно спотворить ваші уявлення. — Прим. авт.

Хибні уявлення

Вимагайте оренду від своїх переконань (у розмірі очікуваного досвіду)

Так починається давня притча:

У безлюдному лісі падає дерево. Чи породжує воно звук? Хтось скаже:

— *Так, оскільки падіння спричиняє вібрації у повітрі.*

— *Ні, бо в жодному мозку не відбувається оброблення звуку, — відкаже інший.*

Якщо у бойовому мистецтві раціональності і є базова навичка, то нею має бути ментальний стан, на який спирається решта техніки, а саме — здатність виявляти психологічні ознаки того, чи є у вашому розумі ментальна мапа певного явища.

Уявімо, що після того, як дерево вже впало, ці двоє разом заходять у ліс. Чи буде один із них очікувати, що дерево впало на правий бік, а другий — на лівий? Уявімо, що перед падінням вони ставлять біля того дерева диктофон. Чи очікуватиме хтось із них, відмотуючи запис, почути щось відмінне від того, що почув опонент? Уявімо, що вони прилаштують електроенцефалограф до якогось мозку. А тоді очікуватимуть, що прилад видасть два різні графіки активності головного мозку?

І хоча їхні погляди кардинально протилежні (перший відповідає «Так», а другий — «Ні»), вони не розраховують, що результат якось вплине на їхнє сприйняття. Обидва вважають, що у них різні моделі світу, але з огляду на те, як ці переконання *позначаються* на них, між цими поглядами немає жодної чуттєвої різниці.

Існує спокуса усунути цей клас помилок шляхом обстоювання того, що єдино виправданий спосіб формувати переконання — передчувати чуттєвий досвід. Проте у світі насправді міститься багато такого, що не пізнається безпосередньо чуттями. Ми не бачимо атомів, з яких складається цегла, хоч вони там є. Під вашими ногами є

підлога, але ви не *переживаєте* її безпосередньо; ви бачите світло, *відбите* від підлоги — або, точніше, те, що ваша сітківка й зорова кора зробили з цього світла. Виснувати існування підлоги з того, що ми бачимо підлогу, означає відступити до невидимих причин досвіду. Це хоч прямолінійний і нехитрий, та все ж таки крок.

Ось ви стоїте на даху високого будинку; поряд секундною стрілкою цокає годинник дідуса — годинникова і хвилинна нерухомі. У руці ви тримаєте кулю для боулінгу, а потім скидаєте її з самого вершечка. На якій секунді ви почуєте, як куля розіб'ється об землю?

Щоб дати точну відповідь, вам доведеться скористатися переконанням, що *тіло падає на Землю з прискоренням приблизно $9,8 \text{ м/с}^2$, а ця будівля близько 120 метрів заввишки*. Ці переконання — не безсловесні передбачення чуттєвого досвіду; це радше вербалізовані, пропозиційні твердження. Мабуть, не буде перебільшенням описати ці два переконання як речення, що складаються зі слів. Однак ці два переконання мають умовивідний *наслідок* — пряме чуттєве передбачення: якщо під час скидання кулі секундна стрілка стає на позначку «12», ви очікуватимете побачити її на цифрі 1, коли почуєте звук удару через 5 секунд. Щоб навчитися передчувати такий досвід якомога точніше, маємо аналізувати переконання, які не є очікуванням чуттів.

Ось вам і особлива перевага виду *Homo sapiens* — ми, краще ніж інші види на Землі, вміємо моделювати невидиме. Але й при тому це значна слабина. Часто люди вірять у те, що не тільки невидиме, а й несправжнє.

Той самий мозок, в якому утворюється мережа умовивідних причин на основі чуттєвого досвіду, може також генерувати мережу причин, яка ніяк (або слабо) пов'язана з чуттєвим досвідом. Алхіміки вірили, що вогонь горить через флогістон. (А можна було би просто намалювати вузлик під назвою «Флогістон» і стрілку від нього до чуттєвого досвіду тріскотливого багаття.) Проте це уявлення не породило подальших передбачень. Зв'язок від флогістону до досвіду завжди формувався після проведення експерименту, проте не обмежував досвід заздалегідь.

Або ж уявімо, що ваш викладач англійської літератури розповідає, що відомий письменник Валкі Вілкінсен насправді писав у жанрі «ретропозиційності», бо у його книгах присутня «відчужена ресублімація». Певно, він знає, що каже, бо дізнався про це від свого вчителя. Однак усі їхні пізнання про ресублімацію зводяться до ретропозиційного мислення, а ретропозиційність, вочевидь, притаманна відчуженій ресублімації. Що ж тоді ви маєте очікувати від книг Валкі Вілкінсена?

Анічогісінько. Це переконання, якщо його можна так назвати, взагалі не стосується чуттєвого досвіду. Але вам краще запам'ятати пропозиційні твердження про те, що «Валкі Вілкінсен» має атрибути «ретропозиційність» та «відчужена ресублімація», бо їх можна видати на наступному тесті. Ці уявлення поєднані одне з одним, проте так і не в'яжуться із жодним очікуваним досвідом.

Ми можемо вибудувати цілу мережу поєднаних між собою уявлень. Назвемо їх «плаваючими» переконаннями. Вони — ознака суто людської вразливості, збій в умінні *Homo sapiens* формувати більш абстрактно-гнучкі мережі переконань.

Чеснота раціоналіста — *емпірика* — у тому, щоб постійно питати себе, який досвід передбачають (чи краще сказати — забороняють) наші уявлення. Ви вірите, що флогістон породжує вогонь? То, з огляду на це, як мав би поводитися вогонь? Ви вважаєте, що Валкі Вілкінсен пише у жанрі ретропозиційності? Якими б тоді були ваші очікування від письменника? І я не про «відчужену ресублімацію». *Який досвід ви отримаєте, читаючи його твори?* Ви вірите в те, що після падіння у безлюдному лісі дерево все одно породжує звук? То як саме це позначилося б на вашому досвіді?

Та ще краще навіть запитати: який досвід ви *не повинні* пережити? Ви вірите у те, що за допомогою *Élan vital*¹ можна пояснити загадкову життєздатність біологічних істот? Тоді чи стає це переконання на *заваді* чомусь? Що б напевне сфальсифікувало це уявлення?

1. Філософське поняття, введене Анрі Бергсоном. Українською можна перекласти як життєвий порив, життєва сила. — Прим. пер.

Якщо відповідь «Нічого», то таке переконання не *виключає* досвід, а тільки валідуює *будь-який* випадок. Таке переконання «плаває».

Коли ви сперечаєтеся за якесь, здавалося б, конкретне питання, не забувайте про те, яке саме очікування ви відстоюєте. Якщо ви не бачите різниці в очікуваннях, то суперечка, найімовірніше, відбувається довкола ярликів у вашій системі уявлень чи, того гірше, плаваючих переконань, котрі, наче риба-прилипала, в'їлися в систему. Якщо ви не знаєте, чого чекати від ретропозиційності Валкі Вілкінсена, готуйтеся сперечатися до смерті.

Отже, «У що вірити?» — кепське запитання. Краще питати «Чого очікувати?». Питаючи про переконання, починайте з очікувань. Їх слід поставити на перше місце. Для початку кожне припущення має перетворюватися на конкретне очікування, а згодом — сплачувати за своє проживання, надаючи прогнози на майбутнє. Тож якщо якесь переконання заборгувало — виселяйте його.

Притча про науку та політику

За часів Римської імперії цивільні громадяни були поділені на команди «синіх» та «зелених». Кожна сутичка, засідка, групова баталія чи заколот не обходилася без убивств з обох сторін. Ось що писав Прокопій¹ про ворожі стани: «Ворожнеча до супротивників виникає у них без причини і не вщуває ні на мить — не шанують вони ні пут шлюбу, ні родинних зв'язків, ані дружби. Та навіть рідні брати чи інші свояки, що пристали до одного з цих кольорів (кожен до різних таборів), загрузли в розбраті між собою».² З цього приводу Едвард Гіббон писав: «Кожен громадянин, який жадав суспільних чи церковних почестей, мав підтримувати ту чи іншу фракцію».³

Ким же були ті «сині» та «зелені»? Вони були вболівальниками команд синіх та зелених колісниць.

Уявіть собі, що у майбутньому люди будуть вимушені перевертатися у величезну мережу печер, щільно закриваючи за собою усі входи. Незалежно від того, що їх до цього спонукало — епідемія, війна чи радіація, — припускаємо, що Перші Підземельники навчилися вирощувати їжу, добувати воду, очищувати повітря, виробляти електроенергію, загалом — виживати. А їхні нащадки процвітають і навіть будують міста під землею. А про горішній світ не лишилося нічого, крім легенд, записаних на жмутиках паперу. І на одному з таких клаптиків описано *небо* — величезний відкритий простір повітря над безкрайною підлогою. Сам обшир повітря описували як колір небесної синяви, у якому кружляють химерні жмутки бавовни. Однак словосполучення «небесна синява» не всі тлумачать однаково: хтось каже, що йдеться про синій колір, інші ж вважають, що мається на увазі зелений.

1. Прокопій Кесарійський — пізньоантичний грецький історик. — Прим. пер.

2. Procopius, *History of the Wars*, ed. Henry B. Dewing, vol. 1 (Harvard University Press, 1914).

3. Edward Gibbon, *The History of the Decline and Fall of the Roman Empire*, vol. 4 (J. & J. Harper, 1829).

Якщо ще на світанку історії підземної цивілізації «сині» та «зелені» відкрито чубилися між собою, то нині між ними вже укладено перемир'я, яке постало з нестримного відчуття безглуздості спору. Змінилися культурні звичаї. З'явився потужний і заможний середній клас із дієвою системою забезпечення правопорядку, нетерпимою до насильства. У школах дають розуміння історичної перспективи: як довго тривала боротьба між «синіми» та «зеленими», скільки людей у ній загинуло і врешті-решт як мало що змінилося. У голови заклали дивну нову філософію: не приналежність до «синіх» чи «зелених» робить з людини людину.

Проте конфлікт так і не вщух. Суспільство все ще розділене, і за цей час в обох таборах сформувалися різні точки зору на усі можливі сучасні проблеми політичної чи культурної важливості. «Сині» виступають за податки на фізичних осіб, «зелені» ж прагнуть обкласти податками торгівлю. «Сині» прагнуть зробити шлюбне законодавство жорсткішим, тоді як «зелені» хочуть спростити процес шлюботворення. «Сині» мають значну підтримку у міських районах, а прихильники «зелених» — то зазвичай далекі від міського життя фермери та продавці води. «Сині» вважають, що Земля — то велетенська сфера у формі кулі, довкола якої обертається всесвіт, «зелені» ж натомість гадають, що Земля — то велетенська плоска сфера, що обертається довкола іншого небесного тіла під назвою Сонце. Щоправда, не кожен «синій» чи «зелений» тримається позиції власного табору щодо усього на світі, хоч і міський торговець, що вважає небо синім і тримається позиції обкладання податками фізичних осіб та полегшення процесу реєстрації шлюбів, — справді рідкісний птах.

Підземне суспільство і досі поляризоване, а мир у них не те щоб міцний. Дехто щиро вважає, що «сині» та «зелені» можуть і мають товаришувати, і в тому, що «синій» підтримує бізнес «зеленого» або «зелений» ходить до корчми «синього», немає нічого осоружного. І навіть попри всю історію сутичок, з перемир'я, укладеного колись через утому, потроху проростає зерно терпимості — і навіть дружби.

Та ось одного дня легкий землетрус сколихнув підземну цивілізацію. І в тому місці, де через пошкодження відкривається прохід до руїн стародавніх помешкань у верхніх печерах, опинилася група із шістьох туристів. Від такого видива їх наче блискавкою уразило. Вони відчують, як під ногами двигтять земля. Один з туристів спотикається і дряпає коліно. Побоюючись подальших землетрусів, група вирішує розвертатися. На зворотному шляху хтось із них вловлює якийсь дивний запах, що долинає із давно закинутого проходу. Нехтуючи доброзичливими засторогами товаришів, один із них бере заряджений ліхтар і заходить у той прохід. Кам'яна лазівка тягнеться вгору... вгору... аж доки відчайдух не виходить у портал поза межі свого кам'яного світу. Аж раптом — роздолля. Широченний обшир, що простягається вусібіч — куди б оком не кинув. Така територія умістила б тисячі міст. А десь там угорі — нестерпне для його очей джерело світла — пекуча цятка осяває увесь видимий простір — мов оголена нитка розжарення велетенської лампочки. У повітрі кружляють нічим не закріплені жмутки бавовни. А простора сяйлива стега *кольору*...

Тепер розвиток історії залежатиме від того, котрий саме член туристичної групи зважився піднятися тією лазівкою нагору.

Адитья Синя стояла під небесною синявою, і на її вуста поволі забігала усмішка. Усмішка, сповнена болю. Вона відчувала ненависть через уражене самолюбство. Вона пригадала кожен спір із «зеленими», кожную сутичку, кожную оспорювану позицію. *«Увесь цей час ти була права, — тихо мовило до неї небо, — і зараз ти можеш це їм довести»*. Якусь хвилину Адитья ще постояла, упиваючись словами неба та своїм тріумфом, і пірнула у кам'яний отвір, несучи світові просвітлення. Поки Адитья спускалася вглиб печер, вона кілька разів стискала кулаки. *«Перемир'я, — прошепотіла вона, — скінчено»*.

Якийсь час Бєррон Зелений розгублено витріщався на розмай кольорів. Від гіркого розуміння йому скрутило

шлунок — наче лещатами хтось стиснув його нутроші. До очей підступали сльози. Беррон згадав різанину в Катєї, коли армія «синіх» вирізала усіх жителів містечка «зелених» разом з дітьми. Згадав, як легендарний генерал «синіх» Аннас Релл називав своїх противників «збіговиськом прокажених» і «чумою, од котрої треба вилікувати світ сей». Згадав полум'яну ворожість у їхніх очах — і всередині щось обірвалося. *«Як ти можеш бути на їхній стороні?»* — проволав Беррон до неба і розридався. Стоячи тут, під зловтішним небесним склепінням, він тепер на власні очі впевнився: всесвіт — суще пекло.

Чарльз Синій приголомшливо розглядав синю стелю. Як професор у змішаному коледжі він обережно зауважував, що точки зору і «синіх», і «зелених» були однаково тверезі і заслуговували на терпимість. Річ у тім, що небо — метафізичний конструкт, а синява — колір, який різні люди можуть бачити по-різному.⁴ Чарльзу було цікаво, чи «зелений» на його місці справді побачить небо зеленим. Чи може завтра у цей час доби небо стати зеленим? Та він не міг поставити на кін майбуття цивілізації. Це природне явище не мало нічого спільного з філософією моралі або суспільства... Чарльз боявся, що його неправильно зрозуміють. Він зітхнув і розвернувся до кам'яного portalу. Завтра він прийде сюди сам-один і запечатає прохід.

Дар'я — прихильниця «зелених» — судомно хапала ротом повітря на згарищі свого світу. *«Я не відступаю, — пообіцяла собі Дар'я, — не подарую їм цього»*. Усе своє життя вона була за «зелених». А тепер, що — має стати за «синіх»? Її друзі, сім'я — усе оточення відвернеться від неї. *«Завжди кажи правду, навіть якщо твій голос тремтить»*, — казав їй батько, та

4. На спектрі (https://en.wikipedia.org/wiki/Visible_spectrum#/media/File:Linear_visible_spectrum.svg) видимого світла помітно, що відстань між синім та зеленим кольором доволі коротка. — Прим. пер.

нині він в Аїді, а мати її ніколи не зрозуміє. Дар'я не зводила очей з умиротвореної синяви неба, намагаючись змиритися з нею — дихання її сповільнилось. *«Ні, так не можна, — пролеbedіла вона, — зрештою, це не так уже й важко»*. Вона знайде нових друзів, і, можливо, родина навіть пробачить їй... Потім запитала себе із крихтою надії, чи витримає це випробування, стоячи під цим небом. *«Небо... синє»*, — спробувала Дар'я. І лишилася жива, хоч і була вже сама не своя. Дар'я Синя видихнула. І з відчуттям гіркоти повернулася до свого світу, міркуючи над тим, як сказати, що з нею щойно сталося.

Еддин Зелений здійняв очі до синього неба і розреготався сардонічним сміхом. Хід історії цивілізації, в якій він жив, нарешті прояснився. Навіть Еддин не міг повірити у те, що увесь цей час вони були такими довбнями. *«Довбні, — не вгавав він, — довбні, довбні! І весь цей час відповідь була тут»*. Злоба, вбивства, війни — усе це було заради того, що хтось десь колись написав, як і багато інших речей. Ні поезії, ні вроди, нічого з того, про що могла б писати нормальна людина. Усе крутилося довкола беззмістовного спору, який вийшов з берегів. Еддин утомлено притулився до устя печери, міркуючи над тим, як не дозволити цій інформації затягнути його світ у хаос і чи достойні вони взагалі цих знань.

У Ф'єрриса мимоволі перехопило подих. Він застиг від цілковитого подиву та захоплення. Очі Ф'єрриса жадібно ковтали небо, вглядаючись у кожну дрібничку, поволі переходячи до наступної. Синє небо, білі *хмарки*, стільки *незвіданого* назовні, купа місцин та речей (а може, і людей?), яких підземельники ніколи на власні очі не бачили. *«Ах ось він який — цей колір»*, — промовив Ф'єррис і пішов відкривати для себе новий світ.

Віра у віру

Якось Карл Саган розказав притчу¹.

Уявіть, що до вас приходить приятель і заявляє: «У мене в гаражі живе дракон». Чудово! Ви кажете, що хотіли б побачити того дракона на власні очі і вже готові вирушити до гаража — аж раптом: «Та ні, стривай, — відказує вам знайомий, — це *невидимий* дракон».

Тут Саган зауважує, що таку заяву ще можна спростувати. Імовірно, ви підете до гаража свого приятеля і, хоча не побачите ніякого дракона, зможете натомість почути важке дихання, що долинає невідомо відкіля. На підлозі загадковим чином з'являтимуться сліди. Прилади показуватимуть, що щось у гаражі вдихає кисень і видихає вуглекислий газ.

Тепер ви скажете своєму знайомому: «Гаразд, ми можемо піти у твій гараж і почути гучне дихання», а ваш товариш на те хутко відповість, що його дракон *не видає жодних звуків*. Тоді ви запропонуєте виміряти рівень діоксиду вуглецю, але і на це знайомий відкаже, що дракон не дихає. Ви пропонуєте підкинути в повітря мішок з борошном, щоб воно покрило його тіло, унаочнивши обриси. А знайомий не забариться із відповіддю: «Борошно не зачепить його».

Цією притчею Карл Саган доносив хрестоматійну істину: що гірша гіпотеза, тим дужче вона тікає від спростування. Але я переказую цю притчу, щоб донести дещо іншу думку: *десь у свідомості пропонента мусить бути модель цієї ситуації, оскільки він може наперед передбачити, які саме результати експерименту він виправдовуватиме*.

Деякі філософи, глибоко збентежені такими варіантами розвитку подій, питали: «Чи пропонент *справді* вірить у присутність дракона?» Мабуть, гадали, що у людському мозку вистачає місця тільки для одного переконання за раз. Проте насправді мозок складніший. Існують різні типи переконань, і не всі вони є прямими очікуваннями. Пропонент явно не *очікує* побачити щось незвичне за

1. https://rationalwiki.org/wiki/The_Dragon_in_My_Garage

дверима свого гаража. Інакше він не плодив би виправдань. Також може виявитися, що у системі висловлених переконань пропонента знайдеться місце і для плаваючого твердження «*У мене в гаражі живе дракон*». Раціоналістові може здатися, що ці два переконання вступили б у конфлікт, хоч вони й різні. Хай там як, а закони фізики не передбачають того, що якщо на світліні синього неба написати «Небо зелене!», папір займеться синім полум'ям.

Одна з чеснот раціоналіста — емпіризм — має забезпечити нас від цього класу помилок. Ми маємо постійно питати у своїх переконань, які досвіди вони передбачають, і брати з них орендну плату у вигляді очікувань. Однак проблема із пропонентом дракона має глибше коріння. Її не можна розв'язати, слідуючи такій простій пораді. Не так уже й *складно* поєднати віру в дракона з очікуванням досвідом перебування в гаражі. Якщо ви вірите, що у вашому гаражі живе дракон, то й очікуватимете, що за дверима він вас зустріне. Та якщо ніякого дракона ви не бачите, то й нікого, крім гризунів, там і не знайдете. Простіше вже нікуди. Можете навіть зазирнути у свій гараж.

Та ба — цей випадок із невидимістю є симптомом дещо тяжчої хвороби.

Пригадайте той перший раз, коли засумнівалися в існуванні Санта-Клауса, але все ще думали, що *маєте* в нього вірити, тому відкидали будь-які сумніви. Як зазначає Деніел Деннет, якщо вам складно повірити у щось, завжди можна переконати себе, що ви *повинні* у це вірити. Як воно — повірити у цілковиту зелень та синь Сушого Небесного Склепіння? Таке абстрактне твердження збиває з пантелику. Навіть не зрозуміло, про що *свідчить* ця віра: у що саме ви б повірили зрештою? Набагато легше повірити, що у це належить вірити або що є певна *шляхетність*, *праведність* чи *користь* від того, що ви повірите у цілковиту зелень та синяву Сушого Небесного Склепіння. Деннет іменує це явище «вірою у віру».²

І тут ситуація дещо ускладнюється, як це завжди буває, коли йдеться про людський мозок. Гадаю, навіть Деннет має надто спрощене

2. Daniel C. Dennett, *Breaking the Spell: Religion as a Natural Phenomenon* (Penguin, 2006).

розуміння того, як це працює на практиці. Скажімо, якщо ви вірите у переконання, ви не можете зізнатися собі, що ви робите це тільки через те, що це праведно, а не через саму лише віру. Тому якщо ви просто *вірите* у переконання, а не по-справжньому поділяєте його, то не належатимете до категорії праведних. Ніхто не *зізнається* собі у такому: «Я насправді не вірю у зелень та синь Суцього Небесного Склепіння, я вірю в це через те, що маю» — хіба що ці люди здатні визнати власну небажородність. Люди не вірять у віру у віру — вони просто вірять у віру.

(До речі, для тих, кого попередній абзац добряче спантеличив, певно, було б незле опанувати математичну логіку. Адже логіка вчить проводити чіткий вододіл між твердженням Р, доведенням Р та доказом того, що Р довідне. Такий самий вододіл існує між Р, бажанням Р, вірою в Р, бажанням вірити в Р і переконанням, що ви вірите в Р.)

До того ж існують різні види віри у віру. Можна відверто вірити у віру. Можна свідомо речитувати: «Благородно вірити у цілковиту зелень та синь Суцього Небесного Склепіння». (І заодно вірити, що ви вірите у це, хіба що ви наділені рідкісною здатністю усвідомлювати свою небажородність.) Однак є ще менш очевидні форми віри у віру. Можливо, пропонент дракона боїться, що його висміють на людях, щойно він публічно зізнається, що схибив.³ Можливо, пропонент дракона боїться самої лиш думки про те, щоб зізнатися собі у тому, що ніякого дракона таки не існує, тому що вона суперечить його образу славетного першовідкривача драконів, який побачив у гаражі те, що гавили інші.

Якби всі наші думки були — як провадять філософи — свідомими вербальними реченнями, людський мозок було б куди легше збагнути. Швидкоплинні образи, непроговорені страхи, бажання, які без нашого відома керують вчинками, — усе це складає таку саму частину нас самих, як і слова.

3. Хоча раціоналіст привітав би таку щирість, інші, скоріше, візьмуть пропонента на кпини, якщо він і далі торочитиме про існування дракона у гаражі. — Прим. авт.

І хоча я не погоджуюсь із Деннетом стосовно кількох деталей та ускладнень, все ж його ідея про *віру у віру* є ключем до розуміння поведінки пропонента дракона. Але нам потрібна ширша концепція *віри*, яка б не обмежувалася словесними твердженнями. Сенс, який закладається у слові «віра» (або «переконання»), має містити в собі непроговорені регулятори очікувань. Поняття «віра у віру» має охоплювати непроговорені когнітивно-поведінкові орієнтири. З точки зору психології, твердження «Пропонент дракона вірить не в те, що в його гаражі живе дракон, а в те, що йому вигідно вірити в нього» не відповідає реальності. Ближчим же до неї буде той, хто скаже, що пропонент дракона *очікує*, що ніякого дракона у гаражі він не побачить, але *все одно виправдовуватиме* свою віру у це переконання.

Якщо у вашій картині світу дракони не живуть в гаражах, то й ваші очікування відповідатимуть досвіду перебування всередині, і для цього не знадобиться навіть словесний вираз «*У моєму гаражі немає дракона*». Закладаюся, таке траплялося і з вами: коли відкриваєте двері гаража, спальної чи будь-якої іншої кімнати і не очікуєте зустріти дракона, то й думки про його присутність не виникне.

Страх розлучитися з вірою в дракона або гаданим *образом* першовідкривача не обов'язково передбачає чітку думку «*Я хочу вірити, що в моєму гаражі живе дракон*». Цуратися навіть можливості зізнатися собі, що більше не вірите, цілком достатньо.

Якщо ж людина не тільки вірить у своє переконання, що дракони існують, а ще й, власне, вірить у них, то й проблема не настільки глибока. Такій людині закортить кинути оком на те, що покаже експеримент, і якщо результати будуть не на користь її переконання, вона, можливо, навіть відмовиться від нього.⁴ А коли така людина *заздалегідь* шукає виправдання, то це переконання і віра у це переконання, видно, вже розсинхронізувалися.

4. Хоча віра у віру все ще може цьому заважати, якщо саме переконання не є цілком певним. — Прим. авт.

Релігійні твердження та їхня неспростовність

Іронічно, та найперша відома мені згадка наукового експерименту з'являється в історії про пророка Ілля та жерців Ваала¹.

Народ Ізраїлю вагається між Єговою та Ваалом, тому Ілля оголошує, що проведе експеримент, щоб уже ні в кого не виникало сумнівів, який бог істинний. (Для тих часів — мушу зазначити — доволі новаторське рішення!) Жерці Ваала приводять бика на вівтар для свого божества, а Ілля приводить бика для Єгови. Та нікому з них не дозволено розпалювати багаття — тільки справжній Бог має послати вогонь на Свою жертву. Жерці Ваала виконують роль контрольної групи для експерименту Іллі: деревне паливо, бик і священнослужителі, які виголошують заклинання, але до лжебожества, — усі у рівному становищі. Потім Ілля наповнює водою свій вівтар, чим руйнує симетрію експерименту (не слід забувати, що тоді ще не існувало стандартів його проведення), але й свідомо бере на себе тягар доведення, як-от необхідність рівня значущості 0,05. Вогонь зійшов на вівтар Іллі — експериментальне спостереження. Народ Ізраїлю волає: «Господь є Бог!» — дослідження пройшло рецензування.

І потяг ізраїльський народ 450 жерців Ваала за шкибарки вниз річкою Кішон і перерізав їм горлянки. Процедура жорстока, але й конче необхідна. Сфальсифіковану гіпотезу слід усувати рішуче і без вагань — так, щоб вона не встигла знайти виправдання на свій захист. Якщо жерців Ваала таки помилувати, то вони почнуть торочити про релігію як окрему магістерію, яку не можна ні довести, ні спростувати.

У давнину люди саме *вірили* своїм релігіям, а не просто *вірили* в них. Біблійні археологи, котрі намагалися знайти Ковчег Ноя, не відали, що гайнують свій час. Вони очікували здобути славу завдяки гаданій знахідці. І тільки після невдалих спроб відшукати свідчення на

1. <https://www.wordproject.org/bibles/uk/11/18.htm#0>

свою користь — тобто після спростування своєї гіпотези — віряни здійснили, що називав Вільям Бартлі, *перехід до відданості*: «Вірю, бо така моя віра».

У давнину навряд чи комусь спадало на думку назвати релігію окремою магістерією. Старий Завіт — це такий собі потік свідомості обізнаного вар'ята, в голові котрого знайшлося місце для історії, права, притч і навіть моделей світобудови, як-от: створення всесвіту за шість днів (тлумачиться як метафора на Великий вибух) або ремігання зайців. (Так само метафора на ...)

У давнину сказати, що релігію «не можна спростувати», означало бути спаленим на вогнищі. Ортодоксальний юдаїзм ґрунтується на вірі в те, що Бог з'явився перед Мойсеєм на горі Синай і громоподібним голосом мовив: «Так, це все правда». З точки зору баєсіанства, це до біса однозначний доказ існування надлюдської сутності. (Хоча це й не свідчить, що ця сутність і є *тим самим* Богом або що сутність доброзичлива. Може, то взагалі так розважалися прибульці-підлітки.) У більшості релігій за всю історію людства — за винятком створених *зовсім* недавно — знайдеться місце для історій, події в яких, якщо такі взагалі були, становлять беззаперечні свідчення. А от уявлення про протилежність релігійних та фактологічних питань виникло *не так давно* і *суто на Заході*. Однак люди, які писали священні тексти, схоже, гадки не мали про цю різницю.

Римляни успадкували філософію від давніх греків, запровадили закони та імперський устрій у своїх провінціях, вели адміністративну звітність та насаджували релігійну терпимість. Через те у Новому Завіті, створеному у часи Римської імперії, прослідковуються риси сучасності. Вкрай важко написати історію про те, як Бог стер з лиця землі Рим (подібно до Содому та Гоморри), адже римські історики так просто цього не залишили б. А так просто закидати їх камінням не виходило.

Люди, які писали Старий Завіт, могли собі додумати що заманеться. Ранні єгиптологи були щиро здивовані тим, що їм не вдалося знайти жодних слідів перебування гебрейських племен у Єгипті. Хай не свідчення десятиох кар, та вони очікували знайти бодай *щось*.

Однак щось їм таки вдалося знайти. Дослідники виявили, що під час імовірних подій, описаних у Книзі Вихід, Єгипет володів більшою частиною Ханаану. Це — приклад *колосальної* історичної омани, коли через відсутність бібліотек ніхто не міг оскаржити наявні дані.

У Римській імперії були бібліотеки. Тому-то у Новому Завіті немає місця для видовищних масштабних геополітичних чудес, які повсякчас з'являлися на сторінках Старого Завіту. Та все ж писарі Нового Завіту вписали менші дива, які, однак, узгоджуються із римською системою свідчень. Хлопчик падає додолу, і з його рота виходить піна. Причина — нечестивий дух. Послідовним буде очікування, що нечестивий остерігатиметься справжнього пророка, а не якогось пройдисвіта. Ісус виганяє злого духа — Ісус не якийсь пройдисвіт, а справжній пророк. Цілком пересічний випадок баєсового мислення, якщо ви допускаєте основну вихідну умову, що епілепсія спричиняється демонами (кінець епілептичного нападу доводить, що демона вигнано).

Та й не наукою єдиною — у релігії знайдеться точка зору на *кожну* сферу людської діяльності. Релігійні переконання лягли в основу правової системи до того, як з'явилися органи законодавчої влади; релігійні наративи формували історичну пам'ять до того, як історики та археологи взялися до справи; релігійні переконання формували сексуальну етику ще до того, як виник Рух визволення жінок; у релігійних книжках форми правління були описані ще до укладання конституцій; а також у релігій уже були відповіді на всі питання науки — від таксономії в біології до формування зір.² Модерне уявлення про релігію як суто набір *етичних* принципів зумовлене тим, що всі інші сфери були перейняті ефективнішими інституціями. *Лишилася етика.*

Чи то б пак люди *гадають*, що нею ще не зайнялися. Візьмімо культурну прірву 2500-річної давнини. З часом людство досягне такого рівня розвитку, що зможе позбутися рудиментів тієї культурної

2. У Старому Завіті не йдеться про трансцендентне переживання складності всесвіту, тому що його укладачі були надто заклопотані прописуванням смертної кари для жінок, які носили чоловічий одяг. Такий контент задовольняв релігійні настрої тогочасної аудиторії. — Прим. авт.

прірви. Прогрес не оминає й етику: скажімо, нині ми не вважаємо легітимізоване Біблією рабство нормальним явищем. Чому тоді люди досі *вважають*, що етика є предметом для відкритих спекуляцій?

Не слід нехтувати етичною проблемою вбивства тисячі невинних немовлят-первістків, щоб переконати необраного фараона звільнити рабів. Логічно було би просто телепортувати їх із країни. Принаймні ця подія *відразу* впадає у вічі на відміну від відносно тривіальної помилки, що у коників чотири лапки. А от назвете Землю плоскою — люди кидатимуть на вас здивовані погляди. Але назвете Біблію етичною опорою — жінки уже не даватимуть вам ляпаса. Уявлення більшості людей про раціональність вимірюється тим, що, на їхню думку, може зійти їм з рук. Думають, що їм може зійти з рук схвалення біблійної етики, і тому вони вдаються до самоомани, щоб не помічати моральні проблеми у Біблії. Усі вони домовилися не помічати слона у вітальні, і ця домовленість може протриматися ще бозна-скільки.

Можливо, одного дня людство дійде до того, що будь-кого, хто називає Біблію етичною опорою, сприйматимуть як підтримку президентської кампанії сенатора Строма Термонда Трентом Лоттом.³ А потім скажуть, що ядром релігії завжди була генеалогія або ще щось.

Твердження про те, що релігія — окрема магістерія, котру *не можна ні довести, ні спростувати* — Велика брехня, яку невтомно торочать із кожної праски, що воно вже в'їлося в мозок. Та при критичному розгляді не більше, ніж звичайна хіба. Якщо подивитися на те, яке місце релігія займала протягом історії, як у святих писаннях викладено віру, як підштовхують дітей до неї, і в що більшість релігійних людей і досі вірять, то релігія далеко не окрема магістерія. Таке нахабство межує хіба що із твердженням «*Океанія ніколи не воювала з Остазією*».⁴ Обвинувач дістає закривавлену сокиру, й

3. Термонд балотувався як кандидат у президенти від діксикратів, які закликали до продовження расової сегрегації на Півдні. — Прим. пер.

4. У романі Джорджа Орвелла «1984» Остазія виступає то противником, то союзником Океанії. — Прим. пер.

обвинувачений, захоплений зненацька, хутко мізкує і видає: «Але ти не можеш спростувати мою невинність простими свідченнями, адже це окрема магістерія!».

А якщо і така витівка не спрацює, то завжди можна розраховувати на невинне помилування.

Сповідувати та вболівати

Якось я брав участь ув обговоренні на тему сумісності науки та релігії. Одна пані — язичниця — увійшла в кураж, розповідаючи про те, як творився світ. Згідно з її версією, у прадавній безодні народилася гігантська первісна корова, яка, облизуючи солону кригу, дала життя першому богу-велету. Його нащадки вбили прабатька і, розчленувавши його труп, створили Землю. Її розповідь була довгою, розлогою і навіть ще абсурднішою, ніж оповідка про Землю, яка стоїть на спині здорової черепахи. А вона, між іншим, була досить обізнаною у питаннях науки, щоб дійти до того своїм розумом.

Мені все ще бракує слів, щоб описати той стан, у якому та жінка розповідала всю ту історію. Вона говорила з... гордістю? самовтіхою? Чи зумисне хизувалася своїми переконаннями?

Пані і не думала зупинитися. Здавалося, її розповідь про створення світу тривала цілу вічність, хоч насправді минуло, мабуть, хвилин п'ять. Очевидно, ця дивна гордість/задоволеність/хизування була якось пов'язана з її *усвідомленням* своїх поглядів як абсурдних з точки зору науки. Ні, вона була не з тих, хто ганить науку, адже під час дискусії відстоювала позицію сумісності релігії та науки. Крім того, вона згадала, що з огляду на батьківщину вікінгів немає нічого дивного у тому, що в їхніх оповідях була первісна безодня — вона розпояснювала цю деталь своєю релігією! — але потім все-таки наголошувала, що такою є її «віра». Останнє слово вона вимовляла з особливою насолодою.

Не певен, чи концепт Деніела Деннета про «віру у віру» стосується цього випадку. Це було щось екзотичніше. Вона не переказувала свій міт про створення світу із запалом фанатика з потребою самоствердитися. Не поводитися так, ніби очікувала, що їй удасться переконати аудиторію, чи ніби їй була потрібна наша віра як знак її правоти.

Крім поняття «віра у віру», Деннет запропонував вивчати те, що називають «релігійною вірою», як «релігійну декларацію віри».

Уявімо, що антрополог з іншої планети досліджує групу студентів, які вивчають англійську літературу і *переконані*, що Валкі Вілкінсен пише у жанрі «ретропозиційності». У такому разі доцільніше буде запитати не «Чому всі студенти носяться із цим дивним переконанням?», а «Чому у тестах так дивно формулюють питання?». Навіть якщо питання звучить безглуздо, ви все одно можете знати, коли час декларувати відповідь.

Гадаю, прирівняння Деннетом релігійної декларації віри до *простого* сповідування віри дещо грубе — адже більшість людей досить щирі у своїй вірі: якщо вони виголошують релігійне твердження, то почуваються зобов'язаними повторити його у своїй голові.

Проте, схоже, навіть «релігійна декларація віри» не стосується твердження язичниці про віру у первісну корову. Якби у вас на думці було виголосити релігійне переконання, щоб потішити священника чи одновірця — та бодай навіть щоб відчутти себе частиною релігійної спільноти, — вам довелося б *удавати* віру *набагато переконливіше*, ніж робила та пані. Переказуючи свою байку про первісну корову з тим самим дивним відчуттям гордості, вона навіть не *намагалася* переконати нас, що цілком серйозно ставиться до своєї релігії. Гадаю, саме це і спантеличило мене у її розповіді. Я знаю людей, котрі вважають, що вірять у безглузду дурню. Коли ж вони заявляють про це, то витрачають набагато більше зусиль, щоб переконати себе, що сприймають свої переконання серйозно.

Урешті-решт до мене дійшло, що ця жінка не намагалася переконати ані себе, ані нас. Міт у її переказі взагалі не *стосувався* створення світу. Виголошуючи свою п'ятихвилинну тираду про первісну корову, вона, скоріше, *вболівала за язичництво* подібно до того, як уболівальники розмахують саморобними плакатами на футбольних матчах. Плакат із написом «ВПЕРЕД, СИНІ!» не є констатацією факту чи спробою переконати — його намалювали, щоб підбадьорити.

Ця дивна гордість напоказ... це було так, наче вона вийшла на гей-парад у чому мати народила.¹ Та її виступ не був простим

1. Якщо що, я не засуджую похід голяка на гей-параді. І це взагалі не підпадає під категорію явищ, які може знищити істина. — Прим. авт.

уболіванням, як під час матчу, — воно було обурливим, як вихід голяка, з вірою в те, що її не заарештують чи засудять лиш тому, що вона робить це для свого параду.

Саме тому для неї було важливо, щоб розповідь була гротескно комічною. Якби вона хотіла, щоб історія звучала більш правдоподібно, то хоча б одягнулася.

Віра напоказ

У попередніх есеях я розрізняв переконання як регулятор очікувань, віру у віру, сповідування та вболівання. Серед них переконання, що встановлюють рамки для очікувань, можна назвати «правильними», а інші види — «неправильними». Та якщо, скажімо, щиро сподіватися на те, що молитва лікує хворих немовлят, навіть «правильні переконання» можуть бути хибними та ірраціональними. А от решта видів, схоже, «і не переконання зовсім».

Та все ж існує ще один вид неправильних переконань — переконання як маркер приналежності до групи. Робін Гансон уводить в ужиток чудову метафору¹, суть якої полягає у звичаї всередині групи носити незвичний одяг, як-от священницькі ризи чи шаламоки.² Тому, за аналогією, назвू цей вид переконання «вірою напоказ».

З точки зору реалістичної людської психології³, мусульмани, котрі скеровували літаки у Всесвітній торговий центр, безсумнівно, бачили себе героями і захисниками правди, справедливості та ісламського шляху від огидних іншопланетян, як у фантастичній стрічці «День незалежності». Заявити такє десь у барі в штаті Алабама може хіба що зовсім не досвідчений душній, котрий поняття зеленого не має, як сприймають світ недушній. За таке в Америці можна й облизня піймати. Справжній американський патріот сказав би, що вони кляті терористи, які «зневажають нашу свободу», а влетіти літаком у будівлю — «вчинок боягуза». Ви не можете використовувати словосполучення «героїчна самопожертва» і «пілот-смертник» в одному реченні, навіть якщо намагаєтеся якомога точніше описати світогляд свого Ворога. Саме тільки *уявлення* про відвагу та альтруїзм пілота-смертника — це вбрання Ворога, оскільки лише Ворог про це і говорить. Боягузтво та соціопатія пілота-смертника — американське

1. https://lesswrong.com/lw/i6/professing_and_cheering/egb

2. Також — ярмўлка. Традиційний єврейський чоловічий головний убір. — Прим. пер.

3. <https://www.lesswrong.com/posts/28bAMAxhoX3bwbAKC/are-your-enemies-innately-evil>

вбрання. Ви просто не можете говорити про так званий героїзм Ворога, коли йдеться про його світогляд. Це все одно що перевдягнути-ся в офіцера СС на Хеловін.

«Вірою напоказ» можна пояснити, чому люди *захоплюються* неправильними переконаннями. У випадку віри у віру або ствердження власної релігійності дещо проблематично породити справжній, глибокий, емоційний зв'язок із переконанням. Принаймні така моя гіпотеза, але зізнаюся: я не компетентний у цьому питанні. Проте у мене таке враження, що люди, які облишили всяку надію на істинність своєї релігії, зроблять усе можливе, щоб *переконати* себе у своїй ревності. І цей відчай можна помилково витлумачити як пристрасть. Це вже не той вогонь віри, що колись палахкотів у серці дитини.

З іншого боку, для людини на рівні нутра прийнятно відчувати себе частиною групи, вболівати за улюблену спортивну команду.⁴ Визначення себе через приналежність до племені — потужний емоційний рушій. Люди вмиратимуть за своє плем'я. І щойно ви переконаєте людей у приналежності до племені, вони із непохитною щирістю одноплемінника виголошуватимуть переконання, які відповідатимуть стилю одягу у цій групі.

4. Це фундамент, на якому тримається брехня «республіканці проти демократів» та подібні хибні дилеми в інших країнах. Але це вже тема для іншої розмови. — Прим. авт.

Удавання мудрості

Найгарячіші місця у пеклі залишені для тих, хто в часи скрути зберігав нейтралітет.

Данте Аліґ'єрі, знаний фахівець з питань пекла
Джон Фіцджеральд Кеннеді, невірно процитував¹

Віра — кількісна величина: відносно своїх очікувань можна заявляти про щось як *надміру* впевнено, так і *недостатньо* впевнено. Отже, напоказ можна виставляти свою невпевненість — тобто сповідувати агностицизм, проте не бути агностиком. Тут я окреслю особливий випадок недоречної невизначеності, а саме — демонстрацію *нейтралітету* або *відстороненого судження* з метою дати знати про свою зрілість, неупередженість або вищу точку зору.

Прикладом можуть слугувати мої батьки², які на теологічного штибу питання «Чому у Стародавньому Єгипті, де збереглися записи чого завгодно, немає жодних згадок про те, що там були євреї?» відповідали: «Коли я був у твоєму віці, то, бувало, ставив такі ж питання, але я вже переріс їх».

Або директор школи, котрий заскочив двох школярів на бійці на спортивному майданчику і з суворим виразом обличчя заявляє: «Неважливо, хто розпочав бійку, важить тільки те, хто її закінчив». Звісно, знати, хто розпочав бійку, важливо. Можливо, директор не володіє надійною *інформацією* про це вирішальне свідчення. Та навіть якщо так, він мав би *сказати* про це, а не *применшувати важливість* того, хто завдав першого удару. Цікаво було б поспостерігати, як довго протримався б аргумент «Неважливо, хто розпочав», якби хтось із батьків спробував натовкти пику директору. Дорослим же бійка дітей просто *не вигідна*, і для їхнього *комфарту* зовсім не важить, хто першим підняв кулак. *Вигідно*, щоб сварка скінчилася якомога швидше.

1. <https://web.archive.org/web/20210305154727/http://www.bartleby.com/73/1211.html>

2. <https://www.lesswrong.com/posts/rM7hcz67N7WtwGGJq/against-maturity>

Гадаю, саме такий підхід застосовують і на арені міжнародної політики, де гегемони вимагають від менших держав *негайно* припинити боротьбу. Гегемона не цікавить, хто розпочав, спровокував або неадекватно відреагував на провокацію, оскільки поточний конфлікт є причиною наявного *дискомфорт*у гегемона. Та хіба Ізраїль і ХАМАС не можуть просто поладнати?

Я називаю це явище «вдаванням мудрості». Певна річ, способів проявити мудрість існує багато. Проте тактика відмовлятися робити припущення — підсумовувати свідчення, виносити вирок, ставати на чийсь бік — і натомість вивищуватися над метушнею дурних смертних та дивитися на суперечку зверхнім поглядом мудрого дорослого, себто мовчати і відмовлятися від суджень, відгонить мені неабиякою претензійністю.

«Якщо ви відмежовуєтеся від конфлікту між сильними та слабкими, — казав Пауло Фрейре, — ви стаєте на сторону сильного, а не зберігаєте нейтралітет».³ Якщо вчителям немає діла до того, *хто розпочав бійку*, спортивний майданчик — вигідна позиція для цькувальника і програшна для його жертви. Те саме можна сказати і про міжнародну політику: у світі, в якому гегемони відмовляються приймати чиясь сторону, а тільки те й роблять, що вимагають миттєвого перемир'я, наявні всі умови для агресорів та немає можливостей для упосліджених. І, звісно, у такому світі доволі зручно бути одним із тих гегемонів або директором школи. Отже, частково таку поведінку можна списати на чистий егоїзм з боку «мудрих».

А частково така поведінка спрямована на те, щоб піднести свою точку зору над іншими. Що б зрештою подумали *інші дорослі* про директора, який фактично *став на чиясь сторону* у бійці між *дітлахми*? В очах батьків директор просто впав би до рівня *учасника сутички*.

Свою репутацію чесної людини не бажає втрачати і шанований мудрець — генеральний директор, авторитетний академік чи засновник поштової розсилки. Їхній імідж залежить від готовності

3. Paulo Freire, *The Politics of Education: Culture, Power, and Liberation* (Greenwood Publishing Group, 1985), 122.

відмовитися від винесення суджень, коли інші таки піддаються цій спокусі. Шукаючи підтримки, сторони майже ніколи не знаходять її у шанованих мудреців, оскільки ті вважаються шанованими доти, доки винесуть свій перший вирок — *інакше* їх уважали б просто ще одним учасником спору, нічим не кращим за інших.⁴

Але і *не* обходиться без випадків, коли раціональніше не поспішати із судженнями, коли через свої упередження краще не квапитись із висновками. Якось один із коментаторів Майкл Руні написав⁵:

Ця помилка схожа на ту, на якій я постійно ловлю першокурсників філософського факультету: коли з'являються причини для скептицизму, вони стають на сторону релятивізму. Тобто, коли раціонально утриматися від судження стосовно проблеми, більшість висновує, що усі судження один одного варті.

Як же тоді можна уникнути вдавано раціоналістичної поведінки, суть якої — вип'ясти свою неупереджену безсторонність і заявити, що поточний розподіл свідчень рівномірний? «Ну, звісно ж, у вас там стільки тих замотивованих дарвіністів, але, як на мене, ще не достатньо свідчень, щоб віддавати перевагу природному добору над розумним задумом».

Тут доречно підмітити, що *нейтральність* — це *теж* певне судження, а не *високочале* абстрагування. Це як висунути конкретну позицію про те, що розподіл свідчень у конкретному випадку дозволяє зробити *тільки* один висновок — на користь нейтральності. І це переконання також мусить платити оренду очікуваням досвідом. Відстоювання нейтральності має стати вразливим для критики, як і просування будь-якої іншої сторони.

Та сама ситуація і з питаннями політики. Коли говорять, що як прихильники, так і противники абортів мають вагомі аргументи,

4. Як не дивно, професійні судді можуть неодноразово виносити чинні вирoki, і вони не ризикують своєю репутацією неупередженої людини. Можливо, тому що такою є загальноприйнята норма: вони мають повноваження на здійснення правосуддя. Або, можливо, суддям не доводиться постійно ухвалювати непрості рішення, які б розкололи плем'я, у якому вони користуються повагою. — Прим. авт.

5. https://www.greaterwrong.com/lw/he/knowning_about_biases_can_hurt_people/dza

тому їм краще порозумітися і навчитися поважати погляди одне одного, то цим аж ніяк не займають позицію *над* обома сторонами у цій дискусії. Цим вони висувають певне судження — таке саме, як і «за» та «проти» абортів.

Якщо ви ставите перед собою ціль покращити навичку формувати більш точні переконання, у пригоді може стати тактика уникати емоційно забарвлених тем, як-от аборти або ізраїльсько-палестинський конфлікт. Та це зовсім *не* означає, що раціоналісти занадто розумні, щоб говорити на політичні теми. Це *не* означає, що раціоналісти не достойні метушні дурних смертних, в якій беруть участь хіба що політичні діячі та завзята молодь.

Робін Гансон пише про те, що здатність вести розмови, які можуть призвести до чвар, — це обмежений ресурс. Якщо ви можете запропонувати способи потягнути канат убік, то маєте підстави витрачати свій обмежений ресурс на відносно рідкісніші питання, для яких граничний вииграш від додаткового обговорення є відносно більшим.⁶

Але потім, якщо ви відмовляєтеся від певних обов'язків, то це привід для визнання обмеженості своїх ресурсів. А *не* для високочолого піднесення над іншими у всій своїй безтурботності й мудрості.

Врешті-решт, є різниця між

- винесенням нейтрального судження,
- відмовою вкладати в обговорення обмежені ресурси
- та удаванням, що якийсь із вищезазначених пунктів свідчить про глибоку мудрість, зрілість та вищість точки зору, з чого можна виснувати, що початкові сторони конфлікту займають начебто нижчі позиції, нічим не кращі від тих, що зазначені у перших двох пунктах.

6. Див. Hanson, “Policy Tug-O-War” (https://www.overcomingbias.com/2007/05/policy_tugowar.html) та “Beware Value Talk” (<https://www.overcomingbias.com/2009/02/the-cost-of-talking-values.html>).

Знак «ОПЛЕСКИ»

Під час саміту сингулярності у 2007 році один із доповідачів закликав до розроблення штучного інтелекту на засадах демократії та багатонаціональності. Після його промови я підійшов до мікрофона і запитав:

— Уявімо, що ряд демократичних республік засновує консорціум із розробки ШІ, і в процесі розгортається бурхливе політиканство: одні групи інтересів отримують непристойно велику сферу впливу, а решта лишається ні з чим. Іншими словами, у підсумку маємо те саме, що породжують сучасні демократії. Або ж уявімо, що у підвалі група бунтівних технарів розробляє ШІ, дає йому вказівку провести всесвітнє опитування — скидають мобільні телефони усім, хто їх не має, щоб вони змогли проголосувати — і робить те, що обере більшість. Який із цих варіантів вам здається більш «демократичним»? Чи почувалися б ви у безпеці при бодай одному розвитку подій?

Я волів з'ясувати, чи вбачає він у демократичному політичному процесі прагматичну адекватність чи просто вважає, що голосувати правильно з моральної точки зору. Доповідач відповів:

— Перший сценарій схожий на редакційну статтю у журналі *Reason*,¹ а другий — на сюжет голлівудської кінострічки.

Спонтелічений відповіддю, я запитав:

— Тоді який демократичний процес ви *мали* на увазі?

Доповідач відповів:

1. Reason (англ. Розум) — американський лібертаріанський щомісячний журнал, метою якого є підтримка незалежної журналістики, що «висвітлює події поза межами ехокамери “лівих” і “правих”». — Прим. пер.

— Щось на кшталт проєкту геному людини — дослідницького проєкту із міжнародним фінансуванням.

Я запитав:

— Тоді як різні групи інтересів вирішували б свої конфлікти у такій структурі, як Проєкт геному людини?

Мій співрозмовник відповів:

— Не знаю.

Цей діалог нагадав мені слова² якогось диктатора, котрого запитали, чи має він намір змінити свій політичний курс у бік демократії:

Гадаю, ми вже стали демократичною країною. Хоча дечого ще бракує — волевиявлення народу, наприклад.³

Сутність демократії — це конкретний механізм, за допомогою якого вирішують політичні конфлікти. Якби всі групи мали однакові політичні вподобання, у демократії не було би потреби — ми чудово співпрацювали б і без неї. Процес прийняття рішень може здійснюватися прямим голосуванням більшості або обраним законодавчим органом, або навіть штучним інтелектом, що динамічно реагує на голоси. Має бути *якийсь* механізм. Як *тлумачити* пропозицію закликати до «демократичного» рішення, якщо у вас немає на прикметі ніякого механізму врегулювання конфліктів?

Гадаю, пояснити таку недалекоглядність можна очікуваним уболінням за слово «демократія». Це навіть не стільки пропозиційне твердження, скільки відповідник до знака «ОПЛЕСКИ», що сповіщає аудиторії, коли час перейти до оплесків.

Цей випадок примітний лише тим, що я сприйняв сигнал до оплесків за стратегічну пропозицію, чим збентежив усіх учасників

2. <https://time.com/archive/6700533/roberto-eduardo-viola-dead-underground-or-abroad/>

3. Слова президента Аргентини (29 березня — 11 грудня 1981) Роберто Едуардо Віоли. — Прим. пер.

саміту. Більшість сигналів до оплесків набагато очевидніші. Виявити їх можна за допомогою простого тесту на зворотність. Наприклад, хтось каже:

Нам слід збалансувати ризики та можливості ІІІ.

Якщо змінити твердження на протилежне, отримаєте:

Ми не повинні збалансовувати ризики та можливості ІІІ.

Оскільки обернене твердження звучить ненормально, то початкове, ймовірно, є нормальним, а отже, не несе нової інформації. Існує низка обґрунтованих причин, навіщо виголошувати речення, яке саме по собі не вельми інформативне. Реченням «Нам слід збалансувати ризики та можливості ІІІ» можна розпочати розмову і наголосити на важливості конкретної пропозиції зі збалансування і/або критикувати незбалансовану пропозицію. Якщо посилається на звичне твердження, воно може бути інформативним для обмеженого часовими та обчислювальними ресурсами раціоналіста, хоча сам зв'язок може бути не очевидним. Але якщо після цього твердження немає ніякої конкретики, то, швидше за все, це сигнал до оплесків.

Іноді мене долає спокуса зачитати промову, яка складатиметься з *одних лише* сигналів до оплесків, і читати, аж поки аудиторія не хапатиметься за животи:

Метою моєї сьогоднішньої промови є пропозиція збалансувати ризики та можливості передового штучного інтелекту. Ми повинні уникати ризиків і, наскільки це можливо, втілювати можливості. Не слід безпідставно протистояти небезпекам, не вартим нашої уваги. Для досягнення цих цілей нам варто розробити мудрий та раціональний план дій. Ні страх, ні паніка, ні технофобія не мають впливати на наші рішення, але й не варто уповати на сліпий ентузіазм. Маємо поважати інтереси усіх сторін, які зацікавлені у сингулярності. Ми маємо прагнути до того, щоб перевагами передових технологій користувалися якомога більше людей, а не тільки обмежене

коло осіб. Ми повинні докласти всіх зусиль, щоб уникнути конфліктів із використанням цих технологій, а також не дозволити, щоб руйнівний потенціал потрапив у руки окремих осіб. Поки не стало надто пізно, варто починати задумуватися над цими питаннями до, а не після...



Навчитися помічати спантеличення

Зосередити свою невизначеність

Вартість облігацій зростає, впаде чи вийде на плато? Якщо ви балакаюча голова на екрані телевізора і суть вашої роботи зводиться до пояснення наслідку постфактум, то нема чого перейматися. Незалежно від того, *як саме* з трьох версій справдиться, ви знайдете пояснення, чому результат так плавно лягає на вашу улюблену ринкову теорію. Нащо припускати, що ці три версії якось *суперечать* між собою або *виключають* одна одну? Головне, що ви заробили собі балів експерта, і вже грець із тим наслідком.

Стривайте ж! Уявімо, що ви робите перші кроки на вашому шляху до кар'єри *балакаючої голови* і вам бракує досвіду у висмоктуванні правдоподібних пояснень із пальця. Вже завтра етер, а час на підготовку обмежений. У такому разі не завадило б знати, *котрий* із наслідків насправді станеться — вартість облігацій зростає, впаде чи вийде на плато, — оскільки тоді потрібно буде підготувати тільки один сценарій.

На жаль, нікому не під силу передбачити майбутнє. Що ж тоді робити? Звісно ж, ви не використовуватимете «ймовірності». Ще зі школи усі знають¹, що «ймовірності» — це такі малі числа, які з'являються у математичних задачах. Але ж хіба вони тут доречні? Оце жахливе *відчуття* непевності! Ви не пам'ятаєте *його*, відколи за допомогою тих малих чисел розв'язували математичні задачі. *Шкільний клас математики* — охайне, приємне місце, тому математику не можна застосовувати до життєвих ситуацій, які далеко не приємні. А що як ви мимохіть припуститеся помилки, коли застосовуватимете ці навички мислення в іншій сфері? Ні, це точно не питання «ймовірностей».

Хай там як, а в запасі всього-на-всього 100 хвилин на підготовку. Витратити по 100 хвилин на кожну з версій не випадає. Варто якось порозставляти пріоритети.

1. <https://www.lesswrong.com/posts/48WeP7oTec3kBEada/two-more-things-to-unlearn-from-school>

Якби вам довелося пояснювати комісії, на що ви витратили час і в якому співвідношенні, то потрібно було б розподілити час підготовки порівну на кожен сценарій. Немає малих чисел — немає документального підтвердження, яке б виправдовувало нерівномірний розподіл часу. У комісії могли б сказати щось на кшталт: «Пане Фінкклдінгере, чому ви витратили саме 42 хвилини на сценарій номер три? Чому не 41 хвилину чи 43? Визнайте: ви не досить об'єктивні! Ви віддаєте перевагу суб'єктивним уподобанням!».

Але — яке полегшення! — немає такої комісії, яка б вам дорікнула. Це радує, тому що вже завтра у Федеральній резервній системі зроблять важливе оголошення, і навряд чи ціни на облігації лишаться на тому самому рівні. Адже ви не хочете витратити дорогоцінні 33 хвилини на виправдання сценаріїв, які вам не стануть в пригоді.

Ваш мозок постійно повертається до пояснень, які ви можете дати у прямому етері, — чому кожна подія правдоподібно лягає на вашу ринкову теорію. Та в процесі підготовки швидко стає ясно, що правдоподібність вам нічим не допоможе — усі три події правдоподібні. Те, що якийсь варіант вписується у вашу улюблену ринкову теорію, не допоможе розподілити час. Як наслідок, маємо нездоланну прірву, з одного боку якої залишається обмеження у 100 хвилин, а з іншого — ваша невичерпна здатність виправдовувати результати своєї теорії.

І все ж... навіть у стані невизначеності ви, схоже, по-різному *очікуєте* ці три події: ви *розраховуєте*, що деякі виправдання вам потрібні *більше* за інші. І найцікавіше: коли ви думаєте про щось, що підвищує ймовірність зростання облігацій, то відчуваєте *меншу* потребу у виправданні решти сценаріїв.

Здається, існує навіть зв'язок між ступенем очікування кожного з трьох сценаріїв та кількістю часу, яку вам захочеться витратити на підготовку відповідних виправдань. Певна річ, цей зв'язок не можна виміряти кількісно. Дано: 100 хвилин на підготовку доповіді. Але у цій справі формування очікувань немає ніяких ста одиниць, які можна було б розподілити. (Хоча ви чудово розумієте, що *якщо* є

певний результат, то ваша функція корисності є логарифмом від часу, витраченого на пошук виправдання.)

І все ж... ви раз у раз вертаєтеся до думки, що, на відміну від виправдовування, спектр передбачення обмежений, але й час на підготовку не гумовий. Можливо, до очікування слід ставитися як до грошей, себто як до *обмеженого ресурсу*. Перше, що ви намагаєтеся зробити, — отримати більше очікувань, але згодом усвідомлюєте, що, навіть отримавши їх цілий оберемонок, ви не матимете часу на підготовку виправдань. У цьому й проблема, тому єдиний вихід — *розподілити* свій *обмежений запас* очікувань якнайефективніше.

Але ж нічого такого на заняттях зі статистики не навчали. На тих заняттях не розповідали, що варто робити, якщо ви *відчуваєте* таку сильну непевність. Не розповідали, що робити, коли немає малих чисел на руках. Та навіть якщо спробувати використати числа, яка зрештою різниця, які саме? І взагалі — як зрозуміти, яку саме математику потрібно використовувати, якщо взагалі потрібно? Може, ви таки використаєте *кілька* чисел зліва і справа... або хто зна що ще? (Щоправда, на підготовку у вас усе ще 100 хвилин.)

Якби ж то існувало мистецтво *зосередження непевності*, себто *втиснення* якомога більше очікувань у той результат, який *насправді станеться*!

Що б тоді собою являло таке мистецтво? За якими правилами воно б працювало?

Що таке свідчення?

Твердження «Сніг білий» істинне за умови, що сніг білий.

Альфред Тарський

Казати про суще, що воно існує, і про не-сущє, що воно не існує, є істинним».¹

«Метафізика» IV, Арістотель

Ви прогулюєтеся вулицею, коли у вас раптово розв'язуються шнурівки. Опісля, майже миттєво, ви бозна-чому починаєте *вірити* у те, що ваші шнурівки розв'язані. Сонце випромінює світло, яке потрапляє на ваші шнурівки і відбивається від них. Фотони, котрі досягають зіниць, потрапляють у сітківку ока. Енергія фотонів породжує нейронні імпульси, які дають сигнал зоровій корі головного мозку. Там оптична інформація піддається обробці, внаслідок чого утворюється тривимірна модель, яка розпізнається як розв'язані шнурівки. Існує послідовність подій, так званий причиново-наслідковий ланцюг, який існує як у світі, так і у вашому мозку, завдяки якому ви вірите у те, у що вірите. Кінцевий результат цього процесу — стан *розуму*, що віддзеркалює дійсний стан ваших *шнурівок*.

Що ж таке *свідчення*? Це подія, сплутана мережею причин і наслідків, що охоплює всю інформацію, яку ви хочете знати про предмет дослідження. Якщо ціль вашого дослідження, скажімо, — шнурівки, тоді сонячне світло, яке потрапляє у зіницю, є свідченням сплутаності зі шнурівками. Це не та «сплутаність», яка у фізиці. Тут я

1. Переклад з давньогрецької Олександра Юдіна. — Прим. пер.

вживаю це поняття, щоб вказати на те, що через взаємодію причин і наслідків дві речі зрештою досягають стану взаємопов'язаності.

Не кожен такий вплив є причиною такої «сплутаності»,² необхідної для свідчення. Автомат, який видає звуковий сигнал, коли ви вводите виграшні номери лотереї, буде не вельми ефективним, якщо він робить *те саме* і з *програшними* номерами. Світло, яке відбивається від ваших черевиків, не свідчитиме про стан ваших шнурівок, якщо фотони раптом опиняться в однаковому фізичному стані незалежно від того, зав'язані ваші шнурівки чи розв'язані.

Якщо висловлюватися абстрактно, то для того, щоб подія була *свідченням* про об'єкт дослідження, вона має відбуватися *по-різному* — у спосіб, пов'язаний із *різними* можливими станами цього об'єкта. (Якщо ж висловлюватися технічно, то взаємна інформація за Шенноном³ повинна вказувати на зв'язок між подією-свідченням та об'єктом дослідження відносно вашого поточного стану невизначеності щодо цих двох змінних.)

При належній обробці даних сплутаність може бути заразливою — ось тому вам потрібні очі й мозок. Якщо фотони відбиваються від шнурівок і натрапляють на скелю, то скеля майже не зміниться. Скеля не відобразить стан ваших шнурівок; його не можна буде розрізнити залежно від того, зав'язані вони чи ні. А ось фотоплівка захопить шнуркову сплутаність із вхідних фотонів, так що фотографія може бути свідченням. Якщо ваші очі та мозок функціонують належним чином, *ваш* розум сплутається зі станом ваших шнурівок.

З огляду на це раціоналісти приділяють аж настільки велику увагу, здавалося б, парадоксальному твердженню, що переконання

2. Сплутаність — 1) причинно-наслідковий зв'язок між двома явищами; 2) у квантовій фізиці взаємозалежність станів двох частинок одна від одної. У другому значенні сплутаність виникає, коли розподіл квантової амплітуди неможливо розкласти на простіші компоненти. — Прим. пер.

3. Для двох змінних це кількість інформації, яку отримують про одну змінну через знання про іншу. Якщо обидві змінні мають нульову взаємну інформацію, тоді вони незалежні: знання про значення однієї змінної не зменшує невизначеності щодо іншої. — Прим. пер.

заслуговує на існування тоді й лише тоді, коли вас можна переконати у протилежному. Якщо після потрапляння світла (неважливо якого) на сітківку ока її стан не змінився, це означає, що ви осліпли. А от прихильники деяких систем переконань, вдаючись до досить очевидного виверту для підкріплення власних поглядів, стверджують, що певні переконання заслуговують на існування тоді, коли ви берете їх на віру, *незалежно* від того, що ви бачите чи думаєте. Попри все ваш мозок має залишатися у тому самому стані. На те цей стан і називають «сліпою вірою». Якщо на вміст вашого переконання не впливає те, що ви бачите, то вашу сліпоту можна прирівняти до втрати очних яблук.

Якщо ваші очі та мозок функціонують належним чином, тоді ваші переконання зрештою узгоджуватимуться із тим, що існує. *Рациональне мислення породжує переконання, які самі по собі є свідченнями.*

Якщо ви завжди говорите правду, ваші раціональні переконання, які вже самі по собі є свідченнями, можуть служити свідченням для когось іншого. Сплутаність може передаватися через ланцюжок причин і наслідків. Комунікація — не виняток. Коли під час телефонної розмови ви говорите «Мої шнурівки розв'язані», ви ділитеся із другом своєю шнурковою сплутаністю.

Тому у колі чесних людей, які вірять у чесність одне одного, раціональні переконання передаються когнітивно-комунікативним шляхом. Саме з цих міркувань твердження про те, що ваші переконання *не* заразливі, себто ви можете тихенько собі вірити у що завгодно, нічого не передаючи іншим, виглядає вкрай сумнівно. Якщо ваші переконання переплітаються з реальністю, вони *мають* передаватися іншим чесним людям.

Якщо ваша модель реальності передбачає, що продукти вашого мисленнєвого процесу *не* повинні передаватися іншим, то ваша модель продукує переконання, які самі по собі не є свідченнями, і тому не переплетені з реальністю. Можливо, саме час зайнятися коригувальною рефлексією і відмовитися від переконання.

Адже якщо ви на рівні *нутра відчуєте*, що тут *щось не те*, то одразу ж *відкинете* переконання. Тому що «мої переконання не сплутані з реальністю» *означає* «мої переконання хибні». Щойно ви перестаєте вірити у те, що «"сніг білий" — це правда», ви повинні (одразу ж!) перестати вірити у те, що «сніг білий», — інакше щось тут не те.

Не спиняйтеся на цьому і подумайте, чому ті мисленнєві процеси, які ви систематично залучаєте, породжують переконання, які віддзеркалюють реальність. Поміркуйте над тим, що змушує вас вважати себе раціональним. Чому, на вашу думку, за таких мисленнєвих процесів, на які ви спираєтеся, ваш розум прийде до переконання «сніг білий» лише в тому випадку, якщо сніг справді білий? Якщо ви *не* вважаєте, що результати ваших мисленнєвих процесів переплетені з реальністю, тоді чому ви досі вірите тим результатам? Зрештою, перше тотожне другому, або принаймні так мало би бути.

Свідчення наукові та раціональні. Процесуальні докази

Ваш давній знайомий — комісар поліції — розказує вам (за умови тримати язика за зубами), що Валкі Вілкінсен — місцеве цабе. Чи ви як раціоналіст довіряєте його словам? Скажімо так: складно буде назвати вас розважливими, якщо ви зачепите Валкі за живе. Оскільки розсудливіше буде поводитися так, наче існує значно вища ймовірність, ніж за інших умов, того, що Валкі — кримінальний авторитет, слова комісара поліції мусять бути вагомим (баєсовим) свідченням.

Згідно з правовою системою, Валкі не ув'язнять, спираючись лише на слова комісара поліції. Це твердження не має сили *процесуального доказу*. Напевно, якщо ви почнете затримувати кожного, кого комісар поліції запідозрить у злочинній діяльності, то *на початку* ви зловите багато кримінальних авторитетів і декількох людей, які не догодили тому ж комісару. Влада корумпує: з часом ви ловитимете все менше справжніх очільників кримінальних банд (які почнуть доповідати більше зусиль для того, щоб їх було важче викрити) і все більше невинних жертв (необмежена влада потурає корумпованості).

Але це не означає, що твердження комісара не можна зарахувати до раціональних свідчень. У цього твердження і досі односторонній коефіцієнт правдоподібності, проте це не означає, що переходити до рогу Валкі буде розважливим вчинком. Але у *суспільстві*, де ми працюємо над досягненням спільної мети, у визначення процесуального доказу ми цілком усвідомлено включаємо конкретні свідчення, такі як спостереження комісара поліції під час подій у ніч на 4 квітня. Теоретично усі процесуальні докази мають бути раціональними свідченнями, але не навпаки. А перед тим, як оголосити раціональне свідчення процесуальним доказом, ми встановлюємо певні жорсткі додаткові стандарти.

Зараз, коли я пишу речення о 20:33 за північноамериканським тихоокеанським часом 18 серпня 2007 року, на моїх ногах білі шкарпетки. Чи можете ви як раціоналіст довіряти попередньому твердженню? Цілком. Чи можу я використати його як свідчення на суді? Так. Чи можна віднести його до *наукових* тверджень? Ні, бо його неможливо перевірити експериментом, який ви могли б провести самотужки. Наука побудована на *узагальненнях*, які застосовуються до багатьох конкретних випадків. Ви можете провести нові експерименти у природних умовах, чим випробуєте узагальнення і з'ясуєте, чи воно істинне, причому ніякий авторитет вам для цього не знадобиться. Отже, наука — це знання людства, які *може відтворити будь-хто*.

І наукою, і судовою системою, обидві з яких представляють суспільний процес, опікуються недосконалі люди. Ми хочемо сформулювати надбання *особливо* надійних переконань. Хочемо, щоб соціальні норми заохочували до формування таких знань. Тому перед тим, як допустити раціональне знання до цього перевіреного набутку переконань під назвою «наукове знання», ми встановлюємо певні жорсткі додаткові стандарти. Чи можете ви як раціоналіст вірити в існування історичної постаті Александра Македонського? Так. Наші уявлення про історію Стародавньої Греції хоч і досить неточні, але це все ж краще, ніж повна невідомість. Ми залежні від таких авторитетів, як Плутарх. А знехтувати його працями і перевірити усе самотужки нам не під силу. Тому історичне знання не є науковим.

Чи можете ви як раціоналіст вірити, що 18 вересня 2007 року зійде сонце? Так. Щоправда, не з повною певністю, але можна побитися об заклад.¹ Чи можна вважати це твердження, яке я висловлюю у цьому есеї 18 серпня 2007 року, *науковим* переконанням?

Чи можна відкидати прикметник «наукове» для твердження «Сонце зійде 18 вересня 2007 року»? Якби у науки не було можливості передбачати майбутні — себто ті, які *ще не* трапилися, — події, то який би тоді був із неї зиск? Жодних вам припущень до початку

1. Примітка для буквоїдів: тлумачте це твердження як обертання Землі по своїй орбіті на відносно постійній відстані від Сонця. — Прим. авт.

експерименту? Передбачення про те, що сонце зійде, безперечно, *екстраполюється* від наукових узагальнень. Воно ґрунтується на моделях Сонячної системи, які можна експериментально протестувати.

Тепер уявімо, що ви розробляєте експеримент для затвердження передбачення номер двадцять сім у нових умовах прийнятої теорії Q. Причин сумніватися у припущенні може й не бути — ви просто хочете протестувати його у нових умовах. Хіба доцільно тоді говорити про «науковість» такого результату *перед* початком експерименту? Це «традиційний прогноз» чи «прогноз теорії Q». Але ж якщо ви вже маєте «наукове переконання» щодо результату, то нащо взагалі потрібен той експеримент?

Тепер, сподіваюся, стає зрозуміліше, чому я ототожнюю Науку з *узагальненнями*, а не з історією одного експерименту. Історичні події стаються разово, а узагальнення розповсюджуються на велику кількість подій. Історія не відтворюється, на відміну від наукових узагальнень.

Чи моє визначення «наукового знання» *істинне*? Це питання неправильно сформульоване. Вибір застосовувати оті особливі стандарти у науці має прагматичний характер. Не існує таких скрижалей, на яких було б висічено, що $p < 0,05$ має бути стандартом наукових публікацій. Нині багато хто вважає, що показник 0,05 завищений, і було б *незле* опустити його до 0,01 чи навіть 0,001.

Можливо, прийдешні покоління відштовхуватимуться від теорії про те, що наука — *відкрите відтворювальне* знання людства, і називатимуть «науковими» тільки ті праці, які опубліковані у журналах відкритого доступу. Яке ж це знання *людства*, якщо ви платите за доступ до нього? Чи можна взагалі довіряти результату дослідження, якщо за можливість критики потрібно платити?

Як на мене, науці більше личила б теза про те, що тільки відкриті знання мають вважатися суспільним відтворювальним надбанням знань людства. Та хай на якому визначенні для науки ми зійдемося, публікацію у журналі із закритим доступом вартістю у 20 тис. доларів за рік усе ще можна назвати баєсовим свідченням. Те саме

стосується і слів комісара поліції про те, що Валкі — кримінальний авторитет.

Скільки потрібно свідчень?

У передпопередньому есеї я писав про *свідчення* як про «подію, сплутану мережею причин і наслідків, що охоплює всю інформацію, яку ви хочете знати про предмет дослідження». Крім того, ця подія «має відбуватися *по-різному* — у спосіб, пов'язаний із *різними* можливими станами цього об'єкта». Скільки ж тоді таких сплутаностей — або свідчень — потрібно мати для підтримки переконання?

Почнімо з питання достатньо простого, щоб його можна було описати математично: скільки сплутаностей із лотереєю вам знадобиться задля виграшу? Уявімо, що є сімдесят кульок, які дістають з барабана і не кладуть назад. Щоб виграти, потрібно вгадати шість чисел. Отже, маємо 131 115 985 можливих виграшних комбінацій, а тому у випадково розіграного білета ймовірність виявитися виграшним складає 1:131 115 985 (0,0000007%). Для виграшу в лотереї вам знадобиться достатньо *вибіркове* свідчення, яке було б явно на користь однієї комбінації з-поміж решти 131 115 984.

Припустімо, за допомогою певних тестів вам вдасться на рівні ймовірності відсіяти програшні номери від виграшних. Скажімо, ви кидаєте комбінацію цифр у чорну скриньку, яка завжди видає звуковий сигнал для виграшної комбінації. Ймовірність того, що вона видасть хибний сигнал, складає 1/4 (25%). Мовою баєсіанства це означає, що *відношення правдоподібності* складає 4 до 1. Тобто ймовірність того, що скринька видасть звуковий сигнал для виграшної комбінації, вчетверо вища у порівнянні з отриманням сигналу для хибної комбінації.

Але це не усуває проблему — у нас і досі гора можливих комбінацій. Кинете 20 невірних комбінацій — скринька чисто випадково відреагує на п'ять із них (у середньому). Кинете 131 115 985 можливих комбінацій — скринька, безумовно, відреагує на одну виграшну комбінацію, однак, крім неї, ще на 32 778 996 програшних (у середньому).

Що ж, за допомогою скриньки у лотереї вам не виграти, та це все ж краще за дірку від бублика. Зі скринькою ваші шанси на виграш зростуть з 1:131 115 985 до 1:32 778 997. Ви зробили поступ на шляху до своєї цілі — істини — серед усього розмаїття можливостей.

Тепер припустімо, що для тестування ви можете *двічі* скористатися іншою чорною скринькою, причому результат однієї спроби *не впливатиме* на іншу. Обидві неодмінно дадуть знати про виграшний квиток. Але ймовірність того, що скринька дасть сигнал при програшній комбінації, складає $1/4$ для кожної скриньки незалежно від інших. Отже, ймовірність того, що *обидві* скриньки дадуть сигнал для програшної комбінації, складатиме $1/16$. У такий спосіб *сукупність* свідчень двох незалежних тестів дає відношення правдоподібності 16:1. Число програшних квитків, які пройдуть через обидва тести, знизиться (у середньому) до 8 194 749.

Оскільки всього існує 131 115 985 можливих лотерейних білетів, вам могло спасти на думку, що для виграшу вам потрібне свідчення, ймовірність якого складає 131 115 985:1. Тобто це подія або низка подій, що трапляється ймовірніше у 131 115 985 разів для виграшної комбінації. Власне, такої кількості свідчень вам вистачило б лише для *збалансування* шансів виграти в лотереї. Чому? Бо якщо застосувати фільтр такої потужності до 131 мільйона програшних квитків, то в середньому один програшний квиток пройде цей фільтр. Виграшний квиток, зрозуміло, теж пройде фільтр. Зрештою, ви лишитеся з двома білетами, які пройшли через фільтр. І тільки один із них принесе вам виграш. У такому разі, якщо ви можете дозволити собі тільки один білет, то це п'ятдесятивідсотковий шанс на виграш.

Кращим підходом до розв'язання проблеми буде з самого початку визначити свої шанси на виграш як 1:131 115 984. Якщо використовувати одну скриньку, ймовірність сигналу становить 1 для виграшного квитка та 0,25 для програшного. Множимо 1:131 115 984 на 1:0,25 — отримаємо 1:32 778 996. Додасте ще одну скриньку для перевірки свідчень — помножите отримані шанси на 1:0,25 ще раз, і тепер шанси складають 1 виграшний квиток на 8 194 749.

Свідчення зручно вимірювати у бітах (але не в тих бітах, що на жорсткому диску, а в бітах математиків, які концептуально відмінні від комп'ютерних). Біти математиків — це логарифми з основою $1/2$ від імовірностей. Скажімо, якщо чотири наслідки А, В, С і D можуть статися з імовірностями 50%, 25%, 12,5% і 12,5%, а я скажу, що сталося-таки D, то я передав вам три біти інформації, оскільки повідомив про результат, імовірність якого складала 1:8.

Так склалося, що 131 115 984 трохи менше за 2 у 27 -му степені. Отже, за допомогою 14 скриньок, або 28 бітів свідчень, — події, ймовірність якої у 268 435 456 разів вища, якщо білет виявиться виграним, — можна посунути шанси від 1:131 115 984 до 268 435 456:131 115 984, які скорочуються до 2:1. Співвідношення 2:1 означає, що є дві можливості виграти на одну програти. А тому *ймовірність* виграти при наявності 28 бітів свідчень становить $2/3$. Якщо додати ще одну скриньку (себто ще 2 біти свідчень), шанси зростають до 8:1. Додасте ще дві скриньки — підвищуєте шанс на виграш до 128:1.

Отже, якщо ви хочете отримати *сильні підстави* для виграшу в лотереї — припустімо, з ймовірністю програти менше ніж 1% — 34 бітів свідчень, що ви оберете виграшну комбінацію, має бути достатньо.

Правило зважування необхідної кількості свідчень загалом діє схожим чином: що *ширший простір* імовірностей, в якому може справдитися гіпотеза, що менш імовірною здається гіпотеза перед її тестуванням у порівнянні з альтернативними, що впевненішим вам кортить бути, то більше вам знадобиться свідчень.

Ви не можете нехтувати цим правилом. Не можете формувати точні переконання на основі нерозмірних свідчень. Скажімо, у вас є 10 скриньок, розташованих в одну лінію, в які ви починаєте кидати свої комбінації. Навряд чи зупинитися на першій комбінації, яка отримає звуковий сигнал схвалення в усіх 10 скриньках, буде гарною ідеєю. На це можна одказати: «Але ж імовірність натрапити на прогашну комбінацію один мільйон до одного! Чому б не знехтувати тим високочолим правилом Баєса?» Тому що десь 131 прогашний

квиток пройде цей тест. З урахуванням простору ймовірностей і попередньої малої ймовірності ви зробили занадто поспішний висновок на основі недостатніх свідчень. У тому-то й річ, що це не безглузда бюрократична постанова. Це — математика.

Звісно, якщо дуже хочеться, ніхто не забороняє вірити в щось без належних свідчень. Але тоді ваші переконання будуть *хибними*. Уявіть, що ви намагаєтеся завести автівку, в якій немає палива. А бак не заправили, бо тільки старі діди вірять у те, що для пересування потрібне паливо. А якби скасували закон, який зобов'язує заправляти автівки, уявіть, наскільки *простішим* стало б наше життя. Хіба так не буде краще для всіх?

Якщо так вже кортить, то можна і на цурупалку поїхати. Можна закрити очі і думати, що автівка їде. Однак щоб *справді* досягти точного переконання, потрібно паливо у вигляді свідчень. І чим довша дорога, тим більшою кількістю палива варто запастися.

Зухвалість Айнштейна

У 1919 році сер Артур Еддінгтон очолив експедицію до Бразилії та острова Принсіпі, метою якої було на основі спостережень сонячних затемнень протестувати передбачення нової загальної теорії відносності Айнштейна. Фізика тоді запитав журналіст: що як спостереження Еддінгтона не узгоджуватимуться з його теорією? Відповідь Айнштейна увійшла в історію: «Тоді я б широко поспівчував Господу. Теорія правильна».

Така заява здається вельми безрозсудною, оскільки нехтує тропом традиційної раціональності: експеримент — усьому голова. Може здатися, що зарозумілість Айнштейна була настільки великою, що він згордував відповіддю Природи, відмовився прихилити коліно перед Нею, чого науковці не мають робити у жодному разі. Як можна *знати*, що теорія правильна задовго до експерименту?

Так, Айнштейн мав рацію. Я утримуюся від критики, коли хтось має рацію. Якщо ж хтось заслуговує на неї, то я не чекатиму нагоди, коли цей хтось таки наламає дров.

Але, можливо, Айнштейн і не був настільки безрозсудним, як це виглядало у тому твердженні...

Щоб приписати п'ятдесятивідсоткову і вищу ймовірність правильній гіпотезі з-поміж ста мільйонів можливих, вам потрібно щонайменше 27 бітів свідчень (чи близько того). Ви не можете розраховувати на те, що без настільки ретельної перевірки вам вдасться знайти правильну гіпотезу, тому що через менш надійне тестування може пройти більш ніж одна гіпотеза. Якщо ви проводитимете тест, який з імовірністю один на мільйон дасть хибнопозитивні результати (~20 бітів), на руках у вас лишиться сто гіпотез. Якщо ви хочете *знайти* правильну відповідь у широчезному просторі ймовірностей, вам потрібно не абискильки свідчень.

Традиційні раціоналісти наголошують на такому обґрунтуванні: «Переконати мене в X вам вдасться Y кількістю свідчень». Я й сам часто-густо вдаюся до цього формулювання, коли кажу щось на

кшталт «Щоб я повірив у це твердження на більш ніж 99%, вам потрібно 34 біти свідчень». Або «Щоб приписати п'ятдесятивідсоткову і вищу ймовірність своїй гіпотезі, вам потрібно 27 бітів свідчень». З традиційного формулювання випливає, що ви відштовхуєтеся від своєї здогадки або власного ланцюга міркувань і збираєте «свідчення», якими *підкріплюватимете* свій хід роздумів і *переконуватимете* наукову спільноту або *виправдовуватимете* віру у свою здогадку.

Однак, з точки зору баєсіанства, кількість ваших свідчень має бути приблизно еквівалентною складності гіпотези лише для того, щоб ідентифікувати цю гіпотезу у просторі теорії. Не йдеться про те, щоб щось перед кимось виправдовувати. Якщо у вас на руках сто мільйонів альтернативних гіпотез, то вам потрібно щонайменше 27 бітів свідчень, щоб сфокусувати свою увагу на однозначно правильній відповіді.

Хай там як ви називаєте своє припущення — передчуттям, інтуїцією чи здогадкою — це справжні процеси, які відбуваються у справжньому мозку. Якщо ваш мозок не володіє хоча б 10 бітами дійсно сплутаних баєсових достовірних свідчень, які він опрацьовуватиме, він не зможе сфокусуватися — чи то свідомо, чи то підсвідомо, чи то хай якось іще — на правильній 10-бітній гіпотезі. Підсвідомі процеси справляються не краще за свідомі, коли потрібно знайти одну з мільйона цілей при всього-на-всього 19 бітах сплутаності. Інтуїція може здаватися таємничою для тієї людини, у голові якої відбуваються ці процеси, але вона не може порушити закони фізики.

Бачите, до чого я хилю? *На момент першого формулювання гіпотези* — коли Айнштайну вперше спали на думку ті рівняння — він, очевидно, *вже мав у розпорядженні* достатньо спостережних свідчень, щоб виокремити складні рівняння загальної теорії відносності у просторі своєї уваги. Інакше він не прийшов би до них.

Яка ймовірність того, що Айнштайн, маючи достатню кількість спостережних свідчень, звернув би увагу на загальну теорію відносності, але приписав їй тільки п'ятдесятивідсоткову ймовірність? Припустімо: загальна теорія відносності — гіпотеза на 29,3 біта. Яка

ймовірність того, що Айнштайн натрапить *саме на 29,5 біта* свідчень під час читання наукових статей з фізики?

Украй низька! Якщо Айнштайн мав достатню кількість спостережних свідчень, щоб із самого початку виокремити правильні рівняння загальної теорії відносності, тоді, мабуть, він був *збіса певним*, що загальна теорія відносності правильна.

По суті, оскільки людський мозок навряд чи можна назвати надзвичайно ефективним обробником даних, Айнштайн, либонь, мав *набагато більше свідчень*, ніж потрібно теоретичному баєсіанцю, щоб надати загальній теорії відносності такий величезний кредит довіри.

«Тоді я б щиро поспівчував Господу. Теорія правильна» — уже не звучить аж так безрозсудно, якщо поглянути на цей вислів із такого боку. І пам'ятайте: загальна теорія відносності *була* правильною у широчезному просторі ймовірностей.

Лезо Оккама

Чим складніше пояснення, тим більше свідчень знадобиться, щоб розпізнати його у просторі переконань. (У традиційній раціональності часто зустрічається оманливе формулювання: «Чим складніше твердження, тим більше свідчень потрібно для його обґрунтування».) Яким чином можна виміряти складність пояснення? Яким чином можна визначити, скільки потрібно свідчень?

Принцип леза Оккама часто формулюють як «найпростіше пояснення, яке узгоджується з даними». На це Роберт Хайнлайн відповів, що найпростішою відповіддю може бути «Жінка далі по вулиці — чаклунка. Саме тому це зробила вона».

Можна помітити, що довжина речення не найкращий критерій вимірювання «складності». А ще — якщо теорія *не виключає варіанти розвитку подій*, то вона недостатньо «узгоджена» з даними.

Чому, власне, довжина речення — поганий критерій складності? Тому що коли ви проговорюєте речення, то користуєтеся *ярликами* для позначення понять, відомих вашому співрозмовнику. Ця складність уже зберігається у його ментальному лексиконі. Можна скоротити все Хайнлайнове речення до набору літер «Ждпвчстцзв», щоб усе це пояснення можна було передати одним словом. А ще можна дати йому короткий випадковий ярлик — «Фнорд». Чи применшує це складність? Ні, тому що вам доведеться заздалегідь попередити свого співрозмовника, що «Ждпвчстцзв» означає «Жінка далі по вулиці — чаклунка. Саме тому це зробила вона». Саме по собі слово «чаклунка» — це ярлик, яким користуються у надзвичайних твердженнях. Те, що ми усі з ним знайомі, не означає, що поняття просте.

Небо розітнула блискавка і влучила у землю. Реакція нордичних племен: «Оце, мабуть, могутній агент розлютився і метнув блискавку». Людський мозок — найскладніша річ у всьому видимому всесвіті. Якщо *лють* здається простою, то це тому, що ми не бачимо нейронні ланцюги, завдяки яким утворюється емоція. (Уявіть собі: ви

намагається пояснити прибульцям із нульовим почуттям гумору, чому телевізійне шоу *Saturday Night Live* таке кумедне. Але не поспішайте з висновками: ви і досі не маєте почуття фнорду.) Люди, які вивчили гіпотезу про Тора-громовержця, просто проігнорували складність люті та інтелекту.

Людині легше буде пояснити, хто такий Тор, аніж викласти рівняння Максвелла. У людей є вбудований словник для розуміння гніву, але немає такого словника для математичного аналізу. Вам належить спочатку пояснити свою мову, мову для опису цієї мови і саму концепцію математики, а вже потім ви матимете справу з електроенергією.

І все ж, здається, має бути якийсь резон у тому, що рівняння Максвелла *простіші* за людський мозок або Тора-громовержця.

І він таки є. Виявляється, написати комп'ютерну програму, яка симулюватиме рівняння Максвелла, *куди* простіше, ніж ту, що симулюватиме розум, наділений інтелектом та емоціями, подібний до Торового.

Вимірюють «складність опису» за допомогою формальної системи індуктивного висновування Соломонова.¹ Це робиться шляхом визначення довжини найкоротшої комп'ютерної програми, яка виводить цей опис на виході. Маючи справу з робочою «найкоротшою комп'ютерною програмою», ви маєте вказати простір комп'ютерних програм, для чого вже потрібні мова та інтерпретатор. У теорії індуктивного висновування Соломонова для стиснення даних використовують машини Тюрінга² (точніше — бітові стрічки, які ті машини задають). А що як вам не до вподоби машини Тюрінга? Тоді залишається тільки сталий штраф складності за конструювання власної

1. Індукція Соломонова — це, по суті, спроба дати визначення оптимальній (хоч і неврахованій) логіці. Поеднання байєсових оновлень з пріором простоти, що приписує меншу ймовірність програмам, що здатні генерувати сприйняття, залежно від того, наскільки вони довгі. — Прим. пер.

2. Абстрактна машина, яка слідує правилам оперування символами на довільно довгій стрічці. За наявності скінчених ресурсів неможливо збудувати справжню машину Тюрінга, однак такі машини — доволі зручний математичний концепт, введений для формального уточнення поняття обчислюваності. — Прим. пер.

універсальної машини Тюрінга, яка може інтерпретувати будь-який поданий їй код, якою б мовою програмування він не був написаний. Різні індуктивні формальні системи штрафуються в найгіршому випадку постійним коефіцієнтом відносно один одного, що відповідає розміру універсального інтерпретатора для цієї формальної системи.

У кращих, на мою скромну думку, версіях індукції Соломонова комп'ютерна програма не видає детермінований прогноз, а присвоює стрічкам імовірності. Наприклад, ми могли б написати програму, що описуватиме симетричну монету, написавши програму, що присвоює рівні ймовірності усім стрічкам 2^N на довжині N . Таким є підхід індукції Соломонова для *зіставлення* спостережуваних даних. Що вища ймовірність, яку програма приписує спостережуваним даним, то краще та програма *узгоджується* з даними. Сума ймовірностей має дорівнювати одиниці, тому, щоб програма краще «узгоджувалася» з однією подією, вона має поцупити певний масив ймовірностей в іншій події, яка потім «узгоджуватиметься» набагато гірше. Однак не існує надсиметричної монети, яка присвоюватиме стовідсоткову ймовірність «числу» і стовідсоткову ймовірність «трізубу».

Як же тоді знайти компроміс між узгодженістю з даними та складністю програми? Якщо ви нехтуєте штрафами за складність і думаєте *тільки* про узгодженість, то завжди віддаватимете перевагу програмам, які претендують на детерміністичне прогнозування даних, і присвоюватимете їм стовідсоткову ймовірність. Якщо монета випадає у порядку «ч-т-т-ч-ч-т», то програма, котра стверджує, що монету було підігнано саме під цю послідовність, узгоджується зі спостережними даними у 64 рази краще, ніж програма, котра видає, що монета симетрична. І навпаки, якщо ігнорувати узгодженість і враховувати *тільки* складність, то гіпотеза про симетричну монету завжди здається простішою за решту. Навіть якщо монета випадає у порядку «ч-т-ч-ч-т-ч-ч-ч-т-ч-ч-ч-ч-ч-ч-ч-ч-ч-ч-ч-ч-ч...». Авжеж, гіпотеза про симетричну монету таки простіша й узгоджується з даними не гірше, ніж будь-яка інша стрічка з 20 підкидань монети — ні більше, ні менше. Проте ми бачимо й іншу гіпотезу, на перший погляд, не надто складну, яка краще узгоджується з даними.

Якщо дати програмі зберегти ще один двійковий біт інформації, це допоможе скоротити простір імовірностей удвічі — а отже, призначити вдвічі більшу ймовірність усім точкам у просторі залишкових варіантів. Це означає, що завдяки одному біту програмної складності показник узгодженості має зрости *щонайменше* удвічі. Якщо ви спробуєте розробити комп'ютерну програму, яка точно зберігатиме результат на кшталт «ч-т-т-ч-ч-т», то шість бітів, які ви втратите у складності, повинні зруйнувати всю правдоподібність, досягнуту 64-кратним зростанням узгодженості. Інакше рано чи пізно ви дійдете висновку, що всі симетричні монети такі нечесні.

Якщо ваша програма не досить продумана і не *стискає* дані, переміщення одного біта даних в опис програми не принесе жодної користі.

Ось як діє індукція Соломонова для передбачення послідовностей: ви сумуєте усі дозволені комп'ютерні програми — однак якщо всі програми дозволено, індукція Соломонова стає необчислювальною — з апіорною ймовірністю $(1/2)$ у степені довжини її коду у бітах, а потім оцінюєте здатність кожної програми узгоджуватися з усіма спостережуваними даними. Так ви отримуєте зважену суму експертів, які передбачатимуть подальші біти.

Формальний метод мінімальної довжини повідомлення близький до індукції Соломонова. Ви надсилаєте стрічку, що описує код, потім — стрічку, що описує дані у тому коді. Годі шукати краще пояснення за те, яке приведе до найкоротшого *повного* повідомлення. Якщо розглядати множину допустимих кодів як простір комп'ютерних програм, а мову опису кодів як універсальну машину, тоді метод мінімальної довжини повідомлення близький до індукції Соломонова.³

Звідси видніше, чому використати фразу «Жінка далі по вулиці — чаклунка. Саме тому це зробила вона» для пояснення закономірності у послідовності 0101010101 — не найкраща ідея. Якщо ви надсилаєте другові повідомлення, в якому намагаєтеся

3. Близький, але не є відповідником, оскільки він обирає найкоротшу програму, а не сумує їх усі. — Прим. авт.

описати спостережувану послідовність, вам доведеться надрукувати таке: «Жінка далі по вулиці — чаклунка. Це вона зробила так, щоб послідовність набула вигляду 0101010101». Ваше звинувачення у чаклунстві не приведе вас до *скорочення* решти повідомлення — адже вам усе ще доведеться вичерпно описати дані, які воно породило.

Чаклунство може узгоджуватися із нашими спостереженнями у тому сенсі, що якісно *виправдовуватиме* їх. Власне, чаклунством можна дозволяти *які завгодно варіанти*, як і фразою «Це ж флогістон!». Тому навіть назвавши когось «чаклуном», ви все одно муситимете ґрунтовно описати спостережувані дані. Назвавши жінку чаклункою, ви не *стиснули загальну довжину повідомлення, описуючи свої спостереження*, а просто додали беззмістовний пролог, тільки розширивши загальну довжину.

А ось тут і ховається справжній підступ: а що ж із займенником «це» у твердженні «Чаклунка зробила це»? Чаклунка зробила *що*?

Звісно, слід завдячити повзучому детермінізму, ефекту якорування, вигаданим поясненням, сумнівній причиновості, упередженню позитивного та ангажованому мисленню за те, що наявність чаклунських здібностей у тієї жінки здається надто очевидною. Відповідно, це вона зробила так, щоб монета випала у порядку 0101010101. Але до цього питання я ще повернуся...

Сила раціоналіста

Ще за царя Гороха, коли я спілкувався у тематичних чатах, мене спіткав ось такий трапунок. З часом спогади про цю подію дещо потьмяніли, тому мій виклад може бути неточним.

Отже, якось у чаті я натрапив на чиєсь повідомлення про те, що товариш автора цього повідомлення потребує фахової поради лікаря. За словами друга, у нього раптово заболіло у грудях, і він викликав карету швидкої допомоги. По приїзду парамедики відказали, що нема чого хвилюватися, і поїхали. Але біль у грудях так і не вщух і, навпаки, тільки загострився. Що ж робити його другові?

Ця історія мене спантеличила. Я пригадав, як читав про безпритульних у Нью-Йорку. Вони викликали швидку, щоб їх просто забрали у якесь тепле місце, і парамедики не мали права не доставити їх до відділення невідкладної допомоги. Навіть у двадцять сьомий раз. Бо якщо вони відмовлять, то на клініку, яка надає послуги швидкої медичної допомоги, можуть подати позов до суду і стягнути чималі гроші. Так само працівники відділення швидкої медичної допомоги за законом зобов'язані надавати допомогу усім, навіть якщо дехто не може за неї заплатити.¹ Тому мені було не до кінця ясно, як таке могло статися. Усякого, хто повідомляв про раптовий біль у грудях, мала б негайно забрати швидка.

І на цьому випадку я дав маху як раціоналіст. Я пригадав, як лікар не поспішав хвилюватися, коли я повідомив про схожі симптоми, які здалися мені вкрай тривожними. І лікарі завжди мали рацію. Жодного разу не схибили. Одного дня у мене самого заболіло у грудях, і лікар спокійно пояснив, що я описую не серцевий напад, а біль у грудних м'язах. Тож я написав у тому чаті: «Що ж, якщо парамедики сказали вашому другові, що хвилюватися не варто, то, треба

1. І клініка витрачає на це величезні кошти, тому відділення швидкої допомоги закриваються... Це наводить на думку, що економісти, виходить, нам і не потрібні, якщо ми просто нехтуємо їхніми знаннями. — Прим. авт.

гадати, *так і є* — інакше його б забрали, якби був бодай найменший ризик чогось серйозного».

Ось так я пояснив собі всю цю історію в рамках моєї теперішньої моделі, хоча все одно відчувався деякий примус із узгодженням...

Опісля автор повідомлення повернувся до чату і написав, що його друг вигадав історію від початку до кінця. Вочевидь, не найнадійніший друг.

Гадаю, я мав би зрозуміти, що невідомий знайомий знайомого в Інтернеті — не таке вже надійне джерело інформації, на відміну від статті, надрукованої в журналі. На жаль, прийняти твердження за істину куди легше, ніж не прийняти — віра інстинктивна, а невіра потребує свідомих зусиль.²

Тож насправді я доклав величезних зусиль, змусивши свою модель реальності пояснити аномалію, якої *ніколи й не ставалося*. І я *знав*, наскільки ганебним це було. *Знав*, що корисність моделі полягає не в тому, що вона може пояснити, а в тому, чого вона пояснити не може. Гіпотеза, яка нічого не забороняє, дозволяє будь-що, а отже, ніяк не обмежує очікування.

Сила раціоналіста полягає у здатності спантеличуватися при взаємодії з вигадкою, а не з дійсністю. Якщо ви неабиякий мастак із пояснення чого завгодно, то у вас нульове знання.

Усі ми буваємо слабкі час від часу. Та найприкріше те, що я *міг* бути розсудливішим. У мене була вся необхідна інформація, щоб дійти правильної відповіді. Я навіть *помітив* проблему. А потім знехтував нею. Мое відчуття спантеличеності мало би правити мені за свідчення, та я викинув цю зачіпку.

2. З публікації McCluskey (2007), "Truth Bias": «[Л]юдям краще вдається ідентифікувати правдиві твердження порівняно з брехливими. Такий висновок виглядає досить надійним, оскільки він не є просто функцією правди на основі правильної здогадки, коли свідчення слабкі, адже він проявляється у контрольованих умовах експериментів, в яких суб'єкти мають вагомні причини не припускати правди». <https://www.overcomingbias.com/p/truth-bias.html> Із публікації Gilbert et al. (1993), "You Can't Not Believe Everything You Read": «Чи можуть люди розуміти твердження, не вірячи у них? [...] Три експерименти свідчать на користь гіпотези про те, що розуміння передбачає певну початкову віру в інформацію, яку намагаємося досягнути». — Прим. авт.

Я мав би бути уважнішим до того, що те відчуття спокою *було злегка натягнутим*. Це те відчуття, яке шукач істини має цінувати, це — частина вашої сили раціоналіста. Недолік конструкції людського мислення полягає в тому, що описане відчуття проявляється у вигляді ледь помітного напруження на задвірках вашої свідомості, а не виття тривоги та саяйва неонові вивіски:

Або твоя модель
хибна, або ця історія —
нісенітниця.

Відсутність свідчень є свідченням відсутності

З книги Робіна Дейвза «Рациональний вибір у мінливому світі»:

Власне, таке помилкове підлаштування свідчень під гіпотезу траплялося у найбільш ганебні часи для Сполучених Штатів. Приклад тому — примусове затримання американців японського походження на початку Другої світової війни. Коли 21 лютого 1942 року губернатор Каліфорнії Ерл Воррен давав свідчення на слуханні у Конгресі США, один із присутніх заявив, що до цього часу не було помічено жодних ознак саботажу чи шпигунства з боку американців японського походження. На що Воррен тоді відповів: «Я вважаю, що відсутність [підривної діяльності] — то у нашому випадку найлихіша ознака. Вона тільки ще більше, ніж будь-який інший фактор, утворює мене у думці, що нам іще належить побачити і саботаж, і підступи п'ятої колонії, сплановані так само, як і був спланований Перл-Харбор... Підозрюю: нас просто заколисують хибним відчуттям безпеки».

А тепер розглянемо аргумент Воррена з точки зору баєсіанства. Коли ми бачимо якесь свідчення, гіпотези, які присвоювали *вищу* правдоподібність спостережуваній події, отримують приріст ймовірності коштом інших гіпотез, які присвоювали *нижчу* правдоподібність свідченню. Це явище відоме як *відносна* правдоподібність та *відносна* ймовірність. Можна приписати свідченню високу правдоподібність і все одно втратити ймовірнісну масу на користь іншої гіпотези, якщо вона приписує цьому свідченню ще більшу правдоподібність.

Виглядає так, що Воррен заявляв, що якщо ми не бачимо ніякого саботажу, це тільки *підтверджує* існування п'ятої колонії. Можна, звісно, заявити, що п'ята колона, *мабуть*, відкладає свій саботаж. Та

правдоподібність того, що *відсутність* п'ятої колони означала б відсутність саботажу, все одно вища.

Нехай E позначатиме спостереження саботажу, а $\neg E$ — відсутність такого спостереження. Символ $H1$ позначатиме гіпотезу про взаємозв'язок американців японського походження із п'ятою колоною, а $H2$ — гіпотезу про неіснування п'ятої колони. *Умовна ймовірність* $P(E|H)$ або « E за умови H » — це те, наскільки надійним є наше очікування побачити подію E за умови, що гіпотеза H істинна.

Хай яка правдоподібність того, що п'ята колона не вчинить саботажу — ймовірність $P(\neg E|H1)$ — вона не буде настільки ж високою, як і правдоподібність того, що ніякого саботажу не трапиться *за умови, що не існує ніякої п'ятої колони*, — ймовірність $P(\neg E|H2)$. Тому через відсутність спостережуваного саботажу зростає ймовірність неіснування п'ятої колони.

Відсутність саботажу не *доводить*, що п'ятої колони не існує. Відсутність *доказу* не є *доказом* відсутності. Мовою логіки: $(A \Rightarrow B)$ — читається як « A тягне за собою B » — не можна прирівняти до $(\neg A \Rightarrow \neg B)$ — читається як «не- A тягне за собою не- B ».

Та коли йдеться про теорію ймовірностей, відсутність *свідчень* завжди є *свідченням* відсутності. Якщо E — бінарна подія і $P(H|E) > P(H)$, тобто спостереження того, що подія E підвищує ймовірність події H , тоді $P(H|\neg E) < P(H)$, тобто відсутність спостереження події E знижує ймовірність події H . Ймовірність $P(H)$ являє собою збалансоване поєднання $P(H|E)$ та $P(H|\neg E)$ та неодмінно лежить між ними.¹

У більшості реальних випадків причина не завжди може супроводжуватися наочними проявами свого існування, а відсутність причини — і поготів. Відсутність спостереження може бути сильним свідченням відсутності або дуже слабким — залежно від ймовірності того, що причина супроводжуватиметься проявом. Відсутність спостереження, яке допустиме лише частково (навіть якщо альтернативна гіпотеза взагалі не передбачає його), — доволі ненадійне свідчення

1. Якщо для вас усе це — китайська грамота, прошу ознайомитися з розділом «Вичерпний посібник з використання теорема Баеса» наприкінці третьої книги «Машина у духові». — Прим. авт.

відсутності (хоча воно і досі є свідченням). У цьому полягає помилковість аргументу «прогалина в історії викопних решток»: скам'янілості утворюються не так часто, тому немає сенсу сурмити про відсутність частково допустимого спостереження, коли існує купа інших переконливих позитивних спостережень. Та якщо зовсім не існує *жодних* позитивних спостережень, саме час почати перейматися, бо з-за рогу вас уже виглядає парадокс Фёрмі.

Сила раціоналіста полягає у здатності спантеличуватися при взаємодії з вигадкою, а не з дійсністю. Якщо ви неабиякий мастак із пояснення чого завгодно, то у вас нульове знання. Надійність моделі полягає не в тому, що вона *може* пояснити, а в тому, чого вона пояснити *не може*, оскільки тільки заборони обмежують очікування. Якщо ви не помічаєте, як ваша модель занижує правдоподібність настання події, цілком можливо, що у вас немає ні моделі, ні відповідних свідчень — ні мозку, ні очей.

Закон збереження очікуваних свідчень

У 1631 році Фрідріх Шпее фон Лангенфельд — священник, який вислуховував сповіді засуджених відьом, — у своїй праці *Cautio Criminalis* («Застереження обвинувачам») уїдливо описав схему прийняття рішень, за якою судили звинувачених у відьомстві. Якщо відьма вела порочний спосіб життя, вона визнавалася винною. Якщо вона вела праведний спосіб життя, це так само доводило її провину, оскільки відьми вміють задурити голову і вдавати із себе неабияких праведниць. Якщо після того, як жінку саджали до в'язниці, вона була наляканою, це тільки підтверджувало її провину; якщо не проявляла ніякого страху, це так само підтверджувало її провину, оскільки відьмам властиво вдавати із себе невинних і незворушних. Або коли вона чула, як її звинувачують у чаклунстві, обвинувачена могла спробувати втекти або залишитися: дала ногам волю — винна, не дала — це диявол перешкодив їй.

Шпее був сповідником багатьох відьом. Так він отримав змогу спостерігати за тим, як ухвалюється *кожне* рішення про звинувачення, на яке не впливали *ні слова, ні вчинки* обвинуваченої — що завгодно могло стати доказом проти неї. У кожному конкретному випадку ви почуєте тільки одну сторону цієї справи. Саме тому науковці заздалегідь записують свої прогнози результату експерименту.

З огляду на теорію ймовірностей — облишмо справедливність — *не може і свідчення, і його відсутність підтверджувати одну й ту саму гіпотезу*. Правило «відсутність свідчень є свідченням відсутності» — це спеціальний випадок більш загального закону, який я називатиму збереженням очікуваних свідчень. *Очікування*

апостеріорної ймовірності¹ після врахування відповідного свідчення має дорівнювати апіорній ймовірності.²

$$P(H) = P(H)$$

$$P(H) = P(H, E) + P(H, \neg E)$$

$$P(H) = P(H|E) \cdot P(E) + P(H|\neg E) \cdot P(\neg E)$$

Тому для кожного очікування підтверджувального свідчення існує рівне йому очікування, що знижує ймовірність.

Якщо ви очікуєте з високою ймовірністю побачити слабе свідчення в одному напрямку, вона має бути збалансована слабким очікуванням побачити сильне свідчення в іншому. Якщо ви висловлюєте неабияку впевненість у своїй теорії і тому очікуєте побачити результат, що узгоджуватиметься з вашою гіпотезою, то навіть такий результат може лише дуже трохи підвищити вашу впевненість (адже воно вже близьке до 1), а ось несподіваний провал вашого прогнозу може (і має) неабияк підважити вашу впевненість. У середньому ви маєте розраховувати на *таку ж* упевненість, з якої починали. Відповідно, одне лиш *очікування* натрапити на свідчення — перед тим, як, власне, побачити їх, — не має впливати на ваші апіорні переконання. (Знову ж: якщо усе вищесказане не виглядає вам інтуїтивно очевидним, раджу прочитати есей «Інтуїтивне пояснення теореми Баєса»³.)

Отже, якщо ви стверджуєте, що відсутність саботажу прирівнюється до свідчення *на користь* існування п'ятої колонії у вигляді американців японського походження, ви, навпаки, мусите вважати, що спостереження саботажу — це аргумент *проти* існування п'ятої колонії. Якщо ви стверджуєте, що «праведний спосіб життя» — свідчення того, що жінка — відьма, тоді «порочний спосіб життя» має

1. Переконання агента після врахування якогось свідчення. Протиставляється апіорним переконанням (пріори). — Прим. пер.

2. Інформація (уявлення, очікування тощо), якою володіє агент перед врахуванням якогось свідчення. Уявлення агента після опрацювання свідчень називають апостеріорною ймовірністю. — Прим. пер.

3. <https://www.lesswrong.com/posts/XTXWPQSEgoMkAupKt/an-intuitive-explanation-of-bayes-s-theorem>

бути свідченням, що вона не відьма. Якщо ви стверджуєте, що Бог (щоб випробувати віру людства) не розкриває Свого існування, тоді чудеса, описані в Біблії, мають свідчити проти існування Бога.

Щось не те, правда? Зверніть увагу на те відчуття, що щось *видається трохи натягнутим*, на ледь помітне напруження на задвірках вашої свідомості. Воно важливе.

Справжній баєсіанець не шукає свідчення, які *підтверджують* теорію. Не існує ніякого вигадливого плану, ніякої розумної стратегії чи хитрого прийому, що дозволив би вам обґрунтовано очікувати, що ваша впевненість у наперед заданому твердженні буде *в середньому* більшою, ніж до цього. Свідчення шукають заради тестування теорії, а не її підтвердження.

Усвідомлення цього може неабияк розвантажити вам мозок. Адже не варто хвилюватися про те, як тлумачити кожнісінький результат експерименту так, щоб підтвердити вашу теорію. Не варто ламати собі мозок тим, як *кожною* отриманою крихтою свідчень підтвердити свою теорію, оскільки, як уже знаєте, на *кожну* одиницю очікування свідчення існує таке саме зворотне очікування зниження ймовірності. Якщо ви намагаєтеся послабити спростувальні свідчення можливого «аномального» спостереження, ви не можете не послабити доказову вагу «нормального» спостереження рівно на стільки ж пунктів. Це гра з нульовою сумою. Хай які у вас потурання, аргументи чи стратегії, ви не можете математично очікувати, що розроблений план дій у середньому зрушить ваші переконання в конкретному напрямку.

Вмостіться собі зручно на канапі і просто чекайте нових свідчень.

... Яка ж *усе-таки* дефектна та людська психологія.

Ретроспектива знецінює науку

Цей есей ґрунтується значною мірою на уривку¹ із книги Девіда Маєрса «Дослідження соціальної психології». Він вартує того, щоб його прочитали повністю.

Якось редактор журналу *The Atlantic* Каллен Мерфі казав, що у соціальних науках «перевинаходять ті самі ідеї та висновки, давно поховані у звичайних цитатниках... Щодня суспільствознавці проводять якісь дослідження, із якими виходять у світ. І дізнаються щось таке про людську поведінку, що цілком відповідає їхнім очікуванням».

Звісно, такі «очікування» — чистісінька ретроспектива. (Ось так працює упередження ретроспективи: ті, хто знають справжню відповідь на питання, присвоюють вищі ймовірності тому, що вони «і так знали» відповідь, у порівнянні з тими, хто мав здогадатися, не знаючи достеменно.)

Історик Артур Шлезінгер-молодший відкидав наукові розвідки досвіду солдатів Другої світової війни через те, що вони «складними й масивними методами демонстрували» здоровий глузд. До прикладу:

1. Більш освічені солдати мали більше проблем з адаптацією порівняно з менш освіченими. (Інтелектуали були менш психологічно підготовлені до бойових стресів, ніж люди з розвинутою практичною кмітливістю.)
2. Солдати з півдня швидше пристосовувалися до кліматичних умов спекотних островів Океанії, ніж солдати з півночі. (Південці більш при звичаєні до спекотної погоди.)
3. Білошкірі рядові частіше прагнули отримати звання унтерофіцерів, аніж чорношкірі. (Роки пригноблення позначаються на мотивації досягнення.)

1. <https://web.archive.org/web/20170801042830/http://csml.som.ohio-state.edu:80/Music829C/hindsight.bias.html>

4. Чорношкірі південці охочіше йшли у підпорядкування білошкірим офіцерам із півдня, а не з півночі. (Офіцери з півдня мали більше досвіду у взаємодії з чорношкірими солдатами.)
5. Під час бойових дій солдати проявляли більше бажання повернутися додому, ніж після закінчення війни. (Під час бойових дій солдати були свідомі того, що вони перебували у смертельній небезпеці.)

Як гадаєте, скільки таких знахідок *можна було* передбачити заздалегідь? Три з п'яťох? Чотири з п'яťох? Чи були такі випадки, коли ви передбачали протилежне, коли ваша модель зазнала поразки? Перш ніж читати далі, подумайте над цим...

...

Зі свідчень, наданих Паулем Лазарсфельдом за посередництва Маєрса, усі вищезазначені висновки насправді *суперечать* достеменним.² Пригадайте-но: скільки разів ви подумали про хибність вашої моделі? Скільки разів ви допускали, що могли помилитися? Настільки точною є ваша модель. Мірилом вашої сили раціоналіста служить ваша здатність спантеличуватися при взаємодії з вигадкою більше, аніж із дійсністю.

Якщо я, звісно, знову не змінив результати на протилежні. Як гадаєте?

А тепер ваші розумові процеси, коли ви *дійсно не знаєте* відповіді, відрізняються від тих, якими ви користувалися задля виправдання «відомої» відповіді?

Якось Діфна Баріц запропонувала студентам коледжів кілька висновків, вигаданих для експерименту: одним — істинні (як-от: «У часи економічного добробуту люди витрачають більшу частину своїх доходів, аніж під час економічної кризи»), а іншим — протилежні

2. Paul F. Lazarsfeld, "The American Soldier—An Expository Review," *Public Opinion Quarterly* 13, no. 3 (1949): 377–404.

до істинних.³ Що та, що та група студентів оцінила очікуваний висновок як такий, що «можна було б [його] передбачити». Кращого опису упередження ретроспективи годі й шукати!

Це наводить людей на думку, що наука їм не здалася й поготів — усе ж і так було зрозуміло.

(Саме так, як і очікувалося, правда?)

Ефект упередження ретроспективи призводить до систематичного знецінення несподіваних наукових відкриттів, особливо тих, які ми *розуміємо*, які здаються нам справжніми і які можна вписати у свою модель світу. Якщо ви розумієте нейрологію або фізику і читаєте новини в цій галузі, то, либонь, так само недооцінюєте несподівані результати досліджень. У такий спосіб несправедливо знецінюється внесок дослідників. Ба гірше, цей ефект заважає вам побачити, коли свідчення не узгоджуються із тим, чого *дійсно* очікували.

Належне здивування потребує свідомого зусилля. І ми повинні його докладати.

3. Daphna Baratz, *How Justified Is the "Obvious" Reaction?* (Stanford University, 1983).

Ілюзія прозорості: чому вас не розуміють

Біас «знання заднім числом» виглядає ось так: люди, які знають, чим закінчиться ситуація, вірять, що результат можна було заздалегідь легко передбачити. Коли нам відомий наслідок, ми переосмислюємо становище з урахуванням уже наявного результату. Навіть коли ми свідомі цього упередження, то не можемо забути результат інтерпретації і подивитися на ситуацію очима людини, яка не знає того, що знаємо ми.

До споріднених явищ належить *ілюзія прозорості*: ми завжди знаємо, що означають наші слова, і тому очікуємо, що решта теж володіє цим знанням. Читаючи власне висловлювання, ми з легкістю вловлюємо сенс написаного, керуючись знанням того, що дійсно було на думці. А от поставити себе на місце того, хто мусить тлумачити всліпу, спираючись лише на слова, а не на те, що автор мав на увазі, — справа не з легких.

Джун радить Маркові ресторан. За обідом у хлопця складається враження про заклад: А) несмачна їжа та посереднє обслуговування або Б) смачна їжа та бездоганний сервіс. Тоді Марк залишає повідомлення на автовідповідачі дівчини: «Джун, я тільки-но пообідав у тому ресторані, який ти мені радила, і мушу сказати, що обід був неперевершеним — я просто в захваті». Бобз Кізár ознайомив групу респондентів зі сценарієм А: 59% сприйняли повідомлення Марка як саркастичне і *сказали, що Джун витлумачить його так само*.¹ Серед решти, якій показали сценарій Б, тільки 3% повідомили, що Джун прочитає сарказм у словах Марка. Кізар та Барр, схоже,

1. Boaz Keysar, "The Illusory Transparency of Intention: Linguistic Perspective Taking in Text," *Cognitive Psychology* 26 (2 1994): 165–208.

вказують на те, що учасникам експерименту відтворювали справжнє голосове повідомлення.² Кізар виявив, що якби респондентам сказали, що ресторан жакхливий, але *Марк хотів завуалювати свою відповідь*, вони б вважали, що Джун не розпізнає сарказму у тому повідомленні:³

Вони з однаковою ймовірністю оцінювали протилежні події: вона прочитає сарказм, і коли він спробує приховати негативний досвід, і коли буде цілком щирий у своїх словах. Учасники розцінили комунікативний намір Марка як прозорий. Вони ніби припускали, що Джун зрозуміє Марків намір так, як того хоче він.⁴

«The goose hangs high» — англійський фразеологізм, який вже вишов з ужитку. Одній групі Боаз Кізар та Бріджит Блай сказали, що сенс цієї ідіоми — світле майбутнє⁵; друга ж дізналася, що ідіома позначає похмуре майбутнє. Опісля учасників запитали, яке з цих двох значень непоінформована людина з більшою ймовірністю приписала б тому фразеологізмові. Кожна група відповіла, що така людина прийняла б дане їй значення як «стандартне».⁶

2. Boaz Keysar and Dale J. Barr, "Self-Anchoring in Conversation: Why Language Users Do Not Do What They 'Should,'" in *Heuristics and Biases: The Psychology of Intuitive Judgment*, ed. Griffin Gilovich and Daniel Kahneman (New York: Cambridge University Press, 2002), 150–166.

3. Boaz Keysar, "Language Users as Problem Solvers: Just What Ambiguity Problem Do They Solve?," in *Social and Cognitive Approaches to Interpersonal Communication*, ed. Susan R. Fussell and Roger J. Kreuz (Mahwah, NJ: Lawrence Erlbaum Associates, 1998), 175–200.

4. Формулювання Кізара та Барра. — Прим. авт.

5. Boaz Keysar and Bridget Bly, "Intuitions of the Transparency of Idioms: Can One Keep a Secret by Spilling the Beans?," *Journal of Memory and Language* 34 (1 1995): 89–109.

6. Серед інших ідіом були «to come the uncle over someone», «to go by the board» та «to lay out in lavender». Так, англійська — ну просто еталон ясності. — Прим. авт.

В іншому дослідженні Кізар та Енн Хенлі перевіряли калібрування впевненості мовців: наскільки точно вони оцінювали рівень розуміння слухачів.⁷ Мовцям давали двозначні речення («Чоловік переслідує жінку на велосипеді») та зображення, що уточнювали зміст (чоловік переслідує жінку, яка їде на велосипеді), а потім просили їх озвучити ці висловлювання перед аудиторією та оцінити, скільки адресатів утямили закладене значення. Мовці вважали, що їх зрозуміли у 72% випадків — а насправді у 61% випадків. Коли адресати не розуміли повідомлення, доповідачі вважали, що їхня аудиторія вловлювала сенс у 46% випадків; а коли адресати, навпаки, розуміли, доповідачі думали, що їхнє повідомлення не дійшло у 12% випадків.

Інші учасники експерименту, які підслухали тлумачення виразів, не піддалися цьому біасу та очікували розуміння слухачів тільки у 56% випадків.

У своєму дослідженні Кізар та Барр згадали випадок, як за два дні до вторгнення Німеччини у Польщу Чемберлен надіслав листа, у якому хотів чітко дати знати, що якщо напад таки станеться, то Британія втрутиться. Гітлер сприйняв той лист, написаний дипломатичним жаргоном, як жест примирення — і розпочав війну.

Саме тому не варто поспішно звинувачувати тих, хто хибно витлумачив ваші ідеально сформовані речення. Адже існує неабияка ймовірність того, що ваші слова більш двозначні, ніж здається.

7. Boaz Keysar and Anne S. Henly, "Speakers' Overestimation of Their Effectiveness," *Psychological Science* 13 (3 2002): 207–212.

В очікуванні коротких умовивідних дистанцій

Середовище еволюційного пристосування *Homo sapiens* (також відоме як «середовище проживання предків», або СЕП) складалося з груп мисливців та збирачів із щонайбільше 200 людей¹. Писемності у них не було, тому все успадковане знання передавалося по пам'яті усним шляхом.

У такому світі фонове знання доступне всім. По суті, немає повністю приватної інформації — тільки публічна.

Проживаючи у середовищі предків, навряд чи ви могли просунути на *один крок умовиводу* далі за ваших одноплемінників. Якщо ви знайшли нову оазу, вам не доведеться пояснювати своїм одноплемінникам, що таке оаза, навіщо потрібна вода або як потрібно дістатися до неї. Тільки вам відоме розташування тієї оази — і це приватне знання. Однак немає таких членів племені, котрі б не тямили, що таке оаза, і все, що пов'язане з водою, — адже всі про це знають. Якщо ви передаєте якусь інформацію у середовищі предків, вам майже не доводиться роз'яснювати свій поняттєвий апарат. У крайньому разі ви можете розтлумачити одне нове поняття, але не два чи три за раз.

У середовищі предків не існувало абстрактних дисциплін із розлогими корпусами надійно відібраних свідчень, узагальнених у витончені теорії, що поширювалися б у друкованих книжках із висновками, *відірваними на сотні умовиводів* від універсальних вихідних умов.

У середовищі предків кожен, хто стверджує щось без очевидного підтвердження, або брехун, або бовдур. Навряд чи вам спаде на думку щось на кшталт «Так, а може, у цієї людини вагомі засновки, про які у моєму племені ніхто не знає», тому що у тому середовищі тако-го просто не могло бути.

1. https://uk.wikipedia.org/wiki/Число_Данбара

І навпаки: якщо ви озвучуєте щось явно очевидне, чого не бачить ваш співрозмовник, то бовдуром вже стає *він*. Або ж навмисне прикидається, щоб позлити вас.

Ба більше, якщо хтось щось говорить без очевидного підтвердження та *очікує*, що ви приймете це на віру, а потім ще й обуриться, коли ви відмовили, то він, напевне, *не стовна розуму*.

І в купі з ілюзією прозорості та ефектом прив'язки це *багато* в чому пояснює добре відомі труднощі комунікації науковців з непосвяченою аудиторією або навіть з науковцями з інших галузей. Коли мовець припускається помилок у поясненні, то з мого досвіду він зазвичай відступає на *крок* назад там, де варто було б відійти на два чи більше. Або слухачі припускають, що матеріал має бути зрозумілим за один крок, тоді як на пояснення може піти два чи більше кроків. Обидві сторони діють так, наче очікують мінімальних умовивідних дистанцій від загального знання до нового.

Біолог у розмові з фізиком може обґрунтувати еволюцію, стверджуючи, що це найпростіше пояснення. Проте не кожен на планеті Земля посвячений у легендарну історію науки від Ньютона до Айнштейна, протягом якої словосполучення «найпростіше пояснення» набуло особливого значення — Слово Сили, вимовлене на світанку життя теорій та викарбуване на їхніх надгробках. Для решти аргумент «Це ж найпростіше пояснення!» може звучати привабливо, проте навряд чи переконливо: не виглядає він настільки потужним інструментом для розуміння службової політики чи ремонту зламаної автівки. Зрозуміло, що біолог, зациклений на власних ідеях, стає настільки зрозумілим, що відчужується від альтернативних пояснень, які звучать не менш правдоподібно. (Якщо це звучить правдоподібно для мене, то так воно має бути і для інших притомних членів моєї групи.)

З точки зору біолога ще можна зрозуміти, чому, на перший погляд, теорія еволюції може здатися дещо дивакуватою. Проте якщо її відкидають навіть після аргументу «Це ж найпростіше пояснення!», то хто ж тоді ті ненауковці як не йолопи — нема чого з ними розмовляти.

Чітка аргументація має прокладати *стежку* умовиводів: починаючи від того, що *вже відомо і прийнятно* для аудиторії. Якщо ви не відступаєте на достатню кількість кроків у своїх міркуваннях, то вважайте, що говорите з самим собою.

Якщо в якийсь момент ви стверджуєте щось без належного обґрунтування аргументів, які ви раніше обстоювали, то аудиторія прийме вас за вар'ята.

Коли слухачі помічають, що ви надаєте аргументам явно більшої ваги, ніж *на той момент* було б виправдано в очах аудиторії, вас сприймуть за вар'ята. Скажімо, ви говорите так, наче «найпростіше пояснення» — переконливий аргумент на підтвердження теорії еволюції (яким він і є), а не просто цікава ідея (як це звучить для тих, хто не свідомий духу шанування леза Оккама).

І ще — краще не натякати, що *ви* мислите на добрий десяток кроків умовиводу далі за те, що відомо аудиторії, або що *ви* маєте якесь особливе фахове знання, недоступне їй. Слухачі поняття не мають про еволюційно-психологічний аргумент на користь когнітивного упередження, під впливом якого недооцінюються умовивідні дистанції. І це призводить до комунікативних заторів. І перше, що спаде їм на думку, — це ваша зверхність.

А якщо ви вважаєте, що зможете пояснити поняття «систематично нехтуваних умовивідних дистанцій» у кількох словах — мушу вас розчарувати...



Загадкові відповіді

Вигадані пояснення

Одного дня викладач фізики покликав своїх учнів до класу і показав їм широку квадратну металеву пластину, що стояла поряд з увімкненим радіатором опалення. Учні по черзі клали руку на ту пластину і виявляли, що сторона з боку обігрівача була холодною, а протилежна, навпаки, — теплою. *«Як на вас, яка цьому причина?»* — запитав учитель. Одні зробили припущення про конвекційні потоки повітря, інші — про наявність дивних металів у пластині. Учні витворили багацько цікавих пояснень, проте жоден не опустився до того, щоб сказати «Я не знаю» або «Такого просто не може бути».

Підступ був у тому, що перед тим, як учні ввійшли до класу, викладач розвернув ту пластину.¹

А тепер уявіть собі учня, який видає заїкаючись: «Е-е-е, мабуть, то через теплопровідність або щось типу того?» Тепер запитую я: чи є така відповідь належним переконанням? Ці слова виголосити легко — досить підвищити голос і додати рішучості. Та чи здатні ці слова спрямовувати наші очікування?

Зверніть увагу на цей безневинний прийменник «через», що стоїть перед словом «теплопровідність». І поміркуйте, що *ще* можна поставити після нього. Так само можна, до прикладу, сказати «через флогістон» або «через магію».

«Магія?! — усередині вас накочує хвиля обурення. — Але ж це не наукове пояснення!». І справді: словосполучення «через теплопровідність» та «через магію» заведено відносити до різних *літературних жанрів*. «Теплопровідність» — це щось таке, що міг би сказати Спок в одній із серій «Зоряного шляху», тоді як «магія» звичніше почути з вуст Руперта Джайлза, котрий із «Бáффі — переможниця вампірів».

1. Joachim Verhagen, Science Jokes, 2001, <https://web.archive.org/web/20060424082937/http://www.nvon.nl/scheik/best/diversen/scijokes/scijokes.txt>.

Та ми, баєсіанці, вважаємо не стільки на літературні жанри, скільки на спрямування очікувань, в якому і полягає суть моделі. Якщо ви скажете «теплопровідність», який досвід це слово дає вам підстави *очікувати*? За звичайних обставин, якщо ви покладете руку на ту сторону пластини, яка з боку обігрівача, то вона на дотик буде теплішою, ніж протилежна. Якщо причиною «через теплопровідність» можна також пояснити і свідчення того, що сторона з боку радіатора на дотик *холодніша*, то нею можна пояснити взагалі *що завгодно*.

І як ми всі, сподіваюся, вже знаємо, дійшовши до цього речення, якщо ви неабиякий мастак із пояснення чого завгодно, то у вас нульове знання. У такому разі «через теплопровідність» — це гіпотеза, яка приховує в собі максимальне значення ентропії.² У термінах очікуваних спостережень таке припущення еквівалентне «через магію». Відчувається як пояснення, але ним ні разу не є.

Припустімо, замість того, щоб гадати, ми виміряли температуру металевої пластини у різних точках і в різний час. Коли ми бачимо металеву пластину поряд із радіатором, ми зазвичай очікуємо, що температури у різних точках досягають рівноваги, зазначеної у рівнянні дифузії, відносно граничних умов, які задаються показниками навколишнього середовища. Ви можете не знати точної температури у першій точці, але після вимірювання кількох точок — я не настільки фізик, щоб знати, скільки їх потрібно — можна з великою точністю здогадатися про решту.

Той, хто неабияк знається на тому, як використовувати числа для обмеження очікувань щодо матеріальних явищ — умовний фізик, —

2. 1) У термодинаміці кількість різних способів отримати фізичний стан (принцип Больцмана). Наприклад, злегка перетасована колода має менший рівень ентропії, ніж повністю перетасована, через те, що існує набагато більше конфігурацій, в яких може опинитися друга колода. 2) У теорії інформації очікувана цінність інформації, що міститься в повідомленні (принцип Шеннона). Тобто принцип ентропії Шеннона випадкової величини полягає у кількості (у середньому) витрачених бітів інформації за умови відсутності значення випадкової величини. Принципи ентропії Больцмана і Шеннона виявилися рівнозначними, а це означає, що термодинамічна невпорядкованість системи відповідає числу бітів, необхідних для її повного опису. — Прим. пер.

провів би кілька вимірів і сказав: «Дві з половиною хвилини тому температура цієї пластини перебувала у рівновазі, а потім її розвернули, і зараз її показники знову наближаються до рівноваги».

Грунтовніша помилка учнів полягала у тому, що вони не обмежили свої очікування. Вони думали, що займаються фізикою, тому вжили прийменник «через», після якого поставили слова, які, можливо, використав би Спок із «Зоряного шляху», і думали, що таким робом ступили у магістерію науки.

А хто думкою багатіє, ви знаєте і без мене. Вони просто посунули свою магію з одного літературного жанру в інший.

Вгадати вчительський пароль

Замолоду я читав популярні книжки про фізику, серед яких була «КЕД: дивна теорія світла і матерії» Річарда Фейнмана. Я був свідомим того, що світло, звук і матерія — це хвилі. У дев'ять років я пишався своєю обізнаністю в науці.

Подорослішавши, я взявся читати «Фейнманівські уроки з фізики» і там натрапив на перлину під назвою «хвильове рівняння». Я розумів, як він виводить його, але, оглядаючись назад, я не відразу збагнув його істинність. Три дні минули у роздумах над хвильовим рівнянням, аж доки мені не стало соромно за своє нерозуміння. І я нарешті зміркував, що надто буквально сприймав твердження фізиків про те, що світло — це хвиля, звук — це хвиля і матерія — це хвиля. Як виявилось, я поняття не мав, що це слово — хвиля — означало для фізиків.

На рівні інтуїції зазвичай вважають, що якщо фізики кажуть «світло складається з хвиль» і вчитель запитає «З чого складається світло», а учні скажуть «З хвиль!», то учні засвоїли урок. Цілком справедливо. Чи ні? Якщо ми приймаємо відповідь «хвилі» від фізика як правильну, було б несправедливо вимагати від учнів чогось іншого. Звісно ж, відповідь «Хвилі!» або правильна, або хибна. *Хіба ні?*

І це ще одна набута у школі шкідлива звичка¹, від якої треба відмовитися. У слів немає внутрішньо властивих значень. Якщо я чую два склади «бо-бер» і на думку мені спадає великий гризун, це свідчить про мій стан розуму, але аж ніяк не про склади «бо» і «бер». Послідовність складів «складається з хвиль» (або «через теплопровідність») — це ніяка не *гіпотеза*. Це звукові коливання у певному порядку, які поширюються повітряним шляхом або через чорнила на папері. Хтось може *брати* ці коливання за гіпотезу, але вони самі по собі ні хибні, ні правильні. Але у школі вчитель ставить вам

1. <https://www.lesswrong.com/posts/48WeP7oTec3kBEada/two-more-things-to-unlearn-from-school>

високий бал за те, що ви *сказали*: «складається з хвиль», бо це мусить бути правильною відповіддю, адже від фізика вчитель почув ідентичне звукове коливання. Оскільки учнів оцінюють за вербальну поведінку (усну чи письмову), вони починають надавати їй значення істинності. Але ж світло або складається з хвиль, або ні.

І це виливається у ще гіршу звичку. Припустімо, ваш учитель дає вам на розв'язання заплутану задачу про металеву пластину, яка стоїть поряд з обігрівачем, причому сторона з боку обігрівача холодна, а протилежна, навпаки, тепла. «Чому так?» — питає вчитель. Скажете «не знаю» — про «відмінно» можете *забути*. Вам навіть не зарахують таку відповідь. Та ось протягом цього семестру вчитель використовував такі словосполучення, як «через конвекцію», «через теплопровідність» та «через теплове випромінювання». І, либонь, одне з них він очікує почути. І ось ви відповідаєте: «Еммм, мабуть, через теплопровідність?».

Це не гіпотеза про металеву пластину. Навіть не належне переконання. Це — спроба *вгадати вчительський пароль*.

І навіть якщо ви уявили символи рівняння дифузії (математика, яка описує теплопровідність), це не означає, що ви сформулювали гіпотезу *про* металеву пластину. Та зараз ми не у школі — немає потреби перевіряти, чи пам'ятаєте ви рівняння дифузії. Це — мистецтво баєсіанства: тут ми ведемо рахунок ваших очікувань від досвіду. Досвідом це можна назвати тоді, коли ви використовуєте рівняння дифузії так, що після вимірювання термометром кількох точок ви намагаєтеся передбачити подальші вимірювання. Навіть якщо учень візуалізує собі *потік* чогось, тримаючи сірник біля холоднішої сторони пластини з метою визначити напрямок руху тепла, цей внутрішній образ потоку все одно можна назвати досвідом, який керує очікуваннями.

Якщо ви не *використовуєте* рівняння дифузії — не підставляєте числа, отримуючи на виході результати, які мали би звужувати ваші очікування від певного досвіду, — тоді зв'язок між вашою мапою і територією обірвано. І ви лишаєтеся не з переконанням, а з порожніми словами.

А в школі тільки й лишається, що оперувати порожніми словами: чи то під час письмового тесту, чи то під час усного опитування. Оцінку — хай яку — ви отримуєте за вербальну поведінку. Позбутися цієї поганої звички частково можна усвідомленням різниці між поясненням і паролем.

Що, надто суворо? Чи може відповідь «теплопровідність» бути першим кроком на шляху до правильної відповіді, коли вперше стикаєтеся з металевою пластиною, яка збиває вас з пантелику? Либонь, але тільки якщо ви не втрапите у пастку відшукування пароля. А що як поряд немає учителя, який вказав би на помилки? Що ж, тоді можете припустити, що «Світло — це вакалікси» і є тим самим поясненням, що «вакалікса» — вірний пароль. Такий випадок спіткав дев'ятирічного мене не тому, що я був дурний, а тому, що так стається *за замовчуванням*. Так мислять людські істоти, за винятком тих, хто навчився *оминати* цю пастку. І в таких ямах люди застрягали на тисячі років.

А якщо втовкмачувати учням, що *слова не рахуються* — *тільки регулятори очікувань*, може, вони *перестануть* носитися зі своїми «теплопровідність? Ні? Може, конвекція? Теж ні?» Можливо, *тоді*, якщо вони матимуть у голові слово «теплопровідність», це виведе їх на потрібний шлях:

- «теплопровідність»?
- Просто слово. Що воно означає?
- Рівняння дифузії?
- Набір символів. Як їх узагалі використовувати?
- До якого очікування має привести мене рівняння дифузії?
- Певна річ, не до очікування, що сторона металевої пластини, віддалена від обігрівача, на дотик буде теплішою.
- Я помічаю спантеличення. А раптом ближча до обігрівача сторона на дотик холодніша, бо зроблена з більш ізоляційного матеріалу і передає менше тепла руці? Виміряю температуру...

- Гаразд, це не те. Чи можу я взагалі спробувати перевірити, чи рівняння дифузії застосовне до цієї металевої пластини? Тепло тече, як і завжди, чи якось інакше?
- Я міг би піднести до пластини сірник і виміряти, як тепло розподіляється з часом...

Якщо ми не будемо суворо стежити за тим, щоб «Ееем, може, через теплопровідність?» не було вигаданим поясненням, учень, найімовірніше, застрягне на паролі штибу «вакалікси». *Цього не уникнути: із людьми таке відбувається ось уже тисячі років.*

Наука напоказ

У прев'ю до фільму «Люди Ікс» закадровий голос говорить: «Генетичний код... для мутації». Безсумнівно, шляхом мутації ви можете набути всіляких корисних здібностей. Наприклад, мутантка Шторм уміє метати блискавки.

Любий читачу, а тепер прошу тебе взяти до уваги біологічні механізми, необхідні для продукування електроенергії, біологічні модифікації, необхідні для убезпечення від цієї ж електроенергії, а також когнітивні схеми, необхідні для високоточного орудування блискавками. Якби такий організм, який внаслідок *мутації* отримав подібні здібності *за одне покоління*, дійсно існував, він був би прямим свідченням хибності синтетичної (неодарвіністської) моделі природного добору. Ще гірше хіба що знайти скам'янілі рештки кролика докембрійської ери. Якби теорію еволюції *дійсно* можна було натягнути на випадок Шторм, цією теорією можна було б пояснити що завгодно, а ми вже знаємо, чим це обернеться.

У коміксі «Люди Ікс» використовують такі терміни, як «еволюція», «мутація» і «генетичний код» чисто з метою віднести себе до *літературного жанру* під назвою «наука». Мене страхає ось що: можна тільки уявити, скільки людей, особливо завдяки медіа, розуміють науку *лишень* як літературний жанр.

Я зустрічаю людей, які мають непохитну віру в еволюцію і насміхаються з дурості креаціоністів. І разом із тим поняття не мають, що дозволяє і забороняє теорія еволюційної біології. Вони мудрагельствуватимуть над тим, яким буде «наступний етап в еволюції людства», ніби природний добір стався за чийсь планом. Або, ба навіть гірше, правитимуть смаленого дуба про щось, що виходить за межі еволюційної біології, як-от: покращений дизайн для комп'ютерних чипів, поділ корпорацій або завантаження людської свідомості в комп'ютери. А потім називатимуть усе *це* «еволюцією». Якщо еволюційну біологію можна натягнути на таке, нею можна пояснити взагалі будь-що.

Либонь, більшість тих, хто *вірить* в еволюцію, використовує фразу «бо еволюція», щоб не відставати від наукової тусовки і принагідно похизуватися своєю вірою, як лабораторним халатом. Якби у науковій тусовці було заведено казати «бо розумний задум», то більшість із таким самим завзяттям користувалася б цим словосполученням. Зрештою, що одне, що інше словосполучення ніяк не регулює їхні очікування. Якщо вони казатимуть «бо еволюція», а не «бо розумний задум», Шторм видаватиметься їм цілком органічною. Віднести себе до племені — саме таку функцію виконує ця фраза.

Мені доводиться зустрічатися з людьми, які тішаться думкою про «штучний інтелект, тупіший за людину» або навіть «штучний інтелект, трохи розумніший за людину». А коли розповісти їм про надрозумний штучний інтелект, вони вирішать, що це якась псевдонаука¹. Не те щоб у них є своя теорія інтелекту, за допомогою якої вони вираховували теоретичну граничну межу оптимізаційного процесу. Вони ототожнюють надрозумний ШІ із жанром апокаліптичної фантастики, тоді як ШІ, що керує невеликою корпорацією, — зі статтею із журналу *Wired*.² Відкриваючи рот, вони не залучають свою модель мислення. Вони не розуміють, що їм *потрібні* моделі. Не розуміють, що наука *будується на* моделях. Їхня нищівна критика надрозумного ШІ повністю складається з апеляцій до апокаліптичної фантастики, а не, скажімо, пізнаваних законів, які виключають такий варіант розвитку подій. Їхнє розуміння науки *повністю* зводиться до літературного жанру або приналежності до племені. Просто вони не хизуються лабораторним халатом і вболівають за іншу футбольну команду.

Чи є в науці такий концепт, вірою в який ви *пишаєтеся*, проте на практиці цією вірою не користуєтеся? Але краще поставте собі інше питання: якому майбутньому досвіду ваше переконання *забороняє* статися? Зрештою, ви отримаєте суму того, що засвоїли і зробили справжньою частиною себе. Решту, мабуть, можна віднести до паролів або спроб похизуватися.

1. <https://www.lesswrong.com/posts/XKcawbsB6Tj5e2QRK/is-molecular-nanotechnology-scientific>

2. Щомісячний журнал, в якому публікуються матеріали про вплив комп'ютерних технологій на культуру, економіку та політику. — Прим. пер.

Вигадана причиновість

Відповіддю алхіміків вісімнадцятого століття на стихію вогню, запроваджену давніми греками, був флогістон. Запалюєте деревину і дивитеся, як вона горить. А потім питаєте: що це за жовтогаряча полум'яна штукенція? Чому дерево обертається на попіл? Обидва питання тогочасні хіміки закривали однією відповіддю — флогістон.

Йойки, розумієте? Їхньою відповіддю був... флогістон.

У процесі горіння флогістон вивільнявся у вигляді видимого полум'я. З виділенням флогістону горючі речовини втрачали його й оберталися у попіл — «чисту субстанцію». А в закритих посудинах полум'я згасало, бо повітря перенасичувалося флогістоном, що унеможливлювало подальше горіння. Опісля згоряння від деревного вугілля майже нічого не залишалося, тому що вугілля — майже чистий флогістон.

Але ніхто, звісно, не застосовував теорію флогістону, щоб *передбачити* результат хімічної реакції. Спочатку ви дивилися на результат, а теорією флогістону *пояснювали* його. Теоретики флогістону не прогнозували, що у закритій посудині полум'я згасне, — вони запалювали полум'я у посудині, дивилися, як воно потухає, а тоді казали: «Повітря перенасичилося флогістоном». Теорія не годилася для того, щоб вказати на те, які результати були б *неможливими*, якби вона була правильною. Нею можна було випояснити що завгодно.

Такими були перші кроки науки. Довгий час нікому й на думку не спадало, що це було проблемою. Вигадані пояснення *виглядають* правдоподібними. І цим вони небезпечні.

Згідно із сучасними дослідженнями, люди думають про причинно-наслідковий зв'язок як про орієнтовані ациклічні графи (ОАГ) мереж Баеса. Оскільки дощило, тротуар мокрий; оскільки тротуар мокрий, він слизький.

Дощ → Тротуар мокрий → Тротуар слизький

З цього ми можемо виснувати (або, з позиції мереж Баєса, строго розрахувати в імовірностях), що якщо тротуар слизький, то, мабуть, дощило. Та якщо нам уже відомо, що тротуар мокрий, то, дізнавшись, що він іще й слизький, ми не можемо нічого сказати про те, чи дощило.

Чому під час горіння вогонь гарячий і яскравий?

Флогістон → Вогонь гарячий і яскравий

Схоже на пояснення, представлене у тому ж форматі когнітивних даних. Проте людський мозок не завжди розпізнає, коли причина не обмежує наслідок. Ба навіть гірше, через ефект знання заднім числом може скластися враження, що причина обмежує наслідок, тоді як вона просто підлаштовується під нього.

Показово, що на основі нашого сучасного розуміння ймовірного міркування про причиновість ми можемо з точністю описати, що теоретики флогістону робили не так. Одним зі стимулів для створення баєсових мереж була проблема подвійного підрахунку свідчень, коли висновок перегукується з наслідком і причиною. Скажімо, я отримую не зовсім надійну інформацію про те, що тротуар мокрий. І в мене виникає думка, що, скоріше за все, зараз дощить. А якщо, скоріше за все, зараз дощить, чи не збільшує це ймовірність того, що тротуар мокрий? І чи не збільшує *це* ймовірність того, що тротуар слизький? Але якщо тротуар слизький, він, можливо, і мокрий, а тоді мені знову потрібно буде підвищити ймовірність того, що зараз іде дощ...

Джу́да Перл використовує метафору про алгоритм для підрахунку кількості солдатів у строю. Припустімо, ви стоїте у строю: один солдат попереду, один позаду. Усього їх троє (разом з вами). Ви питаєте солдата позаду: «Скільки солдатів *ти* бачиш?» Оглядається і відповідає: «Троє». Тепер усього — шестеро. Очевидно, це слід робити *не* так.

Розумнішим було б запитати солдата попереду «Скільки солдатів перед тобою?», а солдата позаду — «Скільки солдатів позаду тебе?» Направду, можна було поставити питання «Скільки солдатів попереду?» і не спровокувати плутанину. Якщо стрій починається мною, я передаю сигнал: «Один солдат попереду». Той, хто позаду, отримує «один солдат попереду» і передає «двоє солдатів попереду» тому, хто позаду. Водночас кожен солдат отримує повідомлення «N солдатів позаду» від тих, хто стоїть позаду, передаючи його далі у вигляді «N + 1 солдатів позаду» тому, хто стоїть попереду. То скільки тих солдатів усього? Додайте два отримані числа і ще одиницю — ось вам загальна кількість солдатів у строю.

Суть у тому, що кожен солдат має *окремо* вести лік своїх обрахунків — чи то позаду, чи то попереду — і вже тільки насамкінець додати обидва. Не варто додавати солдатів, про яких ви дізналися ззаду, до тих, про яких ви дізналися спереду. Ніхто не передає і не озвучує вголос загальну кількість солдатів.

Аналогічний принцип діє у строгому варіанті ймовірнісного міркування про причиновість. Якщо ви дізнаєтеся про те, що йде дощ з якогось *іншого* джерела, а не зі спостереження мокрого тротуару, це спровокує переадресацію повідомлення від [Дощ] до [Тротуар мокрий]. Це підвищить очікування того, що тротуар мокрий. Якщо ви бачите, що тротуар мокрий, це спровокує зворотний сигнал до нашого переконання про те, що зараз йде дощ. І це повідомлення розповсюджується від [Дощ] до всіх сусідніх вузлів, *окрім* вузла [Тротуар мокрий]. Ми зараховуємо кожне свідчення рівно один раз. Жодне оновлене повідомлення не «стрибає» туди-сюди. Точний опис цього алгоритму можна знайти у книзі Джуди Перла «Імовірнісне

міркування у системах інтелекту: мережа вірогідних висновків».¹²

То що ж пішло не так у теорії флогістону? Коли ми дізнаємося, що вогонь гарячий, вузол [Вогонь гарячий і яскравий] може передати свідчення у зворотному напрямку до вузла [Флогістон], що спонукає нас оновити свої уявлення про флогістон. Але в такому разі ми не зможемо зарахувати таке міркування до вдалого передбачення флогістонової теорії. Це повідомлення має прямувати тільки в один бік і не стрибати назад.

Але, на жаль, люди не послуговуються строгим алгоритмом для оновлення мереж переконань. Ми дізнаємося про батьківський вузол (джерело) зі спостережень за дочірнім і передбачаємо дані про дочірні вузли з наших уявлень про батьківський. Але ми не проводимо строгого розмежування між записами для напрямків назад і вперед. Ми запам'ятовуємо собі, що флогістон гарячий, тому він *є причиною* того жару у вогні. Що ж, схоже, флогістоною теорією можна передбачити вогняний жар. Чи, гірше того, виникає враження, що *флогістон є причиною того жару*.

Поки ви не помічаєте ніяких завчасних прогнозів, ви не називаєте необмежений причиновий вузол «вигаданим». Він представлений так само, як і будь-який інший вузол у вашій мережі переконань. Він сприймається як факт, як і всі інші відомі вам факти: *через флогістон вогонь гарячий*.

Правильно спроектований ІІІ миттєво помітив би цю проблему. Не потрібен навіть спеціальний код — достатньо правильного обліку мережі переконань. (На жаль, ми, люди, не можемо перепрограмувати себе так, як міг би правильно спроектований ІІІ).

Ефект знання заднім числом — простий нетехнічний спосіб сказати, що люди не проводять строгого розмежування між прямими і зворотними повідомленнями, через що перші забруднюються другими.

1. <https://books.google.com/books?id=k9VsqN24pNYC&pg=PP1#PPA143,M1>

2. Judea Pearl, *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference* (San Mateo, CA: Morgan Kaufmann, 1988).

Ті, хто багато років тому пішов шляхом флогістону, не з власної волі пошилися в дурні. Науковці не настільки йолопи, щоб навмисне загнати самих себе у сліпий кут. А у вас є вигадані пояснення? Коли такі є, певен, що ви не називаєте їх «вигаданими поясненнями», тому за ключовим словом «вигаданий» ваша ментальна база даних жодних результатів вам не видасть.

Через ефект знання заднім числом уже замало перевірити, наскільки вдало ваша теорія передбачає наявні дані. Якщо спираєтеся на «вчора», ви позбавляєте себе гарантії, що безладний людський розум надішле незабруднене пряме повідомлення. Тому й наполягаю, що завбачати треба «завтра».

Семантичні стоп-сигнали

Якось дитина запитала:

- Звідки взявся цей камінь?
- Я відколов його від здоровезного валуна, що стоїть посеред села.
- А звідки взявся той валун?
- Либонь, він скотився з величезної гори, що височіє над нашим селом.
- А звідки взялася та гора?
- З чого ж і все каміння — з кісток першого бога-велета Іміра.
- А звідки взявся той Імір?
- Із прадавньої безодні Гіннунгагап.
- А безодня та звідки взялася?
- Досить на сьогодні питань.

Розглянемо гаданий парадокс першопричини. У науці дійшли до того, що все почалося з Великого вибуху. Але чому він взагалі стався? Звісно, відлік часу почався з Великого вибуху, а до нього не було звичного для нас плину хвилин і годин. Але ж таке твердження ґрунтується на нашому законі фізики, котрий сам по собі видається вельми структурованим. Але він потребує пояснення. Звідки беруть початок ті закони фізики? Ви можете сказати, що ми живемо у комп'ютерній симуляції. Але ж тоді комп'ютерна симуляція функціонує на основі якихось інших фізичних законів. Звідки ж тоді беруть початок *ті* закони фізики?

І тут дехто вигукне: «Бог!».

Але що змушує навіть глибоко релігійних людей уважати, що ця відповідь взагалі *допоможе* розв'язати парадокс першопричини? Що спиняє вас одразу ж запитати: «Звідки взявся Бог»? Відповідь «У Бога немає причини» чи «Бог сотворив себе сам» можна прирівняти до позиції «Час почався з Великого вибуху». Ми просто запитуємо, чому взагалі існує ця метасистема або чому деякі події можуть не мати причини, тоді як для всього іншого ми її вимагаємо.

Я ставлю собі за мету не обговорити гаданий парадокс першопричини, а поставити питання, чому існує переконання, що відповідь «Бог!» *може* розв'язати його. Обґрунтовувати будь-яку подію божественним втручанням — спосіб, яким люди проговорюють, що вони належать до певного племені, а тому що частіше вони пояснюють усе Богом, то краще, навіть якщо це відповідь на запитання «Чому Новим Орлеаном пронісся ураган?». Хай там як, ви все ж сподіваєтеся, що вони помітять: відповідь «Бог!» на *конкретну* загадку першопричини не допомагає. Та від того, *навіть якщо Бог існує*, парадокс менш парадоксальним не стає. Як таке взагалі можна не помітити?

Джонатан Волес припустив, що відповідь «Бог!» виконує функцію семантичного стоп-сигналу, себто він не є пропозиційним твердженням, а радше дорожнім знаком когнітивного руху: після нього думати заборонено.¹ Сказавши «Бог!», ми не стільки розв'язуємо парадокс, скільки встановлюємо когнітивний світлофор з постійним червоним світлом, щоб зупинити послідовне продовження ланцюжка питання-відповідь.

Але ж *ви*, порядний атеїст, такого б точно не утнули. Але «Бог!» не єдиний семантичний стоп-сигнал — просто найочевидніший приклад.

Через появу сучасних технологій — молекулярні нанотехнології, передові біотехнології, гена інженерія, штучний інтелект тощо — постають складні політичні питання. Яку роль має відігравати держава (якщо взагалі має), коли йдеться про контроль батьківського вибору генів для своєї дитини? Чи можуть батьки свідомо обрати гени, що призведуть до розвитку шизофренії? Якщо процедура підвищення рівня інтелекту дитини не по кишені батькам, чи має держава профінансувати її, щоб перешкодити утворенню інтелектуальної прірви? Ви можете запропонувати різним установам відповісти на це питання, наприклад: чи повинні приватні благодійні фонди надавати фінансову допомогу для підвищення рівня інтелекту?

1. Див. статті Волеса “God vs. God” (<https://www.spectacle.org/yearzero/godvgod.html>) та “God as a Semantical Signpost” (<https://www.spectacle.org/1095/stop1.html>).

Наступне очевидне питання: чи будуть ці установи ефективними? А якщо подавати позови на корпорації за шкоду від їхньої продукції, чи *допоможе* це перешкодити виходу руйнівних нанотехнологій?

Я знаю декого, хто має одну відповідь на всі ці питання: «Ліберальна демократія!». Ось вона! Їхня відповідь. Коли ви поставите послідовне питання на кшталт «Наскільки ефективно ліберальні демократи давали раду таким складним проблемам у минулому?» чи «А що як ліберальні демократи роблять якусь дурню?», вас неодмінно охрестять прихильником автократії, лібертопіанства чи просто негідником. Адже нікому не дозволено ставити демократію під сумнів.

Цей мисленнєвий шаблон я назвав «божественним правом демократії». У цьому випадку семантичним стоп-сигналом слугує відповідь «Демократія!». Якби прихильнику демократії сказали: «Передайте це у власність корпорації “Кока-кола”!», ви б отримали послідовні питання: «Навіщо?», «Що та корпорація збирається робити з тією власністю?», «Чому ми маємо їй довіряти?», «Наскільки ефективно вона давала раду подібним проблемам у минулому?».

Або, скажімо, хтось стверджує: «Американці мексиканського походження змовилися викачати весь кисень із земної атмосфери». «Навіщо їм *це*? Хіба вони не дихають, як і всі інші люди? Хіба вони взагалі діють як єдина зла сила?» — запитаєте ви. Якщо ви не ставите подальших запитань, коли хтось говорить: «Корпорації змовилися викачати весь кисень із земної атмосфери», тоді відповідь «Корпорації!» ваш мозок розпізнає як семантичний стоп-сигнал.

Але попереджаю: тут запросто можна піддатися спокусі витворити новий загальний контраргумент проти того, що вам не до вподоби: «А, та це ж просто стоп-сигнал!». Жодне слово саме по собі не є стоп-сигналом. Питання в тому, чи справляє воно такий ефект на певну людину. Те, що слово може спровокувати сильні емоції, не означає його як стоп-сигнал. Я не в захваті від терористів і не маю страху перед приватною власністю, але це не означає, що відповіді «Терористи!» чи «Капіталізм!» діють на мене як дорожні знаки когнітивного руху. (Колись такий ефект на мене справляло слово

«інтелект», але це вже в минулому.) Відмінна риса семантичного стоп-сигналу — *нехтування наступним послідовним питанням*.

Загадкові відповіді на загадкові питання

Уявіть, що ви дивитеся на свої руки, анічогісінько не знаючи про клітини, біохімію та ДНК. Після препарування кількох тіл ви дізналися, що у руці містяться м'язи, але не знаєте, чому ті м'язи рухаються, а не лежать глиною. Для вас рука — якась... штукенція... І з якоїсь причини вона рухається у потрібному вам напрямку. Що ж це, як не магія?

Мене не полишає відчуття, що тіло тварини функціонує за принципами, відмінними від тих, як працює тепловий двигун... Вплив тваринного чи рослинного життя на матерію безмежно перевищує можливості будь-якого наукового дослідження, яке досі проводилося. Здатність спрямовувати рухи рухомих часток — диво, яке ми маємо змогу щодня бачити як свободу волі або як зростання рослини з насінини покоління за поколінням, — у жодному разі не порівняти з будь-яким можливим результатом випадкового збігу атомів.¹

Під впливом свідомості у кожної людини виникає враження, що вона певною мірою підпорядкована власній волі. Отже, виявляється, одухотворені істоти можуть миттєво докладати сили для спрямування рухів певних частинок матерії у своєму тілі, щоб створити бажані механічні ефекти».²

Сучасні біологи вкотре приходять до визнання того, що існує щось більше, ніж просто сили гравітації, фізики чи хімії, і цей

1. Lord Kelvin, "On the Dissipation of Energy: Geology and General Physics," in *Popular Lectures and Addresses*, vol. ii (London: Macmillan, 1894).

2. Lord Kelvin, "On the Mechanical action of Heat or Light: On the Power of Animated Creatures over Matter: On the Sources available to Man for the production of Mechanical Effect," *Proceedings of the Royal Society of Edinburgh* 3, no. 1 (1852): 108–113.

невідомий компонент — віталістичний принцип.³

Лорд Кельвін

Щойно ви прочитали опис теорії *віталізму*, у межах якої таємнича різниця між живою і неживою матерією пояснювалася *Élan vital*⁴. *Élan vital* пронизувала живу матерію і слугувала причиною її свідомого руху. Ця сила брала участь у хімічних перетвореннях, яких не зазнавали жодні неживі частинки. Пізніше Фрідріх Велер синтезував сечовину — складову частину сечі — і тим самим завдав удару по віталістичній теорії, показавши, що за допомогою простої хімії можна відтворити продукт біології.

Забагато честі називати *Élan vital* поясненням, навіть таким вигаданим, як флогістон. Передусім воно спрацювало як стоп-сигнал для допитливості. Запитали: «Чому?». Отримали: «*Élan vital!*».

Коли говорите: «*Élan vital!*», у вас виникає *враження*, що ви розумієте, чому ваші руки можуть рухатися. Ось такий вигляд має коротка причинова схема у вашій голові:

Життєва сила → Руки рухаються

Та, по суті, ви не дізналися нічого нового. Вам невідомо, чи може ваша рука, скажімо, виділяти або поглинати тепло, якщо ви вже не пересвідчилися у цьому на власному досвіді. Передбачити вже не вдасться. Ви заморили черв'ячка своєї допитливості, але не втамували спрагу до знань. Реакція «Чому? Бо *Élan vital!*» на будь-яке спостереження годиться для обґрунтування усіх результатів. Гіпотеза, яка приховує в собі максимальне граничне значення ентропії.

3. Silvanus Phillips Thompson, *The Life of Lord Kelvin* (American Mathematical Society, 2005).

4. Життєве поривання (*фр.*). — Прим. пер.

Та головний урок ми можемо винести саме з благоговіння, яким сповнювалися віталісти перед *Élan vital*, їхньої наполегливості охрещувати це явище таємницею, яка виходить за рамки науки. Зіткнувшись з драконом Невідомості, віталісти не стали з ним на прю, а покірно схиляли голови. Вони пишалися своїм невіглаством і перетворили біологію на *священне* таїнство. А коли у двері постукали свідчення, віталісти не захотіли поступатися своїм неучтвом.

Таємниця Життя безмежно перевищувала можливості науки! Зауважте: *безмежно перевищувала можливості, а не трішки не вписувалася!* Безсумнівно, лорд Кельвін переживав трепет через своє *незнання*.

Але невігластво існує на мапі, а не на території. Моє незнання чогось свідчить про мій поточний ментальний стан, а не щось про об'єкт мого незнання. Щось може *видаватися* комусь таємничим. Але не існує чогось такого, що було б таємничим саме по собі. Поклонятися чомусь, бо воно здається таким дивовижним і загадковим, — що поклонятися своєму невігластву.

Помилка віталізму була тією самою, що й у теорії флогістону, — *таємницю герметизували в речовині*. Вогонь був чимось таємничим, тому у флогістоновій теорії таємницю помістили у загадкову речовину під назвою флогістон. Життя було священним таїнством, тому у віталізмі священну таємницю помістили у загадкову речовину під назвою *Élan vital*. І жодна відповідь не допомагала зосередити щільність імовірності моделі — тобто полегшувати пояснення деяких результатів на відміну від інших. Таке «пояснення» просто упакувало поставлене питання у чорну наглухо закриту скриньку.

В одній із комедій Мольєра⁵ лікар узявся пояснювати силу снодійного: мовляв, люди засинають завдяки «дрімотній властивості» лікарського засобу. Той самий принцип. Одна з хиб людської психології полягає у тому, що, зіткнувшись із чимось загадковим, ми скоріше припишемо цьому якісь невіддільні таємничі властивості, ніж визнаємо складність засадничих процесів.

5. У комедії «Удаваний хворий» (*Le Malade imaginaire*). — Прим. пер.

А ще гіршим буде припускати, що *відповідь* може бути так само загадковою. Гадана загадковість якогось явища свідчить про стан наших знань, а не про саме явище. Віталісти бачили загадкову прогалину у своїх знаннях і заповнили її таємничою штуkenцією. Так вони помилково прийняли мапу за територію. Будь-яка плутанина і розгубленість існують тільки в розумі, а не всередині речовин.

Ось таким і є остаточне й універсальне пояснення, чому люди раз у раз із подивом виявляли, що надзвичайно загадкове питання має зовсім не загадкову відповідь. Бо таємничість властива питанням, а не відповідям.

З таких міркувань я називаю теорії на кшталт віталізму загадковими відповідями на загадкові питання.

Ось кілька ознак того, що перед вами *загадкові відповіді на загадкові питання*:

- По-перше, пояснення виступає стоп-сигналом для допитливості, а не регулює очікування.
- По-друге, у гіпотезі немає рухомих частин, а модель являє собою не конкретний складний механізм, а всуціль непробивну речовину чи силу. Ще можна сказати, що таємнича речовина чи сила перебуває то тут, то там, спричиняє те чи інше. Але причину, чому ця містична сила поводить саме так, ховають за туманною й порожньою «єдністю».
- По-третє, ті, хто пропонують пояснення, плекають своє невігластво. Вони з гордістю розповідають про те, як це явище не піддається вивченню науковим методом або не схоже на решту звичайних явищ.
- По-четверте, *навіть після того, як відповідь отримано, явище все одно залишається таємницею* і не втрачає своєї дивовижної незрозумілості, якою характеризувалася на початку.

Емерджентність: чи потрібна вона?

Ми бачимо хибність теорій флогістону та віталізму, бо з позиції сьогодення нам легко бачити помилки минулого. Чи міг би я зважитися назвати якусь *сучасну* теорію, яка, як мені видається, хибує у тому ж напрямку?

Я хочу розглянути *емерджентність*, яку зазвичай визначають як вчення про системи, що «виникають» із взаємодії низькорівневих елементів і впливають у особливі високорівневі. (З вікіпедії^{1,2} «Спосіб, у який виникають складні системи і закономірності з безлічі відносно простих взаємодій».)

Якщо сприймати цей опис буквально, він пасує до будь-якого явища у нашому всесвіті вище рівня окремих кварків, і ця всеохпність терміна — частина проблеми. Уявіть, що ви спостерігаєте обвал ринку і кажете: «Це не кварк!». Схоже на пояснення? Ні? Тоді нема чого казати: «Це емерджентне явище!».

Зауважте, що я виступаю саме проти іменника «емерджентність». У тому, що ми кажемо « X виникає³ з Y », немає нічого поганого, якщо Y — конкретна деталізована рухома модель. «Впливати з» — ще одне слушне формулювання, яке має те саме значення: сила тяжіння впливає з викривлення часопростору, і це описано конкретною математичною моделлю загальної теорії відносності. Хімія впливає із взаємодій між атомами, описаними конкретною моделлю квантової електродинаміки.

А тепер уявімо, що, скажімо, сила тяжіння пояснюється «виникалізмом» або що хімія — «виникалістське явище». Ось таке пояснення.

1. <https://en.wikipedia.org/wiki/Emergence>

2. Схоже, відтоді, коли автор написав цей есей, англomовну статтю про емерджентність встигли переписати. — Прим. пер.

3. Англійський іменник «emergence» (емерджентність) утворюється з дієслова «emerge» (виникати, з'являтися). — Прим. пер.

Словосполучення «виникає з» так само прийнятне, як і «впливає з» чи «спричинений чим», якщо після нього зазначена якась конкретна модель, яку слід розглядати за її прогностичною силою та внутрішньою структурою.

Проте слово «емерджентність» зазвичай уживається в *іншому* значенні. Зазвичай воно вживається у контексті самодостатнього пояснення.

Я вже збився з ліку, скільки разів я чув, як люди казали, що «інтелект — емерджентне явище», ніби це твердження пояснювало інтелект. Такий слововжиток підходить під усі ознаки загадкової відповіді на загадкове питання. Що ви дізналися, коли почули, що інтелект «емерджентний»? З цього твердження навіть передбачень ніяких не зробиш. Ви й досі ні чорта не знаєте про те, що насправді відбувається у розумі. Схоже на те, що ви вірите новому спостереженню, але не очікуєте інших результатів. Ви заморили черв'ячка своєї допитливості, але не втамували спрагу до знань. У цієї гіпотези немає рухомих частин. Немає внутрішньої деталізованої моделі, якою можна було б оперувати. Ті, хто пропонують гіпотезу емерджентності, визнають своє незнання внутрішніх частинок та ще й пишаються ним. Вони протиставлять науку про емерджентність іншим більш приземленим наукам.

І навіть після того, як на питання «Чому?» дали відповідь «Емерджентність!», *це явище залишається таємницею* і не втрачає своєї священної недосяжності, якою характеризувалася на початку.

Ідея для цікавої вправи: прибрати прикметник «емерджентний» з усіх речень, в яких воно трапляється, і подивитися, чи зміниться їхнє значення:

- *До:* Людський інтелект — емерджентний продукт роботи нейронів.
- *Після:* Людський інтелект — продукт роботи нейронів.
- *До:* Поведінка мурашника — емерджентний наслідок взаємодії багатьох окремих мурашок.

- *Після:* Поведінка мурашника — наслідок взаємодії багатьох окремих мурашок.
- *Або ще краще:* Мурашник складається з мурашок. Ми можемо передбачити певні аспекти поведінки мурашника тільки за допомогою моделей, у які входять окремі мурашки без жодних макрозмінних цілого мурашника. І це означає, що ми розуміємо, як поведінка мурашника впливає з поведінки мурашок.

Ідея для ще однієї цікавої вправи: замінити слово «емерджентний» старим-добрим слівцем, яким люди користувалися як поясненням до того, як з'явилася емерджентність:

- *До:* Життя — емерджентне явище.
- *Після:* Життя — магічне явище.
- *До:* Людський інтелект — емерджентний продукт роботи нейронів.
- *Після:* Людський інтелект — магічний продукт роботи нейронів.

У кожному із цих тверджень рівно порівну кількості знань про поведінку явища. І кожна гіпотеза повністю відповідає однаковому набору результатів.

«Емерджентність» увійшла в моду так само, як і колись це зробила «магія». І з тієї ж причини вона має схожий потужний вплив на людське сприйняття. «Емерджентність» — напрочуд просте пояснення, його приємно вимовляти, а ще — виникає відчуття таїнства, перед яким слід схилити голову. Поняття у широкому вжитку *через те, що* воно подається у забігайлівці для допитливих. Емерджентністю можна пояснити що завгодно, і люди не відмовляють собі у такому задоволенні. Це ж так чарівно — відчувати, що можеш щось пояснити.

Люди не перестають бути людьми навіть після кількох занять із наукознавства у коледжі. Знайшовши спосіб зняти п'ята усталеної науки, вони все одно витворюють ті самі штуки, що й їхні прашури, і так само маскують свої вихилиси під жанр науки. Та все ж психологія дає про себе знати.

Скажіть складності «Ніт»

Одного разу...

Було це тоді, коли я вперше зустрівся із Марчелло. Згодом цілий рік ми працювали над теорією ІІІ, хоч на той момент я ще не взяв його в учні. Я знав, що він брав участь у національних олімпіадах з математики та інформатики. Це привернуло мою увагу, і я почав придивлятися до нього, хоч тоді ще й не знав, чи його можна було б навчити думати про ІІІ.

Був запитав Марчелло, як, на його думку, ІІІ може зібрати кубик Рубіка. Не способом банального попереднього програмування, а шляхом пізнання штучним інтелектом законів усесвіту Рубіка і того, як їх застосовувати. Як ІІІ зміг би *розробити собі* поняття «оператор» і «макрос», без яких неможливо зібрати кубик?

І ось посеред розмови пролунала його відповідь:

— Що ж, гадаю, щоб зробити X та Y, ІІІ має бути досить складним.

— Забудь про «*складність*», — відказав я.

— Що? Чому?

— Складність ніколи не має бути самоціллю. Можливо, тобі знадобиться особливий алгоритм, що додає якусь частину складності, але нею самою ти тільки ускладниш собі завдання. (У ту мить я думав про усіх тих людей, від яких чув заяви про «пробудження» інтернету, про те, як він перетвориться на ІІІ, щойно стане «достатньо складним».)

— Але ж має бути *хоча б якась* складність, яка опікуватиметься цим, — не вгавав Марчелло.

На мить я заплющив очі і подумав, як донести йому те, що було у мене на думці. Мені «складність» *відчувалася* як хибний крок на шляху до розвитку ІІІ. Нікому не під силу думати настільки швидко, щоб обмірковувати кожне речення у потоці свідомості, оскільки для цього знадобилася б нескінченна рекурсія. Хоч ми і мислимо словами, та потік свідомості прямує глибше рівня слів, керуючись

залишками минулих осяянь та суворого досвіду, отриманого численними вишколами.

— Ти читав есе «Технічне пояснення технічного пояснення»?¹

— Так.

— Гаразд. А тепер: коли ти кажеш «складність», твоя маса ймовірності не зосереджується на конкретніших передбаченнях.

— О, то це як з «емерджентністю». Он воно як. Отже, тепер я маю подумати над тим, як насправді можна отримати Х...

Тоді я про себе подумав: «*Мабуть, його таки можна навчити*». Складність — не безглузда концепція. До неї прикріплені математичні визначення: складність Колмогорова та складність Вапника — Червоненкіса. Про складність часто доводиться думати навіть на інтуїтивному рівні, наприклад: оцінити складність гіпотези і вирішити, чи вона «занадто складна» з урахуванням супровідних свідчень, або після оцінки дизайну спробувати спростити його.

Проте концепти не корисні і не безглузді самі по собі. Важить те, як ви їх *застосовуєте*. Роблячи цей крок, Марчелло намагався пояснити щось задарма, отримати щось за просто так. У цій галузі це доволі поширена помилка. Доедняйтеся до будь-якого обговорення про штучний генералізований інтелект і побачите, як учасники не перестають наступати на ті самі граблі: постійно спускають з уваги те, чого не розуміють, і, як наслідок, не усвідомлюють, що припускаються тієї самої помилки.

Не встигаєте помітити, а вже під'єднали неконтрольованим причиново-наслідковим вузлом щось таємниче, вузлом, котрий відчувається як пояснення, але ним не є. Цей тип помилки лежить значно глибше, ніж рівень слів. Але це не якась особлива вада тієї чи іншої людини — так за замовчуванням з діда-прадіда працює людський мозок.

У жодному разі не можна *оминати таємничу частину* — на ній варто зосередитися, щоби віч-на-віч стати з нею на прю. Люди понавигадували силу слів, якими оминають таємниці. Деякі з них

1. Див.: <https://www.lesswrong.com/rationality/a-technical-explanation-of-technical-explanation>.

використовують в інших контекстах: слово «складність» — тому приклад. І хай би яким був той причиново-наслідковий вузол, основна помилка саме в *нехтуванні* таємницею. І це нехтування проявляється не думкою, а мікродумкою. Щоб піймати себе на цьому, слід проявити особливу пильність. І коли ви докладете достатньо зусиль, щоб помічати таємниці, це уміння вийде на рівень інстинкту, так що його не доведеться навіть ословлювати. Ви маєте *відчувати*, які частини вашої мапи і досі не заповнені і, що більш важливо, навчитися звертати увагу на це відчуття.

Підозрюю: в академічних колах відчувається чималий тиск, щоб ви зробили вигляд, що ніяких проблем не існує, і подали дослідження із позірною завершеністю. Ви отримаєте більше очок за позірну повну модель з «емерджентними явищами», на відміну від явно неповної мапи із позначками «поняття зеленого не маю, як ця частина працює» або «а потім стається диво». Редактор наукового журналу навіть не прийме другу статтю до публікації. Мало хто знає, що на незвіданій місцевості відбувається найцікавіше.²

Якщо ви розпочинаєте новий проєкт з розробки революційного ШІ, виникає навіть сильніша спокуса через шалений тиск ховатися від проблем. Або ви визнаєте, що не знаєте, як зараз розробити ШІ, і ваші плани на життя розсиплються як картковий будинок. Але, можливо, я передаю куті меду, адже люди нехтують таємницями за замовчуванням і без того: свідчення тому — численні обговорення релігії, філософії, духовності або якоїсь науки, в якій людина відучора стала фахівцем.

Коли ми з Марчелло працювали над ШІ, домовилися ось про що: якщо ми стикалися із чимось таким, чого не розуміли (а таке бувало неодноразово), то обидвоє казали «магія» — наприклад, «Х магічно перетворюється на Y», — і це слугувало нагадуванням про *наявність нерозв'язаної проблеми, прогалини у нашому розумінні*. Набагато

2. А іноді буває так, що усі немагічні частини вашої мапи більше не мають значення. Це та ціна, яку ви платите за вхід до незвіданих земель і старання розв'язувати проблеми поступово. Але знати, коли ви закінчили освоєння, навіть іще важливіше. Адже у більшості випадків люди навіть не наважуються ступити у невідомість, оскільки їх у полоні тримає страх згаяти час. — Прим. авт.

краще говорити «магія», а не «складність» або «емерджентність», оскільки два останні слова створюють ілюзію розуміння. Розумніше сказати «магія», залишивши знак питання, який нагадуватиме, що до цього місця ще варто повернутися.

Упередження позитивного: зазирнути в темряву

Лекція. Записую на дошці три числа: 2, 4, 6. А потім кажу: «Я задумав правило, яке визначає послідовності трьох чисел. Виявляється, що послідовність 2-4-6 підкоряється цьому правилу. У кожного з вас на парті лежить стос індексних карток. Запишіть на картці послідовність трьох чисел, і якщо вона узгоджується із задуманим правилом, ви отримаєте свою картку із позначкою “Так”, а якщо не узгоджується — із позначкою “Ні”. Потім ви можете записати ще якусь послідовність із трьох чисел і перевіритися знову й знову. Якщо ж ви впевнені, що знаєте правило, напишіть його на картці. Тестувати комбінації можна скільки завгодно разів».

Зразок запису одного учня:

4-6-2

Ні

4-6-8

Так

10-12-14

Так

І тут учень записує своє припущення стосовно правила. До речі, а що думаєте *ви*? Хотіли б протестувати ще одну комбінацію? Якщо так, якою б вона була? Будь ласка, не поспішайте з відповіддю.

Ця задача ґрунтується на класичному експерименті Пітера Бейсона. І хоча учасники експерименту, яким давали завдання, зазвичай висловлювали високу впевненість у своїх здогадках, тільки 21% із них вгадували задумане правило. При повторних спробах рівень влучних здогадок коливався у межах 20%.

Це дослідження назвали «Про невміння відкинути гіпотези у концептуальній задачі». Учасники, які намагалися розв’язати задачу 2-4-6, зазвичай демонструють не *негативні* приклади, а *позитивні* — тобто вони роблять припущення про правило і

придумують на його основі показовий приклад, щоб побачити, чи отримають відповідь «Так».

Отже, той, хто сформулював гіпотезу «числа збільшуються на два», тестуватиме комбінацію 8-10-12, почує, що вона узгоджується із задуманим правилом, і сміливо виголосить своє припущення. Той, хто сформулював гіпотезу вигляду $X-2X-3X$, тестуватиме комбінацію 3-6-9, отримає відповідь «Так» і потім виголосить своє припущення.

У кожному випадку дійсне правило те саме: ці три числа мають розташовуватися у порядку зростання.

Щоб розгадати його, ви мали б придумати послідовності, які *не повинні* узгоджуватися із вашим початковим припущенням, наприклад: 20-23-26, щоб подивитися, чи отримаєте ви відповідь «Ні». Але цього, як правило, у цьому експерименті якраз і не роблять. У певних випадках учасники придумують комбінацію, тестують її і виголошують правила набагато складніші за дійсну відповідь.

Це когнітивне явище зазвичай відносять до «упередження підтвердження». Однак, як на мене, те, що люди тестують *позитивні* приклади, а не *негативні*, не варто змішувати зі спробою зберегти своє початкове уявлення. «Упередження позитивного» час від часу використовують як синонім до упередження підтвердження, і ця назва набагато краще підходить для конкретно цієї хиби.

Колись також вважали, що за допомогою флогістонової теорії можна пояснити затухання вогню у закритій коробці (бо у повітрі накопичувалося стільки флогістону, що він уже не міг виділятися), проте так само флогістоном можна було пояснити те, що вогонь *не* гаснув. А щоб помітити таке, ви маєте шукати негативні приклади замість позитивних — почати з «нулів» замість «одиниць», що, як показав експеримент, іде врозріз з інстинктом людини.

Адже на рівні інстинктів ми, люди, живемо у половинчастому світі.

Лекцій про упередження позитивного вистачить на кілька днів, але навіть якщо прослухати їх усі, прогавити його можна саме в цю мить. Упередження позитивного не стосується логічного мислення чи навіть емоційної прив'язаності. Задача 2-4-6 — суха і чисто

логічна річ. Та все ж ця помилка не виражається на рівні свідомого обмірковування — радше на рівні образів та інстинктивних реакцій. Оскільки корінь проблеми не в дотриманні якогось спеціального правила штибу «Думай тільки про позитивні приклади», її не можна вирішити і запам'ятовуванням іншого правила: «Ми маємо думати і про позитивні, і про негативні приклади». Який приклад першим спадає на думку вам? Варто на інтуїтивному рівні звертати в протилежний бік. Вчитися рефлекторно схилитися до нуля, а не відсахуватися від нього.

Кілька есеїв тому я вже писав про те, що сила гіпотези в тому, чого вона пояснити *не може*, а тому, якщо ви мастак із пояснення чого завгодно, у вас насправді нульове знання. Отже, щоб ідентифікувати некорисне пояснення, мало подумати над тим, що воно пояснює. Варто також пошукати результати, які воно *не здатне* пояснити. У цьому й полягає сила теорії.

І після того, як проговорив усе це, піддав сумніву корисність поняття емерджентності. Один коментатор навів такі суміжні з емерджентністю приклади, як надпровідність і феромагнетизм. Я відповів, що ненадпровідність і неферомагнетизм — такі самі приклади емерджентності. Тому і ці терміни нічим не кращі. Але хто ж я такий, щоб критикувати того коментатора! Попри те, що я прочитав багато всілякого про підтверджувальне упередження, я так само не помітив підступу у задачі 2-4-6, коли вперше дізнався про неї. Такі речі слід тренувати на підсвідомому рівні. Я і досі вправляюся у цьому.

Отже, більшу частину навичок раціоналіста годі вкласти у слова. Це та складність, з якою стикаються, коли намагаються описати мистецтво вербальними засобами. Люди спочатку погодяться з вами, а потім у наступному реченні ви зробите щось несвідомо всупереч своїм словам і незчуєтеся, як розійдетеся врізнобіч зі своїм співрозмовником. Але я в жодному разі не нарікаю! Основна причина, чому я пишу це, — побачити те, чого *не* передали мої слова.

Уже почали шукати позитивні приклади упередження позитивного? Чи заощаджуєте час на пошуки, намагаючись за допомогою

нього побачити те, чого зазвичай *не* бачите? Ви дивилися на світлу сторону чи зазирали у темряву?

Закономірна невизначеність

У своїй книзі «Рациональний вибір у мінливому світі» Робін Дейвз описує експеримент Твєрського:¹

Наприкінці 50-х — на початку 60-х років XX століття проводилося багато психологічних експериментів, в яких учасників просили передбачити результат події, в якій містився елемент випадковості, але із передбачуваністю на основі базової частоти. Наприклад, учасників питали, якого кольору виявиться картка, яку переверне експериментатор — червоного чи синього, — причому 70% карток були синіми. А от послідовність чергування кольорів була повністю випадковою.

Щоб отримати найвищу ймовірність успіху у цій ситуації, ви маєте передбачити найчастотнішу подію. Скажімо, якщо 70% карток сині, тоді успішність вибору синього кольору при кожній спробі складає 70%.

Натомість учасники, як правило, намагалися відтворити розподіл частот у своїх відповідях — тобто передбачали більш імовірну подію за відносною частотою, з якою вона відбувалася. Наприклад, у 70% випадків вони зазвичай передбачали, що експериментатор переверне синю картку, а у 30% — червону. Ця стратегія принесла їм 58% успіху, оскільки учасники мали рацію у 70% випадків, коли їм траплялася синя картка (імовірність цієї події складає 0,7), і в 30% випадків, коли траплялася червона (з імовірністю 0,3). Маємо: $(0,7 \times 0,7) + (0,3 \times 0,3) = 0,58$.

1. Dawes, Rational Choice in An Uncertain World; Yaacov Schul and Ruth Mayo, "Searching for Certainty in an Uncertain World: The Difficulty of Giving Up the Experiential for the Rational Mode of Thinking," *Journal of Behavioral Decision Making* 16, no. 2 (2003): 93–106.

По суті, учасники експерименту передбачають більш частотні події із трохи вищою ймовірністю, ніж ту, з якою вони відбуваються, але не спроможні передбачити її настання у 100% випадків, навіть коли їм платять за точність передбачень... Наприклад, учасники, яким давали п'ять центів за кожне правильне передбачення з тисячі спроб..., передбачали [найпоширенішу подію] у 76% випадків.

Ні, цей експеримент не про незначний огріх у стратегіях, які застосовують в азартних іграх. Він лаконічно ілюструє найважливішу ідею раціональності.

Учасники не переставали припускати «червоне», наче і не сумнівалися у своєму шансі передбачити випадкову послідовність. Ось що про цей експеримент пише Дейвз далі: «Попри зворотний зв'язок після тисячі спроб учасники не можуть усвідомити, що у цій ситуації передбачити випадковість їм *не вдається*».

Але ця помилка має ще глибші корені. Навіть якщо учасники експерименту *думають*, що висунули гіпотезу, то їм не обов'язково *робити ставку* на цей прогноз, щоб перевірити її. «А тепер, якщо *ця* гіпотеза правильна, наступна картка буде червоною», — але при цьому ніхто не забороняє ставити на синю. Вони можуть щоразу обирати синю, збираючи стільки п'ятицентових монет, скільки їм *вдається*, і разом вести в голові облік припущень про помічені закономірності. Якщо ті припущення виявилися правильними, *тоді* можна спробувати протестувати нововідкриту послідовність на практиці.

Я б не звинувачував учасника за те, що він продовжує вигадувати гіпотези. Зрештою, звідки йому знати, що не під силу спрогнозувати послідовність? Але я би звинувачував його за те, що він *робить ставку* на свої *припущення*, тоді як зовсім не обов'язково було збирати інформацію, причому *сотні* його попередніх здогадок спростувалися.

Чи може людина бути *настільки* самовпевненою?

Підозрюю, все простіше: стратегія ставити все на «синє» просто *не спала їм на думку*.

Люди бачать суміш лівової частки синіх карток із незначною кількістю червоних і припускають, що оптимальна стратегія — переважно ставити на сині і коли-не-коли — на червоні.

Контрінтуїтивність у тому, що за неповної інформації *оптимальна стратегія ставок не схожа на типову послідовність карток*.

Власне, *оптимальна* стратегія — чинити закономірно, навіть у середовищі з елементами випадковості.

Здається, що ваші дії мають бути настільки ж непередбачуваними, як і середовище. Але це хибна думка! *Випадковий ключ не відімкне випадковий замок лиш тому, що вони обидва підібрані навмання*.

З вогнем борються водою, а не вогнем. Але ця думка містить в собі ще один крок, нове поняття, яке не впливає безпосередньо з постановки проблеми; вона не з тієї когорти думок, які першими приходять у голову.

У дилемі синьої та червоної карток наші неповні дані свідчать про те, що кожного разу найкращим вибором буде ставити на «синє». І ця порада при неповному знанні незмінна на кожній спробі. Якщо у 30% випадків ми йдемо всупереч нашому частковому знанню і натомість ставимо на «червоне», врешті-решт зробимо тільки гірше, оскільки ставити на, як нам відомо, менш імовірний результат — відверта дурість.

А ставити щоразу на «червоне» — це взагалі найгірше, що можна зробити. Ставити на «червоне» у 30% випадків (із 30% червоних карт у колоді) — це тридцятивідсоткова дурість.

Коли ваше знання неповне (тобто у світі міститься елемент випадковості), випадковий вибір не розв'яже проблеми. Вносячи випадковість у свої дії, ви тільки віддаляєтеся від своєї цілі й аж ніяк не стаєте ближчими до неї. У мінливому світі викинути у вікно свою здатність мислити — не найкращий вибір.

Можливо, це здається комусь незвичним, але оптимальною стратегією може бути *закономірне мислення — навіть в умовах непевності*.

Тому й раціоналістів не так і багато, позаяк ті, хто сприймають світ хаотичним (а таких більшість), боротимуться із хаосом за допомогою хаосу. Ви маєте зробити ще один крок і подумати про те, що не одразу спадає на думку, та уявити боротьбу з вогнем чимось іще, крім вогню.

Певно, колись вам доводилося чути від непросвітлених щось штибу «Раціональність прекрасно працює тоді, коли решта людей так само раціональна. Але цей світ ірраціональний». Проте *якщо вам трапиться ірраціональний супротивник, навряд чи ви чимось зарадите, викинувши свій розум у вікно*. Навіть попри те, що ваш супротивник порушує закони, все ще існують закономірні форми мислення, за допомогою яких можна обрати найкращу реакцію. Навіть тоді, коли ви стикаєтеся із супротивником, який порушує теорію рішень, вона *не* займеться полум'ям.

Це не така вже й очевидна думка, як і поставити все на «синє», коли у колоді трапляються як сині, так і червоні картки. Кожна ставка на «червоне» — це математичне сподівання програшу, що також правда і для кожного відхилення від Шляху у вашому мисленнєвому процесі.

А тепер порахуйте: скільки серій «Зоряного шляху» після цього спростовано? А скільки теорій ШП?

Моя наївна й несвідома юність

Кажуть, в усьому, що батьки забороняють робити своїм дітям, перші пересвідчилися на власному досвіді — так і знають, чого робити не варто.

Ще за царя Гороха я присвячував усього себе традиційній раціональності¹ і вважав себе мастаком у цій справі, хоч і не знав шляху Баеса. Коли молодий Еліезер стикався із загадковим, на перший погляд, питанням, настанови традиційної раціональності не спиняли його від вигадування загадкової відповіді. З усіх тих помилок, що я їх припускався за життя, ця, безумовно, найганебніша. При думці про неї і досі дрижаки пробігають тілом.

Якою була та загадкова відповідь на загадкове питання? Докладно не описуватиму, оскільки це довга історія. Я був юним і звичайнісіньким традиційним раціоналістом, котрий не читав праць ні Тверского, ні Канемана. Знав про лезо Оккама, але не про оману поєднання. Думав, що зможу самотужки впоратися зі складними думками, які я вичитував у книжках, написаних у високочолому науковому стилі, не усвідомлюючи, що правильна складність можлива тільки тоді, коли кожен крок сильно звужує простір можливостей. Нині одна з головних порад, які я даю амбітним раціоналістам-початківцям, звучить приблизно так: «Не вдавайтесь до довгих ланцюжків міркувань або складних планів».

Ось що я вам скажу: навіть після того, як я витворював свою «відповідь», досліджуване явище все одно видавалося мені таємницею і зберігало свій флер дивовижної неосяжності, з якою я колись підступав до нього.

Але не подумайте: молодий Еліезер не був дурнем. Усі ті помилки, до яких він був причетний, і досі роблять поважні науковці, які

1. Традиційна раціональність — поняття, створене Юдковскі, для позначення наукових норм та домовленостей, яких дотримувалися такі мислителі, як Річард Фейнман, Карл Саган та Чарльз Пірс. Він протиставляє її уявленням про раціональність, які панують у сучасній математиці та когнітивістиці. - Прим. пер.

публікуються у престижних журналах. Щоб уникнути тих помилок, йому знадобилося б більш витончене вміння за те, якого його навчали у душі традиційної раціональності.

Адже юний Еліезер слідував приписам традиційної раціональності старанно і неухильно, поки не збився на манівці.

Як традиційний раціоналіст він пильнував, щоб його таємнича відповідь містила в собі сміливе передбачення майбутнього досвіду. Якщо конкретніше, я очікував, що у майбутньому нейробіологи дійдуть до квантової гравітації як рушія роботи нейронів, як вважав сер Роджер Пенроуз. Для цього нейрони мали підтримувати певний рівень квантової когеренції, яку можна було шукати, а потім знаходити або не знаходити. Так ви або побачите її, або ні.

Проте у моєї гіпотези не було ніяких *постфактумних* передбачень. Згідно з приписами традиційної науки, постфактумні передбачення не рахуються. То нащо тоді ними перейматися? Утім, якщо *сьогодні* гіпотеза баєсіанця не має переваги співвідношення правдоподібностей над відповіддю «я не знаю», то нащо тоді *сьогодні* вірити у щось складніше за «я не знаю»? Але тоді я не знав Шляху Баєса і не думав ні про які співвідношення правдоподібностей, ні про якесь фокусування ймовірнісної густини. Я сформулював спростовуване передбачення. Хіба цього було не досить?

Як традиційний раціоналіст юний Еліезер беріг свої переконання від магії, містики, вуглецевого шовінізму² та інших подібних дуростей. З моїх вуст гордо лунала таємнича відповідь: «Це просто фізика, як і все інше — просто фізика!». Виглядало це так, ніби ви хочете вберегти магію від когнітивного ізоморфа магії і підставляєте на її місце квантову гравітацію. Але я не знав Шляху Баєса і не бачив того рівня, на якому моя думка уподібнювалася до магії. Хоч я й *присягнув* на вірність фізиці, мене це не врятувало. А теорія ймовірностей узагалі щось знає про вірність? Я уникав усього, що забороняла традиційна раціональність. І навіть попри заборону те, що лишилося, не відрізнялося від магії.

2. Ідея про те, що основним компонентом молекул, відповідальних за життєдіяльність, обов'язково має бути вуглець. — Прим. пер.

Безумовно, завдяки моїй вірності традиційній раціональності я виліз з ями, яку сам собі вирив. Якби не та відданість, опинився б у *неабиякій* скруті. Але традиційної раціональності було замало, щоб зробити все *правильно*. Я зіштовхнувся з іншими помилками, відмінними від тих, які були для мене недвозначно заборонені.

Коли я міркував над тим, як юний я скрупульозно слідував приписам традиційної раціональності й отримував *хибну* відповідь, ставало зрозуміло, чому люди, які називають себе раціоналістами, і досі не керують світом. Вам потрібна *величезна* доза раціональності, аж поки натрапите на нові цікаві помилки.

Традиційна раціональність подається, скоріше, як мистецтво, а не наука: ви читаете біографії відомих фізиків, в яких подано уроки, яких їх навчило життя, а ви, читач, намагаєтеся прикласти ці уроки до свого життя. Але ви не можете прожити їхнє життя, і половина з того, що вони намагаються описати, — це інстинкт, який вони випрацювали на власному досвіді.

З погляду традиційної раціональності, у порядку речей витратити тридцять років на свою дурнувату ідею, якщо тільки вам вдасться таки спростувати її, визнати, що передбачає ваша теорія, і прийняти спростування, коли воно з'явиться, і т.д. Цього достатньо, щоб механізм науки рухався вперед, але трохи несправедливо до людей, які змарнували тридцять років. Традиційна раціональність — це прогулянка, а не танець. Вона влаштована так, щоб ви *уже таки* дісталися тієї істини, згайнувавши купу часу на приємні дурниці на шляху.

Традиційні раціоналісти можуть дозволити собі таку розкіш, як «кожен може лишитися при своїй думці». У традиційній раціональності *не прописано*, що мислення — це точне мистецтво, де є лише одна правильна оцінка ймовірностей за наявності таких-то даних. Там вам дозволено вгадувати, а потім тестувати свою здогадку. Проте зі свого досвіду можу сказати, що якщо ви не *знаєте* і намагаєтеся вгадати, ви однозначно помилитеся.

Шлях Баеса — так само неточне мистецтво, принаймні у тих випадках, коли я вдаюся до нього. Ці есеї — такі собі незграбні спроби ословити те, що краще було б освоїти на власному досвіді. Утім, мене

рятує те, що я можу *спертися* на математику, експериментальні свідчення з когнітивної психології про те, як насправді влаштовано людське мислення. Можливо, цього буде досить, щоб перетнути захмарний поріг, необхідний для освоєння алгоритму, за допомогою якого ви зможете отримувати правильні відповіді замість того, щоб шпоратися об нові цікаві помилки.

Проґавлені уроки історії

Колись замолоду, не відавши Шляху Баеса, я давав таємничі відповіді на загадкові питання (або принаймні вони такими здавалися). Одна помилка вервечкою вела до іншої, проте одна з них вирізняється з-поміж інших: молодий я не розумів, що *саме розплутування таємниці має розвіювати відчуття спантеличення*. Коли я намагався пояснити таємниче явище, це означало, що я мав віднайти його причину, а потім вбудувати її у цілісну й несуперечливу модель реальності. Якщо така природа того явища, то чому ж воно має втратити у таємничості? Я намагався *пояснити* таємниче явище, а не перетворити його (якимось неможливим алхімічним процесом) на звичайне явище, яке не вимагало б жодного особливого пояснення.

Будучи традиційним раціоналістом, я, звісно ж, знав історії про астрологів та астрономію, про алхіміків та хімію, про віталістів та біологію. Але жодна з них не нагадувала мені таємниче явище. Це було щось *нове*, набагато дивніше, складніше, що звичайній науці було не під силу пояснити століттями.

(Пишу так, ніби зірки, матерія і життя не залишалися таємницями впродовж сотень і тисяч років — відтоді як люди навчилися мислити й аж до того моменту, коли науковці врешті-решт знайшли відповіді.)

У школі ми вчимо астрономію, хімію та біологію, які *завжди здавалися належними* науці. Хіба всі ці речі *колись* були для когось таємничими? Коли науковці наважуються кинути виклик новій Великій таємниці, діти того покоління налаштовані скептично, оскільки вони ніколи не бачили на власні очі, щоб науковці пояснювали щось, що *здається* їм таємницею. Адже наука годиться тільки для пояснення того, що *асоціюється із наукою*, як-от: зірки, матерія і життя.

Тоді я думав: урок історії у тому, що астрологи, алхіміки і віталісти просто мали вроджену ваду у своєму характері — схильність до містеріанізму¹, який приводив їх до загадкових відповідей на загадкові явища. Якщо явище і справді було таке химерне, то чому ж тоді не може бути дивного пояснення?

Лише згодом, коли я зсередини почав бачити, з чого складається таємниця, то почав розуміти тих астрологів, алхіміків та віталістів. Тільки тоді я втямив, наскільки розважливим видавався віталізм *на ті часи*, наскільки *несподіваною* і *ніяковою* здавалася відповідь усе-світу: «Життя прозаїчне і не потребує химерних пояснень».

Ми читаємо історію, але не проживаємо її, не *відчуваємо* її на власному досвіді. Якби ж то я *особисто* взяв на віру астрологію, а потім відкрив ньютонівську механіку, повірив ув алхімію, а потім відкрив для себе хімію, увірував у віталізм, а потім відкрив біологію. Тоді я згадав би свою таємничу відповідь і сказав собі: «*Нізащо більше не поведуся на цю дурню знову*».

1. Філософська позиція, згідно з якою, наприклад, людський розум не спроможний збагнути природу свідомості. — Прим. пер.

Зробити історію доступною

У головах людей побутує мисленнева звичка, яку я називаю *логічною хибною узагальнення на основі вигаданих свідчень*. Наприклад, журналісти, які згадують стрічку «Термінатор» у своїх публікаціях про ІІІ, зазвичай не вважають її пророцтвом або незмінною істиною. Але фільм згадують — тобто він доступний — у тому контексті, ніби він уже демонструє випадок з історії. Ніби ті журналісти були свідками того, як таке сталося на якійсь іншій планеті, тому, цілком імовірно, те саме може статися і на цій.

Але є ще одна, протилежна до вищезгаданої, помилка, а саме — неналежна увага до історичних свідчень. Проблема узагальнення на основі вигаданих свідчень у тому, що вони вигадані — таких подій ніколи не ставалося. Це узагальнення взяте не з того ж розподілу, що й наш дійсний всесвіт, адже вигадка відрізняється від реальності систематичністю. А от історія *вже* сталася, тому *має* зробитися доступною.

У середовищі проживання предків не було ніяких фільмів, тому те, що ви бачили на власні очі, було правдою. Чи випадає тепер дивуватися, що вигадки, які ми бачимо у реалістичних стрічках, мають на нас аж такий вплив? І навпаки — з подіями, які *дійсно відбувалися*, ми стикаємося у вигляді чорнил на папері: вони хоч і відбулися, але на власні очі ми їх ніколи не бачили. Власне, ми їх просто не пам'ятаємо.

Протилежна помилка — ставитися до історії як до байки, сприймати її як сюжет художнього роману. Ви можете сказати, що історія ближча до правди, ніж до вигадки, проте це не означає, що на вас це повпливає як годиться. Багато біасів пов'язані з тим, що суха абстрактна інформація недостатньо змінює наше мислення.

Коли після того, як я дав Таємничу Відповідь на Загадкове Питання, я зрештою усвідомив, чиї помилки повторюю, я відразу відчув, наскільки цей досвід несподівано пов'язаний із минулим. Я збагнув, що віталізм — про який я читав тільки у книжках — придумали, а

потім зруйнували *справжні люди*, які мали той самий досвід, що і я, коли вигадував і руйнував свою Таємничу Відповідь. Також я подумав, що якби я отримав *безпосередній* досвід переживання минулого — не дізнався про наукові революції з підручників з історії, а на своєму досвіді прожив їх, — можливо, я б ніколи більше не припускався тих самих помилок. Не вигадував би *інші* Таємничі Відповіді. Перша тисяча уроків утовкмачила б мені цю мораль у голову.

Тому, думав я, щоб достатньою мірою відчутти силу історії, я повинен спробувати наблизитися до думок того Еліезера, який *пережив* історію — тобто я повинен спробувати думати так, ніби те, що я вчитав з підручників з історії, ставалося зі мною насправді.¹ Я маю зануритися в історію, уявити, як воно — *прожити* епохи, які бачив у вигляді чорнила на папері.

Навіщо мені пам'ятати про перший політ братів Райт? До тієї події я не маю ніякого стосунку. Але коли я вже називаюся раціоналістом, хіба я можу дозволити собі *не* пам'ятати, коли сталася та подія? Чи є аж така різниця між тим, щоб побачити подію на власні очі — що передбачає причинний ланцюжок із залученням відбитих фотонів, навіть не прямий зв'язок — чи через призму підручника з історії? Що фотони, що підручники з історії виникають причиново-наслідковими ланцюжками від самої події.

Через те, що я народився у певний час, мені доводилося долати свою хибну амнезію. Я мав пригадати — зробити доступними — *всі* спогади, а не тільки ті, які, за певним збігом обставин, стосувалися мене і доби, в якій я народився.

І раптом Земля постаріла.

У моїх ранніх спогадах Сполучені Штати Америки існували завжди, і не було такого періоду в історії, коли такої держави не існувало. До тих пір я не пам'ятав, як постала Римська імперія, встановила мир і порядок і проіснувала стільки століть, що я забув, що колись було інакше. Та все ж імперія впала, варвари захопили моє місто, і я

1. З відповідною поправкою на упередження доступності у підручниках з історії. Тобто я маю пам'ятати, що на кожного правителя була тисяча селян. — Прим. авт.

втратив знання, якими колись володів. Ось так у моїх очах сучасний світ став крихкішим — адже це був далеко не перший сучасний світ.

Помилку зроблено стільки, що можна *збитися з ліку*. А все тому, що я не пам'ятав, як робив їх кожної епохи, в якій ніколи не жив...

Тільки подумайте: іноді люди ще й питаються, наскільки важливо долати свої упередження.

Що, забули, скільки разів уже помирали від них? Забули, так? Я помітив, що часто раптова амнезія настає після смертельної помилки. Але повірте мені: це сталося. Я пам'ятаю, хоч і не був там особисто.

Отже, наступного разу, коли ви сумніватиметеся у химерності майбутнього, пригадайте, як десять тисяч років тому народилися у племені мисливців-збирачів, коли ніхто й уявити не міг, що таке наука. Згадайте, наскільки глибоко вас вразило наукове пояснення великих і жахливих священних таємниць, перед якими ви колись падали ниць. Згадайте, як ви колись вірили у те, що зможете літати, якщо з'їсти правильний гриб, а потім довелося змиритися з тим, що ви ніколи не полетите. Але згодом таки навчилися літати. Згадайте, як вірили у те, що у рабстві немає нічого поганого, що це у порядку речей, а потім змінили свою думку. Не тіште себе надією, що ви *могли б* передбачити ці зміни, бо на те вона й амнезія. Не забувайте, що ви так і не вгадали. Століття за століттям світ змінювався так, що вам на думку такого б і не спало.

Тому, можливо, ви вже менше дивуватиметеся майбутньому.

Пояснити? Поклонятися? Чи проігнорувати?

Коли у пошуках фруктових дерев і здобичі наше плем'я кочує луками, час від часу з неба летиться вода.

«Чому вода іноді падає з неба?» — із цим питанням я прийшов до бородатого мудреця з нашого племені.

На якусь мить він задумався — із таким питанням до нього ще не приходили. А потім з його вуст лунає відповідь: «Час від часу між духами Неба стається сутичка, після якої їхня кров окроплює землю».

Тоді я питаю: «Звідки тоді взялися ті духи Неба?».

Мудрець стихає до шепоту: «Із сивої давнини. З прадавніх часів».

Коли вода починає падати з неба і ви не розумієте чому, у вас є кілька шляхів. Перший — узагалі не питатися «чому», не намагатися відповісти на нього або ніколи не задумуватися про це. Так виглядає команда «Ігнорувати», яку спочатку обрав бородатий мудрець. Другий — вигадати якесь пояснення, тобто обрати команду «Пояснити», що і зробив мудрець, коли ви поставили своє перше питання. Третій — тішити себе відчуттям таємничості. У цьому суть команди «Поклонятися».

І тепер, як можна було помітити з цієї історії, щоразу, коли ви обираєте команду «Пояснити», у найкращому випадку отримуєте «бо духи Неба». Але таке пояснення породжує ще одне діалогове вікно. Що робити далі: пояснити, поклонятися чи ігнорувати? Щоразу, коли ви тиснете «Пояснити», зубчасті колеса науки починають рухатися, невдовзі ви отримуєте відповідь, а потім діалогове вікно спливає знову. Як чесні раціоналісти ми відчуваємо обов'язок постійно тиснути на «Пояснити». Але хіба тоді можливо отримати остаточну відповідь?

Тиснете «Пояснити», коли стикається із життям, — отримуєте хімію, тиснете знову — отримуєте атоми, тиснете знову — отримуєте

електрони і ядра, тиснете «Пояснити ядра» — отримуєте квантову хромодинаміку та кварки, тиснете «Пояснити кварки» — опиняєтеся на ланці «Великий вибух»...

Можна натиснути «Пояснити Великий вибух» і чекати, поки крутяться коліщата науки, а потім, одного дня, ми отримаємо цілком слушне пояснення. Але після того пояснення так само спливе чергове діалогове вікно. Отже, якщо продовжувати тицяти «Пояснити» досить довго, одного дня спливе *особливе* діалогове вікно, *нова* кнопка — «Пояснення, яке не потребує пояснень», — на якому обірветься цей ланцюжок. І це, либонь, єдине пояснення, яке варто знати.

Ось — я щойно натиснув «Поклонятися».

Не забувайте, що запалювати свічки навколо вівтаря далеко не єдиний спосіб чомусь поклонятися.

Якби я сказав «Гм, схоже, це парадокс. Цікаво: як його розв'язати?», тоді натиснув би «Пояснити», що зайняло б деякий час.

А якщо проблема у цілому видається вам неважливою чи недоречною або ви можете дозволити собі відкласти її до завтра, це означає, що ви натиснули «Ігнорувати».

Обирайте з доброго розуму.

«Наука» як гальмівник допитливості

Уявімо, що перед телекамерами у прямому ефірі я здійняв руки догори, вигукнув «абракадабра», і з моїх розчепічених пальців, де не взялося, спалахнуло яскраве світло. Уявіть, що я вчинив цей акт зухвалого і неприхованого чаклунства на очах у Джеймса Ренді та інших із когорти скептиків. Гадаю, більшість *неабияк зацікавилася* б цією витівкою.

А тепер уявімо, що я не виступаю перед камерами. Не розповідаю нікому ані про свою здібність, ані про те, звідки вона взялася. Я волію зберігати своє чаклунство у таємниці. Але я також хочу чаклувати, коли і де мені заманеться. Як би мені хотілося вичаклувати спалах світла, щоб у потязі краще читалося, але ніхто б не дошкуляв своєю допитливістю. Якби ж то існувало закляття, яке загальмовує ту допитливість!

І, на моє щастя, таке справді є! Щойно якась Варвара питає мене: «Як у Вас це виходить?», я просто кажу: «Наука!».

Як і належить гальмівнику допитливості, таке пояснення не справжнє. Адже воно нічого не говорить вам про те, чи світло спалахне чи погасне, чи змінить забарвлення за відтінком або насиченістю, і вже точно не скаже, як створити таке саме світло самому. А от після того, як я вимовив чарівне слово, нічого нового ви насправді не *дізналися*. Та попри це ви відвертаєтеся, вдовольнившись тим, що нічого незвичного не відбувається.

Ба більше, така сама дивина трапляється і зі звичайнісіньким перемикачем світла.

Клацаєте перемикач — лампочка загоряється. Чому?

У школі вчать, що пароль до лампочки — «Електрика!». Сподіваюся, тепер ви менш упевнені в тому, наскільки добре зі своїми шкільними знаннями «розумієте» лампочку. А от чи вдасться вам за допомогою пароля «Електрика!» провести розрахунки, котрі

регулюватимуть ваші передбачення досвіду? У будь-якому разі тут ще багато чого треба повчитися.¹

Якби ви думали, що лампочка — це об'єкт, який *наука пояснити не в змозі*, ви б очей від неї не відводили. Уся ваша увага була б прикута до неї.

Але що ж тоді означає вираз «наука може пояснити»? Це означає, що хтось *інший* знає, як працює лампочка. Коли хтось вам скаже, що лампочка — річ, яку «наука може пояснити», ви не дізнаєтеся нічого нового: і до, і після ви не знаєте, чи та лампочка загориться або погасне. Але через те, що це знає хтось *інший*, у ваших очах таке знання знецінюється. А допитливість згасає.

«Якби лампочки були невідомі науці, ви б зробили неабияку славу і статки, досліджуючи їх», — неодмінно скаже якийсь мудрагель. Та я не маю на увазі жадібність. Чи побудову кар'єри. Я говорю про чисту допитливість — те відчуття заінтригованості. Чому *ваша* допитливість згасає, коли *хтось* там — не ви — знає, як працює лампочка? Хіба це не обурливо? Вам мало знати самому; вам треба, щоб інші теж були невігласами. Чи від того, що інші люди не знатимуть, вам стане краще?

Крім допитливості, знання можуть сприяти, наприклад, розвитку технологій, з яких суспільству є користь. Для технологічної користі важливо, щоб знання існувало бодай у когось на планеті. Але який сенс саме для моєї допитливості знати, як працює лампочка?

Окрім того, подумайте-но про наслідки, якщо ви дозволите ставленню «Хтось інший знає відповідь» гальмувати вашу допитливість. Одного дня ви заходите у вітальню і бачите оповитого ореолом сріблястого світла здоровенного зеленого слона, що парує у повітрі.

«Якого біса?» — питання саме собою зірветься з ваших вуст.

А потойбічний голос, що долинатиме десь над слоном, констатуватиме:

«Хтось уже знає, чому у вітальні ширяє слон».²

1. Фізикам варто пропустити цей абзац і підставити сюди проблему з теорією еволюції, суть якої знову ж таки полягає в обчисленнях, які мало хто вміє виконувати. — Прим. авт.

2. <https://godescalc.wordpress.com/2012/06/24/overlooked-elephant/>

«Що ж, тоді все одно», — і після цих слів ви підете на кухню.

Я й уявлення не маю про теорію великого об'єднання для законів фізики, дійсних для цього всесвіту. Є в мене і прогалини в знаннях про людську анатомію, за винятком мозку. Я б не зміг показати, де саме у моєму тілі розташована печінка. І не зможу сходу пригадати, які функції вона виконує.³

Чи мушу я, якщо вже говорити про *допитливість*, більше цікавитися своїм незнанням фундаментальних законів фізики чи своєю необізнаністю в анатомії?

Якби з моїх пальців вихопився жмуток світла, такою з'явою ви б точно зацікавилися. А те, що я зміг підняти руку, має викликати *менше* зацікавлення? Коли ви піднімаєте руку і розмахуєте нею, кожен рух керується мозочком (хоч і не без участі інших ділянок мозку). Закладаюся: ви не знаєте, як функціонує мозочок. Так, я знаю небагато — тільки основне, чого недостатньо для проведення розрахунків... То й що з того? Кого взагалі хвилює *ваше* незнання? Звідки у допитливості ці подвійні стандарти для чаклунства і рухів рук?

Погляньте на себе у дзеркало. Ви знаєте, на що ви дивитесь? Знаєте, хто дивиться з-за ваших очей? Ви знаєте, ким ви є? На деякі з цих питань наука знає відповідь. Деякі відповіді і досі шукають. Але якщо не знаєте *ви*, то чому вашу допитливість турбує, що знає чи не знає та наука?

Ви знаєте, як працюють ваші коліна? А як виготовляється ваше взуття? Чому загоряється комп'ютерний монітор? Чому вода волога?

Навоколишній світ повен таємниць. За потреби розставте пріоритети. Але не нарікайте, що жорстока наука позбувається загадок. Якщо ж ви апологет незнання, тоді наполегливо прошу: не помічайте слона у вашій вітальні.

3. І я далекий від того, щоб пишатися своїм незнанням. На жаль, за усією математикою, яку я маю вивчати, навряд чи у мене скоро знайдеться час на вивчення анатомії. —

Прим. авт.

Справжня частина вас

У своїй відомій статті «Штучний інтелект зустрічає природну дурість»¹ Дрю Макдёрмотт критикував програми ШІ, в яких такі твердження, як «щастя — це стан розуму» намагаються представити за допомогою такої семантичної мережі:

STATE-OF-MIND

↑

| IS-A

|

HAPPINESS

І, звісно ж, вузол HAPPINESS порожній *всередині*. Просто собі голий символ мовою програмування Лісп, виражений смисловіювальним англійським іменником.

Ось що з цього приводу казав Макдермотт: «Для вишколеного програміста гарним завданням буде спробувати використати функцію `gensym`² у ключових ділянках коду, а потім подивитися, чи йому досі подобається така система. Наприклад, якщо вузол STATE-OF-MIND перейменувати на випадковий символ G1073 [...], тоді ми отримаємо вираз вигляду IS-A(HAPPINESS,G1073). Доволі сумнівний результат».

Я би сформулював трохи інакше: якби ви підставили випадкові символи в усі смисловіювальні англійські іменники, то нізачо на світі не второпали б, що означає вираз G1071(G1072,G1073). Чи призначена ця програма для відтворення гамбургерів? Може, яблука? Чи щастя? Або щось інше? *Якщо ж ви вирішите геть повидаляти ті смисловіювальні іменники, вони більше не з'являтимуться.*

1. Drew McDermott, "Artificial Intelligence Meets Natural Stupidity," *SIGART Newsletter*, no. 57 (1976): 4–9.

2. Функція, яка генерує унікальний символ, який можна використати для назви змінної чи функції. — Прим. пер.

Припустімо, фізик каже вам, що «світло — це хвилі», і ви вірите йому. Тепер у вашій голові сформувалась невеличка мережа:

IS-A(LIGHT, WAVES).

І якщо хтось питає вас: «З чого складається світло?», ви скажете: «З хвиль!». «Уся проблема в тому, щоб змусити слухача звернути увагу на сказане. Не “зрозуміти”, а саме “звернути увагу”», — каже Макдермотт. Припустімо, фізик сказав: «Світло складається з закарлюк».³ Чи помітили б ви тоді якусь різницю в очікуваному досвіді?

Як тоді зрозуміти, що не потрібно довіряти оманливому знанню «світло — це хвилі»? Можна випробувати його за допомогою запитання «Чи вдалося б мені відновити це знання, якби я міг почистити свою пам'ять від нього?».

Щось у тому ж дусі роблять програмісти, у програмі ІІІ перемішуючи назви смислослов'язливих токенів мовою Лісп, а потім дивляться, чи хтось інший зможе второпати, на що вони нібито «посилаються». Так само можна спостерігати, що штучний арифметик, запрограмований записувати і відтворювати

Plus-Of(Seven, Six) = Thirteen⁴

не зможе відновити цю інформацію, якщо ви видалите її з пам'яті, а інший програміст не введе у базу даних наново. Тобто якби ви забули, що «світло — це хвилі», то вже не змогли б пригадати це, крім як знову спитати у фізика. Самостійно відтворити це знання — як це роблять фізики — у вас би не вийшло.

Ті досвіди, з яких виростає переконання, поєднують його з іншими знаннями, чуттєвим сприйняттям і руховим відтворенням. Коли ви бачите бобра, який гризе колоду, то знаєте, як виглядає оте створіння, яке перегризає колоди. І ви зможете розпізнати його при подальших зустрічах, хай яким словом ви називаєте того гризуна. Але якщо ви тільки починаєте складати уявлення про бобрів з чийогось опису бобрів, імовірно, ви не впізнаєте його, коли побачите на власні очі.

3. До речі, це не так. — Прим. авт.

4. Сім та шість — тринадцять. — Прим. пер.

Ось у чому полягає страшна небезпека: намагатися *переказувати* штучному інтелекту дані, які він не зміг би засвоїти сам. Так само немає нічого хорошого у тому, щоб *розказувати* комусь про фізику те, у чому вони не можуть пересвідчитися на власному досвіді. Адже під «хвилиєю» фізики розуміють не «кривульку», а математичне поняття.

Як зазначає Девідсон, якщо ви вірите у те, що «бобри» живуть у пустелях, мають білосніжне хутро, а дорослі особини важать 300 фунтів⁵ — у вас немає ніяких переконань *щодо* бобрів — ні правильних, ні хибних. Такі переконання навіть не досить правильні, щоб бути хибними.⁶ Тобто якщо у вас немає досвіду, за допомогою якого ви змогли б відновити переконання, якби їх стерли з вашої пам'яті, тоді виникає сумнів у тому, чи у вас взагалі досить досвіду, щоб до чогось підв'язати це переконання. Казав-бо Вітгенштайн: «Коліщатко, яке може обертатися, коли ніщо інше не рухається, не є частиною механізму».

Щойно я почав читати про ШІ — навіть перед тим, як читав праці Макдермотта, — я усвідомив *важливість* питання «Якщо це знання зітруть з моєї пам'яті, як мені його відновити?».

Глибина видалення співвідноситься із суворістю тестування. Якби з мого розуму стерли всі способи доведення теореми Піфагора, чи зміг би я повторно довести її? Думаю, так. А якби я забув усе, що знаю про теорему Піфагора, чи зміг би я знову помітити цю закономірність у природі? Без експерименту складно сказати напевне, проте якби ви дали мені правильний трикутник із катетами довжиною 3 і 4, сказавши, що довжину гіпотенузи можна порахувати, гадаю, я б упорався із цим завданням (за умови, що я знаю решту математики).

А як щодо поняття *математичного доведення*? Якби я зроду не чув про математичне доведення, то чи зміг би на основі своїх інших переконань перевинайти його? Колись люди ні сном ні духом не відали ні про яке доведення. Але ж якось дійшли до нього. Що саме

5. Приблизно 135 кг. — Прим. пер.

6. Richard Rorty, "Out of the Matrix: How the Late Philosopher Donald Davidson Showed That Reality Can't Be an Illusion," *The Boston Globe*, 2003, https://archive.boston.com/news/globe/ideas/articles/2003/10/05/out_of_the_matrix/.

вони помітили? А якби щось настільки ж нове й важливе трапилося і мені, чи помітив би я? Чи зміг би я мислити аж так широко?

Яку частину своїх знань вам вдалося б відтворити? Від якої глибини стирання ви здатні вберегти його? Такий тест спрямований не тільки на те, щоб ви виявили і позбулися недостатньо внутрішньо зв'язних переконань. У такий спосіб ви зможете вибрати *ціле джерело знань, а не просто один факт*.

Якось пастух розробив свою систему лічби: коли вівця покидає кошару, він кидає круглястий камінець у відро, а коли повертається, дістає його. Якщо ви набилися в учні до пастуха і не розібралися у цій системі — якщо для вас це магія, яка відбувається без зрозумілих на те причин, — ви не знатимете, що робити із випадково кинутим у відро камінцем. Що несила зробити самому, те не вдасться і *переробити*, коли того вимагає ситуація. У вас не вийде повернутися до джерела, відкоригувати необхідний параметр і відтворити результат без доступу до того самого джерела. Якщо «два та чотири — шість» — це для вас даність, то замінімо один із доданків на «п'ять». Як цього разу ви збираєтеся дізнатися, що «два та п'ять — сім» за умови, що ви просто *завчили*, що «два та чотири — шість»?

Якщо ви побачите рослинку, яка щоразу скидає насінину, коли повз неї пролітає пташка, вам і на думку не спаде, що за допомогою спостереження за рослиною можна частково автоматизувати облік овець. Навіть якби ви дізналися щось таке, що творець міг би використати для покращення свого винаходу, ви не зможете повернутися до джерела і відтворити його.

Коли джерело думки перебуває у вас, після набуття нових знань і навичок думка може змінюватися. Коли джерело думки перебуває у вас, вона стає справжньою частиною вас і розвивається разом із вами.

Тому прагніть поселити у своїй голові кожну думку, яку варто обдумувати. Якщо якась думка прийшла до вас ззовні, впевніться, що вона проросла всередині. Не переставайте питати себе: «Якщо цю думку зітруть з моєї пам'яті, як мені її відновити?». А коли у вас є відповідь на це питання, уявіть, що зітруть і її. Коли ж намацаєте фонтан, подумайте, що ще ви зможете отримати з того потоку.



ІНТЕРЛЮДІЯ

Проста істина

І досі пам'ятаю, як писав той твір про екзистенціалізм. Моя вчителька повернула його з позначкою «незадовільно». Вона підкреслила слова «правдивий» і «правда» у кожному абзаці мого есею (всього було десь двадцять таких підкреслень) зі знаком питання навпроти кожного. Вона хотіла зрозуміти, що я маю на увазі під правдою¹.

Деніел Іген, журналіст

Мета цього есею — повернути наївний погляд на істину.

Хтось може сказати:

— Моя чудодійна змійна олія допоможе вам вилікуватися від раку легень всього за три тижні.

— Хіба клінічні дослідження не свідчать про те, що це неправда? — відповісте ви.

— Таке уявлення про «істину» доволі наївне. Що ви взагалі маєте на увазі під «істиною»?

Багато людей, коли їм прилітає таке питання, губляться і не знають, як відповісти на нього з необхідною точністю. Хай там як, а відмовлятися від поняття «істина» вкрай нерозумно. Колись ніхто й уявлення не мав про рівняння гравітації в усіх його подробицях. Але при цьому, зійшовши зі скелі, ви впадете.

Я часто натрапляю — особливо на інтернет-форумах — на розмови, в яких хтось з учасників пише: «Х істинне» — а потім спалахує суперечка довкола вжитку слова «істинний». Цей есей не покликаний надати енциклопедичний коментар до цього диспуту. Я радше сподіваюся, що сперечальники прочитають його і повернуться до змісту суперечки, перш ніж хтось поставить під сумнів природу істини.

У цьому есеї я ставлю питання. Якщо ви бачите відповідь, яка здається вам очевидною, ймовірно, це і є та відповідь, яку я маю на

1. У цій книзі леми «істина» і «правда» взаємозамінні. — Прим. пер.

увазі. Очевидний вибір не *завжди* найкращий. Але іноді, їй-богу, годі шукати кращого. Коли я натрапляю на очевидну відповідь, то не перестаю шукати. Але якщо я продовжую свої пошуки і відповідь, яка здається очевидною, *все ще* такою лишається, мені не соромно триматися її. Ну, звісно, всі *думають*, що два та два — чотири, усі одногolosно *кажуть*, що два та два — чотири, і в марудній рутині повсякденного життя всі *поводяться* так, ніби два та два — чотири. Та врешті-решт чому ж *насправді* дорівнює два та два? Наскільки я можу порахувати, чотири. Навіть якщо я поставлю це питання урочисто грізним тоном, сума доданків від того не зміниться.

Скажете: залегко? Можливо, у таких речах життя і не *має* бути складним. Хіба ж не чудово?

Якщо ви один із тих щасливчиків, яким на початку питання здається залегким, сподіваюся, воно таким і лишиться наприкінці. Якщо ви побиваєтеся над глибокими і змістовними питаннями, пам'ятайте: якщо ви точно знаєте, як працює система, і можете створити таку з відер і камінців, вона не має бути загадкою для вас самих.

Якщо навіть при тлумаченні метафори як метафори виникає загроза плутанини, спробуйте ставитися до всього *геть буквально*.

* * *

Уявімо, що я зробився пастухом, котрий живе у часи, коли історію ще не записували, а формальної математики ще не винайшли. Так-от переді мною стоїть проблема: треба якось вести облік овець у кошарі. Мої вівці сплять у загоні, загородженому стіною. Її висоти достатньо, щоб захистити їх від вовків, які вночі принаджуються до овець. Мій день починається з того, що я випускаю овець на пасовисько, а ближче до ночі знаходжу їх і повертаю до кошарі. Якщо вівця лишилася ночувати назовні, наступного ранку я знайду пошматований вовками труп. До того ж я не в захваті від того, що мені доводиться годинами прочісувати поля у пошуках останньої вівці, причому, можливо, всі вони вже у кошарі. Іноді, коли пошуки нічого не дають, я махаю рукою, і зазвичай така байдужість сходить мені з рук,

але приблизно у кожній десятій такій ситуації наступного ранку я знаходжу тіло мертвої вівці.

Якби ж то існував якийсь спосіб дізнатися, чи вівця досі пасеться, і не обтяжувати себе пошуками. У мене є кілька методів: підкидаю ворожбитські палички свого племені; я вправляюся у яснобаченні, завдяки якому я краще знаходитиму овець; я ретельно підшуковую причини повірити, що всі вівці у кошарі. Та нічого з цього не допомагає. Майже кожного десятого разу, коли я лягаю спати раніше, зранку так само знаходжу мертву вівцю. Можливо, я усвідомлюю, що мої методи недієві, і щоразу ретельно підбираю нові виправдання, коли не вдається знайти вівцю. Але так чи інакше дилема лишається. Я можу витратити годину, зазираючи в усі можливі закутки, і в більшості випадків просто змарнувати час. Або можу лягти спати раніше і втратити (в середньому) десяту частину овець.

Якось пізно ввечері я втомився як ніколи. Підкидаю ворожбитські палички і маю відповідь: повернулися усі вівці. В уяві спливає кожен закуток, з якого не доведеться нікого виганяти. Але я й досі не певен, тому заходжу до кошари і бачу багато овець. Аналізую вкладені зусилля і вирішую, що на сьогодні вже досить. Моя тривога спадає, і я йду спати. А наступного ранку знаходжу вже двох мертвих овець. Аж раптом у голові щось клацає, і я починаю думати нестандартно.

Того дня біля воріт кошари було чути гучні звуки роботи молотком.

Наступного ранку відкриваю тільки невеличку щілину. Коли одна вівця виходить із загону, я кидаю камінчик у відро, прибите цвяхом до воріт. А надвечір із кожною вівцею, що вертається до кошари, я забираю по камінчику з відра. У відрі немає камінчиків — я не йду на пошуки загубленої вівці. Ідея *блискуча*. Вона докорінно змінить роботу пастуха.

Так мало би бути в теорії. На практиці, перш ніж метод став надійним, довелося суттєво доопрацювати його. Кілька разів я шукав годинами, і пошуки були безплідними. А на ранок не помітив жодної відсталой вівці. Кожного такого разу мені доводилося добряче помізкувати, щоб виявити недоліки своєї відерної системи. А після

безплідних пошуків я згадав, що у тому відрі вже були камінці, коли тільки виводив овець на пасовисько. Як виявилось, погана ідея. Іншого разу, розважаючись, зранку до обіду я намагався влучити камінцями у відро. І після кількох годин пошуків сильно пожалкував про свою забаву. Але, вправляючись у камінчикарстві, я став досить умілим у цьому ремеслі.

Якось після обіду піщаною стежкою, що веде до моїх пасовиськ, простував ошатний чоловік у білих ризах, лавровому вінку, сандалях та ще якомусь діловому вбранні.

— Чим можу допомогти? — питаюся.

Чоловік дістає з-під убрання значок, розгортає його, не лишаючи і тіні сумніву: переді мною Марк Софістичій Максим — представник Румського сенату. (Хтось може поставити питання, чи не вкрав хтось інший той значок і не видає себе за Марка. Запевняю: сила тих значків така велика, що якщо хтось ними і скористається, то негайно *перетвориться* на Марка.)

— Називайте мене Марком. Сенат Руму доручив мені конфіскувати ці магичні камінці — не можна допустити, щоб артефакти такої великої сили потрапили до рук ідіотів.

— Той малий придурок знову навішав локшини селякам, — тільки й чуто буркотіння. Я подивився на суворе обличчя Марка і зітхнув: — Ніякі вони не магичні, — вголос сказав я. — Звичайні собі камінці, які я підібрав з дороги.

На якусь мить обличчям Марка пробігає розгубленість, але потім воно знову прояснюється:

— Тоді мені потрібне магичне відро!

— Та не магичне воно, — втомлено пояснюю. — Я взагалі у ньому брудні шкарпетки зберігав.

Тепер Маркове обличчя виглядає спантеличеним:

— Тоді де ж та магія? — з надією питає посол сенату.

Цікаве питання.

— Складно пояснити, — зітхаю я.

Мій нинішній учень, Атрі, якого приваблює усе незвичне, ходить межи люди і всім розказує: «Це — рівень камінців у відрі. А ще існує

магічний рівень камінців. І щоб воно спрацювало, ви маєте встановити потрібний рівень. Якщо ви закинете або дістанете більше камінців, відро втратить свої магічні властивості. Саме зараз, щоб розворушити магію відра, потрібно заповнити його десь на третину».

— Зрозумів! — захоплено вигукує Марк. Із задньої кишені він дістає власне відерце і купу камінців. А потім зачерпує кілька пригорщ і висипає у своє відро. Опісля Марк дивиться у посудину, на око визначаючи, скільки там тих камінців: — Ось! Магічний рівень — піввідра камінців, — каже Марк. — Правильно?

— Ні! — відрізає Атрі. — Піввідра не магічний рівень. Третина ж. А половина точно не магічна. Та й до того ж у Вас неправильне відро.

До мене повертається спантеличене лице Марка:

— Хіба ти не казав, що відро не магічне?

— Казав, — із загону виходить вівця, і я кидаю камінець у відро. — А взагалі, я маю порати своїх овець. Поговоріть з Атрі.

Марк окинув підозрілим поглядом на камінчик, який я кинув у відро, але вирішив усе ж не надокучати. Тоді посланець обертається до Атрі і гордовито випростовується:

— У нас вільна країна. Під дбайливою опікою диктатури Сенату, звісно ж. Я можу кинути у відро стільки камінців, скільки захочу.

Атрі ненадовго замислюється:

— Ні, не можете, — видає він, — тоді не буде ніякої магії.

— Дивись, — терпляче провадить Марк. — Я уважно спостерігав за тобою. Ти зазирає у відро, перевіряє рівень камінців, а потім встановлював магічний рівень. Я зробив точно так само.

— Це працює не так.

— Ага, тоді це не рівень камінців у *моєму* відрі робить його магічним, а їхній рівень у *твоєму*. Про це ти говориш? Чим відрізняється твоє відро від мого, га?

— Що ж, — задумався Атрі, — якби ми спорожнили Ваше відро і пересипали камінці з мого відра у Ваше, тоді Ваше відро так само набуло б магічних властивостей. Також існує процедура, за допомогою якої ми можемо перевірити, чи Ваше відро наділене магічними

властивостями, якщо ми знаємо, що моє точно наділене. Назвемо її операцією порівняння відер.

Ще одна вівця виходить із загону, і я докидаю один камінець.

— Він щойно кинув ще один камінець! — вигукнув Марк. — І що ти тепер скажеш? Що новий рівень так само магічний? Я міг би накидати у своє відро стільки камінців, скільки у твоєму, щоб у нас було порівну. Ти просто порівнюєш моє відро зі своїм, щоб визначити, чи, як на *тебе*, рівень «магічний» або ні. Що ж, думаю, що це якраз у *твоєму* відрі немає магії, тому що це у тебе рівень камінців недостатній. Ось воно!

— Стривайте, — відгукується Атрі. — Ви не розумієте...

— Під «рівнем магії» ти маєш на увазі рівень камінців у твоєму відрі. А я під цим маю на увазі рівень камінців у моєму відрі. Саме тому ти дивишся на моє відро і кажеш, що це не магія. Просто для кожного це слово — магія — означає щось різне. Маєш уточнити, *чию* магію маєш на увазі. Ти маєш говорити, що у мого відра відсутній «рівень магії Атрі», а я скажу, що твоє відро не має «рівня магії Марка». Ось так і розв'язується ця суперечливість.

— Але ж, — безпорадно відказує Атрі.

— У різних людей можуть бути різні відра з різним рівнем камінців, що говорить про те, що вся ця «магія» примхлива і суб'єктивна.

— Марку, — у розмову втручаюсь я, — чи хтось казав, що *роблять* ці камінці?

— А вони щось *роблять*? — спантеличено відповідає Марк. — Я думав, що вони просто магічні.

— Якби камінці нічого не робили, наш інспектор, який перевіряє ефективність процесів за стандартом ISO 9000, вилучив би цю процедуру з нашої робочої рутини.

— Як звати вашого інспектора?

— Дарвін, — відповідає Атрі.

— Гм, — задумався Марк. — У Чарльза репутація суворого інспектора. То камінці примножують благодать отари, внаслідок чого овець стає більше?

— Ні, — відказую я. — Камінці потрібні ось для чого: коли Ви дивитесь у відро і бачите, що в ньому порожньо, це означає, що на пасовиську не лишилося овець. Якщо не використовуємо відро, доведеться до пізньої ночі шукати тих овець до останньої. А якщо махнете рукою на тих, кого не змогли знайти, наступного ранку знайдете одну мертву вівцю, бо вовки тільки того й чекають, щоб якась вівця лишилася поза кошарою. А якщо у Вас є відерце, Ви завжди знаєте, що всі вівці вдома і можете із чистим сумлінням іти відпочивати.

Марк ненадовго задумується:

— Звучить дещо неправдоподібно, — зрештою видає він. — Ви пробували ворожбитські палички? Вони не підведуть. Принаймні тих, хто казав зворотне, спалили на вогнищі. А горіти на вогнищі — ще та тортура, тому ворожбитські палички *точно* працюють.

— Якщо хочете, можете використовувати їх, — говорю я.

— Святі небеса, та ні за що в житті. Вони працюють бездоганно і безпомилково у кожному випадку, як і належить таким благословеним інструментам. Але що як наступного ранку я знайду мертву вівцю? Я вдаюся до ворожбитських паличок тільки тоді, коли напевне не зможу довести їхню недієвість. Інакше мене б уже спалили живцем. Так як усе ж таки працює твоє магічне відро?

Як працює відро...? Краще почати з найпростішого випадку.

— Що ж, — починаю я, — припустімо, пасовиська порожні, а відро ні. Тоді Ви змарнуєте купу часу на пошуки овець, яких там немає. А якщо всі вівці на пасовиськах, але відро порожнє, тоді ми з Атрі повернемося надто рано, а наступного ранку вівці будуть мертві. Тому порожнє відро магічне, якщо (і тільки якщо) пасовиська також порожні...

— Стривайте, — втручається Атрі. — Мені звучить як беззмістовна тавтологія. Хіба порожнє відро і порожні пасовиська не одне й те саме?

— Зміст є, — відказую я. — Така аналогія: логік Альфред Тарський якось сказав, що твердження «Сніг білий» істинне, якщо і тільки якщо сніг білий. Якщо таке тобі зрозуміти до снаги, то має бути

зрозуміле і те, чому порожнє відро магічне, якщо і тільки якщо на пасовиськах немає овець.

— Стривайте, — втручається тепер Марк. — Ми ж говоримо за *відра*. Який стосунок вони мають до *овець*? Відра і вівці зазвичай взагалі не мають нічого спільного. Де це бачено, щоб вівці взаємодіяли з відром?

— Звідкіль тоді, як на *Вас*, береться та магія? — питає Атрі.

Марк на хвилю задумується:

— Ти казав, що міг би порівняти два відра, щоб перевірити, чи вони на однаковому рівні магії... Як відра взаємодіють з відрами, я можу побачити. Може, коли ви назбираєте велику колекцію відер і всі вони будуть на одному рівні, *тоді* вони набудуть магічних властивостей. Назвемо це когерентистською теорією магічних відер.

— Цікаво, — озвався Атрі. — Я знаю, що мій учитель працює над системою множинних відер. Каже, що через «надмірність» та «виправлення помилок» вона, може, працюватиме краще. Мені схоже на когерентизм.

— Вони не те щоб ідентичні, — починаю я.

— Нумо тестувати когерентистську теорію магії, — каже Атрі. — У Вас на підвір'ї ще п'ять відер. Я передам Вам робоче відро, а Ви наповнюйте інші відра до такого ж рівня...

Марк із жахом відсахнувся:

— Стоп! У моїй родині ці відра передавалися з покоління у покоління. Їхній рівень ніколи не змінювався! Якщо я візьму твоє відро, моя колекція відер втратить частину когерентності, і магія зникне!

— Але ті відра, що у вас *зараз*, ніяк не стосуються овець! — заперечує Атрі.

Обличчя Марка спохмурніло:

— Дивися: я вже пояснював, що вівці, очевидно, у жодному разі не можуть мати ніякого стосунку до відер. Відра можуть взаємодіяти з іншими відрами.

— Щоразу, коли вівця виходить, я кидаю камінець, — зазначаю я.

— Коли вівця виходить, ти кидаєш камінець, — повторює Марк. — І як це стосується справи?

— Так взаємодіють вівці з камінцями, — відповідаю я.

— Та ні, це взаємодія між *тобою* і камінцями, — заперечує Марк. — Магія не у вівцях, магія в *тобі*. Звісно, вони і не можуть бути магічними. Магія ж має *звідкілясь* брати початок на своєму шляху до відра.

Я вказую на дерев'яний механізм, закріплений на воротах:

— Бачите клапоть тканини, що звисає з цієї дерев'яної конструкції? Маємо ще мороку із нею — працює не так добре, як хотілося б, — але коли вівці ходять тут, вони зачіпають ту тканину. Коли тканину відсувають убік, з резервуара випадає камінчик і падає у відро. Тому ні я, ні Атрі не маємо кидати камінці власноруч.

Марк насупив брови:

— Не розумію... *Тканина* магічна?

Знизую плечима.

— Я замовив її в інтернет-магазині «Природні набори». Матеріал називається «Сенсорна модальність», — бачачи недовіру на обличчях Атрі і Марка, замовкаю. — Визнаю: від назв відгонить трохи нью-ейджем.² Суть у тому, що вівця, яка проходить через ворота, запускає ланцюжок причиново-наслідкових подій, внаслідок яких камінець опиняється у відрі. *Зрештою*, можете порівняти це відро з іншими.

— Все одно не розумію, — відповідає Марк. — Як у тебе вівця може поміститися у відрі? У відра потрапляють тільки камінці. Очевидно ж, що камінці можуть взаємодіяти тільки з іншими камінцями.

— Вівці взаємодіють з речами, які взаємодіють з камінцями... — мій мозок підшукує вдалу аналогію. — Припустімо, Ви дивитесь на свої шнурівки. Сонце випромінює фотон, який потрапляє в атмосферу Землі і відбивається від Ваших шнурівок. Тоді він досягає Ваших зіниць, потрапляє у сітківку ока, а потім вловлюється паличками і колбочками. Енергія фотона спричиняє збудження відповідного нейрона, після якого активується сусідній. Ланцюжок активації нейронів у Вашій зоровій корі може взаємодіяти з Вашими уявленнями про

2. Рух у західній культурі, що характеризується змішанням різномірних традицій. — Прим. пер.

шнурівки, оскільки ці уявлення мешкають у нервовому субстраті. Якщо Вам до снаги зрозуміти це, маєте також зрозуміти, як вівця, яка проходить через ворота, спричиняє падіння камінчика у відро.

— На якому *саме* етапі цього процесу камінець набуває магічних властивостей? — питає Марк.

— На... еммм... — тепер потроху з пантелику збиваюся я. Я стріпнув головою, прочищаючи думки. Ще зранку усе здавалося вкрай простим, але з цією розмовою камінчико-відерна система обросла стількома ускладненнями. — Якщо Ви пам'ятатимете, що *призначення* цієї системи — вести облік овець, то це набагато простіше, ніж здається.

Марк скрушно зітхає:

— Не зважай... Очевидно, що ти не знаєш. Може, камінці магічні ще навіть до того, як потрапляють у відро. Можемо назвати цю позицію панкамінчикізмом.

— Ага! — У голосі Атрі звучало презирство. — Та Ви просто приймаєте бажане за дійсне! Не всі камінці створені однаковими. Камінці у *Вашому* відрі *не* мають *ніяких* магічних властивостей. Вони ж лише шматки каменю!

Маркове обличчя суворішає:

— А тепер, — зривається на крик, — тепер ти бачиш небезпеку тієї дороги, якою йдеш! Щойно ти скажеш, що чийсь камінці магічні, а чийсь ні, твоя погórда зжере тебе! Твоя зверхність до інших погубить тебе! Скільки разів уже такого було в історії, що хтось катував і вбивав через те, що вважав, що його камінці найважливіші! У голосі Марка тепер відчувуються нотки поблажливості: — Поклонятися рівню камінців як «магічному» означає, що є якийсь абсолютний рівень камінців у Всевишньому Відрі. У наш час ніхто вже не вірить у Всевишнє Відро.

— По-перше, — починаю я, — вівці не абсолютні камінці. По-друге, я не думаю, що у моєму відрі містяться фізичні вівці. По-третє, я не поклоняюся ніякому рівню відра як досконалому (іноді даю йому лад), але я це роблю, *бо* мені не байдужі мої вівці.

— Крім того, — провадить Атрі, — той, хто вважає, що якщо у його розпорядженні абсолютні камінці, то він *має* право на катування і вбивства, припускається помилки, що ніяк не стосується відер. Ви намагаєтеся розв'язати не ту проблему.

Марк утихомирюється:

— Мабуть, більшого годі чекати від посполитих пастушків. Ви, либонь, і в те, що сніг білий, вірите, так?

— Ем... так? — відповідає Атрі.

— А вас не хвилює те, що *Йосип Сталін* вірив у те, що сніг білий?

— Ем... ні? — відказує Атрі.

Марк обдарував Атрі поглядом, повним скепсису, і врешті-решт низив плечима:

— Лишень заради суперечки припустімо, що ваші камінці магічні, а мої ні. Що тоді їх відрізняє, можете мені сказати?

— Мої камінці *відображають* овець! — звияжно мовить Атрі. — *Ваші* камінці не мають властивості відображуваності, тому і не працюють. У них не закладено ніякого смислу. Тільки подивіться на них. Ні сліду семантичної наповненості — звичайнісінькі камінці. Вам потрібне відро з особливими причиновими силами.

— Он воно що! — вигукує Марк. — Замість магії особливі причинові сили.

— Саме так! — підтверджує Атрі. — І це ніякі не забобони. У нашу Добу для міжнародного товариства пастухів брати магію на віру неприйнятно. Ми з'ясували, що якщо обґрунтовувати все магією, то для наших пастушачих явищ вона не матиме пояснювальної сили. Тому якщо я бачу щось таке, чого не розумію, і хочу пояснити це за допомогою моделі без внутрішніх деталей, які б допомагали мені робити передбачення заднім числом, я беру на віру особливі причинові сили. Або ще кажу на них «емерджентні явища» чи ще якось.

— Якими такими особливими силами володіє відро? — питає Марк.

— Гм, — задумується Атрі. — Можливо, це відро наділене відношенням *спрямованості* на пасовиська. Тоді б це пояснило принцип роботи відра: коли воно порожнє, пасовище так само порожнє.

— Де ти знайшов це відро? — запитав Марк. — І як ти дійшов до цього відношення спрямованості на пасовиська?

— Це *звичайнісіньке відро*, — кажу я. — Колись я лазив із ним по деревах... Думаю, ця проблема *не має* завести у сліпий кут.

— Я розмовляю з Атрі, — відрізав Марк.

— Ви маєте поєднати відро з пасовиськами, а камінці — з вівцями магічним ритуалом... Даруйте, емерджентним процесом з особливими причиновими силами, які відкрив мій учитель, — пояснив Атрі.

Тоді як Атрі намагається описати ритуал, Марк киває головою із повним розумінням.

— Тобто потрібно кидати камінець *щоразу*, коли вівця виходить через ворота? — уточнює Марк. — І діставати його *кожного* разу, коли вона повертається?

Атрі киває:

— Ага.

— А це не так просто, — зауважує Марк.

Обличчя Атрі осяяла посмішка — Маркове розуміння тішить його, мов теплий дощ:

— Саме так! Емоційно це *надзвичайно* важко дається. Коли відро деякий час залишається на одному рівні, ви, знаєте... прив'язуєтесь до того рівня.

Тоді вівця виходить через ворота. Помітивши це, Атрі нахилиється, бере камінець, тримає його над відром, і...

— Узріть це диво! — урочисто виголошує Атрі. — Вівця пройшла! Шановне відерце, тепер я мушу кинути камінець у тебе, щоб зруйнувати той затишний рівень, який тримався так довго... — проходить ще одна вівця. Атрі, поглинутий своєю драмою, не помічає її, тому я хутко кидаю камінь у відро. Атрі продовжує: — ... адже найбільше випробування пастуха — кинути камінець, хай навіть воно сповнене тяжких митарств і хай би яким цінним був той попередній рівень. Воістину, тільки найкращий з пастухів може дотриматися вимоги настільки суворої...

— Атрі, — перебиваю я, — якщо ти одного дня хочеш стати вправним пастухом, повчися стуляти писок і кидати бісів камінець, коли

твоя ласка. Без метушні. Без драми. Просто роби діло.

— А цей ритуал, — продовжує Марк. — Він поєднує камінці з вівцями магічними законами Подібності та Контакту за принципом ляльки вуду.

Атрі здригнувся й озирнувся:

— Прошу: ніяких магічних законів. Ми, пастухи, не забобонні простаки. Краще казати «інтенціональність» або щось на кшталт того.

— Дасте поглянути на камінчик? — питає Марк.

— Звісно, — відповідаю я. Дістаю один з відра і кидаю Маркові. Тоді я нахиляюся, підбираю ще один і кидаю у відро.

Атрі кидає спантеличений погляд:

— Ви щойно все зіпсували.

Знижую плечима:

— Не думаю. От якщо наступного ранку ми знайдемо мертву вівцю або вб'ємо кілька годин на пошуки якоїсь вівці і не знайдемо її, тоді й дізнаємося, чи зіпсував.

— Але ж, — почав Атрі.

— Я навчив *тебе* усього, що знаєш ти, але не усього, що знаю я.

Марк уважно розглядає камінець, обдивляючись кожну щілинку. Тримавши руку над камінцем, він тихцем промовляє кілька слів, а потім струшує головою:

— Я не відчуваю ніякої магії. Даруйте. Не відчуваю ніякої інтенціональності.

— Камінець володіє властивістю інтенціональності, якщо він знаходиться всередині магіч... емерджентного відра, — пояснює Атрі. — Інакше це звичайний камінець.

— Не проблема, — кажу я. Дістаю камінець з відра і викидаю його. Тоді я підходжу до Марка, торкаюся його руки, що тримає камінець, і кажу: — Оголошую цю руку частиною магічного відра! І повертаюся на своє робоче місце біля воріт.

Атрі сміється.

— А зараз Ви дражнитесь.

Киваю, бо це справді так.

— Але чи справді так воно і є? — питає Атрі.

Киваю знову, сподіваючись, що мої думки слухні. Я вже робив щось подібне з двома відрами, і, в принципі, різниці між Марковою рукою і відром бути не повинно. Навіть якщо Маркова рука пронизана якоюсь *життєвою силою*, якою нежива матерія відрізняється від живої, такий трюк має спрацювати, навіть якби Марк був статуєю із мармуру.

Марк дивиться на свою руку із легким занепокоєнням:

— І... камінець знову має властивість інтенціональності?

— Ага, — кажу я. — Не бери більше ніяких камінців і не викидай оцей, інакше порушиш ритуал.

Марк шанобливо киває. І повертається оглядати камінець:

— Тепер я розумію, як твої вівці вирости такими великими, — зауважує Марк. — Завдяки силі цього відра ти міг би і далі жбурляти ті камінці, а вівці все поверталися і поверталися б з полів. Ти міг би спочатку завести кількох овець, випустити їх пастися, а перш ніж вони повернуться, наповнити відро вщерть. А якщо порати таку кількість овець тобі стало б не до снаги, можна ж тоді просто відпустити їх усіх, спорожнити відро, щоб повернулися лише кілька... А потім, коли прийде час стрижки, можна знову збільшити їх кількість у кошарі... Боже правий, чоловіче! Ти усвідомлюєш, яку *силу* ти відкрив цим ритуалом? Можу тільки уявити наслідки цього відкриття. Людство може зробити поступ на ціле десятиліття — ба навіть століття!

— Це не так працює, — відказую я. — Кинете камінець, коли вівця ще не вийшла, чи приберете камінець, коли вівця ще не увійшла, — порушите ритуал. Камінці не накопичують силу — вона зникає миттєво.

На Марковому обличчі читалося страшенне розчарування:

— Ти певен?

Киваю:

— Пробирав — не вийшло.

Марк тяжко зітхає:

— Аж дотепер ця... *математика*... Видавалася такою могутньою і корисною... Йой, гаразд. Ось тобі й поступ людства.

— Марку, та *геніальна* ж ідея була, — захопливо відказує Атрі. — Мене така думка і не відвідувала, а вона така очевидна... *Скільки* б зусиль вона зберегла... Неодмінно *мусить* бути спосіб врятувати Ваш план! Ми могли б спробувати різні відра, шукаючи те саме, яке зберігатиме силу маг... інтенціональність у камінцях навіть без того ритуалу. Або спробуємо інші камінці. Може, у наших камінцях просто хибні властивості, тому у них і бракує *засадничої* інтенціональності. А що як ми використовуватимемо камінці у вигляді овець? Або ж просто напишемо «вівця» на камінці — може, цього буде досить.

— Не вийде, — коротко підсумовую я.

Атрі не вгаває:

— Може, нам потрібні органічні камінці, а не штучні... або із коштовних каменів. Кожні вісімнадцять місяців ціна коштовного каміння зростає вдвічі, тому можна зараз купити пригорщу дешевих коштовних камінців, а через двадцять років їхня цінність зросте ще вище.

— Ти ж пробував докинути камінці, щоб овець стало більше? І що? Вийшло? — питає мене Марк. — Що саме ти робив?

— Узяв стос доларових купюр. Потім я по черзі ховав ті купюри під згином своєї ковдри; щоразу, коли я ховав чергову купюру, я брав із коробки по скріпці і складав їх у купку. Я старався не вести облік у голові, тому все, що я знав, — було «багато» купюр і «багато» скріпок. Коли ж усі купюри були під моєю ковдрою, я додав ще одну скріпку до купки — все одно що кинув додатковий камінець у відро. Опісля почав діставати купюри з ковдри, складаючи скріпки назад до коробочки. А коли закінчив, лишалася одна-єдина скріпка.

— І що з цього впливає? — спитав Атрі.

— Впливає, що таке штукárство не працює. Щойно я цією єдиною хибною дією порушив ритуал, сила зникла миттєво. Ні купка скріпок, ні доларові купюри більше не спорожнювалися водночас.

— Ти *справді* таке робив? — запитав Марк.

— Так, я справді провів експеримент, щоб перевірити, чи збігається результат із моїм теоретичним передбаченням. У мене особлива

пристрасть до наукового методу, навіть коли його застосування видається абсурдним. Зрештою, а що, якби я помилявся?

— А якби таке *спрацювало*, — каже Марк, — тебе звинуватили б у підробці грошей! Уяви, якби всі на таке були спроможні. Економіка обвалилася б! В усіх на руках мільярди доларів готівки, і за ці гроші нічого не можна купити!

— Не зовсім, — відповів я. — За тією ж логікою, за якою докладання ще однієї скріпки до купки спричинить появу ще однієї купюри, що, своєю чергою, створить додаткову кількість товарів вартістю цієї купюри.

Марк струснув головою.

— Підробка грошей — злочин... Ти не маєш навіть пробувати.

— Я був *цілком* певен, що зазнаю невдачі.

— Ага! — вигукнув Марк. — Ти *очікував*, що не вдасться! Ти не *віриш*, що зможеш!

— Саме так, — визнав я. — Ти вгадав мої очікування з разючою точністю.

— Угу, в цьому ж і проблема, — тут же відповів Марк. — Магія живиться вірою і силою волі. Якщо ти не віриш, що тобі вдасться, нічого не вийде. Ти маєш змінити своє припущення стосовно результату експерименту, і, як наслідок, зміниться сам результат.

— Кумедно, — кажу з ностальгією, — те саме мені казав Атрі, коли я розказував йому про камінчиково-відерний метод. Йому він здавався надто сміховинним, тому метод і не працював для нього.

— І як ти переконав його? — запитав Марк.

— Сказав стулити писок і робити те, що кажуть, а потім, коли метод почав працювати, Атрі почав вірити у нього, — поділився я.

Марк спантеличено насупив брови:

— Якесь безглуздя. Це ж не розв'язує основної дилеми про курку і яйце.

— Звісно, розв'язує. Відерний метод працює незалежно від твоєї віри у нього.

— Якийсь *абсурд*! — пирхнув Марк. — Я не вірю у магію, яка працює незалежно від того, у що я вірю!

— І я так казав! — чітко виголосив Атрі. — Схоже, я помилявся.

Намагаючись зосередитись, Марк кривить обличчя:

— Але... якщо ти не вірив у магію, що працює незалежно від твоєї віри, тоді чому відерний метод спрацював, коли ти не вірив у нього? Ти віриш у магію, що працює незалежно від того, віриш ти в неї чи ні, незалежно від того, віриш ти в магію, яка працює незалежно від того, віриш ти в неї чи ні?

— Я... так... не *думаю*, — із часткою сумніву відповів Атрі.

— Тоді якщо ти не вірив у магію, яка працює незалежно від віри у неї... стривай, мені потрібен олівець і папір, щоб розписати це... — Марк знято щось креслить, скептично оглядає те, що вийшло, перевертає покреслений аркуш догори дригом, а потім викидає його. — Ну і хай йому, — підсумовує Марк. — Магія надто складна для мого мозку, а метамагія і поготів.

— Марку, не думаю, що ти розумієш мистецтво відерного ремесла, — кажу я. — Йдеться не про те, щоб за допомогою камінців контролювати овець. Йдеться про те, щоб контролювати камінці за допомогою овець. У це мистецтво зовсім не обов'язково вірити, щоб почати його застосовувати. Тобто спочатку мистецтво працює, а потім учень починає вірити, що воно працює.

— Або ж так віриш ти, — сказав Марк.

— Вірю, — відповідаю я, — *бо* такою виявилась реальність. Відповідність між дійсністю і моїми переконаннями бере початок з дійсності, що контролює мої переконання, а не навпаки.

Проходить ще одна вівця, внаслідок чого я кидаю ще один камінчик.

— Ага! Тепер ми підходимо до кореня проблеми, — говорить Марк. — А що воно взагалі таке — та реальність? Я розумію, що для гіпотези означає бути елегантною, спростовною або узгоджуваною із свідченнями. Мені здається, що називати переконання «істинними» чи «реальними» — це те, що відрізняє твердження про щось, у що віриш, від твердження про щось, у що дійсно віриш.

Зробив павзу.

— Що ж... — починаю я обережно. Чесно, я й сам не до кінця певен, звідки бере початок та реальність. У лабораторних умовах я не зможу відтворити її, тому, скоріше за все, я не розумію, що таке реальність. Але часом я свято вірю у те, що щось ось-ось станеться, а натомисть стається щось інше. Мені потрібен іменник, який називатиме оце щось, що визначатиме результати мого експерименту, тому я називаю це «реальністю». І чомусь оця «реальність» стоїть осторонь навіть від моїх найкращих гіпотез. Навіть коли у мене є проста гіпотеза, надійно підкріплена усіма відомими мені свідченнями, іноді реальності вдається мене здивувати. Тому мені потрібні іменники для тих штук, які визначають мої передбачення, і тієї штуки, яка визначає результати експерименту. Перше я називаю «переконанням»,³ друге — «реальністю».

Марк пирхнув.

— Навіть не знаю, чому я досі слухаю цю очевидну нісенітницю. Що б ти не казав про цю так звану реальність, це просто ще одне переконання. Навіть твоє переконання, що реальність стоїть вище твоїх переконань, — чергове переконання. Отже, логіка неухильно веде нас до того, що ніякої реальності не існує — тільки переконання.

— Стривайте, — втручається Атрі. — Чи не могли б Ви повторити останню частину? На цьому різкому повороті посередині я загубився.

— Що б ти не казав про реальність, це просто ще одне переконання, — пояснив Марк. — Отже, ми маємо негайно визнати, що є тільки переконання — ніякої реальності.

— Ага, — кажу я. Так само, хай би що ти їв, ти пережовуєш цю їжу ротом. Отже, не існує ніякої їжі — тільки рот.

— Аякже! — вигукує Марк. — Усе, що ми їмо, має бути у роті. Як їжа взагалі може існувати поза ротом? Ця думка безглузда, що підтверджує: «їжа» — суперечливе поняття. Саме тому ми всі померемо від голоду — адже немає ж ніякої їжі.

Атрі намагається проаналізувати свої відчуття у шлунку:

— Але я не помираю від голоду.

3. У цій серії леми «переконання», «уявлення», «віра» взаємозамінні. — Прим. пер.

— *Ага!* — переможено вигукує Марк. — А як тобі вдалося вимовити це заперечення? *Ротом*, мій друже! *Ротом!* Що може краще унаочнити, що ніякої їжі не існує!

— *А як щодо твого голодування?* — вигукує суворий, хриплий голос позаду.

Ми з Атрі стоїмо непорушні, вже мавши нагоду пройти через усе це. Перелякавшись мало не до втрати свідомості, Марк аж підстрибнув.

На обличчі інспектора Дарвіна рясніла широка усмішка — він тішився тим, що зміг заскочити когось зненацька. Ставить невелику позначку у своєму записнику.

— Просто метафора! — хутко говорить Марк. — Забирати у мене рот чи щось іще Вам ні до чого...

— Так а *навіщо* тобі *рот*, якщо немає ніякої *їжі*? — грізно вигукує Дарвін. — *А хоча забудь*. На такі *дурниці* в мене катма *часу*. Я прийшов, щоб оглянути *овець*.

— Отара росте, сер, — кажу я. — Востаннє вівця помирала у січні.

— *Неймовірно*. Тоді присуджую вам 0,12 бала з *приспособованості*. А що тут робить цей *чолов'яга*? Він необхідна частина цього *проєкту*?

— Гадаю, він був би кориснішим людству, якби його прив'язали до повітряної кулі, як баласт, — відзначив я.

— Ух, — тихо вимовив Атрі.

— Людство мені *ні до чого*. Нехай говорить *сам за себе*.

Марк гордовито випростався.

— Цей посполитий *пастух*, — вказує на мене, — стверджує, що реальність існує. І цим твердженням він ображає мене, оскільки з усією своєю непохитною і глибокою вірою я знаю, що ніякої реальності не існує. Адже саме поняття «істина» — чергова хитрість, до якої вдаються, щоб нав'язати свої переконання іншим. Кожна культура має свою інакшу «істину», і жодна «істина» якоїсь культури не може переважати над іншою. Щойно сказане мною завжди і скрізь лишається актуальним. Наполягаю, щоб і ви визнали це.

— Стривайте-но, — каже Атрі. — Якщо нічого не істинне, то чому я маю вірити Вашим словам про те, що нічого не істинне?

— Я не казав, що нічого не істинне, — каже Марк.

— Ні, казали, — заперечує Атрі. — На власні вуха чув.

— Я сказав, що «істина» — це привід, яким користаються деякі культури, щоб нав'язати свої переконання іншим. Тому коли ви кажете, що щось «істинне», ви маєте на увазі, що так буде вигідно вашій соціальній групі, якщо у це повірять.

— І це те, що Ви сказали, — втручаюся я, — це ж правда?

— Безсумнівна й остаточна правда! — погодився Марк. — Люди створюють свої власні реальності.

— Зачекайте, — втручається Атрі, у голосі якого уже звучить збентеження, — з точки зору логіки, говорити, що люди створюють свої реальності, — це вже інше, ніж говорити, що немає ніякої істини. Я навіть не можу цілісно уявити собі такий стан справ, може, тому що ти досі не пояснив, як саме ці два твердження мають узгоджуватися...

— Знов за рибу гроші, — дратується Марк. — Знову намагаєтесь прикласти свої західні поняття логіки, раціональності, розуму, узгодженості і послідовності.

— Чудово, — бурчить Атрі, — тепер мені доведеться додати ще й *третьої* тематичну рубрику, щоб відстежувати ще й це геть окреме твердження...

— Воно не окреме, — заперечує Марк. — Дивись: ти неправильно ставишся до моїх тверджень, сприймаючи їх як гіпотези і ретельно виводячи з них наслідки. Тобі варто думати про них як про суто загальні виправдання, до яких я вдаюся, коли хтось каже щось таке, що мені не до вподоби. Вони не стільки модель того, як працює всесвіт, скільки козир, який дозволяє вийти сухим із води. Головне — застосовувати це виправдання *вибірково*. Коли я кажу, що немає ніякої істини, воно стосується тільки *твого* твердження, що магічне відро працює, хай у що я вірю. Воно *не* стосується *мого* твердження, що ніякої істини немає.

— Еммм... чому ні? — питає Атрі.

Марк терпляче зітхає.

— Атрі, думаєш, ти перша людина, яка задумується над цим питанням? Питанням, чому наші переконання можуть мати сенс, у той час

як усі переконання безглузді. Те саме говорять студенти, коли вони стикаються з цією філософією, у якої, щоб ви знали, купа прихильників і про неї написано гори літератури.

— Тож яка відповідь? — питає Атрі.

— Ми назвали це проблемою рефлексивності, — пояснив Марк.

— То яка, в дідька, *відповідь*? — не вгаває Атрі.

На обличчя Марка напливає зневажливий усміх:

— Повір мені, Атрі: ти не перша людина, яка задумується над таким простим питанням. Не варто подавати це як тріумфальне спростування.

— Яка ж тоді *кінцева відповідь*?

— А тепер я хочу з'їхати до проблеми того, як логіка вбиває милих тюленят...

— Ти *гайнуєш час*, — відрізав інспектор Дарвін.

— І овець треба рахувати, — кидаю я камінець.

Інспектор Дарвін окидає поглядом двох сперечальників, які не схожі на тих, хто так просто відступлять від своїх позицій.

— Слухайте, — цього разу вже поблажливіше каже Дарвін, — у мене є ідея, як можна легко розставити крапки над «і» у вашій суперечці. *Ти* кажеш, — провадить Дарвін, вказуючи на Марка, — що переконання людей змінюють їхні особисті реальності. А *ти* невідступно віриш, — вказує пальцем на Атрі, — що Маркові переконання *не можуть* змінити реальності. Тому нехай Марк, кров з носа, повірить у те, що він уміє літати, а потім зійде зі скелі. Марк побачить, як він літає пташкою, Атрі ж побачить, як він полетить вниз і розіб'ється. І всі будуть задоволені.

Усі ненадовго задумуються.

— *Звучить* розумно... — врешті-решт видає Марк.

— Та от неподалік і скеля є, — зазначає інспектор Дарвін.

Обличчя Атрі набуло рис глибокої зосередженості. Врешті-решт він скрикує:

— Стійте! Якби це було правдою, ми всі давно уже розійшлися б по своїх власних усесвітах, де інші люди — лише плоди вашої уяви. І намагатися нам щось довести — справа не варта зусиль...

З найближчої скелі вже лунає протяжний крик. Поволі стихаючи, галас обірвався глухим гепанням. Інспектор Дарвін перегортає свій записник до тієї сторінки, на якій відображається поточний генотип, і робить примітку олівцем про трохи нижчу частоту Маркових алелів.

Атрі трохи зле:

— Це було аж так необхідно?

— *Необхідно?* — спантеличено повторює інспектор Дарвін. — Так уже *сталося*... Не певен, чи розумію твоє питання.

Ми з Атрі повернулись до свого відра. Саме час заводити овець до кошари. Навряд чи вам захочеться забути ту історію з вівцями. Інакше який тоді узагалі сенс?



Кінець першої книги