

**Як по-справжньому
змінювати думку**

Rationality: from AI to Zombies — Eliezer Yudkowsky

Вперше опубліковано як записи у блогах Overcoming Bias та Less Wrong, з 2006-го по 2009-й рік.

Цей переклад — фанатський проєкт, що створюється з 2023-го року, з люб'язного дозволу авторів. Не для продажу. Не для комерційного використання. Всі права на оригінальний твір належать Елієзеру Юдковські



Від перекладача — Данила Жирка

Красно дякую друзям зі спільноти pre post, які терпляче і вичерпно роз'яснювали складні моменти у книзі щоразу, коли я цього потребував.

Завдяки вам у перекладі куди менше помилок.



Від дизайнера — Дениса Лук'яненка

Долучитися до перекладу, вказати на помилку або просто подивитись, як все влаштовано можна на GitHub:

DanTheStrongworded/rationality-ua-public¹



Зверстано у Сторінкаторі 1.0.0 — denlukia/storinkator²

Гарнітури: EB Garamond, Geologica.



1. <https://github.com/DanTheStrongworded/rationality-ua-public>

2. <https://github.com/denlukia/storinkator>

Версія перекладу 2.0 · 3 травня 2026

Зміст

9	Рациональність. Вступ від Роба Бенсінгера
18	Ретельно підібрані заспокійливі виправдання
19	Цуйоку Нарітай! (Я хочу стати сильнішим!)
22	Належна скромність
27	Цуйоку проти егалітарного інстинкту
29	Третя альтернатива
32	Лотереї: примарна надія
34	Нова покращена лотерея
37	Але ж усе-таки шанс є, так?
40	Омана сірого
45	Безумовний авторитет
52	Як переконати мене у тому, що $2 + 2 = 3$
55	Довічна певність
60	0 та 1 не належать до ймовірностей
65	Та не однаково мені, чи будете ви раціональними
68	Політика та раціональність
69	Політика — губитель розуму
71	Небезпека односторонніх політичних дебатів
75	Терези Феміди, Записник Рациональності
78	Фундаментальна помилка атрибуції
82	Чи дійсно ваші вороги лихі від природи?
85	Обернена дурість не породжує тямучість
89	Аргумент усуває залежність від авторитету
95	Тримайтеся свого питання
97	Рациональність та англійська мова
101	Людське зло і каламутне мислення
105	У боротьбі з раціоналізацією

- 106 Як знання про біаси може нашкодити
109 Оновлюйте переконання — крок за кроком
113 Один аргумент проти армії
116 Нижній рядок
120 Які засвідчення рахуються за відфільтровані
124 Раціоналізація
127 Раціональний аргумент
130 Витурить справжні вразливості з переконання
135 Заангажована зупинка та заангажоване продовження
138 Вигадане обґрунтування
141 Причина відмови справді у цьому?
145 Сплутана істина і заразна брехня
149 Про брехню та чорних лебедів
150 Темна сторона епістемології
- 155 У боротьбі з дводумством**
156 Дводумство, або Вибір на користь упередженості
161 Серйозно: я дурила себе
163 Віра в самообман
168 Парадокс Мұра
171 Досі вірите, що зможете удавано самообманюватися?
- 174 Свіжим поглядом**
175 Якорування і коригування
177 Праймінг та інформаційне забруднення
180 Чи завжди ми віримо сказаному?
183 Закешовані думки
187 Свіжий погляд
190 Чеснота звуження погляду
194 Дивніше історії
196 Логічна хиба узагальнення на основі вигаданих засвідчень
203 Ми змінюємо свою думку рідше, ніж здається
205 Не поспішайте з рішеннями

- 208 Омана походження
- 211 Смертельні спіралі**
- 212 Евристика афекту
- 216 Оціненність (та дешеві покупки на свята)
- 221 Безперервна шкала, чималі штрафи від присяжних та дослідження майбутнього
- 225 Ефект ореолу
- 229 Гаданий супергероїзм
- 233 Смертельні спіралі радості
- 235 Опір смертельній спіралі щастя
- 241 Некритична надкритичність
- 246 Випарне охолодження і групові переконання
- 250 Коли ніхто не зважується закликати до стриманості
- 253 Кожна справа тяжіє до сектантства
- 256 Два коани про секти
- 259 Експеримент Аша
- 263 Проговорити занепокоєння
- 266 Самотній інакодумець
- 271 Сектантське сектоборство
- 280 Відпускання**
- 281 Цілодумство
- 283 Йойкати — важливо
- 286 Спокуса пришелепкуватістю
- 289 Саме час здаватися
- 291 Належний сумнів
- 294 Вам до снаги витримати дійсність
- 295 Медитація на допитливість
- 299 Перед законами раціональності усі рівні
- 302 Залиште шляхи відходу
- 306 Криза віри
- 315 Ритуал

Раціональність. Вступ від Роба Бенсінгера

Восени 1951 року футбольний матч між студентами Дартмутського коледжу та Принстонського університету виявився особливо грубим. Двоє психологів — Альберт Хейсторф з Дартмута і Хедлі Кантріл із Принстона — узялися розпитувати студентів обох вишів, з котрої команди розпочалися порушення правил гри. Майже кожен опитуваний погодився, що принстонці не були ініціаторами порушень, але 86% принстонців вважали, що правила почала порушувати команда Дартмута, причому лише 36% дартмутців звинувачували свою команду. (І більшість дартмутців вважала, що «і ті, і ті почали порушувати правила».)

Коли студентам пізніше показали запис гри й попросили підрахувати спостережені порушення, дартмутці заявили, що побачили у середньому 4,3 порушення, скоєних командою Дартмута (з них половину оцінили як «легкі»), а принстонці заявили, що побачили у середньому 9,8 порушення, скоєних командою Дартмута (і третину з них оцінили як «легкі»)¹.

Коли щось цінне для нас під загрозою — світогляд, статус у групі, репутація або щось, до чого ми небайдужі, — наші думки та сприйняття стають гуртом на їхній захист.^{2 3} Деякі психологи припускають навіть, що люди навчилися витворювати явні

1. Albert Hastorf and Hadley Cantril, "They Saw a Game: A Case Study," *Journal of Abnormal and Social Psychology* 49 (1954): 129–134.

2. Emily Pronin, "How We See Ourselves and How We See Others," *Science* 320 (2008): 1177–1180.

3. Robert P. Vallone, Lee Ross, and Mark R. Lepper, "The Hostile Media Phenomenon: Biased Perception and Perceptions of Media Bias in Coverage of the Beirut Massacre," *Journal of Personality and Social Psychology* 49 (1985): 577–585, <https://ssc.wisc.edu/~jpiliavi/965/hwang.pdf>.

виправдання для своїх висновків *суто* для того, щоб перемагати у суперечках.⁴

Одне з найбільших відкриттів психології XX століття полягає у тому, що у своїй поведінці людина часто керується складними неусвідомленими процесами, а історії, якими ми пояснюємо свої мотиви і приводи, більш упереджені і висмоктані з пальця, ніж усвідомлюємо. Часто направду і не задумуємося, коли починаємо витворювати історію. Коли ми, як нам здається, «безпосередньо сприймаємо» щось про самих себе поглядом всередину, часто виявляється, що ці уявлення ґрунтуються на безпідставних причинових моделях.^{5 6} Коли ми силкуємося захистити свої переконання, не так і складно збитися на манівці зрадливих міркувань, які ніяк не стосуються того, як ми вперше прийшли до цих переконань.⁷ Але замість того, щоб довіряти поясненням відповідно до їхньої прогностичної сили, ми схильні довіряти *історіям* відповідно до їх впливу на психіку.

Чи можна це якось змінити? Як можна прийти до реалістичного бачення світу, якщо ми настільки піддатливі до раціоналізації? Як можна прийти до реалістичного бачення того, що коїться у нас у голові, якщо наші думки *про* мислення також підпадають під підозру?

Що ж це за *найменш* хитка опора, на яку ми могли б спертися?

4. Hugo Mercier and Dan Sperber, “Why Do Humans Reason? Arguments for an Argumentative Theory,” *Behavioral and Brain Sciences* 34 (2011): 57–74, <https://hal.archives-ouvertes.fr/file/index/docid/904097/filename/MercierSperberWhydohumansreason.pdf>.

5. Richard E. Nisbett and Timothy D. Wilson, “Telling More than We Can Know: Verbal Reports on Mental Processes,” *Psychological Review* 84 (1977): 231–259, <https://people.virginia.edu/~tdw/nisbett&wilson.pdf> (<https://goo.gl/3HcEgh>).

6. Eric Schwitzgebel, *Perplexities of Consciousness* (MIT Press, 2011).

7. Jonathan Haidt, “The Emotional Dog and Its Rational Tail: A Social Intuitionist Approach to Moral Judgment,” *Psychological Review* 108, no. 4 (2001): 814–834, doi:10.1037/0033-295X.108.4.814 (<https://dx.doi.org/10.1037/0033-295X.108.4.814>).

Математика раціональності

На рубежі XX століття завдяки виведенню простих (наприклад, теоретико-множинних) аксіом математики отримали чіткіший орієнтир, за яким можна оцінювати правильність висновків. Якщо людина або калькулятор видає « $2 + 2 = 4$ », ми можемо не просто сказати, що «інтуїтивно це здається правильним». Ми можемо пояснити, *чому* це правильно, і довести, що ця правильність систематично пов'язана з правильністю решти арифметичних операцій.

Однак за допомогою математики ми можемо моделювати поведінку фізичних систем, що набагато цікавіші за кишеньковий калькулятор. Так само за допомогою теорії ймовірностей можна формалізувати *раціональне переконання загалом*, щоб виокремити спільні риси усіх вдалих форм умовиводів. І навіть *раціональну поведінку як таку*, якщо спиратися на теорію рішень.

Теорія ймовірностей визначає, як ми теоретично мали б мислити в умовах невизначеності за наявності необхідного часу, обчислювальних потужностей і психічного контролю. Маючи певні базові знання (*priori*) і нове свідчення, за допомогою теорії ймовірностей я можу недвозначно і точно визначити (і прийняти) найкращу множину нових переконань (*aposteriori*). Так само теорія рішень допомагає мені з'ясувати, яке рішення я маю ухвалити з огляду на мої переконання. На кожну узгоджену множину переконань та вподобань існує відповідь з теорії рішень про те, як я маю поводитися, щоб задовольнити свої вподобання.

Уявімо, що на вас запов один із шести однокласників — можливо, ви отримали лист від таємного прихильника і певні, що це один із тих шести, — але поняття не маєте, хто саме міг би бути тим прихильником. Як виявилось, Боб — один із тих шести. Якщо у вас немає особливих причин гадати, що

кандидатура Боба більш чи менш ймовірна порівняно з іншими п'ятьма кандидатами, які тоді шанси, що Боб і є тим самим?

Відповідь: 1:5. Існує шість варіантів, тому вибрати наздогад — у середньому п'ять разів помилитися на один раз вгадати.

Уже не можна сказати: «Що ж, я дуля не відбиваю, хто за-
пав на мене. Може, Боб, а може, хтось інший. Нехай буде п'ятдеся-
т на п'ятдесят». Навіть якщо сказати «Я не знаю» або
«Може» і зупинитися на цьому, правильною відповіддю лишає-
ться 1:5. З цього припущення випливає, що у вас є шість варіан-
тів і що надавати перевагу комусь одному з-поміж інших
безпідставно.⁸

А тепер припустимо таке: *крім того*, ви помітили, що вам
підморгує удесятеро частіше ті, кому ви подобається. Якщо
підморгує Боб, у вас є нове свідчення. Тоді недоречно триматися
свого скепсису, що Боб і є тим таємним прихильником, оскільки
шанс 10:1 на користь «випадковий кандидат, який підморгує,
запав на мене» переважає шанс 1:5 на користь «Боб запав на
мене».

Так само недоречно буде сказати «Свідчення настільки силь-
не, що я готовий закластися на те, що саме він запав на мене! Те-
пер вважатиму, що Боб закоханий у мене». Надмірна упевне-
ність настільки недоречна, як і її брак.

Насправді на це питання є лиш одна прийнятна відповідь.
Щоб змінити думку з апіорного шансу 1:5 на відношення прав-
доподібності 10:1, підкріплене свідченням, ми множимо праву
та ліву частини й отримуємо апостеріорний шанс 10:5, скорочу-
ємо до 2:1 на користь того, що «Боб запав на мене». З урахуван-
ням припущень та наявного свідчення виявляється, що здогадка
«Боб запав на мене» правильна у двох випадках на кожен один
помилковий. Тобто ймовірність того, що ви йому подобається,

8. Ми також допускаємо, що ви можете бути певними, що ваш прихильник —
один із тих шести людей, причому ви не нехтуєте іншими варіантами. (Що як не
один однокласник запав на вас?) — Прим. авт.

становить 2/3. Будь-який інший рівень упевненості буде суперечливим.

Отже, в умовах доволі помірних обмежень питання «У що мені вірити?» має об'єктивно правильну відповідь. Воно має правильну відповідь, якщо ви сповнені непевності, а не тільки тоді, коли маєте вичерпні свідчення. Завжди існує правильна кількість упевненості у твердженні, навіть якщо воно має вигляд «особистого переконання», а не «факту», підкріпленого словами експерта.

І навіть попри це ми часто говоримо про такі речі, ніби сама наявність неупевненості й незгоди робить переконання справою смаку. Ми говоримо «це просто моя думка» або «маєш право на свою думку», ніби твердження науки й математики завжди існували на суттєво інших і вищих рівнях, на відміну від посполитого «особистого» і «суб'єктивного». Ось що на це відповів економіст Робін Хансон:⁹

«У вас немає права на особисту думку. Взагалі! У вас навіть немає права сказати “Я не знаю”. Ви маєте право на свої бажання, а іноді — право зробити свій вибір. У вас може бути вибір. Якщо оберете свої вподобання, ви, певно, маєте право на це. Але пам'ятайте: ваші переконання стосуються не вас, а світу. Ваші переконання мають бути найкращою оцінкою наявного стану речей. Усе інше — брехня. [...]

Правда, що для деяких тем у фахівців є надійніші механізми для вирішення суперечок. Для інших же тем через наші біаси та складність світу набагато складніше сформулювати однозначні висновки. [...]

Та ніколи не забувайте, що на кожне питання про те, яким є (чи має бути) стан речей, за будь-якої наявної кількості даних завжди існує найкраща оцінка. У вас є лише право докласти максимум чесних зусиль для визначення найкращої оцінки. Все інше — брехня».

9. Robin Hanson, “You Are Never Entitled to Your Opinion,” *Overcoming Bias* (Blog), 2006, https://www.overcomingbias.com/2006/12/you_are_never_e.html.

Наша культура не засвоїла уроки теорії ймовірностей: правильна відповідь на питання штибу «Наскільки певним я можу бути у тому, що Боб запав на мене?» настільки ж обмежена логічно, як і правильна відповідь на задачу з алгебри чи підручника з геології.

Наші мізки зіплені природним добром на тят-ляп. Люди приходять до логічно неідеальних висновків, ухвалюють неідеальні рішення, здійснюють неідеальні обчислення. Навіть на піку своїх можливостей ми не можемо вирахувати *точну* правильну відповідь на питання «Що я маю думати?» та «Що мені робити?». ¹⁰

Але те, що ми не можемо бути *бездоганно* послідовними, не означає, що не варто старатися. Завдяки розумінню, що існує бездоганий стандарт, із яким ми можемо себе порівняти, — дослідники називають його баєсовою раціональністю — можна визначити, як калібрувати свої переконання та дії. І хоча нам ніколи не стати бездоганими баєсівськими агентами, математика раціональності нам у поміч, коли потрібно зрозуміти, чому певна відповідь правильна і де саме ми схибили.

Уявіть, що намагаєтеся вивчити математику самим лише за виванням. Вам сказали, що « $10 + 3 = 13$ », « $31 + 108 = 139$ », але від цих прикладів не буде багато користі, якщо ви не розумієте закономірності, за якими функціонують ці палички й нулики. Якщо ви не володієте загальними принципами для оцінки успішності методу, шукати ці методи для покращення навичок раціональності буде набагато важче. За мету цій книзі служить спроба допомогти людям сформулювати такі принципи.

10. Нам бракує обчислювальних ресурсів (еволюції ж бракувало знань у конструюванні та передбачливості), щоб витруїти усіх тарганів з голови. Насправді навіть ті, хто приходить до щонайефективніших висновків, у реальному світі досі мають покладатися на евристики та наближення. Найкращі з можливих обчислювальних алгоритмів для зміни переконань не дотягують до послідовності теорії ймовірностей. — Прим. авт.

Прикладна раціональність

Спочатку Еліезер Юдковські писав ці есеї, об'єднані у книгу «Як по-справжньому змінювати думку», для блогу *Overcoming Bias* («Подолання біасів»). Коли він опублікував ці дописи наприкінці двохтисячних років, вони слугували натхненням для розвитку жвавої спільноти, що цікавилася раціональністю та самовдосконаленням.

Збірка «Мапа і територія» була першою у цій серії. «Як по-справжньому змінювати думку» — друга за ліком. Повне шестикнижжя під назвою «Раціональність: від Алгоритмів до Якорування» можна знайти мовою оригіналу на сайті *LessWrong* за посиланням <https://lesswrong.com/rationality>.

Якось один зі знаних дописувачів спільноти раціональності Скотт Александер писав так:¹¹

«Ні в кого не виникає сумнівів у тому, що непогано мати якомога більше грошей — те саме зі свідченнями. А також немає сумнівів у тому, що розпоряджатися обмеженою кількістю свідчень краще мудро, як і з грошима».

За допомогою технік раціональності ми збільшуємо пробіг наявних свідчень у тих випадках, коли вони непереконливі або наші біаси спотворюють тлумачення цих свідчень.

І вони застосовні до буденного життя, як у випадку з Бобом. Застосовні до суперечок у залі парламенту і на футбольному полі, до філософських питань і дебатів про плани на подальший розвиток технологій і суспільства. Завдяки застосовності математичних законів до кожної з цих галузей (плідне підґрунтя для зрощування одних і тих самих біасів) книга «Як по-справжньому змінювати думку» охоплює широке розмаїття тем.

У першому ланцюжку есеїв під назвою «Ретельно підібрані заспокійливі виправдання» увага приділяється імовірно

11. Scott Alexander, "Why I Am Not Rene Descartes," *Slate Star Codex* (Blog), 2014, <https://slatestarcodex.com/2014/11/27/why-i-am-not-rene-descartes/>.

«легким» питанням, де шанси надзвичайно високі, й виникає враження, що систематичні помилки на видноті.

Звідси ми рухаємося до темних вод — до частини «Політика та раціональність». Політика — точніше, обговорювана політика країни, про яку сперечаються балакучі голови з екранів — відома своїми лютими безплідними суперечками. На перший погляд, у цьому є щось дивне. Чому ми беремо політичні незгоди так близько до серця, якщо процес та наслідки державної політики часто настільки далекі від нас у часі та просторі? І якщо вже на те пішло, то чому ми тоді не стаємо *більш* розважливими та скрупульозними до свідчень, коли маємо справу з важливими для нас питаннями?

На відповідь натякає гра між Дартмутом і Принстоном. Більша частина процесу нашого мислення — справжнісінька раціоналізація, оповідання історій, завдяки яким наші нинішні переконання видаються більш узгодженими та виправданими, хоч їхня точність при цьому не обов'язково підвищується. У частині «У боротьбі з раціоналізацією» йдеться про цю проблему, а в наступній — «Свіжим поглядом» — про складність розпізнавання свідчень, що не вписуються у наші очікування та припущення.

На практиці підвищення рівня раціональності часто виливається у можливість натрапити на цікаві та вагомі нові ідеї й інтенсивніше спілкування з особистою раціональною спільнотою. У частині «Смертельні спіралі» йдеться про важливі ризики, що можуть спіткати групи, об'єднані спільними інтересами та незвичайними ідеями, які раціоналісти мають покращити, якщо вони прагнуть втілити свої піднесені ідеї у приземлену реальність. Наприкінці книга переходить до серії «Відпускання».

Ми не *заточені* під те, щоб змінювати свої мізки на баєсівський манір. Привернути увагу дартмутців та принстонців до того, що вони насправді бачать, децю важче, ніж декламувати перед ними аксіоми теорії ймовірностей. Ось що з цього приводу пише аналітик із питань благодійності Люк Мюлхаузер у книзі

«Сила агентності»:¹²

«Ви не баєсівський гомункул, чиє мислення зіпсоване когнітивними упередженнями.

Ви і є тими упередженнями».

Упередження підтвердження, упередження статус-кво, фундаментальна помилка атрибуції та решта не просто присмокталися до вашого мозку, а являють собою саму його суть.

Та це не означає, що позбутися їх неможливо. З усіма нашими арифметичними помилками ми й не ідеальні калькулятори. Причина лівової частини наших обмежених обчислювальних можливостей кориниться у глибинних особливостях роботи людського мозку. Втім, ми можемо вправлятися у цьому, навчитися, коли довіряти чи сумніватися у своїй математичній інтуїції, можемо сформувати середовище, яке посприяє цьому. І якщо сьогодні ми схилили, то завтра можна схилити менше.

12. Luke Muehlhauser, "The Power of Agency," *Less Wrong* (Blog), 2011, https://lesswrong.com/lw/5i8/the_power_of_agency/.

Ретельно підібрані заспокійливі виправдання

Цуйоку Нарітай! (Я хочу стати сильнішим!)

В ортодоксальному юдаїзмі побутує прислів'я: попереднє покоління для прийдешнього — як янголи для людей, прийдешнє для попереднього — як віслюки для людей. Воно походить з вірування ортодоксальних юдеїв, що усі юдейські закони Мойсей отримав від Бога на горі Синай. Проте ви не можете отримати нове галахічне знання експериментальним методом — хтось має передати його вам (хтось, хто почув від того, хто почув від Бога). І через відсутність нового джерела інформації у процесі передачі від покоління до покоління таке знання тільки спотворюється.

Тому сучасним рабинам і не дозволяється змінювати правила рабинів-пращурів. Плазунів традиційно вважають некошерними, але до черв'яка у яблуці ні в кого питань не виникає — його з'їсти можна, оскільки давні рабини вірили, що черв'яки з'являються у яблуках ні з того ні з сього, а тому їх уважають частиною того яблука. А от сучасний рабин уже не може сказати: «Ну так, давні рабини ні чорта не тямили в біології. Треба змінити правило!» Сучасний рабин ніяк не може знати про галахічний принцип, про який його пращури ні сном ні духом. Як би давні рабини змогли передати йому це знання з гори Синай? Оскільки єдине джерело — авторитет, відновити таке знання вже ніколи не вдасться. Воно буде остаточно втрачено.

Коли у (релігійній) початковій школі я вперше почув прислів'я про янголів та віслюків, хоч і не був ще тоді зрілим атеїстом, одразу подумав собі: «Щопокоління Тора втрачає знання. Наука з кожним поколінням його набуває. Хай де вони почали його накопичувати, рано чи пізно наука випередить Тору».

Без поступу діла не буде. Рухатиметесь уперед — ціль ставатиме дедалі ближчою, зупинитесь — залишитесь на місці.

У японській мові є така фраза — «цуйоку нарітай». «Цуйоку» означає «сильний», «нару» — «стати», а його форма «нарітай» — «хотіти стати». Разом ця фраза означає «Я хочу стати сильнішим». Вона виражає сентимент, що за емоційним наповненням зчитується у японській літературі у рази сильніше від будь-якого знайомого мені твору у західній літературі. Цю фразу можна сказати, коли ви заявляєте про свою рішучість навчитися професійно грати у го або після поразки у важливому матчі (але не думаєте здаватись), або після виграшу у важливому матчі (але у вас ще немає дев'ятого дану), або після того, як ви навчилися грати у го краще від усіх (але все ще думаєте, що можете краще). Ось це і є *цуйоку нарітай* — воля до перевершення.

Щороку на йом-кіпур ортодоксальний єврей читає молитву, яка починається з «Ашамну багáдну газáльну діба́ну до́фі» і продовжується за івритським алфавітом: «Ми вчинили ганебно, ми зрадили, ми вкрали, ми лихословили...»

З кожним вимовленим словом ви картаєте своє серце у кятті. Причому від цього не можна ніяк звільнитися: навіть якщо ви не крастимете цілий рік, то все одно не зможете пропускати слово «газальну» і не картати себе хоча б за крадіжку. Адже це порушить святковий дух йом-кіпура, суть існування якого у *спокуті* гріхів. Але про *уникання* гріхів, щоб менше чого було спокувати, там не говорять.

Крім того, вимовляти «ашамну» ви також не перестанете: «На жаль, таким був цей рік, але наступного я старатимуся краще».

Такий принцип відмолювання гріхів напрочуд схожий на той шлях раціональності, коли ви б'єте себе у груди, примовляючи: «Усі ми упереджені, усі ми ірраціональні, усі ми не до кінця обізнані, ми надміру самовпевнені, наші переконання погано калібровані...».

Просто чарівно. А тепер скажіть-но мені: як ви збираєтеся стати *менш* упередженими, *менш* ірраціональними, *більш* обізнаними, *менш* самовпевненими і *краще* калібрувати свої переконання?

На цей випадок у євреїв є бородатий анекдот. На йом-кіпур рабіна накрила раптова хвиля провини, він падає ниць і кричить: «Боже, перед Тобою я ніщо!». Охоплений сентиментом провини, кантор¹ так само кричить: «Боже, перед Тобою я ніщо!». Спостерігаючи за ними, на задніх рядах синагоги воротар падає ниць і кричить: «Боже, перед Тобою я ніщо!». Рабин штовхає ліктем кантора і шепоче йому: «Ти диви, хто тут визнав свою ницість».

Навіщо пишатися визнанням чи усвідомленням своїх упреждень? Це нагадує принцип: не створювати приводу для гордості з того, що визнаєш своє невігластво. Якщо невігластво — джерело вашої гордині, такий умонастрій може підкосити вашу охоту до нівелювання необізнаності, коли свідчення стукають у двері. Те саме із нашими хибами: не варто набивати собі пиху через те, наскільки ми самосвідомі своїх помилок, адже блаженний не той, хто спокутує свої помилки, а той, хто рідше їх припускається.

Інакше — коли хтось прийде до нас із планом усунення біасу, ми почнемо огризатися: «Що ти, думаєш, великограмотний дуже, так?». «Певно, ти не досить самосвідомий», — похитаємо тоді головою.

Не треба зізнаватися мені, що ви такі ж упреджені, як і я, якщо у вас немає плану, що ви робитимете зі своїми упредженнями. Це не означає, що після виконання плану ви позбудетеся усіх мисленнєвих хиб. Не в тому суть. Найголовніше — не опускати рук, зробити наступний крок. *Цуйоку нарітай!*

1. Або хазан. Головний співак у синагозі. — Прим. пер.

Належна скромність

З агальновідомо, що скромність — запорука належної науки. Яка саме скромність — питання спірне.

Уявіть, що креаціоніст каже вам: «Та хто там знає, чи еволюція правильна? Це ж усього-на-всього теорія. Тобі слід бути скромнішим і відкритішим». Це та скромність? Креаціоніст у край вибірково проявляє замалу впевненість, відкидаючи колосальну кількість свідчень на користь незручного для нього висновку. Я хочу сказати, що питання, чи називати таку вибірково занижену впевненість «скромністю» чи ні, — крок у хибному напрямку.

Як щодо інженера, котрий скромно проектує відмовостійкі механізми для техніки, хоча він, як ніхто інший, упевнений у надійності механізму? Як на мене, ось та скромність, якої варто прагнути. Історія знає численні випадки, коли інженер був, як ніхто інший, упевненим у надійності свого механізму і попри те все одно хибив.

Як щодо учня, котрий скромно двічі перевіряє свої відповіді на контрольній з математики? І цю скромність я вважаю чесною. Учень, який двічі перевіряє свої відповіді, *хоче стати сильнішим* — він розуміє, що потенційно може схибити, тому докладає зусиль, щоб виправити ту можливу хибу.

А як щодо учня, котрий скаже: «Що ж, хай би скільки разів я перевіряв, все одно ніколи не можу бути *певним* у правильності своїх відповідей» — і не перевірить жодного разу? Навіть якщо це рішення проростає з тієї ж емоції, яку переживає і попередній учень, такий учинок не можна назвати мудрішим.

Ви пропонуєте вчитися старанніше, на що учень відповідає: «Та ні, мені то все як до сраки дверці. Де я, а де ти — мегамозок! Такі, як я, після школи у бурсу йдуть». Це соціальна смиренність, а не скромність. Вона стосується більше розподілу статусу у племені, ніж наукового процесу. Попросите когось «бути скромнішим» — першим ділом ця людина подумає про

соціальну смиренність — інтуїтивно зрозумілу повсякденну успадковану від пращурів концепцію. Наукова скромність — відносно пізній і досить витончений інтелектуальний винахід, що за своєю природою не є соціальною. Наукова скромність — це те, у чому варто вправлятися, навіть якщо ви сам-один у глибокому космосі, за багато світлових років від Землі, і ніхто не оцінить ваші старання. Чи навіть якби ви отримали цілковиту гарантію, що ніхто за все життя не скаже жодного критичного слова на вашу адресу, хай би що ви сказали чи подумали про себе. Якщо ви не бовдур, то завжди ретельно перевіряєте свої розрахунки.

А ось той учень каже: «А от я якось бачив, як інші учні ретельно перевіряли свої відповіді і все одно помилялися. А що як за примхою проблеми індукції цього разу виявиться, що $2 + 2 = 5$? Хай би скільки разів я перевіряв себе, ніколи не можу бути остаточно впевненим». Звучить дуже проникливо. І дуже смиренно. Скоріше за все, той учень хоче якнайскоріше здати ту контрольну і чкурнути додому рубатися у відеоігри.

Початок кінця у фізиці не завжди супроводжується гуркотом грому чи волюванням сурм. Імовірніше, він почнеться з малесенької на позір помилочки... Але через те, що фізики носяться зі своєю гоноровою ідеєю фікс, що їхні моделі мають працювати постійно — навіть не просто у більшості випадків, — вони відстежують кожну малесеньку помилочку. Зазвичай малесеньку помилочку можна усунути, якщо придивитися уважніше. У рідкісних випадках помилочка розгортається до масштабів знищення цілої теорії. Недаремно ж пишуть: «Якщо ви не прагнете досконалості, можете тільки мріяти про поступи».

А тепер подумайте, наскільки зухвало — за соціальними мірками — намагатися мати рацію *увесь* час! Я цілком серйозно підозрюю, що якби Наука заявила, що теорія еволюції істинна у більшості випадків, але не в усіх, або якби та Наука припустила можливість того, що у деякі дні Земля *стає* — та хто його там зна, як воно насправді! — плоскою, то репутація науковців у суспільстві була б кращою. Наука виглядала б більш поступливою,

оскільки нам не довелося б сперечатися з усіма тими людьми, які вважають Землю плоскою — аж ось знайшлося б місце для компромісу. Коли ви багато сперечаєтеся, вас починають сприймати через призму вашої впертості. А якщо ви відмовляєтеся йти на поступки вже не вперше, тим гірше для вас. Подивіться на цю ситуацію як на питання статусу у племені: безумовно, науковці заслужили додаткові плюсики у карму за винайдення таких корисних інструментів, як ліки, телефони. Проте цей соціальний статус не виправдовує їхньої наполегливості, що еволюцію у школах мають викладати *тільки* з позиції науки. Адже у священників так само високий статус. Ті науковці — зарозумілі вискочки. Думують: якщо заробили трохи плюсиків у карму, то вже царі гори! Їм варто би збити собі пиху і йти на більші поступки.

Схоже, багато хто дотримується дещо туманного розуміння «раціоналістської скромності». Якщо ви дотримуєтеся приписного принципу, який самі до пуття не розумієте, можете собі ж і нашкодити, оскільки тоді у вашої ментальної картини може бути стільки рівнів свободи, що ви зможете підлаштовувати її до виправдання майже будь-чого. Коли у людей розмиті ментальні моделі, які можна використати для обґрунтування чого завгодно, вони зазвичай закінчують із вірою у те, у що на початку хотіли вірити. Зазвичай люди неохоче відмовляються від розмитості, бо вона напрочуд зручна. Проте етика потрібна нам, щоб керувати нами, а не ми нею.

Скромність — це та чеснота, яку часто хибно розуміють. Не те щоб її варто позбутися — радше бути свідомим контексту, в якому використовуєте це поняття. Помічним буде зауважити *дії*, до яких радять приступити за стратегії «скромного» мислення, і запитати себе: «Якщо я чинитиму отак, я ставатиму сильнішим чи слабшим?». Якщо подумати про проблему індукції на прикладі підвісного мосту, може здатися розумним висновок, що немає нічого надійного, хай би якими були ті заходи безпеки. Але, поміркувавши над тим, чи є насправді різниця між

укріплюванням кількома канатами і знизуванням плечима, ви починаєте розуміти, що саме може зміцнити міст.

Переважає ж більшість закликів до «раціоналістської скромності», з якими мені доводиться стикатися, є лише приводом знизувати плечима. Так говорить людина, яка купляє лотерейний білет: «Але ж ти не можеш *знати*, що я програю». Так говорить той, хто не вірить в еволюцію: «Але ж ти не можеш *довести* мені, що це правда». Так говорить той, хто відмовляється стати на прохання складною на вигляд проблемою: «Мабуть, її геть складно вирішити». Проблема закорінена в ангажованому скептицизмі, тобто в упередженні спростування, яке полягає у ретельнішій перевірці тверджень, яким ви не хочете вірити.¹ Під скромністю у більшості випадків хибно розуміють цілком загальне виправдання, орієнтоване на відкидання віри у щось. Так чи інакше ви не можете бути *певними* на всі сто. Тому прошу: остерігайтесь загальних виправдань!

Наступна проблема — скромність надто легко сповідувати. У своїй книзі «Розчарування. Релігія як природне явище» Деніел Деннет зазначає, що якщо у більшість релігійних тверджень складно повірити, завжди можна повірити, що ви *повинні* у них вірити. Такий випадок він називає «вірою у віру». Як би це виглядало — дійсно припустити, дійсно повірити, що три дорівнює одиниці? Набагато простіше повірити, що ви з якоїсь причини *повинні* повірити, що три дорівнює одиниці, і заявити про це у церкві у належну годину. Деннет пропонує, щоб більшу частину «релігійних переконань» вивчали як «релігійне сповідання віри», яке складається з того, у що, на їхню думку, їм треба вірити і що вони повинні говорити.

Спочатку ви відповідаєте на кожен контраргумент словами «Що ж, звісно, я можу помилятися». А потім, покійно прихилившись перед смиренністю, зробивши — як належить — реверанс у її сторону, ви із почуттям виконаного обов'язку і далі триматиметеся своєї думки.

1. Charles S. Taber and Milton Lodge, "Motivated Skepticism in the Evaluation of Political Beliefs," *American Journal of Political Science* 50, no. 3 (2006): 755–769.

Завжди залишається спокуса отримати якомога більше балів за найменшу кількість зусиль. Спокуса ретельно продумувати усі вхідні дані так, щоб вони якомога менше впливали на наші переконання і, перш за все, *дій*. Як казав Джон Кеннет Гелбрейт, «опинившись перед вибором між тим, щоб змінити свою думку і довести, що в цьому немає жодної необхідності, майже кожен почне доводити».² І чим вищий рівень *дискомфарту*, коли доводиться змінювати думку, тим більше зусиль іде на доведення.

Знаєте що: якщо ви так чи інакше не збираєтеся нічого *змінювати*, немає сенсу аж так затято вигинатися у ментальній гімнастиці для виправдання своїх поглядів. Часто я бачу, як люди, отримавши нову інформацію, нібито приймають її, а потім старанно пояснюють, чому вони робитимуть усе так, як планували до цього, хоч і тепер з іншим виправданням. Сенс роздумів — *сформувати* свої плани. Якщо ж ви збираєтеся дотримуватися тих самих планів, то навіщо ви так переймаєтеся підшукуванням вдалих виправдань? Коли ж ви стикаєтеся з новою інформацією, найскладніша частина — *оновити* свої знання і *відреагувати* на неї, а не пожбурити у чорну діру. Завдяки хибно витлумаченій скромності й утворюється така магічна чорна діра, адже усе, що треба зробити, — визнати, що можете помилятися. Тому-то й пишуть: «Бути скромним означає вживати чітких заходів, щоб запобігти своїм помилкам. Визнання своєї схильності до помилок і подальша бездіяльність не роблять із вас скромної людини — навпаки, ви вихваляєтеся своєю смиренністю».

2. John Kenneth Galbraith, *Economics, Peace and Laughter* (Plume, 1981), 50.

Цуйоку проти егалітарного інстинкту

Зазвичай члени мисливсько-збиральницьких племен були вкрай рівноправними (принаймні стосовно чоловіків). Всемогутній ватажок племені зустрічався переважно в аграрних суспільствах, рідко — у середовищах предків. Мисливець із мисливсько-збиральницького племені, який приносив чималу здобич, применшував своє досягнення, щоб не напоротися на заздрість одноплемінців.

Можливо, якщо ви починаєте з рівня, нижчого за середній, можете розвиватися, не зазіхаючи на переверщення більшої частини інших гравців. Та рано чи пізно ваше прагнення зробити усе якнайкраще змусить поставити планку вище середнього.

Якщо ви не зможете визнати, що впоралися краще від інших або соромитеся свого бажання досягти більшого, серединна лінія назавжди лишиться для вас залізобетонною стіною, об яку розіб'ється увесь саморозвиток. А як щодо тих, хто навіть нижче цієї серединної лінії? Наважтеся сказати їм, що прагнете більшого, ніж вони? Бач, який гордй!

Можливо, пишатися тим, що у вас щось виходить краще від інших, не так уже й розсудливо. Попри мої принципи, я все ж вважаю гордість корисним рушієм, доки маю з нього користь. Можливо, таке суперництво — гра із нульовою сумою, як і го. Та навіщо відмовлятися від діяльності, яка приносить задоволення і приводить до чогось цікавого?

І в будь-якому разі *соромитися* своєї переваги — точно нерозсудливо.

А ще — життя не оцінюється по кривій.¹ Воля до переверщення не має такої межі, поза якою вона вичерпується і

1. Спосіб оцінювання, за якого оцінки коригуються відповідно до бажаного для викладача розподілу балів. Хай би як добре студент виконав завдання, його кінцева оцінка залежить від успіху решти студентів. — Прим. пер.

перетворюється на волю до деградації. До того ж за перегони без фінішу не дають ані золотої, ані срібної медалі. Ніхто не забороняє просто бігти собі щосили і не перейматися, чи вдасться обігнати суперників. (Та майте на увазі: перестанете перейматися цією можливістю — одного дня, можливо, випередите інших; ігноруватимете наслідки випередження — вони можуть наздогнати вас.)

Рано чи пізно, якщо ви керуватиметеся істиною, то поставите собі за мету виправити ваду, якій більшість так і не спромоглася дати раду. Рано чи пізно, якщо ваші зусилля почнуть приносити плоди, кількість гріхів, у яких належить сповідатися, почне зменшуватися.

Можливо, ви навіть захочете применшити своє досягнення, навіть якщо досягли успіху. Якщо тачдаун ще можуть пробачити, то за танці в очковій зоні можна й на горіхи отримати.² Звісно, набагато швидше й зручніше публічно зректися своєї достойності і вдавати, що ви так само не без гріха. Звісно, лише доти, доки всі знають, що це не насправжки. З цього можна зробити собі розвагу: гордо випинати свою смиренність, якщо всі знають, як багато у вас підстав для цієї скромності.

Та це не означає, що можна вже опускати руки. Навіть якщо ваші губи ледь ворухнуться, не облишайте спроб: *Цуйоку, цуйоку!* Сильніше, сильніше!

А потім ви поставите планку вище. Власне, ось таке воно — усвідомлення того, як далеко вам іще до досконалості (хоч уже й на кілька кроків ближче). Завжди тягнутися вгору і не соромитися цього.

Цуйоку нарітай! Я завжди бігтиму щосили, і навіть якщо обжену когось, не подумаю зупинятися. А хтось одного дня перевершить і мене. Та навіть якщо колись я відстану, я все одно бігтиму до останніх легень.

2. В американському футболі тачдаун — додаткові очки — можуть заробити гравці команди, що атакує, забігаючи на очкову зону противника. — Прим. пер.

Третя альтернатива

«Віра у Санта-Клауса дарує дітям відчуття дива і наснажує їх поводитися чемно, за що вони чекають подарунків. Якщо діти втратять віру в Санту, то разом із нею — і відчуття дива, тож про чемну поведінку можна буде забути. Отже, навіть якщо віра в Санту фактично хибна, цю Благородну брехню варто підживлювати, оскільки чистий виграш від неї слугує корисній цілі».

Так виглядає класична хибна дилема, а саме хибна виключеного третього, або оптова угода. Навіть якщо ми приймемо фактичні та моральні засновки вищенаведеного аргументу, він однаково не витримує критики. Навіть якщо припустити, що стратегія «Санта» (заохочення дітей повірити у Санта-Клауса) краща за її відсутність, повірити у нього — так само не *найкраща з усіх можливих альтернатив*. Адже подарувати дітям відчуття дива можна різними способами, наприклад: взяти їх подивитися на запуск космічного корабля або дати почитати щось із наукової фантастики. З таким же успіхом можна запропонувати дітям хабар за гарну поведінку: *поки* дитина під наглядом дорослих, хабар діє. Натомість проста похвала без хабаря діятиме незалежно від контролю батьків.

Загалом, Благородна брехня — прояв хиби оптової угоди. Щоб усунути її, ми можемо задуматися над Третьою альтернативою, якщо дійсно прагнемо очікуваної вигоди.

Тож як відшукати ту третю альтернативу? Крок перший: почати шукати рішення. Крок останній: прийняти знайдене рішення. Очевидно ж. Та все ж більшість шпортається саме на згаданих кроках, а не в процесі пошуку.

Певні хибні дилеми насправду виникають через когнітивну складність побачити кращі альтернативи. Хибні дилеми виникають, зокрема, на підґрунті виправдання сумнівної стратегії шляхом вказування на гадану користь від неї. Такий виправдувач *закриває очі* на Третю альтернативу, адже знайти її означало б

зруйнувати виправдання. Похвала дієвіша за хабар, а космічні кораблі можуть надихати не гірше летючих північних оленів — це останнє, що хоче почути апологет стратегії «Санта».

Найкраще — ворог хорошого. Якщо ми *справді* хочемо допомогти, тоді краща альтернатива — те, що треба: знайдете кращу стратегію — допомога буде ефективнішою. А якщо мета — виправдати певну стратегію *шляхом ствердження, що вона допомагає*, Третя альтернатива стає ворожим аргументом і суперником.

У сучасній психології процес ухвалення рішень розглядають як пошуку альтернатив. У житті замало порівнювати варіанти — потрібно, у першу чергу, вітворити їх. Для багатьох проблем кількість альтернатив величезна, тому при пошуку вам потрібен стоп-критерій. Якщо ви хочете придбати будинок, ви не можете об'їздити усе місто, оглянувши кожен будинок на продаж. У якийсь момент доведеться припинити пошуки й ухвалити рішення.

Але що робити, коли наші свідомі мотиви пошуку — критерії, у яких ми можемо собі зізнатися, — не збігаються з підсвідомими мотивами? Коли ми запускаємо нібито альтруїстичний пошук альтруїстичної стратегії і знаходимо ту, яка приносить користь іншим і шкодитиме нам, ми не зупиняємося на *цьому*; ми шукаємо далі. Говоримо собі, що шукаємо стратегію, від якої буде більше користі. А тепер припустімо, що ми знаходимо-таки стратегію із якоюсь виправданою вигодою, а *ще* вона виявляється просто зручною для нас. От тоді можна закінчити пошуки. І будь-яким пропозиціям почати шукати знову ми, певно, чинитимемо *опір*, наприклад, через брак часу або що. (Хоч на виправдання поточної стратегії когнітивних ресурсів чомусь не бракує.)

Стережіться суперечок довкола *виправданості* стратегії (адже наша мета — її *оптимальність*) або її корисності порівняно з бездією (адже наша мета — максимальна корисність будь-якої дії).

Хибні дилеми часто подають для виправдання неетичних стратегій, які, за дивовижним збігом обставин, виявляються

дуже зручними. Наприклад, у багатьох випадках брехати набагато зручніше, ніж казати правду, а триматися початкових переконань простіше, ніж оновлювати їх. Звідси й популярність аргументів за Благородну брехню, яка виступає захистом початкового переконання. Адже навряд чи вдасться знайти Благородних брехунів, які вираховують нову оптимальну Благородну брехню, — вони триматимуться своєї початкової брехні. Тому для них краще негайно припинити такий пошук!

Поставте собі відверте питання: *якби я побачив крашу альтернативи за мою нинішню стратегію, я б щиро зрадив чи відчув момент спротиву перед тим, як відпустити попередню?* Якщо відповідь «ні» і «так», можливо, ви навіть не спробували шукати Третю альтернативу.

А тепер наступне важливе питання: *чи заплющив я очі, подумав як слід протягом п'яти хвилин над творчим рішенням, над кращою альтернативою?* Головна умова: на справжньому годиннику хвилинна стрілка має відлічити справжніх п'ять хвилин. Інакше — ви просто кліпнете — заплющите-розплющите очі на мить — і скажете: «Що ж, я спробував, і нічого не спало на думку». Кліпнути — значить створити зручну чорну діру, в яку можна скинути свої обов'язки. Тому бажано скористатися фізичним годинником.

Може, ви і не старалися подумати над творчим рішенням? Чи не було на задвірках вашої свідомості потаємної думки зархувати кожен варіант до очевидно невдалого?

Дивовижно, скільки Благородних брехунів та їм подібних охоче підтримують етичні порушення — з усім належним ниттям про їхні муки совісті, — коли вони не витратили і п'яти хвилин на пошук альтернативи. У кожного із нас є такі ментальні пошуки, які ми, по секрету, воліли б провалити, адже якщо перспектива успіху створює дискомфорт, люди підуть на перший-ліпший привід здатися.

Лотереї: примарна надія

Традиційно лотереї критикують за те, що гравці не можуть собі дозволити програти, що таке дозвілля — марнування і викачування грошей із тих, хто найбільше їх потребує. Деякі пропоненти лотереї, і навіть коментатори з блогу «Подолання біасів» (Overcoming Bias), спробували захистити лотерейні ігри аргументом *«раціональна покупка фантазії»*: за долар купити приємне одноденне очікування стати мільйонером.

Тепер подумаймо, на яких засадах стоїть цей аргумент. Ви гаєте цінні ресурси мозку на фантазію, справжня ймовірність якої наближається до нуля, а отже, реалізувати її ви не зможете. Ваше майбутнє визначають лотерейні кульки. Йдеться про фантазію, в якій багатство звалюється на голову без зусиль, сумлінності, навчання, харизми чи навіть терпіння.¹

Звідси лотерея — це ще й марнотратство емоційної енергії. Вона заохочує вкладати свої мрії і надії на краще майбутнє у незрівнянно малу ймовірність. Якби не лотерея, можливо, ті люди мріяли б вступити до університету або відкрити власний бізнес або отримати підвищення на роботі — жили б надії, які піддаються *втіленню* і можуть викликати бажання стати сильнішими. А вже десь на двадцятій спробі виобразити приємну візію мозок у стані мріяння помітить спосіб утілити її у життя. Зрештою, чи не *для цього* призначені мрії та мізки? Але чи може цей обмежений реальністю спосіб конкурувати зі штучно підсоложеною перспективою миттєвого збагачення — не після того, як стартап з доткомів пройде шлях до IPO,² а вже з дня на день?

Серйозно: чому ми не можемо просто сказати, що купляти лотерейні білети — діло дурнів? Люди *дурні* — це ні для кого не має бути вже такою дивною гіпотезою.

1. Див.: По Bronson, "How Not to Talk to Your Kids," *New York*, 2007, <https://nymag.com/news/features/27840>.

2. Initial public offering — первинна публічна пропозиція. Перший продаж цінних паперів. — Прим. пер.

Не випадає дивуватися і тому, що людський мозок не оперує 64-бітною (із плавучою комою) арифметикою, не здатен зменшити емоційну силу приємного очікування у 0,00000001 раз, не втративши при цьому саму послідовність міркування. Не дивно і те, що багато людей не розуміють того, що чисельний розрахунок очікуваної корисності має *перевіжити* або *замінити* їхню неточну фінансову інтуїцію, а замість цього вони трактують цей розрахунок як просто *один з аргументів*, який слід врівноважити з їхніми приємними очікуваннями. Емоційно такий аргумент слабкий, оскільки складається усього-на-всього із закарлюк на папері, а не візій казкового багатства.

Здається, це достатньо пояснює популярність лотерей. Чому тоді стільки сперечальників воліють захищати цей класичний спосіб саморуйнування?³

Власне, процес подолання біасу складається з таких кроків: 1) помітити упередження, 2) ретельно проаналізувати його, 3) прийти до висновку, що це упередження шкодить, 4) почати шукати обхідні шляхи, 5) утілити їх. Шкода, що так багато людей проходять перший і другий кроки, а потім шпортаються на третьому, який заслуговує на звання найпростішого. Якщо біаси — це лимони, не треба робити з них лимонад — просто спалить їх до дідька.

3. Див.: “Debiasing as Non-Self-Destruction.” https://lesswrong.com/lw/hf/debiasing_as_nonseldestructioin.

Нова покращена лотерея

Пропоненти не втомлюються просувати ідею, що лотерея — аж ніяк не примарна надія, а така собі послуга: люди купують фантазію — «багатіти думкою, що одного дня прокинешся мільйонером, обходиться дешевше, ніж мріяти про кар'єру голлівудської зірки».¹ Принагідно один користувач надрукував такий коментар: «Нульовий шанс розбагатіти та епсилонний² шанс розбагатіти — це дві великі різниці. Придбавши білет, ви долаєте цей розрив зі своєю мрією».

Я ж намагаюся донести тезу, що між нульовим та крихітним шансом розбагатіти є різниця розміром в епсилон. Сумніваєтесь? Нехай епсилон дорівнює одній гуголплексній.³

Хай там як, а якщо ми припустимо, що лотерея дає епсилонну кількість надії, така умова породжує дизайн Нової Покращеної Лотереї. У цю версію лотереї виграють у середньому раз на п'ять років у випадковий момент, визначений, скажімо, розпадом не дуже радіоактивного елемента. Купуєте білет за долар, а отримуєте не просто кілька днів досвіду крихітного шансу розбагатіти, а кілька *років*. Ба навіть більше, ви можете розбагатіти у будь-який момент! У *будь-яку мить* може задзвонити телефон, і з того боку слухавки вас сповістять, що *ви — так, ви — тепер мільйонер!*

Невже така лотерея не краща за звичайний розіграш, який відбувається у визначений час кілька разів на тиждень? От уявіть: заходить начальник і вимагає переробити проєкт, поповнити запаси на складі або надокучає чимось іншим. І ви, замість того, щоб іти на роботу, сідаєте біля тумбочки з телефоном і

1. Див. "The Future of Fantasy," https://www.economist.com/blogs/freeexchange/2007/04/the_future_of_fantasy. Коментар, на який відповідаю, за посиланням https://lesswrong.com/lw/hl/lotteries_a_waste_of_hope/e1u.

2. Тут: крихітна ймовірність. У математиці епсилоном позначають надзвичайно малу додатну величину, якою можна знехтувати. — Прим. пер.

3. Гуголплекс — число зі ста нулями. — Прим. пер.

чекаєте на заповітний дзвінок, адже у вас є той самий крихітний шанс, що *у визначений час ви — так, ви* — виграєте бажаний мільйон! І навіть якщо телефон не задзвонить у цю хвилину, не варто вішати носа: він завжди може вас порадувати *наступної* хвилини!

Скільки фантазій породила б Нова Покращена Лотерея! Ви можете закупуватися у магазині дорогими товарами, складаючи їх у свій кошик. А якщо голос на тому боці дроту не порадує вас новиною про виграш, завжди можна викласти набране.

Можливо, ця Нова Покращена Лотерея навіть відображала б розподіл ймовірностей, що безперервно змінюється: як для ймовірності виграшу, так і для вибору окремих чисел — причому в підсумку це зводилося б до згаданого розподілу Пуассона.⁴ Оце *весело* буде! Святі ховрахи, у цю хвилину шанс виграшу зріс майже вдсятеро! Подивіться: у числа 42, яке я обрав для кульки *Mega Ball*, майже вдвічі більше шансів на виграш! Дістали телефон — і перед вами шанси на перемогу. Хіба не *захопливо*? Набагато захопливіше, ніж пробувати збалансувати свої витрати. Набагато захопливіше, ніж робити домашку! Цей солодкавий присмак очікування від нової мрії — набагато солодший за бажання вступити у технічне училище чи піти з роботи раніше. Люди можуть так залипати в екран цілий день. Навіщо мріяти про щось *іще*?

Аякже, продавати спокусливі *безпідставні* марева — цінна послуга, безумовно. Люди готові платити. Вона точно має бути цінною. Або ж покупці теж помиляються, але ж ми всі знаємо, що люди не можуть помилятися, коли купують лотерейний білет.

І все ж нинішні уряди, маючи бісову монополію на лотереї, не пропонують таку просту та очевидну послугу. Чому? Бо вони хочуть, щоб люди переплачували. Вони хочуть, щоб люди

4. Пуассоновий розподіл імовірностей позначає ймовірність того, що задана кількість подій відбудеться за фіксований часовий проміжок, якщо ці події відбуваються з відомою постійною середньою частотою і не залежать від часу, що минув з моменту останньої події. — Прим. пер.

витрачали гроші щотижня. Хочуть, щоб люди витрачали сто доларів за трепет від віри у те, що їхній шанс на виграш у сотню разів вищий, а не витріщалися на екран телефона в очікуванні побачити підвищення ймовірності. Тому якщо ви вважаєте, що лотерея — це послуга, то у неї явно завищена ціна, за яку доводиться платити найбіднішим верствам суспільства. Тому ваш почесний обов'язок як громадянина — вимагати Нової Покращеної Лотереї.

Але ж усе-таки шанс є, так?

Колись давно я мав бесіду з одним паном, який обмовився, що він не вірить в еволюцію. На його заяву я відповів так:

— Надворі не дев'ятнадцяте століття. Коли Дарвін уперше презентував теорію еволюції, ще, можливо, був резон у таких сумнівах. Але нині двадцять перше століття. Ми вміємо *аналізувати гени*. У людей та шимпанзе 98% спільної ДНК. Ми знаємо, що шимпанзе — еволюційний родич людини. Більше нема про що говорити.

— А раптом це випадковість, що ДНК збігаються, — каже він.

— Шанс того, що це випадковість, складає $1:2^{750\,000\,000}$.

— Але ж усе-таки шанс є, так?

Є низка причин, чому тодішня версія мене не може оголосити остаточну моральну перемогу у цій розмові. Одна з них — я не пригадую, звідки взяв число $2^{750\,000\,000}$, хоча воно, мабуть, відображає правильний метапорядок величини.¹ Інша причина — тодішня версія мене не вдалася до каліброваної впевненості. За всю історію людства, коли люди вираховували шанс $1:2^{750\,000\,000}$ того, що щось станеться, вони точно помилялися частіше за раз на $2^{750\,000\,000}$ разів. Наприклад, відсоток спільних генів було переглянуто з 98% до 95%. І це число може стосуватися навіть 30 000 відомих генів, а не всього геному, тому в цьому випадку це хибний метапорядок величини.

І попри це я все одно думаю, що відповідь того пана доволі кумедна.

Не пригадую, що саме я відповів йому — може, «Ні», — та ця розмова запам'яталася мені тим, що я виніс із неї кілька цінних думок про закони мислення, якими їх бачать непросвітлені.

Мені спершу спало на думку, що людські інтуїції проводять якісну різницю між «жодних шансів» і «дуже крихітний шанс»,

1. Порядок величини — наближена міра величини числа, що дорівнює десятковому логарифму, округленому до цілого числа. — Прим. пер.

але його варто враховувати». Свідченням цьому є дискусія про лотерею на сайті *Overcoming Bias*.

Проблема в тому, що іноді за допомогою теорії ймовірностей ми можемо вирахувати шанс, який насправді настільки крихітний, що його не варто навіть тримати в голові, хоч на той момент ви вже вираховували його. Люди плутають мапу з територією, тому їхнє нутро може підказувати, що відстежувати символічно описану ймовірність — це «вартий того шанс», навіть якщо символічно описане *явище* — число настільки мале, що його неможливо було б розгледіти навіть примружившись. Ми можемо описувати словами скільки завгодно малі числа, але не відчуттями — настільки слабкого відчуття просто не існує: воно не активує достатньо нейронів і не спричиняє достатнього вивільнення нейромедіаторів, щоб його можна було відчути. Тому люди купляють лотерейні білети — ніхто не *відчуває* крихітності ймовірності.

Що навіть іще дивніше, у дискусіях, де проводиться якісна різниця між аргументами «певними» і «непевними», якщо аргумент не певний, ним дозволено знехтувати. Тобто якщо ймовірність дорівнює нулю, ви маєте позбутися цього переконання, але якщо та ймовірність становить один із гугола, то, звісно, можна нічого не змінювати.

Ми живемо у вільній країні, і ніхто не може вас позбавити волі за незаконне мислення, та якщо ви збираєтеся нехтувати аргументом, що ймовірність становить один із гугола, чому послідовно не знехтувати й аргументом про те, що ймовірність дорівнює нулю? Тобто якщо ви вже грéбуєте свідченнями, чому б уже не знехтувати і певними, і непевними?

У житті неодноразово помічав, що я вчуся на відвертих негативних прикладах інших людей, які належним чином узагальнював на більш специфічні випадки. За цих умов зворотний урок у тому, що якщо ви не можете ігнорувати ймовірність один із гугола, бо вам так хочеться, то відповідно не можете ігнорувати ймовірність розміром 0,9, бо вам так хочеться. Обидві ймовірності — ковзкий край урвища.

Пригадайте цей приклад, коли спіймаєте себе на думці «А *доведи*, що я неправий». Навіщо обмежуватися нехтуванням лише ймовірнісного контраргументу, якщо можна піти далі й ігнорувати доведення?

Омана сірого

Софістикат: Світ не ділиться на чорне та біле. Ніхто ні янгол, ні демон. Усе сіре. Тому ніхто не кращий за когось іншого.

Зетет: Знаючи тільки сіре, ти висновуєш, що усі відтінки сірого один одного варті. Ти насміхаєшся з простоти двоколірного бачення і ставиш на його місце одноколірне...

— «Праща Давида», Марк Стіглер

Не знаю, чи помилка, якої припустився Софістикат, має затверджену назву, тому називатиму її оманю сірого. У попередньому есеї ми побачили, як вона проявляється: хто вважав, що шанс настання події становить один до двох у степені сімсот п'ятдесят мільйонів, казав: «Ще є шанс». Для того пана будь-яка ймовірність була «непевною», тому він волів нехтувати ними усіма.

«Місяць складається із зеленого сиру» та «Сонце складається переважно з водню та гелію» — однаково непевні твердження, та рівень їхньої непевності різний.

Усе складається з відтінків сірого, але є відтінки настільки світлі, що майже білі, і настільки темні, що майже чорні. Та навіть якщо і таких відтінків немає, ми все ще можемо порівнювати: «цей темніший, а цей світліший».

Колись давно цей уривок із книги Ієна М. Бénkса «Гравець ігор» — особливо виділений жирним шрифтом фрагмент — неабияк впливав на моє становлення як раціоналіста:

«Усередині системи, в якій діє презумпція винуватості, немає невинних. Якщо органи влади цієї системи розділяють усіх на тих, хто або за, або проти неї, ми виступаємо проти. Ти б також був проти, якби поміркував над цим як слід. Задумався — тебе вже зараховано до ворогів.

Хтозна, чи є у тому твоя провина, оскільки кожне суспільство нав'язує частину своїх цінностей тим, хто виріс у ньому, але питання у тому, як воно намагається дати раду цьому ефекту — довести до крайнощів чи звести до мінімуму. Ти виріс у суспільстві другого типу, а тебе просять виправдовуватися перед першим. Приховувати свої думки буде важче, ніж здається. Про нейтральність можеш забути. Ти не можеш не мати своїх політичних поглядів, адже вони не якийсь окремий набір сутностей, відокремлений від решти твого єства, — вони серцевина твоєї ідентичності. Я знаю це. Вони знають це. Краще тобі прийняти це».

Не поспішайте вистукувати гнівні коментарі: якщо суспільство не так напосідатиме зі своїми цінностями, кожному наступному поколінню доведеться починати спочатку. З цього уривку я взяв дещо інше.

У ретроспективі здавалося, що якби мені давали по різочці щоразу, коли я стикався з цією думкою, я б уже загатив цілу гроблю. Але щось у тому уривку мене змусило-таки задуматися.

Як виявилося, тоді я натрапив на концепцію Кількісного шляху, застосовну до життєвих проблем на кшталт моральних суджень та особистісного зростання. Навіть якщо ви не маєте можливості запалити чи загасити вогонь, ви все ж можете спробувати роздмухати його чи обмежити радіус дії.

Чи перевірив я Америку? Хай там як, а для багатьох коментаторів на *Overcoming Bias* ця думка не очевидна: «Неможливо — ні в кого ще не вийшло викоринити усі біаси». Мені однаково, чи є серед тих коментаторів фахові економісти. Очевидно, що вони не пізнали Кількісний шлях, принаймні ту його частину, застосовну до повсякдення, особистісного зростання і тому подібних аспектів. Те, що я не можу *позбутися* їх, не означає, що не варто *зменшувати* їхній уплив.

Для кращого розуміння пропоную проаналізувати наступну розмову між Робіном Хансоном та Тайлером Кауном.¹ Перший заявив, що принаймні у 75% випадків воліє покладатися на приписи економічної теорії замість інтуїції:

— Здебільшого я намагаюся застосовувати чисту теорію економіки, не сходячи на манівці, і роблю невелику поправку на особисте чи культурне бачення.

На що Тайлер Каун відповів:

— Як на мене, не можна просто так взяти і застосувати чисту теорію економіки... Ті, хто застосовують теорії, завжди пропускають їх через особисті та культурні фільтри. Іншого способу просто немає.

Так, але ж можна постаратися послабити цей ефект. Або ваші дії призводитимуть до його посилення. Та навіть *якщо* ви старатиметеся послабити ефект, думаю, що у багатьох випадках називати результат «чистим» цілком доцільно, навіть в економіці.

«Усі не ідеальні». Мохандас Ганді та Іосіф Сталін були неідеальними, проте їхня неідеальність має різні відтінки. «Усі не ідеальні» — чудовий приклад заміни двоколірного бачення на одноколірне. Скажете «Ніхто не ідеальний, але *дехто менш ідеальний, ніж інші*» — можете лишитися без оплесків. А тим, хто прагне кращого, дасте надію. Зрештою, ніхто ще не сягнув *апогею* неідеальності.

(Щоразу, коли хтось говорить мені «Перфекціонізм шкодить тобі», я відповідаю: «Як на мене, немає нічого поганого у тому, щоб бути неідеальним, але доти, доки мою неідеальність не помічають інші».)

Спочатку вони кажуть «Кожна наукова парадигма накладає свої припущення на те, як ми тлумачимо експерименти», а потім поводяться так, ніби довели, що наука на рівних із чаклунством. Так, кожен світогляд накладає свою модель на

1. Hanson (2007), "Economist Judgment," <https://www.overcomingbias.com/2007/12/economist-judgm.html>. Cowen (2007), "Can Theory Override Intuition?", <https://marginalrevolution.com/marginalrevolution/2007/12/how-my-views-di.html>.

спостереження, з якими має справу, та суть у тому, що деякі світоглядні намагаються послабити цей вплив, а деякі, навпаки, утверджують його. Хоч білого і немає, натомість є відтінки сірого, які помітно світліші за інші, і ставитися до них як до рівних — дурисвітство.

Якщо кілька мільярдів років тому Місяць зайшов на орбіту Землі, якщо ви весь цей час спостерігали це небесне тіло на небосхилі та очікуєте завтра побачити його у визначеному місці та фазі, ви не певні у цьому. А якщо ви очікуєте, що невидимий дракон вилікує вашу доньку від раку, ви теж не певні. В обох випадках ви не певні, але різною мірою. Порівняйте: ви очікуєте те, що вже ставалося так, як ви й передбачали з точністю до дванадцяти знаків після коми, і ви очікуєте щось таке, що *порушує* порядок ваших попередніх спостережень. Називати обидва очікування «вірою» виглядає так, ніби ви розмиваєте кордони між ступенями певності.

«А наука теж тримається на вірі!» — один із видів ментальних станів. Зазвичай так говорять ті, хто стверджує, що віра — це щось добре. Тоді чому вони підносять віру як підґрунтя науки уїдливо-тріумфальним тоном? Чому з їхніх вуст це твердження не звучить як комплімент? Якщо подивитися з їхньої точки зору, такий комплімент доволі *небезпечний*. Тобто якщо наука тримається на вірі, вона нічим не відрізняється від релігії. А якщо наука — це релігія, тоді саме релігія лікує хворих і розкриває таємниці зірок. Тоді можна було б сказати: «Жерці науки можуть демонстративно ходити по поверхні Місяця, що може підтвердити будь-хто. Чим не чудо віри? Жерці твоєї віри такого не вміють». Цим шляхом ви хочете йти, пані та панове віряни? Можливо, подумавши ще раз, ви захочете відмовитися від твердження «А наука теж тримається на вірі!».

Направду, наступна тенденція виглядає доволі дивно. Ви намагаєтеся зачистити свій відтінок сірого, відшліфовуєте його до світлого тону, а потім приходить якийсь Пилип і глибоко ображеним голосом віщає: «Але ж це не білий! Це сірий!». Одна справа, коли хтось говорить: «Тут не такий вже й світлий тон, як

здається, бо є конкретні проблеми А, Б і В», і зовсім інша, коли якийсь Пилип пащекує: «Це не білий! Це сірий!», не вказуючи на конкретні проблемні місця.

У такому разі я починаю підозрювати ментальні стани, які тяжіють до примхливості. Можливо, той Пилип продав душу за свої помилки, а тепер закриває вуха, коли розмова заходить за можливість покращення. Коли такий Пилип знаходить виправдання своєму небажанню зробити краще, він часто не готовий визнати, що хтось інший *може* пробувати робити краще, тому кожен такий спосіб він сприймає як ворожий, а кожне твердження на користь можливого поступу — як образливе. І на одному диханні він пискує: «Маю честь бути сірим, — і злісно додає: *Але ж ти теж сірий!*».

Якщо немає ні чорного, ні білого, у нас лишається світліше і темніше. Адже далеко не все те сіре, що на один штиб.

Тут пасує коментар користувача G2, який цитує працю Азімова «Відносність помилок»:

«Коли люди думали, що Земля пласка́, вони помилялися. Коли люди думали, що Земля має форму сфери, вони теж помилялися. Та якщо ви думаєте, що переконання “Земля має форму сфери”, однаковою мірою хибне, як і переконання “Земля пласка”, то помиляєтеся ще глибше, ніж ті, хто висловлювали два попередні погляди».

Безумовний авторитет

До вас приходить якийсь мудрагель і з гордістю заявляє: «Насправді ті науковці нічого не *тямлять*. Теорії — це все, що в них є. Вони не знають *напевне*, чи мають рацію. Ви, науковці, змінили свій погляд на принцип роботи гравітації. Хтозна, чи не зміните ви завтра свою думку щодо еволюції».

Вдумайтесь, яка глибока культурна прірва. Не варто тішити себе думкою, що кількома реченнями ви зможете побудувати міст через неї, — інакше на вас чекає гірке розчарування.

Для непросвітлених існує бінарний розподіл на авторитета та неавторитета: гідні довіри не втратять її, а негідні не здобудуть. У їхньому світі джерела інформації бувають правдивими та брехливими. Якщо колись науковці змінювали свій погляд на щось, наука не може бути справжнім Авторитетом, а тому їй узагалі не можна довіряти, мов тому свідку, що заплутався у своїх показаннях, чи продавцю, якого піймали на крадіжці каси.

До того ж вони очікують, що пропонент ідеї боронитиме її від усякого контраргументу і, звісно ж, ні в чому таки не зізнається. Відповідно, усі твердження занижуються у ймовірності. А якщо вже навіть і *пропонент* науки визнає її неідеальною, то вона вже точно має бути нічого не вартою.

Коли людина прожила з вірою у певність, ви не можете просто сказати їй: «Наука ймовірнісна, як і все інше знання». Першу половину твердження вони приймуть за визнання провини, а другу відкинуть як марну спробу звинуватити усіх інших, щоб самим уникнути осуду.

Ви зізналися, що вам не можна довіряти, тому зникніть разом зі своєю наукою і не вертайтесь!

Релігія — одна з очевидних причин такого умонастрою. Святе Письмо дає нібито самим Господом Богом, тому визнати помилки у ньому — означало б на пні знищити авторитет Письма. Через те будь-яка краплина сумніву вважається за гріх. Певні ви

чи ні, ви зобов'язані заявити, що певні.¹

Підозрюю: до цього доклалася і традиційна шкільна система. Вчителі розказують матеріал, у якому не сумніваються; ви маєте повірити їм на слово і переказати його на контрольній. Та коли учень висловлює пропозицію, ви не зобов'язані погоджуватися із нею: можете прийняти або відхилити (здається), і ніхто вас не покарає за це.

Боюся: такий підхід накладає вимір переконання на соціальні виміри *авторитетності, командування та законодавства*. У соціальному вимірі різниця між абсолютними та неабсолютними законами, командами та пропозиціями, авторитетами та неавторитетами полягає у якості. У такому разі за аналогією із суворим та несуворим розпорядженням мав би бути також розподіл на суворе та несуворе знання. Жорсткій владі належить підкорятися, а от необов'язкові пропозиції можна приймати або відкидати — як кому до смаку. Тому наука, яка визнає свою погіршеність, має належати до другого класу.

(Принагідно зауважу, що я бачу певну схожість із тими, хто думає, що як Авторитетна ймовірність отримана не від учителя під час уроку чи не з якогось Беззаперечного джерела, то ваша непевність ніяк не стосується баєсової теорії ймовірностей.² Адже тоді хтось — *матері його ковінька!* — може оскаржити вашу попередню оцінку ймовірностей. Тому непросвітленим здається, що баєсові пріори належать до того класу переконань, які пропонують студенти, а не вчителі. Через те це таке *знання* не є належним.)

І непокоїть ця культурна прірва між Шляхом авторитету та Кількісним шляхом більше тих, хто дивиться на неї зі сторони раціональності. По той бік якийсь Пилип вірить у те, що володіє знанням, *більш* надійним за якісь там наукові ймовірнісні припущення. Одне з тих припущень — завтрашня поява Місяця у визначеній точці та фазі, яка лишалася тією самою кожною

1. Див. «Сповідувати та вболівати» у книзі «Мапа і територія».

2. Див. «Зосередити свою невизначеність» у книзі «Мапа і територія». — Прим. авт.

спостережуваної ночі з того дня, як почали реєструвати астрономічні спостереження. Її ж прогнозували і фізичні теорії, чії попередні передбачення підтверджувалися з точністю до чотирнадцяти знаків після коми. Що ж це за знання таке, яке непросвітлені ставлять над нашим? І чому? Мабуть, якийсь запліснявильний давній сувій, який суперечить собі у бозна-скільких місцях уже з понеділка, з вівторка — і взагалі кожного дня тижня. Але все одно він надійніший за науку, бо, мовляв, ніколи не визнає своєї погрішності, не змінює своєї позиції, хай би скільки разів суперечив сам собі. Вони з такою легкістю жонглюють тим словом «певність», ніби тенісним м'ячем, тоді як науковці обтяжені обов'язковим сумнівом і насилу вибирають бодай мінімальну ймовірність. «Я ідеальний, — безтурботно кажуть вони. — Раз вам досі доводиться працювати над собою, я перевершую вас».

Донести до них якусь думку — справа не з легкіх. Навіть не думайте про *миттєвий* і нищівний розгром. Якщо так подумати, у дебатах публічних ви могли б здобути перемогу. На жаль, не можна просто так взяти і сказати: «Прешановне панство дурнів, ви не розумієте і йоти Кількісного шляху, а ваші переконання, які ви так легковажно називаєте «певними», програють у достовірності нашим найслабшим гіпотезам». Описати словами цю різницю *гештальтів* — справа геть не легка, а в кількох словах — і поготів.

То які риторичні прийоми варто було б спробувати перед аудиторією? Складно сказати... хоча можна навести щось на кшталт того:

- «Науковці черпають силу зі здатності змінювати свій погляд та визнавати його помилковість. Якщо ви не визнаєте своїх помилок, то аж ніяк не станете від того рідше помилятися».
- «Будь-хто може *сказати*, що певен на всі сто. А от зовсім не припускатися помилок дещо важче. Науковці розуміють це, тому не кажуть, що повністю певні у чомусь. Отак і живуть. Ні, у них немає конкретного приводу не довіряти теорії: навіть коли кожнісіньке свідчення на своєму місці, усі зорі та

планети вишиковуються так, як описує та єдина гіпотеза, науковці все одно не скажуть, що вони абсолютно певні. А все тому, що у них вищі стандарти. Це не означає, що науковці мають менше підстав для певності, ніж, скажімо, політики, які здаються певними щодо всього».

- «Науковці використовують словосполучення “не до кінця певен” не в тому повсякденному значенні, до якого ви звикли. От ви, скажімо, пішли до лікаря здати тест на кров. Лікар повертається і каже: “Прийшов результат Вашого тесту. І ми не до кінця певні, чи Ви не зроблені з сиру. А також, до речі, є ненульовий шанс, що у тонкій кишці вашого тракту двадцять жабенят Пепе співають áрії”. Тікайте куди очі бачать — вашому лікарю потрібен лікар. Коли ж цю фразу використовує науковець, він має на увазі, що ймовірність помилки настільки мала, що її навіть не можна буде розгледіти в електронний мікроскоп. Однак якщо за якимось неймовірним збігом обставин у вас знайдуться свідчення протилежного, науковець захоче побачити їх».
- «Чи змінили б ви свою думку, у якій почуваєтеся “певними”, якби побачили достатньо свідчень протилежного? Уявімо, що сам Господь зійшов з Небес і повідав, що вся релігія — суцільна правда, крім Непорочного зачаття. Якщо ця подія змінить вашу думку, ви вже не можете сказати, що на всі сто певні Непорочного зачаття. З технічних причин теорії ймовірностей усе ж є теоретична можливість, що ви зміните свою думку стосовно чогось, тому ваша певність не може повністю дорівнювати одиниці. Непевність може бути крихітнішою за пиліну, але її наявність необхідна. А якщо ви не зміните свою думку, навіть якщо сам Бог сказав вам протилежне, то у вас проблема: ви відмовляєтеся визнавати свою неправоту, і цю проблему я, простий смертний, вже не зможу пояснити вам словами».

Ще цікавіше це питання звучатиме так: що ви можете сказати *не* перед аудиторією, а сам-на-сам з опонентом? Як можна розпочати довгий процес навчання мистецтва жити у цьому все-світі без певності?

Гадаю, спершу слід прищепити розуміння, що жити без певності взагалі-то *можливо*. Якщо гіпотетично ви не можете бути певними ні в чому у цьому світі, це не означає повну втрату можливості відрізнити моральне від аморального, свідчення від вигадки. Десь так про це писала Лóїс Буджолд: «Не тисни так сильно — меншим буде опір».

Один із найтиповіших аргументів *на захист* абсолютного авторитету я називаю «Аргументом від аргументу від сірого», який виглядає приблизно так:

- *Моральні релятивісти кажуть:*
 - Світ не ділиться на чорне та біле, тому
 - усе — сіре, тому
 - ніхто не кращий за когось іншого, тому
 - я можу робити що заманеться, і ви не зможете мене зупинити, бугага.
- Але ж ми повинні вміти перешкоджати вбивствам.
- Тому повинен існувати спосіб, як бути абсолютно певним.
Інакше — моральні релятивісти переможуть.

Обернена дурість не породжує тямучість. Переінакшуючи *кожен* рядок аргументу, що веде до поганого висновку, ви не отримаєте правильну відповідь, адже такий підхід дозволить дурневі маніпулювати вами щонайрізноманітнішими способами. Щоб математичний аргумент мав сенс, кожен рядок має бути правильним. Як із того, що Сталін вірив у те, що два та два — чотири, не слідує, що вираз « $2 + 2 = 4$ » хибний, так і з того, що моральні релятивісти кажуть, що світ не ділиться на чорне та біле, не впливає, що це твердження хибне. Помилка (і

вона лише одна) виникає при стрибку від двоколірного до одноколірного бачення: мовляв, усі відтінки сірого на один манір.

Щоб погодитися із початковою тезою про те, що моральність потребує повного знання про безперечно гарні та погані рішення, довелося б взагалі поступитися цілим аргументом. Можна мати непевні знання про відносно кращі та відносно гірші рішення і робити вибір. І зовсім не варто робити з цього трагедію, адже ось вона — буденність у всій її простоті.

Так, якщо ви змушені обирати між А та Б і якимось чином вам вдалося сформулювати добре зважену певність у 100%, що А цілком і повністю прийнятне, а Б — сума усіх зол та апофеоз огиди, тоді це *достатня* умова, щоб віддати перевагу А. Та *обов'язковою* вона не є.

Точно, ледь не забув. Є ж іще така логічна хиба, як звернення до наслідків переконання.

Так... Що ще їм треба знати? У спільноті раціоналістів є ціла культура, частиною якої сумніватися, ставити щось під питання і визнавати помилки не є чимось ганебним.

А також є уявлення про збір інформації шляхом *спостереження за явищами*. Ніхто нікого нікуди не навертає. Коли ви до чогось придивляєтеся, іноді до вас приходить розуміння, що ці речі не такі, якими ви їх спочатку уявляли. Але це не означає, що Природа вам брехала або що ви маєте відвести погляд.

Урешті-решт є поняття належно каліброваної впевненості: «ймовірність» не прирівнюється до вашого внутрішнього індикатора прогресу, яким ви міряєте свою емоційну прив'язаність до ідеї. Це радше мірило, яке показує те, як часто висловлювання людей на певному рівні певності відображають дійсний стан речей. Якщо взяти сто людей і попросити їх висловити сто суджень, у яких вони певні на всі сто, скільки з них будуть вірними? Спойлер: не сто.

Зрештою, твердження, у яких люди щиро переконані, *набагато менш* імовірні, ніж твердження на кшталт «Розміри Сонця перевищують розміри Місяця», які здаються надто очевидними, щоб ними захоплюватися. На кожне твердження, у

якому хтось «на всі сто певен», гадаю, можна знайти когось, хто «на всі сто певен» у протилежному, оскільки таке фанатичне виголошення віри не постає з відсутності опозиції. Тому маленький внутрішній індикатор прогресу, що вимірює емоційну прив'язаність до переконання, не переводиться так легко у калібровану впевненість — він навіть не функціонує монотонно.

А тепер про «стовідсоткову певність». Якщо ви кажете, що якась подія станеться з імовірністю 99,9999%, звідси випливає, що десь протягом року ви можете висунути *один мільйон* рівнозначно незалежних тверджень, *один за одним*, і помилитися лише у середньому один раз. Просто неймовірно. (Дивовижно, якого рівня певності ми можемо набути для твердження «Ти не виграєш у лотерею».) Тому краще облишмо у спокої ймовірність 1.0. Щойно ви усвідомите, що для повноцінного життя ймовірність 1,0 вам *не потрібна*, то зрозумієте, наскільки безглуздо думати про можливість прийти до такої ймовірності людським мозком. Адже ймовірність 1,0 є не просто певністю. Це *нескінченна певність*.

Направду, мені думається: щоб запобігти непорозумінню з боку громадськості, науковцям, можливо, варто всюди торочити: «Ми не нескінченно певні» замість «Ми не певні». У звичайному дискурсі останній випадок нехай передбачатиме конкретний привід для сумнівів.

Як переконати мене у тому, що $2 + 2 = 3$

В есеї «Що таке свідчення?»¹ писав ось що:

«3 огляду на це раціоналісти приділяють аж настільки велику увагу, здавалось би, парадоксальному твердженню, що переконання *заслужує на існування* тоді і тільки тоді, якщо вас можна переконати у протилежному. Якщо після потрапляння світла на сітківку ока її стан не змінився, це означає, що ви осліпли. [...] На те цей стан і називають “сліпою вірою”. Якщо на вміст вашого переконання не впливає те, що ви бачите, то вашу сліпоту можна прирівняти до втрати очних яблук».

Ось що на це відповів Дзіхан Баран:²

«Я ніяк не можу второпати, за якої умови вираз “ $2 + 2 = 4$ ” взагалі може виявитися хибним. Може, тому що моя віра у те, що $2 + 2 = 4$, безумовна».

Визнаю: я так само не можу збагнути, як вираз « $2 + 2 = 4$ » може *виявитися* хибним. (Щоправда, можна переозначити його компоненти, але тоді ми говоримо не про ситуації. Не про «2», «4», «=» чи «+».) Проте звідси не випливає, що моє переконання безумовне. Ніщо не заважає мені уявити ситуацію, за якої вам удалося б *переконати* мене у тому, що $2 + 2 = 3$.

От одного ранку я прокидаюся, дістаю пару затичок для вух, кладу її на тумбочку коло іншої пари і бачу три, а не чотири затички, як я того очікував, спираючись на моє гадане знання про « $2 + 2 = 4$ », причому жодна з них не випарувалася і не впала з неба. Ба більше, коли я відтворював цей процес у своїй свідомості, дійшов до того, що для того, щоб хх і хх давали хххх, потрібен додатковий х, який виникає нізвідки; і це, до того ж, не

1. Див.: книга «Мапа і територія». — Прим. авт.

2. Коментар: https://lesswrong.com/lw/jl/what_is_evidence/f7h. — Прим. авт.

узгоджувалося з іншою арифметикою, яку я уявляв, оскільки, віднявши xx від xxx , отримуємо xx , а віднявши xx від $xxxx$ — xxx . Такий розвиток подій зовсім не узгоджувався б з моїм попереднім знанням про те, що $3 - 2 = 1$. Проте переконавшись на власні очі, що $xxx - xx = xx$, я вирішую, що тепер моя пам'ять геть не надійна.

А опісля я потягну руку до кишенькового калькулятора, звернуся до гугла і почну шукати свій примірник «1984», в якій Вінстон пише, що «Свобода — це можливість сказати, що два плюс два буде три». Усі наведені приклади закономірно свідчитимуть про те, що решта світу поділяє моє ментальне відтворення, а ненадійні спогади про те, що два та два — чотири, відкидає.

Як я взагалі міг дозволити ошукати себе настільки, щоб повірити у те, що два та два — чотири? На думку спадають два пояснення. Перше — неврологічне порушення (імовірна причина — чхання), внаслідок якого у моїй пам'яті суми доданків збільшилися на один. Друге — чийсь розіграш: хтось піддав мене гіпнозу або я перебуваю у комп'ютерній симуляції. У другому випадку я більше покладатимуся на версію, що хтось зіпсував мою арифметичну *пам'ять*, аніж на те, що два та два — *насправді* чотири. Проте жодне із цих правдоподібних пояснень не завадить мені помітити моє *щире* спантелечення.³

Іншими словами: у тому, що $2 + 2 = 3$, мене переконують ті самі свідчення, на котрих тримається моє переконання у тому, що $2 + 2 = 4$. Тобто — перехрещення таких свідчень, як спостереження, ментальне відтворення та суспільна домовленість.

Колись я й уявлення не мав про те, що $2 + 2 = 4$. Я прийшов до цього нового переконання не випадково, адже на те, чому мій мозок зрештою запам'ятав вираз « $2 + 2 = 4$ », а не « $2 + 2 = 7$ », були особливі причини. Те, що мій мозок зберігає відповідь, напрочуд схожу на стан справ, коли я кладу пару вушних затичок до іншої пари, потребує пояснення, як саме сплутаність породжує це дивне відображення реальності у дзеркалі мого розуму.

3. Див. «Сила раціоналіста» у книзі «Мапа і територія». — Прим. авт.

Насправді для фактуального переконання є лише дві можливості: або воно виникло через процес сплутування розуму з реальністю, або ні. Якщо ж сплутування не відбулося, переконання не може бути правильним, за винятком збігу обставин. Якщо ж переконання містять у собі бодай крихту внутрішньої складності (щоб її відтворити, необхідна, наприклад, комп'ютерна програма за складністю більш ніж 10 бітів), простір можливих сценаріїв настільки розлогий, що можливість збігу обставин просто нівелюється.⁴

Безумовні факти не тотожні безумовним переконанням. Якщо сплутані з реальністю свідчення переконують мене, що певний факт є безумовним, це не означає, що я завжди вважав його таким без потреби в цих свідченнях.

Я вірю у те, що два та два — чотири, і мені не складно уявити ситуацію, за якої я би змінив свою думку на користь виразу « $2 + 2 = 3$ ». Зрештою, це та сама ситуація, завдяки якій я тримаюся переконання, що два та два — чотири. Тому у мене і немає страху стати жертвою сліпої віри.⁵

4. Більше про формування переконань та віру у спостереження читайте в есеях «Відчувати — раціонально» та «Що таке свідчення?» у книзі «Мапа і територія». Про складність переконання читайте в есеї «Лезо Оккама» у тій самій книзі. — Прим. авт.

5. Якщо Ви християнин, свідомий теореми Баєса, чи можу я запитати, яка ситуація може переконати Вас ув істинності ісламу? Припускаю, та сама, внаслідок якої Ви здобули віру у Христа. Що якби Ви вийшли із лона мусульманки, Вас виховали батьки-мусульмани, які день у день торочили Вам: хай би там що стається у житті, головне — безумовно вірити в іслам? Чи є ще якісь свідчення чи підстави? Яка ситуація переконала б Вас повернутися в іслам чи бодай зректися християнства? Наскільки Ви впевнені, що загальних свідчень та аргументів, до яких апелюєте, вистачило б, щоби переконати Вас відмовитися від своєї релігії, якби Ви виростили мусульманином? — Прим. авт.

Довічна певність

Весеї «Безумовний авторитет» я стверджував, що вам *не потрібна* нескінченна певність:

«Якщо ви змушені обирати між А та Б і якимось чином вам вдалося сформулювати добре зважену певність у 100%, що А цілком і повністю прийнятне, а Б — сума усіх зол та апофеоз огиди, тоді це *достатня* умова, щоб віддати перевагу А. Та *обов'язковою* вона не є. [...] Можна мати непевні знання про відносно кращі та відносно гірші рішення і робити вибір. І зовсім не варто робити з цього трагедію, адже ось вона — буденність у всій її простоті».

Говорячи про твердження « $2 + 2 = 4$ », ми маємо розділяти мапу і територію. З огляду на спостережувану постійність та універсальність фізичних законів за всю історію всесвіту, ми можемо говорити про те, що жодна частинка не перевищувала швидкість світла. Тобто те, що немає нічого швидшого за світло, є правдою не просто у 99%, 99,9999% чи в (1-1/гутолплексна) випадках, а *правдою в останній інстанції*.

Та чи можемо ми бодай колись бути *абсолютно певними* у тому, що немає нічого швидшого за швидкість світла, — це вже зовсім інше питання. Мапа — не територія.

Те, що студент списав розв'язок свого завдання, може бути цілковитою правдою. Проте наявність у вас засвідчень списування (уже не кажучи про *абсолютну* певність у цьому) — це вже інша справа. Якщо ви підкинете монетку і не відразу поглянете, щоб випало, цілком можливо, що це «число», хоча жодних підстав для того у вас може і не бути. Адже ступінь непевності не можна прирівняти до ступеня істинності чи частотності події.

Те саме стосується і математичних істин. Викликає сумніви твердження, що вираз « $2 + 2 = 4$ » чи « $SS0 + SS0 = SSS0$ в арифметиці Пеано» може бути *істинним* у суто абстрактному

вимірі поза фізичними системами, які функціонують у спосіб, подібний до аксіом Пеано. Після цих слів я забіжу наперед і припущу, що незалежно від того, у якому контексті вираз « $2 + 2 = 4$ » є істинним, він завжди і точно істинний, а не просто наближений до істини («два плюс два насправді дорівнює 4,0000004») або істинний у 999 999 999 999 випадках з 1 000 000 000 000.

Я не до кінця певен, що саме лексема «істинний» має означати у цьому випадку, але це не заважає мені триматися свого припущення. Надійність твердження «вираз “ $2 + 2 = 4$ ” є завжди істинним» суттєво вища за надійність будь-якої філософської позиції на те, що означають слова «істинний», «завжди» чи «є» у вищенаведеному твердженні.

Однак із цього не випливає, що я *абсолютно певен* у тому, що $2 + 2 = 4$. Про це я писав у попередньому есеї «Як переконати мене у тому, що $2 + 2 = 3$ ». Власне, тими самими засвідченнями, які переконали мене у тому, що $2 + 2 = 4$. Тому що я міг просто вимислити усі ті попередні засвідчення або неправильно запам'ятати їх. Повірте: в анналах нейробіології є куди дивніші неврологічні розлади.

Отже, якщо й наділяти твердження « $2 + 2 = 4$ » якоюсь імовірністю, якою вона має бути? У цьому випадку ми ставимо мету налаштувати своє калібрування, себто зробити так, щоби події, які ви наділяєте 99% ймовірністю, сталися у 99 випадках зі 100. А це достобіса складніше, ніж здається. Візьміть і попросіть сто людей назвати по десять тверджень, у яких вони певні на 99%. Думаєте, що з тисячі тверджень десять виявляться хибними?

Я не робитиму огляд власне експериментів про калібрування — ви можете ознайомитися із ними в есеях про когнітивні упередження та ризик глобальних катастроф,¹ — оскільки я вже пересвідчився: коли заявляю про такі речі аудиторії без належної підготовки, вона використовує їх як Загальний

1. Eliezer Yudkowsky, “Cognitive Biases Potentially Affecting Judgment of Global Risks,” in *Global Catastrophic Risks*, ed. Nick Bostrom and Milan M. Ćirković (New York: Oxford University Press, 2008), 91–119.

Контраргумент. І чомусь він спадає на думку, коли цим людям доводиться занижувати певність у тій думці, яка їм не до вподоби, але зі своїми опініями таке вже не проходить. Тому-то я намагаюся уникати розмов про експерименти з калібрування, крім тих випадків, коли структуровано викладаю тему раціональності і викладаю у свої слова застереження про ангажований скептицизм.

Зі своїх спостережень можу сказати, що рівень калібрування людей, які кажуть, що вони певні чогось на 99%, не дотягує до того ж рівня точності.

Припустімо, ви скажете, що певні на 99,99% у тому, що $2 + 2 = 4$. Отже, ви заявили, що можете зробити 10 000 *незалежних* тверджень, на які покладаєте той самий відсоток упевненості, і помилитеся у середньому один раз. Можливо, для твердження « $2 + 2 = 4$ » такий надзвичайний рівень упевненості і спрацював би, адже воно до неподобства просте що математично, що емпірично, а також широко поширене у суспільстві (передається не із пристрасним піднесенням, а просто береться за належне). Що ж, можливо, на цьому твердженні вам удасться дістатися певності на 99,99%.

А от на твердженні «53 — просте число» ви навряд чи змогли б дістатися певності у 99,99%. Так, воно здається ймовірним, але поки ви намагатиметеся встановити протоколи, які дозволятимуть вам заявляти 10 000 *незалежних* тверджень такого ґатунку — не просто твердження про прості числа, а щоразу новий протокол, — ви зазнаєте невдачі частіше, ніж раз.²

І все ж мапа не територія. Якщо я скажу, що я на 99% певен у тому, що $2 + 2 = 4$, це не означає, що у моїй голові твердження « $2 + 2 = 4$ » маркується як істинне тільки з точністю до 99% або істинне у 99 випадках зі 100. Твердження, на яке я покладаю свою певність, звучить як «вираз “ $2 + 2 = 4$ ” завжди і точно

2. З цього приводу у Пітера де Бланка є кумедний анекдот: <https://www.spaceandgames.com/?p=27> (<https://web.archive.org/web/20090203013258/http://www.spaceandgames.com/?p=27>). (Я казав йому не робити того знову.) — Прим. авт.

істинний». Аж ніяк не «вираз $2 + 2 = 4$ » зазвичай у більшості випадків істинний».

А щодо думки, що можна мати стовідсоткову певність у математичному твердженні, — та невже! Коли ви кажете про певність на 99,9999%, ви маєте на увазі, що можете зробити *мільйон* однаково небезпечних тверджень, один за одним, і помилитися у середньому бодай раз. На це у вас може піти близько року, причому ви маєте стверджувати щось кожні 20 секунд 16 годин на день.

Заявляєте про певність на 99,9999999999% — збільшуєте число тверджень до трильйона. Тепер ви маєте продукувати твердження сто людських життів поспіль і не помилитися жодного разу.

Заявіть про певність на $(1-1/\text{гуголплексна})$ — і ваше роздуте его перевершить тих, хто вважає себе Богом.

А гуголплекс — число набагато менше навіть на фоні немислимо величезних чисел, як-от $3 \uparrow \uparrow \uparrow 3$. Проте навіть певність на $(1-1/3 \uparrow \uparrow \uparrow 3)$ не набагато ближча до ЙМОВІРНОСТІ 1, ніж певність на 90%.

А якщо все перелічене зазнає краху, тоді вже гіпотетичні агенти Сміти, які прямо зараз втручаються в оцінку достовірності цього речення вашим мозком, стануть на заваді і вбережуть вас від лиха нескінченної певності.

Чи я навіки-віків певний цього?

Йойки — звісно ж, ні.

Як казав колись Рафал Смігродський:

«Я б сказав, що ви маєте наділяти математичні поняття, необхідні для виведення теореми Баеса, ймовірністю меншою за одиницю, що не виливається у її знецінення на практиці. Я не повністю певен того, що маю завжди бути непевним. Можливо, я виявлюся правим на цілком законних підставах. Та щойно я присвоюю твердженню ймовірність 1, я більше ніколи не зможу змінити її. Тоді, хай би там що я побачив чи дізнався, я муситиму

відкидати усе, що суперечить цій аксіомі. Мені зовсім не до вподоби ідея, що я більше ніколи не зможу змінити свою думку».

0 та 1 не належать до ймовірностей

1, 2, 3 — цілі числа. Як і -4. Просуватиметесь уперед додатними чи назад від'ємними — життя не вистачить, щоб злічити усі цілі числа. Проте ви ніколи не дійдете до того, що називають «плюс нескінченність» чи «мінус нескінченність», тому вони і не належать до множини цілих чисел.

Хоча що плюс, що мінус нескінченність не належать до цілих чисел, вони являють собою спеціальні символи, які позначають властивості цілих чисел. Буває, кажуть: « $5 + \infty = \infty$ », адже якщо почати рахувати з п'яти і не зупинятися, ви отримуватимете числа з усе більшою кількістю цифр, але так і не завершите почате. Але з цього не слідує, що $\infty - \infty = 5$. Неможливо почати рахувати від нуля без упину, потім змінити напрямок у зворотний бік і врешті-решт закінчити на п'ятірці.

На цьому прикладі ми бачимо, що нескінченність не тільки не входить до множини цілих чисел — вона *виконує зовсім інші функції*. Якщо ви спробуєте абияк змішати нескінченності із цілими числами, вам знадобляться різного штибу нові особливі і, на перший погляд, непослідовні властивості, непотрібні для одиниці, двійки, трійки та решти *дійсних* цілих чисел.

Проте навіть якщо нескінченність не належить до ряду цілих чисел, нема чого непокоїтися через втрачені числа. Люди можуть налічити п'ятьох овець, мільйони піщинок та септильйони атомів, однак ніхто ще не дорахувався до нескінченності. Те саме стосується і неперервних величин: люди вимірюють порошинку міліметрами, тварин — метрами, міста — кілометрами, галактики — тисячами світлових років, проте не знайшлося ще такої людини, яка б виміряла щось нескінченністю. Тому у

дійсному світі вам не так уже й *потрібна* уся повнота тієї нескінченності.¹

Зазвичай імовірності використовують як простір між нулем та одиницею. Імовірність того, що випаде «число», становить 0,5. Синоптик прогнозує на завтра дощ з імовірністю 0,9.

Однак це не єдиний спосіб застосування ймовірностей. Наприклад, їх можна перетворити на шанс за допомогою формули $O = (P/(1 - P))$. Так, імовірність у 50% перетворюється на шанс 0,5/0,5 (або 1), який зазвичай записують як 1:1, тоді як імовірність 0,9 — на шанс 0,9/0,1 (або 9), який зазвичай записують як 9:1. Для перетворення шансу на ймовірність застосовують формулу $P = (O/(1 + O))$. Вона є зворотним відображенням попередньої формули. Отже, ймовірності та шанси ізоморфні, а використовують їх залежно від того, яка зручніша.

Наприклад, коли ви виконуєте баєсівське оновлення даних, зручніше користуватися шансами. От я підкидаю шестигранний кубик. Якщо випадає будь-яка грань, крім одиниці, я почую дзвоник з імовірністю 10%, проте якщо випаде одиниця, я почую дзвоник з імовірністю 20%. Я підкидаю кубик і чую дзвоник. Який *шанс* того, що випала одиниця? Що ж, апріорний шанс становить 1:5 (у дійсних числах — $\frac{1}{5} = 0,2$), відношення правдоподібності — 0,2:0,1 (у дійсних числах — 2). Я можу просто помножити шанс на відношення й отримати апостеріорний шанс 2:5 (у дійсних числах — $\frac{2}{5}$, або 0,4). Тоді, якщо захочу, я переводжу це число у ймовірність й отримаю $0,4/1,4 = 2/7 = \sim 29\%$.

Тому-то при баєсових оновленнях зручніше оперувати шансами, адже якщо ви користуєтеся імовірностями, доведеться застосовувати ускладнену версію теореми Баєса. А от імовірностями легше відповідати на питання стибу «Якщо я підкину

1. Для більш обізнаних читачів маю зазначити, що їм зовсім не обов'язково починати вистукувати по клавіатурі уточнювальні подробиці про різницю між трансфінітними та кардинальними числами. Я свідомий існування різних концепцій у теорії множин, однак не бачу сенсу вносити їх до теорії ймовірностей. — Прим. авт.

шестигранний кубик, який шанс того, що випаде цифра від 1 до 4?»». Можна додати ймовірності $1/6$ для кожної сторони й отримати $4/6$, але не можна додавати співвідношення шансів, яке становить $0,2$ для кожної сторони, й отримати $0,8$.

Що намагаюся усім цим сказати? Відношення шансів — виправданий спосіб мапувати фактори невизначеності на дійсні числа, як і ймовірності. Відношення шансів принагідні для одних операцій, ймовірності — для інших. Як показує доведення, відоме під назвою теорема Кокса (а також її різні доповнення та доопрацювання), усі способи представлення факторів невизначеності, які дотримуються певних логічних обмежень, зрештою, ізоморфні між собою.

Навіщо взагалі перейматися тим, чи відношення шансів так само виправдане, що й ймовірності? Ймовірності зазвичай сприймають як простір між нулем та одиницею, обидва виглядають легкодоступними величинами: не виникає проблем із тим, щоб побачити одну зебру або нуль єдинорогів. Проте коли ви перетворюєте ймовірності на відношення шансів, нуль залишається нулем, а одиниця перетворюється на плюс нескінченність. І от тепер кінцева істина вже не виглядає настільки легкодоступною.

Логарифм шансів ще більше спрощує обробку баєсових оновлень даних. Саме через цю призму Едвін Тімпсон Джейнз радив сприймати ймовірності. Скажімо, апіорна ймовірність якого-небудь твердження становить $0,0001$, що відповідає -40 децибелам логарифма шансів. Потім вам трапляється свідчення, яке у сто разів ймовірніше, якщо твердження істинне, ніж якщо воно хибне. Таке свідчення має силу 20 децибелів. Отже, апостеріорний шанс становить близько $-40\text{дБ} + 20\text{дБ} = -20\text{дБ}$, що дорівнює $\sim 0,01$ у ймовірностях.

Коли ви перетворюєте ймовірності на логарифм шансів, нуль стає мінус нескінченністю, а один — плюс нескінченністю. Тепер що нескінченна певність, що нескінченна неймовірність уже не видаються такими досяжними.

Коли мова заходить про ймовірності, $0,9999$ від $0,99999$ відділяє всього-на-всього $0,00009$, тож відстань між $0,502$ та $0,503$

набагато більша за ту, яка між 0,9999 та 0,99999. Здається, щоб перестрибнути від 0,99999 до 1, варто зробити невеличкий крок розміром у 0,00001.

Та при переході до відношення шансів 0,502 та 0,503 стають 1,008 та 1,012, а 0,9999 та 0,99999 — 9,999 та 99,999. При переведенні у логарифм шансів 0,502 та 0,503 стають 0,03 та 0,05 децибелами, однак 0,9999 та 0,99999 — 40 та 50 децибелами.

Коли маєте справу із логарифмом шансів, **відстань між двома значеннями невизначеності дорівнює кількості свідчень, необхідних для переходу від одного до іншого.** Саме тому логарифм шансів дає справжню оцінку простору між значеннями впевненості.

Використовуючи логарифм шансів, ви усвідомлюєте, що досягнення абсолютної певності потребує нескінченно переконливих свідчень, як і абсолютна маячня потребує нескінченно переконливих контрсвідчень.

Ба більше, в усіх стандартних теоремах теорії ймовірностей є особливі випадки, в яких описуються спроби вставити в них одиниці або нулі. Наприклад: що станеться, якщо спробувати виконати баєсівське оновлення даних для спостереження, якому присвоїли ймовірність 0?

Тож я і пропоную винести одиницю та нуль за межі ймовірностей. Зрештою, мінус та плюс нескінченності не додержуються аксіом поля, тому і не вважаються дійсними числами.

Головна причина, чому це може засмутити теоретиків ймовірностей, полягає в тому, що нам довелося б заново виводити теореми, які раніше спиралися на припущення, що ми можемо проінтегрувати функцію двох змінних по одній із них.

Попри це, у дійсному світі під час підкидання кубика не може бути нескінченної певності у тому, що випаде якесь число між одиницею та шісткою. Кубик може приземлитися на ребро, його може збити метеорит. Або ж агент Сміт може непомітно дописати «37» на одній із граней.

А от якби ви винайшли магічний символ, що означав би «усі можливі варіанти, які я не врахував», тоді ви могли б розкласти

усі події з урахуванням цього магічного символу. Так і дійшли б до магічного символу T , який позначає нескінченну певність.

Але тоді я би прийшов і спитався, чи є якийсь спосіб вивести теорему без застосування магічних символів з якимись особливими властивостями. Погодьтеся: спосіб без магічних символів і властивостей виглядає більш доладним. Як деякі математики відмовляються вірити у закон виключеного третього або нескінченних множин, я буду тим теоретиком імовірностей, який відмовляється вірити в абсолютну певність.

Та не однаково мені, чи будете ви раціональними

У коментарях до есею «Лотереї: примарна надія» деякі користувачі взялися докоряти мені тим, хто я, мовляв, такий, щоб критикувати рішення інших людей. Чи не однаково мені до того, що хтось вирішив зіграти в лотерею? Це питання можна вважати частиною більш загального. Чому я пхаю свого носа у чийсь вибір вірити у щось приємне, а не істинне? Чи не може кожен сам для себе вирішити, чи варто йому опікуватися тією істиною?

Очевидно, у відповідь я міг би завдати удару різкого: «З якого це дива *віс* обходить те, чи *мене* обходить, чи *когось* обходить істина?». Я вбачаю певну непослідовність у тому, що ваша функція корисності передбачає негативний член для функції корисності іншої людини, яка містить член функції корисності для іншої людини. Але я не волів би так відповідати.

Я вірю у те, що чиню правильно і відповідно для людини, яка має інтерес до того, якою людська цивілізація постане у майбутньому. Один із таких інтересів — людське прагнення істини, яке повільно посилювалося протягом поколінь (адже Наука існувала не завжди). Тому я й прагну ще більше посилити те прагнення у *нинішнього* покоління. Прагну заради майбутнього. Позаяк усі ми граємо на одній широкій шахівниці, хоч дехто не бере на себе ту відповідальність.

Тому і не однаково *мені*, чи будете *ви* раціональними.

Чи небезпечна ця думка? Авжеж — і «небезпечна» не в тому плані, коли вам лоскотують нерви. Людей спалювали живцем, бо якийсь священник вирішив, що бідолаха думав неналежним чином. Хіба самé рішення засудити людину до спалення живцем через її, мовляв, неналежні думки не видається вам обурливим? Навряд чи ви хотіли б, щоб люди мислили у такому дусі, бо

навіть думка про такий спосіб мислення викликає *відразу*. Тому треба щось робити з тими людьми, які так мислять...

Згоден! Ось моя пропозиція: виступаймо проти поганих ідей так, щоб дискусія *не* закінчувалася спаленням їх носіїв на багатті.

Силогізм, якого ми прагнемо уникати, звучить як «Сьюзі жене химери, тому її треба спалити на вогнищі». Проте, намагаючись уникнути цього силогізму, дехто починає вважати неетичною думку про те, що Сьюзі жене химери. Ніхто ніколи не повинен нікого судити. Кожен, хто судить, учиняє страшний гріх, і його мають публічно покарати за це.

Дозвольте-но мені *переписати* цей силогізм: «Я думаю, що Сьюзі жене химери, *тому* я сперечатимуся із її заявою, але не спалюватиму на вогнищі і не затикатиму їй рота примусом чи будь-яким іншим законним шляхом».

Усі ми граємо на одній широкій шахівниці, і я зацікавлений у тому, щоб зробити гру чесною. У засадах науки закладена думка, яка суперечить інтуїції багатьох людей: суперечки про стан справ потрібно вирішувати за посередництва експериментів і математики, а не насилля чи непорушних законів. Цю думку можна реалізовувати і поза межами науки — сформувані чесні правила боротьби за майбутнє. Перемагати переконуючи, а не спалюючи. Таким є один із принципів раціональності, якому я присягнув на вірність.

Борці за релятивізм чи егоїзм насправді не виглядають мені по-релятивістськи чи егоїстично налаштованими. Якби вони дійсно були релятивістами, то не бралися б судити. Якби вони справді опікувалися лиш особистими інтересами, то заробляли б собі гроші, а не палко сперечалися у коментарях. Схоже на те, що вони стали на бік релятивізму, щоб досягнути своєї цілі — не давати гравцям (*усім* гравцям) виносити певні судження. А позиція егоїзму слугує меті зробити з *усіх* гравців егоїстів. А потім вони вже беруться грати — за чесними правилами чи ні, залежить від їхньої тямущості.

А як і є справжні релятивісти чи егоїсти, ми не чуємо і не бачимо їх на шахівниці.

Мене не може не обходити ваш спосіб мислення (інакше — я був би сліпцем), оскільки щоразу, коли людина відвертається від правди, наша історія стає на краплю темнішою. Так, у багатьох випадках та темрява не значна. (Зрештою, не *завжди* хтось страждає через відвернення від правди.) Самообманом, якщо займатися ним тихенько у підсобці своєї свідомості, ви не кидаєте тінь на нашу історію так, якби брехали на загал або спалювали людей на вогнищі. Хоча і є та частина мене, яка не може не сумувати. Оскільки я *не* намагаюся спалити вас на вогнищі — а тільки сперечаюся з вашими ідеями, — я вірю у те, що чиню правильно і належно як для людини, якій не байдужі інші. І цю позицію я б теж волів передати у спадок майбутнім поколінням.

Політика та раціональність

Політика — губитель розуму

К оли розмова заходить за політику, у головах людей починаються якісь дивні процеси. Еволюційні причини цих процесів настільки очевидні, що їх просто не можна ігнорувати. У середовищі предків політика була питанням життя і смерті. А також питанням продовження роду, доступу до ресурсів, наявності союзників та репутації... Тепер, коли ви заводите суперечку про те, чи маємо «ми» підвищувати мінімальну зарплатню, у вашому мозку активується механізм поведінки, випрацьований у середовищі предків: займете неправильну позицію у спорі — вас можуть вбити; займете *правильну* позицію — уже *ви* можете вбити ненависного суперника!

Якщо ви хочете говорити про науку або раціональність, моя вам порада: не обирайте тему, яка стосується *сучасної* політики, якщо ви маєте можливість оминати її. Якщо у спорі не вдається не зачіпати політику, заведіть розмову у русло діяльності Людовика XVI за часів Французької революції. Політика — важлива сфера людського життя, до якої кожен із нас має підходити з усією розважливістю, однак *навчатися* раціональності на темах, дотичних до політики, — жахливий вибір, якщо не всі учасники дискусії достатньо вправні у раціональності.

Іншими словами, політика — це продовження війни. Аргументи — це солдати. Щойно ви розумієте, на чий бік стали, мусите підтримувати усі аргументи вашої сторони і нищити ворожі. Інакше — ви б'єте своїм же у спину, діючи на користь ворога. Навіть люди, які у професійному житті ретельно і неупереджено зважують усі сторони питання, можуть раптово перетворитися на гаслолюбних зомбі, коли стикаються з позицією «синіх» чи «зелених».

Для прикладу наведу стандартну проблему у сфері штучного інтелекту, а саме у галузі немонотонної логіки: «Усі квакери¹ —

1. Квакерство — протестантська конфесія у християнстві. — Прим. пер.

пацифісти. Усі республіканці проти пацифізму. Ніксон — квакер та республіканець. Ніксон — пацифіст?»

До чого тут узагалі Ніксон? Щоб збурити політичні емоції у читачів та відвернути їх від головного питання? Щоб змусити республіканців почуватися не в своїй тарілці й віднадити їх від роботи у сфері штучного інтелекту?²

Навіщо комусь підбирати такий *відволікальний* приклад для демонстрації немонотонної логіки? Можливо, тому що його автор не зміг встояти перед спокусою дати добрячого ляпаса тим ненависним «зеленим». Та-а-ак, це *солодке* відчуття дати комусь смачного ляща, а втриматися від нього настільки ж важко, як і від куска шоколадного пирога.

Але не все те корисне, що смачне.

Ні, я не агітую за аполітичність чи нейтральну точку зору, якої намагаються дотримуватися у Вікіпедії. Однак якщо можна не давати ляпаса, спробуйте опиратися цьому бажанню. Якщо ваша тема дійсно стосується спроб заборонити у школах викладання еволюції — сміливо говоріть про цю конкретну проблему, але не потрібно прямо звинувачувати Республіканську партію. Дехто з ваших читачів може виявитися республіканцем, котрий може вважати, що проблема у кількох негідниках, а не в усій партії. Навіть за мірками нейтральної точки зору немає значення, чи (на вашу думку) Республіканська партія *винна* в усіх бідах. Тому що на користь спільноті йде обговорення проблеми без згадування політичних кольорів.

2. До речі, я не зараховую себе ні до республіканців, ні до демократів. — Прим. авт.

Небезпека односторонніх політичних дебатів

Якось Робін Хансон запропонував ідею магазинів, у яких дозволено продавати заборонені товари.¹ На користь такої політики можна навести низку вагомих аргументів: невідчужне право на особисту свободу, кар'єрний стимул для бюрократів забороняти *усе*, до чого дотягуються руки, — адже законодавці упереджені так само, як і прості громадяни. Але навіть якщо так, — відповів я — *якось* бідна, чесна і не надто освічена мати п'ятьох дітей піде в один із тих магазинів і придбає від артрити «Сірчаноокислотну мазь доктора Кашпіровського» і невдовзі помре, а діти, ставши сиротами, будуть оплакувати її на якомусь горезвісному ток-шоу.

Я, власне, констатував небезпеку таких магазинів. Але з чого дехто взяв, що це був аргумент за регулювання?

Коли йдеться про прості істини (наприклад, чи постало життя на Землі завдяки природному добору), справедливо очікувати, що аргументація має бути односторонньою, адже дані або такі, або інші. А вже так званий баланс свідчень має відображати ті прості істини, оскільки, за баєсівським визначенням, «сильне свідчення» — якраз той вид свідоцтв, які ми очікуємо здобути, щоб знайти ту позицію в суперечці.

Проте коли мова заходить за комплексні заходи, які можуть вилитися у розмаїття наслідків, підстав займати односторонню позицію немає. Чому ж тоді люди прагнуть зробити *політичні* дебати односторонніми?

Тому що політика — губитель розуму. Аргументи — це солдати. Щойно ви розумієте, на чий бік стали, мусите підтримувати усі аргументи вашої сторони і нищити всі ворожі. Інакше — ви б'єте своїм же у спину. Якщо у вас панує такий умонастрій,

1. Robin Hanson et al., "The Hanson-Hughes Debate on 'The Crack of a Future Dawn,'" 16, no. 1 (2007): 99–126, <https://jetpress.org/v16/hanson.pdf>.

політичні дебати також видаватимуться вам однобокими, адже недоліки вашої улюбленої політики — ворожі солдати, яких треба розбити за будь-яку ціну.

Варто стеретися і схожого умонастрою: вважати, що курс Глибокої Мудрості — це компроміс з ідеальною рівновагою між двома політичними позиціями, які отримують найбільше етерного часу. У політичній стратегії і справді можуть бути *непропорційні* витрати або вигоди. Якби питання політичного курсу не були схилені на той чи інший бік, ми були б геть не здатні давати їм раду. Але разом з тим людям властиво заперечувати усі хиби улюбленої політичної позиції або переваги тієї, з якою не погоджуються. Звідси й думка про те, що політичні компроміси мають бути посунуті набагато ближче до їхньої позиції.

Якщо ви дозволите крамниці із забороненими товарами, якась бідна, чесна і погано освічена мати п'ятьох дітей купить щось таке, що призведе до її смерті. Такий наслідок цілком імовірний, тому застереження однозначне: розсудлива людина має визнати, що воно має невігдані підстави, хай би якої політичної позиції вона трималася. Можливо, ви вважаєте, що заборона деяких товарів просто призведе до їх подорожчання, що чиновники зловживатимуть своїми повноваженнями або що особиста свобода тієї жінки важливіша за ваше бажання втручатися у її життя. І попри це вона все одно помре.

Ми живемо у несправедливому всесвіті. Як і всі інші примати, люди не терплять відчуття несправедливості, звідси і сприйняття цієї ситуації як нестерпної. У суспільній свідомості побутують два методи подолання когнітивного дисонансу. Перший — змінити свій погляд на події, себто заперечити, що подія відбулася, або переписати історію так, щоб вона виглядала справедливою.² Другий — змінити свою моральну позицію, себто заперечувати несправедливий характер події.

Деякі лібертаріанці можуть відповісти: якщо хтось заходить до крамниці заборонених товарів, проходить повз стелажі із

2. Це зумовлено евристикою афекту та оманною справедливим світу. — Прим. авт.

написом «НЕБЕЗПЕЧНІ ДЛЯ ЖИТТЯ ТОВАРИ» і все одно щось та й купує, загибель споживача на його власній совісті — він заслужив таку смерть. Якби моральна правда була такою, не було б жодних проблем із крамницями, в яких продають заборонені товари. Крім *чистої вигоди*, ще й *односторонній* компроміс без негативних наслідків.

Інші стверджують, що чиновників можна навчити раціонального вибору, так що вони не йтимуть наперекір інтересам споживачів. Якби це відповідало дійсності, тоді (з їхньої моральної точки зору) не було б жодних проблем із законодавчим регулюванням.

Хочете ви того чи ні, а інтелект — це результат лотереї народження, хоча це один із тих випадків, коли всесвітня несправедливість настільки крайня, що багато хто обирає за краще заперечувати стан речей. Експериментальні дані суто генетичного компонента (частка спадковості становить 60–80%) досить переконливі. Та навіть якщо ви і їх відкинете, все одно ні виховання, ні початкову школу обираєте не ви.

Мене виховали з переконанням, що заперечувати реальність — це моральний злочин. Якби мої батьки виховували мене у парадигмі прийняття бажаного за дійсне, що, наприклад, сірчаноокислотна мазь корисна для мого здоров'я, я б робив те, від чого мене *застерігали* і що вважали неприйнятним. Дехто народжується у такому середовищі — винесемо за дужки гени, позаяк ця частина занадто несправедлива, — де місцевий знахар навчає, що віра — це *благо*, а скептицизм — *гріх*. Тож вони з доброї волі прислухаються до поради знахаря. І помирають. Адже, на відміну від вас, їх не виховали із переконанням, що люди відповідальні за особисте рішення наслідувати суспільний приклад. Чи ви справді вважаєте себе настільки тямущими, що змогли б залишитися вірними науковому скептицизму, навіть якби народилися 500 року нашої ери? Так, лотерея народження — цілком реальна річ, хай там які у вас уявлення про гени.

Казати «Люди, котрі купують небезпечні товари, заслуговують на страждання!» — це не прояв твердомисності, а спосіб закрити очі на несправедливість всесвіту. Бути по-справжньому твердомисним — казати: «Так, сірчана кислота — це жахлива і болісна смерть. Ні, та мати п'ятьох дітей її не заслуговувала. Однак ми все одно не закриємо ту крамницю, бо провели розрахунок витрат і вигод». Можете уявити собі політика, котрий сказав таке у своїй промові? От і я не можу. Але якщо вже економісти у змозі впливати на політику, то нехай уже висловлюють свої міркування у приватному порядку — може, нехай навіть напишуть про це у наукових статтях, огорнувши свою думку таким хитроплетивом слів, що ЗМІ не наважаться процитувати їх.

Не думаю, що чийсь дурний вибір і подальша смерть мають слугувати приводом для радощів. Особисто я сприймаю це як трагедію. Рятувати людей від наслідків їхніх вчинків — не завжди їм допомога; однак смертна кара — та межа, через яку я не готовий переступити з моральних міркувань. Мертві не вчаться на помилках.

Однак усесвіт, на жаль, не погоджується зі мною. Що ж, подивимось, хто стоятиме на ногах, коли це все скінчиться.

Терези Феміди, Записник Раціональності

Феміду заведено зображати із терезами у руках. Покладете щось на одну шальку — вона опуститься додолу, а інша підніметься. Так терези полегшують ведення обліку. Але водночас спотворюють саму концепцію.

У людській культурі цілком органічно виробилася звичка сприймати дискусію як форму боротьби, що є продовженням війни, як спорт урешті-решт. І як у будь-якому виді спорту, ви маєте рахувати, скільки очок набрала кожна команда. У грі на дві команди одне очко на користь однієї іде у мінус іншій. В аудиторії ж кожен слухач веде свій власний облік очок, які один учасник дискусії набирає проти іншого. Наприкінці дебатів мовець, який набрав більше очок, — очевидний переможець; тож усе, що він сказав, має бути правдою, а все, що каже переможений, — неправдою.

Під час дослідження під назвою «Евристика афекту в оцінюванні ризиків та переваг» експериментатори намагалися з'ясувати, чи його учасники плуталися у своїх судженнях про можливі вигоди та ризики використання технологій (наприклад, ядерної енергетики), зводячи усе до загального позитивного чи негативного враження від цієї технології.¹ Скажімо, спочатку я кажу вам, що певний вид ядерного реактора виробляє менше ядерних відходів порівняно з конкуруючими реакторними конструкціями. Далі я конкретизую, що цей реактор менш стабільний за конкуруючі і з більшим ризиком може розплавитися, якщо достатня кількість факторів одночасно посприяє цьому.

Здається, якщо реактор розплавиться з більшою ймовірністю, ця характеристика піде у мінус йому або тому, хто виступає за його будівництво. А якщо він виробляє менше відходів, ця

1. Melissa L. Finucane et al., "The Affect Heuristic in Judgments of Risks and Benefits," *Journal of Behavioral Decision Making* 13, no. 1 (2000): 1–17.

характеристика, навпаки, піде йому у плюс або стане аргументом за його будівництво. То що, ці дві характеристики суперечать одна одній? Аж ніяк. Коли йдеться про дійсність, не суперечать. Їх можуть навести різні сторони однієї дискусії, хоч логічно вони стоять окремо одна від одної. Свідчення не знають, на чию сторону їм ставати.

Пасивна безпека (тобто навіть якщо всі системи охолодження вийдуть з ладу, стан реактора не сягне критичної точки) — це стан речей, з якого не обов'язково слідує, що реактор вироблятиме менше відходів чи продукуватиме дешевшу електроенергію. Наявність усіх характеристик — бажаний стан речей, проте кожна з них по-своєму хороша. Обсяг відходів, які продукує реактор, обумовлений його властивостями. Інші ж фізичні властивості цього реактора спричинять підвищення нестабільності ядерної реакції. Навіть якщо йдеться про ті самі характеристики, слід окремо врахувати ймовірність розплавлення та очікуваний обсяг відходів щороку. На ці два різні питання фізичного характеру мають бути дві різні предметні відповіді.

Й отакі дослідження, приклад одного з яких я навів, вказують на те, як люди звикли судити про технології та багато інших проблем — за загальним позитивним чи негативним враженням. Якщо ви скажете піддослідним про те, що якийсь реактор продукує менше відходів, вони вирішать, що ймовірність його розплавлення нижча. Це означає, що вони отримали *хибну відповідь* на питання фізичного характеру із чіткими предметними відповідями через те, що переплутали логічно різні питання і поводитися зі свідченнями як із солдатами по різні сторони барикад — ніби будь-якого солдата з однієї сторони можна змусити воювати проти будь-якого солдата з іншої.

Тож якщо пані Феміда розслідує питання суто провини чи невинності, терези ще не найгірший інструмент. Джон Сміт або вбив Джона Доу, або ні. Але ми вже знаємо (завдяки Едвіну Джебінзу), що всі баєсівські свідчення становлять потоки імовірностей *між* гіпотезами — не існує свідчень, які «підтримують» чи «спростовують» окрему гіпотезу, хіба що інші гіпотези

справляються гірше або краще. Поки пані Феміда розслідує *одне* строго *предметне* питання, на яке можна відповісти «так» або «ні», терези — доцільний інструмент. Якщо ж вона має розглядати більш комплексне питання, їй слід відкласти терези або меч.

Не всі аргументи зводяться до простого «за» чи «проти». Пані Раціональність носить із собою записник, куди нотує усі свідчення, котрі не стоять на чиемусь боці.

Фундаментальна помилка атрибуції

«Фундаментальна помилка атрибуції¹ — це схильність робити висновки про сталі риси характеру, особливі для конкретної людини, з її поведінки, яку цілком можна пояснити ситуаціями, у яких вона проявляється».

— Гілберт та Мелбун²

Ми надто схильні бачити прямий зв'язок між діями інших людей та їхньою особистістю. Бачимо, як хтось без видимої причини б'є ногою торговельний автомат — припускаємо, що ця людина зла. Але коли торговельний автомат б'єте ви, то знаєте, що причина у несвоєчасному прибутті автобуса або потяга, у браку часу на складання звіту, а тепер ще й бісів автомат зажував ваші гроші уже вдруге. «Та що там, — думаєте ви, — будь-хто вдарив би той торговельний автомат на моєму місці».

Свої дії ми приписуємо своїм *ситуаціям*, бачачи свою поведінку як цілком нормальну реакцію на обставини. Та коли хтось інший б'є ногою торговельний автомат, ми не знаємо, що стоїть за цим. Бачимо лише удар, а причина лишається невидимою, тому й вважаємо цю злість рисою характеру людини — ні з того ні з сього взяв і зацідив ув автомат!

А тепер врахуймо апріорні ймовірності. Автобуси та потяги відстають від графіка набагато частіше, ніж нам трапляються люди, у яких через мутації від народження спостерігається високий рівень гніву, через що вони можуть спонтанно зацідити торговельний автомат. Так, у генетичному апараті пересічної людини точно наявні ті чи інші мутації. Коли мені не зраджує пам'ять, у середньостатистичної людини трапляється від двох до

1. Також відоме як упередження відповідності. — Прим. пер.

2. Daniel T. Gilbert and Patrick S. Malone, "The Correspondence Bias," *Psychological Bulletin* 117, no. 1 (1995): 21-38.

десяти соматичних мутацій.³ Проте вкрай мало ймовірно, що вони вплинуть на якусь *конкретну* ділянку ДНК. Відповідно, якийсь аспект чийогось характеру навряд чи аж настільки відмінний від середньостатистичного. Стверджувати зворотне — брати на себе тягар наднизької ймовірності.

Та навіть якщо людям напроямі сказати про ситуаційні причини такої поведінки, навряд чи вони поставляться до своєї здогадки скептично. Коли учасників експерименту повідомляли, що мовцю було *випадково призначено* виступити з промовою на підтримку або проти абортів, учасники все одно вважали, що мовці плекають схильності, які їм призначили у випадковому порядку.⁴

Пояснювати дощ витівками духів води, вогонь «вогненною субстанцією» (тобто флогістоном) всередині горючої речовини, снодійний ефект ліків «дрімотною властивістю» видається доволі інтуїтивним рішенням. Однак в основу реальності зазвичай покладені набагато складніші механізми: причина дощу — кругообіг води у природі, причина вогню — горіння, яке підтримується реакцією окиснення, а причина снодійного ефекту — хімічна дія на нервову систему. Ці механізми набагато складніші для розуміння, ніж сутності — вони менш доступні. Тому коли хтось б'є ногою торговельний автомат, ми думаємо, що у нього з народження закладена схильність бити автомати.

Тільки якщо цей «хтось» не ми, адже з урахуванням обставин своя поведінка видається цілком нормальною: певна річ, будь-хто зробив би те саме на моєму місці. Направду, доволі часто ми переоцінюємо те, що на нашому місці хтось інший відреагує так само. У психології цей ефект відомий як омана хибного консенсусу. Студенти, які випивають, значно переоцінюють

3. Зраджує. У різних тканинах відбуваються десятки мутацій. Проте вкрай рідко трапляється так, що ці мутації потрапляють на робочий ген і поширюються на весь організм. — Прим. пер.

4. Edward E. Jones and Victor A. Harris, "The Attribution of Attitudes," *Journal of Experimental Social Psychology* 3 (1967): 1-24, https://www.radford.edu/~jaspelme/443/spring-2007/Articles/Jones_n_Harris_1967.pdf.

відсоток однокурсників, які теж люблять перехилити по чарці. А от непитущі значно недооцінюють цей відсоток. Під «фундаментальною помилкою атрибуції» ідеться про нашу схильність надмірно приписувати поведінку інших людей їхнім внутрішнім рисам характеру, тоді як стосовно себе ми цю схильність обертаємо навпаки.

Щоб зрозуміти, чому люди роблять те, що роблять, ми маємо спочатку усвідомити, що всі вважають свою поведінку нормальною. Тому і не варто питатися, із якими такими дивними мутантськими рисами характеру вони народилися, що тепер так поводяться. Правильним буде запитати, у якій ситуації людина себе бачить. Так, у нас є певна вдача, але тих спадкових особливостей геть не *достатньо*, щоб безпосередньо пояснити всю поверхневу поведінку, яку ви спостерігаєте.

От уявіть, що я вам дав пульт із двома кнопками — червоною та зеленою. Натиснете червону — знищите Землю, натиснете зелену — ніхто не зможе натиснути червону. Котру натиснете ви? Зелену. Той, хто дасть якусь іншу відповідь, переускладнює питання.⁵

І все ж люди іноді питають мене, чому я хочу врятувати цей світ.⁶ Може, у мене було складне дитинство чи щось таке. Але такий вибір видається мені доволі очевидним... якщо подивитися на ситуацію з мого боку.

Можливо, я притримуюся не середньостатистичних переконань, і тому вони вимагають пояснень. Чому я вірю в одне, коли більшість вірить в інше? Проте з огляду на ці переконання моя *реакція* не видається мені такою, що потребує виняткового пояснення. Можливо, я став жертвою хибного консенсусу і переоцінюю кількість людей, які натиснуть зелену кнопку, дивлячись на ситуацію зі своєї дзвіниці. Але, от знаєте, я б усе одно

5. Див. "Transhumanism as Simplified Humanism." <https://yudkowsky.net/singularity/simplified>.

6. Див. Eliezer Yudkowsky, "Artificial Intelligence as a Positive and Negative Factor in Global Risk," in *Global Catastrophic Risks*, ed. Nick Bostrom and Milan M. Ćirković (New York: Oxford University Press, 2008), 308–345.

поставив на те, що таких людей було б щонайменше *суттєва меншість*.

Як-не-як більшість людей бачить себе цілком нормальною. Зсередини. Навіть ті, кого ви ненавидите, хто робить жахливі речі, не є винятковими мутантами. Для цього не потрібно ніяких мутацій. На жаль. Коли ви зрозумієте це, можете переставати дивуватися вчинкам людей.

Чи дійсно ваші вороги лихі від природи?

Ми надто схильні бачити прямий зв'язок між діями інших людей та їхніми вродженими рисами. Замість того, щоб шукати відповідей у реальних або умовних ситуаціях, якими можна було б пояснити їхню дивну поведінку, бачимо натомість точний збіг між незвичними рисами характеру і такою поведінкою. Ми припускаємо існування покручів.

Коли хтось дійсно завдає нам *кривди* — вчиняє дію, яку ми (справедливо або ні) засуджуємо, — за моїми спостереженнями, ефект фундаментальної помилки атрибуції зростає вдвічі. Схоже, у злих вчинках звинувачують здебільшого злу покруцьку сутність Ворога. Однак не заради етичності, а заради визначення апіорної ймовірності варто все ж поцікавитися Ворожим баченням ситуації, у якій він перебуває. А там, дивіться, менше дивуватиметеся його поведінкою. І зрештою будете припускати менш виняткову сутність, а ноша наднизької ймовірності стане куди легшою.

11 вересня 2001 року дев'ятнадцятеро мусульман захопили чотири пасажирські авіалайнери і свідомо скерували їх на загибель, щоб завдати удару по Сполучених Штатах Америки. Навіщо вони, як на вас, зробили це? Бо вони бачили в Америці гавань свободи, однак, народившись свободоненависними покручами, завдали удару. Так?

Будьмо *реалістами*: більшість людей не мислять себе злодіями у своїй історії. Кожен думає, що він у головній ролі кіна власного виробництва. У своїй історії Ворог *не мислитиме себе як поганця*. Якщо ви думаєте про мотивацію Ворога *так*, що після її тлумачення він постає поганцем, ви так і не зрозумієте, що коїться у його голові.

Тому що політика — губитель розуму. Дебати — це війна, аргументи — це солдати. «Ворог — хворий покруч» — це

аргумент, який воює на вашій стороні. І *будь-який* аргумент вашої сторони треба підтримувати, хай би яким дурним він не був. Інакше ви дестабілізуєте фронт. Усі прагнуть перевершити сусіда у патріотичному пориванні затаврувати Ворога, однак ніхто не наважується перéчити. І ось раптом у Ворога виростають роги, кажанячі крила, він дихає полум'ям, а з його пащі, повної ікл, скрапує їдка отрута. Якщо ж ви ставите під сумнів будь-яку з цих рис, маючи під ногами ґрунт свідощтв, ви перейшли на сторону Ворога. Ви зрадник. Лиш деякі зрозуміють, що ви бороните істину, а не Ворога.

Якби тільки покручі були здатні на жажливі речі, історія людства мала б зовсім інший вигляд. Покручі були б рідкістю.

Чи люди таки бояться, що розуміння підштовхне їх пробачити Ворогу? Звісно, що хворих покручів легше відстрілювати. Під час битви клич «Помри, смердючий виродку!» наснажує куди більше за «Помри, людино, котра могла бути такою, як я, якби виросла в іншому середовищі!». Адже тоді ви можете почати відчувати провину за вбивство людей, у яких *не* ростуть роги на голові.

Як на мене, така позиція схожа на глибоко вкорінене прагнення до односторонніх політичних дебатів, в основі якого лежить уявлення, що найкраща політика *позбавлена* недоліків. Якщо армія іншої країни перетинає державний кордон або божевільний іде на вас із ножем, ви можете а) оборонятися або б) завмерти і померти. При обороні вам ніяк не уникнути вбивств. Якщо ви вбиваєте того, хто у паралельному світі міг бути вашим другом, це трагедія. *Не може не* бути трагедією. Альтернативне рішення — завмерти і померти — також трагедія. Але ж має бути варіант, який не обернеться трагедією... Правда ж? Хто сказав, що найкраще політичне рішення мусить бути чистим від недоліків? Якщо хтось і має померти, то той, з якого насилля починається, щоб у майбутньому завадити йому і скоротити загальне число смертей.

Якщо Ворог не має рідкісних рис характеру і діє зі своїх переконань про ситуацію, які примушують його вважати насилля

нормальною людською реакцією, його переконання не стають від того правдивими чи виправданими. Тож вам доведеться пристрілити людину, яка вважає себе героєм власної історії. Отак головний герой її роману і помре на вісімдесятій сторінці. Хоч такий розвиток подій і трагедія, вона краща за трагедію альтернативну. Цей вибір щодня ухвалює поліціант, щоб наші крихкі світи не розчинилися у хаосі.

Коли ви точно починаєте розуміти психологію Ворога — знаєте, що насправді відбувається у його голові, — це розуміння розщепить насолоду від удару по ворожій стороні. Воно не дасть вам приємного відчуття праведного обурення. Ви не пишатиметесь собою. Якщо ваше розуміння викликає у вас відчуття незборимого смутку, певно, ви дивитеся на світ таким, яким він є. У більш рідкісних випадках, коли ви зустрінете справжніх психопатів або неврологічно здорових людей із переконаннями, які на пні знищили їхній глузд (наприклад, саєнтологи або таборяни Ісуса), точне розуміння може викликати у вас дрижаки чистого жаху по всьому тілу.

Скажу прямо: терористи, які 11 вересня викрали авіалайнери, не були хворими покручами. Вони не були ненависниками свободи. Вони так само були героями своїх історій і померли за те, що вважали правильним — за істину, справедливість та ісламський шлях. Та те, що терористи бачили себе у такому світі, не означає, що ми маємо погодитися, що їхні вчинки були виправданими. Не означає, що пасажирів рейсу United Flight 93 мали стояти осторонь і допустити теракт. Але якби їх виховали в іншому середовищі, ті терористи могли б стати поліціантами. Ось де справжня трагедія. Ласкаво просимо на Землю.

Обернена дурість не породжує тямучість

— ... а потім на тій часовій лінії наші люди взялися виправляти помилки. Поглянь.

Він протер екран і взявся до розслідування. Гортаючи сторінку за сторінкою, натрапляв на показання людей, які бачили таємничі диски. Кожна наступна доповідь була химернішою за попередню.

— Класична техніка розгладжування, — вишкірився Вєркан Валь. — Чув хіба що нечисленні згадки про «літаючі тарілки», та й ті розказують жартома. У цьому культурному ладі завжди можна кинути тінь недовіри на одну правдиву історію, вигадуючи натомість десятки інших, очевидно брехливих, хоч і суголосних із правдивою.

— Г. Бім Пайпер, «Поліційна операція»

Пайпер мав рацію. Я не вірю в існування прибульців, у яких забракло розуму як слід замаскуватися, через що їх помічають то тут, то там. Однак моя невіра ніяк не позначається на жадливій сороміцькій несосвітєнності, яку демонструють прихильники секти літаючих таріло́к. (Принаймні я сподіваюся на це.)

Як на мене (та й на вас, гадаю), для подібних сект існування самих літаючих таріло́к зовсім не обов'язкове. Завдячимо людській дурості за те, що секта може розвинутися на підґрунті взагалі будь-якої ідеї. Цей вид дурості поширюється *незалежно* від втручання прибульців. Адже бачимо ми літаючі тарілки чи ні, на наше очікування зустріти секти свідків літаючих таріло́к це спостереження ніяк не впливає. Навіть якби прибульці не були мастаками з маскування, то ймовірність появи відповідних сект аніскілечки не зменшилася б. Умовна ймовірність

Р(секти|прибульці) не менша ніж Р(секти|¬прибульці), якщо ви не припускаєте можливості, що нетямущі у маскуванні прибульці навмисне перешкоджають утворенню сект довкола літаючих тарілок.¹ До того ж, згідно з баєсівським визначенням свідчення, спостереження «секти довкола літаючих тарілок існують» не свідчать *проти* існування самих літаючих тарілок. Зрештою, взагалі показань не так і багато.

Так діє загальний принцип, який Роберт Пірсіг описує твердженням «Найбільший у світі дурень міже сказати, що сонце сяє, проте від того воно не погасне».²

Якби ви знали когось, хто помиляється у 99,99% випадків стосовно питань із відповіддю «так» або «ні», ви могли б досягти точності 99,99%, просто змінюючи його відповіді на протилежні. Але цій людині довелося б видобути якісні свідчення, сплутані з реальністю, послідовно їх опрацювати — лише для того, щоб потім надійно їх антикорелювати. Та з огляду на дурість таких заявників, цей підхід надзвичайно розумний.

Автівка зі зламаним двигуном не може їхати заднім ходом зі швидкістю 300 км/год, навіть якщо двигун зламаний якось *по-особливому*.

Якщо дурість не можна надійно звести до оберненої істини, чи можемо ми застосувати цей прийом до людського зла? Зворотна сторона гало-ефекту — ефект рогів (тобто всі видимі негативні якості взаємозалежні). Якщо Сталін — зло, усі його твердження мають бути хибними. Навряд чи вам було б приємно піддакувати товаришу *Сталіну*.

А він, як і ви, вірив у те, що $2 + 2 = 4$. Проте якщо ви візьметься захищати бодай якесь твердження Сталіна (навіть «два та

1. Читайте «Р(секти|прибульці)» як «імовірність існування сект довкола НЛО за умови, що прибульці бували на Землі». «Р(секти|¬прибульці)» читайте як «імовірність існування сект довкола НЛО за умови, що прибульців не було на Землі». — Прим. авт.

2. Robert M. Pirsig, *Zen and the Art of Motorcycle Maintenance: An Inquiry Into Values*, 1st ed. (New York: Morrow, 1974). У цієї книги є українськомовний переклад Анжели Асман «Дзен і мистецтво догляду мотоцикла. Дослідження цінностей» від видавництва «КМ-БУКС». — Прим. пер.

два — чотири»), люди вирішать, що ви «погоджуєтеся зі Сталіним», воюєте на його боці.

З цього принципу випливають такі наслідки:

- Щоб добросовісно сперечатися з ідеєю, вам слід ставати на прох із найкращими аргументами найсильніших її пропонентів. Сперечаючись зі слабшими захисниками, ви *нічого* не доведете, адже навіть найсильніша ідея приваблює слабких захисників. Хочете сперечатися з трансгуманізмом чи сингулярністю — маєте напрому опонувати аргументам Ніка Бострома чи Еліезера Юдковскі версії після 2003 р. Найменш зручний шлях єдино правильний.³
- Якщо ви хочете спростувати ідею, показувати пальцем на нещасних вар'ятів, які збожеволіли через свою пристрасть до неї, не те, що вам слід робити. Багато прихильників нью-ейджу втратили розум через своє захоплення квантовою механікою.
- Якось мені довелося від когось почути твердження «Не всі консерватори телепні, проте більша частина телепнів — консерватори». Якщо вам не вдається прийти до умонастрою, в якому це твердження — правдиве воно чи ні — здається *зовсім недоречним* для критики консерватизму, ви поки не готові мислити про політику у термінах раціональності.
- Переходити на особистості не годиться.
- Вам слід навчитися аргументувати проти геноциду без аргументу «Гітлер хотів винищити євреїв». А якби Гітлер *не* вдавався до геноциду, екстермінація стала б від того виправданою практикою?
- Словами Хансона, ваша природна охота вірити у щось зміниться разом з охотою *долучитися* до людей, відомих за

3. Див. Scott Alexander, "The Least Convenient Possible World," *Less Wrong* (blog), December 2, 2018, https://lesswrong.com/lw/2k/the_least_convenient_possible_world/.

їхні переконання, *істинні* чи ні — питання десяте. Дехто може не визнавати відсутність Бога не через наявність свідчень про Його *існування*, а через те, що вони не хочуть долучатися до когорти Річарда Докінза або тих клятих невгомонних атеїстів, котрі всюди носяться зі своїм безвір'ям.

- Якщо ваш комп'ютер раптом перестає працювати, некоректним буде висновок, що міняти треба всю систему, і вам потрібна нова, але без мікропроцесорів від AMD, відеокарти від АТІ, жорсткого диска від Maxtor або корпусних вентиляторів, навіть якщо у вашій системі наявні усі ці складники і вона не працює. Можливо, взагалі потрібно замінити кабель живлення.
- Якщо сотням винахідників не вдалося створити літаючі машини з металу, деревини та брезенту, з цього не випливає, що вам потрібна літаюча машина з кісток та плоті. Якщо на тисячах проєктів не змогли створити штучний інтелект на основі електронних обчислювальних пристроїв, хибно буде вважати, що корінь проблеми в електроенергії. Допоки ви не зрозумієте проблему, вкрай мало ймовірно, що обладдйливі обернення допоможуть розв'язати проблему.⁴

4. Також див. "Selling Nonapples." https://lesswrong.com/lw/vs/selling_nonapples.

Аргумент усуває залежність від авторитету

Сценарій 1. Бєррі — відомий геолог. Чарльз — юнак чотирнадцяти років, правопорушник із довгою історією судимості та періодичними випадками психозу. Бєррі впевнено висловлює Артуру контрінтуїтивне твердження про гірські породи, і той оцінює його ймовірність у 90%. А потім рівноцінно контрінтуїтивне твердження він чує від Чарльза та оцінює його ймовірність у 10%. Очевидно, що, приймаючи рішення, чи вірити твердженню, Артур бере до уваги *авторитет* заявника.

Сценарій 2. Девід висловлює контрінтуїтивне твердження про фізику і в подробицях роз'яснює аргументи, посилаючись на джерела. Ерні висловлює рівноцінно контрінтуїтивне твердження, проте його аргумент не надто переконливий. До того ж він кілька разів переходить до стрибків віри. Девід та Ерні стверджують, що кращого пояснення вони не спроможуться дати (будь-кому, а не тільки Артуру). Після ознайомлення з його аргументами Артур присуджує твердженню Девіда 90% ймовірність, а твердженню Ерні — 10%.

На позір може здатися, що обидва сценарії майже симетричні: що там, що там Артур враховує необхідні свідчення, спираючись на силу авторитету або аргументу.

Тепер уявімо, що Артур просить Бєррі та Чарльза надати технічне обґрунтування із посиланнями на джерела. Обидва справляються однаково добре — джерела достовірні. А потім Артур просить Девіда та Ерні надати їхні дипломи, і виявляється, що вони вчилися майже на те саме: обидва — клоуни чи фізики.

Якщо припустити, що Артур достатньо обізнаний в усіх тонкощах технічних аргументів — інакше він просто чує незв'язний набір звуків, — здається, що Артур мав би вважати позицію

Девіда значно правдоподібнішою за позицію Ерні, тоді як Беррі має над Чарльзом щонайбільше незначну перевагу.

Звісно, якщо технічні аргументи досить переконливі, можливо, перевагу Беррі над Чарльзом не варто й простежувати. Адже саме переконливий технічний аргумент *усуває* залежність від авторитету заявника.

Відповідно, якщо ми дійсно віримо, що Ерні навів найкращий аргумент, який тільки *міг*, зробив усі необхідні логічні кроки, врахував усі джерела — себто процитував тих фахівців, яких сам слухав, — тоді ми можемо з легкістю ігнорувати наявність будь-якої інформації про компетенції Ерні. Клоун він чи фізик — це не має значення. (Знову ж, за умови, якщо наша технічна обізнаність дозволяє опрацювати аргумент. Інакше з рота Ерні виходять незбагненні звуки. І наша «віра» у ті звуки, великою мірою залежить від його авторитету.)

А тепер ми бачимо асиметрію між аргументом та авторитетом. Якщо ми знайомі з авторитетом, то все ще хочемо почути аргументи. Однак, ознайомившись з аргументами, ми отримаємо зовсім не багато інформації від наявності авторитету у заявника.

Очевидно (каже новачок), що авторитет та аргумент — zasadничо різні види свідчень, і цю різницю ніяк не вирахувати нудними формальними методами баєсівської теорії.¹ Хоча в обох випадках сила свідчень — 90% проти 10% — однакова, при поєднанні вони функціонуватимуть по-різному. Тож як нам це порохувати?

Я наведу технічний приклад того, як можна представити цю різницю у вигляді теорії ймовірностей. (В іншому можете покластися на мій авторитет або шукати у джерелах.)


Якщо $P(G|P1)=90\%$, а $P(G|P2)=9\%$, яка ймовірність $P(G|P1, P2)$? Дізнаємось, що Подія 1 правдива, — присуджуємо 90% ймовірності Гіпотезі. Правдива Подія 2 — Гіпотеза отримує 9% ймовірності. Та якщо ми дізнаємось, що правдиві і Подія 1, і

1. Див. есей «Що таке свідчення?» у книзі «Мапа і територія». — Прим. авт.

Подія 2, яку ймовірність нам слід присудити Гіпотезі? За таких даних розрахувати її неможливо. І справа не в апіорній ймовірності Г. Події П1 та П2 можуть залежати одна від одної.


Скажімо, Гіпотеза звучить як «Тротуар, по якому я йду, слизький», Подія 1 — «Працює мій обприскувач», Подія 2 — «Надворі ніч». Тротуар стає слизьким через хвилину після вмикання обприскувача і залишається таким, доки обприскувач вимкнеться, а працює він десять хвилин. Тож якщо ми знаємо, що обприскувач увімкнено, то ймовірність того, що тротуар слизький, становить 90%. Уночі його робота займає 10% нічного часу, тому у цей час доби ймовірність слизького тротуару становить 9%. Обприскувач працює уночі — за умови, що ми свідомі обидвох подій, — ймовірність слизькості тротуару становить 90%.

У вигляді моделі графів цей аналіз можна зобразити у такий спосіб:




Час доби *спричиняє* увімкнення (вночі) або вимкнення Обприскувача, а робота Обприскувача *спричиняє* Слизькість або не-Слизькість тротуару.

Напрямок стрілок має значення. Скажімо, отак:



З цього випливає, що якби я гадки *не* мав про існування того обприскувача, ймовірність настання ночі була б незалежною від імовірності слизькості. Наприклад, я підкидаю дві гральні кості, а отримані числа складаю й отримую Суму:



Якщо ви замовчуєте суму двох чисел, але говорите, що на першій гральній кості випала шістка, мені все ще бракує інформації про те, що випало на другій. А якщо скажете, що сума двох чисел дорівнює семи, я второпаю, що на другій випала одиниця.

Насправді проблема визначення, коли різні частини інформації залежать чи не залежать одна від одної за різного фонового знання, цілком собі належить до категорії технічних. Про неї Джуда Перл пише у своїх книгах «Ймовірнісні міркування в інтелектуальних системах: мережі правдоподібного висновування» та «Причиновість: моделі, міркування і висновування». (Якщо у вас часу тільки на одну книгу, раджу прочитати першу.)

Якщо ви знаєте, як правильно читати причинові графи, подивіться на граф кидання кості й одразу ж побачите:

$$P(\text{Кубик 1}, \text{Кубик 2}) = P(\text{Кубик 1}) \times P(\text{Кубик 2})$$

$$P(\text{Кубик 1}, \text{Кубик 2} | \text{Сума}) \neq P(\text{Кубик 1} | \text{Сума}) \times P(\text{Кубик 2} | \text{Сума})$$

Подивившись правильну схему з тротуаром, побачите ось що:

$$P(\text{Слизькість} | \text{Ніч}) \neq P(\text{Слизькість})$$


$$P(\text{Слизькість} | \text{Обприскувач}) \neq P(\text{Слизькість})$$

$$P(\text{Слизькість} | \text{Ніч}, \text{Обприскувач}) = P(\text{Слизькість} | \text{Обприскувач})$$

Тобто ймовірність того, що тротуар слизький (з урахуванням наявних даних про обприскувач та нічний час доби) дорівнює ймовірності, призначеній за наявності даних лише про обприскувач. За наявності даних про обприскувач інформація про ніч стала недоцільною відносно слизькості тротуару.

Цей процес відомий як *перегородження*. Критерій, за якого з причинових графів можна визначати такі умовні незалежності, відомий як *орієнтована розділеність*, або *о-розділеність*.

У випадку розділення між аргументом та авторитетом при-
чинова діаграма набуває такого вигляду:



Якщо твердження правдиве, воно, як правило, передбачає аргументи на свою користь. Тому фахівці враховують свідчення і змінюють свою думку. (Але це в теорії!)

Якщо ми бачимо, що фахівець вірить у щось, то заднім числом висновуємо наявність свідчень в абстракції (навіть якщо точно не свідомі їхнього існування). І вже від наявності абстрактних свідчень висновуємо правдивість твердження фахівця.

Проте якщо ми свідомі значення вузла «Аргумент», він орієнтовано розділяє вузол «Істина» від вузла «Переконання фахівця», перекриваючи всі шляхи між ними відповідно до певних технічних критеріїв «блокування шляху», які в цьому випадку видаються цілком очевидними. Тому навіть не перевіряючи точний розподіл імовірностей, ми можемо зчитати з графа, що

$$P(\text{істина}|\text{аргумент, фахівець}) = P(\text{істина}|\text{аргумент}).$$

Цей запис не суперечить класичній теорії ймовірностей. Просто так можна виразити певні ймовірнісні дані більш стисло. Інакше вам було б важче зчитувати рівності та нерівності з необробленого розподілу ймовірностей. Авторитет та аргумент не потребують двох різних видів ймовірностей — так само як обприскувачі не зроблені з онтологічно відмінної матерії, ніж сонячне світло.

На практиці вам не вдасться *повністю* позбутися залежності від авторитету. Компетентні авторитети із більшою ймовірністю знають про наявні контрсвідчення, які варто взяти до уваги; менш компетентні авторитети із меншою ймовірністю знають про них, що робить їхні аргументи менш надійними. Авторитетність не зводиться до фактора, яким можна просто знехтувати, якщо вислухати свідчення, які фахівці *брали* до уваги.

Крім того, не так уже й легко звести аргументи до *чистої* математики. Інакше при оцінці сили логічного кроку ви покладатиметеся на інтуїцію, яку не зможете відтворити, не посилаючись на тридцятирічний досвід.

Приписувати словам Едвіна Джебейна про баєсову ймовірність трохи вищу вірогідність, аніж тому самому твердженню, висловленому Елієзером Юдковскі, — невикорінно правомірно. Не слід зводити п'ятдесят років досвіду до нуля.

Однак та невелика сила авторитету — всього-на-всього *ceteris paribus*,² адже її легко підважити сильнішими аргументами. Між іншим, коли вже зайшла мова, я помітив одну невеличку помилку в одній із книг Джейнза. Ось так алгебра переважила авторитет.

2. За інших рівних умов. Вислів, у якому йдеться про змінність одного параметра і незмінність інших. — Прим. пер.

Тримайтеся свого питання

До мистецтва раціональності входить дисципліна, відома як *близькість до питання*. Вона передбачає розгляд свідчень, які настільки близько стосуються початкового питання, що блокують якомога більше сторонніх аргументів.

«Мій літак полетить», — кажуть брати Райт. При порівнянні їхнього авторитету (брати Райт були конструкторами велосипедів, які виявилися чудовими фізиками-аматорами) з авторитетом, скажімо, лорда Кельвіна з'ясовуємо, що у другого він вищий.

Якщо ви попросите братів Райт показати їхні розрахунки і зможете зрозуміти їх, а потім попросите лорда Кельвіна показати його розрахунки (певно, у нього немає нічого, крім власного скептицизму), авторитет одразу втрачає у своїй вазі.

Якщо ви *на власні очі бачите*, як літак відривається від землі, з багатьох причин розрахунки вже втрачають у доцільності. З цих міркувань авторитет лорда Кельвіна можна навіть не розглядати.

Що *безпосередніше* ваші аргументи стосуються питання (без проміжних висновків) — тобто що ближче у Великій Павутині Причиновості спостережувані вузли до запитуваного вузла, — то сильніші свідчення. З теореми цих причиново-наслідкових графів випливає, що від віддалених вузлів ніколи не можна отримати *більше* інформації, на відміну від строго ближчих вузлів, що блокують віддалені.

З цього приводу Джеррі Клівер якось казав: «Ви дали маху не тому, що не змогли застосувати якусь захмарно складну техніку. Ви знехтували основами. Не зосередилися на суті справи».¹

Так само як доречніше аргументувати фізикою, а не дипломом, кращим аргументом є фізика, а не раціональність. Хто був раціональнішим — брати Райт чи лорд Кельвін? Якщо ми

1. Jerry Cleaver, *Immediate Fiction: A Complete Writing Course* (Macmillan, 2004).

можемо перевірити їхні розрахунки, це питання втрачає сенс. Чеснота раціоналіста *безпосередньо* не змусить літак відірватися від землі.

Якщо ви забудете про цей принцип, ваша обізнаність про біаси тільки нашкодить, оскільки це знання відволікатиме вас від більш точкових аргументів. Вказати комусь на Біас № 182, котрий ви тримаєте у шухляді повністю загальних звинувачень, — діло зовсім не хитре, проте *закрити* предметне питання без ближчих свідчень вам не вдасться. Від того, що хтось ангажовано вмотивований говорити про світло сонця, воно світити аж ніяк не перестане.

Ви не завжди можете у цей же день поставити експеримент — те саме стосується і перевірки розрахунків.² Іноді вам бракує вихідних даних, іноді у вас немає доступу до інформації, а іноді ще вам просто бракує часу. На жаль, доволі часто доводиться ще судити про раціональність заявника. Це завжди варто робити із відчуттям порожнечі, ніби вам іще бракує якоїсь інформації.

Щойно маєте таку можливість, підходьте до початкового питання якомога ближче. Чимдуж притисніть його до себе. Тримайтеся свого запитання.

2. Також див. “Is Molecular Nanotechnology ‘Scientific’?” https://lesswrong.com/lw/io/is_molecular_nanotechnology_scientific.

Раціональність та англійська мова

Цими днями один коментатор написав, що мої публікації нагадують йому есей Джорджа Орвелла «Політика та англійська мова».¹ Для мене це було честю. Так, власне, і виникла тема сьогоденішнього есею.

Якщо ви *хочете* побачити раціональність очима митця, читайте Орвелла. Його твори обов'язкові до прочитання як для раціоналістів, так і для людей слова. Орвелл був не науковцем, а письменником. Його знаряддям були не числа, а слова. Його опонентом була не Природа, а зло у людській подобі. Якщо ви хочете на роки кинути людину за ґрати без суду і слідства, вам варто подумати над тим, як це можна сформулювати замість «Я кидаю містера Джэ́нніґза до в'язниці на роки без суду і слідства». Ви мусите збити слухача з пантелику, не дати чітким образам обурило його совість. Тому натомість ви кажете: «Ненадійні елементи були піддані альтернативному судовому процесу».

Орвелл був гнівним противником тоталітаризму та каламутного мислення, за яким зло зазвичай ховає себе. Ось так його праці про мову стали класичними раціоналістськими творами на рівні з працями Фейнмана, Сагана та Докінза.

«Пасивний стан дієслова повинен уникатися письменниками». Раціоналіст, досвід якого виходить *виключно* з науки, може не помітити вади у попередньому реченні. Хто ж має бодай невеликий досвід написання текстів, відразу побачить проблему. Я сконструював речення у пасиві, не розголошуючи, хто говорить авторам уникати пасивного стану. Пасив усуває *діяча*, залишаючи об'єкт, над яким виконується дія. *Хто* піддав ненадійні елементи альтернативному судовому процесу? Що взагалі *робить* той «альтернативний судовий процес»? Так, застосовуючи

1. Коментар знаходиться за посиланням https://lesswrong.com/lw/jb/applause_lights/flt. — Прим. авт.

достатню кількість статичних іменних конструкцій, ви справді можете не допустити, щоб *сталося* щось неприємне.

Статті у фахових виданнях також часто пишуться у пасиві. (Даруйте, *деякі науковці* пишуть свої статті для фахових видань у пасиві. Це не статті пишуться самі по собі, щоб не було кого критикувати.) Твердження «Піддослідним призначили Продженіторівокс» звучить більш авторитетно, ніж «Я дав кожному студенту по пляшечці Продженіторівоксу із двадцятьма пігулками і сказав їм приймати по одній щоночі, поки вони не закінчатся». Якщо ви приберете тих науковців, залишається тільки найважливіша інформація. Проте насправді науковець *таки присутній*, піддослідними є студенти, а Продженіторівокс ніхто не «призначав» — його просто передали з інструкціями. Ось так пасивний стан і спотворює реальність.

Судячи з отриманих коментарів, хтось точно заперечить, що використання пасиву в академічних статтях можна назвати грихом. Як-не-як, якщо ви *задумалися* над цим, то й маєте зрозуміти, що науковці були дотичні до дослідження. На логічну хибу якось не тягне. Саме тому раціоналістам слід прочитати Орвелла і не обходитися лише Фейнманом або Джейнзом.

У нехудожній літературі автор ділиться *знанням*, у художній — *досвідом*. Медики можуть узагальнити, що станеться з людиною у відкритому космосі без скафандра. Письменники можуть написати так, щоб ви пережили досвід тієї людини.

Деякі раціоналісти *спробують* проаналізувати оманливе формулювання, зрозуміти, чи передає воно щось значуще, *реконструювати* логічну інтерпретацію. Вони проявлять добродішність і нададуть автору презумпцію невинуватості. Авторів же вчать *не* давати собі тієї презумпції. Що аудиторія *подумала* про ваш текст і є тим, що ви сказали, мали ви це на увазі чи ні. Ви не можете сперечатися зі своєю аудиторією, хай би якими розумними були ваші виправдання.

Письменник знає, що читачі *не* дадуть собі кількох хвилин задуматися над прочитаним. Вигаданий досвід — це

неперервний потік перших вражень. Тому письменник-раціоналіст не оминає увагою і *досвід*, який створюють слова. Якщо ви оцінюєте, наскільки раціональним твердження виглядає для аудиторії, ретельно аналізуєте слова — перефразовуєте висловлювання, перебираєте різні відтінки значень, шукаєте крупичі позірної істини, — то втрачаєте з поля зору перше враження: те, що аудиторія *бачить*, а радше *відчуває*.

Людина слова одразу помітила б кричущу помилку у реченні «Піддослідним призначили Продженіторівокс²». Який досвід отримають читачі, натрапивши на нього? Це речення створює відчуття авторитетності джерела — *та й по тому*. Крім відчуття, що вам сказали щось надійне, воно нічого не викликає. Людина слова бачить іменники, які своєю абстрактністю відчужують від самої події: постдок із пляшечкою в руці намагається тримати суворе лице, а студент, ховаючи свою знервованість за посмішкою, уважно слухає.

Я не кажу про те, що академічні статті варто писати з узуванням на романи, але раціоналіст має усвідомлювати, який *досвід* створюють слова. Має розумітися на тому, що таке мозок і як ним правити. Сюди ж входить і потік свідомості — та частина себе, яка розкривається у мові. Раціоналіст мусить усвідомити справжній чуттєвий вплив висловів за межами їхньої буквальної пропозиційної семантики.³

Іншими словами: *сєнс висловлювання не виправдовує його впливу!*

Мене не цікавить, яке раціональне тлумачення ви вкладаєте у заклик до оплесків «ІІІ повинен розвиватися відповідно до демократичних процесів». Воно все одно не виправдовує того ірраціонального впливу у вигляді сигналу до оплесків, і я вже мовчу про туманну розпливчастість із круговим міркуванням.

2. Вигаданий лікарський засіб з сатиричного мультфільму *The Drugs I Need* (https://youtu.be/WgoB2h_Wkco). Підступ у тому, що у цього засобу довгий перелік побічних дій. — Прим. пер.

3. Порівняйте есеї «Семантичні стоп-сигнали» та «Знак “ОПЛЕСКИ”» у книзі «Мапа і територія». — Прим. авт.

Тут на допомогу якраз і приходить Орвелл, який виступає проти кліше і їхнього впливу на досвід мислення:

«Коли подивитися на якогось втомленого наймита-пустослова, котрий механічно повторює з трибуни затерті словосполучення — ТВАРИННИЙ, ЗВІРСТВА, ЗАЛІЗНИЙ КАБЛУК, КРИВАВА ТИРАНІЯ, ВІЛЬНІ НАРОДИ СВІТУ, СТОЯТИ ПЛІЧ-О-ПЛІЧ — виникає таке дивне відчуття, наче спостерігаєш не за живою людиною, а за якоюсь лялькою... Промовець, котрий послуговується фразеологією такого стибу, вже пройшов неабиякий шлях до перетворення себе на машину. З його горла лунає підходящий до ситуації гомін, хоча його мозок при цьому не працює, як мав би, якби він сам обирав слова...

Перш за все потрібно дати сміслу обирати слово — не навпаки. Найгірша помилка, яку може зробити прозаїк, — втратити контроль над словами. Коли ви думаєте про конкретний об'єкт, на думці у вас не слово. А якщо захочете описати виображений предмет, певно, вам знадобиться добряче подумати, щоб знайти влучні слова. Коли на думці щось абстрактне, ви з самого початку вже більш схильні використовувати слова. І якщо свідомо не опиратися цій звичці, вже існуючий жаргон почне розпускати свої мацаки і зробить усе за вас. І за втрату контролю ви заплатите розмиванням чи навіть підміною значень. Певно, гарною ідеєю буде якнайдовше утримуватися від використання слів і формувати зміст якомога чіткіше для себе через образи та чуття».

Останній абзац цього есею міг би написати Чарльз Сандерс Пірс. Далеко не одна стежка приведе вас до Шляху.

Людське зло і каламутне мислення

На очах у Джорджа Орвелла цивілізований світ скочувався до тоталітаризму: країни одна за одною опускалися до тоталітарних систем; кирзовий чобіт, здавалося, уже ніколи не злізе з людського обличчя, запам'ятайте: ніколи. Ви не застали тих часів, коли марш тоталітаризму, здавалося, не зупинити, коли у низці країн таємна поліція тероризувала людей по ночах, коли професори вільних університетів ставилися до чисток у Радянському Союзі як до прогресу. Реальність, описана у його книжках, видається вам відчуженою — украй складно брати написане за чисту монету. Тому що Берлінська стіна впала у вашій гілці часу. А ім'я Орвелла варто було б викарбувати на одній із її цеглин.

Він бачив, до чого йде людство, тому й докладав гарячкових зусиль, щоб збити його із цього шляху. Зброєю Орвелла був прозорий стиль письма. Він знав, що туманна мова виливається у каламутне мислення, яке переплітається із людським злом, мов спарені нитки ДНК:¹

«Нині політичні промови і тексти спрямовані переважно на захист того, що не піддається захисту. Продовження британського панування в Індії, чистки і депортації в Росії чи скидання атомних бомб на Японію дійсно можна захищати, але тільки такими аргументами, які є надто брутальними для більшості людей і які не узгоджуються із задекларованими принципами політичних партій. Тому політичне мовлення і повинне складатися здебільшого з евфемізмів, кругових аргументів та всуціль туманної розпливчастості. Бомбардування беззахисних сіл з повітря, вигнання мешканців у сільську місцевість, розстріл скотини, руйнація будинків запалювальними кулями — усе це називають умиротворенням...».

1. George Orwell, "Politics and the English Language," *Horizon*, 1946.

Орвелл чудово усвідомлював, що його мета — ясність:

«Спрощена англійська звільняє вас від згубних пороків ортодоксії. Ви не володієте необхідним жаргоном, тому коли кидаєте дурну репліку, її дурість стає очевидною навіть вам».

Для цього і був створений блог «Подолання біасів» (*Overcoming Bias*) — щоб оголити нашу дурість.

Ці лихі змії крадуться під мороком розуму. З усією ясністю історії ми оглядаємося у минуле і з гіркотою пам'ятаємо голодомори Сталіна і Мао, внаслідок яких загинули десятки мільйонів людей. Ми називаємо це злом, оскільки такі заходи впроваджувалися свідомо та умисно, щоб завдати невинним людям болю і вбити їх. Ми називаємо це злом через відчуття відрази до тих заходів, на які тепер дивимося з усією ясністю, яку тільки дозволяє історія. Щоб злочинці уникли природного спротиву, відразу мусять лишатися прихованою. З цієї причини вони за всяку ціну уникають ясності. Так само як людина ясного зору намагається протистояти видимому злу, воно, незалежно від місця вкорінення, насаджує каламутне мислення.

У романі «1984» Орвелл чітко вказує на це. Найбільшими лиходіями в Орвелла були ретушери (цих персонажів він запозичив з історично зафіксованих випадків вирізання людей з фотографій та ретушування у Радянському Союзі). У найдраматичнішій сцені у Міністерстві Любові О'Браєн катує Вінстона, щоб той визнав, що два та два — п'ять:²

— Ви пам'ятаєте, — провадив О'Браєн, — як записали у своєму щоденнику: «Свобода — це можливість сказати, що два плюс два буде чотири»?

— Так, — відповів Вінстон.

2. Тут та інша цитата — переклад Віктора Шовкуна. Українськомовний переклад вийшов у Видавництві Жупанського у межах серії «Майстри світової прози». — Прим. пер.

О'Браєн підніс свою ліву руку до Вінстона, заховавши великого пальця і виставивши чотири інші.

— Скільки пальців я вам показую, Вінстоне?

— Чотири.

— А коли Партія скаже, що не чотири, а п'ять — скільки тоді їх буде?

— Чотири.

Вимовивши це, він зойкнув від болю. Стрілка циферблата скочила на п'ятдесят п'ять. По всьому Вінстоновому тілу виступив піт. Він судомно хапнув повітря, а його видих супроводжувався важким стогоном, якого він не міг стримати, навіть зціпивши зуби. О'Браєн дивився на нього, все ще показуючи чотири пальці. Він знову торкнувся важеля. Цього разу біль був лише трохи слабшим.

Я не перестаю дивуватися позірно розумним людям — як-от колезі Робіна Хансона Тайлеру Кауну, — котрі не вважають подолання біасів важливою справою.³ Ми ж говоримо про ваш *розум*. Ваш інтелект. Ним ви відрізняєтеся від орангутанга. Завдяки йому постала цивілізація. І ви ще кажете, що розум не важливий? Кажете, що систематичні несправності у роботі розуму не мають значення? Думаєте, що Священна Інквізиція катувала б відьом, якби всі ті судді були бездоганними баєсіанцями?

Схоже, Тайлеру Кауну здається, що подолання біасів — таке саме упередження, як і всі інші: «Я думаю, що блог Робіна — приклад упередженості, який насправді показує користь від біасів». *Сподіваюся*, що це лише наслідок надто абстрактних міркувань та одночасних спроб виглядати розумним. Чи справді Тайлер вважає, що ігнорування масштабу цінності людського життя

3. Див. Tyler Cowen, "How Important is Overcoming Bias?," *Marginal Revolution* (blog), 2007, <https://marginalrevolution.com/marginalrevolution/2007/08/how-important-i.html>.

нічим не відрізняється від спроби скласти *ефективний* план порятунку якомога більше життів?

Орвелл був змушений протистояти тому самому ставленню: мовляв, по-юнацьки наївно визнавати будь-які відмінності між абстрактними поняттями:

«Стюарт Чейз та його колеги дійшли до того, що усі абстрактні слова позбавлені усякого значення, і використали свій синізовок для пропаганди свого роду політичного квієтизму⁴. Немає визначення фашизму — немає проти чого боротися».

Коли подолання упереджень подають як боротьбу з випадковими помилками, цей процес, певно, не виглядає настільки захопливим. Коли погано видно противника, то й складно проїнятися боротьбою. Тож будьмо відвертими: де панує людське зло, де можливе насилля, тортури та умисні вбивства, там упередження окутують те зло. Де люди ясного зору борються з біасами, завуальоване зло б'є у відповідь. У Правди є вороги. Якби у Радянському Союзі випускали газету «Подолання біасів», кожного дописувальника і коментатора відправили б до ГУЛАґу.

В історії людства саме ясність думки приводила до великих стрибків. За винятком кількох стихійних лих, кожна велика біда спричинена дурістю. Наш останній ворог — це ми самі. І це війна. І ми солдати.

4. Учення, прихильники якого обстоюють споглядальне ставлення до дійсності, втечу від життя і «непротивлення злу». — Прим. пер.

У боротьбі з раціоналізацією

Як знання про біаси може нашкодити

Одного разу я спробував пояснити матері, що не так із точністю оцінок експертів: «І тому, коли експерт каже, що впевнений на 99%, його прогноз справджується тільки у 70% випадків». А потім запала мовчанка, і я раптово усвідомив, що розмовляю зі своєю матір'ю, тому поспішно додав: «Звісно, ти і до себе маєш застосовувати цей скептицизм, а не просто відкидати усе, із чим не погоджуєшся...».

І тоді мати відповіла: «Жартуєш? Чому не розказав раніше? Тепер завжди користуватимусь цією штукою!».

У своїй статті «Заангажований скептицизм при оцінці політичних поглядів» Чарльз Тейбер та Мільтон Лодж описують шість прогнозів, котрі підтвердилися їхнім дослідженням:

1. Ефект попереднього ставлення. Учасники експерименту, котрі мають сильні емоції з приводу певного питання — навіть якщо вони прагнуть об'єктивності, — схилитимуться більше до аргументів на користь їхньої позиції, а не проти.
2. Спростувальне упередження. Учасники експерименту витрачають більше часу і розумових зусиль, розбиваючи аргументи, що суперечать їхнім поточним позиціям.
3. Підтверджувальне упередження. Піддослідні, необмежені при виборі джерел інформації, шукатимуть не спростувань, а підтверджень.
4. Поляризація настроїв. Якщо учасників ознайомити з нібито збалансованим переліком аргументів за та проти, такий крок посилить їхню початкову поляризацію.
5. Ефект сили ставлення. Що палкіше піддослідні озвучують своє ставлення, то більше вони схильні до згаданих біасів.

6. Ефект мудрифікації. Оскільки політично підковані піддослідні мають більший багаж ерудиції, яким вони протиставляють суперечливі свідчення та аргументи, вони більше схилитимуться до згаданих біасів.

Якщо ви з самого початку дієте ірраціонально, *ерудиція* може *нашкодити* вам. У справжнього баєсіанця інформація ніколи б не мала негативного значення очікуваної корисності. Але люди застосовують баєсовий підхід недосконало, тому за необережності можуть порізатися.

Я *бачив* людей, які незлецьки шпортелися об свої знання про біаси. Як наслідок, завдяки своїй ерудиції вони аргументували проти всього, що їм не до вподоби. І ця проблема — приведена до бойової готовності ерудиція — одна з основних причин, чому люди зі жвавим розумом виявляються дурнями (дурість у значенні «дисраціоналії» Кейта Становича).

Певен, що вам вдасться пригадати людей, які підпадають під цей опис. Люди із високим фактором загального інтелекту, котрі виявляються менш ефективними через їхню мудрифікованість. Вгадав? Гадаєте, вони змогли б дати собі раду — стати більш ефективними раціоналістами, — якби вони ознайомилися із традиційним переліком біасів?

Пригадую одного пана, який дізнався про проблему калібрування та надмірної впевненості. Ось що він сказав: «Отже, довіряти експертам не можна — надто часто вони помиляються, про що й свідчать результати експериментів. Отже, тому, коли я прогноую майбутнє, вважаю за краще припустити, що стан справ продовжуватиметься так, як історично склалося...» — і далі він пустився у цілу складну, схильну до помилок і дуже сумнівну екстраполяцію. Якимось чином, коли справа дійшла до його улюблених висновків, він перестав *помічати* усі ці біаси та хиби — ніби його мозок осліп до них — у порівнянні з тими випадками, коли йому доводилося контраргументувати.

Тож я розказав панові про спростувальне упередження та проблему мудрифікації. Вгадайте, що було далі. Наступного

разу, коли я сказав йому щось таке, що йому не припало до серця, у мудрифікованості він звинуватив мене. Не завдавши собі клопотів вказати на конкретний мудрифікований аргумент чи хибу, він просто похитав головою і з сумним виразом обличчя зітхнув через те, що я, вочевидь, використовував власний інтелект проти самого себе. Так він здобув ще один Повністю Загальний Контраргумент.

Навіть саме поняття «мудрифікованого сперечальника» може бути шкідливим, якщо воно першим спадає на думку, коли ви натрапляєте на нібито розумну людину, яка говорить щось таке, що вам не подобається.

Я прагну вчитися на своїх помилках. Останнього разу, коли я виступив з промовою про евристики та біаси, загальне уявлення я вирішив дати через оману поєднання та евристику репрезентативності. Потім перейшов до упередження підтвердження та спростування, мудрифікованого аргументу, заангажованого скептицизму та решти ефектів ставлення. Наступні тридцять хвилин я присвятив *утовкмачуванню* теми, розглядаючи її зі стількох кутів зору, зі скількох я взагалі міг її представити.

Я хотів зацікавити аудиторію. І, схоже, простим описом оман поєднання та евристики репрезентативності я досяг мети. Гаразд, вони проявили інтерес. То що тепер? Література про біаси існує переважно у дискурсі когнітивної психології заради самої когнітивної психології. Під час виступу я почувався зобов'язаним сповістити свою аудиторію про суворі застереження — інакше вони б пропустили їх повз вуха.

Тепер незалежно від того, чи я пишу есей, чи виступаю з промовою, я намагаюся уникати згадок про калібрування та надмірну впевненість, якщо не розказав іще про спростувальне упередження, заангажований скептицизм, мудрифіковані аргументи та дисраціоналію у вертких розумом. Адже перше правило: не нашкодь!

Оновлюйте переконання — крок за кроком

Політика — губитель розуму. Дебати — це війна, аргументи — це солдати. Важко опиратися спокусі витлумачувати результат кожного експерименту на користь своєї теорії, ніби ви обороняєте фортецю від хвиль наступу. Але не можна робити того, що не вкладається в математику. Адже ми знаємо, що на кожне очікування свідчення існує рівнозначне очікування контрсвідчення.

Немає нічого страшного у тому, що облюблене вами переконання не захищене з усіх сторін. Якщо ви припускаєте, що «число» на монетці випадає у 95% випадків, тоді ви маєте очікувати, що один раз з двадцяти монетка випаде іншою стороною. Повторюся: у цьому немає нічого страшного. Так і має бути. І можна навіть очікувати, що на кожне протилежне свідчення ви отримуєте дев'ятнадцять підтверджувальних. Імовірна модель може витримати удар-другий¹ і все одно вижити — але не тоді, коли удари *далі* надходять один за одним.

З усім тим у суспільстві побутує опінія, що істинна теорія повинна не мати *жодних* недоліків, а хибна теорія не породжує *жодного* вдалого передбачення.

Запросто можна знайти людей, котрі демонструють одиницю того, що вважають свідченням, і стверджують, що їхня теорія може «пояснити» її, ніби саме стільки свідчень і вимагає будь-яка теорія. Мовляв, очевидно ж, що хибна теорія *не може мати й одного* свідчення на своє підтвердження, що вона не може вписатися навіть в одну подію. Тому навіть одиниця підтверджувального свідчення — максимум того, що потрібно для теорії.

Трохи менш дурним учинком буде спроба спростування демонстрацією одного *імовірного* контрсвідчення, ніби проти правильної теорії неможливо висунути і *найменшого*

1. <https://www.lesswrong.com/posts/vrHRcEDMjZcx5Yfru/i-defy-the-data>

контраргументу. У такій манері люди сперечалися століттями, намагалися завдати поразки аргументам суперника, знецінюючи найменші прояви підтримки на їхню користь. Люди прагнуть односторонніх дебатів. Вони звикли до світу, в якому до їхніх улюблених теорій не можна висунути і йоти контраргументу. Тому для них допустити навіть крихту імовірного контрсвідчення означає кінець такого світу.

З досвіду я просто знаю, що хтось в аудиторії може сказати: «Але якщо ви хочете виграти дебати у справжньому світі, поступитися навіть одним аргументом *неприпустимо!* Якщо ви визнаєте існування бодай одного контраргументу, Ворог не перестане згадувати вам його! Такого не можна допустити! Не можна дати Йому *виграти!* Що може пробирати до кісток більше за *поразку?*».

Хай там як. Раціональність не для того, щоб вигравати дебати, — за допомогою неї якраз вирішують, за яку сторону виступати. Якщо ви вже обрали сторону, ви *дійшли* висновку — кепського або вдального. Але як вирішити, за чію сторону виступати? Якщо думка про *вибір не тієї сторони* жахає вас на рівні нутра (хоча б навіть трішечки), вам краще б урахувати *всі* свідчення.

Раціональність подібна до танцю — не прогулянки. Кожен рух вимагає від вас поставити ногу у правильне положення — ні лівіше, ні правіше. З кожним новим підтверджувальним свідченням посувати переконання вперед. З кожним спростувальним свідченням посувати переконання назад. Так, *назад*. Навіть із правильною моделлю, якщо вона не до кінця точна, вам іноді доведеться *переглядати* свої уявлення, посуваючи їх назад.

Можуть знайтися одне чи два свідчення, які суперечать вашому переконанню. Таке іноді стається з імовірнісними свідченнями для неточних теорій. (А от якщо вже точна теорія дає маху, саме *час* бити в дзвони!) Просто зсуньте своє переконання трохи вниз — зменшіть його ймовірність, співвідношення шансів чи навіть невербальну вагу довіри у своєму розумі. Трохи змістіть донизу, а потім чекайте нових свідчень. Якщо теорія

істинна, підтверджувальні свідчення не забаряться, і ймовірність знову зростає. У протилежному випадку вона не варта вашої уваги.

Проблема чорно-білого двійкового якісного мислення у тому, що будь-яке спостереження теорію або знищує, або дозволяє їй функціонувати далі. Заборона кожного спростувального спостереження створює когнітивний дисонанс та необхідність ухилитися від критики. Така необхідність виключає покроковий прогрес, виключає розкладання усіх свідчень по правильних місцях. Міркуючи ймовірно, ми усвідомлюємо, що в середньому коректна теорія породжуватиме більше свідчень у бік її підтримки, ніж спростування. Тому можна *сміливо* сказати собі: «Це свідчення злегка суперечить моему переконанню — я трохи посуну його назад». Так, назад. Вашій улюбленій теорії такий легкий зсув не нашкодить. Думайте кількісно, а не якісно.

На кожне очікування свідчення існує рівнозначне та протилежне очікування контрсвідчення. У кожному випадку ви в середньому повинні бути готові до перегляду своїх переконань у бік зменшення тією мірою, якою ви готові переглянути їх у бік збільшення. Якщо ви думаєте, що знаєте, яке свідчення буде наступним, ваша впевненість у своїй теорії мусить бути доволі міцною — ймовірність близька до 1, — тому місця для подальшого зростання ймовірності не лишається. І незалежно від того, наскільки мало ймовірною вам здається зустріч зі спростувальними свідченнями, у такому випадку зсув донизу має бути настільки великим, щоб він зрівноважував очікуваний приріст з іншого боку. Середньозважене значення вашої очікуваної апостеріорної ймовірності має дорівнювати апіорній ймовірності.

Хіба ж не безглуздо тоді боятися зменшувати свою впевненість, якщо ви доклали зусиль, щоб розібратися у питанні? У середньому ви маєте бути готовими на підґрунті кожного окремого спостереження настільки зменшувати ймовірність, наскільки ж і збільшувати.

А може бути таке, що контрсвідчення насувають і насувають, тоді як нові свідчення надходять по краплиночці. Ви можете

помітити, що ваше переконання поступово слабшає і слабшає. А згодом ви врешті усвідомите, з якої сторони проти вас дме вітер свідчень. У цю мить забудьте про нові виправдання. В цю мить ви *вже відмовилися* від свого облюбленого переконання. Так тримати! Таку подію гріх не відсвяткувати! Відкоркуйте пляшку шампанського або замовте піци! Адже ви не зможете стати сильнішими, тримаючись поглядів, з яких починали.

Один аргумент проти армії

У попередньому есеї я писав про спосіб міркування, який забороняє бодай найменший контраргумент, внаслідок чого треба відбиватися від кожного спостереження не на користь переконання. Тут я припускаю: коли люди натрапляють на контраргумент, вони не дають собі знизити власну впевненість і відкараскуються *прокручуванням* уже відомих підтримувальних свідчень.

Уявімо, що країна Фрідонія обговорює питання відповідальності своєї сусідки, Сильвенії, за недавню серію ударів метеоритів по її містах. На це є кілька свідчень: метеорити вразили міста поблизу сильвенійського кордону; на фондових біржах Сильвенії спостерігалася незвична активність *до* ударів; і сильвенійського посла Трентіно чули, як він бурмотів щось про «відплату з небес».

І тут хтось підходить до вас і каже:

— Я не вважаю, що Сильвенія відповідальна за той метеоритний дощ. Щороку ми заробляємо мільярди на торгівлі із нею.

— Так, — відповідаєте ви, — але метеорити вдарили по містах на кордоні із Сильвенією, на їхніх фондових біржах була якась дивна активність, а їхній посол говорив про відплату з небес.

Оскільки ці три аргументи переважають перший, ви *зберігаєте* своє переконання, що Сильвенія несе відповідальність — якісно кажучи, ви вірите, а не не вірите. Очевидно, що баланс свідчень не на користь Сильвенії.

А потім хтось інший підходить до вас і каже:

— Я не вважаю, що Сильвенія відповідальна за той метеоритний дощ. Скерувувати астероїди не так вже й легко. А уряд Сильвенії не фінансує жодної космічної програми.

— Але ж, — відповідаєте ви, — метеорити вдарили по прикордонних із Сильвенією містах, їхні інвестори знали це і їхній посол відкрито визнав це!

І знову ці три аргументи переважають перший (трое проти одного), тому ваша віра у відповідальність Сильвенії досі не похитнулася.

Ба більше, ваша впевненість у своїх судженнях навіть *зростає*. Вже у двох окремих випадках ви оцінили баланс свідчень, і в обох випадках він схилився проти Сильвенії у співвідношенні 3:1.

Знову і знову, і ще сотню разів ви чуєте наступні аргументи просильвенійських зрадників, однак щоразу новий аргумент програє з рахунком 3:1 на користь звинувачувачів. І з кожною суперечкою ваше відчуття впевненості у провині Сильвенії зростає, чим зміщує апіорну ймовірність до гаданого балансу свідчень.

Звичайно, проблема у тому, що, *прокручуючи* вже *відомі* аргументи, ви двічі зараховуєте те саме свідчення. Та навіть через подвійне зарахування усіх свідчень ви все одно зіпсували б собі карму. (Уявіть собі науковця, який, провівши експеримент з п'ятдесятьма учасниками, отримує статистично незначущий результат і подвоює отримані дані.)

А вибірковий подвійний підрахунок *деяких* свідчень — взагалі суцільне нахабство. Пам'ятаю: дитиною я дивився мультфільм, у якому антагоніст ділив здобич у такий спосіб: «Раз — тобі, раз — мені. Раз — тобі, раз-два — мені. Раз — тобі, раз-два-три — мені».

Як я вже наголошував у попередньому есеї, навіть якщо улюблене переконання *вірне*, розкладаючи *усі* свідчення по полицях, раціоналіст іноді може знизити ймовірність. Так, баланс підтримки може бути все ще на стороні вашого переконання. Та все ж ви маєте *знижити* ймовірність — так, *знижити*, — хай на якому місці вона була до того, як ви дізналися протилежні свідчення. А *прокручувати* підтверджувальні аргументи немає сенсу, оскільки ви вже врахували їх.

Мені виглядає, що, стикаючись з *новим* контраргументом, люди починають шукати виправдання, щоб не втратити свою впевненість, і — хто б сумнівався — знаходять уже *відомі*

аргументи на підтримку своєї думки. І я теж маю бути на сторожі, щоб не припуститися тієї ж помилки! Адже відчувається це так само природно, як і відбити удар меча підручним щитом.

За правильного підбору помилкових міркувань жменька підтримки — може вистачити й одного аргументу — здатна встояти проти армії суперечностей.

Нижній рядок

На аукціоні виставили дві закриті скриньки — А та Б. Одна і тільки одна містить коштовний діамант. Це можна визначити за багатьма ознаками і прикметами. Однак я не *знаю* жодного, в якому міг би бути цілковито впевненим. На одній із них, наприклад, стоїть синя печатка, і мені відомо, що скриньки з діамантами частіше мають синю печатку, ніж порожні. Або ось в іншій скриньки виблискує поверхня, і в мене є підозра — хоча я й не певен, — що скринька з діамантом ні за що не блищатиме.

Тепер уявімо, що до власників скриньки А та Б звертається вправний сперечальник з аркушем паперу у руці: «Запропонуйте ціну на мої послуги. Переможець отримає мої аргументи на користь того, що діамант саме у його скриньці. Відповідно за скриньку того, хто замовить мої послуги, можна просити вищу ціну». Власники торгуються — і власник скриньки Б пропонує вищу ціну і виграє.

Вправний сперечальник задумується і нижнім рядком на аркуші паперу пише: «*Отже*, скринька Б містить діамант!». Потім його рука рухається вгору, і у верхньому лівому кутку вправний сперечальник пише: «По-перше, скринька Б проштампована синьою печаткою. По-друге, у скриньки А виблискує поверхня. По-третє, скринька Б світліша за скриньку А». І ще багато інших прикмет. Він нехтує всіма ознаками на користь скриньки А. Після своїх міркувань він приходить до мене і зачитує зі свого аркуша: «По-перше, скринька Б проштампована синьою печаткою; по-друге, у скриньки А виблискує поверхня», — аж поки він не доходить висновку: «*Отже*, скринька Б містить діамант».

Подумайте ось про що: щойно вправний сперечальник записав висновок, щойно його ручка торкається паперу, доказова сплутаність фізичного чорнила із фізичними скриньками стала фіксованою.

Принагідним буде виобразити скупчення світів — гілки Еверетта або копії світів Тегмарка, — в яких спостерігається певна

об'єктивна частотність, за якої скринька А або Б містить діамант.¹

На папері фізичне чорнило набуває химерних візерунків, які нагадують речення «Отже, скринька Б містить діамант». Якщо так припало, що ви добре володієте мовою, та абракадабра на папері може вас спантеличити тим, що вона якось *вказує* на діамант у скриньці Б. Якось піддослідних попросили назвати колір друкованих зображень. Бачачи слово «зелений» червоним чорнилом, вони відповідали «зелений» замість «червоний». Тож іноді неграмотність рятує від оманливої форми чорнила.

Для нас справжнє значення речі полягає у її сплутаності з іншими речами. Подумайте про сукупність світів, гілки Еверетта або копії світів Tegmark. Щойно ручки усіх вправних сперечальників в усіх світах торкаються нижнього рядка — нехай це буде одна мить, — вони фіксують взаємозв'язок між фізичним чорнилом та фізичними скриньками. Чорнило, яким пише вправний сперечальник, ні стерти, ні змити вже не вийде. Скриньки все ще ті самі. У підмножині світів, де вправний сперечальник написав рядок «Отже, скринька Б містить діамант», уже є певний фіксований відсоток світів, де скринька А містить діамант. Хай що написано у ще порожніх рядках вище, цього не змінити.

Отже, доказова сплутаність фізичного чорнила уже стала фіксованою. Подумайте, яка саме сплутаність. Можливо, власники скриньок, які вірять, що їх можна краще презентувати, більш схильні наймати рекламодавців; а можливо, власники роблять вищі ставки з остраху викриття власних недоліків. Якщо вони не розуміються на прикметах, напис фізичним чорнилом не матиме жодного зв'язку з умістом фізичних скриньок. Скоріше, зв'язок буде з фінансовими можливостями та звичками торгуватися

1. Max Tegmark, "Parallel Universes," in *Science and Ultimate Reality: Quantum Theory, Cosmology, and Complexity*, ed. John D. Barrow, Paul C. W. Davies, and Charles L. Harper Jr. (New York: Cambridge University Press, 2004), 459–491, <https://arxiv.org/abs/astro-ph/0302131>.

Тепер уявімо, що до процесу долучилася людина, якій дійсно цікавий уміст скриньок. *Першим ділом* на папері вона запише всі вирізняльні ознаки *обидвох* скриньок. Потім використає всі свої знання законів імовірностей і врешті-решт запише нижній рядок: «*Отже*, за моїми підрахунками, ймовірність того, що діамант сховано у скриньці Б, становить 85%». Про що свідчить цей запис? Вивчаючи ланцюг причиново-наслідкових зв'язків, внаслідок якого запис фізичним чорнилом і з'явився на папері, я бачу, що цей ланцюг тягнеться через усі прикмети фізичних скриньок і залежить від них. Тому у світах, в яких проявляються інші ознаки, у нижньому рядку записана інша ймовірність.

Тому запис допитливого розвідника сплутаний з прикметами та вмістом скриньок, тоді як запис вправного сперечальника є лише свідченням про те, чий власник більше заплатить. Між тими двома свідченнями, на які вказує чорнило, величезна різниця, хоча тому, хто читає чорнильні закарлюки, слова можуть видаватися однаковими.

Від того, який алгоритм записує нижній рядок ваших міркувань, залежить ваша ефективність як раціоналіста. Якщо при гальмуванні ви чуєте скрегіт металу і не дуже хочете витратити гроші на ремонт гальм, ви можете почати шукати причини, чому ремонт не потрібен. Однак дійсний відсоток копій вас, які вижили у гілках Еверетта або у світах Тегмарка, — їх ми візьмемо для вимірювання вашої ефективності як раціоналіста, — визначається алгоритмом, відповідальним за висновок, на користь *якого* ви шукаєте аргументи. У цьому випадку справжній алгоритм звучить як «Не лагодь нічого дорогого». Якщо це хороший алгоритм, то й добре, а як ні — що ж. Аргументи, які ви дописуєте над нижнім рядком, однаково нічого не змінять.

Цим есеєм я звертаю увагу на ваші алгоритми мислення, тому не потрібно розглядати його як Повністю Загальний Контраргумент проти висновків, які вам не до вподоби. Якщо ви платите собі за те, щоб лишатися при своїх переконаннях, посправжньому розумним аргументом буде сказати: «Мій суперник — вправний сперечальник». Найуправніший сперечальник

на Землі може стверджувати, що сонце світить, і все ж надворі все одно, мабуть, день.

Які засвідчення рахуються за відфільтровані

У попередньому есеї я розглядав дилему вправного сперечальника, якого найняли продати скриньку з діамантом всередині або без нього. Вправний сперечальник зауважує, що на скриньці поставлена синя печатка, а ще відомо те, що скриньки з діамантами частіше, ніж порожні, мають синю печатку. Що це означає для баєсіанця? Що ви безапеляційно мусите оновити свої імовірності, чого і хоче від вас вправний сперечальник?

Якщо ви можете оглянути скриньку без посередників, сполучити всі прикмети не має стати для вас проблемою. А що як ви не можете подивитися скриньку без посередників? Що як єдині наявні у вас свідчення — слова вправного сперечальника? Хоча закон і зобов'язує його висловлювати тільки істинні твердження, всієї інформації він не розкриває. Адже якщо кожне твердження вправного сперечальника — обґрунтоване свідчення, як ви можете не оновлювати свої ймовірності? Невже можна забути, що в такій-то пропорції гілок Еверетта або копій світів Тегмарка, де скринька Б проштампована синьою печаткою, вона ж і ховає в собі діамант? Згідно з Джейнзом, баєсіанець завжди повинен обумовлювати свої оцінки всіма відомими свідченнями — інакше виникає парадокс. Однак за наявності достатньо різноманітних ознак, про які вправний сперечальник розповідає вибірково, він може змусити вас повірити у те, що потрібно йому. Звучить не дуже.

Поглянемо на простіший випадок з несиметричною монетою, яка може випадати «гербом» у 2/3 випадків і «числом» в 1/3 випадків або навпаки. Що перший, що другий випадки апріорі рівноймовірні. Кожне випадання «герба» — біт свідчення,

що монета упереджена у бік «герба», як спостереження «числа» — біт, що переважена у бік «числа».¹ Я підкидаю монету десять разів і кажу, що «на четвертому, шостому і дев'ятому підкиданні випав “герб”». Яка ваша апостеріорна ймовірність, що монета упереджена у бік «герба»?

Відповідь: вона може бути якою завгодно залежно від того, який причиново-наслідковий ланцюжок стоїть за моїми словами, за моїм вибором повідомляти про певні підкидання.

- Можливо, я дотримуюся алгоритму повідомляти результати четвертого, шостого та дев'ятого підкидань попри результати решти. Якщо ви знаєте, що я використав цей алгоритм, апостеріорні шанси складають 8:1 на користь переважання «герба».
- Я міг би повідомляти про всі підкидання і тільки ті, в яких випав «герб». У такому разі ви знаєте, що решта сім підкидань випали «числом», тому апостеріорні шанси складають 1:16 проти того, що монетка упереджена у бік «герба».
- Я міг би взяти і заздалегідь повідомити результати четвертого, шостого і дев'ятого підкидань тільки у тому випадку, якщо ймовірність упередженості монетки у бік «герба» перевищує 98%. То що-тощо.

Візьмімо задачу Монті Холла:

Ви берете участь у телегрі, в якій вас просять обрати одні з трьох дверей. Кожна веде до однієї кімнати. Вам відомо, що за одними дверима 100 тисяч доларів, а за двома

1. У цьому контексті біти — мірило вагомості свідчень; логарифм ймовірностей з основою 1/2. Припустімо, у питання рівно дві можливі (взаємозаперечні) відповіді, і спочатку ви приписуєте п'ятдесятивідсоткову ймовірність кожній відповіді. Тоді якщо я кажу вам, що вірна перша відповідь (і ви свято вірите моїм заявам), ви здобули один біт свідчень. Якщо ж існує чотири рівноймовірні варіанти і я кажу вам, що правильний перший, я даю вам два біти. Якщо розподіл іде на вісім варіантів, кажучи «правильний», я даю вам три біти тощо. Детальніше про це розписано в есеї «Скільки потрібно свідчень?» у книзі «Мапа і територія».

іншими порожньо. Ведучий просить зробити вибір — ви обираєте двері №1. Ведучий відчиняє двері №2, за якими порожня кімната. Чи захочете ви змінити свій вибір на користь дверей №3? Чи триматиметеся свого початкового вибору?

Відповідь залежить від алгоритму ведучого. Якщо ведучий завжди відчиняє двері до порожньої кімнати, вам слід змінити вибір на користь дверей №3. Якщо ведучий завжди відчиняє двері №2, хай що за тими дверима, ймовірність, що за дверима №1 та №3 гроші, в обох випадках становить 50%. Якщо ведучий відчиняє двері лише тоді, коли ви спочатку обрали двері з грошима, то вам однозначно слід обирати двері №1.

Ви маєте зважати не просто на те, що за дверима №2 порожньо, а й на те, що ведучий *обрав* саме ці двері. Багатьох спантеличує стандартна задача Монті Холла, оскільки учасники беруть до уваги тільки відсутність виграшу за дверима №2, тому ймовірність виграти гроші розподіляється рівномірно між двома іншими дверима. Ось тому баєсіанці повинні обумовлювати свої оцінки всіма наявним знанням — інакше виникає парадокс.

Коли хтось каже: «Вчетверте випав “герб”», ми враховуємо не те, що монетка вчетверте випала «гербом», і не підмножину усіх можливих світів, де монетка вчетверте випала «гербом», а скоріше підмножину усіх можливих світів, в яких мовець, дотримуючись певного алгоритму, *сказав*: «Вчетверте випав “герб”». Вимовлене речення не сама реальність; не дозволяйте самим лише значенням слів збити вас на манівці.

Більшість судових процесів виходять з теорії, що у кожній справі є рівно дві протилежні сторони і що легше знайти двох упереджених людей, аніж одного неупередженого. Теорія: між сторонами обвинувачення та захисту у *когось* є мотив представити той чи інший доказ, тож суд побачить всі докази. У дилемі зі скринькою двоє вправних сперечальників майже так само ефективні, як і допитливий розвідник. Але ця ситуація стосується двох скриньок. Часто дійсність підкидає багатошарові, глибокі

задачі та неочевидні відповіді, до яких не готові ні «блакитні», ні «зелені», які тільки знай волають одне на одного.

Не зловживайте принципом фільтрування свідчень як Повністю Загальним Контраргументом, щоб виключати всі ті дані, які вам муляють. Наприклад: «Той аргумент відфільтрований, тому я можу не зважати на нього». Якщо ж вам муляє аргумент опонента, ви свідомі теми обговорення і вам не байдуже, чию сторону займати. Можливо, ви знаєте найсильніші аргументи своєї сторони. Ви не маєте підстав, спираючись на протилежний аргумент, припускати існування нових іще не бачених сприятливих ознак чи передвісників. Отже, ви лишилися сам на сам з незручними свідченнями, і блакитна печатка на скриньці Б досі слугує свідченням.

Але якщо ви чуєте аргумент уперше і лише від однієї сторони, не втрачайте пильності. Зрештою, навряд чи хтось *повністю* *сходу* довірятиме теорії природного добору, аж поки не вислухає п'ятихвилинні промови креаціоністів. Тоді усвідомлять, що теорія надійна.

Раціоналізація

Весеї «Нижній рядок» я писав про дилему двох скриньок, з яких тільки в одній був діамант. На прикладі допитливого розвідника та вправного сперечальника я продемонстрував два протилежні підходи. Допитливий розвідник записує усі ознаки, обдумує їх і зрештою виводить: «*Отже*, за моїми підрахунками, ймовірність того, що діамант сховано у скриньці Б, становить 85%». Вправний сперечальник працює на того, хто дасть найвищу ціну: починає з твердження «*Отже*, у скриньці Б сховано діамант», а потім відбирає підхожі ознаки, які перелічує над висновком.

Перший підхід — раціональність. Другий загальновідомий як раціоналізація.

Раціоналізація. Курйозне слово. Сказав би навіть *хибне*. Адже годі «раціоналізувати» те, що від початку раціональності не стосувалося. Це як «брехню» назвати «істинізацією».

На рівні опрацювання різниці між ними колосальна:

1. Почати зі свідчень і далі виконати обчислення ймовірностей, щоб дійти до ймовірного висновку. (Записати усі ознаки, які виляються у таку ймовірність у нижньому рядку, яка залежатиме від початкових ознак.)
2. Почати з висновку і далі виконати обчислення ймовірностей, щоб отримати свідчення, що нібито підтверджують цей висновок. (Записати нижній рядок, а потім повернутися до відбору ознак і прикмет, які демонструють висновок.)

Яка дурість — витворити оманливо схожі слова «раціональність» та «раціоналізація», які описують принципово відмінні мисленнєві процеси! Мені б хотілося таких слів, які наголошують на алгоритмічній різниці двох процесів, скажімо:

«раціональність» та «велетенська всепоглинальна когнітивна чорна діра».

Не кожна зміна породжує покращення, та жодне покращення неможливе без змін. Дискутуючи про певне твердження, ви не зможете видобути для нього більше правди. Можете перекопати більше людей у його правдивості, проте не зробити його більш *правдивим*. Без змін переконань покращувати їх, знаєте, ніяк не вийде. Адже раціональність — це процес уточнення переконань шляхом їхньої зміни. Мета раціоналізації — укоренити переконання. З огляду на її прагматичні наслідки і зворотний алгоритм дії, краще б її назвали «антираціональністю».

Раціональність — рух *за* течією: ми збираємо і зважуємо свідчення, а потім видаємо висновок. От допитливий розвідник плыв за течією: *спочатку* він зібрав свідчення, записав перелік усіх видимих прикмет; обдумавши їх, він *дійшов* до попередньо невідомої ймовірності, що саме у цій скриньці лежить діамант. Поки процес раціональності потоком ніс розвідника, він і не підозрював, куди течія його приведе. Через те йому і було так *цікаво*. Хто ступає Шляхом Баєса, знає, що апіорна ймовірність дорівнює очікуваній апостеріорній ймовірності. Адже якщо ви розумієте, куди вас принесе течія, ви вже на місці.

Раціоналізація — це рух *проти* течії: від висновку до підібраних свідчень. Спершу ви записуєте нижній рядок. Місце призначення вже відоме і фіксоване. Опрацювання зводиться до підбору підхожих аргументів, якими ви заповните порожні рядки зверху. У цьому процесі верхні строки стають невідомими змінними.

Боюся, що у колах традиційних раціоналістів не заведено напоумлювати одне одного щодо різниці між рухом за течією чи проти неї. За мірками традиційної раціональності немає нічого осудного у тому, що науковець висуває свою облюблену гіпотезу, а потім береться шукати експеримент, який підтверджує її. Традиційний раціоналіст схвалив би такий підхід: «Оця гордість — двигун, який рухає науку». Такий двигун *дійсно* просуває науку.

Знайти по-різному упереджених обвинувача та захисника легше, ніж одного неупередженого.

Лише на підставі розповсюдженості якоїсь поведінки не варто судити про її прийнятність. Краще б ті науковці, висунувши улюблену гіпотезу, бралися за її *тестування* заради *цікавості* — ставили експерименти, які скеровували їхні переконання у невідомому напрямку.

Коли ви справді не підозрюєте, куди рухаєтеся, гадаю, пункт призначення викликатиме у вас інтерес. Допитливість — перша чеснота: без неї запитання втрачають мету, а навички — напрям.

Відчуйте потік Сили — і переконайтеся, що він не тече назад.

Раціональний аргумент

Уявіть: ви працюєте політехнологом. І от одного дня вас наймає кандидат від Партії зелених на посаду міського голови Гедліберга Мортімер Снодграсс. От ви читаете посібник з раціональності, й у вас виникає таке питання:

— Як мені створити бездоганний раціональний аргумент на користь головування Мортімера Снодграсса у Гедліберзі?

— Мені шкода, але так не можна.

— Що? — ви зриваєтеся на крик. — А що як я використаю тільки надійні свідчення на його підтримку? А що як кожен наведений факт відповідатиме істині (принаймні у моїй моделі), щоб за Баесом він був доречним свідченням?¹

— Мені шкода, але все ще ні. Наперед конкретизувавши висновок свого аргументу, ти програв.

Цього року усім кандидатам на посаду міського голови редакція газети «Вісті Гедліберга» розіслала по анкеті із шістнадцятьма питаннями. Серед них були, зокрема, такі, як «Чи пізнали Ви вітру ніжні кольори?» та «Ви колись нюхали?». Однак сталася прикрість: перед публікацією відповідей в офіс редакції влучив метеорит. Вас ця звістка засмутила, оскільки ваш кандидат випереджає опонентів по п'ятнадцятих пунктах з шістнадцяти. Єдиний камінь спотикання — хіба що питання №11: «Чи доводилося Вам колись бути суперлиходієм? Чи залишаєтеся ним до сьогодні?».

І от вас долає спокуса опублікувати результати відповідей як частину виборчої кампанії... питання №11 ви, безумовно, ховаєте від громадськості.

Ось тут і перетинає кордон між *раціональністю* та *раціоналізацією*. Тепер виборці вже не можуть спиратися лише на представлені свідчення — їм доведеться враховувати ще й

1. Див. есей «Що таке свідчення» у книзі «Мапа і територія».

представлення тих свідчень і думати, чи, бува, не приховали щось від них.

Ба більше, ви перетнули кордон уже тоді, коли перед рішенням про публікацію задумалися, наскільки вигідними будуть результати опитування для вашого кандидата. «Що? — зриваєтеся на крик. — Під час виборчої кампанії публікувати невідгідні факти про свого кандидата?». Поставте себе на місце виборця, який роздумує над тим, за кого віддати голос. Навіщо вам піддавати цензурі якусь корисну інформацію? Якби вам було посправжньому цікаво, ви б не переходили до цензури. Якби ж то ви спершу *відштовхувалися* від свідчень, а вже потім робили вибір (завчасно невідомий), а не *настоювали* на конкретному кандидатові, під якого підібрали аргументи.

Логічний аргумент — це такий, що впливає із засновків. Тому наступний аргумент логічним не є:

- Усі прямокутники — чотирикутники.
- Усі квадрати — чотирикутники.
- *Тому* усі квадрати — прямокутники.

Від хибної логіки цей силогізм не рятує ні правдивість засновків, ні висновку. Важливо відрізнити логічні умовиводи від алогічних і не потурати їм навіть попри те, що їхні висновки часом правдиві. Насамперед це розрізнення може вплинути на те, як ми переглядаємо свої уявлення з урахуванням нових свідчень. А ще — недбалість входить у звичку.

Передовсім цей силогізм не вказує на справжнє пояснення. Можливо, всі квадрати — прямокутники, але не *тому*, що обидва — чотирикутники. Цей силогізм можна назвати лицемірним, оскільки у нього наведені причини не збігаються зі справжніми.

Якщо ви хочете навести чесний раціональний аргумент *за свого кандидата*, спробуйте зробити так:

- зберіть усі посильні свідчення щодо різних кандидатів *перед тим, як вас наймуть*;

- складіть контрольний список, за яким будете оцінювати тих кандидатів;
- послідовно опрацюйте цей список;
- обирайте переможця;
- запропонуйте йому свої послуги політтехнолога;
- коли до вас звернуться по агітаційний матеріал, просто роздрукуйте свій список.

Тільки так ви можете запропонувати *раціональний* ланцюжок аргументів: від початкових записів *поток*ом свідчень вас принесе до нижнього рядка. Те, що *насправді* визначає ваш нижній рядок, — єдине, що ви можете *чесно* вписати в рядки вище.

Витуріть справжні вразливості з переконання

Кілька років тому через глибоку і немічну старість у віці дев'яноста років померла моя прабабуся. Хоч я й не був з нею добре знайомий, з якихось далеких спогадів пам'ятав, як вона готувала фаршировану рибу. Пам'ятав її обличчя та доброту. На похоронах прабабусі мій двоюрідний дід, який доглядав за нею останні кілька років, виголосив промову. Ковтаючи сльози, він розказував, що Господь забирав його матір частинами: спочатку її пам'ять і дар слова, а потім — посмішку. А коли Господь забрав у неї посмішку, двоюрідний дід зрозумів, що лишилося їй недовго, бо вона вже майже повністю згасла.

Його моторошна розповідь не на жарт збентежила мене — ніколи б не подумав, що мій двоюрідний дід пов'яже Бога зі смертю прабабусі. А здивувався я, бо євреї звикли ігнорувати логічну причетність Бога до цієї трагедії, адже це Він дозволив когось померти. Згідно з юдейською теологією, Бог безперервно підтримує цей усесвіт і визначає кожну подію у ньому. Але у буденному житті євреї виводять логічні висновки з цього переконання тільки у щасливих випадках. Кажучи «Господь зробив це!» тільки тоді, коли Він благословляє вас дитиною, й ігноруючи думку «Господь зробив це!», коли у жінки стається викидень або дитина народжується мертвою, ви формуєте собі викривлений образ милосердного Господа.

Тому, почувши, як двоюрідний дід пов'язує немічну старість його матері з добре пропрацьованим планом Божим, я неабияк здивувався. Він порушував — як я це бачив — звичай самообману серед вірян.

Помітив би я тоді своє спантеличення — зробив би несподівано успішне передбачення. Невдовзі після нашої розмови двоюрідний дід відмовився від юдаїзму. (Наскільки мені відомо, крім мене, він був єдиним, хто наважився на такий крок.)

Сучасний ортодоксальний юдаїзм годі порівняти з іншими відомими мені релігіями, тому навіть не знаю, як описати його людям, яких ніколи не примушували вивчати Мішну́ та Гемару́.¹ Хоча традиція розпитування в юдаїзмі існує, але саме розпитування *таке собі*... Навряд чи я когось здивую тим, що на щотижневій промові ра́бин вказує на суперечність між сімома днями творіння та віком усесвіту від Великого вибуху (13,7 млрд років). А все тому, що у нього, як йому здається, є міцне пояснення на основі трьох біблійних цитат, Мідрáша² і сяк-так зрозумілої статті з журналу *Scientific American*.³ В ортодоксальному юдаїзмі ви можете помічати неузгодженості та суперечності, але потім доведеться придумати хитромудре пояснення. Хто вигадує найскладніше, отримує приз.

Традиція розпитування, звісно, існує. Але ви беретеся критикувати лише те, що потім збираєтеся захищати. Ви обираєте мішені, які напевно зможете відстояти.

У сучасному ортодоксальному юдаїзмі мені не доводилося чути про особливий наголос на чесноті сліпої віри. Сумніви допускаються. Не можна сумніватися так, щоб опісля ви *справді* втратили віру.

Гадаю, більшість освічених ортодоксальних євреїв бодай раз піддавала сумніву свою віру. Однак процес розпитування відбувався якось так: «Скептики кажуть, що семиденне творення світу за Торою не точне з погляду науки. Але чи змогли б автохтонні ізраїльські племена, які збиралися на горі Синай, збагнути наукову істину, навіть якби хтось її і підніс? А в них взагалі було слово, яке позначає “мільярд”? Куди легше дивитися на історію семи днів як на метафору: спочатку Господь створив світло, яке символізує Великий вибух...».

Чи серед усіх ця вразливість юдаїзму найочевидніша? Читатимете Тору далі — дізнаєтеся, як Бог убив усіх єгипетських

1. Мішна́ — збірка усного юдейського закону і традицій. Гемарá — збірка коментарів до Мішни. — Прим. пер.

2. Мідрáш — збірка для тлумачення текстів Святого Письма. — Прим. пер.

3. Найстаріший науково-популярний американський журнал. — Прим. пер.

первістків чоловічої статі, щоб переконати необраного фараона звільнити рабів, яких можна було б телепортувати з країни. Типовий ортодоксальний єврей точно знає цей епізод — щороку ж вони збираються у синагозі читати Тору повністю, і ця подія вважається великим святом. Ім'я «Песах» (івр. «оминути») позначає Господа, який *оминув* єврейські будинки і забрав життя у єгипетських первістків.

Здебільшого сучасні ортодоксальні євреї набагато добріші та культурніші, якщо порівнювати їх з редакторами Старого Завіту. Навіть рабини у віці культурніші. Під час песахального седера⁴ проводиться такий ритуал: із чаші ви берете десять крапель вина. Вони символізують Десять кар та підкреслюють страждання єгиптян. (Звісно, ви можете поспівчувати єгиптянам, але не настільки, щоб підвестися і сказати: «Яка *дурість!* Як таке взагалі можна робити!».) Так оприявнюється цікавий контраст: рабини були значно гуманнішими за укладачів Старого Завіту, щоб помітити жорстокість Десяти кар. У ті часи наука була слабшою, тому рабини могли розмірковувати над більш неприємними моментами Писання і не боятися, що повністю втратять віру.

І ви навіть не здобудетесь *запитати*, чи не дискредитує цей випадок Бога, тож і не доведеться швидко виправдовуватися фразами на кшталт «Шляхи Господні несповідимі!», «Чи ж глина скаже гончареві: “Що ти вчиняєш?”» або «Бог забирає тих, хто чистий серцем, щоб вони перебували з Ним у світлі Його слави!». Про цю частину питання не заведено задумуватися.

Підозрюю: освічені віряни лишаються релігійними, бо, коли у них виникають сумніви, вони підсвідомо завдають обережних ударів по своїх переконаннях лише в найсильніших місцях — там, де впевнені, що зможуть їх відстояти. Ба більше, це саме ті місця, де повторення звичних аргументів лише зміцнює їхню впевненість.

Певно, повторювати заданий захист «Хіба наука не засвідчує, що всесвіт — беззмістовне скупчення сновигаючих атомів?»

4. Ритуальна трапеза, якою розпочинається свято Песах. — Прим. пер.

доволі приємно, оскільки воно підтверджує, що сенс усесвіту бере початок у Богові. Про таке думати набагато приємніше, ніж уявляти неписьменну матір з Єгипту, яка ридає над колискою мертвого сина. Хто *раптово* задумується над стражданнями матері, ставить під сумнів свою віру в юдаїзм *по-справжньому* і наврод чи залишиться юдеєм надовго.

Я не ставлю собі за мету розгромити ортодоксальний юдаїзм. Гадаю, і на вбивство перворідних знайдуться свої відповіді — можливо, навіть з десятків. У процесі раптових рефлексій віри більш імовірно, що такий скептик завдаватиме удару по найміцніших стовпах і повторюватиме заспокійливі відповіді, а найвразливіші, скоріше, не чіпатиме. Такий скептик, гадаю, зупиниться на найпершій відповіді і заспокоїться, не зробивши наступного кроку до критики цього стовпа віри. Куди точніше було б назвати цей есей не «Витурити справжні вразливості з переконання», а «Звичка не думати мимоволі про найболючіші слабкості свого переконання».

Передусім лещата релігії не розтискаються, бо люди просто не хочуть думати про вразливості сповідуваної релігії. Як на мене, справа більше в інстинкті, ніж у натренованості. Вони не замислюються про вразливості релігії з тієї ж причини, з якої не торкаються розпеченої плити — через нестерпний *біль*.

Та якщо ви вже тут: коли піддаватимете сумніву своє найоблюбленіше переконання, заплющте очі, почистьте голову від зайвих думок, зчепіть зуби і свідомо думайте про найболючіше. Забудьте про класичні відмовки, якими робите собі приємне. Спитайте себе, що *розумні* люди, які не згодні з вами, могли б відповісти на вашу першу і другу відмовку. Витягніть те заперечення, від думки про яке вас проймають дрижаки, в осмислену частину свідомості. Стукніть себе у сонячне сплетіння. Встроміть ножа прямисінько у серце, проверніть руків'я, поглиблюючи поріз. Перед ликом болю повторюйте наступні рядки:⁵

Що істинне — вже сталося таким.

5. Eugene T. Gendlin, Focusing (Bantam Books, 1982).

Відверте визнання істини не зробить її гіршою.

Не бути відкритим до неї — не змушує її зникнути.

І тому що вона істина — вона те, що присутнє, аби стикатися з цим.

Будь-що неістинне не присутнє, щоб бути пережитим.

Люди можуть прийняти, чим є істина,

Бо вони вже переживають її.

Заангажована зупинка та заангажоване продовження

Попри те, що де в чому я не погоджуюся з поглядами спільноти «швидкого та економного» підходу,¹ — як на мене, додають забагато лимонів у лимонад — мені також здається, що саме вони розробляють найбільш *психологічно реалістичні* моделі серед усіх шкіл теорії рішень. Більшість експериментів зводяться до того, що учасникам пропонують декілька варіантів. Результат експерименту — власне вибір. Вони збагнули, що у житті людина має *виготовити* варіанти дій. А як уже вона *це* робить, стало предметом їхнього дослідження.

Хоча під час експериментів часто вам підносять свідчення на срібній тарілочці, у житті ж їх доводиться збирати (причому цей процес може бути не з дешевих), а вже на якомусь етапі ви вирішуєте спинити пошуки і зробити вибір. Коли ви плануєте купити будинок, навряд чи обираєте з десяти будинків, навряд чи берете екскурсію тими будинками перед тим, як зробити бодай якийсь вибір. Ви дивитесь один будинок, другий, порівнюєте їх, підлаштовуєте свої прагнення — переглядаєте, наскільки вам потрібно жити поряд з роботою, наскільки ви готові спорожнити гаманець, — думаєте, який будинок подивитися наступним. І в якийсь момент ви вирішуєте зупинитися і зробити вибір.

Томас Гілович розрізняє *заангажований скептицизм* та *заангажовану довірливість*, причому наголошує, що небажані висновки люди опрацьовують прискіпливіше за бажані. Тобто заангажований скептик питає, чи свідчення *примушують* його прийняти висновок; заангажований легковірний питає, чи свідчення *дозволяють* йому прийняти висновок.

Як на мене, при психологічно реалістичних пошуках аналогічно можуть траплятися *заангажована зупинка* та -

1. Див. <https://web.archive.org/web/20190529132448/http://fastandfrugal.com/>

заангажоване продовження. У нас є прихований мотив обрати поточно «найкращий» варіант, тож ми зупиняємося, робимо вибір і відкидаємо думку про можливу наявність інших варіантів. Коли ж у нас є прихований мотив відкинути поточно найкращий варіант, у нас також з'являється прихований мотив утриматися від судження, відклавши його до появи додаткових свідчень, продукувати нові варіанти — знайти щось, будь-що, *аби тільки не доходити висновку*.

Історія статистики пам'ятає скандальні слова засновника дисципліни Рональда Фішера, що ніякого *причинного* зв'язку між курінням та раком легень не було встановлено. «Кореляція ще не причиновість», — свідчив він перед Конгресом. Може, то взагалі у курців був якийсь ген, через який вони були схильні до куріння і раку легень.

Або, може, Фішера найняли консультантом до тютюнового підприємства, через що він вирішив, що зібраних свідчень для остаточного висновку замало, тому краще пошукати ще. Між іншим, Фішер був курцем і помер у 1962 році від колоректального раку.²

Подібно до інших форм заангажованого скептицизму, заангажоване продовження лиш намагається сховатися за доброчесною раціональністю. Хто взагалі виступає проти збирання свідчень?³ Я виступаю. Часто збирати свідчення дорого і ще й повільно. І годі шукати якусь доброчесність у відмові враховувати вже наявні свідчення. Завжди можна змінити думку пізніше.⁴

А заангажована зупинка настає там, де бояться третьої альтернативи, де ви воліли б не помічати очевидний контраргумент

2. Примітка *ad hominem*: Фішер походив зі школи частотницької статистики. Баєсів підхід дозволяє приходити до більш обґрунтованих висновків про імовірнісну причину. Див.: Judea Pearl's *Causality: Models, Reasoning, and Inference*. — Прим. авт.

3. Див. Robin Hanson, "Cut Medicine In Half," *Overcoming Bias* (blog), September 10, 2007, <https://www.overcomingbias.com/2007/09/cut-medicine-in.html>.

4. Позірну суперечність можна вирішити так: витратити годину на обговорення проблеми і ретельно почистити розум від усіх висновків не те саме, що чекати десять років на ще одне дослідження вартістю 20 млн доларів. — Прим. авт.

на ваш аргумент, і не тільки. Вона настагає, коли ви щось робите лише через задоволення від активності, коли боїтеся пошкодити теплий кокон моральної втіхи, за який віддали чималі гроші, коли не хочете досліджувати, наскільки ефективний ваш план.⁵ Настагає там, де ваші переконання та очікування розходяться між собою, і у вас знаходяться підстави остерігатися будь-яких нових свідчень.⁶

Мораль: рішення припинити пошук (тимчасово чи назавсім), як і сама процедура пошуку, може бути упередженим та проростати з прихованих мотивів. Заангажовану зупинку варто запідозрити, коли ви припиняєте пошуки після того, як прийшли до задовільного висновку. І при цьому ви ще не зібрали багато швидко- і легкодоступних свідчень на вебсайтах, не обдумали контраргументи до контраргументів, не заплущили очей на п'ять хвилин за годинником, пробуючи подумати над кращим рішенням. Заангажоване продовження варто запідозрити, коли потік свідчень рухається у небажаному напрямку, і ви вирішуєте, що для прийняття неприємного рішення потрібно більше свідчень — *дорогих і ресурсозатратних*, — які ще не скоро вдасться зібрати (те, що можна нагуглити за тридцять хвилин, не рахується).

5. Див. “Can’t Say No’ Spending.” https://lesswrong.com/lw/kb/cant_say_no_spending.

6. Див. есей «Віра у віру» у книзі «Мапа і територія».

Вигадане обґрунтування

Багато християн, котрі втратили віру, тепер беруть Біблію за моральний кодекс. На цю позицію Сем Харріс відповідає як атеїст: «І ви, і я знаємо, що на створення книги, у якій мораль була б більш послідовною та милосердною за біблійну, пішло б п'ять хвилин».¹ Тоді вони починають наполягати, що Біблія має цінність літературну. Чому б тоді не вважати таким твором «Володар перснів», який значно якісніший? Та навіть попри стандартну критику Толкінової моралі, його трилогія більш етична за Біблію. Чому тоді люди носять на шиях хрестики, а не персні? Та навіть «Гаррі Поттер» виграє у Біблії за літературною цінністю та моральністю.²

— Як ти можеш виправдовувати покупку діамантового ноутбука за мільйон доларів, коли у багатьох людей його взагалі немає? — питаєте ви свого друга.

— Подумай про те, у скількох людей буде робота — у виробника ноутбука, його рекламного агентства. Вони замовлятимуть їжу, ходитимуть до перукарні, чим покращуватимуть стан економіки, тож інші люди теж колись зможуть дозволити собі ноутбуки, — відповідає.

Однак придбати п'ять тисяч ноутбуків для організації «Ноутбук для дитини»³ було б набагато *ефективнішим* рішенням. Так, тамтешні виробники будуть при роботі, а ноутбуки потраплять у потрібні руки.

1. З діалогу Харріса з Ендрю Салліваном «Релігія побудована на брехні?» (Is Religion Built Upon Lies?), який можна прочитати за посиланням <https://www.samharris.org/blog/sam-harris-vs-andrew-sullivan>. — Прим. авт.

2. Якби я дозволив собі бути більш жорстоким, порівняв би Біблію із серією «Кушіль» Джаклін Кéрі. — Прим. авт.

3. *One Laptop per Child* — неприбуткова організація у США, яка ставить собі за мету забезпечувати дітей бідних країн ноутбуками для освітніх цілей. — Прим. пер.

Я вже писав про опір третій альтернативі. Проте цей випадок стосується не зовсім заангажованої зупинки. У такому разі це означало б, що заявник спочатку бодай намагався шукати.

В есеї «Нижній рядок» я відзначив, що тільки справжні визначники наших переконань узагалі можуть впливати на нашу точність у реальному світі. Тільки справжні визначники наших дій можуть вплинути на те, наскільки результативно ми досягаємо цілей. Насправді, коли друг купляв ноутбук, у нього виникла думка «Оце шик!». Отакою і була справжня причинова історія його рішення придбати ноутбук. Ніяке обґрунтування не змінить цього — хіба що воно дасть поштовх новому процесу пошуків, який змінить висновок. Знаєте, *дійсно* змінять. Критика ж, яку породжує відчуття обов'язку, зводиться здебільшого до формальної перевірки. Такі собі вільні вибори в однопартійній державі.

Щоб аргументувати літературну цінність Біблії, ви мали б спочатку неупереджено прочитати інші книжки-кандидати, аж поки натрапите на книгу найвищої літературної якості. Один із обґрунтованих критеріїв для відбору кандидатів — популярність, тому, гадаю, ви могли б зупинитися на прочитанні Шекспіра, Біблії та «Гюделя, Ешера, Баха». (Інакше — було б збігом натрапити на Біблію серед мільйона інших кандидатів.) Та найбільша складність саме у «неупередженості» прочитання. Нічого складного, якщо ви не християнин. Та якщо ви послідовник учення Христа...

Але, звісно, нічого такого і близько не було. Ніхто не проводив ніяких пошуків. Напис «літературна цінність» над нижнім рядком «Я ♥ Біблію» — історичне спотворення того, як насправді виник нижній рядок. Ніби нам продають кота у мішку. Не завдяки літературній цінності виник нижній рядок. Не з того засновку притягли за вуха висновок.

Якщо ви дійсно піддаєте свій висновок критиці, якщо критика має силу, потенційно вона може розвіяти його. Така критика *дійсно* видозмінює «справжній алгоритм», котрий стояв за вашим висновком. Змінює сплутаність висновку з можливими

світами. Але люди значно переоцінюють, наскільки вони *готові* міняти свою думку.

Скільки людей торочать, що вони відкриті до нових ідей. І ви думаєте, що усі вони від того частіше оновлюють свої переконання?

Дайте-но вгадаю: так, ви визнаєте, що захотіли купити ноутбук за мільйон доларів, бо вас охопило спонтанне бажання. І ви погоджуєтесь, що цей процес прийняття рішення розходиться із заявленими цілями. Але відтоді ви вирішили, що вам справді слід витратити гроші так, щоб забезпечувати ноутбуками якомога більше нужденних. І все ж ви *не* знайшли більш ефективного способу досягти цілі, ніж купити діамантовий ноутбук вартістю у цілий статок, бо, ну, ви ж віддали ці гроші на покращення економіки! Геніальний план!

Друже, цей просто дивовижний збіг дуже насторожує. Маю великі підозри, що ця геніальна відповідь у контексті цього прекрасного альтруїстичного критерію X ґрунтується на думці, яка випадково з'явилася у непов'язаному і необґрунтованому процесі Y. Якщо ви не вірите, що кидання кубика дасть правильну відповідь, то наскільки ймовірно, що вона з'явиться у процесі ірраціонального розмірковування?

Украй мало ймовірно керуватися хибними міркуваннями і не припуститися помилок.

Причина відмови справді у цьому?

Часом хтось, бува, дізнається про мої погляди на трансгуманізм — окремо від поглядів на людську раціональність, — частина з яких виглядає доволі екзотично: суперінтелект, Дружній ІІІ тощо. І цей хтось відкидає їх.

Якщо попросити його пояснити причину, часто доводиться чути таку відповідь:

— А чому я маю вірити всьому, що говорить Юдковскі? Він же навіть не доктор наук!

— Щоб люди слухали тебе, було б гарно отримати доктора, — докине ще хтось ні звідти ні звідси.

Або таку пораду дасть і той перший скептик, примовляючи:

— Повертайся, коли здобудеш ступінь доктора наук.

Згоден, що існують як вагомі, так і надумані причини здобувати науковий ступінь. Проілюстрована — серед надуманих.

На несхвальну реакцію щодо тез трансгуманізму може бути багато причин. Більшість із них ґрунтується не на умовиводах, а на впізнаванні шаблонів: тези навівають асоціативні категорії на кшталт «якась дивна ідея», «якась наукова фантастика», «якесь апокаліптичне сектанство» чи «якийсь юнацький максималізм».¹ І в змиг ока, зі швидкістю сприйняття, ідея йде на дно сміттевого бака.

Якщо хтось і скаже: «Яка причина вашої невіри?» — може запуститися процес пошуку пояснень, хоч він не гарантує прибуття до справжньої причини. Під «справжньою причиною» я маю на увазі не *найкращу* причину із запропонованих, а ті, які мали вирішальне значення *саме* в момент відторгнення.

Але при пошуку пояснення скептик наштовхується на те, що звучить як пояснення: «У цього доповідача немає ступеня доктора наук». А між іншим, я і не доктор раціоналістських наук,

1. Див. есей «Що таке свідчення» у книзі «Мапа і територія».

хоча розповідаю тут про людську раціональність. Чому те саме заперечення не виникає тут?

Ближче до діла: якби у мене *був* ступінь, люди все одно не керувалися б цим фактором у своїй довірі кожному моєму слову. А швидше за все, вони відкинуть ідею з тих самих причин, а пошук обґрунтувань закінчиться десь на іншій точці.

Вони скажуть: «Чому ми маємо вірити тобі? Ти ж усього-навсього доктор наук! Таких, як ти, — що собак нерізаних. Вертайся, коли здобудеш визнання у своїй галузі і викладатимеш у провідному університеті».

Але чи люди *справді* вірять пересічним гарвардським професорам, які розповідають про якісь дивні малозрозумілі штуки? Навіть не сподівайтесь.

Якщо ви говорите щось, що новачкові відгонить *химородиною*, а не правите магічні для вуха слухача технічні теревені про лептично-кваркові джгути у вимірах $N+2$, якщо слухач не знайомий ні особисто з вами, ні з предметом вашої галузі, підозрюю, що середньостатистична людина дійсно довірятиме вашим академічним заслугам, а не своєму першому враженню, коли вас номінують на Нобелівську премію. Якщо взагалі довірятиме. Грубо кажучи, вам потрібні такі академічні досягнення, які інші оцінять як «непересічні».

Гадаю, саме таке ставлення пережив на собі Ерік Дрєкслер.² Він поділився своїм баченням нанотехнологій, на що йому казали: «Де технічні подробиці?» чи «Повертайся зі ступенем доктора!». Ерік витратив шість років на те, щоб розписати технічні подробиці, і під керівництвом М́арвіна Мінські³ захистив докторську дисертацію. Опісля вийшла його чудова книга «Наносистеми». Чи змінилася думка про молекулярні нанотехнології тих, хто казав: «Повертайся зі ступенем доктора!»? Наскільки я знаю — ні.

Підприємцям та консультантам, які починають свою справу, варто пам'ятати: не обов'язково саме ті причини, якими вам -

2. Фундатор молекулярних нанотехнологій. — Прим. пер.

3. Дослідник у галузі штучного інтелекту. — Прим. пер.

аргументують відмову, впливають на їх рішення. І перш ніж витрачати величезні зусилля, слід добряче подумати і над цією версією. Якщо інвестор каже: «Якби ж ваші продажі зростали швидше!» чи можливий клієнт каже: «Виглядає привабливо, проте не вистачає X», можливо, їхні слова не варто розцінювати як *справжню* відмову. Усунення озвучених зауважень може бути марнотратством часу.

І є ще дещо варте пам'ятування, коли справа доходить до незгоди. Ми з Робіном Хансоном поділяємо погляд, що двоє раціоналістів не можуть лишатися кожен при своїй думці: між ними не може виникнути спільного знання про епістемічну незгоду — хіба що щось серйозно пішло не так.⁴

У загальних рисах, підозрюю, якщо двоє раціоналістів взяли-ся усувати розбіжності, що лишилися після першого обговорення, вони мають очікувати, що справжні витоки незгоди або геть складно донести, або їх у край важко оприямнити. Кілька прикладів:

- малопоширене, проте добре підкріплене наукове знання чи математика;
- довгі умовивідні дистанції;
- інтуїція, яку важко передати словами, яка, можливо, бере початок з конкретних образів;
- дух професійного середовища (можливо, там були вагомі підстави для цього);
- схеми, розпізнані через досвід;
- суто мисленнєві звички;
- емоційна прив'язаність до віри у певний наслідок;
- страх перед спростуванням помилок минулого;
- глибоко вкорінена потреба самообманюватися через гордість чи інші персональні вигоди.

4. Див. Hal Finney, "Agreeing to Agree," Overcoming Bias (blog), 2006, https://www.overcomingbias.com/2006/12/agreeing_to_agr.html.

Якби це було одне з тих питань, у якому можна викласти на стіл *усі* справжні заперечення, незгода стала б, напевно, настільки очевидною, що усунути її за одне обговорення не було б проблемою.

«Причина відмови справді у цьому?» — це питання, яке незгодні мають поставити *собі*, щоб полегшити життя співрозмовнику. Але й спроби напряду піддавати співрозмовника психоаналізу, певно, зроблять *тільки* гірше (суджу зі свого досвіду).

І все ж — «Причина відмови справді у цьому?» має слугувати тим чесним запитанням для незгодних, яке може допомогти відшукати якийсь конструктивний спосіб розв'язати підпроблему. Можливо, буде гарно взяти собі за правило відкрито питати: «Ця проста і зрозуміла причина вашої відмови справжня? Чи вона ґрунтується на інтуїції Х або галузевому світогляді Y?». А ті непривабливі варіанти на стороні столу Іншого вже на його відповідальності.

Сплутана істина і заразна брехня

«Один з ваших найперших філософів дійшов висновку, що, виходячи з вивчення однієї події чи одного артефакту з будь-якого всесвіту, чистий розум здатен відтворити чи виобразити той усесвіт з моменту його створення й аж до самого кінця...»

— «Перший лénсмен», Едвард Сміт

«Зосередившись на одній події чи одному предметі (скажімо, на камінчику, гірчичному зернятку чи істоті) на такий короткий відтинок часу, як сто років людського життя, почнете розуміти сутність об'єкта уваги».

— «Сірий лénсмен», Едвард Сміт

Маю підстави вважати, що один камінець з якогось пляжу не визначає сутність континентів, країн, політик та людей цієї планети. На інших планетах у просторі-часі, в інших гілках Еверетта існував би точно такий камінець.

З другого боку, повний опис одного камінчика, схоже, включає наші закони фізики. У цьому сенсі з нього впливає весь наш Всесвіт — усі евереттівські гілки.¹

Вивчивши тільки один камінчик, ви можете зрозуміти закони фізики та все, що з ними пов'язано. Із цих законів фізики видно, що планети формуються, тож можна припустити, що цей камінчик походить від однієї з них. З кристалів всередині камінчика і його молекулярної структури, сформованої під дією сили тяжіння, можна дізнатися дещо про масу планети, із суміші елементів у камінчику — дещо про процеси формування тієї планети.

1. Якщо припустити, що не існує дійсно вільних змінних, що здається ймовірним. — Прим. авт.

Я не геолог, тому не знаю, до яких таємниць вони мають доступ. Але мені не важко уявити геолога, якому показую камінець і кажу: «Цей камінець я взяв з каліфорнійського пляжу», на що він відповідає: «Не може бути» чи «Ти брешеш». Можливо, камінець не тієї гірської породи чи недостатньо потертий, щоб належати саме до того пляжу. Я не настільки добре розбираюся в камінцях, щоб точно визначити ознаки, які дозволили б викрити мене у брехні.

Лише Господь може явити правдоподібну брехню. Цікаво, чи існувала колись релігія, яка б могла породити крилатий вираз, схожий на цей. Припускаю (на підставах спростовуваності), що ні: ця думка раціоналістського штибу, навіть якщо її спробують перетворити у теологічну метафору. Проповідь «усе у світі взаємопов'язано, тому що Господь сотворив світ сей і підтримує його» може викликати тепле і розмите відчуття, та коли вам потрібно визначити походження камінців, це твердження вам нічим не допоможе.

Монетка на Землі притягує Місяць з гравітаційним прискоренням приблизно $4,5 \times 10^{-31} \text{ м/с}^2$, тому у якомусь сенсі не буде аж такою помилкою сказати, що кожна подія сплутана з її минулим світловим конусом. А якщо умовиводи можуть поширюватися вперед і назад причиновими мережами, *епістемічна* сплутаність з легкістю може перетинати кордони світлових конусів. Але я не хотів би бути судовим астрономом, який мусив би дивитися на Місяць і з'ясовувати, число чи герб випав на монеті — цей вплив значно менший за квантову невизначеність і тепловий шум.

Якби ви сказали: «Усе з чимось взаємопов'язано» чи «Усе сплутано на основі умовиводів, і деякі сплутаності міцніші за інші» — могли б іще зайти за мудрого, а не «метафізично мудрого».

З погляду фізики, кожна подія в якомусь сенсі становить суму всіх взаємодій і станів у минулому світловому конусі, причому без меж і кордонів між тими станами. Однак перелік *видимих* сплутаностей куди коротший, і, як наслідок, ви бачите щось

на кшталт мережі. Цю закономірність високого рівня я називаю Великою Павутиною Причиновості.

(Може здаватися, що я іронічно пишу це поняття великими літерами. Але якщо щось і заслуговує великих літер, то це поняття у першу чергу потрапляє до цього переліку.)

Казав-бо якимсь сер Вальтер Скотт: «О, які ж заплутані тенета ми тчемо, коли вперше стаємо на стежку брехні».² Не *вся* брехня виходить з-під контролю, адже ми не живемо у настільки справедливому всесвіті. Проте буває і таке, що коли хтось бреше про подію, то мусить вже тоді брехати і про сплутану із нею подію, і так далі:

— Де ти був?

— Та у справах їздив.

— Яких справах?

— Не можу сказати — вели конфіденційні перемовини з великим клієнтом.

— То вони таки пропустили тебе? Оце так новина! Подзвоню твоєму босу — подякую йому за те, що взяли тебе.

— Та він... якраз кудись відійшов...

Люди, на відміну від богів, часто навіть *уявити* не здатні усі події, про які їм доведеться брехати, щоб витворити дійсно правдоподібну вигадку. Слова «Святий Дух запліднив мене» звучали трохи більш імовірно — до того, як у наших моделях світу з'явилися — цитую — Y-хромосоми. Коли генетичне тестування стане більш розповсюдженим, розвіється багато подібних брехень. Роки потому гвалтівників засуджено, а неправдивих обвинувачувачів викривають — на основі свідчень, які вони залишили, не

2. Рядок з поеми «Марміон. Сказання про Флодденські пагорби» (*Marmion: A Tale of Flodden Field*). — Прим. пер.

усвідомлюючи цього. Студент курсу еволюційної біології бачить відбиток природного добору у вовкові, що женеться за кролем, у кролику-втікачеві, у бджілці, яка жалить, а не чемно застерігає про небезпеку. Але брехня креаціоністів здається їм правдоподібною, не сумніваюся.

Як не всі брехні викрито, так і не всіх брехунів покарано, — світ, у якому ми живемо, назвати справедливим не випадає. Але не всі брехні такі безпечні, як здається їхнім творцям. Цікаво, скільки грішків стало б відомо баєсівському суперінтелекту, якби він провів (неруйнівне?) нанотехнологічне сканування Землі. Принаймні — усі випадки брехні, сліди яких ще можна знайти в будь-якому мозку. А якщо нейробіологам вдасться створити дійсно надійний детектор брехні на основі нейровізуалізації, деякі брехні можуть стати відомими й раніше. Провідний дослідник мікрорухів лицевих м'язів Пол Екман, можливо, вже зараз зміг би розпізнати значну частину людської брехні, якби мав таку можливість.

Як не всі брехні викрито, так і не всіх брехунів покарано. Але Велику Павутину доволі часто недооцінюють. Лише на засвоєння того знання, яке людство *вже накопичило*, піде казна-скільки людських життів. Хто думає, що небожество може створити *досконалу* брехню, яку буде неможливо викрити, недооцінює сплетеність Великої Павутини.

Виходить, краще бути чесним? Не знаю, чи зайшов би я аж так далеко: Навіть за моїми етичними мірками не розкривати писок — цілком прийнятна тактика. Але на відміну від відвертої брехні, чесність або мовчання хоча б зменшують ризик рекурсивних ускладнень, про які ви навіть не підозрюєте.

Про брехню та чорних лебедів

Кілька років тому сімдесятирічний суддя — радник королеви (з 1977 року), носій статусу «Національна гордість Австралії» (1997), лауреат Премії миру ООН (2002), президент-засновник Австралійської комісії з прав людини та рівних можливостей — М́ркус А́йнфелд вийшов на пенсію, хоч періодично і вертався до розгляду важливих справ...

Його на два роки запроторили до в'язниці за низку лжесвідчень під присягою, які почалися зі штрафу на 77 доларів за перевищення швидкості на 6 миль/год^{1, 2}.

Зрештою, вся ця *підозріло доброчесна* теорія — що чесні люди не вміють брехати, що сплутані сліди десь неминуче лишаються і що все це може закінчитися епічним чорним лебедем³ — справді має показові випадки, хоча те, що ми чуємо саме про цей випадок, очевидно зумовлене вибіркоvim висвітленням.

1. https://en.wikipedia.org/wiki/Marcus_Einfeld

2. Приблизно 10 км/год. — Прим. пер.

3. Метафора Насіма Талеба про те, що випадкові або важкопрогнозовані події мають значні наслідки. — Прим. пер.

Темна сторона епістемології

Збрехавши, ви обертаєте правду на ворога.

До ідеї заразної брехні. Якщо ви підберете камінчик з проїзної частини і скажете геологу, що знайшли його на пляжі... Чи знаєте *ви*, що знає геолог про гірські породи? Я не знаю, та підозрюю, що відшліфований водою камінчик виглядає інакше, ніж уламок застиглої лави з колись виверженого вулкана. Ви знаєте, звідки з'явився камінчик на дорозі? У закономірному всесвіті кожен предмет несе позначку свого походження. Брехня ж у цій павутині руйнує зв'язок із джерелом.¹

Що для однієї людини правда може бути довільною і легко заміною вигадкою, для іншої ця правда може кріпитися десятками ланцюжків, які ведуть до картини ширшого знання. Для креаціоніста, наприклад, уявлення, що життя сформоване за «розумним задумом», може звучати як гасло улюбленої спортивної команди для вболівальника. А біологові, щоб переконливо обґрунтовувати розумно спланований організм, довелося б брехати про кожен його аспект. Щоб аргументувати на користь розумного задуму, вам доведеться брехати про будову сітківки ока, структуру мозку, білки, пов'язані не міцними ковалентними зв'язками, а слабкими силами ван дер Ваальса...

Або можна обрати шлях більшості креаціоністів — спотворити теорію еволюції. Брехати не про вузли мережі, а про *загальні* закони, що визначають її зв'язки.

І в спробах приховати *це* вони брешуть про закони науки: мовляв, що означає назвати щось «теорією», або спекулюють на тому, що науковці не впевнені на всі сто.

Вони переходять від брехні про конкретні свідчення до спотворення загальних законів, законів мислення. Щоб брехати про

1. Власне, у коментарях один геолог пише, що більша частина гальки на проїзній частині береться з пляжів, тому він не зміг би відрізнити, але зміг би вказати на відмінності гірської породи з камінцем з пляжу/проїзної частини (https://lesswrong.com/lw/uy/dark_side_epistemology/4xbv). Такий приклад... — Прим. авт.

розвиток *Homo sapiens*, потрібно брехати про еволюцію та закони науки, які задають рамки розумінню еволюції.

Але як інакше? Як людина вибивається з ряду форм життя, спроектованих за розумним задумом (щоб так не виглядало, потрібно брехати про закони еволюції), так і переконання креаціоністів самі по собі вибиваються з науки (у добре організованому розумі для них не знайдеться місця — як не знайдеться місця пальмі на льодовику). Тому ви маєте рознести бар'єри, які перешкоджають такому тлумаченню.

Так починається самообман.

Одна брехня, яку ви розказуєте *собі*, може видаватися доволі правдоподібною... якщо ви не знаєте жодного закону належного мислення чи навіть не підозрюєте їхнього *існування*. І вибір між еволюцією та креаціонізмом здається настільки ж випадковим, як вибір між шоколадним і м'ятним морозивом, настільки ж віддаленим, як і камінчик на узбережжі...

А потім хтось підважує ваше переконання законами належного мислення:

— Які твої свідчення?

— Га? Нащо тобі свідчення?

— Знаєш, переконання вимагають свідчень.

Цей аргумент схожий на ворожого солдата, якого треба нейтралізувати:

— Та розкажи мені! Не всі переконання вимагають свідчень. От для віри в дракона свідчень не треба. Вірю собі, у що схочу. Тому у моєму гаражі живе дракон, і ніяких свідчень мені для цього не потрібно.

— Ем, ні, — відповідає ваш співрозмовник. — Не можна так просто взяти і зробити драконів винятком. Закон про те, що переконання вимагають свідчень, виведений не без підстав. Щоб накреслити коректну мапу міста, тобі треба пройтися вулицями і нанести на папір лінії, які відповідають тому, що ти бачиш. Закон не випадковий. Якщо ти сидиш у вітальні і креслиш лінії від балди, мапа вийде хибною. З украй високою ймовірністю. Мапи

дракона це стосується рівно стільки ж, скільки мапи усього іншого.

Тепер і це пояснення потрібно нейтралізувати як ворожого солдата:

— Хибною з украй високою ймовірністю? Але ж усе-таки шанс є, так? Нащо мені вірити у те, в чому я не буду довічно певен?

Інший сценарій: ви почнете і собі сумніватися, що, можливо, і справді «переконання вимагають свідчень». Але ж воно загрожує вашій цінній брехні. Щойно з'являються перші промені світанку, ви зашторюєте вікно.

Або ще такий сценарій: колись ви чули вислів «переконання вимагають свідчень». Схоже на мудрість, тому ви погодилися з нею на загал. Але ви й помислити не могли, доки хтось не сказав, що ця мудрість *застосовна* і до вашого переконання про дракона у гаражі. І, швидко зметикувавши, відповідаєте: «Дракон — це окрема магістерія».

Мати хибні переконання хоч і зле, але вони не мають бути довічною вадою, тому знаходите помилку — виправляєте. Небезпека починається тоді, коли ви вирішуєте, що *зобов'язані захищати хибне переконання*, свою віру у віру, незалежно від того, чи супроводжується воно дійсним переконанням.

Одненька брехня, яка вимагає захисту, може затягнути і перешкодити руху до раціональності. Це вам не жарти.

Світ значно сплутаніший, ніж здається, тому й існують і куди суворіші закони мислення, які обмежують віру більше, ніж може уявити невишколений. Світ тісно сплетений і підпорядкований загальним законам, як і *раціональні* переконання.

Подумайте, чого вимагало б заперечення еволюції чи геліоцентризму — усіх взаємопов'язаних істин та базових законів, знання яких вам довелося б відкидати. Тоді уявіть, як одненький випадок самоомани може перекрити весь метарівень пошуку істини, щойно ваш розум починає відчувати загрозу від спостереження зв'язків. Уявіть, що як заборонити всі проміжні та вищі рівні мистецтва раціональності і витворити величезний

комплекс антизаконів антимислення і загальних виправдань хибної віри.

Стівен Каас якось казав: «Заохочувати до недостатньо точних поглядів — шкідництво. Так роблять хіба що з тими, кому хочуть порізати шини». Нав'язувати людині хибні переконання *нібито задля її захисту* — переконувати її, що *саму цю віру* треба оберегати від будь-якої загрозової думки, — не варто, хіба що ви готові також зробити їй лоботомію.

Збрехавши раз, ви оголосили істину своїм ворогом і кожну пов'язану з нею істину і з усіма іншими. Щоб захистити свою брехню, ви маєте оборонятися від усіх правд. Неважливо — брешете ви собі чи іншим.

Тож спочатку треба заперечувати, що переконання вимагають свідчень. Потім — що мапа має відображати територію. А насамкінець відкидати, що правда — це благо...

Так і ступають на темну сторону.

Мене непокоїть, що люди не усвідомлюють цього, що вони недостатньо обережні, адже жити у світі людей — очікувати зустрічі із *систематично* кривою епістемологією.

Усі ці меми про «як думати», якими повниться стрічка соцмереж, по-мудрому мудрі думки на підкірці — якісь із них можуть виявитися слухними підказками, які колись запропонували раціоналісти. Але для оборони брехні придумали ще деякі способи, виплекані темною стороною.

«Кожен має право на свою думку». Яке походження у цього виразу, якщо задуматися? Його застосовують, коли боронять правду чи обороняються *від* неї? Люди не хапаються за голову зі словами «Хай йому! Відчуваю темну сторону!». Наскільки я можу говорити, не так багато людей усвідомлюють її присутність.

Але як інакше? Хай там кого ви обманюєте — себе чи когось, — брехня, яка вимагає захисту, рекурсивно поширюватиметься через мережу емпіричних причиново-наслідкових зв'язків, загальних емпіричних законів, а також законів мислення і розуміння цих законів. Якщо у світі є місце для *змістовної*

епістемології і брехні, яку люди силкуються захистити, тоді на противагу їй з'являється крива епістемологія. Усі ж знають, що до гараздів і лиху завжди прилаштується. Як є сонце, так і є те, що відсажується і породжує Тінь-покров.

Врахайте, що ці люди не обов'язково *лихі*. Більшість тих, хто не тямиться від повторень мудрої мудрості, більше ошукані, ніж лицемірять, більше самообманюються, ніж намагаються обманути когось. Я так думаю.

Звісно ж, я менше за все хочу, щоб ці міркування перетворилися на повністю загальний контраргумент, яким ви можете кинути в опонента, чия епістемологія не припала вам до душі: «Отако-о-ої, хтось став на темну сторону і жене химери». Один із законів світлої сторони: ви маєте спростувати саме судження, а не винувавчувати у лихих намірах того, хто його висунув.

Темна сторона десь поряд. Страх — шлях, що веде до неї, і достатньо однієї зради, щоб вона вас змінила. Не кожен, хто носить мантиї, — джедай чи пройдисвіт. Серед носіїв мантий водяться і лорди ситхів, майстри та несвідомі учні. Будьте обережними.

І про типові меми темної сторони епістемології (не випадкові хибні переконання, а саме крива епістемологія, загальна оборона невдач)... Доповніть список?

У боротьбі з дводумством

Дводумство, або Вибір на користь упередженості

У руках О'Браєна з'явилася довга газетна вирізка. У Вінстона було кілька секунд, щоб її роздивитися. Щодо цієї фотографії не було жодних сумнівів. Це була та сама фотографія. Це був ще один примірник фотографії Джонса, Ааронсона та Рудзерфорда на партійній зустрічі у Нью-Йорку, тієї самої, яка одинадцять років тому потрапила йому на очі і яку він відразу знищив. О'Браєн тримав її перед його очима лише якусь мить і відразу ж прибрав. Але він бачив її, він, безперечно, її бачив! Вінстон здійснив відчайдушну, болісну спробу поворушити верхньою частиною свого тіла. Проте він не міг зрушитися бодай на сантиметр. На мить він навіть забув про циферблат. Йому лише хотілося знову потримати ту світлину у своїх руках або принаймні ще раз побачити її.

— Вона існує! — вигукнув він.

— Ні, — сказав О'Браєн.

Він зупинився посеред кімнати.

У стіні напроти була діра пам'яті. О'Браєн підняв решітку. Невидимий потік теплого повітря підхопив тонкий

клапоть паперу, і він зник у спалаху полум'я. О'Браєн відвернувся від стіни.

— Попіл, — сказав він. — Навіть не попіл — порошок. Її немає. Її ніколи не було.

— Але ж вона була! Була! Вона існує у моїй пам'яті. Я пам'ятаю її! Ви пам'ятаєте її!

— Я її не пам'ятаю, — заперечив О'Браєн.

У Вінстона стислося серце. Це було дводумство. Його опанувало відчуття повної безпорадності. Це було б не так важливо, якби він був певен, що О'Браєн бреше. Але скидалося на те, що О'Браєн і справді забув про фотографію. А якщо так, то, можливо, він уже встиг забути й про свої заперечення, що він її пам'ятає, і забув про сам факт свого забування? Чи можна це вважати простим обманом? Можливо, й справді у свідомості можуть відбуватися такі божевільні маніпулювання? Ця думка остаточно збила його з пантелику.

— «1984», Джордж Орвелл

А що як завдяки самообману ми почуваємося щасливішими? А що як ми подолаємо упередження і — зітхає — станемо *нещасними*? Рішення — раціональність *другого порядку* — обирати, коли діяти раціонально. Так і визначимо — звісно, щоби примножити щастя, — який когнітивний біас має визначати наші вчинки.

Навіть якщо винести моральну сторону питання за дужки, дуже сумніваюся, що такий дикий виверт у голові взагалі можливий.

Під раціональністю другого порядку розуміється, що в якийсь момент у вашій голові вистрілить думка «А зараз, щоб мені було добре, я ірраціонально вірю, що виграю в лотерею». Та от біда: у нас немає безпосереднього контролю над

переконаваннями. Зусиллям волі ви не можете змусити себе повірити, що небо зелене. Можна повірити, що ви вірите у зелене небо. Але ви вже дізналися різницю, і повірити буде куди складніше. (Не дякуйте.) Можна навіть *повірити*, що зараз ви щасливі і самообманюєтеся (хоча *насправді* щасливими не почуваетесь, але самообманюєтеся).

Щоб по-справжньому діяти *раціонально* у межах раціональності другого порядку, вам спочатку потрібно сформулювати робочу модель реальності — інакше ви не зможете зекстраполювати наслідки раціональності та ірраціональності. А якщо ви потім змінили вибір на користь ірраціональності першого порядку, доведеться стерти з пам'яті цю точну модель. А потім забути акт стирання з пам'яті. Не хочеться припускатися логічної хиби і виводити узагальнення на основі вигаданих засвідчень, але, як на мене, Орвеллу вдалося показати, куди веде цей шлях.

Ви не знаєте наслідків упередженості, доки не усунете вплив упереджень. А потім самообман втратить сенс.

Або ще такий сценарій: можна робити сліпий вибір на користь упередженості і не думати про наслідки. А це вже свідомо дурість, а не раціональність другого порядку.

Проявіть ірраціональний оптимізм щодо своїх водійських навичок, і там, де буде спокійно вам, інші нервово пітнітимуть. А за оптимізмом можна і не завдати собі клопоту пристебнутися. Таке щастя може тривати день, тиждень, рік. Аж раптом — ДТП, і решту свого життя вам чухатиметься ампутована кінцівка. Або відніме все тіло нижче шиї. Або смерть. Не фаталізую — пишу, що таке може бути. Яка ймовірність такого наслідку? Свідомо піти на такий компроміс без *розуміння* своїх навичок водіння неможливо — інакше ви не вмієте адекватно оцінювати

небезпеку. Якщо ви не свідомі, скажімо, біасу відкидання ймовірності¹, ваше рішення піти на цей компроміс сліпе.

Хай скільки солодких днів ви проживете у невігластві, знадобиться одненька помилка, щоб віддати кінці і перекреслити кожену думку, якою ви багатіли до смерті.

Рационалістам, які роблять перші кроки на цьому шляху, я однією з перших даю пораду: «Не намагайся вдавати з себе розумника». За нею слідує друга — «Дослухайся до тихих дзижчливих сумнівів». Якщо ви не знаєте, то не знаєте, *чого* не знаєте, *скільки* не знаєте і *скільки потрібно* знати.

Забудьте про раціональність другого порядку. Стрибнути у казан з розпеченою лавою можна тільки наосліп. А коли *розплющите очі*, буде вже пізно.

Люди легковажно ставляться до власного незнання. Власне незнання недоступне. Замість того, щоб зосередитися на порожній частині мапи, вони вважають її порожньою територією. Приймаючи рішення стрибнути казна-куди, вони перевіряють, чи є у пам'яті інформація про небезпеки на порожній частині мапи, і ніякого казана з лавою там не знаходять. Чому б не стрибнути?

Стрибнув — потрапив у лаву — згорів. Ось і небезпека вдавати розумного.

Якось я балакав з подругою і сказав їй, що щастя від дурості сильно переоцінене. Вона покрутила головою із серйозним виразом: «Ні, зовсім ні».

Можливо, десь існують щасливі дурні. Можливо, вони щасливіші за вас. Життя, звісно, не справедливе, але ж і ви не станете щасливішими, заздрячи їм. Підозрюю: якби і намагалися, читачі блогу *Overcoming Bias* не змогли б щасливитися в дурості.

1. https://uk.wikipedia.org/wiki/%D0%92%D1%96%D0%B4%D0%BA%D0%B8%D0%B4%D0%B0%D0%BD%D0%BD%D1%8F_%D0%B9%D0%BC%D0%BE%D0%B2%D1%96%D1%80%D0%BD%D0%BE%D1%81%D1%82%D1%96

Ці двері зачинені. Вам уже не досягти того рівня дурості, за якого ви забудете свої знання і знебачите побачене.

Таке щастя не доступне для вас. Хіба що ваш мозок уразить травма чи якась хвороба. Та й то сумніваюся. Може, ви колись могли задуматися, чи щастя від дурості — якщо цей вид щастя *найбажаніший* з усіх — якоюсь мірою *оптимальне*. Та це вже не має значення. Ті двері для вас зачинені, якщо вони колись взагалі були відкритими.

Лишається прагнути того щастя, яке може здобути раціоналіст. Думаю, віддача від нього буде з лихвою. Можна дисципліновано йти стежками до обмежених цілей, а можна — у відкриті і безмежне. Можна йти рівниною без клопоту, а можна дертися на гору. І якщо на підйом потрібно більше зусиль, то гора все одно зрештою веде увись.

Та й самим щастям життя не обмежується. Наприклад, від ваших рішень може залежати щастя інших.

Але це вже не має значення. Перш ніж ви усвідомите свій вибір, у вас його вже не буде. Побачене не знебачити. Іншого шляху немає.

Серйозно: я дурила себе

Недавно розмовляв з однією пані, яка... як би це так описати... Формально вона була ортодоксальною єврейкою. Жінка надзвичайно розумна, свідомо археологічних знахідок, які свідчили проти її віри, та усіх тих поверхових аргументів проти релігії, які віряни вже вивчили напам'ять. До прикладу, вона знала, що про Мордехая, Естёр, Аман, Вашті¹ немає жодних згадок у перських літописах. Натомість була одна давня перська легенда про вавилонських богів Мардуга та Іштар, з якими конкурували еламські боги Хампан та Вашті. *Знаючи* це, вона досі святкує пурім.² Вона з тих надзвичайно розумних вірян, які роками пережують власні суперечності, нашаровують і підлаштовують їх, аж поки їхній розум не перетворюється на щось на кшталт внутрішнього лабіринту з гравюр Маврица Ешера.

Хоча значна частина таких людей вдає із себе мудрих настільки, що їм не до розмов з атеїстами, вона охоче поговорила зі мною кілька годин.

І завдяки цій розмові я трохи більше дізнався про самообман: поки ви *вірете*, що вже обманулися, вам не потрібно *насправді* обманюватися. Назвемо цей випадок «вірою в самообман».

Старшокласницею вона вважала себе атеїсткою. Якось вона вирішила, що має поводитися так, ніби вірить в Бога. І з часом — її слова були щирі — вона почала по-справжньому вірити в Бога.

Як на мене, вона помиляється. У нашій розмові вона постійно казала: «Я *вірю* в Бога», — але жодного разу: «Бог *існує*». Коли я спитався, чому вона досі тримається своєї віри, пані

1. Персонажі Старого Завіту. — Прим. пер.

2. Єврейське свято, під час якого вшановують пам'ять про порятунок євреїв, які жили в імперії Ахеменідів, від перського урядовця Амана. — Прим. пер.

навіть не торкнулася наслідків існування Бога — тільки наслідків віри в Нього. Ніколи — «Бог підтримає мене», раз у раз — «Моя віра в Бога підтримає мене». Коли я сказав їй: «Хто прагне істини і досліджує наш усесвіт, не став би вигадувати Бога навіть як гіпотезу», — вона повністю погодилася.

Пані так і не змусила себе повірити в існування Бога чи в істинність юдаїзму. Навіть не наблизилася до цього, наскільки я можу судити.

Разом з тим мені думається, що вона *дійсно* вірить у те, що дурить себе.

Отже, хоча вона не має вигоди від своєї віри в Бога, пані щиро *вірить*, що вона змусила себе повірити в Бога і тепер *очікує* вигод, які вона пов'язує із цим зусильним самообманом. У *цьому* випадку, припускаю, її віра в самообман чинить на неї той самий ефект плацебо, що і *справжня* віра в Бога.

Можливо, цим і пояснюється її мотивація щиро захищати своє судження про *віру* в Бога від моїх скептичних розпитувань, хоча вона і словом не обмовилася про існування Бога і не проявила жодного інтересу до цієї теми.

Віра в самообман

У попередньому есеї я згадував свою розмову із формально ортодоксальною юдейкою, яка затято відстоювала те, що вона вірить у Бога, хоча з її поведінки, здається, зовсім не виглядало, що вона у нього вірила.

Розпитавши її про переваги віри, я розповів пані про літанію Тарського — одну з сім'ї численних раціоналістських літаній, наприклад:

Якщо небо синє — Я вірю, що небо синє. Якщо небо не синє — Я вірю, що небо не синє.

— Це не про мене, — почув від неї.

— Я й не казав, що про тебе, — відповів. — Просто питаю: якщо припустити, що Бога *не* існує і всі про це знають, то що тобі з віри у нього?

Вона завагалася. Було схоже, що справді задумалася, чим здивувала мене.

— Отже, це умовне питання... — зважувала кожне слово.

На той момент я подумав, що через її прив'язаність до світу, в якому Бог існує, вона не могла дозволити собі виобразити світ без нього.

Тепер же я припускаю, що вона не могла уявити контраст між *світами*, в одному з яких Бог існує, а в іншому ні. Усі її міркування стосувалися власне *віри в Бога*, а от у причиновій мережі її моделі світу Бог не був ланкою, до якої кріпиться решта деталей. Тому вона могла легко відповісти на питання «Наскільки іншим був би світ, якби я не вірила в Бога?», а от питання «Наскільки іншим був би світ, якщо Бога не існує?» спантеличило її.

На той момент на друге питання вона не могла дати відповіді. Натомість пані явила мені *контрприклад* літанії Тарського:

— Я вірю, що в людях більше доброти, ніж є насправді.

Тоді я спробував пояснити, що твердження «Люди погані» означає, що вона вірить у те, що люди погані, а твердження «Я вірю, що люди добрі» означає, що вона вірить, що вірить у те,

що люди добрі. Тому казати «Люди погані, але я вірю, що люди добрі» означає вірити у те, що люди погані, але вірити у віру, що люди хороші.

У відповідь на її репліку процитував слова Людвіга Вітгенштайна:

— *Якби існувало дієслово зі значенням “хибно вважати”, то воно б не мало виправданої форми першої особи теперішнього часу.*¹

— Так, я вірю, що в людях більше доброти, ніж є насправді, — відповіла вона, усміхаючись. — Просто подумала, що краще так сформулювати.

«Я думаю, Бабуня має добряче набачитися тебе, Волтере, — сказала Тітуня. — Я думаю, твій розум зараз схожий на клубок ниток, з яким погралася кішка».

— «Маскарад», Террі Пратчетт²

«Мабуть, вона не вважала за потрібне бути послідовною у своїх міркуваннях», — думаю собі, але мені досі складно змиритися з цією думкою.

Я бачу структуру у її словах, але на рівні емпатії не можу збагнути, що стоїть за ними. Я можу уявити себе на місці іншопланетян, які їдять своє потомство, на місці Третьої леді Кіріцугу, але на місці тієї пані ніяк не можу.³

Чи просто не хочу?

Ось чому для розумних людей існує певне обмежене вікно часу (особистий час, витрачений на роздуми про релігію), у межах якого вони ще можуть стати атеїстами. І після того, як воно

1. Переклад «Філософських досліджень» Євгена Поповича. — Прим. пер.

2. Переклад Олександра Михельсона. Українськомовний переклад випустило Видавництво Старого Лева. — Прим. пер.

3. Іншопланетяни, які їдять своє потомство (baby-eating aliens) та Третя леді Кіріцугу (Lady 3rd Kiritsugu) — персонажі новели Елієзера Юдковскі *Three Worlds Collide* (<https://www.lesswrong.com/posts/HawFb7RvDM4RyoJ2d/three-worlds-collide-0-8>). — Прим. пер.

закривається, якщо ви розумний, витратили якийсь час на обмірковування своїх релігійних переконань та їхню оборону і при цьому не вирвалися із лещат темної сторони епістемології, вміст свого розуму зрештою стане схожим на картину Ешера.

(До речі, якщо це якось доповнить картину, в один із тих моментів вона задумалася про те, наскільки добре вірити, що когось не байдуже до моральності людських учинків. Звісно, про те, чи *існує* Бог, якому не байдуже до моралі, *не* йшлося. Останнє твердження не входить до її релігії.

На це я відповів: «*Мені не байдуже. Ти кажеш, що цього замало і не можеш не вірити у щось надлюдське, якому не байдуже до моральності твоїх учинків*». Мої слова заскочили її розгубленою — з такого боку вона про це не думала. А я просто знайшов стандартне застосування нестандартному набору інструментів⁴.)

Уже пізніше якось я запитав її, чи було б доцільно бодай *щось* робити інакше, якби Бога достеменно не існувало. Цього разу вона відповіла:

— Ні.

— Отже, — я налаштував свій скепсис, — існування Бога жодним чином не впливає на те, як людям належить поводитися і думати? Навіть рабин скося подивився б на того, хто наважиться промовити таке вголос.

Тепер її релігія виглядає як *суцільне* поклоніння перед поклонництвом. Як справжні віряни старозавітних часів вірили у порятунок всевидячим батьком, так і вона вірить у віру у порятунок Божий.

Після тих слів, що вона вірить у доброту людей більше, ніж виправдано вірити, я спитався:

— Як часто ти дивиєшся, коли люди не дотягують до твоїх очікувань?

Вона довго мовчала. А потім ніби вичавлювала з себе по слову:

— Чи... *здивована*, коли люди... не дотягують до моїх очікувань?

4. <https://www.overcomingbias.com/2007/10/how-to-seem-and.html>

Я вагався, як мені тлумачити цю павзу. Вже був хотів сказати: якщо реальність раз у раз засмучувала її, то це такий недолік хибної віри. Натомість, здавалося, її приголомшили наслідки *відсутності* здивування.

Тепер я бачу, що весь її світогляд зводився до *віри в самообман*, і сама можливість, що її справжні уявлення про інших *не такі вже хибні*, загрожувала темній стороні її епістемологічного процесу, якою вона огорнула переконання на кшталт «Я виграю від віри в те, що люди добріші, ніж вони є насправді».

Скинувши старого боввана з капища, вона стала поклонятися темній стороні епістемології, яку вона витворила, щоб захистити того боввана; тепер же вона возвеличує власні спроби самообману. Спроба провалилася, і вона щиро не усвідомлює провалу.

І тепер символічні вартості людського розуму (з ефектним мотто «У сраці маєм ваші байки з часів Епікура» на вустах) мають виходити на прю з поклонінням самообману і *гаданим перевагам* віри в Бога без Бога.

Завдяки цьому випадку я дещо дізнався і про *себе*, чого раніше не розумів: мене вкурвлюють слова про те, що самообманюватися буцімто *легко*. Так і з'явилися дописи у блозі про те, що свідомо змусити себе повірити в зелене небо набагато складніше, ніж здається.

Річ у тім, що, хоч ви й *не можете* просто взяти і повірити у зелене небо, якщо не *усвідомлюєте* цього самообману, то обдурити себе, вважаючи, що вам це вдалося, таки *під силу*.

А потім щиро *очікуючи* мати зиск з нібито несправжнього самообману, ви отримуєте той самий плацебний зиск, який мали б і з неудаваного самообману.

Тож, розказуючи, як *важко* самообманюватися, я пишу про свого роду плацебо, яке люди отримують від віри у свій самообман, та новий тип релігії, яка побожно схиляється перед поклонінням як таким.

Цікаво: чи породить ця дискусія новий перелік причин, чому не віра, а віра у віру *як така* становить цінність? Що то за

користь, яку люди отримують від поклоніння поклонництву?

Чи не переросте ця тенденція у віру у віру у віру чи поклоніння поклонінню поклонництву? Чи розумні теїсти перестануть врешті тягнути аргументи з цієї скриньки?

Хотілося б думати, що ні в кого не вийде вірити у віру у віру у віру, проте філософська суперечка про світ зомбі⁵ стала ще заплутанішою, і її пропоненти так і не відмовилися від неї.

Уже уявляю, як хтось палко вистукує по клавіатурі, пишучи коментар на захист віри у віру. Але от цікаво: хтось зіграє на випередження і перейде одразу до захисту віри у віру у віру? Може, варто нарешті покінчити з цим і рухатися далі.

5. <https://www.lesswrong.com/posts/fdEWWr8St59bXLbQr/zombies-zombies>

Парадокс Мура

Читаючи деяких коментаторів на *LessWrong*, я став краще розуміти парадокс Мура. Наприклад, коментатор Джимрендом (Jimrandomh¹) пише:

«Багато людей не розрізняють рівнів опосередкування. Для них "я вірю в X" і власне "X" — на один манір, і тому підстави вважати віру в X корисною вони трактують як підстави істинності X».

Не зовсім. Відносно малі діти розуміють, що таке хибне переконання, а це вміння вимагає окремих ментальних комор для мапи й території.

Ця думка вказує на схожу ідею.

Багато хто може не усвідомлювати різниці між *вірою* та *схваленням*.

Зрештою, у повсякденному мовленні твердження «я вірю в демократію» означає, що ви схвалюєте концепт демократії, а не вірите, що демократія існує. Та й саме слово «віра» має більше одного значення. Можливо, ми маємо справу із плутаним словом, що веде до плутанини в думках (або ж відображає вже наявну плутанину).

В есеї «Віра в самообман» я писав про жінку, яка трималася переконання «Я вірю, що в людях більше доброти, ніж є насправді». Вона вигадала, чому було б добре вірити у людську доброту — мовляв, так краще для ментального здоров'я, — і після теплового емоційного відчуття до «віри в людську доброту» вона зазирнула всередину і вирішила: «Я вірю, що люди добрі». Тобто пані сплутала *позитивний афект* від згаданого переконання із *власною вірою у це твердження*. Світ давав їй знати, що люди

1. <https://www.lesswrong.com/posts/rZX4WuufAPbN6wQTv/no-really-i-ve-deceived-myself#29ZzA5pgsgfmsqwCH>

не такі вже й добрі. Але вона все повторювала: «Я вірю, що в людях більше доброти, ніж є насправді».

І цей випадок дуже близький до щирої, незумисної помилки. А виникла вона, бо людей не навчають помічати свої сформовані переконання. Як у притчі про дракона в гаражі: хто каже «У моєму гаражі живе дракон. Але він невидимий», не усвідомлює, що його *очікування* (не побачити дракона) свідчить про відсутність дракона в його (точній) моделі реальності.

Люди не помічають, як формують переконання. У старшій школі не *навчають* підходити до цього процесу усвідомлено: «Насправді вірити у щось — зберігати твердження у власному реєстрі переконань — означає мати уявлення, що світ *саме так і влаштовано*. Відчуття наявності отакого уявлення, що і є власне переконанням, варто навчитися відрізняти від відчуття комфорту від переконання, яке може розпізнаватися як “переконання”».

І ось я можу плавно перейти до життєвого випадку парадокса Мура і продемонструвати ще один механізм того, як люди можуть одночасно мати рацію і не мати.

От коментатор під нікнеймом Куріге (Kurige²) пише:

«Я вірю в існування Бога і в те, що він дарував людям здатність відрізняти добро від зла, і це мірило дозволяє нам оцінювати світ навколо. Крім того, я вірю, що в нас еволюційно закодоване відчуття моралі, спричинене, я впевнений, прадавнім формуванням метаполітичних об'єднань у племенах мавп бонобо».

Підозрюю: Куріге, ти вирішив, ніби маєш *підстави схвалити* наведене переконання про те, що Бог наділив нас відчуттям добра і зла. І так само вирішив, що маєш підстави схвалити вердикт науки. Тож обидві спільноти виглядають привабливими, еге ж? В обидвох системах переконань є свої вигоди, так? Ти

2. <https://www.lesswrong.com/posts/rZX4WuufAPbN6wQTv/no-really-i-ve-deceived-myself#9ShudmvmEfYwqyeBt>

заглядаєш всередину, й обидві позиції дають тобі відчуття комфорту?

Але ти *не* написав:

«Бог наділив нас відчуттям відрізняти добро від зла, а ще в нас еволюційно закодоване відчуття моралі. Тому ці два стани реальності не суперечать одне одному, хоча узгодити їх — ще та морока».

Якщо ти читаєш це, Куріге, швидко вимов уголос написане вище, щоб ти помітив, що його вже трохи важче перетравити — відчуй *суб'єктивну різницю*, — перш ніж ти знову вшелепкаєшся у раціоналізацію.

У цьому і полягає суб'єктивна різниця між наявністю підстав схвалювати два різні переконання і ментальною моделлю єдиного світу — єдиного стану речей.

Досі вірите, що зможете удавано самообманюватися?

Не хочу, щоб мої міркування виглядали, ніби я чіпляюся до бідолахи Куріре. Але як учасники спільноти *LessWrong* ви маєте очікувати, що вам ставитимуть питання, коли, наприклад, пишете¹:

«Я усвідомив один важливий нюанс, який допомагає пояснити різницю, що я її відчуваю, спілкуючись з лівовою часткою християн. Мій теперішній світогляд суттєво відрізняється від сліпої віри і нагадує орвеллівське дводумство».

Так і хочеться відповісти: «Якщо ти усвідомив присутність дводумства...

... то чому ж іще не відмовився від віри?».

Або ще такий коментар:

«Я обрав вірити в існування Бога — така моя свідомая воля. Це рішення жодним чином не змінює того, чи існує Він насправді».

Якщо ти *знаєш*, що твоє переконання не стосується реальності, то навіщо ти досі тримаєш його у голові?

Люди, хіба після *інтуїтивного* усвідомлення «Моя мапа, згідно з якою небо зелене, не має жодного стосунку до реальності» у вас не клацає у голові: «Заждіть, а небо таки *не* зелене?»

Бачу, що не клацає...

Частково ця проблема може бути спричинена, як я уже пояснював, парадоксом М'юра («За вікном іде дощ, але я в це не вірю»): внаслідок самоаналізу люди плутають тепле відчуття від «переконання» з власне переконанням.

1. <https://www.lesswrong.com/posts/rZX4WuufAPbN6wQTv/no-really-i-ve-deceived-myself#9ShudmvmEfYwqyeBt>

Інше пояснення: попри обурення, яке крутиться у мене на кінчику язика, насправді не перейти від «На мапі, що відображає територію, зазначено Х» до власне віри в Х напрочуд *легко*. Усвідомлення ідеї розуму як картографа не падає з неба, і навіть якщо ви схопили її на концептуальному рівні, для розуміння наслідків *на рівні нутра* потрібно докласти ще більше зусиль.

Тепер я розумію, що коли писав: «Самим зусиллям волі ви не можете змусити себе повірити, що небо зелене», я не тільки нейтрально констатував стан речей, а й прагнув навіяти самозбувне пророцтво.

А може, свідомо повторювати собі: «Я знаю: дводумство не уживеться у моїй голові. Що глибше копаю, то менше вірю. Якщо мапа моя не віддзеркалює території, я не вірю їй» — не така вже й погана ідея.

Адже у такому випадку — якщо ви колись піддастесь спокусі вшелепкатися у дводумство — думки «Але ж я знаю, що це не так» та «Не брехатиму ж я собі» вчасно виринатимуть у свідомості й не дадуть самообману вкорінитися. І тоді ви на рівні нутра зрозумієте, що говорити про Х не означає зробити Х (і, відповідно, не-Х) істинним.

Якщо повторювати собі, що *не можна* просто взяти й повірити у зеленість неба, обвести себе навколо пальця буде вже не так легко. І не важливо — повірили ви у свою брехню не удавано, піддалися парадоксу Мура, повірили у віру чи спробували удавано повірити у самообман.

Якщо повторювати собі, що глибоко всередині ви знаєте, якщо повторювати собі, що уже від першого погляду на вигадливу хибну мапу видно, що вона не відображає дійсну територію, тому хай яка вишукана і ретельно накреслена, вона не заслуговує і йоти вашої віри,

якщо повторювати собі, що епістемічна узгодженість рано чи пізно візьме гору і не дасть повірити в Х на рівні об'єкта (момент метаусвідомлення, що мапа хибує), —

тоді ймовірність піддатися самообману і справді зменшиться.

Щоб навмисно обдуритися, треба *вірити у власну нездатність зробити це!*

Переконайте себе, що зусилля приречені — *і так воно й буде!*

І в цьому сила славнозвісного позитивного мислення? Позитивне чи негативне — я вас попередив.

Свіжим поглядом

Якорування і коригування

Я розкручую колесо фортуни, воно зупиняється на числі 65. А потім питаю: «На вашу думку, відсоток країн Африки серед країн-членів ООН вищий чи нижчий за це число? Який відсоток країн Африки серед країн-членів ООН?» Подумайте трохи над цими двома питаннями і, коли ваша ласка, не підглядайте у гугл.

А тепер *за п'ять секунд* спробуйте оцінити значення наступного арифметичного виразу. П'ять секунд. Готові? На старт... *Пуш!*

$$1 \times 2 \times 3 \times 4 \times 5 \times 6 \times 7 \times 8$$

Тверські й Канеман фіксували оцінки учасників експерименту, які перед цим бачили, як «колесо фортуни» зупиняється на різних числах.¹ Медіанна оцінка тих, кому випало 65, становила 45%, тоді як для тих, кому випало 10, — 25%.

Згідно з робочою теорією, яка пояснює цей експеримент та подібні, учасники відштовхуються від початкового випадкового числа — *прив'язуються* до нього, — а потім *підлаштовують* (збільшують або зменшують) те число, щоб воно «виглядало правдоподібно». Через такий підхід люди не відходять від якоря надто далеко: хоча більш віддалені числа теж можуть бути «правдоподібними», зупиняються саме на першій задовільній відповіді.

Так само медіанна оцінка студентів, яким показували вираз « $1 \times 2 \times 3 \times 4 \times 5 \times 6 \times 7 \times 8$ », становила 512, тоді як для виразу « $8 \times 7 \times 6 \times 5 \times 4 \times 3 \times 2 \times 1$ » — 2 250. Робоча гіпотеза: студенти намагаються перемножити (або приблизно скомбінувати) перші множники, а потім коригуватимуть оцінку в бік збільшення. В обох випадках ці коригування і близько не стоять до

1. Amos Tversky and Daniel Kahneman, "Judgment Under Uncertainty: Heuristics and Biases," *Science* 185, no. 4157 (1974): 1124–1131.

правильного добутку — 40 320, — причому перший набір здогадок через нижчі числа ще хибніший.

У дослідженні Тверські й Канеман пишуть, що винагорода за точність не зменшує впливу ефекту якорування.

В іншому дослідженні Фриц Страк та Томас Массвайлер запитали, у якому році Айнштайн відвідав США.² Як виявилось, далекі від реальності якорі (1215 чи 1992) спричиняють не менший за впливом ефект за більш правдоподібні (1905 чи 1939).

Домовленість про зарплату чи покупка машини — тільки найочевидніші приклади цього ефекту, які трапляються у повсякденні. Користуватися ним не пропоную — лише попереджаю, що на них можна попастися.

І стежте за своїм мисленням. Намагайтеся помічати ті моменти, коли при пошуку оцінки ви *підганяєте* число.

Загалом, методи усунення ефекту якорування виявилися малоефективними. Можу хіба що дати дві поради. По-перше, якщо початкове припущення звучить неправдоподібно, спробуйте відкинути його і порахувати ще раз без опори на якір. Проте і цього може виявитися недостатньо: навіть коли учасників просять не прив'язуватися до якоря, вони все одно, схоже, до нього вдаються.³ По-друге, навіть якщо ви пробуєте перший метод, розверніть якір у протилежний бік — наприклад, замалий якір замість великого або зavelикий замість малого — і ненадовго зупиніться на ньому.

2. Fritz Strack and Thomas Mussweiler, "Explaining the Enigmatic Anchoring Effect: Mechanisms of Selective Accessibility," *Journal of Personality and Social Psychology* 73, no. 3 (1997): 437–446.

3. George A. Quattrone et al., "Explorations in Anchoring: The Effects of Prior Range, Anchor Extremity, and Suggestive Hints" (Unpublished manuscript, Stanford University, 1981).

Праймінг та інформаційне забруднення

А тепер попросимо піддослідних натиснути одну кнопку, коли вони бачать слово, а коли перед ними безглуздий набір літер, натиснути іншу (наприклад, «банер» і «банак»). Потім ви покажете їм послідовність літер «вода» — вони швидше розпізнають послідовність «пити» як слово. Це явище відоме як «когнітивний праймінг», а саме цей випадок можна назвати «семантичним, або концептуальним, праймінгом».

Вражає те, що праймінг відбувається на такому низькому рівні: він пришвидшує *розпізнавання* літер як слова, що, як можна очікувати, відбувається *ще до* осмислення значення слова.

Крім того, це явище дозволяє зрозуміти, як мозок водночас активує декілька взаємопов'язаних слів: слово «вода» веде до слова «пити», а також — слів «річка», «чашка» або «бризки»... Така активація поширюється від семантичних зв'язків між поняттями аж до розпізнавання послідовності літер.

Праймінг — це позасвідомий та неспинний артефакт людської нейронної структури. Намагатися уникати праймінгу — що пробувати зупинити активність власної нейронної мережі.

Можете і собі провести такий експеримент: на каталогових картках напишіть назви кольорів різнобарвними олівцями, наприклад: слово «зелений» червоним, «жовтий» синім і в такому дусі. А потім уголос вимовляйте саме колір, яким написано слово.

Під час іншого експерименту Томас Массвайлер та Фриц Страк поставили піддослідним якорувальне питання «Річна середня температура у Німеччині вища чи нижча за 5°C/20°C?».¹ Опісля на завданні з розпізнавання слів респонденти, яким

1. Thomas Mussweiler and Fritz Strack, "Comparing Is Believing: A Selective Accessibility Model of Judgmental Anchoring," *European Review of Social Psychology* 10 (1 1999): 135–167.

ставили питання про п'ять градусів, швидше розпізнавали слова «холодний» та «сніг», тоді як піддослідні, яким дали більший якір, — слова «спекотний» та «сонце». Тобто результати свідчать про можливість якорування без коригування — себто праймінг суміжних думок та спогадів.

З усіх цих експериментів можна вивести загальніший висновок: *повністю беззмістовна і від початку хибна чи зовсім не до речна* «інформація» може впливати на ваші оцінки та рішення. У контексті евристик та біасів це ширше явище відоме як *забруднення*.²

Ефекти якорування фіксували ще за ранніх досліджень евристик та біасів, наприклад: респонденти називали нижчий (чи вищий) відсоток країн Африки в ООН залежно від першого питання, чи цей відсоток вищий чи нижчий за 10 (чи 65). Спочатку цей ефект пояснювали тим, що учасники відштовхуються від якоря як від початкового значення, коригують оцінку і зупиняються, щойно вона здається правдоподібною, недокориговуючи її, оскільки зупиняються на межі довірчого інтервалу.³

У деяких обставинах ранню гіпотезу Тверского та Канемана можна досі вважати коректним поясненням, особливо для випадків, коли респонденти дають оцінку самостійно. А от сучасні дослідження більше вказують на те, що більшість випадків якорування спричинена не поступовим коригуванням, а забрудненням.⁴

У магазині неподалік точно мають бути ці дратівливі оголошення штибу «До 12 товарів в одні руки» або «Купуй 5 за 10». Думаєте, вони не виконують своєї функції — підмовляти до

2. Gretchen B. Chapman and Eric J. Johnson, "Incorporating the Irrelevant: Anchors in Judgments of Belief and Value," in *Heuristics and Biases*, ed. Thomas Gilovich, Dale Griffin, and Daniel Kahneman (New York: Cambridge University Press, 2002), 120–138.

3. Tversky and Kahneman, "Judgment Under Uncertainty."

4. Nicholas Epley and Thomas Gilovich, "Putting Adjustment Back in the Anchoring and Adjustment Heuristic: Differential Processing of Self-Generated and Experimentor-Provided Anchors," *Psychological Science* 12 (5 2001): 391–396.

зайвих покупок? Думаєте, на вас такі трюки не діють⁵? На *когось* точно діють, бо вивіски таки виконують свою роботу. Не для краси ж вони там висять.⁶

А найстрашніше якраз те, що інформаційне забруднення — одне з тисячі облич підтверджувального упередження.⁷ Щойно якась ідея закрадається вам у голову, вона активує сумісну з нею інформацію, чим сильніше вкорінюється у розумі. Забудьте про тиск добору у боротьбі за перемогу у політичних суперечках — підтверджувальне упередження і без того глибоко вкорінене у наш когнітивний апарат: асоціативні мережі підсилюють сумісні думки й спогади. Такий собі прикрий побічний ефект нашого буття як нейронних істот.

Для розпізнавання слів, пов'язаних асоціаціями, може вистачити одного погляду на зображення. Для підтверджувального упередження більшого й не треба. Мить — і нижній рядок уже сформовано, адже ми змінюємо свою думку рідше, ніж здається...

5. https://uk.wikipedia.org/wiki/%D0%A1%D0%BB%D1%96%D0%BF%D0%B0_%D0%BF%D0%BB%D1%8F%D0%BC%D0%B0_%D1%83%D0%BF%D0%B5%D1%80%D0%B5%D0%B4%D0%B6%D0%B5%D0%BD%D1%8C

6. Brian Wansink, Robert J. Kent, and Stephen J. Hoch, "An Anchoring and Adjustment Model of Purchase Quantity Decisions," *Journal of Marketing Research* 35, no. 1 (1998): 71–81, <https://www.jstor.org/stable/3151931>.

7. Див. есеї «Третя альтернатива», «Як знання про біаси може нашкодити», «Один аргумент проти армії», «Які засвідчення рахуються за відфільтровані?» та «Рационалізація». А також — «Ретроспектива знецінює науку», «Вигадана причиновість» та «Упередження позитивного: зазирнути в темряву» у книзі «Мапа і територія». — Прим. авт.

Чи завжди ми віримо сказаному?

У раних експериментах з якорування та коригування досліджували, чи *зростання когнітивного навантаження* (наприклад, пошук числа 5 у послідовності) зменшує коригування та посилює вплив якорів. Результати більшості експериментів підтверджують, що когнітивна навантаженість посилює якорування і забруднення у більш загальному сенсі.

Аналізуючи чимраз більшу базу свідчень інформаційного забруднення, підсиленого когнітивного навантаження, Деніел Гілберт помітив химерну тенденцію і поставив собі питання: «Чи завжди ми віримо сказаному?».

Цілком природним здається, що, почувши від когось якесь твердження, ми спочатку *розуміємо* його сенс, потім *обмірковуємо* його зміст і лише після цього *приймаємо* або *відхиляємо*. Саме такою уявляли собі модель процесу мислення за часів Декарта. Але Спіноза, заперечуючи Декарту, вважав, що спершу ми *пасивно приймаємо твердження в процесі його розуміння*, а вже потім *активно відкидаємо* ті з них, що не витримують обмірковування.

Протягом кількох останніх століть філософи в принципі погоджувалися з Декартом, адже (ну, знаєте) звучить логічно та інтуїтивно.¹ Поки Гілберт не знайшов експериментальний спосіб протестувати гіпотези Декарта та Спінози.

Якщо правий Декарт, то відволікання заважатиме як прийняттю істинних тверджень, так і відхиленню хибних. Якщо правий Спіноза, то через відволікання вони мають запам'ятати хибні твердження як істинні, але не навпаки.

У своєму дослідженні Деніел Гілберт, Дуглас Кралл та Патрік Мелбун підтвердили, що відволікання не впливало на розпізнавання нових тверджень, позначених як істинні (55%

1. Див.: Robin Hanson, "Policy Tug-O-War," *Overcoming Bias* (blog), 2007, https://www.overcomingbias.com/2007/05/policy_tugowar.html. — Прим. авт.

успішних відповідей без відволікання проти 58% із відволіканням), але погіршувало розпізнавання нових тверджень, позначених як хибні (55% без відволікання проти 35% із відволіканням).²

У подальших експериментах Деніел Гілберт, Ромін Тафероді та Патрік Мелоун просунулися ще далі.³ Піддослідні вголос читали з екранів твердження, позначені кольором як істинні або **хибні**. Частина протоколів містила **хибні** твердження, що перебільшували тяжкість злочину, інша частина — **хибні** твердження, що пом'якшували (виправдовували) злочин. Крім того, деякі респонденти, поки читали протоколи, мали дивитися на рядок цифр і шукати цифру 5. Метою завдання з відволікання було створення когнітивного навантаження. Насамкінець учасники експерименту мали визначити, на який термін (від 0 до 20 років) слід ув'язнити злочинця, з протоколом якого вони ознайомилися.

Піддослідні, в стані когнітивного навантаження, рекомендували ув'язнити злочинців на 11,15 року, якщо протокол містив «перебільшені» **хибні** твердження про тяжкість злочину. Якщо протокол містив **виправдовувальні** **хибні** твердження, навантажені піддослідні рекомендували у середньому 5,83 року в'язниці. Як ви могли здогадатися, ця майже двократна різниця є статистично значущою.

Ненавантажені учасники читали ті самі протоколи з **виділеними** **хибними** та істинними твердженнями, а також той самий рядок цифр, але без завдання знайти цифру 5. Тому вони могли більше уваги приділяти відкиданню тверджень, **позначених як** **хибні**. Вони рекомендували 7,03 року для злочинців з -

2. Daniel T. Gilbert, Douglas S. Krull, and Patrick S. Malone, "Unbelieving the Unbelievable: Some Problems in the Rejection of False Information," *Journal of Personality and Social Psychology* 59 (4 1990): 601–613.

3. Daniel T. Gilbert, Romin W. Tafari, and Patrick S. Malone, "You Can't Not Believe Everything You Read," *Journal of Personality and Social Psychology* 65 (2 1993): 221–233.

перебільшеними в протоколах злочинами та 6,03 року для тих, чий злочини хибно виправдовували.

Їхня стаття називалася «Ви не можете не вірити усьому прочитаному».

З цього можна зробити висновок, що ненадійну інформацію слід сприймати обережніше, особливо коли ми займаємося чимось паралельно. Тому, читаючи газету у супермаркеті, не втрачайте пильності.

P.S. За непідтвердженими чутками, які щойно спали мені на думку, через розмаїття відволікальних кольорів люди читатимуть цей есей з меншим скепсисом.

Закешовані думки

Чи не найбільша загадка людського мозку полягає в тому, як така система *взагалі* працює, коли нейрони у ній загоряються 10-20 разів за секунду або з частотою до 200 Гц. У нейронах діє «правило ста кроків»: будь-яка гіпотетична операція має завершуватися *не більш ніж* за сто послідовних кроків. Допускається скільки завгодно паралельних процесів, однак не варто припускати, що мозок зможе впоратися з операцією, яка потребує понад сто (а бажано й менше) послідовних активацій нейронів.

Чи можете ви уявити програмування на процесорах із частотою 100 Гц, хоч би скільки їх у вас було? Щоб узагалі *хоча б щось* робити у реальному часі, знадобиться близько ста мільярдів процесорів.

Якби вам довелося писати програми для ста мільярдів процесорів із тактовою частотою 100 Гц, ви б використовували можливості кешування по максимуму. Кешуванням називають технологію, яка дозволяє зберігати результати попередніх операцій, щоб використовувати їх у майбутньому замість того, щоб обчислювати заново. Ця метафора досить точно відображає процеси, що відбуваються в *нейронній* системі, а саме: розпізнавання, асоціювання та формування рамок.

Можна сказати, що *більша* частина людського мислення працює за принципом пошуку у кеші.

Іноді мені таке спадає на думку.

Була така напрочуд хрестоматійна історія, яку, я думав, зберіг собі, але потім не зміг віднайти джерело. Значить, був собі чоловік, а в нього — сусід — майстер на всі руки. І от якось той сусід, між іншим, розказав, що для знесення димоходу потрібно спочатку вибити камін, зачекати, поки вся цегла звалиться на один рівень, вибити її і повторити процедуру, доки димохід не обвалиться. Через багато років, коли чоловік надумав зносити димохід, він згадав ту давню розмову з сусідом...

Згодом чоловік зрозумів, що порада сусіда була не дуже вдаю. Виявилось, що сусід був некомпетентний у питаннях знесення димоходів, тому його слова не заслуговували на довіру. Якби ж то він *поставив* ту пораду *під сумнів*, можливо, він би зрозумів, що вона далека від слушної. Деякі записи у кеші все-таки краще переосмислити. Однак мозок схильний автоматично підганяти думки під звичні рамки. Тому, якщо ви не усвідомите, що рамка потребує корекції, залишитеся з тими ж старими не-ефективними налаштуваннями.

Підозрюю: якби ця думка навідала чоловіка — він *сам* дійшов думки, як знести димохід, — то краще обдумав би її. Але якщо хтось вже подумав *за вас*, ви можете заощадити обчислювальні ресурси, просто зберігши *результат*. Це ж так зручно!

Живучи у сучасній цивілізації, ви не можете думати настільки швидко, щоб знаходити час для особистих думок. Якби мене немовлятом лишили у лісі на виховання вовків чи німих роботів, навряд чи мене можна було б назвати людиною. Нікому не під силу думати настільки швидко, щоб за одне життя самотужки перевірити всю мудрість племені мисливців-збирачів. Про мудрість письменної цивілізації можете забути.

Але є й інша сторона медалі: прагнення до критичного мислення може обернутися простим повторенням чужих закешованих думок, народжених не в головах самостійних мислителів.

Класичний приклад — скептик, який погоджується з твердженням «Релігію неможливо довести або спростувати свідченнями». Як я вже писав в одному з есеїв,¹ воно не витримує критики теорії ймовірностей. І щодо реальних психологічних механізмів релігії, це також є помилковим твердженням. Адже кілька століть тому, якби хтось наважився публічно висловити подібну думку, його б, швидше за все, спалили на вогнищі. Мати, чия донька хвора на рак, звертається до Бога з молитвою: «Господи Милосердний, благаю: зціли мою доньку» — замість того, щоб думати: «Господи, я розумію, що релігії не мають перевірюваних

1. Див. «Релігійні твердження та їхня неспростовність» у книзі «Мапа і територія». — Прим. авт.

чи спростовуваних наслідків, тому Ти не зможеш зцілити мою доньку, тому... по суті, я молюся, щоб мені стало легше, замість того, щоб по-справжньому допомогти їй».

Але люди спочатку бачать «Релігію неможливо довести або спростувати свідченнями», а потім, коли такі натрапляють на спростувальне свідчення, їхній мозок автоматично видає це твердження. Навіть деякі атеїсти без задньої думки повторюють цю маячню. Якби ж вони самі дійшли до цього, а не просто почули від когось іншого, вони б, імовірно, піддали її більш ретельному аналізу та сумніву.

Візьмімо, до прикладу, смерть. Такий шаблон: «Смерть наділяє життя сенсом».

Коли у розмові з добрими й порядними людьми — їм і за тисячу років *не спаде на думку* стерти людство з лиця землі — я зачіпаю тему екзистенційного ризику, мені дуже прикро чути від них щось на кшталт «Можливо, люди не заслуговують на виживання». Ніколи за життя вони б не направили зброю на свою дитину, яка є частиною людства, але мозок уже підставив шаблон.

Які ще шаблони обжилися у вашій голові, яких ви не хотіли б там бачити?

Перейдімо до раціональності. Шаблон «Любов ірраціональна».

Якщо у вашій голові з'являється ця свіжа і незалежна думка, як би ви її аналізували? Я знаю, що скажу я, але питання у тому, що скажете *ви*. Буває дуже непросто подивитися на ідеї свіжим поглядом. Постарайтеся не дати розуму непомітно для вас підставити шаблон. Можливо, кращої відповіді за шаблонну і немає, проте, якщо не зупинятимете себе на автоматичних відповідях, не почнете *задумуватися*.

Відтепер, коли чутимете, як хтось бездумно повторює якийсь, як на вас, безглуздий чи дурний мем, згадуватимете про закешовані думки. Моє переконання уже поселилося у вашій голові й чекає свого часу, коли можна буде підігнати якусь

ситуацію під сформоване лекало. Але чи істинне це переконання? Не дозволяйте розуму підставляти шаблони! *Думайте!*

Свіжий погляд

Цю думку вдало висловив Роберт Пірсіг — я просто процитую його. Не знаю, чи має ця історія якийсь стосунок до реальності, але так чи інакше вона правдива.

«Йому важко давалися учні, яким не було чого сказати. На початках Роберт брав це за лінощі, проте з часом ставало зрозуміло, що їм просто нічого не спадало на думку.

Одна його учениця — дівчина, яка носила окуляри з товстими лінзами, — хотіла написати есей про Сполучені Штати Америки на п'ятсот слів. Звиклий до того, що від таких заяв у нього падає настрій, він без зневаги запропонував обмежитися Бозменом — містечком у штаті Монтана.

Коли прийшов час здавати роботи, вона так і не написала ні слова, що дуже засмутило її. У спробах вичавити з себе бодай щось дівчина так і не спромоглася знайти слова.

Тепер йому відібрало мову. І от після довгої тиші Роберт видає: “Обмежся *центральною вулицею* Бозмена”.

Дівчина слухняно кивнула і вийшла з класу. Перед наступним уроком вона повернулася вся в сльозах — по ній було видно, що бідося промучилася декілька годин (чи навіть днів). Вона так і не спромоглася написати бодай щось і не могла зрозуміти чому: як не має що сказати про містечко, то мала хоча б знайти якісь слова про одненьку вулицю.

Роберт почав гніватися: “Ти не *дивишся!*”. На нього наринували спогади, коли його відрахували з університету за те, що він *завжди мав що* сказати про будь-що. Адже для кожної події можна висунути *нескінченну кількість*

гіпотез. Що довше *дивишся*, то більше *бачиш*. Його учениця не дивилася і чомусь не розуміла цього.

“То обмежся *фасадом одного* з будинків на головній вулиці Бозмена, — подивився він на неї грізно. — Оперний театр. Почни з верхньої цеглини від лівої руки”.

Він бачив, як її очі за товстими лінзами наливалися світлом.

Наступного разу вона зайшла у клас зі здивуванням на обличчі й поклала перед учителем есей на п'ять тисяч слів про фасад оперного театру, що на головній вулиці міста Бозмен, штат Монтана. “Я сіла у бургерній навпроти театру, — почала вона, — і взялася писати про першу цеглину, так перейшла до другої, третьої, а потім вже не могла зупинитися. Люди були вже подумали, що я збожеволіла, сміялися з мене, але ось — я закінчила. Як таке взагалі можливо?”.

Та Роберт сам не знав. Гуляючи вулицями містечка, він все думав про цей випадок і дійшов до того, що дівчина подолала ту саму заваду, на яку він був натрапив у перший день викладання. Вона не могла розписатися, бо тільки знай повторювала те, що вже чула від когось, як і він у свій перший день повторював те, що колись вирішив був розказати. Вона не могла придумати, що написати про Бозмен, тому що не могла дістати з пам'яті щось варте повторювання. Дивно, але вона не усвідомлювала, що, пишучи, вона може сама побачити усе по-новому, не озираючись на те, що вже було сказано. Звуживши увагу до однієї цеглини, вона зруйнувала блок — стало очевидно, що їй *доведеться* подивитися на все самій, свіжим поглядом».

— «Дзен і мистецтво догляду мотоцикла», Роберт Пірсіг

Чеснота звуження погляду

«Що істинне для одного яблука, може не бути для іншого. Тому про одне яблуко можна сказати набагато більше, ніж про всі яблука на світі».

— «Дванадцять чеснот раціоналіста»

Кожен фахівець у своїй професії знає ціну звуженню: механік свідомий різниці між карбюратором та радіатором, тому не мислить їх як «автозапчастини». Мисливці і збирачі розрізняють лева і пантеру. Прибиральник не митиме підлогу очисником для вікон, навіть якщо пляшечки з речовиною виглядають однаково.

А от у позаробочий час люди не морочать собі таким голову і розширюють значення слів, щоб охопити якомога більше території. Розмови про *всі* яблука світу навівають більше престижу чи мудрості? Тоді *узагальнене пояснення людського інтелекту* (без супровідних підпитань, як, наприклад, винахід технології складання кубика Рубіка) слід висікти на вічних скрижалях. Може здаватися, що розглядати *часткові* питання не зовсім доречно. Хіба загальна теорія не гідне досягнення сама по собі?

Людина, яка вирізняється допитливістю, підніме один камінець на пляжі і побачить, що відрізняє його від решти. Ви ж називаєте ці камінці «діамантами» і питаєте, що в них може бути особливого, які внутрішні якості, крім сліпучого блиску, можуть об'єднувати їх. А потім хтось проходитиме повз і скаже: «Чому б не назвати і *цей* камінець діамантом? І цей, і цей...». Подорожній повен ентузіазму і хоче як краще. Адже називати одні камінці діамантами, а інші ні, виглядає як порушення демократії, рівності та суцільності. Схоже на типове мислення людини із... *вузьким* (даруйте за каламбур) світоглядом. Такі люди не прагнуть *нового*, не підтримують *інклюзивність* і не переймаються життям *громади*.

Наділяти слово багатьма значеннями і розкидуватися конотаційними відтінками віддає чимось поетичним. Але навіть поети, якщо вони майстри своєї справи, мусять привчати себе до точного сприйняття світу. Замало порівняти кохання з квіткою. Палке, ревниве і невіддане кохання — не те саме, що кохання, перевірене десятиліттями шлюбу. Якщо поет хоче символізувати пристрасне кохання як квітку, він має піти до саду і знайти квітку, яка вирізняється пишнотою своїх барв, п'янким ароматом та колючками. Передаючи відтінки значень і конотації, поет має точно розуміти, яку асоціацію він хоче викликати у голові читача.

Звужувати погляд на незвичних камінцях з якимись особливими якостями — невіддільна частина мистецтва раціональності. І навіть поетики! Тому не соромтеся звертати увагу на деталі, котрі об'єднують ці — і тільки ці — камінці. Ніякого гріха у тому немає.

У компетенції еволюційних біологів пояснювати *тільки* закономірності змін живих організмів, а не «еволюцію» зір чи технологій. На жаль, знаходяться мудрагелі, які словом «еволюція» описують *що* закони природного добору, *що* цілком випадкову будову зір, *що* продуману інтелектом структуру технологій. Це ж усім відомо: якщо слово те саме, значить і річ та сама. Просто у тих біологів клепки бракує, щоб побачити взаємозв'язки.

Що ж може бути благороднішим за встановлення взаємозв'язків? Тож наймудріші члени роду людського — нью-ейджерські гуру — заходяться зі своїм «Усе пов'язано з усім». Якщо вам і собі захочеться ляпнути подібну мудрість, зверніть увагу, як ваші слухачі у щирому подиві всотують цю Велику Мудрість.

А от різниця між графом та його доповненням не потребує цих містичних формулювань. Повністю зв'язний граф, у якого ребра між кожними двома вершинами, містить в собі стільки ж інформації, скільки граф без ребер. Важливі якраз ті графи, в яких деякі вершини *не* з'єднані з деякими іншими вершинами.

Коли непросвітленим дуже кортить побути глибоко мудрим, вони сиплють порівняннями з цією темою, тією темою, аж

поки все не переплітається настільки, що їхній граф втрачає будь-яку практичну цінність. Ця недуга лікується предметним знанням та поглибленим вивченням. Адже коли ви починаєте розуміти предмет у подробицях, то помічаєте, наскільки *різня-ться* між собою речі, і поступово починаєте *прибирати* зайві зв'язки у своєму графі.

Схожим чином важливі ті категорії, які не містять у собі всього на світі. Влучними гіпотезами можна пояснити тільки деякі можливі наслідки.

Нічого дивного у тому, що Ісаак Ньютон зосередився на гравітації — зокрема на тому, як об'єкти падають дотолу, як планети обертаються довкола Сонця, як Місяць спричиняє припливи та відпливи, — *замість* того, щоб пояснювати роль грошей у суспільстві або роботу серця. У зверхності до звуження погляду є щось від еллінів, які вважали, що *виходити* у світ і дивитися на речі — це суто фізична робота, а отже, справа рабів.

Ще Платон у сьомій книзі «Держави» писав:¹

«[...] якщо хтось, лежачи навznak, розглядає на стелі візерунчасті малюнки й при цьому щось там розпізнає, то він у такий спосіб підносить догори свою думку, а не очі. [...] Тому й ніяк не спроможусь повірити, що звертати погляд угору змушує нашу душу якась інша наука, а не та, що стосується буття і того, що невидиме. Коли ж хтось, роззявивши рота, дивиться у височінь чи, примруживши очі, нахиляється донизу, щоб за допомогою відчуттів спробувати щось розпізнати, я заявляю, що він ніколи з того нічого не осягне, бо для таких речей просто не існує жодного пізнання, і я не сказав би, що душа його дивиться вгору, вона звернена вниз, хоч би він, прагнучи те розпізнати, і лежав горілиць на землі чи вмів плавати в такому положенні по морю».

1. Переклад з давньогрецької Дзвінки Коваль. — Прим. пер.

І в наші часи багато хто припускається подібної помилки: вважає, що оперувати вузькими поняттями та виходити у світ і дивитися на речі — справа неблагородна, гідна плебеїв. Але раціоналістам, як і поетам, потрібні гіпоніми, щоб точніше висловлювати свої думки та категорії, щоб охоплювати одну частину мапи і виключати інші. Немає нічого поганого в тому, щоб зосереджувати увагу, звужувати категорії, виключати можливі події та заточувати свої твердження. Якщо ви використовуєте занадто широкі за значенням слова, ваші висловлювання буде важко назвати правдивими, а вірші — поезією.

І ЦЕ Я НАВІТЬ НЕ ЗГАДУВАВ людей, які вважають Вікіпедію «штучним інтелектом», винахід ЛСД — «сингулярністю», а корпорації прирівнюють до «суперінтелекту»!

Дивніше історії

Припустімо, я скажу вам, що *твердо* переконаний в істинності наступних тверджень:

- Якщо ви розфарбуєте своє тіло в колір спектра *рівно* між блакитним і зеленим, напрямок сили тяжіння зміниться на протилежний — і ви почнете падати вгору.
- У майбутньому небо вкриють мільярди чорних летючих сфер. Кожна сфера буде значно масивніша за всі цепеліни світу разом узяті. Якщо ви дасте сфері гроші, з неї спуститься чоловік-повія на тарзанці.
- Ваші онуки вважатимуть ув'язнення злодіїв не просто дурістю, а й *злом* — натомість їх потрібно шмагати.

Думаєте, я збожеволів?

Тепер припустімо, що надворі 1901 рік, і ви маєте обрати між вірою у вищенаведені твердження та наступними:

- Абсолютна швидкість, з якою може здаватися, що два предмети рухаються один відносно іншого, складає точно 1 079 252 848,5032 км/год. Якщо застрибнути у вагон, що мчить із такою швидкістю, і вистрілити з пістолета у вікно, фундаментальні одиниці довжини зміняться: *ви* бачитимете, як куля летить уперед, а для людей назовні картина виглядатиме інакше. І, до речі, час теж зміниться.
- Ще у майбутньому з'явиться надпотужна глобальна мережа з мільярдів лічильних машин, кожна з яких значно потужніша за усі версії лічильних машин, які існували до 1901 року. Одне з основних призначень цієї мережі — передавати рухомі зображення лесбійського сексу так, ніби вони зроблені з чисел.
- Ваші онуки вважатимуть заяви про те, що чорношкіра жінка не може стати президенткою Сполучених Штатів, не просто

дурістю, а й злом.

На цей есей мене надихнув коментар Робіна Хансона: *«Якось я задумався, чи міг би хтось до найменших деталей придумати історію про альтернативну реальність — реальність, яку наші пращури не змогли б відрізнити від правди, щоб вона оприявнила, наскільки неочевидною виявилася правда»*.¹

1. Джерело: https://lesswrong.com/lw/j0/making_history_available/ewg. — Прим. авт.

Логічна хиба узагальнення на основі вигаданих засвідчень

Як думаєте: що я найчастіше чую першим, коли починаю розповідати про передовий штучний інтелект?

«О, то це як у “Термінаторі” / у “Матриці” / щось типу роботів Азімова!»

«Не зовсім, — відповідаю, — я намагаюся уникати хиби узагальнень на основі вигаданих свідчень».

Дехто, зрозумівши, починає сміятися. Інші захищають свій приклад і не погоджуються з моїм маркуванням їхньої пропозиції як хиби.

Чому ж починати дискусію з посилання на художні фільми чи романи не варто? Ніхто ж не стверджує, що *саме так усе й відбудеться*. У чому ж тут хиба? У науковій фантастиці автор намагається ж виобразити майбутнє. Чому б не скористатися плодами його інтелектуальної праці, а не починати спочатку?

Не кожен хибний крок у точному танці раціональності — відверта віра у брехню. Існують куди підступніші способи помилитися.

По-перше, пропоную відмовитися від уявлення, що у науковій фантастиці завжди представлені повноцінні раціональні способи передбачити майбутнє. Навіть найскрупульозніші автори у цьому жанрі в першу чергу — оповідачі історій. Вимоги до оповідання відрізняються від вимог до передбачення. З цього приводу гарно висловився Нік Бостром:¹

«Коли ви востаннє дивилися фільм про раптове вимирання людства — без лиховісних передвісників чи нелюдської цивілізації, що приходить на заміну? Хоча такий сценарій більш імовірний за той, де люди звитяжно

1. Nick Bostrom, “Existential Risks: Analyzing Human Extinction Scenarios and Related Hazards,” *Journal of Evolution and Technology* 9 (2002), <https://www.jetpress.org/volume9/risks.html>.

відбивають орду чудовиськ чи бойових роботів, на такий фільм навряд чи пішли б у кінотеатр».

Отже, у художніх історіях є певні викривлення.² Однак самих лише спроб відкоригувати їх недостатньо. Художню історію *взагалі не можна* назвати раціональною спробою аналізу, навіть якщо її пише найбільш скрупульозний автор-фантаст. Причина — при написанні історії не користуються розподілом імовірностей. Наведу приклад:

«Боб Меркельтуд обережно прошмигнув крізь двері космічного корабля, оглянувся по сторонах, перевіряючи, чи не йдуть йому назустріч моторошні космічні потвори. У нього під рукою була єдина зброя, що виявилася дієвою проти Космічних Потвор: з імовірністю 30% це був Космічний Меч із чистого титану, з імовірністю 20% — звичайний залізний лом, з імовірністю 45% — мерехтливий чорний диск із димних руїн Стоунхенджа; решта 5% розподілялася між надто багатьма дрібними варіантами, щоб їх тут перелічувати.

Попри немалий шанс, що там була С'юзен Віффлфүфер, Меркельтуд ступив два кроки вперед або один назад, щойно тишу чорного шлюзу обірвав оглушливий рев. Чи тихий фоновий шум білого шлюзу? Хоча Амфер та Вуфі (1997) стверджують, що тут Меркельтуд з'їдають, Спеклбекл (2003) вказує на те, що...».

Герої роману можуть не знати, але *автор* не може дозволити собі написати три чарівні слова — «Я не знаю». Головний герой має слідувати одній сюжетній лінії, повної подробиць, які додають історії об'єму — від ставлення Віффлфүфер до фемінізму у майбутньому до кольору її сережок.

2. Наприклад, Hanson's (2006) "Biases of Science Fiction." https://www.overcomingbias.com/2006/12/biases_of_scienc.html

Усі ці обтяжливі подробиці та сумнівні припущення загортають в одну історію, якій дають коротку назву, чим створюють ілюзію цілісного продукту.³

Коли мають справу із задачами із широкими просторами відповідей, найскладніше не *підтвердити* правильну відповідь, а для початку знайти її. Коли хтось починає питати, чи штучний інтелект помістить нас у капсули, як у стрічці «Матриця», він переходить до стобітового твердження, не наводячи дев'яносто-восьмибітового свідчення, яке б визначило місце такого варіанту у просторі відповідей, що заслуговує на розгляд. А після перших дев'яноста восьми бітів вистачить буквально кількох додаткових свідчень, щоб довести цю можливість до майже повної певності, — це вказує на те, що основна робота полягає у звууженні простору відповідей.

У процесі визначення місця варіанту, вартого розгляду, спершу потрібно зважити, що відомо і невідомо, що можна і не можна передбачити, докласти свідомих зусиль для усунення біасу абсурдності та розширення довірчих інтервалів, а також обміркувати, які питання важливі, і бути готовим до можливих чорних лебедів — (раніше) невідомих невідомостей. Перехід до «Матриці» нехтує всіма вищенаведеними кроками.

Будь-який професійний посередник знає: хто диктує умови дебатів, майже що диктує їхні результати. Якщо починати розмову з «Матриці», у голові виринає образ маршу армії роботів, які після довгої боротьби викошують людство, а не суперінтелект, що клацає нанотехнологічними пальцями. Історії акцентують на боротьбі «ми проти них», звертає увагу до питань «Хто переможе?», «Хто має перемогти?» та «Чи буде штучний інтелект справді таким?». Вони створюють загальну атмосферу видовища — ніби ставлять питання «Наскільки захопливим ви бачите майбутнє?».

Натомість у відлунні порожнечі губляться думки про не одну можливу модель розуму, яку зміг би втілити штучний

3. Див. есеї «Третя альтернатива» у цій книзі та «Лезо Оккама» і «Обтяжливі подробиці» у книзі «Мапа і територія». — Прим. авт.

інтелект, про залежність майбутнього від вихідних умов, про потужність розумнішого за людину інтелекту, з чого випливає його непередбачуваність, про те, що людям час почати серйозно до цього ставитися і вживати якихось заходів.

Починати обговорення зі спростування «Термінатора» — спотворювати фрейм. У контексті дискусії про контроль над зброєю речник Національної стрілецької асоціації США не захоче, щоб його представляли як «мавпу з гранатою», а противник легалізації зброї — як «прибічника обеззброєння жертв». Чому ви дозволяєте голлівудським сценаристам диктувати фрейм, навіть якщо вони роблять це ненавмисно?

Журналісти не кажуть: «Майбутнє буде схоже на роман “2001: Космічна Одісея”». Вони питають: «Майбутнє буде схожим на роман “2001: Космічна Одісея” чи стрічку “Штучний розум”?». Це все одно що питати: «Потрібно скоротити пільги для ветеранів з інвалідністю чи підвищити податки для багатих?».

У середовищі предків ніхто не бачив ніяких рухливих картинок — що бачили на власні очі, те й було правдою. Один погляд на однеє слово може запраймити нас, вивести сумісні думки на поверхню свідомості і неабияк вплинути на оцінки ймовірностей. Як думаєте: якої шкоди двогодинний фільм може завдати вашому судженню? виправити шкоду свідомим зусиллям буде не так уже й легко. Так тоді питається: навіщо добровільно пускати цього упиря в будинок? Коли ви граєте в шахи чи го, кожен змарнований хід — крок до поразки. У контексті раціональності кожен вплив, не сплутаний зі свідченнями, у середньому наближає вас до безладності.

Чи вдається глядачам фільмів ставити під сумнів побачене на великих екранах? Зі свого досвіду можу сказати, що мало хто з глядачів поводитьься так, наче він *на власні очі* побачив майбутнє Землі. Люди, які дивилися всі фільми «Термінатора», не побігли 29 серпня 1997 року всі гуртом у сховища цивільної оборони. Але ті з них, хто припускаються цієї хиби, поведуться так,

ніби події фільму відбуваються на *якійсь іншій планеті* — не на Землі, а на якійсь планеті, схожій на неї.

Ви кажете: «Припустимо, ми створимо надрозумний ШІ» — слухачі відповідають: «Але хіба це не призвело до ядерної війни в “Термінаторі”?» Так само тим же голосом, мені здається, хтось міг би сказати: «Але хіба це не призвело до ядерної війни на Альфа Центаврі?» чи «Хіба не це стало причиною падіння італійського міста-держави Пікколо у XIV ст.?» Фільму не те щоб вірять, але він когнітивно доступніший. Хоча до нього і не ставляться як до пророцтва, він виринає як демонстративний випадок з історії. А чи повториться ця історія? Хтозна.

У ході недавньої розмови про вибух інтелекту хтось згадав Бернара Вінджа, який не вірив у те, що нейрокомп'ютерний інтерфейс суттєво підвищить можливості інтелекту, посилаючись на роман «Покинуті в реальному часі» (*Marooned in Realtime*) і Тунка Блюменталю — найбільш технологічно обізнаного мандрівника, хоч він і не справляв враження надрозумного персонажа. «Але ж Тунк втратив майже все своє обладнання! Він був фактично виведений з ладу!» — обурився я. Потім я прокрутив у голові, що тільки-но сказав, і подумав собі: «Чому я взагалі на це ведуся?».

Це питання потрібно обговорювати окремо від того, як Віндж зображував своїх персонажів. Адже суть не в тому, що Тунк Блюменталь був фактично виведений з ладу, а в тому, що його *не існує*. Я міг би сказати: «Віндж вирішив зобразити Тунка обмеженим з причин, пов'язаних або не пов'язаних з його найкращим прогнозом», і мої слова надали б його авторському вибору відповідної доказової ваги. Але я не можу сказати: «Тунк був фактично виведений з ладу» — не існує ніякого «був».

На початку першої чорнетки есею я навмисне залишив помилку «Інші захищають свій *приклад* і не погоджуються з моїм маркуванням їхньої пропозиції як хибі». Але ж «Матрицю» навіть прикладом назвати *не* можна.

Існує ще одна схожа помилка — логічна хибка аргументації на основі вигаданих свідчень: «А от *якби* ви дійшли до кінця

веселки і знайшли горщик із золотом, то переконалися *б* у моїй правоті!». (Оновлення переконання на підставі прогнозованих, але неспостережуваних даних — математична протилежність повзучого детермінізму.)

Окрім евристики доступності, у мозку є ще багато інших механізмів для узагальнення від спостережень. Бачите три зебри — формуєте категорію «зебра», яка автоматично запускає перцептивне висновування. Конеподібні істоти з білими й чорними смугами класифікуються як «зебри», тому що вони швидкі і їх можна їсти. Очікувано, що ці три зебри подібні до решти.

Так само люди бачать (рухомі зображення) трьох боргів, їхній мозок автоматично створює категорію «борг» — вони автоматично висновують, що люди з нейрокомп'ютерним інтерфейсом належать до класу «боргів», тому будуть схожими на спостережуваних боргів у своїй холодності та байдужості, а також вони будуть вдягнені у чорну шкіру і крокуватимуть важкою механічною ногою. Ще раз — журналісти не вірять, що у *майбутньому* існуватимуть борги чи що «Зоряний шлях» стане майбутнім. Однак коли хтось говорить про нейрокомп'ютерний інтерфейс, у нього виникає думка «Чи існуватимуть борги у майбутньому?». Не «З чого мені відомо, що завдяки комп'ютерній телепатії люди втрачають емпатію?». Не «Я ніколи не бачив борга чи когось на нього схожого». І не «*Буквально* з нічого я формую расовий стереотип».

Ось що Джордж Орвелл писав про кліше:⁴

«Перш за все потрібно дати смислу обирати слово — не навпаки... Коли на думці щось абстрактне, ви з самого початку вже більш схильні використовувати слова. І якщо свідомо не опиратися цій звичці, вже існуючий жаргон почне розпускати свої мацаки і зробить усе за вас. І за втрату контролю ви заплатите розмиванням чи навіть підміною значень».

4. Orwell, "Politics and the English Language."

Але от, на мою думку, найгірше тут те, що, послуговуючись уявою автора, люди відмовляються від власної. Згадаймо слова Роберта Пірсіґа:⁵

«Вона не могла розписатися, бо тільки знай повторювала те, що вже чула від когось, як і він у свій перший день повторював те, що колись вирішив був розказати. Вона не могла придумати, що написати про Бозмен, тому що не могла дістати з пам'яті щось варте повторювання. Дивно, але вона не усвідомлювала, що, пишучи, вона може сама побачити усе по-новому, не озираючись на те, що вже було сказано».

Пригадувані художні історії спливають у пам'яті швидше, ніж ви встигнете додуматися до чогось свого; вони підміняють *бачення*. Так і зробите собі найсмертоноснішу ведмежу послугу.

5. Pirsig, Zen and the Art of Motorcycle Maintenance.

Ми змінюємо свою думку рідше, ніж здається

«За останні кілька років ми просили колег, які постали перед вибором роботи, оцінити ймовірність того, що вони нададуть перевагу одній пропозиції над іншою. Попри те, що середня впевненість у передбаченому виборі склала скромні 66%, лише один із двадцяти чотирьох учасників обрав варіант, якому спочатку надав нижчу ймовірність, що дало загальну точність 96%».

— Дейл Гріффін та Амос Тверські¹

Коли я вперше — 1 серпня 2003 року близько третьої години дня — прочитав цей уривок, він змінив мій спосіб мислення. Я зрозумів: *щойно я вже здатен передбачити свою відповідь* — щойно один варіант видається мені ймовірнішим за інші, — то, швидше за все, рішення я вже ухвалив. Ми змінюємо свою думку рідше, ніж нам здається. Здебільшого ми можемо здогадуватися, якою буде наша відповідь, уже через пів секунди після озвучення питання.

Як же стрімко пролітає той ледь помітний момент, коли ми не здатні навіть передбачити власну відповідь. Таке крихітне вікно для розуму, щоб той устиг втрутитися. Що в питаннях вибору, що в питаннях стану речей.

Принцип нижнього рядка полягає у тому, що тільки справжні причини ваших переконань визначають вашу ефективність як раціоналіста. Щойно ви вкорінилися у своєму переконанні, жодні суперечки не змінять значення істини. Щойно ви вкорінилися у своєму рішенні, жодні аргументи не змінять наслідків.

Певно, ви думаєте, що можете дійти до переконання або рішення нераціональним шляхом, а потім спробувати його

1. Dale Griffin and Amos Tversky, "The Weighing of Evidence and the Determinants of Confidence," *Cognitive Psychology* 24, no. 3 (1992): 411–435.

обґрунтувати. А якщо не вдасться, просто відкинути його.

Тоді ви не враховуєте того, що ми змінюємо думку рідше — *набагато* рідше, — ніж нам здається.

Не сумніваюся, що ви можете пригадати хоча б один випадок у житті, коли змінювали свою думку. І не тільки ви. А як щодо усіх випадків, коли ви свою думку не змінювали? За вашими евристичними оцінками власної компетентності, чи вони настільки ж доступні?

Окрім упередження ретроспективи, вигаданої причиновості, упередження позитивності, якорування/праймінгу і далі за списком, а передусім Великого і Жахливого підтверджувального упередження, якщо ідея потрапляє вам у голову, ймовірно, вона залишиться там надовго.

Не поспішайте з рішеннями

З книги Робіна Дейвза «Рациональний вибір у мінливому світі»¹ (жирний шриффт додав я):

«Як зауважував Норман Маер, коли група стикається з проблемою, для її членів цілком природно починати обговорення з пропозицій її вирішення. Як наслідок, подальша розмова зводиться до переваг і недоліків запропонованих рішень, кожен емоційно прив'язується до свого рішення, а до кращих пропозицій уже й не доходить. Тому для покращення процесу групового прийняття рішень Маер вводить наступне правило: **“Поки ви не обговорили проблему якомога ретельніше, не висувайте жодних пропозицій її рішення”**. Що правило справедливе для контекстів, де для проблеми об'єктивно можна знайти вдалі рішення, можна легко продемонструвати.

Маер підготував такий “рольовий” експеримент. Троє робітників з різним рівнем навичок працюють на конвеєрі. Вони чергуються між трьома роботами різної складності, адже найздібніший із них — і водночас той, хто задає тон, — прагне уникнути нудьги. Найменш здібний працівник, розуміючи, що виконує складніші завдання гірше за інших, погоджується на таку перестановку через вплив більш здібного колеги. “Фахівець з ефективності” зауважує: якщо найздібнішому робітнику доручити найскладніше завдання, а найменш здібному — найлегше, продуктивність підвищиться на 20%, тому він радить скасувати чергування на підприємстві. Потім трьох робітників і... четвертого, якого поставили на роль бригадира,

1. Robyn M. Dawes, *Rational Choice in An Uncertain World*, 1st ed., ed. Jerome Kagan (San Diego, CA: Harcourt Brace Jovanovich, 1988), 55–56.

просять обговорити поради фахівця. Деяким рольовим групам розповідають про правило Маєра — не переходити до рішень, поки вони не розберуться повністю із задачею, — тоді як іншим групам ніяких правил не дають. Групи без правил дискусії одразу переходять до суперечки про важливість продуктивності, автономію робітника і боротьбу з нудьгою. Групи, які знали правило, з більшою ймовірністю обирали чергувати двох найздібніших, залишаючи найменш здібного на простішій роботі. Внаслідок цього рішення продуктивність зросла на 19%.

Я часто застосовував це правило в очолюваних мною групах, **особливо при розв'язанні складних проблем, коли всі прагнули одразу обговорювати рішення.** У мене немає об'єктивних критеріїв для оцінки якості групового рішення, тоді як правило Маєра, схоже, допомагає знаходити кращі варіанти».

Правдивіше нікуди. І що складніша проблема, то важче не поспішати з рішенням. Як приклад візьмімо штучний інтелект. Я зустрічаю безліч людей, які точно знають, як створити загальний штучний інтелект, але не вміють розробляти простіші речі, як-от оптичний розпізнавач символів чи систему спільної фільтрації. Що ж стосується створення ШІ з позитивним впливом на світ — умовного Дружнього ШІ, — то *ця* задача настільки складна, що *більшість* примудряється розв'язати її за п'ятнадцять секунд.² Ну звісно. Мене, я так розумію, можна звільнити.

Ця проблема типова не тільки для ШІ. Фізики дізнаються про нові фізичні теорії від тих, хто і дня не займався фізикою. Економісти, буває, чують про неймовірні економічні теорії. Еволюційним біологам щастить знаходити саме тих, хто сходу може розв'язати будь-яку відкриту проблему, аргументуючи все груповим добором. Ну, ви зрозуміли.

2. Див. Yudkowsky, "Artificial Intelligence as a Positive and Negative Factor in Global Risk ([../Text/main-printch17.html#cite.0Yudkowsky.2008](http://Text/main-printch17.html#cite.0Yudkowsky.2008))."

Порада Маєра співзвучна з принципом нижнього рядка: ефективність наших рішень обумовлена тільки тими свідченнями та розрахунками, які ми зібрали чи провели до ухвалення рішення, тому після написання нижнього рядка годі зверху дописувати ще якісь аргументи. Якщо ви надто швидко ухвалите рішення, воно буде сирим і погано обдуманим, хай скільки чудових аргументів ви придумаете опісля.

Також нагадаю, що ми змінюємо свою думку рідше, ніж нам здається. Двадцять чотири людини зазначили, що у майбутньому зроблять такий-то вибір з імовірністю у середньому 66%, але тільки один із тих двадцяти чотирьох обрав той варіант, який уважав менш імовірним. **Щойно ви можете передбачити свою відповідь, певно, свій вибір ви вже зробили.** Якщо ви вже знаєте відповідь за пів секунди після озвучення питання, тоді у вас всього-на-всього пів секунди, щоб зробити розумний вибір. Дуже мало.

Традиційні раціоналісти наголошують на *фальсифікації* — здатності *відмовлятися* від початкової думки, коли з'являються чіткі свідчення проти неї. Але, як ми вже знаємо, щойно якась ідея потрапляє вам у голову, щоб позбутися її, зазвичай потрібно значно більше свідчень. І гірше того — у нас не завжди є розкіш мати незаперечні свідчення.

Тому підозрюю: набагато дієвішим (і складнішим) методом буде *не поспішати з обдумуванням відповіді*. Відкласти й подовжити той крихітний момент, коли ми ще не можемо передбачити свою відповідь, даючи собі більше часу на обдумування.

Адже навіть пів хвилини на тлі пів секунди буде кращим варіантом.

Омана походження

У будь-якому переліку логічних хиб можна знайти «оману походження» — помилковий аргумент, що атакує переконання лише через причини вірити в нього.

На перший погляд, ця теза не тримається купи: якщо не причини переконання визначають її повторювану надійність, то що тоді? У ситуації, коли комп'ютер *Deer Blue* підказує нам хід у шахах, наша довіра виходить з розуміння *коду*, що шукає дерево гри, хоча самі оцінити ми його не можемо. Що може надати якомусь розподілу ймовірностей статус «раціонального», крім того, що він здобутий завдяки певному систематичному надійному процесу?

У деяких статтях про генетичну оману йдеться про те, що аргументація від походження не завжди помилкова і походження свідчень може впливати на їхню оцінку, як у випадку з довіреним експертом. В інших статтях така аргументація *окреслюється* як помилка. Наприклад, хімік Фрідріх Кéкуле вперше побачив циклічну формулу бензену уві сні, хоча не те щоб це заважало нам довіряти цьому переконанню.

То у деяких випадках про оману походження можна говорити як про оману, а в деяких — як про доречний аргумент?

Формально вона вважається помилкою, оскільки *вихідна причина* переконання не збігається з його *нинішнім обґрунтуванням* — сумою всіх відомих *на сьогодні* свідчень за чи проти.

Але ж ми все ще змінюємо свою думку рідше, ніж нам здається. Серед людей претензія на походження має таку силу, якої б не мала серед досконалих баєсових агентів.

Очищення розуму — воістину *потужна евристика* у ситуаціях, коли ви підозрюєте, що значна частина ваших уявлень може походити з отруєного джерела.

Щойно ідея потрапляє вам у голову, її стає значно важче викоринити свідченнями. Подумайте про всіх тих людей, які виростили на Біблії, а потім відкинули (на свідомому рівні) думку, що її

написав сам Бог, але все-таки вірять, що Біблія — джерело незамінної етичної мудрості. Вони провалили завдання очистити розум, хоча досягли б значно більшого, якби сумнівалися в усьому, що каже Біблія — вже хоча б тому, що це написано в Біблії.

Разом з тим вони могли б тримати в голові принцип «зворотна дурість не породжує тямучість», адже мета — розворушити розум і почати думати своєю головою, а не керуватися алгоритмом заперечення усього, що написано у Біблії.

Щойно ідея потрапляє вам у голову, ви всюди будете бачити підтвердження їй. Тому коли первинне джерело піддається сумніву, з вашої сторони буде мудро підозрювати і все листя, яке виросло на цій гілці...

А це не кожному під силу. Адже очистити розум зовсім не просто. Щоб *відучити* розум крутити ту саму платівку із закешованими аргументами, потрібні наравду судомні зусилля. «Якщо події не можуть із рівною ймовірністю розвиватися в обидва боки, тоді це несправжня криза віри», — якось написав Тор Шенкель.

Якщо у вас назбиралося багато ідей, які походять із сумнівного джерела, варто *ставитися* до них *українською мовою* *насторожено*, хай би там як здавалося, що від того вони, їй-богу, не перестають бути правильними. Біблія — хрестоматійний тому приклад.

З іншого боку, ... ніхто не скасовував достатньо однозначних свідчень, після яких уже немає значення, з якого джерела походить ідея. І завдання Науки у цьому процесі — зібрати однозначні свідчення. Тоді стає байдуже, чи уві сні Кекуле вперше побачив бензенові кільця, чи сформулювали гіпотезу генерування випадкових комп'ютерних зображень чи з допомогою екстра-сенса, якого викрили у шахрайстві, чи навіть взяли з Біблії. Циклічна структура бензену підтверджена достатньою кількістю експериментальних свідчень, тому джерело ідеї можна відкинути.

За браком таких однозначних свідчень треба звертати увагу на походження ідей: давати фахівцям більший кредит довіри, якщо їхня галузь гідна її, підозрювати ідеї із сумнівних джерел,

не довіряти тим експертам, мотиви яких не заслуговують на довіру, *якщо* вони не можуть надати аргументи без посилання на свій авторитет.

Генетична омана тоді стає *оманою*, коли існують обґрунтування *поза* вказаним походженням, але посилання на походження подається так, ніби воно вичерпує питання. Коментатор з нікнеймом ХалФінні (HalFinney) пропонує називати коректне звернення до джерел твердження «генетичною евристикою».¹

Зі свого боку можу запропонувати кілька практичних правил:

- З підозрою ставтеся до претензій на походження переконань, які вам не до вподоби, особливо якщо їхній пропонент висуває аргументи, які виходять за межі його авторитету. «Політ — це ж релігійна ідея, отже брати Райти, ясна річ, брехуни» — один із класичних прикладів.
- З тієї ж причини не сподівайтесь, що вам вдасться зібрати вірогідні дані про технічну сторону проблеми, вдаючись до глибинного психоаналізу зіпсованих мотивів тих, хто причетний до справи. За наявності технічних аргументів їм слід віддавати перевагу.
- Коли на одне із ваших засадничих джерел падає тінь підозри, *варто* взятися переосмислити всі гілки та суцвіття, які беруть початок з того кореня. Водночас ви не можете повністю відкидати їх як висновки, тому що обернена дурість не породжує тямучість, але все ж...
- Якщо ви помічаєте за собою, що досі поділяєте ранні навіювання, що походять з відкинутого джерела, слід неабияк насторожитися.

1. Джерело: https://lesswrong.com/lw/s3/the_genetic_fallacy/lls. — Прим. авт.

Смертельні спіралі

Евристика афекту

Евристикою афекту називають таку евристику — джерело швидких та чуттєвих суджень, — коли цінність або шкода оцінюється за суб'єктивними враженнями. Відчуття приємного та неприємного виступають основними рушіями людського мислення. Евристика афекту, звісно, не обходиться без старих добрих біасів, моїх улюблених.

Почнемо з менш шкідливого упередження порівняно з рештою. Ви готуєтеся до переїзду в інше місто. У списку речей, які ви хочете забрати з собою, антикварний годинник вашого дідуся. У першому випадку годинник подарували вам бабуся і дідусь на ваші п'яті іменини, у другому — далекий родич, до якого у вас немає особливої прив'язаності. Яку суму ви готові віддати за страховий поліс, який зобов'язує повернути вам 100 доларів, якщо годинник загублять при перевезенні? У дослідженні Крістофера Ші та Говарда Кунройтера йдеться про те, що учасники експерименту у першому випадку повідомляли про бажання заплатити вдвічі більше.¹ Таке рішення може видаватися раціональним. Чому б не заплатити більше, щоб цінний для вас предмет безпечно доставили до місця призначення? Аж поки ви не усвідомите, що страхування не *захищає* годинник, а відшкодовує заявлену вами суму, незалежно від того, наскільки він для вас цінний. (В умові було зазначено, що страхуванням опікується компанія, не дотична до перевезень, тому жодної додаткової мотивації подбати про безпеку годинника воно не додає.)

Гаразд, це упередження ще більш-менш *можна* зрозуміти. Ви можете викрутитися тим, що піддослідні страхувалися від емоційних ризиків, а не фінансових — вони хотіли купити спокій.

Тоді що ви скажете про наступний експеримент? Дослідження Кіміхіко Ямагіші показало, що піддослідні оцінювали

1. Christopher K. Hsee and Howard C. Kunreuther, "The Affection Effect in Insurance Decisions," *Journal of Risk and Uncertainty* 20 (2 2000): 141–159.

хворобу як більш небезпечну, коли їм повідомляли, що вона спричиняє 1 286 смертей на 10 000 випадків, порівняно з хворобою, смертність від якої становила 24,14%.² Очевидно, образ тисячі мертвих тіл викликає більш емоційну реакцію, ніж одна людина, яка виживе з вищою ймовірністю.

Але це ще не всі погані новини.

Припустімо, керівництво аеропорту мусить вирішити, чи витратити кошти на нове обладнання. Критики ідеї вимагають витратити гроші на посилення безпеки аеропорту. Пол Словік представив двом групам респондентів аргументи «за» і «проти» купівлі обладнання, а також шкалу відповідей — від 0 («зовсім не підтримую») до 20 («повністю підтримую»)³. Для однієї групи захід було сформульовано як порятунок 150 життів, для іншої — як порятунок 98% із 150 життів. Гіпотеза, що надихнула на експеримент: формулювання «врятувати 150 життів» справляє розмитий позитивний ефект (це багато чи мало?), тоді як «врятувати 98% від чогось» сприймається явно дуже добре, адже 98% так близько до верхньої межі відсоткової шкали. І, як слід було очікувати, порятунок 150 життів отримав середній рівень підтримки 10,4, тоді як порятунок 98% із 150 життів — 13,6.

Погляньмо ще на звіт Вероніки Денес-Рай та Сімора Епстайна: учасники експерименту, яким пропонували виграти долар за те, що вони випадково витягнуть з миски червону желейну цукерку, часто обирали ту, де було більше червоних цукерок загалом, навіть якщо їхня частка була меншою.⁴ Тобто миску з 7 червоними цукерками зі 100 обирали частіше, ніж ту, де була 1 з 10.

2. Kimihiko Yamagishi, "When a 12.86% Mortality Is More Dangerous than 24.14%: Implications for Risk Communication," *Applied Cognitive Psychology* 11 (6 1997): 461–554.

3. Paul Slovic et al., "Rational Actors or Rational Fools: Implications of the Affect Heuristic for Behavioral Economics," *Journal of Socio-Economics* 31, no. 4 (2002): 329–342.

4. Veronika Denes-Raj and Seymour Epstein, "Conflict between Intuitive and Rational Processing: When People Behave against Their Better Judgment," *Journal of Personality and Social Psychology* 66 (5 1994): 819–829.

Піддослідні зізнавалися, що розуміли несприятливі ймовірності, але відчували, ніби шанси вищі там, де червоних цукерок кількісно більше. Обтяжений статистикою читачу, я розумію: для вас слова піддослідних можуть звучати дико, але якщо як слід подумати, їх можна зрозуміти. Імовірність 7% проти 10% може звучати не дуже, проте вона чудово компенсується зростанням кількості червоних цукерок. Імовірність гірша, та шансів на *перемогу* більше — от побачите! Над експериментом варто посушити голову, щоб здобути просвітлення, як решта планети сприймає ймовірності.

В есеї «Терези Феміди, Записник Рациональності» я згадував про те, як в експерименті з ядерними реакторами, природним газом та харчовими консервантами виявили, що подання інформації про великі переваги змушувало людей сприймати ризики як нижчі, а от подання інформації про високі ризики знижувало оцінку переваг — і так по всіх квадрантах⁵ Зрештою, люди об'єднують свої судження про конкретні позитивні та негативні аспекти якогось явища у загальне враження.

Дослідження Меліси Фін'юкейн показує, що брак часу значно *посилює* негативний зв'язок між очікуваним ризиком та очікуваною вигодою, що узгоджується із загальним висновком про те, що через брак часу, неякісні дані або неухважність гору над аналітичним мисленням беруть чуттєві евристики.

Йоав Ганзах спостеріг той самий ефект у царині фінансів.⁶ Згідно із загальною економічною теорією, прибутковість і ризик повинні позитивно корелювати. Іншими словами, люди платять вищу ціну за надійні вкладення, що знижує їхню прибутковість, тоді як акції забезпечують вищий дохід порівняно з облігаціями, але несуть вищий ризик. При оцінці знайомих акцій судження аналітиків про ризики і прибутковість позитивно корелювали між собою, як і передбачалося. Однак при оцінці незнайомих акцій аналітики, як правило, судили про цінні папери,

5. Finucane et al., "The Affect Heuristic in Judgments of Risks and Benefits."

6. Yoav Ganzach, "Judging Risk and Return of Financial Assets," *Organizational Behavior and Human Decision Processes* 83, no. 2 (2000): 353–370.

спираючись на власне узагальнене враження: низький ризик і висока прибутковість або високий ризик і низька прибутковість.

Для подальшого ознайомлення раджу оглядову статтю Пола Словіка «Раціональні актори та раціональні дурні: вплив евристики афекту на поведінкову економіку» (*Rational Actors or Rational Fools: Implications of the Affect Heuristic for Behavioral Economics*).

Оці́ненність (та дешеві покупки на свята)

Наближається період свят, тож я ніяк не можу обійти увагою питання від читачів:

«Шановна редакціє *Overcoming Bias*, чи є якесь упередження, яке я міг би використати, щоб про мене склали *враження* щедрої людини, але я при цьому не дарував *нічого дорогого*?».

Радо відповідаю: і такі упередження існують! Як пише Ші у своїй статті «Менше — краще», якщо ви придбаєте шарф за 45 доларів, в очах отримувача ви, ймовірно, станете щедрою людиною, ніж якщо купите пальто за 55 доларів.¹

Це окремий випадок більш загального явища. До цього Ші ставив піддослідним питання, скільки вони готові заплатити за вживаний словник музичних термінів:²

- Словник А 1993 року випуску містить 10 000 статей — стан як новий.
- Словник Б 1993 року випуску містить 20 000 статей, обкладинка порвана, решта ціла і як нова.

Заковика у тому, що деякі піддослідні бачили два словники, а інші — тільки *один*...

Піддослідні, яким давали *один* з варіантів, були готові заплатити в середньому 24 долари за Словник А і в середньому 20 доларів за Словник Б. Учасники, яким давали одразу *обидва*, були

1. Christopher K. Hsee, "Less Is Better: When Low-Value Options Are Valued More Highly than High-Value Options," *Behavioral Decision Making* 11 (2 1998): 107–121.

2. Christopher K. Hsee, "The Evaluability Hypothesis: An Explanation for Preference Reversals between Joint and Separate Evaluations of Alternatives," *Organizational Behavior and Human Decision Processes* 67 (3 1996): 247–257.

готові заплатити 27 доларів за Словник Б і 19 доларів за Словник А.

Звісно, кількість статей у словнику відіграє більшу роль за якість обкладинки (принаймні якщо ви збираєтеся ним користуватися). Але якщо вам показують тільки один словник, і в ньому 20 000 статей, то це число не несе багато інформації. Це мало? Багато? Хтозна. *Ні з чим порівняти*. З іншої сторони, один зі словників виділяється розірваною обкладинкою. Ця характеристика має негативну емоційну зарядженість.

Однак якщо оцінювати словники, що лежать поряд, кількість статей стає *оцінюваною* — з'являються дві *зіставні* величини. І щойно цей параметр стає оцінюваним, він починає переважати над тим, чи важлива пошарпана обкладинка.

В експерименті Словіка ставили інше питання. Що ви оберете?³

1. Шанс 29/36 виграти \$2.
2. Шанс 7/36 виграти \$9.

Тоді як середні *ціни* цих пропозицій, в еквівалентній вартості, становили 1,25 долара та 2,11 долара, їхні середні рейтинги привабливості складали 13,2 та 7,5 відповідно. І ціни, і рейтинги привабливості отримували в умовах, коли учасникам повідомляли, що з уже оцінених азартних ігор навмання оберуть дві, і вони зіграють у ту, яка має вищу ціну або вищий рейтинг привабливості. (У піддослідних була мотивація оцінювати вище і виставляти вищу ціну за ті ігри, в які вони хотіли зіграти.)

Азартна гра з вищим грошовим виграшем здавалася менш привабливою — класичний випадок обернення вподобань. Дослідники припустили, що грошові суми більше узгоджуються із завданням оцінювання ціни, тоді як імовірність виграшу — із привабливістю. Тому дослідники вирішили зробити виграш у грі більш емоційно виразним — афективно оцінюваним — більш привабливим.

3. Slovic et al., "Rational Actors or Rational Fools."

Невеликий програш вони зробили частиною гри. У старій версії гри виграєте 9 доларів із шансом $7/36$. У новій версії можна виграти 9 доларів з імовірністю $7/36$ і втратити 5 центів з імовірністю $29/36$. Зголошуючись на стару версію, ви відразу оцінюєте привабливість 9 доларів. А в новій грі порівнюєте бажаний виграш у 9 доларів з *утратою* 5 центів.

У статті автори зазначили: «Результати перевищили наші очікування». У новому експерименті проста гра із шансом $7/36$ виграти 9 доларів отримала середній рейтинг привабливості у 9,4 бала, тоді як версія із шансом $29/36$ програти 5 центів — рейтинг у 14,9 бала.

У подальшому експерименті тестували, чи учасники експерименту обирали стару версію або гарантований прибуток у 2 долари. Тільки 33% студентів віддали перевагу старій грі. В іншій групі попросили обрати між гарантованими 2 доларами та новою грою (з доданою ймовірністю втратити 5 центів). 60,8% респондентів віддали перевагу цій грі. Хай там як, а 9 доларів не вельми приваблива сума, а от виграти 9 доларів чи програти п'ять центів — *неймовірно* привабливе співвідношення виграшу до програшу.

Одним лише збитком можна зробити гру більш привабливою. Така вона — людська психологія. Тому-то хто розуміє витончену складність людського інтелекту, не хоче схожості штучного інтелекту на людський.

Звісно, що такий трюк спрацює, коли немає можливості порівняти дві гри.




Рис. 1: Стаканчики морозива з дослідження №2

Два стаканчики морозива з дослідження Ші © 1998 John Wiley & Sons, Ltd (Джон Вайлі та сини).

Як думаєте, якому з двох стаканчиків морозива на Рисунок 1 учасники схожого експерименту Крістофера Ші надали перевагу?

Як і годиться, відповідь залежить від того, чи піддослідні бачили один стаканчик чи одразу обидва. Піддослідні, яким показали один стаканчик, були готові заплатити 1,66 долара Продавцю Н та 2,26 долара Продавцю L, тоді як хто бачив обидва стаканчики, був готовий віддати 1,85 долара Продавцю Н та 1,56 долара Продавцю L.

Що з цього ми можемо винести, коли підемо купляти подарунки? Якщо ви вивернете гаманця на 400 доларів на айПód Táч із 16 Гб, адресат подарунка побачить найдорожчий MP3-плеєр. Заплатите 400 доларів за Нінтénдо Ві — адресат подарунка побачить найдешевшу гральну консоль. Тож яке співвідношення

ціни та цінності вигідніше? Це питання набуває сенсу, коли можна порівняти один товар з іншим. І цей привілей буде тільки у вас — адресат бачитиме тільки ваш вибір.

Якщо у вашому розпорядженні обмежена сума грошей, а ваша мета — показати свою дружбу і не обов'язково *допомогти* адресату, не купуйте цінні речі. Подумайте, скільки ви готові віддати за те, щоб справити враження на отримувача, а потім знайдіть найменш цінну річ, яка коштує стільки ж. Що дешевший *клас* речей, то більш по-багатому ця *річ* виглядатиме — ви ж витратили на неї фіксовану суму. Який із подарунків запам'ятається надовго — футболка за 25 доларів чи свічка за ті ж гроші?

І ось, дивіться, японський звичай купувати дині за 50 доларів уже набуває нового сенсу. А ви, либонь, дивилися на тих японців і хитали головою: «Це ж що там у них у голові?». І все ж їх вважають надзвичайно щедрими, аж до марнотратства, хоча платять вони за свою щедрість 50 доларів. Ви можете заплатити за вишукану вечерю 200 доларів, так і не заживши слави багатія, а можете купити диню за 50 доларів. А якби існував звичай дарувати зубочистки за 25 доларів чи порошинки за 10 доларів, то примудрялися б витратити ще менше.

P.S. Розкажете, що купили, якщо трюк таки стане у пригоді?

Безперервна шкала, чималі штрафи від присяжних та дослідження майбутнього

Попри дивну назву, психофізика — шанована галузь, у якій досліджують співвідношення між фізичними стимулами та реакцією сенсорних систем. Припустімо, ви передаєте акустичну енергію у повітря, тобто створюєте шум. Як *гучність* цього звуку сприймається людиною залежно від акустичної енергії? На скільки більше енергії потрібно викинути в повітря, щоб звук здавався вдвічі гучнішим? Не вдвічі більше — радше приблизно у вісім разів більше.

Виміряти акустичну енергію та кількість фотонів нескладно. Рівень *гучності* та *яскравості* можна визначити опитуванням отримувачів стимулів. І розкласти їхні відповіді на порядковій шкалі від «дуже тихо» до «дуже гучно» або від «дуже темно» до «дуже яскраво». Можна взяти і необмежену шкалу, на якій нульова точка позначатиме «зовсім не чути» або «зовсім не видно», причому з вихідної точки значення можуть зростати до нескінченності. При застосуванні необмеженої шкали реципієнту подають постійний стимул — *модуль*, — якому присвоюється встановлена експериментатором величина. Наприклад, звукові призначають рівень гучності у 10 балів. А тоді отримувач сигналу оцінює гучність на 20 балів — удвічі вище за модульне значення.

Цей метод показав себе як доволі надійний. А що як дозволити піддослідному оцінювати за необмеженою шкалою без модуля? Від нуля до нескінченності, без вивірчої наперед установленної величини. Звісно ж, він вигадає власний модуль. *Співвідношення* між подразниками відображатиме надійну кореляцію між відповідями піддослідних. Іншими словами, піддослідний А оцінює гучність звуку X у 10 балів, а звук Y — у 15 балів. Якщо піддослідний В оцінює гучність звуку X у 100 балів,

можна припустити, що звук Y він оцінить десь у 150 балів. Та якщо ви не знаєте, який модуль — показник масштабності — використовує піддослідний С, здогадатися, яким числом він позначить рівень гучності для звуку X, уже зась. Може, скаже 1. А може, 1 000.

Якщо піддослідний оцінює *окреми* звук за *необмеженою* шкалою (без установленого стандарту порівняння), то майже *весь* цей розкид відповідей зумовлений довільним вибором модуля й аж ніяк не рівнем гучності.

«Хм, — думаєте ви про себе, — страшенно нагадує присяжних у процесі обговорення штрафних збитків. Не дивно, що вони різняться аж настільки!». Аналогія, звісно, цікава. Але як продемонструвати її експериментально?

Якось Канеман дав 867 потенційним присяжним ознайомитися з описом судових справ (одна з них стосувалася дитини, у якої загорівся одяг). А потім попросив їх або

1. оцінити свій рівень обурливості, викликаний діями підсудного, на обмеженій шкалі,
2. оцінити ступінь покарання обвинуваченого на обмеженій шкалі,
3. або призначити доларовий еквівалент для штрафних збитків.¹

І хоча оцінки обурення та покарання у піддослідних — оце так! — корелювали, їхні оцінювання збитків суттєво відрізнялися. Утім, *рангове впорядкування* штрафних відшкодувань — від найменшої до найбільшої суми — добре корелювало між учасниками.

Якщо запитати, яку частку розкиду на шкалі «покарання» можна пояснити конкретним сценарієм — окремою судовою

1. Daniel Kahneman, David A. Schkade, and Cass R. Sunstein, "Shared Outrage and Erratic Awards: The Psychology of Punitive Damages," *Journal of Risk and Uncertainty* 16 (1 1998): 48–86; Daniel Kahneman, Ilana Ritov, and David Schkade, "Economic Preferences or Attitude Expressions?: An Analysis of Dollar Responses to Public Issues," *Journal of Risk and Uncertainty* 19, nos. 1–3 (1999): 203–235.

справою, поданою кільком учасникам, — то відповідь (навіть для сирих балів) становить 0,49. Для *рангових порядків* відповідей у доларах частка поясненого розкиду дорівнює 0,51. А для *сирих доларових* сум пояснений розкид становить лише 0,06!

Іншими словами, якщо ви ознайомилися із випадком — та ж дитина, в якій загорівся одяг, — із немалими шансами вгадаєте оцінку покарання і *ранжування* стягнення в доларах відносно інших випадків, однак суму штрафу в доларах ви нізачо не передбачите.

І навіть якщо візьмете медіанне значення випадково відібраних відповідей, самі ці числа однаково не матимуть економічного сенсу.

Отже, оцінка присяжними штрафних збитків відображає не стільки економічну вартість, скільки ставлення, яке можна трактувати як психофізичну міру обурення на необмеженій шкалі без стандартного модуля.

З моїх спостережень, більшість *футурологічних прогнозів* варто розглядати саме як прояв ставлення. Візьмімо питання «Скільки нам ще чекати до появи III людського рівня?». Відповідей на будь-який смак. Досі згадую, як на одній зустрічі знаний фахівець з III бовкнув про «п'ятсот (!) років».

Питання, чому час появи такого III так *важко передбачити*, саме по собі варте окремої розмови. Але той розумака, який говорив про «п'ятсот років», навряд чи зазірав у майбутнє, щоб видати свою відповідь. І навряд чи він отримав це число, скориставшись стандартним помилковим трюком із законом Мура. То що ж він *хотів сказати* своїми п'ятьмастами роками?

Можу припустити, що він відповів так, ніби я спитався: «За шкалою, де 0 — “зовсім не складно”, наскільки складною вам *здається* задача створення III?». Якби ця шкала була обмеженою, будь-який розсудливий респондент відмітив би варіант «надзвичайно важко». Адже якщо у чомусь ви дупля не відбиваєте, воно буде *здаватися* надзвичайно складним. А натомість маємо необмежену шкалу без стандартного модуля. Люди просто зі стелі беруть число, яким представляють значення

«надзвичайно складно» — 50, 100, 500. Потім вони дописують «років» після тих чисел і загортають свою вигадку у пакунок футурологічного прогнозу.

Питанням про складність ШІ перелік складних запитань не обмежується. Інші відповідають так, ніби їх запитали: «Наскільки позитивно ви ставитеся до ШІ?» — хіба що тут нижчі значення означають більш позитивне ставлення, і вони ще й додають наприкінці «років». Але якщо ці «часові розрахунки» слугують не проявом ставлення на необмеженій шкалі без модуля, тоді я не знаю, що й думати.

Ефект ореолу

Вплив загального позитивного чи негативного відчуття — неважливо, наскільки воно логічне чи усвідомлене, — на інші судження називається евристикою афекту. В одному експерименті після згадування переваг ядерної енергетики піддослідні з більшою ймовірністю оцінювали її як менш ризиковану. Стикаючись з незнайомими акціями, біржові аналітики судять про них із загального враження: низький ризик і висока прибутковість або високий ризик і низька прибутковість. І це всупереч стандартній економічній теорії, згідно з якою дохідність і ризик повинні позитивно корелювати.

У соціальній психології ефект ореолу — одне з утілень евристики афекту. Про це пише Роберт Чалдіні:¹

«Як свідчать дослідження, ми автоматично наділяємо гарних людей схвальними рисами — хистом, добротою, чесністю та інтелектом (ознайомитися зі свідченнями можна у дослідженні 1991 року Еліс Іглі, Річарда Ешмора, Мони Макіджани та Лорі Лонго²). І навіть не приймаємо до свідомості, що причина тих суджень — врода. От деяких наслідків несвідомого припущення “красивий — значить добрий” я й побоююся. Наприклад, дослідження федеральних виборів у Канаді 1974 року показало, що за привабливих кандидатів проголосувало у два з половиною рази більше виборців порівняно з непривабливими.³ Та мало того — у подальшому

1. Robert B. Cialdini, *Influence: Science and Practice* (Boston: Allyn & Bacon, 2001).

2. Eagly, A. H., Ashmore, R. D., Makhijani, M. G., & Longo, L. C. (1991). What is beautiful is good, but...: A meta-analytic review of research on the physical attractiveness stereotype. *Psychological Bulletin*, 110(1), 109–128. <https://doi.org/10.1037/0033-2909.110.1.109>

3. Efran, M. G., & Patterson, E.W.J. (1976). *The politics of appearance*. Unpublished manuscript, University of Toronto.

дослідженні виборці взагалі не помічали за собою прихильності до вродливих політиків. Якщо подивитися на дані, 73% опитаних канадських виборців рішуче заперечували, що на їхній вибір вплинула зовнішність, і тільки 14% допустили можливість такого впливу (Майкл Ефрэн, Пёттерсон). Та скільки б виборці не заперечували вплив зовнішності на виборність кандидата, свідчення все ж демонструють протилежне.⁴

Подібний ефект помітили і при наймі. В одному дослідженні під час імітованої співбесіди кандидатів оцінювали прихильніше через їхню доглянутість, аніж через професійну кваліфікацію, попри те, що рекрутери стверджували, що зовнішній вигляд відіграє незначну роль у їхньому рішенні.⁵ Ця перевага привабливих кандидатів триває від дня найму до виплати зарплати. Економісти, які аналізували вибірки із США та Канади, з'ясували, що гарним працівникам платять у середньому на 12-14% більше, ніж їхнім колегам, які не вирізнялися зовнішніми рисами.⁶

Ще одне не менш тривожне дослідження вказує на такий же вплив пропорцій тіла та будови кісток у нашому судовому процесі. Тож, видно, вродливі мають більше

4. Budesheim, T. L., & DePaola, S. J. (1994). Beauty or the beast? The effects of appearance, personality, and issue information on evaluations of political candidates. *Personality and Social Psychology Bulletin*, 20(4), 339–348. <https://doi.org/10.1177/0146167294204001>

5. Mack, D., & Rainey, D. (1990). Female applicants' grooming and personnel selection. *Journal of Social Behavior & Personality*, 5(5), 399–407.

6. Hamermesh, D. S., & Biddle, J. E. (1994). Beauty and the Labor Market. *The American Economic Review*, 84(5), 1174–1194. <https://www.jstor.org/stable/2117767>

прихильність ще й правової системи.⁷⁸ До прикладу, одне пенсильванське дослідження починалося з оцінювання привабливості 74 обвинувачених чоловіків до судових процесів. Опісля, перевіrivши судові протоколи їхніх справ, дослідники побачили, що привабливі чоловіки відбулися значно м'якшими вироками. Фізично вродливим обвинуваченим щастило мати вдвічі більше шансів уникнути в'язниці. В іншому дослідженні — щодо компенсації збитків під час несправжнього процесу про недбалість — обвинуваченому, який виглядав привабливіше за потерпілого, в середньому доводилося виплачувати 5 623 долари; коли ж зовнішність грала на руку потерпілому, середня компенсація складала 10 051 долар. Прихильність на основі зовнішності проявляли присяжні як чоловічої, так і жіночої статі.⁹

Крім того, експерименти свідчать про те, що привабливі люди мають більше шансів отримати допомогу у скруті¹⁰ та змінити думку аудиторії¹¹ ...».

Вплив зовнішності на оцінку рівня інтелекту, чесності чи доброти — усе це приклади біасу (особливо під час оцінки інших

7. Moore, C. H. (1990). Effects of physical attractiveness of the plaintiff and defendant in sexual harassment judgments. *Journal Of Social Behavior and Personality*, 5(6), 547-562.

8. Downs, A. C., & Lyons, P. M. (1991). Natural observations of the links between attractiveness and initial legal judgments. *Personality and social psychology bulletin*, 17(5), 541-547.

9. Kulka, R. A., & Kessler, J. B. (1978). Is justice really blind? The influence of litigant physical attractiveness on juridical judgment. *Journal of Applied Social Psychology*, 8(4), 366–381. <https://doi.org/10.1111/j.1559-1816.1978.tb00790.x>

10. Benson, P. L., Karabenick, S. A., & Lerner, R. M. (1976). Pretty pleases: The effects of physical attractiveness, race, and sex on receiving help. *Journal of Experimental Social Psychology*, 12(5), 409–415. [https://doi.org/10.1016/0022-1031\(76\)90073-1](https://doi.org/10.1016/0022-1031(76)90073-1)

11. Chaiken, S. (1979). Communicator physical attractiveness and persuasion. *Journal of Personality and Social Psychology*, 37(8), 1387–1397. <https://doi.org/10.1037/0022-3514.37.8.1387>

якостей, з якими ознайомлюються з поточного опису). Чи ви думаєте, що судження про чесність та привабливість можуть збігатися на якихось обґрунтованих підставах? З іншого боку, наскільки мене вважають розумним через мою чесність? І наскільки — чесним через мій інтелект? Процеси пошуку і проговорювання істини щільніші одне до одного, ніж привабливість та образ розумної людини...

Крім того, усі ці дослідження про ефект ореолу довкола привабливості мають викликати у нас підозру, адже він може виникати і довкола доброти або інтелекту. Припустімо, у вас є знайомий — дуже розумний, а ще чесний, альтруїстичний, добрий та спокійний. Не завадить пильність до того, чи не впливають ці риси на ваше сприйняття інших. Можливо, ваш знайомий надзвичайно розумний, чесний та альтруїстичний, але далеко не добрий та спокійний. Тому якщо ваші знайомі чітко поділяються на янголів і демонів, варто задуматися.

А ще — може, *ви* не вважаєте за потрібне, хоч і варто, — трохи більше скептичності до привабливих політичних кандидатів усе ж не завадить.

Гаданий супергероїзм

Уявімо собі ситуацію: озброєний соціопат бере заручників і, відкинувши всі заклики до перемовин, погрожує розстрілом полонених. Якщо поганець має заручників, у справжньому житті хороші хлопці не розноситимуть дверей, хоча іноді — у дуже рідкісних випадках, але іноді, — життя аж до того уподібнюється до голлівудської стрічки, що хорошим хлопцям доводиться вибивати двері.

А тепер уявіть, що у двох віддалених світах двоє героїв першими вриваються у кімнату, щоб зустрітися з лиходієм вічнавіч.

В одному світі герой здатен голіруч піднімати машини, випустити вогонь з ніздрів, чути крізь стіни, а його шкіра не просто відбиває кулі, а розчиняє їх при контакті. Лиходій же засів у початковій школі, де тримає в заручниках понад дві сотні дітей, а на шкільному подвір'ї батьки не тямляться од відчаю.

В іншому світі герой — працівник поліції Нью-Йорка, у заручниках три повії, яких злодій підібрав на вулиці.

А тепер — увага — питання. Перш ніж відповідати, добряче подумайте. Хто з них більший герой? У кого більші шанси потрапити на сторінки коміксу?

Під ефектом ореолу усі позитивні риси видаються пов'язаними. Людей з високими оцінками за шкалою привабливості позначають іще як здібніших, добріших, чесніших та розумніших.

Отже, персонажі коміксів, які здаються сильними й невразливими (обидві позитивні риси), також видаються такими, що більшою мірою володіють героїчними якостями — зокрема мужністю та героїзмом. Та все ж:

«Наскільки складно бути хоробрим і мужнім, якщо ти практично невразливий?»

— Адам Уоррен, «Силою наділена» (*Empowered*), Том 1

Не пригадую, чи наступну думку я десь вичитав чи дійшов до неї сам: «Схоже, *слава*, зокрема, доповнює всі інші особистісні риси». До прикладу, візьмемо Махатму Ганді. Він був *найальтруїстичнішою* особистістю XX ст. чи просто *найвідомішим* альтруїстом? Махатма протистояв поліції з кийками та озброєним солдатам. Але він був знаменитістю — і ця слава його захищала. А що з іншими людьми, які були на протесті, тими, кого теж не оминули кийки та кулі, хоча їхні імена не потрапили б на шпальти міжнародних газет, якби їх госпіталізували чи застрелили?

Як Ганді ставився до того, що саме він потрапляє у заголовки, наживає слави і здобуває своє місце в історії як *уособлення* ненасильницького опору, хоча ризикує менше за людей, які протестують разом із ним? Як він почувався, коли один з тих анонімних героїв з очима, повними вогню, підходив і називав його великою людиною? Чи намагався Ганді колись подивитися на світ з такого боку? Самому тільки Махатмі про це відомо.

Але я ні в якому разі не критикую його. Суть ненасильницького опору не в демонстрації сміливості. Повихвалитися мужністю можна набагато простіше — наприклад, переплисти Ніагарський водоспад у бочці. Звісно, Ганді частково, хоч і не зовсім, захищала його слава — інакше не могло і бути. Його вчинки потребували сміливості — хоч і не такої, як у анонімних протестувальників.

Я хочу вказати на таке упередження: у сприйнятті оцінка Махатминої слави ніби *додається* до його справедливо здобутої оцінки альтруїзму. Адже коли ви думаєте про ненасилля, то на думку спадає Ганді, а не анонімний протестувальник, котрий брав участь в одному з влаштованих Махатмою мітингів, де його били кийками, намагалися застрелити і зрештою госпіталізували, а потім він накульгував до кінця життя. Однак *його імені ніхто не знає*.

Схоже питання: «Що краще — ризикувати своїм життям, щоб урятувати дві сотні дітей чи троє дорослих?».

Залежить від того, що відповідач має під *«краще»*. Якщо вам доведеться-таки обирати між порятунком двох сотень дітей та трьох дорослих, обирайте перше. «Врятувати одне життя — що зберегти цілий світ» може бути натхненною табличкою до оплесків, однак жажливою моральною порадою, коли вам доведеться обирати між одним та іншим. Отже, якщо ви тлумачите *«краще»* як *«Що важливіше?»*, *«Який результат бажаніший?»* чи *«Якби я стояв перед вибором, що мав би зробити?»*, то краще врятувати дві сотні, ніж трьох.

Та якщо говорити про велич як вияв доброчесності, то людина, готова ризикувати життям заради трьох, виявляє більше мужності, ніж та, котра зробила б це заради двохсот, але не заради трьох.

Це не означає, що ви можете свідомо ризикувати життям, щоб врятувати трьох дорослих і кинути дві сотні школярів напризволяще лише тому, що хочете показати, який ви доброчесний. Ризикуючи життям *заради того, щоб бути доброчесним*, ви виявляєте набагато менше чесноти, ніж якби робили це *заради порятунку інших*. Хто обирає врятувати три життя замість двохсот, бо, на його думку, такий вчинок краще розкриває його відвагу, той настільки егоїстично зачарований своєю «величчю», що його вчинок морально прирівнюється до ненавмисного вбивства.

Так виглядає один зі сценаріїв *у-вею*: чеснота розкривається не в спробах її проявити. При виборі між безпечним методом урятувати світ, який не передбачає самопожертв чи незручностей, та методом, який передбачає значний ризик і тяжкі поневіряння, гріш ціна вашому героїзму, якщо ви оберете другий шлях. У бажанні зображати героя немає нічого геройського. Від самого початку програвша мета.

По-справжньому чеснотливі люди, які беруть собі за мету врятувати життя, а не випинатися, намагатимуться врятувати якомога більше життів найменшими зусиллями, себто значна частина їхньої доблесті буде прихована. Такий погляд може спантеличувати, та він не суперечливий.

Але ми не завжди можемо обирати, чи бути нам вразливими до куль. Після того, як ми зробили все можливе, щоб зменшити ризик і розширити масштаб, будь-який *залишковий* героїзм буде по-справжньому проявленим.

Ставлячи на карту своє життя, поліціант без надздібностей (можливості бачити крізь стіни, суперсили, можливості літати, невразливості до куль) демонструє більше мужності, ніж Супермен, який *не більше ніж супергерой*.

Смертельні спіралі радості

Зірок на небі не стане, щоб порахувати помилки людського мислення, через які ми переоцінюємо пояснювальну силу своєї любові теорії. Теорією флогістону в хімії можна було пояснити що завгодно — аж поки доходило до прогнозу майбутніх результатів. Що більше явищ ви стараєтеся пояснити улюбленою теорією, то правдивішою вона здається. То хіба ж усі ті численні спостереження не підтверджують її? Тож що більшої ваги теорія набуває у ваших очах, то більш прискіпливо ви дивитеся на за-свідчення, які їй суперечать. Теорія стає усе загальнішою — ви шукаєте їй застосування у більшому розмаїтті ситуацій.

Якщо у вас є знайомі, які вірять, що уряд Бельгії таємно контролює банкову систему США або що невидимою силою синього духу вони можуть знайти вільні паркомісця, певно, деś так вони і починали.

(Придивіться уважніше — і ви побачите стільки підтвер-джень вашій теорії...)

Мене насправді дуже непокоїть це коло позитивних підтвер-джень, відповідальне за силу-силенну помилок у науці та пов-сякденному житті.

Але це ще нічого порівняно зі спіраллю смерті, яка починає-ться з одного заряду позитиву — з однієї *дуже приємної* думки.

Нова політична система, здатна врятувати світ. Великий про-відник — сильний, благородний і мудрий. Чудове зілля, що і болі в шлунку усуває, і рак лікує.

Біс, заберіть мої гроші і дайте усі три. А там уже і велика справа вимагає великого лідера. А великий лідер має винайти магічне зілля чи навіть цілих два.

Будь-яка позитивна риса (привабливість чи сила) підкріплює уявлення про будь-яку іншу позитивну рису (інтелект чи відвага) — ось вам і ефект ореолу. Що-що? Думали, що він не діє, коли взаємозв'язок не має сенсу?

Уся ця історія з позитивними рисами схожа на те, як атом урану розщеплюється на нейтрони, які потім розщеплюють інші атоми.

Слабка позитивна емоція докритична — вона не виходить з-під контролю. Приваблива людина здається чеснішою, завдяки чому вона стає більш привабливою в очах споглядача, хоч коефіцієнт ефективного множення нейтронів і менший за одиницю. Метафорою, резонанс трохи вводить в оману, а потім зовсім згасає.

При інтенсивній позитивній емоції, пов'язаній з Великою Штукою, резонанс поширюється скрізь. Ідейний комуніст бачить марксистську мудрість у кожному гамбургері з МакДональдзу, у кожному підвищенні, в якому йому відмовили (але яке йому б точно дали у раю для трудящих), у кожних виборах, на яких обирають не його кандидата, у кожній газетній статті, перекошеній не в той бік. Щоразу, коли вони звертаються до Великої ідеї за інтерпретацією кожнісінької події, Ідея пускає коріння все глибше й глибше. Через позитивне підкріплення ви почуваетесь краще і, звісно ж, *хочете* вірити усе більше й більше.

Якщо ця Велика Штука настільки приємна, що ви *не пропускаєте* можливості інтерпретувати по події на день, підкріплюючи свою любов до Неї, резонанс позитивної емоції набуде рис камери повної мишоловок, заряджених м'ячиками для пінг-понгу.

Можете називати це «атрактором щастя», «надпозитивним зворотним зв'язком», «петлею самопідживлюваної похвали» чи «веселописом». Мені більше подобається термін «спіраль емоційної смерті».

У наступному есеї я розповім про те, як їй протистояти.¹

1. Підказка: ні, не назавжди відкинути захоплення до чогось і не тримати предмет захоплення у маленькій безпечній приватній магістерії. — Прим. авт.

Опір смертельній спіралі щастя

Жив-був собі чоловік, який свято вірив у Велику Ідею. Як і слід було сподіватися, той чоловік годину за годиною проводив у міркуваннях над Великою Ідеєю. А потім як усвідомив, що Ідея *не просто* велика, а *найвеличніша з усіх*. Він вірив, що ця Ідея розкриє таємниці всесвіту, посуне корумпований та бездарний Уряд, наділить її носіїв напівмагічною силою, нагодує неситих, вилікує хворих і зробить світ кращим...

Цим чоловіком був Фрэнсис Бэкон, а його Великою Ідеєю був науковий метод. З усіх божевільних, які за всю історію обіцяли людству подібні поступи, він виявився єдиним, хто мав рацію.¹

Власне, ось тут рішення ніколи нічим не захоплюватися і дає маху — деякі ідеї *дійсно* аж настільки вдалі. Принаймні поки що ніхто не *виконав* обіцянок сміливіших за ті, що їх дав Бекон.

З цього постає питання: «Як ми можемо чинити опір нестямності у ставленні до власне Науки?». Смертельна спіраль щастя бере початок з віри у щось настільки *чудове*, що під ефектом ореолу ви *все більше* зачаровуєтеся предметом своєї віри і під дією циклу по спіралі спускаєтеся у безодню. А що як Наука і *справді* приносить стільки користі, що ми не здатні усвідомити її істинну велич і вберегти свої глуздάρні? Звучить-то як! *О ні, я вже падаюууууууууу...*

У вашому кеші, певно, знайдеться місце для дідівської мудрості про те, що *не варто переборщувати з тією наукою*. Так і натрапите на думки штибу «Наука дала нам не тільки кондиціонери, а й водневу бомбу» чи «Наука відкриває таємниці зір і біології, але не може довести чи спростувати дракона у моєму гаражі». Тільки-от люди, у головах яких *народилися* ці думки, *не* здобулися на опір смертельній спіралі щастя. Вони не зважали

1. Звісно, Бекон не самотужки розвивав науку. Однак він зробив немалий внесок і, можливо, першим усвідомив її силу. — Прим. авт.

на те, як їхнє захоплення наукою виходить з-під контролю. А може, дошкуляли заяви науки про їхні любі переконання, тож вони шукали шляхи підважити її авторитет.

Шаблонні закиди у бік науки навряд чи припадуть тим, хто щиро поділяє захоплення наукою. Не та цільова аудиторія. Значить що? Треба шукати інші закиди.

А от у мене питання: «Після вибіркового пошуків нарікань — навіть при спробі не впадати у смертельну спіраль щастя — не хочеться звинуватити себе у раціоналізації? Навіщо взагалі звертатися до тих думок, які виникли при спробі самоманіпуляції?».

До заяв, що один біас може протидіяти іншому, ставлюся загально скептично. Уявіть собі, що автомеханік вам каже, що мотор правого склоочисника зламався, тому він не лагодитиме його, ще й лівий розтратить. Чесно кажучи, від такого розуму і лихо не забариться. Яким би не було рішення, воно має зводитися до віри в істину — а не до віри в те, що ви вірите в те, що самі ж вважаєте неправдивим.

Чи можете ви розірвати смертельну спіраль щастя, звузивши ентузіазм до якоїсь сфери? Складник смертельної спіралі щастя — прагнення бачити Велику Ідею повсюдно: комунізм міг би вилікувати рак — якби ж то йому дали шанс. І з цього випливає, певно, надійніша з усіх ознака провідника секти: гуру заявляє про компетенцію не в одній сфері (і навіть не в кількох суміжних), а в *усьому*. Гуру знає, що член секти мусить їсти, носити, чим заробляти на життя, з ким кохатися, які фільми дивитися, яку музику слухати...

На жаль для цього задуму, коли намагаються втиснути науку у прокрустове ложе наперед заданих меж, більшість продуває по повній. Для їхньої мети шпилька «А наука не може вилікувати рак» надто тупа. А «Наука не повідає про батьківську любов до дитини» — просто помилкове твердження. Якщо ви хочете відірвати науку від батьківської любові, то ігноруєте не тільки когнітивістику та еволюційну психологію. Ви ігноруєте і корпорацію United Therapeutics Мартіни Ротблатт, яку вона заснувала, щоб

знайти ліки від легеневої гіпертензії, на яку хворіла її донька.² Так чи інакше наука долучена до кожного аспекту людського життя.

Які ще *хибноприємні* твердження про науку вам спадають на думку?

На мою скромну думку, до таких належить твердження, що через винятковість науки науковцям не слід навіть думати про етичний бік їхньої роботи — все одно ж вийде якнайкраще. Здається, на цьому твердженні починається нерозуміння процесу примноження наукою блага. Науковці — люди; у них, як і в решті, є просоціальні інтереси, тож це принаймні *часткова* причина, чому наука принесе більше користі, ніж лиха.

Але і це питання, ясна річ, не обділили увагою. Ось кілька прикладів хибних тверджень, які гарно звучать: «Ага, хворий на рак вилікується, прочитавши наукові статті» або «Соціопати могли б стати цілком нормальними — варто їм лише взяти за правило не вірити нічому без відтворюваних експериментів із $p < 0,05$ ».

Одягнути захисний костюм у вигляді помірної привабливості науки — погане рішення, коли ви не хочете приймати подібні твердження на віру. Не варіант і почати вірити, що публікації статей *спричиняють* рак або що наука не розкаже чогось про рак у такій-то площині.

Навпаки: якщо ви досить добре розумієтеся на функціонуванні науки, то й знаєте, що, хоча «наука може вилікувати рак», хворий, що пише статтю для журналу, чудом не видужає. Саме цей *конкретний* ланцюжок причин і наслідків не дасть результату.

Смертельна спіраль щастя — *суто* емоційна проблема, що проростає зі сприйняття (ефекту ореолу), і ось після прийняття першого позитивного твердження ми більше віримо у подальші. Самим бажанням ефекту позбутися неможливо, тож, можливо, він з нами назавжди. Зрештою, можна сповільнитися, зробити

2. На щастя — можу додати. — Прим. авт.

павзу, оцінити кожне додаткове милозвучне твердження як додаткову обтяжливу подробицю і зосередитися на конкретних його деталях, хай скільки воно позитивне.

А що ж як конкретне милозвучне твердження «неможливо спростувати», але аргументи «можна навести як “за”, так і “проти”»? Я б радив остерігатися подібних словосполучень, оскільки їх часто вживають при повторенні тих самих свідчень або за бажання замовчати слабкі сторони. Через небезпеку смертельної спіралі щастя незле буде перечасувати із втіхою до *невирішених* заяв, щоб не втрапити у пастку нарощування позитивного афекту.

Смертельна спіраль щастя стає *серйозною* емоційною проблемою саме через надміру позитивний зворотний зв'язок — здатність процесу переходити у неконтрольований стан. Ефекту ореолу навряд чи вдасться позбутися остаточно, але критичне мислення дозволяє тримати його в докритичному стані — так, щоб резонанс згасав, а не розкручувався.

Ви можете навіть сказати, що вся проблема в тому, що, приймаючи засновки, люди не аналізують кожну обтяжливу подробицю: не вимагають достатніх свідчень, не шукають недоліків і підтверджень, які б підживлювали цікавість. Без омани поєднання ефект ореолу ще зберігався б, але до смертельної спіралі щастя справа б не дійшла.³

Бездоганий раціоналіст, якщо не має достатніх свідчень для кожного додаткового твердження про Найкращу Штуку у видимому всесвіті, не відчуватиме емоційної прихильності навіть до неї. Хоч у вас так не вийде, ніщо не заважає прагнути раціональності настільки, щоб тримати щастя під контролем.⁴

3. Більше подробиць в есеях «Обтяжливі подробиці», «Скільки потрібно засвідчень?» та «Лезо Оккама» у попередній книзі «Мапа і територія». — Прим. авт.

4. Дійсно небезпечною Велика Штука стає, коли *будь-яка критика тверджень на її користь сприймається як закид і піддається суспільному осуду*. Так аргументи стають солдатами: будь-які позитивні твердження — це «наші», а спроба заколоти їх — зрада. Тоді ланцюгова реакція набуває рис надкритичності. Про це у наступному есеї. — Прим. авт.

Стюарт Армстронг якось дав доцільну раду:⁵

«Розділіть свою Велику Штуку на менші незалежні ідеї і користайтесь ними як незалежними одна від одної».

Наприклад, марксист міг би розділити Велику Марксову Штуку на трудову теорію вартості, класову теорію, теорію оплати праці та теорію кінцевого політичного режиму. Потім оцінити кожен з них безвідносно до решти, себто істинність і хибність не мають поширюватися від однієї до інших. І якщо таке вдасться повернути, спіраль не загрожуватиме, оскільки кожна теорія завузька, щоб з неї почалася спіраль».

Можна порівняти з перешкоджанням взаємодії докритичним масам плутонію. Менш імовірно, що вам зірве дах від трьох Великих Ідей. Крім того, Армстронг радить звернути увагу на конкретність. Щоразу, коли хтось каже: «Публікацією достатньої кількості робіт можна вилікувати рак», ви запитаете: «Йдеться про експериментальний метод? Якщо так, то на якому етапі експерименту ми бачимо прогрес? Чи про науку як суспільний процес, що спирається на зусилля дослідників? Або ж про спробу нажитися на дослідженнях?». Сподіваюся, його слова відведуть вас від реакції «добре/погано» і звернуть увагу на плутанину та брак підтверджень.

Отже, щоб *не* потрапити у капкан смертельної спіралі щастя, слід:

- розділити Велику Ідею на частини,
- оцінювати кожен додаткову подробицю як обтяжливу,
- розглядати конкретний причинно-наслідковий ланцюжок, а не позитивні чи негативні відчуття,
- не повертатися до знайомих засвідчень,

5. Джерело: https://lesswrong.com/lw/lm/affective_death_spirals/gp5

- не зачаровуватися твердженнями, помилковість яких ви не можете спростувати.

Але не варто:

- назовсім відмовлятися від надмірного захоплення,
- розпочинати заангажований пошук негативних сторін аж до повернення до нещастя,
- силоміць втискувати ідею у прокрустове ложе.

Некритична надкритичність

Час від часу люди сперечаються про те, чи можна назвати атеїзм «релігією». Десь у статті «Мета і прагматизм» я згадував, що суперечки про значення слова майже завжди призводять до втрати зв'язку з початковим питанням.¹ А як щодо цього спору? Що йому дало початок?

Атеїст звинувачує собі «релігію» у створенні Священної Інквізиції, хрестових походах та різноманітних конфліктах з ісламом чи інших священних війнах. А вірянин, певно, відповідає:

— Але ж атеїзм — теж релігія: ви ж маєте уявлення про Бога. Наприклад, вірите, що Його не існує.

— Атеїзм стільки релігія, скільки ж неколекціонування марок — хобі, — кидає атеїст. Спір розпочався.

Або ж відповідь вірянина на перше звинувачення звучить так:

— Хто б казав! А що коїв Сталін — атеїст, який в ім'я безвір'я репресував церкви.

— Жоден справжній шотландець², — закортить відповісти атеїстові, — Сталіновою релігією був комунізм.

— Комунізм стільки релігія, скільки фіндом «Зоряних воєн» — політична партія, — відповідає вірянин. Спір розпочався.

Чи слід визначати «релігійну людину» як того, хто має визначену думку про існування щонайменше одного бога — наприклад, приписує існування Зевса ймовірність меншу за 10% чи більшу за 90%? Чи того, хто надає існуванню щонайменше одного бога високу (понад 90%) ймовірність? У першому випадку Сталін був би «релігійним», у другому — «нерелігійним».

1. Посилання: https://lesswrong.com/lw/lf/purpose_and_pragmatism/

2. https://uk.wikipedia.org/wiki/%D0%96%D0%BE%D0%B4%D0%B5%D0%BD_%D1%81%D0%BF%D1%80%D0%B0%D0%B2%D0%B6%D0%BD%D1%96%D0%B9_%D1%88%D0%BE%D1%82%D0%BB%D0%B0%D0%BD%D0%B4%D0%B5%D1%86%D1%8C

Проблема тільки в тому, що такий підхід засадничо хибний. Ви ж хотіли дізнатися — пам'ятаєте, з чого почався спір? — що в певні періоди історії спричиняло геноциди й тортури, вчинені нібито в ім'я ідеї. На історичні події перевизначення слів ніяк не впливає.

Комунізм був лихом зі складною природою: у ланцюжку причиновості геть не одна ланка. А ще — якби мені довелося вказати на первинну помилку, я б назвав... еммм, хай Господь скаже за мене:³

«Коли намовить тебе брат твій, син твоєї матері, або син твій, або дочка твоя, або жінка твого лоня, або твій приятель, який тобі як душа твоя, таємно говорячи: Ходімо ж і служім іншим богам, яких не знав ти та батьки твої, з богів тих народів, що навколо вас, близьких тобі або далеких від тебе, від кінця землі й аж до кінця землі, то не будеш згоджуватися з ним і не будеш слухатися його, і не буде милосердитися око твоє над ним, і не змилюєшся й не сховаєш його, **бо конче заб'єш ти його**, рука твоя буде на ньому найперше, щоб забити його, рука всього народу наостанку. І закидаєш його камінням, і він помре, бо жадав відвернути тебе від Господа, Бога твого, що вивів тебе з єгипетського краю, з дому рабства».

— Повторення закону 13:7–11 (жирний шрифт додано)

Те саме правило діяло у Сталіна для комунізму і у Гітлера для нацизму: якщо ваш брат критикує Маркса, а син заперечує єврейську змову — не сперечайтесь, не наводьте свідчень, не перевіряйте, не звертайтеся до історії — просто негайно здайте його таємній поліції.

Я вже писав, що спротив смертельній спіралі щастя включає принцип обтяжливих подробиць: *слід* сумніватися в конкретних деталях кожного нового приємного твердження про Велику

3. Переклад Івана Огієнка. — Прим. пер.

ідею.⁴ Він не усуне ефект ореолу, але, сподіваюся, знизить його до некритичного рівня, щоб кожне милозвучне твердження спричинило в середньому менш ніж одне подібне.

Цілковита протилежність цієї поради, що посилює ефект ореолу до *надкритичної* межі, — боятися сперечатися з *будь-яким* твердженням на користь Великої ідеї.

Нагадаю, що політика — губитель розуму. Аргументи — це солдати. Щойно ви розумієте, на чий бік стали, мусите підтримувати усі аргументи вашої сторони і нищити ворожі. Інакше — ви б'єте своїм же у спину, діючи на користь ворога.

Якщо . . .

- . . . вам здається, що суперечка з тим, хто поширює приємну, але хибну думку про еволюцію, підбадьорить креаціоністів;
- . . . у вас виникає відчуття духовного бонусу за кожне добре слово про Бога, а будь-які суперечки про це тільки псують ваші стосунки з Ним;
- . . . у вас є стійке відчуття, що інші в кімнаті сприймуть вашу критику останньої війни як «відмову підтримувати наших військових»;
- . . . ви скажете щось проти комунізму — і вас або камінням заб'ють, або застрелять;

. . . тоді смертельна спіраль щастя досягла надкритичної точки. Тепер це Надщаслива Спіраль Смерті.

А початкове питання — чому люди вчиняють геноциди? — взагалі не стосується релігії як такої. На мою думку, найкраще розмежування між «надприродним» і «натуралістичним» світоглядами полягає в тому, що перший визнає існування ментальних сутностей, таких як духи, а другий зводить ментальні явища до нементальних складових. Тому зосереджуватися на

4. Це питання зовсім не тривіальне. Часто люди забувають собі його поставити, коли слухають надзвичайно деталізовані замальовки заворожливих проєктів. Мовчу вже про випадки, коли ті футурологи у новій обгортці подають свої любі серцю ідеї. — Прим. авт.

цьому як на ключовому питанні — що повестися на винятковість релігії. Втім, надприродні твердження варто виокремлювати, оскільки на засадничому рівні вони завжди виявляються хибними.⁵ Але всі вони, зрештою, представляють один клас помилок.

Смертельна спіраль щастя може виникати на підґрунті надприродних переконань — особливо з монотеїстичних релігій із Надщасливим Агентом на вершині, що погоджується з будь-яким приємним твердженням про себе, — а навколо достатньо розвинених комплексів мемів, що передбачають надприродне покарання за невіру. Та не одними релігіями — спіраль смерті може вирости з політичного новаторства, натхненного провідника, віри в расове призначення чи економічної гіпотези. Історія вчить, що смертельна спіраль щастя небезпечна, незалежно від надприродного підґрунтя. Релігія не настільки виняткова, щоб вирізнятися на тлі інших класів помилок чи взагалі бути основною проблемою.

Вказавши пальцем на *віру*, Сем Харріс підступився ближче до проблеми. Не покладаючи відповідний тягар свідчень на кожне додаткове приємне твердження, ви ризикуєте *дуже* легко запустити резонанс афекту. Подивіться на тих нещасних нью-ейджерів. Християнство, відстоюючи дива віри, вибудувало захист від критики. Нью-ейджери ж через культуру успадкували заешовану думку, що віра — це щось добре, але їм бракує такого ж виняткового Писання, як у християнства, яке відсікає конкуруючі мемі. Тому нью-ейджери ширяються своїм щастям у компанії зір, дерев, магнітів, дієт, ворожінь та однорогів...

Та щойно критика перетворюється на гріх, недоречність чи навіть злочин, смертельна спіраль щастя набуває нестямніших рис. Світ не позбавлений того, що заслуговує на пошану, тому *категорично* забороняти надмірне шанування абсурдно. Та *не* народилося ще такої Ідеї, настільки чистої від помилок, щоб критикувати аргументи на її користь було чимось

5. Див. есей «Загадкові відповіді на загадкові питання» у книзі «Мапа і територія». — Прим. авт.

неправильним. Не народилося. Не. Народилося. Крапка. Суцільна більшість можливих переконань у просторі нетривіальних відповідей хибна, як і хибна суцільна більшість *аргументів на користь* істинного переконання. І жодна нестямна ідея не змінить цього.

А відповідати на критику насильством категорично категорично категорично заборонено. У людському мистецтві раціональності майже немає приписів, які б не містили в собі «якщо», «та», «але» чи інших способів ухилитися від зобов'язання. Ось це одне з них. На кожен поганий аргумент знайдеться контраргумент. Контраргумент, а не сила чи куля.

Випарне охолодження і групові переконання

З початком вивчення сектантства дослідники, на свій подив, з'ясували, що значне потрясіння — як-от несправджене пророцтво чи викриття моральної вади засновника — лише зміцнює віру і фанатизм членів секти. Свідки Єгови, спираючись на біблійні розрахунки, пророкували Армагеддон у 1975 році. Рік минув спокійно, і світ зустрів наступний. І навіть попри те, що 27 вересня 1975 року на Землі так і не висадився міжгалактичний космічний флот, юнеріанці не зникли — вони й досі активно пропагують свої ідеї.

Чому ж після розгромного спростування групові переконання тільки *набирають* у силі?

Вважають, що це явище проявляється через когнітивний дисонанс. Коли людина заради віри пішла на «незворотні» кроки — скажімо, віддала житло засновнику секти в очікуванні прибульців, — вона вже навряд чи визнає свою помилку. З підриву їхньої віри і проростає когнітивний дисонанс: щоб захиститися від шоку, люди шукають підтвердження своїх поглядів, чим тільки посилюють фанатизм. А там внаслідок підсилення індивідуального у силі набирає груповий фанатизм.

Якось у спеціальній програмі — Джава-аплеті — я побачив, як випарне охолодження утворює конденсат Бозе — Айнштайна, і тоді зрозумів: на посилення фанатизму може впливати ще одна сила. Випарне охолодження утворює потенційний енергетичний бар'єр навколо гарячих атомів. Оскільки атоми рухаються з різною швидкістю, теплову енергію добре описують випадкові величини. При їхньому зіткненні змінюється і кінетична енергія атомів. Якщо встановити потенційний бар'єр трохи вище за середню теплову енергію, окремі атоми з достатньою кінетичною енергією зможуть вирватися з пастки. Коли надзвичайно швидкий атом виривається, він забирає з собою велику

кількість кінетичної енергії, що призводить до зниження середньої енергії. Група стає значно холоднішою, ніж потенційний енергетичний бар'єр навколо неї.

У класичній праці з психології «Коли пророцтво підводить»¹ згадується момент, коли один із сектантів вийшов з кімнати одразу ж після того, як не побачив жодної літаючої тарілки. Хто виходить із секти *першим*? *Середньостатистичний* сектант? Чи відносно скептично налаштований сектант, який раніше виступав голосом поміркованості та пригальмовував запал більш фанатичних членів?

Тому після виходу учасників з найвищою кінетичною енергією подальші дискусії точитимуться між крайніми фанатиками по один бік та меншими фанатиками по інший, а груповий консенсус буде десь «посередині».

А що буде аналогією до утворення конденсату Бозе — Айнштайна? Гадаю, немає потреби розтягувати її аж до цього випадку. Мабуть, ви пам'ятаєте аналогію з ланцюговою реакцією поділу, якою я описував смертельну спіраль щастя. Коли з групи виходять помірковані члени, решта, заохочуючи одне одного та придушуючи інакомислення, внутрішньо зміцнює свій фанатизм.²

Коли члени спілки об'єктивістів дізналися про багаторічний зв'язок Айн Ренд з Натаніелем Бренденом, значна частина приєдналася до Брендена, який пропонував «відкриту систему» об'єктивізму, яка розходилася з поглядом Ренд. А хто ж лишився з нею після того скандалу? Члени, які *найбільше* вірили їй, а також деякі з тих, хто не визначився, і після виходу поміркованих чули лише одну точку зору. Це пояснює, чому в Інституті Айн Ренд рівень фанатизму зріс, якщо порівнювати з початковою групою об'єктивістів до розпаду.

1. Festinger, L., Riecken, H. W., & Schachter, S. (1956). *When prophecy fails*. University of Minnesota Press. <https://doi.org/10.1037/10030-000> (<https://psycnet.apa.org/doi/10.1037/10030-000>)

2. Аналогії з термодинамікою тут немає — хіба що хтось винайде ядерну зброю, що вибухає при охолодженні. — Прим. авт.

Кілька років тому я приєднався до розсилки трансгуманістичної спілки, де мала група прихильників «соціал-демократичного трансгуманізму» активно зневажала кожного лібертаріанця у групі. Більшість лібертаріанців відписалася від розсилки, а решта перестала будь-що постити. Як наслідок, група суттєво зсунулася вліво. Чи зробили вони це навмисно? Певно, ні — не думаю, що кривдники аж стільки знали про психологію.³ У крайньому разі, можливо, вони хотіли показати себе більшою рибою у меншому ставку.

Ось чому так важливо толерантно ставитися до інакомислення — аж до її упередженої форми. Перш ніж виганяти когось із групи, зачекайте ще якийсь час *після* того, як ваше рішення вже здається вам виправданим. Приберіть крайніх — і групова позиція зсунеться, а інакодумцем стане вже хтось інший. Виженете і його — опинитеся на шляху до утворення конденсату Бозе — Айнштейна, тобто за крок до... вибуху.

З іншого боку, на думку Томаса Куна, наука повинна була стати «парадигмою», в якій носії знання користуються спільною технічною мовою, недоступною стороннім. За Куном, на етапі становлення науки її представники всіляко намагаються зробити свої роботи зрозумілими для інших академіків поза своєю галуззю. Але, за Куном, справжній поступ як технічної дисципліни стає можливим лише тоді, коли наука відмовляється від вимоги зовнішньої зрозумілості. При цьому науковці всередині парадигми повинні вважати обізнаність з великими обсягами технічного знання належною. Стосовно розуміння науки громадськістю звучить цинічно, але зерно істини в цьому, безумовно, є.⁴

3. Якщо вже на те пішло, я вже не можу пригадати, де саме закріпив аналогію з випарним охолодженням (хоча, може, хтось згадував її у цьому контексті до мене). — Прим. авт.

4. За мою теорію модерзації інтернет-спілкування, щоб завести обговорення, слід видаляти тролів і поширювачів спаму. Крім них, з розсилки варто теж видалити приязних, але технічно необізнаних користувачів. І ще — дійсно відкрита розмова в інтернеті швидко зводиться нанівець.

Згідно з цією теорією, помилкою буде викидати *яскраво виражених* тролів, оскільки вони виконують приховану функцію перетворення менш радикальних розбіжностей на прийнятні. Але й не можна допустити, щоб ті тролі почали сперечатися між собою чи задавати тон розмові. Якщо у чаті є душній, який не погоджується з усіма, будь-хто із більш поміркованою та обґрунтованою незгодою вже не виглядатиме білою вороною. Утім, теорія не прислужилася мені настільки, наскільки б я хотів, тому користуйтеся нею із дещицею сумніву. — Прим. авт.

Коли ніхто не зважається закликати до стриманості

Одного ранку я вистрибнув з ліжка, увімкнув комп'ютер. Мій браузер автоматично підтягнув стрічку новин. У той день всі писали про те, як два викрадені літаки протаранили хмарочоси Всесвітнього торговельного центру.

Мене одразу ж навідали три думки (точно у такому ж порядку):

Схоже, я дійсно живу у Майбутньому.

Добре, що хоч не ядеркою.

Гіперреакція буде вдесятеро гіршою за саму подію.

Виявилося, своїм зі стелі взятим «вдесятеро гіршою» я дуже прогадав. Навіть я не зміг передбачити, наскільки гіршою виявиться реакція. У цьому й проблема песимізму: як би низько ви не опускали планку, влучити так, щоб приємні несподіванки врівноважували розчарування, *майже неможливо*.

Утім, я одразу зрозумів: з кожної праски повторюватимуть, яка жадлива і моторозна ця подія, — і ніхто не наважиться виступити голосом стриманості та помірної відповіді. За початковими підрахунками, 11 вересня загинули шість тисяч людей. Того дня політика, котрий сказав би: «Шість тисяч смертей — це восьма частина річних жертв ДТП у США», — негайно усунули б з посади.

Звісно, той день був кепським. Але якщо кожен отримує бали за наголошування на масштабі болю і ніхто не наважується сказати «досить» щодо сили відплати, то реакція неминуче перевищить її належний рівень — яким би він не був.

Спіраль ненависті — це таке собі темне дзеркало смертельної спіралі щастя. Завдав удару Ворогу — герой. Засумнівався у бодай єдиному звинуваченні — вже зрадник. Проте як суцільна

більшість усіх складних тверджень хибна, так і суцільна більшість негативних суджень — навіть про найлихішу людину у світі — здебільшого хибна.

Як на мене, найкраща цьому ілюстрація: «ті терористи-самогубці були боягузами». Ви точно у цьому впевнені? Як не крути, щоб свідомо скерувати літак у будівлю, потрібна яка-не-яка, але сміливість. З усіх смертних гріхів боягузтво точно можна викреслити зі списку. Мабуть, їм здається, що будь-який негатив, хай скільки він недолугий, про терористів мусить бути правдивим. Цікаво, скільки очок я б набрав, якби звинуватив Аль-Каїду у вбивстві Кеннеді. А якби назвав їх сталіністами? Чесно, на звання боягузів вони точно не заслуговують.

А чи взагалі потрібно перейматися, чи були ті терористи боягузами? Так, потрібно. І не лише для реалістичного уявлення про психологію ворога. Від спіралі ненависті багато шкоди. Це вкрай небезпечно тим, що про мішень цькування — чи то євреїв, чи то Адольфа Гітлера — *негативні висловлювання* переважають над *точними висловлюваннями*.

Коли у сил оборони запас із тисячі літаків і сотні тисяч дозубів озброєних солдатів, треба врахувати, що імунна система може нанести більше шкоди за дев'ятнадцятьох чоловік та чотирьох невійськових літаків. Витративши мільярди доларів, занапастивши тисячі життів військових, США вистрілили собі в ногу ефективніше, ніж могла б помріяти собі будь-яка терористична група.

Навіть якби уряд проігнорував атаку й просто відбудував вежі, наслідки були б менш руйнівні, ніж ті, до яких призвела його реакція. Але хіба на такому рішенні можна набрати виборців? Навіть якщо окремі політики розуміли, що реакція може завдати більше шкоди, ніж сама атака, зберегти кар'єру вони могли лише, піддавшись провокації Аль-Каїди. Виступаєте за рішучу відповідь — патріот. Аналізуєте заяву патріота — зрадник.

Спочатку реакція на події 11 вересня була більш кмітливою, ніж я очікував. Пам'ятаю, як хтось із конгресменів — забувся імені — говорив перед камерами: «Ми забули, що основна ціль

уряду не економіка, не охорона здоров'я, а захист власних громадян від нападу». У мене аж очі тоді полізли на лоба: оце так — політик сказав щось не для оплесків. Мусить бути, емоційний шок був настільки разючим, що цілий конгресмен сказав щось, що... відповідало дійсності.

Та за два дні шок розвіявся, і жага відповідати образу зайняла чільне місце у політичних обговореннях. Спіраль нагнітання взяла гору. Щойно виникає табу на обговорення стриманості (з чого б воно не починалося), рівень люті та безумства з часом лише зростає.

Кожна справа тяжіє до сектантства

Днями Кейд Метц у виданні *The Register* повідомив, що адміністраторам Вікіпедії у приватній розсилці надходять заклики банити всіх теперішніх і потенційних критиків.¹ Зокрема, банити одного продуктивного користувача, коли один адміністратор — *саме через* його продуктивність — вирішив, що це шпигун від *Wikipedia Review*. І верхівка Вікіпедії згуртувалася, щоб прикрити своїх.

Невже у прагненні систематизувати знання людства прихована якась моральна вада, яка підштовхує ентузіастів Справи до божевілля? Певно, тільки люди з тоталітарними замашками прагнуть контролю над усім...

Обережно: фундаментальна помилка атрибуції! Якщо звинувачення на адресу адміністрації Вікіпедії правдиві, їх можна пояснити *пересічними* психологічними процесами, а шукати чогось *надзвичайного* ні до чого.

Дихотомія «свій-чужий» — цілком собі пересічний прояв людської психології. Смертельна спіраль щастя і спіраль ненависті теж входять до їх числа. Щоб утворити секту «своїх» довкола Благородної Справи, її прихильникам не треба якоїсь прихованої вади. Достатньо бути людиною. Усе інше розгортається природно — розпад іде за замовчуванням, як після вимкнення електрики їжа в холодильнику псується.

Як кожна система прагне до термодинамічної рівноваги, кожна комп'ютерна програма — до імпровізованого виправлення неполадок, так і кожна Справа *тяжіє* до сектантства. Система природно тяжіє до високоентропійного стану (атрактора — у людській психології), хай скільки благородна та Справа. Може здаватися, що Добра Справа має віддзеркалювати свою доброту

1. Див. статті “Secret Mailing List Rocks Wikipedia” (https://www.theregister.co.uk/2007/12/04/wikipedia_secret_mailing) та “Wikipedia Black Helicopters Circle Utah’s Traverse Mountain” (https://www.theregister.co.uk/2007/12/06/wikipedia_and_overstock).

на всіх причетних: її прибічники не гратимуть у статусні ігри, не піддаватимуться біасу «свій-чужий», емоційним спіралям та культам провідника-напівбога. Цікаво: хто вам сказав, що віра у правдиву ідею вимикає ефект ореолу? Навіть прибічникам благородної справи властиве людське. Звичайно, не те щоб не існувало розмаїття зловмисних ідей, від яких може постраждати багато людей, але я зараз не про це.

Кожна група з незвичною метою, хай то хорошою, поганою чи дурною, тяжітиме до сектантського атрактора, якщо не буде постійно йому опиратися. Прохолода у будинку підтримується роботою кондиціонера, але як тільки ви вимикаєте його — перестаєте боротися з ентропією, — усе вертається на круг свій.

Прикметно, що одна група, яка взяла собі гасло «Рациональність! Розум! Об'єктивна реальність!», ледь не стала сектою.² Назвати свою Велику ідею «раціональністю» — що повісити у будинку табличку «Холодно!» і чекати, що стане холодно. Без кондиціонера не обійтися — щоб не стати сектою, треба витрачати необхідну енергію за одиницю часу. Як від поклоніння силі тяжіння ви не навчитеся літати, так і від поклоніння раціональності лою у голові не додасться. Так само немає сенсу розмовляти з термодинамікою чи молитися теорії ймовірностей. Цими інструментами можна навчитися *користуватися*, але не можна зробити їх «своїми».

Сектантство — характеристика кількісна, а не якісна. Замість «Це секта чи ні?» правильніше поставити питання «Наскільки це секта і в чому проявляється її сектантство?». Навіть у Науці — архетипно Благородній Справі — можна вказати на fronti боротьби з ентропією сектантства, де лінія зіткнення рухається то вперед, то назад. От візьмімо наукові видання. З більшою ймовірністю приймуть статтю відомого автора, невідомого автора з відомого закладу чи невідомого автора з невідомого закладу? Скільки довіри покладається на авторитет і скільки — на

2. Див. “Guardians of the Truth” (https://lesswrong.com/lw/lz/guardians_of_the_truth) та “Guardians of Ayn Rand” (https://lesswrong.com/lw/m1/guardians_of_ayn_rand).

експеримент? У котрих з тих видань практикують сліпе рецензування? Наскільки воно ефективне?

Я наводжу цей приклад замість стандартних розмитих звинувачень типу «Науковці закриті до нових ідей», бо тут видно *лінію зіткнення*: саме тут людську психологію активно відсувають назад, а накопичену сектантську ентропію відкачують назовні. (Звісно, не без виділення відпрацьованого тепла.)

У цьому есеї я не ставлю за мету перелічити техніки активного відкачування сектантськості. Однак опишу декілька у наступних есеях, а дещо можна знайти і в попередніх. Лише хочу наголосити, що з цінності Справи не слідує, що ви можете *забути* про опір атрактору сектантства. З вашого розуміння лінії зіткнення не випливає, що ви знецінюєте Благородність Справи. Може здаватися, що якщо вам поставили питання «Це секта чи ні?», то ви зобов'язані відповісти «Ні» — інакше ви зрадите свою Справу. Але це все одно що бінарно ділити двигуни на «досконалі» та «неефективні» замість того, щоб вимірювати їхні втрати.

А якщо ви тішитесь думкою, що Інші Дурні Справи повернули у хибному напрямку через Внутрішню Нечистоту, смієтеся з «тих йолопів, які потрапили в секту», вірите, що ряди сект поповнюють покручі, які ними й керують, то у вас не вистачить сил боротися з ентропією — ви банально не зможете опиратися своїй людській природі.

Два коїни про секти

Був собі у майстра Угі послухник. І навчав він його раціональності. І от одного дня учень від свого друга дістав шпильку: «Ти цілими днями слухаєш свого майстра. Тільки те й робите, що розмовляєте про раціональне те і раціональне се. Я тобі кажу: ти потрапив у секту!».

Слова «Ти потрапив у секту!» неабияк спантеличили учня і того вечора рефреном відлунювали у нього в голові та ще й не давали заснути.

А вже наступного дня він таки наважився розповісти майстру про те, що сталося:

— Майстре, мені не дає спокою одна тривожна думка. Чи справді я потрапив у секту? Чи справді ваше вчення — догма?

— Знайшов на дорозі молоток. Що робитимеш з ним? Либонь, продаси. За скільки? Та хоч за скількись. Але ж цим молотком забиваєш ти цвяхи. То що ж сумніватися у цінності його? — відрік Угі.

— Ось якраз це мене і непокоїть — ваші таємничі відповіді у стилі дзену, — відказав учень.

— Річ моя яснішою стане, а доводи, якими розвію мару страху твого перед сектою, — бездоганно базованими, щойно вдягнеш дурнуватою капелюха.

Угі передав послухнику здоровезний ковбойський капелюх із наголовком на десять галонів.

— Емм, майстре... — протягнув учень.

— Як почуєш пояснення моє, — мовив Угі, — урозумієш, для чого це було. Чи, може, ти волієш знов пробуджуватися у поті страху перед сектою?

Учень нап'яв капелюх.

— Скільки щé ти папужитимеш мої слова, нехтуючи змістом? — завів Угі. — Безладні думи проростають з почуття прив'язаності до жаданих умовиводів. Скільки ж іще тривожитимешся ти про свій образ раціоналіста? У мене не шукай ти

запевнення. Було б тобі справді цікаво, якби не знав так воно чи інак, змикитив би, як розвіяти сумніви свої. Але ж тобі знадобилося розвіяти свій когнітивний дисонанс, тож носи тепер дурнуватою капелюха, чудо ти горохове. А був би я якимось садхуру, сотню срібняків зідрав би з тебе. Коли зосереджуєшся ти на реальному питанні, то й цінність — чи то пак безглуздість — твого розуміння не забариться, повір. А ти зараз поводишся як той фехтувальник, який оглядається, чи над ним, бува, не насміхаються...

— *Пу-пу-пу*, — видихнув учень.

— Довгу версію попросив ти, — відказав Угі.

Переходом учень стане наступником Угі, і його знатимуть як Ні но Таці. Після цього випадку він заборонятиме своїм учням посилатися на його слова: «Користайтесь техніками, не згадуючи їх».

* * *

Якось уже інший послушник Угі прийшов до вчителя з тривогою: «Майстре, я непокоюся, чи наше дідзьо раціональності, бува, раптом не... цейво... секта».

— Серйозне занепокоєння, — учень зачекав ще якусь хвилину, та Угі не зронив і слова.

Тож він і далі гнув своє:

— Я до того — даруйте, — але чому ми взагалі носимо ці мантиї з капюшонами? Ми ж схожі у них на тих фрікуватих франкмасонів.

— Ох, — видав Угі, — то тебе непокоїть наше вбрання.

— Ну, так, оцей весь одяг, — підтвердив учень і додав: — виглядає дуже безглуздо.

— Не хвилюйся: усе витлумачу тобі, — почув його майстер, — та спершу вдягни дурнуватою капелюха. — Угі дістав гостроверхий капелюшок чаклуна, до якого були пришиті зірочки та півмісяці.

Учень узяв капелюха і з розпачу випалив:


— І як ось це допоможе?

— Раз так непокоїшся ти, в якому уборі вчити тобі теорію ймовірностей, то не маєш дивуватися з того, що для розуміння доведеться тобі поносити особливого капелюха.

Коли учень закінчив навчання, він узяв собі ім'я Бúзо і говорив про раціональність тільки у своєму костюмі клоуна.

Експеримент Аша

Завдяки експериментам, які почали проводити у 50-х роках XX ст. і згодом неодноразово відтворили, Соломон Аш привернув увагу до явища, відомого як конформність, або піддатливість. У класичному варіанті піддослідному пропонують завдання, подібне до того, що показано на рисунку нижче. Котрий з відрізків — А, В чи С — має таку саму довжину, що й відрізок Х? Зупиніться трохи на подумати...



Піддослідний сидів поряд з іншими людьми, які так само розглядали рисунок. Але цими людьми були не інші піддослідні, як ви могли подумати, а співучасники експериментатора. У цьому й заковика. Підставні учасники одне за одним відповідали, що відрізок С тієї ж довжини, що й відрізок Х. Справжній піддослідний сидить передостаннім. Скільки піддослідних теж відповіли С, себто дали очевидно хибну відповідь, яка збігалася з одноставною відповіддю решти групи? Як гадаєте, який відсоток?

У ході експерименту Аша три чверті піддослідних хоча б раз дали відповідь, що узгоджувалася із груповою. Третина підлаштовувалася під відповідь інших у більш ніж половині випадків.

Після експерименту піддослідних опитали і дізналися, що більшість насправді не вірила у групові відповіді, хоча деякі все

ж казали, що дійсно вважали поширену відповідь правильною. Результати стурбували Аша:¹

«Як з'ясувалося, схильність до конформної поведінки в нашому суспільстві виявилася надзвичайно сильною... Чи є це приводом для хвилювань? Постали питання і про наші методи навчання та цінності, що керують нашою поведінкою».

Питання про те, наскільки *ірраціональною* була поведінка піддослідних в експерименті Аша, геть не тривіальне. Згідно з теоремою Роберта Ауманна про згоду, чесні баєсіанці не можуть лишатися кожен при своїй думці: якщо їхні оцінки ймовірності ґрунтуються на спільному знанні, вони зрештою мають збігатися. Більше ніж за два десятиліття після експериментів Аша було доведено теорему Ауманна, яка лише формалізує та підкріплює інтуїтивно зрозумілу думку: переконання інших людей часто слугують надійним свідченням.

Ось ви дивитеся на рисунок і *точно* знаєте, що інші учасники, маючи перед очима той самий рисунок, говорять правду про однакові довжини відрізків С та Х. Які взагалі шанси, що *саме* ви праві? Не думаю, що я чимось кращий у *наочно-образному* мисленні за середньостатистичну людину, яка на око може порівняти два відрізки. З погляду особистої раціональності, сподіваюся, що зміг би вловити момент власного спантеличення — і тоді надав би відповіді більшості ймовірність, більшу за 50%.

З погляду групової раціональності, як на мене, чесний раціоналіст має відреагувати якимось так: «Дивно, бо мені *здається*, що це відрізок В тієї ж довжини, що й відрізок Х. Але якщо ми дивимось на той самий рисунок і відповідаємо чесно, то я не можу сказати, що моє судження правильніше за твоє». Останнє речення важливе, хоч і слабше заявляє про незгоду, ніж «А, тепер

1. Solomon E. Asch, "Studies of Independence and Conformity: A Minority of One Against a Unanimous Majority," *Psychological Monographs* 70 (1956).

зрозуміло! Тут оптична ілюзія — я зрозумів, чому ти обрав С, але насправді правильна відповідь все ж таки В».

Тепер піддослідних, які підлаштувалися під групову відповідь, назвати ірраціональними вже *важче*. Правда ж? Адже чорт ховається у подробицях результатів експерименту. Род Бонд та Пітер Сміт провели метааналіз із понад сотнею відтворень . . . ²

. . . Згідно з його результатами, рівень конформності зростає, коли в експерименті беруть участь до трьох підставних учасників, але далі, до десяти-п'ятнадцяти «піддослідних», динаміка виходить на плато. Якщо люди піддаються впливу раціонально, тоді відповідь п'ятнадцяти інших піддослідних мусить бути переконливішим свідченням за відповідь трьох.

Якщо додати хоча б одного інакодумця, який дасть правильну чи неправильну, але відмінну від групової відповідь, вплив конформності різко знижується до 5-10% піддослідних. Якщо ви застосовуєте інтуїтивну версію теореми Ауманна — де незгода однієї людини з трьома вказує на правоту трьох — то в більшості випадків слід бути так само готовими прийняти, що двоє не погоджуватимуться з шістьма. ³ З іншого боку, якщо в групі є люди, які переживають через свій статус білої ворони, то не дивно, що коли на ваш бік стане ще одна людина або хтось, хто не погоджується з рештою, ви почуетесь менш знервованими.

Не дивно, що піддослідні у ситуації одного інакодумця не знали, що на їхній спротив конформності повпливав саме він. Як і 90% водіїв, які вважають, що водять краще за середньостатистичних, деякі з них дійсно мають рацію. Люди не усвідомлюють причин своєї піддатливості впливу чи незгоди, що ускладнює

2. Rod Bond and Peter B. Smith, "Culture and Conformity: A Meta-Analysis of Studies Using Asch's (1952b, 1956) Line Judgment Task," *Psychological Bulletin* 119 (1996): 111–137.

3. Порівняння не свідчить про правдивість когось напругу, та воно правдиве за інших рівних умов. — Прим. авт.

аргументацію на користь раціональності механізмів конформної поведінки.⁴

Коли ж єдиний інакодумець раптово *підлаштовується під групу*, рівень конформності піддослідних повертається до такого ж високого, як і за умови без нього. Тому виступати першим незгодним — цінна (і дорога!) соціальна послуга, але її треба витримувати до кінця.

Крім того, впродовж експериментів жінки-учасниці (як справжні, так і підставні) послідовно демонстрували значно вищий рівень конформності, ніж чоловіча частина. Близько половини жінок у групі погоджувалися з рештою у більш ніж половині випадків порівняно з третиною чоловіків. Отже, якщо ви стверджуєте, що середньостатистичний піддослідний поводить⁵ся раціонально, то жінки, очевидно, надто часто погоджуються, а чоловіки — забагато сперечаються, тож жодна група не є по-справжньому *раціональною*.

Маніпуляції з поділом «свої-чужі» (наприклад, піддослідний з вадами серед інших піддослідних з вадами) так само показують, що рівень конформності значно вищий серед членів своєї групи.

Конформність нижча у випадку очевидних діаграм — як та, що на початку есею — ніж у випадку діаграм із менш помітними помилками. Це спостереження важко пояснити, якщо (всі) піддослідні ухвалюють соціально раціональне рішення не виділятися.

І насамкінець Пол Крбулі звертає увагу на цікавий момент: коли відповіді піддослідних анонімні всередині групи, рівень конформності теж падає. І такий погляд суперечить Ауманновій інтерпретації.

4. Наприклад, якщо виходити з припущення, що люди з соціально-раціональних міркувань вирішують брехати, аби не вирізнятися, — виявляється, що (принаймні деякі) піддослідні в умові з одним інакодумцем свідомо не передбачають тієї «свідомої стратегії», яку б застосували, зіткнувшись з одноставною опозицією. — Прим. авт.

Проговорити занепокоєння

Експеримент Аша оприявнює тривожну перспективу: якщо зібрати в одній кімнаті достатню кількість людей, які називають чорне білим, виникає сприятливе середовище, в якому уже всі повторюють те саме. Але і не без надії: протест хоча б одного інакодумця може помітно зменшити схильність до конформності, навіть якщо його відповідь помилкова. *Прикро* лише те, що інакомислення не *закріпилося*: щойно єдиний інакодумець відмовлявся від своєї позиції, рівень конформності знову зростав.

Тому голос інакодумця може бути вкрай цінним для групи. Але, як відомо, такий голос має свою ціну. Швидкого результату чекати дарма, тому важливо не полишати свого протесту і водночас не забувати, що ви теж можете помилятися.

Недавно у мене був цікавий досвід обговорення проєкту з двома колегами, які до нашої зустрічі вже щось самостійно планували. Мені здалося, що вони були надто оптимістичними, тому я вніс декілька безпекових пропозицій. Невдовзі у кімнату зайшов четвертий — приїхав підкинути одного з тих двох, і почав вносити свої пропозиції. І тоді, коли я проговорював можливу проблему, четвертий відказував: «Не хвилюйтеся так — і з цим упораємося», — мене осяяло, звідки у групі береться надмірна впевненість.

Цілком природно, що в людини, яка працює наодинці, з'являються сумніви. Немає чого соромитися думки «Чи вмію я робити XYZ?». Та варто двом невпевненим людям об'єднатися — і підбадьорення вже звучить чемно, а сумніви видаються нетактовними. Разом вони стають більшими оптимістами, ніж поодиноці: сумніви одного притлумлюються підбадьорливими словами іншого, і жоден з них не усвідомлює, що всередині іншого живе той самий страх.

Експерименти Аша проливають світло на тривожну картину: учасники групи, піддаючись впевненості інших і приховуючи

власні сумніви, погоджуються з більшістю, не усвідомлюючи, що решта так само мовчки придушує схожі тривоги. Це явище відоме як «плюралістичне невігластво».

Ми з Робіном Хансоном давно ведемо суперечку про те, коли саме раціоналісти-початківці мають наважуватися відкрито не погоджуватися. Я схилиюся до поширеної позиції: у вас немає іншого вибору, окрім як сформувані власну думку. Робін натомість відстоює більш критичну позицію: *ви* — не просто інші люди — маєте зважати на потенційну мудрість інших. Попри розходження, ми обидвоє сходимося на тому, що з Ауманнкової теореми про згоду можна вивести, що спільне знання про наявну розбіжність у поглядах вказує на *чиюсь* ірраціональність.¹ Попри здивовані погляди аудиторії, ми залишилися вірними скромності: забудьте, що вам розказують про індивідуалізм, — *будьте* уважними до думок інших людей.

Власне, я до того, що сперечатися із групою для раціоналістів — не поле перейти. Не годиться просто взяти і відмахнутися: мовляв, у всіх все одно своя думка.

Як на мене, найважливіший урок з експериментів Аша — це вміння розрізнати «висловлення занепокоєння» і «незгоду». Порушити питання, якого ніхто не згадав, не означає кінцеву незгоду з усіма.

Баєсівськи бездоганний процес збіжності передбачає, що учасники обмінюються свідченнями, не очевидними для слухача. Висновок з теореми Ауманна про згоду справедливий лише за умови *спільного знання*: ви знаєте, я знаю, ви знаєте, що я знаю, а я знаю, що ви знаєте тощо. У своїй статті «Ми не можемо передбачити незгоду»² Робін Хансон описує, наскільки дивним виглядало б видовище двох досконалих раціоналістів, які погоджуються щодо ймовірності — це зовсім не те саме, що двоє крамарів, які торгуються на базарі.

1. Див. «Аргумент від скромності» (*The Modesty Argument*) https://lesswrong.com/lw/gr/the_modesty_argument.

2. Hanson, R. (2002). Disagreement is unpredictable. *Economics Letters*, 77(3), 365-369.

На жаль, у *соціальному* плані різниця між «висловлюванням занепокоєння» та «незгодою» не така вже велика. Група раціоналістів може домовитися про наявність різниці, але ж люди не навчені помічати її. Висловилися — вчинили соціально необоротний акт: стали тим цвяхом, що стирчить і порушує комфортну гармонію групи, і вашу інакшість уже неможливо не помітити. Той, кого зачепить ваше словесне занепокоєння їхньою компетентністю виконати завдання XYZ, певно, так само затаїть образу на вас, навіть якщо опісля скажете: «Та це нічого, я все одно погоджуюся з усіма».

Власне, експеримент Аша демонструє, що сила інакодумства здатна надихати інших. З нього випливає і те, що сила конформності цілком реальна. Якщо всі утримуватимуться від озвучення внутрішніх сумнівів, група зрештою потоне у безумстві. З іншого боку, історія рясніє уроками про ціну першості — чи навіть дружості — у тому, щоб сказати, що король вочевидь голий. Не закладено в людях й уміння розрізняти між «проговорюванням занепокоєння» та «незгодою зі спільним знанням» — артефакт, доступний суто для раціоналістів. У більш цинічних посібниках самодопомоги (як-от «Державець» (*Il Principe*) Нікколó Макіавеллі) автори взагалі радять *не* висловлювати свої побоювання, а повністю приховати незгідливість, а наприкінці з усім погодитися. Тому якщо ви все ж наважилися надати групі послугу озвучення очевидних проблем, не плекайте ілюзій, що вам подякують за таку щирість.

У цьому й полягають і ціна, і перевага інакодумства: навіть якщо ви не погоджуєтеся чи висловлюєте занепокоєння, рішення зрештою лишається за вами.

Самотній інакодумець

Як показує нам експеримент Аша, акт незгоди навіть одного інакодумця може суттєво знизити рівень конформності до поширених помилкових відповідей. Легко бути індивідуалістом, коли поряд є однодумець, що й підтверджується експериментом. Усі інші піддослідні у кімнаті, крім одного, називають чорне білим. Ви стаєте другим, хто називає чорне чорним. І так ви відчуваєте триумф: вас двоє — самотніх і зухвалих бунтарів проти цілого світу!¹

Але можливість *доєднатися* до повстання відкривається тільки після чиеїсь *першої* ініціативи. Почувши, як усі одне за одним називають чорне білим, *хтось* має набратися мужності назвати чорне чорним. А це, як показує експеримент, *набагато важче*.

Бути самотнім інакодумцем — не те саме, що ходити до школи у вбранні гота. Бути самотнім інакодумцем — це як ходити до школи у машкарі клоуна.

У цьому й різниця між *участю у повстанні* та *виходом зі зграї*.

Якби мене спитали, чого терпіти не можу, я б назвав удаваність. Та ви вже, мабуть, і так помітили. З усіх людських якостей самотнє інакодумство вдають, певно, найчастіше. Кому ж не кортить побути бунтарем?

Та не подумайте: я не принижую акт приєднання до повстання. Не без протестів, вартих участі. Витримати огуду групи однолітків — чи байдужість до такого кроку, що, певно, ще гірше — спроможні сміливі. Думаю, і так зрозуміло, що похід на концерт рок-групи не рахується протестом, чого не скажеш, наприклад, про вегетаріанство. Хоч я сам і не вегетаріанець,

1. Як продемонстрували подальші інтерв'ю, піддослідні при появі одного незгодного проявляли глибоку солідарність до інакодумця, хоч і, звісно, не усвідомлювали, що це присутність інакодумця була повпливала на їхнє дисидентство. — Прим. авт.

поважаю їх вибір: можу тільки здогадуватися, скільки треба витримки, щоб кожного разу вислуховувати: «Скоро зовсім зачахнеш без м'яса».²

Люди думають, що розуміють мотиви вашого вибору (навіть якщо нічого вони не розуміють). Вони можуть не погоджуватися. І навіть образитися, якщо ви говоритимете про вегетаріанство з гордістю. Може, їх просто легко образити? Але вони знають, як до вас ставитися.

Коли хтось ходить до школи у вбранні гота, вчителі та однокласники розуміють цю роль, оскільки у суспільстві знають, хто такі готи. Такий хід нібито «виходу із системи» доволі стандартний — впізнати його може кожен. Але, знаєте, роблячи цей крок, ви не виходите з неї. Нібито і виклик усталеному мисленню, нібито люди обурюються: «Не розумію, навіщо тобі це», але досі в рамках прийнятного, адже після цієї витівки у головах людей нічого не клацне. Як-то кажуть: «Хоча б один “революційний твір” спонукав вас змінити свої політичні переконання?».

Справжня сміливість починається з витримки відвертого *нерозуміння* з боку оточення, коли ви робите щось таке, що *не є* Стандартним повстанням №37, щось, для чого у них немає готового сценарію. Вони не ненавидять вас як бунтаря — вони просто думають, що ви трохи не зі світу цього і відвертаються. Така картина дає підстави для глибшого страху. У цьому різниця між поясненням вегетаріанства та кріоніки. Десь водяться ті кріоністи, та по сусідству з вами немає жодного. Й ось вам доводиться самотужки пояснювати, чому не вважаєте кріоніку чимось *дивним*. Навіть не забороненим, а таким, що виходить за рамки буденного кола думок. Що вони собі там надумали — повідморожувати голови? Це вони хочуть подолати смерть? Що воно за звір такий — та мозкова інформація? Га? Що? Ви там усі *блекоти пооб'їдалися?*

Заднім числом хочу дописати пояснення з погляду еволюційної психології. Ось ви з друзями зібрали юрбу і вирішили

2. Хоча в агломерації затоки Сан-Франциско про такі речі заведено питати. — Прим. авт.

від'єднатися від свого мисливсько-збиральницького племені. Якби ви рішилися на такий крок *самі*, приписали б собі смертний вирок (принаймні у репродуктивному плані). Хоч безпосередньо таких думок у голову не приходять, така вже природа еволюційної психології. Приєднатися до бунту, про який усе всім зрозуміло, страшно, але навіть і близько не так страшно, як зробити щось справді чуже, що у доісторичні часи могли б витлумачити не просто як відокремлення, а як вигнання з племені.

Як показує випадок з кріонікою, страх думати *інакше* сильніший навіть за страх смерті. У мисливсько-збиральницькому племені треба бути готовим до смерті як не сьогодні, то завтра, адже та чигає всюди: під час полювання на велетенських ссавців і пересування у світі, повному хижаків. Життя вимагало постійної сміливості. Однак сміливість кидати виклик узвичаєному способу мислення у племені чи обмірковувати думки, що справді здаються дивними, м'яко кажучи, прислужувалася не так добре тим, хто її виявляв. Хоч безпосередньо таких думок у голову не приходять, такий вже механізм роботи еволюційної психології. Ми, люди, влаштовані так, що значна більшість, скоріше, стрибне з парашута, ніж підпишеться під кріонікою.

І це я навіть не зачепив найвищий рівень сміливості. Хоча у світі більше одного кріоніста, саме Роберту Еттинджеру стало снаги заявити про неї *першим*.

Якщо ви хочете здійснити революцію у *науці*, маєте першим оскаржити думки тих, кого знаєте. Це не єдиний шлях до наукової величі — цей рідкісний навіть серед геніїв. Не варто і дурити себе думкою, що ви зможете здійснити науковий поступ, мавпуючи революційні процеси. Лише прагнучи правильних відповідей — і не важливо, революційні вони чи ні — в усіх аспектах вашої справи, ви можете досягти цілі. Але якщо із плином часу, ввібравши всю силу та мудрість накопиченого знання, і за сприяння чистої удачі, ви розумієте, що прагнення до чистої правильності веде вас до нової території, ... *тоді* можливість згайнувати свою сміливість пропонуватиме себе на кожному кроці.

Ось це і є та справжня сміливість самотнього інакодумця, яку кожен рок-гурт намагається змавпувати — аж зі шкіри пнеться.

Безумовно, не все, що потребує сміливості, гарна ідея. Не обійтися без сміливості, якщо ви вирішите зійти зі скелі. Але чи треба воно вам?

Хай там як, *страх* перед самотнім інакодумством — завада хорошим ідеям, хоч і не кожна ідея, що йде в розріз із думкою більшості, хороша сама по собі.³ Адже майже вся складність отримати нову істинну наукову думку схована у частині «істинна».

Дійсно, немає *потреби* відрізнятися лиш заради самої інакшості. Повірте: навіть якщо ви робитимете щось по-іншому тільки за вагомої на те причини, вам не забракне проблем на решту життя.

Можу навести кілька прикладів справжніх бунтарів. Одні з них — Церква НедоМудреця, засновники якої дійсно ставлять собі за мету не просто образити посполитих, а *спантеличити* їх. Крім них, трапляються острівці справжньої толерантності, як-от фестивалі наукової фантастики. Не без людей, які не бояться виходити зі зграї. Таких менше, ніж тих, хто марить себе бунтарями, але все ж такі є. І попри те наукова революція — подія надзвичайно рідкісна. Ось вам і пожива для роздумів

Якщо говорити за *себе*, так — *я вважаю себе* ревним бунтарем. Та ви й самі бачите. Я б *точно* прийшов до школи у машкарі клоуна. Тільки-от я сперечався із книжками, а не ровесниками.

Якщо ви про себе думаєте, що *теж* розмалювалися б у якийсь грим, не поспішайте пишатися своєю сміливістю. Може, вам треба докласти зусиль у *протилежному напрямку*? Не проявляти незгоди зі спалахом сірника. Мені б *теж* не завадило скоригувати свою звичку ставати руба. В інших є причини думати так, як вони думають, і ігнорувати ті причини настільки ж

3. Див. Robin Hanson, "Against Free Thinkers," *Overcoming Bias* (blog), 2007, https://www.overcoming-bias.com/2007/06/against_free_th.html.

кепсько, як і боятися їм протидіяти. Тому сумніваюся, чи варто обирати вільнодумство. Як бачите, це не *чеснота*, а черговий біас.

Сектантське сектоборство

Певно, у наш час вступ до секти — одна з найгірших подій, що можуть з вами трапитися. За найбільш оптимістичним сценарієм ви опинитеся у громаді щирих фріків. Що не кажіть про їхні переконання, зате гречності їм не позичати. У підсумку ви згайнуєте достобіса часу і грошей, лишившись ні з чим. Чим не провальний проєкт якоїсь компанії у Кремнієвій долині? Так, доволі болісний досвід. Вибачте за мурахи по шкірі.

Секта — щось кількакратно гірше. Чого тільки варте «бомбардування любов'ю» — техніка вербування людей у кризі. Недосипання. Втома від важкої праці. Комуни, відірвані від друзів та сім'ї завербованого. Щоденні збори, на яких прочищають мізки. Нерідко у завербованого забирають *усі* гроші — і заощадження за життя, і тижневу зарплату, — змушуючи його залежати від секти навіть у доступі до їжі та одягу. За непослух карають голодом. Інтенсивно промивають мізки і завдають суттєвих пошкоджень.

Тим-то, певно, мені варто з більшим розумінням ставитися до людей, які, беручись за щось дивакувате, страшенно нервують, *що можуть вступити до секти*. Це не мало б діяти на нерви мені. Але чогось таки діє.

Причина №1. Секту не можна так просто взяти і відділити від «несекти», як собаку від кота. У переліку ознак секти ви знайдете ознаки політичних партій та корпорацій: «у групі вас переконують з недовірою ставитися до критики ззовні, аргументуючи прихованими мотивами критиків», «ієрархічна авторитарна структура». Я вже писав про збої у груповому мисленні, серед яких поляризація всередині групи, смертельна спіраль щастя, некритичність, випарне охолодження, які, видається, підживлюють одне одного. Коли ці помилки переплітаються і сходяться в одній, вони утворюють Надпомилку, гіршу за будь-яку її частину. Але Надпомилка не *сутність* секти, а її *атрактор*.

Собаки народжуються із собачою ДНК, а коти — з котячою. Нічого посередині між ними не існує. (Навіть якщо вдатися до маніпуляцій із генами, не так просто створити істоту 50/50 із собачими і котячими генами.) Немає такого набору взаємопідсилювальних собачих якостей, половину з яких можна передати котів і зробити з нього котопса.

Мислячи категоріями, людський розум, вочевидь, надає перевагу визначальним характеристикам, а не атракторам. Кажете: «Це секта» або «Це не секта», і на цьому питання класифікації вичерпано. Бачите Сократа: у нього десять пальців, він носить одяг і вільно спілкується давньогрецькою — отже, «Сократ — людина», з чого встановлюєте, що «Сократ може померти від отрути болиголов», причому для цього вам не потрібен спеціальний тест на його смертність. Отак ви раз і назавжди визначилися з людською природою Сократа.

Якщо вам трапляється група, де учасники проявляють поляризацію «свій-чужий», ефект позитивного ореолу довкола їх Улюбленої Штуковини — об'єктивізму, вегетаріанства чи нейронних мереж, — *на основі зібраних натепер свідчень* ви не можете висувати, наскільки некритично група ставиться до своїх ідеалів. Так само не можете висувати істинність, хибність чи корисність (і міру корисності, яку їй приписують) ідеї, яка об'єднує тих людей. *З усієї доступної вам інформації* ви не можете висувати їхню гречність і те, чи намагатимуться заманити вас у віддалене поселення, де моритимуть сном і голодом. Тому казати, що у такій-то організації присутні чи відсутні всі ознаки секти, буде некоректно.

Якщо вам колись доводилося читати суперечки в інтернетах про те, чи «Х — секта» або «Х не секта», певно, ви бачили, як одна сторона наводить перелік маркерів секти, знаходить бодай один в організації Х і пише: «Ось тому Х — секта!». А сторона захисту знаходить одну ознаку, яка не входить у цей перелік, і відписує: «Та ніяка Х не секта!».

Орудуючи такого роду есенціалізмом, ви не зможете сформувати точне уявлення про мислення групи у динаміці.

Натомість варто визначитися із маркерами і помічати їх самотійно.

Не забувайте, що обернена дурість не породжує тямучість. Якщо вас цікавить саме чільна *ідея*, а не способи її втілення групою, то мушу розчарувати, що у розумних ідей можуть бути дурні послідовники. Багато нью-ейджерів торочать про «квантову фізику», що жодним чином не кидає тінь на саму квантову фізику.¹ І, як годиться, під руку із дихотомічним есенціалізмом ходить уявлення, що якщо група пройшла тест на сектантство, усі її переконання мусять бути хибними, бо ж хибні переконання — ознака секти. З тієї ж серії: хутро — котяча риса. А якщо вас цікавить ідея, то й дивіться на неї, а не на людей. Сектантство — більше ознака груп, а не гіпотез.

Друга помилка дає про себе знати, коли люди знервовано питають: «Це ж не секта, правда?», ніби хочуть *запевнень в раціональності*. Про концепцію раціоналіста, який не переймається своїм образом, варто написати окремий есей.² Навіть якщо не сильно вдаватися у подробиці, *нервозний пошук запевнень*, очевидно, не найкращий спосіб оцінювати питання раціональності. У такому умонастрої немає місця допитливості, не знаходяться способи розвіяти сумніви. Натомість ви відшукаєте якусь сторінку в інтернеті, де пишуть, що недосипанням у сектах контролюють людей. І якщо у вашій улюбленій групі таке не практикують — ви доходите висновку, що хвилюватися нічого: «Фух, не секта!». Без хутра — не кіт. Таких запевнень вам треба?

Нагадаю, що кожна справа тяжіє до сектантства. У дихотомії «свій-чужий» немає нічого чужого для людської природи, нею не хворіють виключно ті прокляті покручі. Раціональність просто ж не входить до людської природи. Адже для підтримки своєї раціональності слід постійно докладати зусиль — інакше скоотитеся у цілком очікувану ентропію. Прийдете до висновку «Це

1. І відповідно у дурних ідей і дурні послідовники. — Прим. авт.

2. А хоча прочитайте краще два коани про секти, «Чому істина» (у книзі «Мапа і територія») та «Дванадцять чеснот раціоналіста» (<https://www.lesswrong.com/rationality/the-twelve-virtues-of-rationality>). — Прим. авт.

не секта» і видихнете з полегшенням — перестанете докладати зусиль і ніяк не перешкоджатимете *руху* до сектантства. А потім виміркуєте: якщо сектантська сутність відсутня, то можна і не перейматися нейтралізацією ентропії атрактора секти.

За своєю нервозністю не потрапити до секти ви не захочете помічати всі ті натяки на її ознаки. *Немає* такої групи з позитивною метою, щоби була застрахована від ефекту ореолу, з чого і постає необхідність боротися проти ентропії у вигляді смертельної спіралі щастя. До цих груп входять політичні партії — там думають, що ліберальні чи консервативні цінності вилікують рак чи щось інше — і проекти Кремнієвої долини — що успішні, що провальні. Користувачі комп'ютерів на базі Mac та Linux. Від того, що всі піддаються ефекту ореолу, не означає, що так і має бути. Якщо всі почнуть стрибати з даху, вам не обов'язково. З помилками у міркуваннях треба боротися, а не миритися. Якщо ж ви надто переймаєтеся: «Ви точно впевнені, що це не секта?», тоді вам не сподобаються ознаки сектантства, коли ви почнете їх помічати, тому що ви вже вирішили, що не в секті і, як наслідок, — «*Це не се-е-екта-а-а!!!*». Будете сліпі до ситуації на полі бою: *звична* схильність до сектантства наближається усе ближче й ближче або ви нейтралізуєте її сили.

По-третє, підозрюю, що *нервозність*, яка відчувається у питанні «Це ж не секта?», має причини, не пов'язані із сектантством.

Групи, що звеличують Неймовірний Об'єкт Поклоніння, змушують прихожан віддавати всі свої позитки й працювати у добровільному рабстві, мешкаючи далеко від цивілізації. Чому ж вони називають себе «релігіями», а не «сектами», якщо вони існують кілька сотень років?

Чому люди, які переймаються, чи кріоніка не секта, не ставлять такого ж запитання до політичних ігор Республіканської та Демократичної партій? Чи ви думаєте, що політичні дискусії, світові релігії, спортивні фан-клуби убезпечені від дихотомії «свій-чужий» і смертельних спіралей щастя? Якби ця *знервованість* ґрунтувалася на страхові перед помилками у

раціональному мисленні членів групи, люди б так само насторожено ставили питання до своїх партій на кшталт «А хіба тут не розділяють на “своїх” та “чужих”?».

З поважних причин за лібертаріанство можна хвилюватися менше, ніж секту довкола НЛО: лібертаріанці банально не доводять людей до недосипання. Але ж і кріоністи не по цих справах. Чому ж вас тоді хвилює замороження голови, якщо по смерті вам та голова і так ні до чого?

Підозрюю: причина *знервованості* не у страху перед хибними переконаннями чи фізичним насиллям. Це страх перед самотнім інакодумством. Відчуття знервованості, яке піддослідні переживають в експерименті Аша, коли інші (підставні учасники) як один стверджують, що відрізок С однакової довжини з відрізком Х, хоча піддослідний на власні очі бачить, що з відрізком Х збігається відрізок В. Це — страх вийти зі зграї.

Ось чому групи, чії переконання виникли досить давно, сприймаються як «нормальні», не викликають такої ж знервованості, як «секти», хоча у деяких світових релігіях також можуть забрати усі ваші пожитки і відправити до монастиря. Ось чому політичні партії, які значною мірою відповідальні за помилки у мисленні, не викликають такої тривоги, як «секти». Адже словом «секта» не заведено позначати помилки у мисленні — зазвичай його використовують для чогось, що *видається дивним*.

Не кожна зміна породжує покращення, та жодне покращення неможливе без змін. Якщо вам забаглося зробити свою справу краще, вам доведеться діяти інакше. Загальноприйнята мудрість справді містить чимало, власне, мудрості; тому від дивакуватих ідей є сенс вимагати додаткових свідчень. Але, знаєте, *знервованість* далека від осмисленого раціонального міркування. Ви боїтеся повірити у щось таке, за що ваші друзі покрутять пальцем у скроні. Звідси й постає питання «Це ж не *секта*?» з тоном, який не виникне під час політичних дебатів чи вертепу на Різдво.

Ось *тут* починається моє роздратування.

Так ніби щойно ви відступилися від віри своїх прашурів, звідкілясь з неба спускаються гобліни-сектанти і нав'язують вам Сектантську сутність. А вже наступного дня ви носите рясу і молитеся перед їдою. Так ніби «хімерні» переконання, а не недо-сипання чи побиття — *пряма причина* проблем. Завдана секта-ми шкода — як-от масове самогубство членів «Небесної брами» — лише свідчить, що несповні розуму не без химерних переконань. Тому у найпершу ознаку «членів секти» напрошують-ся маргінали зі своєрідними поглядами.

Безумовно, соціально аномальні погляди наражають групу на ризик умонастрою «свій-чужий», випарного охолодження та виникнення інших проблем. Однак аномальність — фактор ризику, а не сама хвороба. Те саме і з метою, яку ви прагнете втілити. Неважливо, чи правдиве переконання саме по собі, достойна мета не застрахована від смертельної спіралі щастя. Але від того амбітні цілі ніяк не назвати хворобою — вони лиш несуть певні ризики. І це не означає, що від цілей потрібно відмовитися.³

Четверта проблема: *секти* експлуатують страх перед самотнім інакодумством. Страх, що ваші друзі дивитимуться на вас як на придурка, — *саме той ефект, яким секти користуються для вербування та утримання людей*, оточуючи новонавернених суцільною одностайністю серед послідовників.

Не сумніваюся, що страх перед химерними ідеями — поштовх до конформності — врятував багатьох потенційних жертв сект НЛО від загрози. Доки ви поза грою, на вас це не діє. Але щойно ви *занурюєтесь*, вони вас *не відпустять*. І безвідносно до того, чи ви з хорошими чи поганими людьми, конформність не дасть вам вийти з групи.

Але ж хочеться, щоб існував якийсь спосіб знати *напевне*, чи ви не в «секті». Щоб існувала якась нищівна відповідь усім тим телепням, які беруть вас на кпини. Щоб можна було раз і

3. І навіть тоді я не бачу адекватної причини, коли загрозливих інакодумців треба морити сном чи бити. Крапка. Коли група — називаєте ви її «сектою» чи «несектою» — іде на такі заходи, ви вже дали відповідь на прагматичне питання, чи варто приєднуватися до неї. — Прим. авт.

назавжди знати, що ви робите усе правильно, — без цих постійних сумнівів. Здається, це називається потребою у визначеності. І, хто б сумнівався, секти експлуатують і її.

Звідси й назва «сектантське сектоборство».

Ви не заробите собі плюсків у карму, якщо просто триматиметеся своїх сумнівів, адже сумнів існує для того, щоб зрештою розвіятися, підтвердившись або спростувавшись. Сумнів, який просто свердлить вам голову, не виконує своєї задачі. Іноді розвіяння сумніву займає немало часу. Купа нерозв'язаних сумнівів — це те, з чим доводиться жити раціоналістам. Тому сумніви не мають лякати. У протилежному випадку вам доведеться обирати між двох вогнів: життя у параної або життя у невігластві.

Якщо ви дійсно не можете збагнути, чи якась група за крок до «секти», тоді мусите приймати рішення в умовах невизначеності. Ось така вона — теорія прийняття рішень.

Проблема п'ята — брак стратегічного мислення.

Деякі мої знайомі, крім вибуху інтелекту та штучного суперінтелекту, насторожено ставляться *і до* політичних партій та світових релігій. Під «насторожено» я не маю на увазі знервовано чи ворожо. Хоча вони бачать, що ідеї довкола сингулярності ще не довели нікого до недосипання, їх хвилює, що довкола вибуху інтелекту можуть *виникнути* сектантські настрої, зокрема через фактор ризику перетворення потужного ІІІ в Агента Надщастя (тобто агента, який погоджується з кожним приемним словом, сказаним на його адресу). Якщо група не має явних ознак секти, це не означає, що вона не може нею стати. Пам'ятаєте? Сектантство — це атрактор, а не сутність.

Чи не дратує мене *це* настороження? Біс, ні! Знали б ви, скільки разів мене тривожив такий сценарій. Я намагаюся заздалегідь розставити свої камінці у го, блокуючи розвиток подій у цьому напрямку.⁴

4. Так і з'явилася низка есеїв про збої в мисленні у вигляді сектантства. — Прим. авт.

Люди, які говорять про «раціональність», несуть додатковий ризик. Роздавати людям поради, як належить думати, — справа небезпечна сама по собі. Але я маю на увазі саме *фактор ризику*, а не саму *хворобу*.

Обидві мої улюблені Справи у зоні ризику. Та чомусь мене набагато частіше питають: «Ви певні, що це не секта?», — коли я розповідаю про потужний ШІ, ніж про теорію ймовірностей та когнітивістику. Не впевнений, чи один фактор ризику вищий за інший, але точно знаю, який з них *виглядає дивнішим...*

Проблема №6...

На моє роздратування саме питання «Це ж не секта?» обертається програвом у будь-якому разі. Справжній Лихий Гуру одразу б скористався вашою знервованістю і виголосив правдоподібний, вигадливий аргумент «чому це не секта», який ви з радістю прийняли б. Іноді у мене виникає враження, що саме цього люди й *хочуть*. Коли я пишу про сектантство і як його уникати, мене не полишає відчуття, що я піддаюся цьому хибному бажанню, що я зрештою даю людям *запевнення*. Навіть коли пишу про необхідність боротьби з ентропією.

Ніби я отой перший інакодумець з експерименту Аша, який дає сигнал іншим: «Так, відрізок X такої ж довжини, що й відрізок B, вам не здалося, ви не одні так думаете». Вони взагалі не повинні питати про це! Чи, ба навіть гірше, ніби я підношу вигадливий аргумент «чому це не секта». Це взагалі *хибне питання*.

Подивіться, як мислить група, і запитайте себе, чи хочете ви бути її частиною, коли позбудетеся страху виглядати дивакуватим. Відповідальність за подолання сектантського способу мислення лежить на вас, незалежно від того, в яку групу ви потрапили.

Секти живляться групомисленням, нервозністю та бажанням до запевнення. Самим лиш бажанням нервозності не позбутися — ще гірше хибною самовпевненістю. Потреба в запевненнях — навіть щодо образу раціоналіста — завжди буде вразливим місцем. Адже вправний фехтувальник зосереджується на мішені, а не оглядається, чи над ним, бува, не насміхаються.

Зрештою, коли ви знаєте, що і з якою метою робите, то й розуміння, наскільки далекі від тієї мети і чи група наближає вас до неї чи віддаляє, не забариться.⁵

5. PS: Якщо хтось звертається до вас із питанням «А ти *певен*, що це не секта?», не витрачайте сил на донесення усіх згаданих понять до вашого співрозмовника за раз. Прошу: не недооцінюйте силу умовивідних дистанцій. Ваш співрозмовник завжди може відповісти: «Ага, то ти *визнаєш*, що потрапив у секту!» або «То ти кажеш, що мені не слід перейматися приєднанням до секти?», або «Тож... страх перед сектами має сектантську природу? Виглядає підозріло по-сектантськи». І нарешті останній фактор дратівливості — сьомий, якщо ви досі рахуєте, — усе це збіса довго пояснювати. — Прим. авт.

Відпускання

Цілодумство

Чітко пам'ятаю, з чого почався мій Шлях раціоналіста.

Ні, не з «Та ви жартуєте, містере Фейнман» чи якої-небудь іншої праці про раціональність. Вони не зробили особливої погоди. Шлях починається з того моменту, коли ви помічаєте серйозну хибу у власному способі мислення і загоряєтеся покликом до вдосконалення, до формування *нових* навичок — не тих помічних, але недостатніх, які ви вичитали у книжках.

В останні моменти до переродження, тоді мені було п'ятнадцять, я із приємною самовпевненістю згадував ті часи, коли був значно молодшим. Спогади з того далекого минулого досить розмиті: я зберіг образ себе того часу, хоч тодішній вік уже не пригадаю. Можливо, шість чи сім. Пам'ятаю: був я у літньому таборі.

І от вожатий-підліток сказав нам, значно молодшим хлопцям, вишикуватися в шеренгу. Він пропонував таку гру: замикальний пролазить між ногами строю, поки решта б'є його, і наступний замикальний повторює процедуру. (Можливо, саме тоді я попрощався зі своєю дитячою простодушністю. Але мене досі не полишає одна думка...) Я відмовився грати — мене відправили у куток.

Цей спогад — про те, як я відмовився бити інших і дозволяти бити себе — став для мене знаковим: ще в дитинстві я не захотів тішитися чужим болем. Я не битиму інших ціною дозволу бити мене, не платитиму болем за можливість заподіяти біль. Тоді я відмовився брати участь у грі з негативною сумою.

А перегодом, десь так само років у п'ятнадцять, на мене звалилося усвідомлення, що той спогад я додумав. Я відмовився *не* через принципову позицію проти ігор з негативною сумою. Хоч я й дізнався про дилему в'язня доволі рано, але точно не в сім. Я відмовився, бо не хотів, щоб мене били, а куток здавався прийнятною платою.

Ба більше, я збагнув, що *завжди* це розумів — справжній спогад увесь час ховався десь у закутку свідомості, а мій внутрішній зір, на мить помітивши його, знову відвертався.

Піймавши себе на узагальненому із суб'єктивного досвіду *відчутті* «То ось як воно — запхати небажану правду у закуток свідомості! Тепер я ловитиму себе щоразу, коли захочу щось приховати від себе, і вичищу *кожен* закуток», ось так я став на цей Шлях.

Цю вправу я назвав *цілодумством* — за аналогією до орвеллівського дводумства. Дводумство передбачає, що ви спочатку забуваєте, а потім забуваєте саме забування. У випадку цілодумства ви помічаєте забуте і згадуєте. За раз ви тримаєте у голові одну несуперечливу думку.

Так я витворив свою першу раніше не бачену у книжках навичку раціоналіста. Не певен, чи ця думка радикально нова для академічного середовища, та мені й не йдеться про новизну.

Просто у свої п'ятнадцять мені подобалося вигадувати назви для різних штук.

Скільки живу, стільки відкриваю для себе страхітливі глибини підтверджувального упередження. Навряд чи цей процес триватиме вічно (хоча може відчуватися як вічність), адже мозок хоч і складний, але скінченно складний. Ви щоразу дізнаєтеся про нові й нові механізми, за допомогою яких розум уміло ховає істину від вашого внутрішнього зору.

Утім, тодішньому мені вдалося почистити кілька таких закутків першою саморобною мітлою.

Йойкати — важливо

Щойно дочитав книгу про історію падіння корпорації «Енрон». Називається «Найрозумніші хлопці в кімнаті», чим виграє у моєї номінації «Найбезглуздіша назва для книги».

До повільного занепаду і раптового краху корпорації призвело, зокрема, небажання керівників визнавати *критичну* помилку. Не дивно. Коли проблема №247 переросла у катастрофу таких масштабів, що потрібно було змінювати стратегію корпорації, вони натомість відказували: «Шкода, що ця ідея не вистрілила. Як нам тоді приховати проблему у нашій звітності?». Чому не доходило до: «Тепер, озираючись у минуле, ми розуміємо, помилка була з самого початку» або «Увесь цей час ми дурили себе». Не існувало такого переломного моменту, який означав би, що от тепер варто звернутися до смирення й усвідомити *засадничість* проблеми. Після банкрутства компанії «Енрон» її колишній головний операційний і виконавчий директор Джеффри Скіллін відмовився від поради особистого адвоката скористатися правом, яке надає йому П'ята поправка. Перед Конгресом він свідчив, що «Енрон» була *чудовою* компанією.

Не кожна зміна породжує покращення, та жодне покращення неможливе без змін. Визнаючи лише невеличкі локальні помилки, ми впроваджуємо лише маленькі зміни. Мотивація ж до критичної зміни породжується усвідомленням *критичної* помилки.

З дитинства мене оточували наука і наукова фантастика. З книжок Роберта Хайнлайна і Річарда Фейнмана я засвоїв тропи традиційної раціональності: теорії не мають боятися спростувань; треба бути готовим приносити у жертву свої погляди, якщо свідчення вказують в іншому напрямку; у дискусіях слід поводитися чемно; намагайтесь не самообманюватись — та подібні розмиті вирази.

Усі ці настанови орієнтовані на виховання сперечальників, які *врешті-решт* схилять голову перед протилежними

свідченнями. Іншими словами, традиційний раціоналіст змінить свою думку тільки тоді, коли назбирається гора свідчень. Зрештою, цим наука і відрізняється від релігії. Але з уваги упускається *швидкість*, а саме необхідність *якомога раніше* припинити спротив свідченням та *ефективно* їх використовувати, щоб для відмови від будь-якого переконання *вистачало мінімуму* протилежних свідчень.

Я ріс на тропях традиційної раціональності і вважав себе повноцінним раціоналістом. А от на шлях баєсіанства (Лаплас/Джейнз/Тверські/Канеман) я ступив внаслідок... насправді це довга історія. По суті, я зробив цей вибір, бо усвідомив, що самих лише тропів традиційної раціональності недостатньо, аби уникати серйозних помилок.

Визнавши свої помилки, я дивлюся на той шлях, який привів мене до жахливого усвідомлення. І я побачив послідовність маленьких поступок, невеличких потурань, неохоче віддаючи своє переконання міліметр за міліметром, і з кожним разом все менше відстрілював, що я робив щось не те; а якщо й визнавав поразку, то лише частково. Я міг би рухатися набагато швидше, якби я просто скрикнув: «ЙОООЙ!».

І я подумав: *треба підняти рівень своєї гри*.

Адже у визнанні *серйозної* помилки є своя *потужна перевага*. Перевага болюча. Але життєзмінна.

Тому потрібно ще визначитися зі своїм переломним моментом: саме час звернутися до смиренності і визнати *засадничість* проблеми, а не кришити помилки на молекули.

І не заводити драму, не чванитися з самого акту визнання помилки. Звісно, зробити все як годиться з першого разу похвально, але помилки варто помічати відразу. Навіть з погляду гедонізму краще пережити одну велику втрату, ніж багато дрібних, розтягнутих у часі. Ви ж не хочете розтягнути цю боротьбу на роки? Ви ж не бажаєте долі «Енрону»?

Я бачив, як інші йдуть на дрібні поступки, неохоче відступають від своїх переконань міліметр за міліметром, уникаючи визнання глибшої проблеми. При цьому локальні помилки вони

визнають без труднощів і не роблять з них жодних висновків. Що можна було б добровільно виправити одним махом, вони перетворюють на крихітні латки, які розкроюють одну за одною. А якщо й визнають одну помилку, і словом не обмовляється про те, якими дурнями вони були. З усіх сил вони не дозволяють собі відчутти збентеження: «У принципі я був правий» або «Ідея б спрацювала», або «Я все ще хочу триматися справжньої сутності [щось таке, до чого я прикипів]». Захищаючи свою гордість, вони відкривають собі двері до тієї ж помилки, від якої знову потребуватимуть захисту.

Що не кажіть, а гірка правда не така гірка, якщо проковтнути її за раз.

Спокуса пришелепкуватістю

Замолоду — у свої тринадцять-чотирнадцять — мені якось примарилося, що я спростував діагональний метод Канта — відоме доведення, яке ілюструє, що множина дійсних чисел перевищує множину раціональних. Ох і розжився я тоді думкою!

Міркував я тоді так: оскільки кожне ціле число можна подати як суму степенів двійки, я можу встановити відповідність між цілими числами та підмножинами натуральних, закодованих у вигляді бітів. Наприклад, число 13 — 1101 — відповідає запису {0, 2, 3}. Пройшов тиждень, перш ніж до мене дійшло, що я, певно, маю *застосувати* діагональний метод Канта до своєї здогадки. Звісно ж, я знайшов контрприклад — двійкове число (... 1111), яке не відповідало жодному скінченному цілому числу.

Так, натрапивши на контрприклад, я зрозумів, що моя спроба спростування виявилася хибною. Плакали мої мрії про математичну славу.

Спочатку я трохи засмутився.

А потім мене навідала така думка: «Я все одно здолаю те доведення! *Одного дня* я спростую діагональний метод Канта, хай скільки разів помилюся!». Як же мене тоді обурювала стійкість того доведення до моїх підкопувань. (Тобто — так, про славу можна було забути.) Я почав копати з іншого боку.

А потім до мене дійшло ось що. Я припустився помилки, і тепер, коли вже помітив її, сумніватися у міцності діагонального методу було настільки ж безглуздо, як і в інших основних математичних теоремах.

Я чітко усвідомив, що мав нагоду стати математичним фріком і згайнувати решту життя, виводячи зеленим по білому слова злови професорам математики. (Якось читав книгу про таких.)

Я не бажав собі такого майбутнього, тож посміявся з себе і більше не повертався до спроб спростування.

Чи здогадався я одразу, чи то прийшло мені згодом — сказати важко... Якесь занадто несправедливе випробування як для тринадцятирічного. Або раціональний, або пропав — причому у такому юному віці.

Коли ви юні й певні свого розуму, часом зринає ідея, яка здається справжнім відкриттям. Мені пощастило, що в мене вистачило клепки самому помітити помилку, що не знадобився інший математик, щоб вказати на неї мені і, можливо, дати мені зовнішнє джерело для звинувачень. Пощастило, що мій мозок легко перетравив те спростування. Хтозна — може, я б колись і перехворів. Дорослим я і не таке переносив. Але якби я ще тоді звернув не туди, чи зміг би згодом розвинути навичку визнавати помилки?

Цікаво, скільки з тих, хто тепер з таким запалом складає гнівні листи, у тринадцять теж мали свій промах. Цікаво, скільки з них були перспективними умами.

Я припустився помилки. Ось і все. Я не був *справді правий*, *десь глибоко всередині*. Я не здобув жодної моральної перемоги. Я не проявив ані амбіцій, ані скептицизму, ані бодай якоїсь іншої гідної риси. Та помилка була цілковито нерозумною. Я не був правий — ні наполовину, ні на дрібку, ні на щонайменший крихітний відсоток. Я плекав думку, яка б не з'явилася у моїй голові, якби я хоч скількись був мудрішим. Та й по тому.

Якби ж я не спромігся визнати помилку перед собою, а натомість почепив її медалью на груди, якби й далі вперто відстоював бодай *крихту* своєї правоти, я б так і не зміг змиритися. Я б і далі докопувався до діагонального методу. Може, рано чи пізно я б таки викопав щось.

Поки не визнаєте помилки, рухатись уперед важко — самосприйняття лишається прив'язаним до старої хиби.

Бажання вчепитися за думку, яка б навряд чи навідала вас, якби ви були хоч трохи мудріші, — це нагода приміряти роль пришепелкуватого. Без зеленого чорнила та просякнутих

обуренням листів. Навіть якщо ніхто з вами не сперечається і ви тримаєте свою ідею при собі, гадаю, це не рятує вас від прищелепкватості. Чи *вхопилися* ви у свою думку мертвою хваткою — ось що визначає фрікуватість.

Це неправда. Неправда десь глибоко всередині. Не «напів-правда» і навіть не «трішечки правда». Цю думку не варто було б навіть обмірковувати. Це — приклад лиха без добра. Люди припускаються помилок, і не варто у кожній з них дошукуватися блага. Люди помиляються. Ось і все. Кажіть «йой» і не зациклюйтеся.

Саме час здаватися

Брешучи банкам в іпотечних заявах, двадцятичотирирічний вебпрограміст Кейсі Серін із нульовим досвідом у нерухомості назбирав 2,2 мільйона доларів боргу. Він хотів одним махом викупити вісім будинків у різних штатах. Готівку з іпотеки (він узяв суму, більшу за вартість будинків) витратив на проживання і семінари з нерухомості. Видно, хлопець думав, що ринок зростатиме.

А це я ще не дійшов до сумної частини. Він *досі не відцурався від цього задуму*. Кейсі Серін не приймає поразки. Він не визнає свого банкрутства, не шукає роботи — все ще думає, що досягне успіху у нерухомості. Він і досі ходить на ті платні семінари. Навіть намагався взяти іпотеку на дев'ятий будинок. Бачте, він не *облизня піймав*, а лише *вчиться на власному досвіді*.

Ось що стається, коли ви не втрачаєте надії.

Цей приклад може здаватися звичайнісіньким проявом дурості. А як щодо двох економістів-нобелеатів . . .

. . . а саме — Роберта Мертон та Майрона Шбулза з компанії «Довгострокове управління капіталом» (*Long-Term Capital Management*).

У перші три роки компанія отримувала колосальні прибутки. А в 1998 році фактори неефективності, на яких вона заробляла, почали вичерпувати себе — усі зрозуміли, у чому фортель, тож він перестав давати ефект.

Але у «Довгостроковому управлінні капіталом» не захотіли скласти руки. Підсівши на 40% річної дохідності, вони нарощували запозичення, щоб компенсувати звуження маржі. Коли компанія опинилася у кризовій ситуації, її власний капітал становив 4,72 млрд доларів, тоді як загальний обсяг залученого фінансування сягав 124,5 млрд, а номінальна вартість деривативних позицій — 1,25 трлн доларів.

У кожній професії свої способи діяти розумно — різні навички і правила. Тому можна подумати, що «раціональність» як

загальна дисципліна мало чим може прислужитися успіху у реальному житті. Та все ж, як на мене, яку професію не візьміть, всюди не зайвим буде розуміти, як *не пошитися в дурні*. Якщо вам забагнеться навчити когось *не перетворювати дрібні помилки на великі провали*, чи то у хедж-фондах, чи то в коханні, суть уроку залишиться незмінною. Майте сміливість визнати поразку.

Належний сумнів

На своєму Шляху до раціональності я зауважив, що у більшості організованих систем вірувань ставлять собі за мету *втекти від сумнівів*. Якось на одній зустрічі слухач зауважив, що єзуїти начебто мають імунітет до критики. Мовляв, їхній шлях ґрунтується на дисциплінованому сумніві: неофітів навчають ставити під сумнів християнство, осмислювати можливість небуття Бога, сумніватися у власному покликанні, вагатися, чи зможуть вони дотриматися вічних обітниць цілібату та бідності.

— *Ага, але вони мають побороти ці сумніви. Правильно?* — відповів я.

— *Ні, вони мають сумніватися у тому, що їхні сумніви примножуватимуться і посилюватимуться.*

Мені не вдалося наугуглити, чи він говорив правду. Але такий хід здається мені цікавим — незалежно від того, чи практикують його єзуїти. Якщо вони, як стверджує той слухач, справді культивують у собі дисциплінований сумнів, *то* чи не варто розглядати їхню чесноту як рівноцінну раціоналістичній?

Мушу визнати: у вищеписаному (можливо, гіпотетичному) випадку навряд чи можна сказати, що єзуїти «тікають від сумніву». Але така (імовірно, гіпотетична) поведінка все ще видається мені вкрай підозрілою. Доброчесного раціоналіста сумнів не має лякати. Така поведінка нагадує вправу з десенсибілізації — наче людину з арахнофобією поступово привчають перебувати в одному просторі з павуками.

Але ж вони все одно заохочують неофітів до сумніву. Яка різниця — їхні міркування хибні чи ні? Хіба цей учинок сам по собі не гідний раціоналіста?

Допитливість прагне знищити саму себе; без *спрямування* на відповідь вона перестає бути допитливістю. А коли ви отримуєте свою відповідь, насичуєте допитливість, шляхетна загадковість втрачає у загадковості.

Те саме із сумнівом — він існує, щоб розвіяти конкретне переконання. Якщо сумнів не зумів знищити ціль, він згасає нездійсненим, але таке завершення все одно є розв'язкою, хай і сумнішою. Сумнів, що не розвіявся сам і не знищив цілі, не мав би існувати взагалі. Храповий механізм раціональності приводить у рух не сам сумнів, а процес його *розв'язання*.

Не кожна зміна породжує покращення, та жодне покращення неможливе без змін. Так і кожен раціоналіст сумнівається, але не кожен сумнів раціональний. Як лабораторний халат не робить з вас лікаря, так позірний сумнів не робить з вас раціоналіста.

Раціональний сумнів народжується з реальних підстав підозрювати хибність переконання. Відповідно, цей процес визначає напрямок розслідування, внаслідок якого зникне або цільове переконання, або сумнів. Цей принцип дієвий і для цілком абстрактних сумнівів, як-от: «Цікаво, чи могла б існувати простіша гіпотеза, яка пояснює ці дані». Тоді ви вивчаєте дані, щоб вимислити простіші гіпотези. Коли пошуки затягуються й не приносять результату, ви дедалі менше вірите у те, що наступне обчислення буде успішним. Зрештою, ціна пошуків перевищить ціну очікуваної користі, і ви зупинитесь. На цьому етапі ви вже не можете стверджувати, що ваш *сумнів корисний*. Сумнів, який не розбирають, міг би й не існувати. Адже сумніви існують для того, щоб так чи інакше розв'язатися. Нерозв'язаний сумнів — це холоста операція, що не рухає коліщатко ні вліво, ні вправо.

Навіщо тому, хто справді вважає релігію істинною (а не просто вірить у неї), вчити новоприбулих замислюватися над сумнівами, яким не судилося бути доведеними до кінця? Уявіть, якби студентів факультету фізики навчали тривожно сумніватися, чи не була наукова революція XX століття хибною, а ньютонівська механіка — насправді правильною від самого початку. Навіщо ж *удавати* сумнів, якщо ви і *не збиралися* сумніватися?

Тому що усім хочеться, щоб про них думали як про раціональних істот, а сумнів якраз *заведено* вважати чесною раціоналістів. Але у масовій свідомості якраз бракує розуміння, що

сумнів потребує особливої причини, а нерозв'язаний сумнів — команда без наслідків. Люди ж дивляться на сумнів як на *смирненість* — покірну поведінку, що підтримує племінну ієрархію (точно така ж проблема зі скромністю). Публічна демонстрація сумнівів задля самозапевнення у власній раціональності приносить стільки ж користі, скільки й носіння лабораторного халата.

Якщо ви не хочете просто сповідувати сумнів,¹ запам'ятайте, що

- раціональний сумнів існує, щоб знищити цільове переконання, а якщо не вдається, він вичерпує себе сам;
- раціональний сумнів постає з конкретної причини, що переконання може виявитися хибним;
- нерозв'язаний сумнів — мов та холоста операція;
- сумнів, за яким не слідує розбір, не має сенсу;
- гордість за сам процес сумнівання вам ні до чого — от коли ви розірвете на шмаття своє облюблене переконання, тоді гордість буде доречною;
- щоб глянути сумнівам у вічі, може знадобитися сміливість, але пам'ятайте, що *чистому розуму* нічого страшитися сумнівів.

1. Див.: «Сповідувати та вболівати» у книзі «Мапа і територія». — Прим. авт.

Вам до снаги витримати дійсність

Що істинне — вже сталося таким.

Відверте визнання істини не зробить її гіршою.

Не бути відкритим до неї — не змушує її зникнути.

І тому що вона істина — вона те, що присутнє, аби стикатися з цим.

Будь-що неістинне не присутнє, щоб бути пережитим.

Люди можуть прийняти, чим є істина,

бо вони вже переживають її.¹

— *Юджин Гендлін*

1. Наведено переклад (літаній Гендліна і Тарського) наукового критика (<https://youtu.be/7rHvDdtKfKE>). — Прим. пер.

Медитація на допитливість

«Перша чеснота — допитливість».

— «Дванадцять чеснот раціоналіста»

Коли ми назвалися раціоналістами, то вже зобов'язалися критикувати свої погляди, ставити їх під сумнів . . . Так же?

Подумайте-но, як на вас вплине фраза «Критикувати свої погляди — мій обов'язок». Колись Роджер Желязни писав про різницю між «бажанням бути письменником» та «бажанням писати». Марк Твен писав: «Класичною називається книга, яку хвалять і не читають». Самокритика з відчуття обов'язку дає відчуття *опрацьованості* і, як наслідок, дозволяє стверджувати, що ваша віра не сліпа. Це не те саме, що *бажання розібратися у проблемі*.

Це шлях до зупинки у пошуках. От ви розглядаєте заперечення, контраргумент до того заперечення і *зупиняєтеся* — ось так це виглядає. Повторюєте цикл із кількома запереченнями, доки не відчуєте, що виконали обов'язок розібратися у питанні. На цьому і *зупиняєтеся*. Ви досягнули своєї психологічної цілі: якщо мислите себе раціоналістом, позбулися когнітивного дисонансу, і при цьому навіть не дійшли до критики власного переконання. Виконавши обов'язок, ви просто продовжили підписку на задоволення почуватися раціональним.

Потім ви встановите досить високий рівень імовірності, щоб виправдовувати чіплення за початкові плани і переконання, але не настільки високий, щоб викликати недовіру у вас самих чи в інших раціоналістів.

Коли ж цікавість не вимушена, вас тягне до запитань, здатних змінити вашу думку, або до тих, що *відрізняються* від уже розглянутих. Адже ваш імовірнісний розподіл має відрізнятися від початкового: якщо вам дійсно цікаво, мали відбутися бодай якісь зрушення — вперед, назад. Бодай кудись.

А тепер порівняйте принцип зрушення з підсвідомим бажанням тупцюватися на знайомому полі — щоб якнайшвидше покінчити з пошуком відповіді, щоб *відчути, що зроблено вдоволь*, щоб зберегти знайомий баланс, на якому тримаються ваші попередні плани і погляди.

Про те, яке лице у справжньої допитливості та її силу, я пишу в есеї «Притча про науку і політику» у книзі «Мапа і територія». У притчі розкриваються реакції різних героїв на дивовижне відкриття, і кожна з них несе свій урок. Феррис, останній персонаж, утілює силу невинної допитливості, яка ґрунтується на легкості та сміливому поступі до свідчень.

Урсула Кребер-Ле Гуїн якось писала: «У невинності бракує сил, аби боротися зі злом. Але для добрих справ сил у неї вистачає...».¹ Та навіть невинна допитливість може невинно збити з правильного шляху. Тому, якщо ми хочемо стати сильнішими, на шлях раціоналіста, як і на супутню йому витонченість розуму, ми маємо наважуватися з пересторогою. Попри ризики, все ж у наших силах триматися легкості і зберігати відкритість до нових свідчень.

В есеї «Дванадцять чеснот раціоналіста» я писав:

«Якщо глибоко всередині ви вірите, що вже знаєте, або не бажаєте знати, тоді ваші запитання втрачають мету, а навички — напрям. Допитливість прагне вичерпати саму себе; не існує допитливості, що не прагне відповіді».

Повірте: справжню цікавість нічим не підробити. Палюча жага дізнатися переважить урочисту присягу переслідувати істину. Але запалити цікавість самим лише бажанням — що силою волі розігріти холодні ноги. Іноді ми багаті лише на урочисті присяги.

Тож як можна впоратися із цим обов'язком? Можна почати з вимушеної розвідки — відстежувати іскри щирої цікавості або

1. Переклав з англійської Анатолій Саган. «Останній берег» вийшов у видавництві «Навчальна книга — Богдан». — Прим. пер.

усвідомленого невігластва, що прагне себе нівелювати. У процесі слід уважно придивлятися до болісних можливостей, від яких ви відсахуетесь — і це не лише негативне мислення.

Помічним буде помедитувати над Законом збереження очікуваних свідчень. Для кожного нового запитання і фрагмента *невидимого* свідчення, котрий ви помічаєте у процесі, очікувана апостеріорна ймовірність має дорівнювати апріорній ймовірності. Це означає, що у ході розгляду ваша позиція завжди може однаково зміститися у будь-яку сторону. Не кожне питання здатне кардинально змінити вашу оцінку проблеми, наприклад, з 70% на 30%. Проте якщо поточна ймовірність становить 70%, слід бути готовими коригувати її навіть до 69% або 71%. Не думайте, що знаєте, в якому напрямку ви підете у ході розгляду, адже, за теорією ймовірностей, якщо розумієте, куди вас принесе, ви вже на місці. Якщо ви досліджуєте чесно, дозволяючи кожній *новій* одиниці даних зрушити вашу позицію в будь-який бік, вам вдасться зберегти зацікавленість у самому процесі.

Якщо ви розглядаєте вже *не* новий для вас аргумент, навіщо ж витрачаєте на нього час? Якби вам було по-справжньому цікаво, чи витрачалися б ви на старі аргументи? Чи ви підсвідомо критикуєте сильні сторони своєї позиції замість слабких? Чи товкмачите знайомі свідчення?

Якщо ви можете утриматися від відпрацювання вже знайомих свідчень на вашу користь і через нові свідчення біт за бітом знижувати свою впевненість, то зможете і повністю відмовитися від переконання і побачити, звідки саме проти вас дме вітер свідчень.

Ще один стимул для підтримки допитливості — літання Тарського (принаймні я так її називаю), яку можна віднести до металітаній, оскільки вона пасує до будь-якого випадку. Скажімо, мені тривожно, але цікаво, чи знайду я у замкненій скриньці діамант, тож замість того, щоб міркувати над усіма приємними наслідками знахідки, я краще повторю літання Тарського:

*Якщо діамант у скриньці,
я бажаю вірити, що діамант у скриньці.*

*Якщо діамант не в скриньці,
я бажаю вірити, що діамант не в скриньці.
Нехай не прихилюся я до неточних вірувань.*

Тоді не зайве і помедитувати над тим, що ви не знайдете діамант, над перевагою віри у його відсутність, а також над шкодою від віри, що він там є. А коли вже на те пішло, то помедитуйте і над літанією Гендліна.

Якщо у своїй позиції ви помічаєте бодай тінь непевності — бережіть її, як пастух стереже ватру. Якщо вам вдасться розпалити вогонь зацікавленості, він поведе вас правильними запитаннями і спрямує ваші навички у потрібному напрямку.

Перед законами раціональності усі рівні

Про принципи традиційної раціональності часто говорять як про *соціальні норми*: порушення тлумачать як шахрайство — відхилення від норм кооперативної поведінки. Якщо ви хочете, щоб я від вас прийняв якесь переконання, ви зобов'язані надати стільки-то свідчень. Спробуєте схитрувати — значить ви нехтуєте своїм обов'язком. Теорія повинна сама робити сміливі передбачення, а не красти ті, над якими інші теорії довго працювали. Теорія повинна бути фальсифікованою: якщо вона ухиляється й починає мудрувати, значить, вона уникає страшного ритуалу посвяти; ви ж маєте платити свої борги.

Принципи традиційної раціональності формулюють у формі, схожій на суспільні звичаї — тому її так просто передавати з уст в уста. Люди значно краще розпізнають соціальне шахрайство, ніж ізоморфні порушення абстрактних логічних правил.¹ А от у розрізі суспільного обов'язку раціональність набуває доволі химерних рис.

Уявімо якогось вірянину, який захищає свої погляди: «А *ти* ж теж не можеш обґрунтувати свою віру в науку!». Іншими словами: «Та як ти смієш критикувати мене за безпідставні переконання! Лицемір! Ти такий самий!».

Для баєсіанців мозок — точнісний механізм: він обробляє і стягує сплутані свідчення у мапу, яка відображає територію. Принципи раціональності являють собою закони у тому ж сенсі, що і Другий закон термодинаміки: як для надійного переконання необхідна обчислювана кількість сплутаних свідчень, так і

1. Leda Cosmides and John Tooby, "Cognitive Adaptations for Social Exchange: Evolutionary Psychology and the Generation of Culture," in *The Adapted Mind*, ed. Jerome H. Barkow, Leda Cosmides, and John Tooby (New York: Oxford University Press, 1992), 163-228.

для охолодження наповнення холодильника потрібен обчислюваний мінімум вільної енергії.

Зasadничо закони фізики оборотні у часі, тож існує нескінченно мізерна ймовірність — настільки мала, що тільки математики відрізнять її від нуля, — що холодильник почне ні сіло ні впало охолоджуватися і виробляти електроенергію. Дещо більш імовірно, що ви зможете намалювати точну докладну мапу Нью-Йорка, жодного разу там не побувавши, із заштореними вікнами і без інтернету. Але я б не розраховував.

Перш ніж наносити незвідану територію на мапу, наповніть склянку водою кімнатної температури й дочекайтеся, коли вона раптово візьметься льодом. Так ви хоча б знатимете напевне, чи можна нехтувати нескінченно мізерними ймовірностями. Можливо, ви так і не зрозумієте, що ваша мапа хибна, особливо якщо ви ніколи не відвідували Нью-Йорк, однак побачити, що вода не заморожується сама по собі, куди легше.

Якщо уявити, що між раціональністю та соціальними нормами можна поставити знак рівності, може скластися враження, що поведінкою інших ви можете виправдовувати свою. Наприклад, вимагати від вас свідчень, якщо ми самі не можемо їх надати, не *чесно*. А потім ми дійдемо до думки, що ніхто з нас не кращий за решту, поступимося і звільнимо вас від соціального обов'язку підкріплювати свої погляди свідченнями. Отойді заживемо у свободі, рівності й братерстві.

Якщо принципи раціональності — це математичні закони, тоді виправдовувати безпідставне переконання чиеюсь такою ж поведінкою — настільки ж марна справа, як і перелічувати тридцять причин, чому не варто сходити зі скелі. Навіть якщо усі ми погодимося, що ваш холодильник несправедливо вимагає електроенергії, він від того не запрацює (з імовірністю ~ 1). І якщо погодимося, що вам не обов'язково відвідувати Нью-Йорк, мапа все одно буде хибною. Матері Природі, як відомо, байдуже до таких клопотань, як і пані Математиці.

Тож соціальною мовою традиційної раціональності: не тіште себе думкою, що ви можете *вийти сухими з води, виправдовуючи*

свої примхливі погляди на XYZ химерами з голів інших людей. Якщо обидві сторони контракту порушують умови, людський суддя може прийняти рішення не накладати покарання ні на одну з них. Але якщо двоє інженерів розробляють однаково погані двигуни, жоден не працюватиме як годиться. Одна помилка у конструюванні не покриває іншої. Навіть якщо *я* роблю XYZ неправильно, вам моя некомпетентність ніяк не допоможе, не звільнить від правил. Просто ми обидвоє зазнаємо невдачі.

За законом ліберальних демократій, кожна людина має право на свою думку. За законом Природи, точність переконань правом не є. Ми не арештуємо людей за віру у химерщину (принаймні у притомних країнах до такого не дійшли). Але ні в кого немає повноважень скасувати закон, що *точні* уявлення потребують свідчень. Навіть гóлосові цілого людства не домогтися ласки Природи.

Не фізики визначають фізичні закони — вони припускають, які ті закони з себе. Раціоналісти не визначають закони раціональності — вони їх вгадують. Тому ви не зможете «раціоналізувати» те, що не було раціональним від початку. Якщо навіть ви зможете якимось дивом переконати всіх фізиків світу, що на вас не діє Закон всесвітнього тяжіння, зійшовши зі скелі, ви все одно впадете. Та й від формулювання «Ми не визначаємо» відгонить антропоморфізмом. Не існує якоїсь вищої влади, яка змогла б звільнити вас від цих законів. Існує лише причина і наслідок.

Тому коли забагнеться виправдовуватися, пам'ятайте: ми не зможемо виправдати вас. У нас немає такої влади.

Залиште шляхи відходу

«Оточивши супротивника, завжди залишай йому змогу до відхідного шляху. Не тисни на протиборця, що перебуває в безвиході».

— «Мистецтво війни», Сунь-дзі¹

«Не посилюй тиск — знижуй бар'єр».

— «Комарр», Лбіс Буджолд

Днями у мене була випадкова розмова з однією пані, яку занесло на місцеве зібрання раціоналістів. У розмові вона заявила про свою а) віру в душу і б) невіру у кріоніку, зумовлену непридатністю замороженого тіла для душі. «Як ви це зрозуміли?» — спитався я.

З її спантеличеного виразу я зрозумів, що до цього вона з подібним питанням не стикалася. Нічого не мав проти неї. Мені пані здавалася приємною людиною, яка просто не проходила вишколу з прикладної раціональності, чим не відрізнялася від більшості людей.

Левава частина подальшої розмови була присвячена питанням, які ми обговорюємо на *Overcoming Bias*: якщо у вас *непідроблений* інтерес до якоїсь проблеми, напевно, вам *удасться* знайти ловкий спосіб дослідити її, спробувати сформулювати точне уявлення про неї, а вже потім давати волю емоціям. Ця розмова нагадала мені про один принцип, який я ще не зачіпав:

«Спробуйте уявити, — я порадив їй, — що з себе представляв би світ без душ і як би ви намагалися впоратися із цим. Забудьте про те, що такого просто не може бути. Просто прийміть неіснування душі за вихідну точку, а потім уявіть наслідки. Наприклад: “Що ж, якщо душі немає, я можу підписатися під

1. З китайської переклав Сергій Лесняк для «Видавництва Старого Лева». — Прим. пер.

кріонікою” або “Якщо Бога немає, я у будь-якому разі можу залишатися людиною”, а не злякатися настільки, щоб навіть не змогти подивитися у вічі страхів. Якщо ви поважаєте себе, вам, як я вже казав, слід прагнути правди, якою неприємною вона б не була; але людська природа така, що корисно спершу знизити дискомфорт від переконання, перш ніж братися за оцінку свідчень на його користь».

В основі цієї техніки лежить простий принцип: що Сунь-дзи радив чинити проти ваших супротивників, те варто спробувати на собі — залишити шлях відходу, щоб вам було легше поступитися. Наприклад, через перспективу втратити роботу ви, певно, боїтеся навіть думати про таку можливість. Інша річ — порахувати, на скільки вистачить заощаджень, дослідити ринок праці у вашому регіоні й спланувати свої подальші дії. Тільки тоді до снаги *на тверезу голову* оцінити ймовірність звільнення на запланованих скороченнях наступного місяця. Не бійтеся проявляти боягузтво і докладно продумувати шляхи відходу, виображувати кожен свій крок (бажано перед власне битвою).

Сіль в тому, щоб проявити менше сміливості й уявити собі неприємну картину у вигляді *мисленого експерименту*, а не розглядати *вірогідність* ситуації. А там після першого вже легше перейти до другого.

Не забувайте, що баєсіанство — це мистецтво точності: навіть якщо страшне припущення дійсно видається малоймовірним, щоб прийти до раціональної кількісної ймовірності, все ще важливо зважити всі «за» та «проти» — наче на аптечних вагах. Виобразити страшний варіант *не* означає визнати ймовірну правдивість глибинного страху. Ви можете піти на цей крок і з турботи про вашу глуздярню. Сценарій «Думка, на яку ви забороняєте собі звернути увагу, має над вами більшу владу, ніж озвучувана» можливий навіть за хибності забороненої думки.

Техніка залишення відхідних шляхів вимагає певного мінімуму чесності з собою.

Для початку ви мусите зізнатися собі, *котрі* думки вас лякають, а до яких ви прив’язалися. І це набагато простіше

випробування, ніж тверезий підрахунок свідчень на користь гнітючої думки. Вам допоможе, якщо скажу, що мені самому доводилося користуватися цією технікою? Адже раціоналіст не нехтує емоціями. Не без думок, які жахають мене своєю реалізацією, хоч я й вважаю їх хибними. Не без думок, до яких я прив'язався і все ще вважаю їх правдивими. Та я все одно продумую свої шляхи відходу. Не тому, що я *готуюся* здати позиції, — завдяки такому передчасному плануванню я обдумую проблему без емоційної прив'язки.

Уже більше випробування для самочесності — *неудало* взяти неприємне припущення за засновок і знайти *надійний* спосіб дати йому раду. Коли ми віч-на-віч стикаємося з неприємними думками, перший імпульс — вимислити будь-які можливі причини *неможливості їх реалізації*. Безумовно, ви зішукатися від певного психологічного опору, коли спробуєте уявити, який би з себе був той світ і як би ви давали йому раду, якщо ваше найцінніше переконання виявиться хибним або ваше найстрашніше переконання виявиться істинним.

Подумайте про всіх тих людей, які вважають, що без Бога мораль неможлива.² Якби віряни наважилися виобразити свою *справжню* реакцію на гіпотетичну відсутність Бога, не забарилося б і розуміння, що від того не почнуть розпинати немовлят. Вони б усвідомили, що їхня реакція, по суті, не відрізняється від реакції атеїстів. Я проговорюю усе це, щоб показати, *наскільки* серйозний виклик уявити свою реакцію, якби ви повірили у щось протилежне до свого глибокоцінного переконання.

До того ж завжди незвично усвідомлювати, що люди проходять і через такий досвід. За пів року люди, у яких недавно паралізувало кінцівки, почуваються не такими розбитими, як очікували. Так само незвично усвідомлювати, що якщо страшна думка таки втілиться, ви якось *впораєтеся* зі своїм становищем. Якщо люди з паралічем дають собі раду, то й ви зможете.

2. І так — ця тема сплила у тій розмові. Я не даю вам солом'яне опудало. — Прим. авт.

Раджу також помедитувати над літанією Гендліна і Тарського. Що істинне — вже сталося таким. Від визнання істини ще нікому не стало гірше. Вас не має лякати лише *образ* страхітливого світу. Якщо той світ уже реальний, ваша уява не погіршить стан речей; якщо ж він *не* реальний, від того, що ви уявите, ніхто не постраждає. Запам'ятайте: якщо страшні речі, які ви уявляєте, уже сталися — а це може бути і не так! — тоді ви точно захочете прийняти їх, і не без того, щоб виобразити їх собі. Невіра вам точно не допоможе.

Скільки вірян зберегли б свою віру у Бога, якби уявили *коректний* гіпотетичний світ без Бога, а себе — атеїстами в ньому?

Залишати собі шлях відходу — техніка потужна, але не проста. *Чесне* уявляння потребує менших зусиль, ніж *пряме* визнання того, що Бога не існує, але зусиль усе ж потребує.

Криза віри

«Справжня криза віри буває лише тоді, коли ситуація може однаково вирішитися у будь-який бік».

— Тор Шенкель

Немало людей тримаються переконань, хиби яких з першого погляду може побачити десятирічна дитина. І не йдеться про важкопомітні помилки. Незаангажований розум, якщо підійде зі скептицизмом десятирічної дитини, розкусить їх із грайливою легкістю. Один критик засновків якомсь писав: «Якби ідею бога вимислили вже після світанку наукової доби, зробити це та ще й удавати, що вона пояснить що завгодно, міг лише украй дивний екземпляр».

Навіть досвідчені вчені та чільні новатори у своїй галузі у наші дні не можуть піддати такій критиці свої релігійні погляди. Візьмемо нобелівського лавреата Роберта Ауманна. Він ортодоксальний єврей. Цілком певен, що в якийсь момент Ауманн ставив свою віру під сумнів. Однак він не зміг сумніватися як слід. Адже ми змінюємо свою думку рідше, ніж нам здається.

Хіба така перспектива не лякає вас аж до волокон кісток? Тобто ви можете бути науковцем зі світовим ім'ям, знатися на баєсовій математиці і *все одно* завалити тест на відкидання переконання, абсурдність якого побачить незаангажована десятирічна дитина. Таку оборонну і непідступну позицію створює для себе переконання, яке подовгу гнило у розумі.

Як же тоді перемогти помилку, яка збудувала навколо себе фортецю?

Перемога починається з *усвідомлення*, що ви помиляєтеся. Адже дилема звучить не «Як мені позбутися міцно вкоріненого хибного переконання Х?», а «Як мені зрозуміти, чи міцно вкорінене переконання Х хибне?». Чесність із собою найбільш

крихка, коли ми не *певні*, який шлях праведний. Тому питання набуває вигляду

«Як викликати в собі справжню кризу віри — таку, що могла б однаково легко завершитися будь-яким із двох способів?».

Почнемо з тривіального випадку, яким нам усім знайомий, — релігії.¹ Та якщо ви відключили всю свою приязнь і мислите вірян лихими покручами, ви не зможете уявити, через які внутрішні складнощі їм доводиться проходити. Ви просто не дійдете до запитання.

«Якої загальної стратегії має дотримуватися вірянин, щоб відкинути свою релігію?».

Уже чую, як, побачивши питання, хтось наперербій починає перелічувати шаблонні атеїстичні опінії: «Мають визнати, що немає жодних баєсових свідчень на користь існування Бога», «Чому ж вони не бачать моральних вивертів, коли виправдовують поведінку біблійського Єгови?», «Нехай навчаться орудувати лезом Оккама»...

Ні! Ні, ні, ні! Саме через отаке відпрацювання, коли ви просто викашлюєте *давно сформовані опінії*, через *точно такий* спосіб мислення віряни і тримаються за свої релігійні переконання. Коли ви не виходите за межі своїх закешованих думок — ваш мозок автоматично вистрілює очевидну відповідь, не даючи подивитися свіжими очима, — ніяку кризу віри у своїй голові вам не породити.

Можливо, проблема у тому, що замолоду дуже мало людей читають «Гюдель, Ешер, Бах». Я помітив, що значна частина людей — навіть технарі — не розуміють міркувань, які виходять

1. Читачі з атеїстичних сімей прогавили одне із засадничих життєвих випробувань, а тому вимушені задовольнятися скромною заміною у вигляді релігійних друзів. — Прим. авт.

на метарівень.² У свої найпесимістичніші дні я іноді замислююся, чи й справді у верблюда два горби.

Деякі люди, вочевидь, *не бачать стрибка* від рівня об'єктів у вигляді аргументу «Застосуйте лезо Оккама! Як ви не бачите, що ніщо не вимагає від вас віри в Бога!» до метарівня у вигляді «Не давайте своєму розуму йти протореним шляхом!». Як ваші друзі-раціоналісти торочать про лезо Оккама і його крутість, як це Лезо з легкістю спадає вам на думку, так і очікувана відповідь вірянина, схвалена його друзями, звучатиме як «Шляхи Господні несповідимі, а хто думає, що зможе пізнати їх, дурень». Тож чим ваша *загальна* стратегія — «Застосовуй лезо Оккама!» — відрізняється від стратегії вірянина плекати віру?

«Але ж лезо Оккама куди краще за віру! Це ж не питання вподобання! Історія показує, що оккамівське мислення принесло куди більше блага за віру...», — не вгаваєте ви.

Усе правильно кажете. Дарма, що ні до ладу ні до прикладу. Проблема в тому, що ви відтарабанюєте шаблонне обґрунтування. Криза віри складна тим, що наші шаблонні висновки та обґрунтування можуть бути *хибними*, і з цим треба якось давати раду. Отже, якщо до X шаблонне обґрунтування «Лезо Оккама!», то варто запитати себе, чи справді лезо Оккама підтримує X, чи ваше розуміння цього принципу коректне, чи (якщо ви готові сумніватися досить глибоко) простота — той критерій, що історично добре себе зарекомендував у подібних випадках або від якого можна було б розумно *очікувати* такої ефективності. Якщо ви порадите вірянину поставити під сумнів переконання, що «віра» — надійне обґрунтування X, тоді маєте і собі порадити докласти рівнозначних зусиль, щоб піддати

2. Див. статті “Archimedes’s Chromophone” (https://lesswrong.com/lw/h5/archimeddess_chronophone) та “Chromophone Motivations” (https://lesswrong.com/lw/h6/chronophone_motivations). — Прим. авт.

сумніву своє переконання про те, що «лезо Оккама» — надійне обґрунтування Х.³

Якщо «Лезо Оккама!» — звична для вас і вашої бульбашки відповідь, то чому б вам у спробах розпалити справжню кризу віри не заглушити двигун, який веде вас протореним шляхом?

Краще спробуйте евристику «Уявити, що сказав би скептик, як він відреагував би на мою відповідь, що ще він міг би сказати — щось таке, на що у мене не стало б клепки» або «Думати найболючішу думку».

Отже, цільне правило звучить так:

Викластися на стільки, на скільки викладатиметься вірянин, щоб відкинути свою релігію.

Тому що коли ви *не* викладаєтеся так само, то — хто *вас* там зна, — може, у вашій голові сміття не краще за релігію.

Як без болісного, внутрішнього надривного зусилля триматися раціональності — таке зусилля знадобилося б, щоб відкинути релігію — ви взагалі смієте вірити у що-небудь, коли ось Роберт Ауманн вірить у Бога?

Уже не пригадаю, хто запримітив, що люди лише до якогось віку можуть відкинути релігійну віру. Після того порогу у них уже сформується усі відповіді на заперечення, вже буде пізно. Навряд чи вам хочеться тієї ж долі. Такий тест сили раціоналіста — дуже суворий: не складете — позичати вам сили у десятирічної дитини.

Знову ж — перемога починається з усвідомлення, що ви помиляєтеся. Ідеться не про відчайдушно-судомне зусилля нівелювати вплив релігійного виховання *після* того, як ви дійшли висновку про хибність релігії. Про надзвичайне зусилля -

3. Подумайте про всіх, хто поняття зеленого не має про мінімальну довжину опису, перевизначення леза Оккама через індукцію Соломонова, які вважають, що лезо Оккама виключає багатосвітову гіпотезу чи гіпотезу симуляції. Їм потрібно обсумнівати власні тлумачення леза Оккама та уявлення про цінність простоти. Чим би не був той Х, який ви хочете обґрунтувати своїм «А от лезо Оккама!», я дуже сумніваюся, що воно таке ж гостре, як і гравітація. — Прим. авт.

вирішити, чи потрібні вам ті кайдани. Чесність із собою найбільш крихка, коли ми не *певні*, який шлях праведний, — ось тоді раціоналізація постає *неочевидним* гріхом.

Не кожен сумнів може обернутися повномасштабною кризою віри. Можливо, варто створити для неї умови, коли

- переконання уже давно живе у вашій голові,
- за роки воно вкрилося наростами знайомих аргументів і спростувань,
- ви прив'язані до нього незворотними затратами (ви вклали у нього час, гроші, публічні заяви),
- переконання несе в собі емоційні наслідки (самі по собі не роблять його хибним),
- воно переплелось з вашою особистістю.

Жодна ознака не дорівнює беззаперечному спростуванню. Наведені перестороги інформують про вразливість переконання до небезпек будь-якого виду, а якщо воно ще й *виявиться* хибним, його буде складніше відкинути. І це однаково стосується як віри Річарда Докінза в еволюційну біологію, так і католицизму Папи Римського.

І ми говоримо не про те, яке морозиво кому до смаку. Два переконання з різним емпіричним підґрунтям можуть викликати рівноцінну емоційну прив'язаність. Суть не в тому, щоб обмежуватися поверхневими переконаннями, а в тому, щоб мапа відображала територію.

Звісно, я наголошую на цьому, щоб ви могли сказати «За моїм переконанням я помічаю підозрілі ознаки» без імплікації «Моє переконання хибне».

Ці ознаки *свідчать* про те, що вам доведеться докласти *суттєво більше зусиль, щоб по-справжньому засумніватися у переконанні*. Вам знадобиться більше зусиль, щоб осумнівати своє переконання так, що, визнавши його хибним, ви зможете відкинути його. Якщо ж ви не можете сумніватися як слід — значить ваша віра сліпа, і розум чіплятиметься за переконання хай там

що. Стан, коли сітківка надсилає той самий сигнал незалежно від того, скільки фотонів потрапляє на неї, ми називаємо сліпотою.

Тож коли приходить той момент, коли варто пройти через кризу віри?

Повернімося до тієї поради, яку ви дали б вірянину. Якщо ви відчуваєте розгубленість і не покидаєте спроб раціоналізувати свою прив'язаність до переконання, певно, прийшов час для кризи віри. Якщо емпірична база вашого переконання настільки ж надійна, наскільки Закон всесвітнього тяжіння, немає чого хвилюватися. Але подумайте про всіх вірян, які аж зі шкіри пнуться зацементувати надійність існування Бога. Подумайте, що сказав би скептик на ваш аргумент «надійний, як закон тяжіння». Безумовно, ви провалите кризу віри зокрема тому, що не зупинитесь, щоб запитати себе, не скажете: «Ось це мені потрібно добряче обсумнівати».

Як думки набувають усе більшої складності, не зупиняйтесь, не звертайте зі стежки кризи віри. Не ступайте навпомацки. Не пробуйте кризу віри спорадично. Не поспішайте — аби відкараскатися і з чистим сумлінням відрепортувати: «Я засумнівався, як і годилося». Як для вірянину такий фокус не проканає, то чому для вас має? Напередодні наберіться сил, добряче відпочиньте. Виберіть собі час, коли вас не потривожать. Знайдіть собі затишне крісло. Очистьте голову від усіх шаблонних аргументів і постарайтесь подивитися на проблему свіжими очима. І з усіх сил викличте справжній сумнів, який зруйнує хибне — і *тільки* хибне — глибоко вкорінене переконання.

Елементи кризи віри ви могли помітити у раніших есеях:

- «Позбутися справжніх вразливостей у переконанні»: пишу про одну з перших спокус під час кризи віри — ставити під сумнів найбільш переконливі аргументи своєї позиції, до яких ви можете повторювати переконливі відповіді. Слід вишукувати найболючіші точки, а не розглядати заспокійливі аргументи.

- «Медитація на допитливість»: колись Роджер Желязни писав про різницю між «бажанням бути письменником» та «бажанням писати». Чимось схоже на різницю між відчуттям опрацьованості та бажанням розібратися у проблемі. Недостатньо сказати: «Критикувати свої погляди — мій обов'язок» — вами має рухати допитливість, яка може прорости тільки з непевності. Завдяки пам'ятуванню про *збереження очікуваних свідчень* ви можете *поступово оновлювати свої переконання*: на кожну окрему тезу, кожен новий аргумент і нове свідчення під прицілом вашої уваги ви мусите очікувати зміщення переконання в одному напрямку не більше (у середньому), ніж в іншому. Так ви зможете зберегти свою допитливість, хай куди вона вас заведе.
- «Свіжий погляд»: як спинити потік закешованих думок і не дати їм вести вас протореним шляхом.
- «Літанія Гендліна» і «Літанія Тарського»: люди можуть прийняти, чим є істина, бо вони вже переживають її. Якщо переконання істинне, вам краще прийняти його, а якщо хибне — відкинути. Спершу ви радите вірянину спробувати уявити світ без Бога — в усіх подробицях, — а потім безобмовно прийти до ясного висновку: *якщо* Бога не існує, *то* краще вірити, що Бога не існує. Якщо для когось неможливо прийняти цю думку на глибинному емоційному рівні, той не зможе навіть наблизитися до кризи віри. Тому-то слід вкласти неудаваних зусиль у витворення такої *альтернативи* вашому переконанню, якої від вас очікував би бездоганный скептик. Подумайте, яких зусиль вартує вірянину уявити всесвіт очима атеїста без спроб підважити цей експеримент задля власного комфорту.
- «Цуйоку Нарітай!»: про стимул ставати сильнішим.
- «Евристика походження»: якщо у вас назбиралося багато ідей, які походять із сумнівного джерела, варто ставитися до

них украй насторожено, хай би там як здавалося, що від того вони, їй-богу, не перестають бути правильними.

- «Йойкати — важливо»: проковтнути цілу гірку пігулку одним ковтком не так боляче.
- «Цілодумство»: про протилежність дводумству. Звертайте увагу на думки, від яких ви відводите погляд, щойно вони з'являються у закутку свідомості. Коли усвідомлюєте, про що ви не дозволяєте собі думати, одразу стає легше зробити перші кроки.
- «Смертельна спіраль радості» та «Опір смертельній спіралі щастя»: головню, до хибних переконань приводять різного роду смертельні спіралі радості, які має розхитати криза віри. Але смертельні спіралі щастя можуть закрутитися і довкола неілюзорних речей — насправду гараздих. У такому випадку необов'язково визнавати хибність переконання — можна і далі чинити спротив ефекту ореолу і відмовлятися від фальшивих вихвалянь дійсно гараздих речей. Адже політичні дебати не мають виходити однобокими.
- «Не поспішайте з рішеннями»: спочатку якомога глибше обговоріть проблему, а вже потім пропонуйте рішення. Привчайте свій розум не квапитися з відповіддю. Відмітьте собі п'ять хвилин на «подумати» як загалом, так і при розгляді точки зору адвоката диявола.

Наступні стандартні техніки, описані у «Як по-справжньому змінювати думку» та «Малі і території», так само стосуються теми:

- в есеях про *нижній рядок* та *раціоналізацію* я пояснюю, чому вибірково обстоювати одну сторону дискусії — безвинятково хибна стратегія;
- раджу ознайомитися з есеями «Упередження позитивного» та «Заангажована зупинка та заангажоване продовження», аби не вийшло так, що ви вибірково шукаєте підтвердження, вибірково добираєте відповіді на заперечення й вибірково

припиняєте міркування, щойно воно стає небезпечним. Прогавлені альтернативи — спеціальний випадок такої зупинки. Особливий різновид заангажованого скептицизму — удавана скромність, коли ви сором'язливо заявляєте, що ніхто не може знати того, чого ви самі воліли б не знати. Словом, не ставте до контраргументів вибірково завищених стандартів доказовості;

- стережіться *семантичних стоп-сигналів, знаків до оплесків*; будьте свідомі свого вибору *пояснити, поклонитися чи проігнорувати*;
- зважте тягар *обтяжливих подробиць*: кожна деталь — камінець у відерце кризи віри.

У книгах і на блозі *Overcoming Bias* можна знайти немало суміжних матеріалів. Деякі ідеї я ще не встиг викласти як слід. *Ішш'юкеммей*⁴ — одне з таких понять, яке позначає *відчайдушно-надривне зусилля* триматися раціональності. Таким зусиллям перевищують рівень Роберта Ауманна та інших знатних науковців, яким так і не вдалося звільнитися від кайданів своєї віри.

Криза віри — це критична точка, раптовий конфлікт, що постав унаслідок тяглого *ішш'юкеммею* — безкомпромісного зусилля тривалістю в життя триматися раціональності, що піднімає вас над тими клятими дурними помилками. Ось тоді приходить час застосувати ті навички, які ви так довго відточували, викладаючись на повну проти самого себе.

Бажаю щонайімовірнішої удачі у сутичці із супротивником. Плідної вам кризи!

4. Isshōkenmei (<https://en.wiktionary.org/wiki/%E4%B8%80%E7%94%9F%E6%87%B8%E5%91%BD>) — щосили. — Прим. пер.

Ритуал

Гостей, далеких від товариства *бейсуцукаїв*,¹ Джеффіссай приймав у стримано формальній кімнаті, вивірено облаштованій в украй консервативному стилі. Через блискучу срібну ґратку пробивалися промені сонця і дув вітер. Її гострі краї натякали на те, що цю стіну не так просто було відкрити. Стіни й підлога були зі скла. За товстими стінами краєвид виглядав розмитим, простір під глибокою підлогою втрачав навіть найтонші обриси. На скляних поверхнях виднілися витончені візерунки без конкретного сенсу — ніби їх надряпала художньо обдарована дитина (насправді без «ніби»).

Хоч у будинку і були кімнати інших стилів, йому здавалося, що гості поза товариством очікували від Майстра баєсіанства саме такого інтер'єру. Як-не-як стримане задоволення було однією з маленьких радостей життя.

Гостя сіла навпроти Джеффіссая, поклавши коліна на подушку і підібгавши під себе п'яти. З одягу він зрозумів, що пані навідалася виключно у справах своєї Змови: її форми облягав комбінезон з рожевої шкіри, долоні ховалися за рукавицями. Комбінезон покривав її з голови до ніг, так що чоловік міг бачити лише її лице.

Джеффіссай вирішив прийняти її у цій кімнаті.

Врешті він видихнув повні груди.

— Ти *певна*?

— О, — почала гостя, — то я маю бути *абсолютно впевненою*, щоб мої слова могли змінити твою думку? Мало того, що я фахівець, а ти ні?

Кутик його рота сіпнувся у напівпосмішку.

— Звідки, кажеш, *ти* стільки знаєш про закони раціональності? Ти ж не проходила і дня формального вишколу.

1. Слово утворене складанням двох основ з японської мови: *beisu* — транслітерація японського слова «Баєс» — і *tsukai* — з японської означає «користувач». З японської можна перекласти як «баєсіанець». — Прим. пер.

— Ще питаєш? — сухо кинула вона. — Вас, *бейсуцукайв*, хлібом не годуй — дай розказати про мотиви своїх учинків.

Джеффіссай подумки здригнувся від спроби опанувати раціональність зі слів інших людей...

— І про себе не кривися так на мене, — дорікнула вона. — Я не хочу опановувати раціональність — лиш виграти спір з раціоналістом. Є різниця. Так ти говориш своїм учням?

Невже вона аж так добре знає мене? Крізь срібну ґратку Джеффіссай виглянув на осяяний сонцем гірський схил. День у день золотаві промені водоспадом обливали надхмарний схил. Яка ж незмінна річ — те світло. Те далеке Сонце, від якого походило це світло, згасло уже як п'ять мільярдів років; але зараз, у *цю* мить, воно ще світить. Того було не змінити. Навіщо хотіти незмінності, якщо це бажання і так уже виконано максимально повно? Парадокс постійності та мінливості у тому, що тільки з погляду останнього існує прогрес або втрата.

— Ти завжди давала мені ловку пораду, — мовив Джеффіссай. — Незмінно. За весь той час, що ми знайомі.

Вона кивнула. Обидвоє розуміли, про що йдеться.

— Не заради суперечки, — сказав Джеффіссай. — Я дійсно хочу знати відповідь. Ти впевнена?

Він не розумів, як вона могла *здогадатися*.

— Доволі впевнена, — відповіла, — ми вже давно збираємо статистику, і в дев'ятисот вісімдесяти п'яти випадках з тисячі...

Його вираз обличчя викликав у неї посмішку.

— Та ні, я жартую. Звісно, я не впевнена. Тобі вирішувати. Але *я впевнена*, що ти маєш піти і зробити, хай там що ви у таких випадках робите. Впевнена, що у тебе є ритуал, навіть якщо ти не говориш про нього *небейсуцукаям*. Той ритуал, у процесі якого ти *дійсно розглядаєш* можливість відкинути глибоко вкорінені засади власного існування.

З її словами було важко сперечатися — подумав Джеффіссай — а тим паче коли фахівець у галузі сказав, що ти, скоріше, помиляєшся.

— Визнаю помилку, — з твердою рішучістю озвучив він думку вголос. — *Не бачу потреби далі сперечатися — ти виграла.*

— Та облиш, — вона підвелася одним плавним рухом. Своїм віком вона не хизувалася, але й не приховувала його. Узявши його витягнуту руку, вона піднесла її до своїх губ — такий собі церемоніальний поцілунок. — Прощай, сенсею.

— Прощай? — утворив їй Джеффріссай. У її репліці він відчув щось більше, ніж буденне «бувай». — Я обов'язково відвідаю тебе знову, міледі. Та й тут тобі завжди раді.

Вона мовчки пішла до дверей. Зупинилася на порозі і не обертаючись мовила:

— Як раніше уже не буде.

Опісля вона ніби випарувалася з кімнати.

Джеффріссай видихнув. Принаймні від цього моменту й аж до самого випробування було цілком зрозуміло, чим він займатиметься.

Вийшовши зі стриманої приймальної, він перейшов до своєї арени і наказав розіслати посланців до учнів: заняття наступного дня мають відбутися без нього, в імпровізованому режимі, а пізніше буде тест.

Він не знайшов кращого заняття, ніж прочитати ще сотню сторінок позиченого підручника — читво не з цікавих, але й книга, яку він проміняв на цю, теж не вирізнялася якістю. Тиняючись з кімнати у кімнату, від нудьги він відкривав-закривав шухляди — перевіряв, чи, бува, нічого не вкрали (зникла колода карт — та й по всьому). Часом його не полишали думки про завтрашнє випробування, і він просто дозволяв їм плисти. Не скеровував їх ніяк — лише відкидав усе те, що вже *колись* думалося йому, не даючи їм розростися у який-небудь висновок чи навіть у міркування про те, куди вони його ведуть.

Сонце ховалося за небокрай. Купаючи очі у догораючому світлі, він дозволив розуму стихнути. Джеффріссай не знав кращого способу заспокоїти розум без мороки і зайвих зусиль утримувати цей стан. Раніше він би подовгу сушив голову над цією задачею, однак практика вже давно дає про себе знати.

Наступного ранку, прокинувшись, він ще ясно пам'ятав хаос нічних сновидінь. Щосили чоловік прагнув зберегти те відчуття безладу у голові, а з ним і згадку про той хаос. Далі на нього чекали сходи... сходи... і ще сходи... Він спустився до найскромнішої кімнати в будинку.

Кімната була біла. В принципі, до її колірної гами нічого було додати.

На стіні (а вона була одна) висіли дощечки. Молодий Джеффріссай ретельно порозписував їх усіх, як йому були радили майстри. Дотиком пензля він укарбовував кожнісіньке поняття собі в голову. *Що може бути зруйнованим істиною — повинне. Люди можуть прийняти, чим є істина, бо вони вже переживають її. Допитливість прагне знищити саму себе.* Була і одна маленька дощечка, на якій рясніла горизонтальна червона риска. Символи могли означати *що завгодно*. Таку пластичність їхньої образної сили навіть Бардична Змова відмовлялася визнавати вголос.

Під табличками в стіні були видряпані дві групи рисок. У колонці «плюси» стояли дві позначки, у колонці «мінуси» — п'ять. У кімнату він заходив сім разів, з яких разів зо п'ять вирішував не змінювати думку, а двічі виходив з кімнати іншою людиною. Жодних наперед визначених пропорцій чи меж — це було б чистою профанацією. Та й який сенс у кімнаті, якби у колонці «плюси» з часом не з'явилося хоча б одного плюса? Навіщо така кімната, якщо немає здібності змінювати думку або вже вродився всевідою?

Джеффріссай сів собі лицем до чистої від дощечок білісінької стіни. Нічого не мало муляти йому око.

Подумки він повторив метамнемоніку, потім перейшов до відгалужених мнемонік, а саме: сім основних принципів та шістдесят дві спеціальні техніки, без яких, найімовірніше, нікуди у ритуалі зміни думки. До всього Джеффріссай промислив ще одну, яка нагадувала йому про чотирнадцять найбільш неприємних промахів.

Він не мав звички драматично вдихати на повні груди. Краще тримати рівний вдих-видих.

Тоді він поставив собі питання.

Кінець другої книги